ADsP 제44회 기출 복원문제

유형 1

문제지 · 정답과 해설은 뒤쪽에 있습니다

총 50문항 · 4지선다 · 90분

1과목 데이터 이해 (1~10번)

1. 이용자가 원하는 정보를 신속하게 획득하기 위해 고려해야 할 데이터베이스 측면은?

① 정보 이용 측면
② 정보 관리 측면
③ 정보 기술 발전 측면
④ 사회 경제적 측면

2. 데이터 1제타바이트 크기에 해당하는 것으로 적절한 것은?

① 1024 테라바이트 (TB)
② 1024 요타바이트 (YB)
③ 1024 페타바이트 (PB)
④ 1024 엑사바이트 (EB)

3. 다음 중 데이터에 대한 설명으로 옳지 않은 것은?

① 이미지, 동영상은 비정형 데이터이다.
② 데이터에 따라 분석 방법이 달라질 수 있다.
③ HTML은 정형 데이터의 예이다.
④ 정형, 반정형, 비정형으로 구분할 수 있다.

4. 기업에서 빅데이터를 활용하는 방안으로 적절하지 않은 것은?

① 마케팅: 적합한 지점의 위치를 선정한다.
② 재무관리: 거래처 리스트를 관리한다.
③ 공급처: 적정한 재고량을 결정한다.
④ 인력관리: 이직률을 예측한다.

5. 커피를 구매한 사람이 탄산음료도 구매할지에 대한 예측을 하는 분석 기법은?

① 회귀분석
② 연관분석
③ 감정분석
④ 유전알고리즘

6. 데이터 사이언스에 대한 설명 중 틀린 것은?

① 데이터 분석부터 설명 및 결과까지 전달한다.
② 데이터를 활용하여 정보와 인사이트를 창출한다.
③ 데이터베이스 구축 자체가 데이터 사이언스의 핵심 목적이다.
④ 통계학, 데이터마이닝, 기계학습 기법을 사용한다.

7. 데이터 분석가에 대한 설명으로 가장 적절하지 않은 것은?

① 도메인 전문가가 분석에 참여하면 더 깊은 통찰을 얻을 수 있다.
② 분석가는 분석 업무와 관리 업무를 동시에 수행할 수 없다.
③ 소통 능력, 팀워크 같은 소프트 스킬을 갖추면 좋다.
④ 분석가의 역할은 코딩만 하는 것으로 한정되지 않는다.

8. 기온 변화에 따른 제품 판매량을 예측하는 데 가장 적합한 분석 방법은?

① 회귀분석
② 연관분석
③ 군집분석
④ 유전 알고리즘

9. 빅데이터 가치 산정이 어려운 이유에 대해 적절하지 않은 것은?

① 데이터를 누가, 언제 사용했는지 알기 어렵기 때문이다.
② 분석 기술의 발전으로 과거에 분석 불가했던 데이터를 분석할 수 있게 되었기 때문이다.
③ 빅데이터는 기존에 존재하지 않던 새로운 가치를 창출하기 때문이다.
④ 데이터 전문가의 증가로 데이터 분석 방법이 일반화되었기 때문이다.

10. 빅데이터의 위기에 대한 대응 방안으로 가장 적절하지 않은 것은?

① 익명화 기술을 활용해 사생활 침해 위험을 줄인다.
② 사생활 침해 통제 방안으로 동의제에서 책임제로의 전환을 검토한다.
③ 잠재적 위협 요인만으로 개인에게 불이익을 준다.
④ 알고리즘 접근을 허용해 데이터 오용으로 인한 피해를 줄인다.

2과목 데이터 분석 기획 (11~20번)

11. 상향식 접근법의 순서로 올바른 것은?

① 프로세스 분류 → 프로세스 흐름 분석 → 분석요건 식별 → 분석요건 정의
② 프로세스 분류 → 분석요건 식별 → 프로세스 흐름 분석 → 분석요건 정의
③ 프로세스 흐름 분석 → 분석요건 식별 → 분석요건 정의 → 프로세스 분류
④ 분석요건 정의 → 분석요건 식별 → 프로세스 흐름 분석 → 프로세스 분류

12. 데이터 분석 거버넌스 구성요소가 아닌 것은?

① 분석 인력 (human resource)
② 프로세스 (Process)
③ 분석 조직 (Organization)
④ 분석 기법 (Technology)

출처: ADsP CBT youneedpython.github.io/ADsP-CBT · 복원 문제로 실제 시험과 다를 수 있습니다.

13. 마스터 플랜 수립 시 우선 순위가 가장 높은 과제 선정 기준은?

① 난이도: 쉬움 / 시급성: 현재
② 난이도: 쉬움 / 시급성: 미래
③ 난이도: 어려움 / 시급성: 현재
④ 난이도: 어려움 / 시급성: 미래

14. 데이터 분석 기획 시 고려사항이 아닌 것은?

① 데이터 유형 분류
② 데이터 정합성 검증
③ 장애요소에 대한 사전 계획 수립
④ 적절한 활용 방안과 유스케이스 탐색

15. 데이터 분석 프로세스를 순서대로 나열한 것은?

① 데이터 준비 → 분석 기획 → 데이터 분석 → 시스템 구현 → 평가 및 전개
② 데이터 준비 → 데이터 분석 → 분석 기획 → 시스템 구현 → 평가 및 전개
③ 데이터 준비 → 데이터 분석 → 분석 기획 → 평가 및 전개 → 시스템 구현
④ 분석 기획 → 데이터 준비 → 데이터 분석 → 시스템 구현 → 평가 및 전개

16. CMMI 모델 기반 분석 성숙도 단계 중 도입 단계에 해당되는 것은?

① 데이터로 미래 예측
② 실적 분석 및 통계 작성
③ 분석 프로세스 내재화
④ 경영진 분석 활용

17. 상향식 접근법의 특징으로 올바른 것만 고른 것은?

가) 인사이트와 지식을 얻는 Bottom-up 접근방식이다.
나) 정확한 문제해결을 위한 프로토타이핑 접근법을 이용한다.
다) 상관관계보다 인과관계가 중요하다.
라) 데이터를 통해 패턴을 발견하고 통찰을 얻는다.

① 가, 나
② 가, 다
③ 가, 나, 다
④ 가, 나, 라

18. 데이터를 활용한 의사결정에 대한 주장으로 가장 적절한 것은?

① 도메인 지식에 의한 판단을 우선하고 데이터는 보조 역할만 한다.
② 데이터에 근거한 판단이 근거 없는 대안보다 바람직하다.
③ 시각화 같은 단순 표현은 의사결정에 큰 도움이 되지 않는다.
④ 주관과 직관을 유지하고 통계 분석은 참고용으로만 쓴다.

19. 과제 중심적 접근 방식의 데이터 분석에 대한 설명으로 옳지 않은 것은?

① 즉각적인 실행으로 성과를 도출하는 데 초점을 둔다.
② 속도와 검증(Speed & Test)을 중시한다.
③ 빠른 문제 해결(Quick-Win)을 목표로 한다.
④ 이행 과제 분석에서 과제 간 선후관계를 고려하지 않는다.

20. 전략적 통찰력이 있는 분석에 대한 설명으로 적절하지 않은 것은?

① 환경 변화에 빠르게 대응하고 새로운 기회를 찾을 수 있다.
② 분석을 많이 하는 것 자체가 핵심은 아니다.
③ 의사결정에 긍정적인 영향을 줄 수 있다.
④ 기업 내부 관점에만 한정하여 분석한다.

3과목 데이터 분석 (21~50번)

21. 스피어만 분석 방법으로 분석할 수 없는 것은?

① 명목척도
② 등간척도
③ 비율척도
④ 서열척도

22. 모집단 개체에 1, 2, 3, …, n과 같은 일련번호를 부여 후 첫 번째 표본으로부터 일정 간격으로 표본을 선택하는 추출법은?

① 단순무작위추출
② 계통추출
③ 층화추출
④ 집락추출

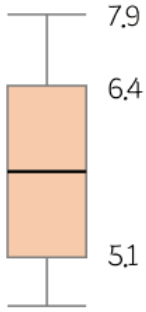
23. 연관분석의 장점이 아닌 것은?

① 조건 반응(If - then) 기반으로 분석 결과 해석이 쉽다.
② 목적변수(반응변수)가 없어도 분석할 수 있다.
③ 데이터를 변환하지 않고 그대로 사용할 수 있어 간편하다.
④ 품목 수가 증가해도 계산량이 거의 늘어나지 않는다.

24. k-NN 알고리즘의 특징 중 틀린 것은?

① 사전 학습 없이 새 데이터 분류 가능하다.
② 가까운 그룹을 찾는다.
③ 가까운 k개 데이터를 탐색한다.
④ k 개수가 클수록 과대적합 문제가 발생할 수 있다.

25. 아래 Box plot에 대한 설명 중 틀린 것은?



① 데이터 최대값은 7.9이다.
② IQR은 1.3이다.
③ 평균은 중앙값보다 항상 크다.
④ 5.1보다 작은 데이터가 약 25% 있다.

출처: ADsP CBT youneedpython.github.io/ADsP-CBT · 복원 문제로 실제 시험과 다를 수 있습니다.

26. 비모수 검정으로 적절하지 않은 것은?

① 윌콕슨 순위합 검정
② run 검정
③ 만-휘트니 검정
④ t-검정

27. 중심극한정리에 대한 설명으로 잘못된 것은?

① 표본의 크기가 커질수록 정규분포에 따른다.
② 표본 평균에 관한 설명이다.
③ 모집단이 정규분포를 따라야 한다.
④ 모집단이 비대칭일수록 표본의 크기가 커야 한다.

28. 비모수 검정에 대한 설명으로 잘못된 것은?

① 표본의 크기가 매우 작을 때 고려할 수 있다.
② 모집단이 정규분포에 가까우면 비모수 검정이 모수 검정보다 항상 더 좋다.
③ 서열척도처럼 평균·분산을 계산하기 어려운 자료에 적절할 수 있다.
④ 모집단의 분포 가정을 만족하기 어려울 때 사용할 수 있다.

29. 시계열 데이터를 정상화하는 방법 중 적절하지 않은 것은?

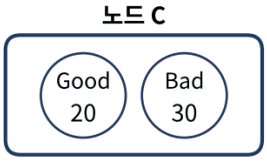
① 차분
② 로그 변환
③ 이상치 제거
④ 구간 분할

30. 다음 거래 내역에서 연관규칙 '우유 → 커피'의 신뢰도는?

거래 품목	거래 횟수
{우유, 커피, 과자}	10
{우유, 과자}	40
{커피, 과자, 캔디}	20
{우유, 커피, 캔디}	20
{과자, 캔디}	10

① 0.3
② $\frac{3}{7}$
③ 0.6
④ 0.7

31. 다음 의사결정나무 노드 C의 지니 지수로 적절한 것은?



① 0.3
② 0.32
③ 0.4
④ 0.48

32. 시계열 데이터 분석에 대한 설명으로 적절하지 않은 것은?

① 추세요인: 일정한 방향으로 상승 또는 하락하는 경향을 보이는 요인
② 계절요인: 일정한 주기를 가지는 상하 반복의 규칙적인 변동의 요인
③ 순환요인: 알려진 주기 또는 고정된 주기로 반복되는 요인
④ 불규칙요인: 설명할 수 없는 오차에 해당되는 요인

33. 아래 표는 남학생과 여학생의 선호 과일에 대한 빈도 교차표이다. 전체에서 1명을 뽑았을 때, 그 학생이 남학생인 경우 사과를 좋아할 확률은?

구분	사과	딸기
남학생	30	40
여학생	10	20

① $\frac{3}{5}$
② $\frac{7}{10}$
③ $\frac{3}{4}$
④ $\frac{3}{7}$

34. 크기가 100인 데이터에서 복원추출로 100번 뽑아 부트스트랩 표본 하나를 만들 때, 특정 데이터가 한 번도 뽑히지 않을 확률은?

① $(1/100)^{100}$
② $(1/100)^{99}$
③ $(1-1/100)^{100}$
④ $(1-(1/100)^{100})^{100}$

35. Apriori 알고리즘의 수행 순서로 올바르게 나열한 것은?

> 가. 최소 지지도를 설정한다.
> 나. 찾은 개별 품목을 이용해 2가지 품목을 찾는다.
> 다. 개별 품목 중에서 최소 지지도가 넘는 품목을 찾는다.
> 라. 반복적으로 수행하여 최소 지지도가 넘는 빈발품목집합을 찾는다.

① 가 - 나 - 라 - 다
② 가 - 다 - 나 - 라
③ 다 - 가 - 나 - 라
④ 다 - 나 - 가 - 라

36. 요약 변수의 특징 중 틀린 것은?

① 많은 모델에서 공통으로 사용할 수 있어 재활용 가능성이 높다.
② 수집된 정보를 분석에 맞게 종합한 것이다.
③ 특정조건을 만족하거나 특정 함수에 의해 값을 만들어 의미를 부여한 변수이다.
④ 데이터 마트에서 중요한 변수이다.

37. 데이터마이닝 모형 평가 기준 중 같은 모집단의 다른 데이터에 적용해도 유사한 결과가 나오는 특성은?

① 다양성
② 일반화
③ 특정화
④ 구간화

38. 회귀분석의 독립변수들 간에 강한 상관관계가 나타나는 문제를 의미하는 것은?

① 다중공선성
② 회귀계수
③ 선형계수
④ 상관계수

39. 두 변수의 상관관계가 클 때 유사도 거리를 측정하는 방법은?

① 맨하탄 거리
② 유클리드 거리
③ 표준화 거리
④ 마할라노비스 거리

40. 주성분 분석에 대한 설명으로 잘못된 것은?

① 차원 축소 기능이 있다.
② 차원 축소로 예측에도 활용이 가능하다.
③ 독립변수와 종속변수의 선형관계를 파악하기 위한 분석이다.
④ 주성분 간에는 상관관계가 없다.

41. K-means 군집분석을 활용할 수 있는 그래프는?

① 잔차 산점도
② ROC 그래프
③ 집단 내 제곱합 그래프
④ 향상도 곡선

42. 확률에 대한 설명으로 잘못된 것은?

① 두 사건이 서로 배반이면 두 사건이 동시에 일어날 확률은 0이다.
② 한 사건 A가 일어날 확률을 P(A)라 할 때, n번의 반복시행에서 A가 일어난 횟수를 r이라 하면 상대도수 r/n은 n이 커짐에 따라 P(A)에 가까워진다.
③ 조건부 확률을 이용해 사전확률로부터 사후확률을 계산하는 것은 베이즈 정리이다.
④ 두 사건이 독립이면 동시에 일어날 확률은 두 사건 확률의 합이다.

43. 회귀분석에서 개별 회귀계수의 유의성을 검정하는 t-검정의 귀무가설과 대립가설로 적절한 것은?

① H_0: 회귀계수 $\neq 0$, H_1: 회귀계수 $= 0$
② H_0: 회귀계수 $= 0$, H_1: 회귀계수 $\neq 0$
③ H_0: 상관계수 $\neq 1$, H_1: 상관계수 $= 1$
④ H_0: 회귀계수 $= 1$, H_1: 회귀계수 $\neq 1$

44. 1~100번의 서로 다른 개체에서 비복원 단순무작위추출로 10개를 뽑는다. 옳지 않은 것은?

① 1번과 100번의 표본 포함 확률은 같다.
② 1번과 2번의 동시 포함 확률은 99번과 100번의 동시 포함 확률과 같다.
③ 1번과 2번이 모두 표본에 포함될 확률은 1/100이다.
④ 각 개체의 표본 포함 확률은 10/100이다.

45. 군집분석의 적용에 대한 설명으로 옳지 않은 것은?

① 여러 과목의 점수로 학생을 군집화할 때 K-means를 활용할 수 있다.
② SOM은 고차원 관측값을 낮은 차원의 격자에 배치하는 데 활용할 수 있다.
③ 군집을 3개로 나누려면 반드시 K-means만 사용해야 한다.
④ 군집화 대상에 맞는 특징과 유사도 또는 거리를 정해야 한다.

46. job이 0 또는 1인 더미변수일 때 다음 회귀식의 해석으로 부적절한 것은? (모든 계수는 유의하다)

회귀식: wage = 5632 + 1300 × age + 3721 × job

① 두 집단(job=0, job=1)의 y절편이 다르다.
② age의 회귀계수는 두 집단에서 같다.
③ age가 1 증가할 때 wage의 증가량은 두 집단에서 같다.
④ age와 job의 교호작용이 유의하다.

47. 다음은 swiss 데이터에서 Fertility를 종속변수로 한 회귀분석 결과이다. 해석으로 부적절한 것은?

```
> summary(lm(Fertility ~ ., data = swiss))
Coefficients:
                 Estimate Std. Error t value Pr(>|t|)
(Intercept)      66.91518   10.70604   6.250 1.91e-07 ***
Agriculture      -0.17211    0.07030  -2.448  0.01873 *
Examination      -0.25801    0.25388  -1.016  0.31546
Education        -0.87094    0.18303  -4.758 2.43e-05 ***
Catholic          0.10412    0.03526   2.953  0.00519 **
Infant.Mortality  1.07705    0.38172   2.822  0.00734 **
Residual standard error: 7.165 on 41 degrees of freedom
Multiple R-squared:  0.7067,  Adjusted R-squared:  0.671
F-statistic: 19.76 on 5 and 41 DF,  p-value: 5.594e-10
```

① 잔차 자유도와 독립변수 수로 보아 데이터 개수는 46개이다.
② 모든 회귀계수가 유의수준 5%에서 유의한 것은 아니다.
③ 다른 변수가 같을 때 Agriculture가 증가하면 Fertility는 감소한다.
④ 조정결정계수(Adjusted R-squared)는 0.671이다.

48. 로지스틱 회귀모형 $\log\dfrac{P}{1-P} = \beta_0 + \beta_1 X_1 + \beta_2 X_2$에서 $e^{\beta_1} = 1.006$, $e^{\beta_2} = 0.489$일 때, X_2가 1 증가할 때의 해석으로 가장 적절한 것은? (P는 Y=1일 확률)

① 다른 변수가 일정할 때 Logit이 48.9% 감소한다.
② 다른 변수가 일정할 때 Logit이 48.9% 증가한다.
③ 다른 변수가 일정할 때 Odds가 0.489배가 된다.
④ 다른 변수가 일정할 때 Odds가 48.9% 증가한다.

49. **계층적 군집분석에서 군집 수를 결정하는 방법에 대한 설명으로 가장 적절한 것은?**

① 와드 연결법에서 오차제곱합이 크게 증가하는 지점을 참고할 수 있다.

② 단일 연결법이 군집 간 거리를 항상 최적으로 결정한다.

③ 중심 연결법이 모든 상황에서 가장 유리하다.

④ 군집 수는 항상 2~3개로 정하는 것이 가장 좋다.

50. **다음 거래 내역에서 연관규칙 'X → Y'의 향상도(Lift)는?**

거래	품목
거래 1	{X, Y, Z}
거래 2	{X, Y, W}
거래 3	{X, R}
거래 4	{Y, Z}
거래 5	{X, Y, Z, W}
거래 6	{R}

① $\frac{9}{8}$

② $\frac{8}{9}$

③ $\frac{7}{8}$

④ $\frac{8}{7}$

정답

1	①	6	③	11	①	16	②	21	①	26	④	31	④	36	③	41	③	46	④
2	④	7	②	12	④	17	④	22	②	27	③	32	③	37	②	42	④	47	①
3	③	8	①	13	①	18	②	23	④	28	②	33	④	38	①	43	②	48	③
4	②	9	④	14	②	19	④	24	④	29	④	34	③	39	④	44	③	49	①
5	②	10	③	15	④	20	④	25	③	30	②	35	②	40	③	45	③	50	①

해설

1. 정답 ①

이용자가 원하는 정보를 신속하게 획득한다는 목적이므로 ① 정보 이용 측면이다. 자료를 관리하는 내부 절차나 관련 기술 산업의 발전을 묻는 질문이 아니다.

핵심 개념: 데이터베이스는 저장된 정보를 찾고 활용할 수 있게 하는 체계이다. 교재의 정보 이용 측면은 이용자가 필요한 자료를 적시에 찾아 활용하는 특성을 설명한다.

보기 검토: ②는 자료 관리 기능과 운영, ③은 하드웨어·소프트웨어·네트워크 등의 기술 발전, ④는 사회·경제에 미치는 효과에 초점이 있다.

학습 포인트: 같은 데이터베이스라도 관점에 따라 설명 대상이 달라진다. 고객지원 담당자가 주문을 조회해 문의에 답하는 상황은 이용 관점이고, 관리자가 백업·접근 권한을 점검하는 것은 관리 관점이다. 지문의 주체가 이용자인지 관리자인지 먼저 확인한다.

2. 정답 ④

교재에서 단계마다 1024배라고 설명한 관행을 적용하면 ④를 의도한 것으로 읽는다. 그러나 표준 십진 단위에서는 $1\,ZB = 10^{21}$ byte이고 $1\,EB = 10^{18}$ byte이므로 $1\,ZB = 1000\,EB$이다. 1024배 관계는 1 ZiB=1024 EiB라는 이진 단위 표기로 표현한다.

핵심 개념: 데이터 크기 단위의 순서는 KB→MB→GB→TB→PB→EB→ZB→YB이다. 제타는 엑사보다 한 단계 크다. 다만 십진 SI 접두어와 이진 접두어를 구별해야 한다.

보기 검토: ①③은 TB·PB로 단계가 다르고 ②는 ZB보다 큰 YB를 써 방향이 반대이다. ④도 ZB와 EB를 엄밀한 십진 단위로 읽으면 정확하지 않다.

학습 포인트: 시험에서는 교재 관행대로 단계마다 1024배로 계산한다. 엄밀한 표준 표기는 1 ZiB=1024 EiB(이진), 1 ZB=1000 EB(십진)이지만 출제 의도는 단위 순서이다.

3. 정답 ③

HTML은 태그로 문서 구조를 표현하는 대표적인 반정형 자료이므로 정형이라고 한 ③이 틀리다. ①의 이미지·동영상은 내용 기준으로 일반적으로 비정형이며 ②④는 적절하다.

핵심 개념: 정형은 고정된 스키마와 행·열 구조를 갖는 자료, 반정형은 태그·키 같은 구조 단서를 포함하지만 고정 관계형 표와는 다른 자료, 비정형은 내용 자체가 고정된 필드 구조로 바로 표현되지 않는 자료이다.

보기 검토: 분석 방법은 숫자·텍스트·영상 등 자료의 형태와 목표에 따라 달라질 수 있다. 형식 구분은 숫자인지 문자인지만으로 정하지 않는다.

학습 포인트: 웹페이지의 표를 추출해 행·열 데이터로 변환할 수 있어도 원래 HTML 문서의 분류까지 정형으로 바뀌는 것은 아니다. 파일 형식, 담긴 내용, 분석을 위해 변환한 표현을 나누어 생각한다.

4. 정답 ②

②의 거래처 리스트 관리는 기본적인 자료 관리이므로 다른 보기의 예측·최적화와 구별되는 답이다. 재무 업무에는 부도 위험 예측, 이상 거래 탐지 등 분석 활용이 가능하다.

핵심 개념: 빅데이터 활용은 자료를 분석하여 패턴을 찾고 예측·최적화·의사결정에 연결하는 활동이다. 자료를 보관하거나 목록을 관리하는 활동만으로 분석 활용 사례가 충분히 설명되지는 않는다.

보기 검토: ①은 위치와 수요를 이용한 입지 선정, ③은 수요와 공급을 이용한 재고 결정, ④는 인력 자료를 이용한 이직 가능성 예측이다.

학습 포인트: 거래처 자료를 분석해 신용 위험이나 거래 패턴을 평가한다면 빅데이터 활용 사례가 될 수 있다. 이 보기는 분석 목적 없이 목록을 관리하는 활동이라 다른 보기와 구별된다.

5. 정답 ②

커피 구매와 탄산음료 구매의 동시 발생 관계를 묻는 장바구니 분석 문맥이므로 ②가 가장 적합하다. 커피 구매자의 음료 조합을 거래 단위로 살펴볼 수 있다.

핵심 개념: 연관분석은 거래 안에서 함께 발생하는 항목의 관계를 찾는다. A→B 규칙에서는 A를 포함한 거래 중 B도 포함하는 비율을 신뢰도로 평가할 수 있다.

보기 검토: ① 회귀는 설명변수와 반응변수의 관계를 모델링하고, ③ 감정분석은 문장 등의 감정·의견을 분류한다. ④ 유전자 알고리즘은 후보 조합을 탐색하는 최적화 방법이다.

학습 포인트: 특정 구매자의 구매 여부를 목표변수로 명시하면 별도의 분류모형을 설계할 수도 있다. 이 문항은 상품끼리 함께 구매되는 규칙을 묻는 취지이다. 규칙의 화살표는 인과관계를 증명하는 것이 아니며 지지도·신뢰도·향상도를 함께 검토한다.

6. 정답 ③

③은 데이터베이스 구축 자체를 핵심 목적으로 보아 틀리다. 데이터 사이언스의 핵심은 데이터에서 의미 있는 정보와 인사이트를 얻어 가치를 만드는 것이며, 저장 체계 구축은 이를 위한 기반이다.

핵심 개념: 데이터 사이언스는 자료의 수집·처리·분석·모델링·해석·결과 전달 등을 연결해 문제를 해결하는 분야이다. 통계와 컴퓨터 과학, 업무 지식을 함께 활용한다.

보기 검토: ①은 분석 결과의 설명·전달, ②는 정보와 인사이트 창출, ④는 통계학·데이터마이닝·기계학습 등 활용 기법을 설명하므로 적절하다.

학습 포인트: 데이터 사이언스는 분석 기술뿐 아니라 결과를 이해관계자에게 전달하는 커뮤니케이션까지 포함한다.

7. 정답 ②

분석과 관리 업무를 동시에 수행할 수 없다고 단정한 ②가 틀리다. 분석 조직의 리더나 프로젝트 관리자가 분석 업무를 함께 수행하는 경우는 흔하다.

핵심 개념: 데이터 분석가는 업무 문제를 이해하고 분석 결과를 이해관계자와 소통하며, 필요하면 프로젝트 관리나 리더 역할도 함께 맡는다.

보기 검토: ①은 업무 지식(도메인)의 중요성, ③은 소프트 스킬, ④는 코딩 이외의 문제 정의·해석·전달 역할을 설명하므로 적절하다.

학습 포인트: 데이터 사이언티스트에게는 하드 스킬(이론 지식, 분석 기술)과 소프트 스킬(통찰력, 설득력 있는 전달, 협력)이 모두 요구된다.

8. 정답 ①

기온에 따른 판매량이라는 수치를 예측하므로 ① 회귀분석이 적합하다. 단순선형 모형이라면 $\hat{y} = b_0 + b_1 \times$ 기온으로 표현한다.

핵심 개념: 회귀분석은 설명변수와 수치형 반응변수의 관계를 모형으로 만들어 값을 예측한다. 기온을 설명변수 X, 판매량을 반응변수 Y로 둔다.
보기 검토: ② 연관분석은 함께 발생하는 항목의 규칙, ③ 군집분석은 비슷한 대상의 묶음, ④ 유전 알고리즘은 최적 조합 탐색에 쓰인다.
학습 포인트: 기온과 판매량 사이 상관이 있어도 인과관계가 자동으로 증명되지는 않는다. 가격·행사·요일 등 다른 요인도 함께 검토한다.

9. 정답 ④

전문가 증가와 분석 방법의 일반화라는 ④는 이 문항에서 가치 측정이 어려워지는 직접적인 대표 이유가 아니다. 다른 보기는 활용의 불확실성, 기술 변화, 새로운 가치 창출에 연결된다.

핵심 개념: 데이터 가치는 활용 주체와 시점, 분석 기술, 다른 자료와의 결합 방식에 따라 달라진다. 미래의 사용처와 새로운 가치가 모두 정해져 있지 않아 일정한 금액으로 평가하기 어렵다.
보기 검토: ①은 누가 어떤 방식으로 활용할지 예측하기 어려운 점, ②는 기술 발전으로 과거 자료의 활용 가능성이 달라지는 점, ③은 기존 평가 기준이 포착하지 못하는 가치가 생기는 점을 설명한다.
학습 포인트: 데이터의 저장 비용이나 수집 비용이 곧 활용 가치와 같지는 않다. 같은 거래 자료도 재고 최적화와 고객 분석에서 다른 성과를 만들 수 있다. 비용과 가치, 현재 활용과 미래 잠재 활용을 구별한다.

10. 정답 ③

예측된 잠재적 위협만으로 개인에게 불이익을 주는 것은 책임 원칙 훼손 그 자체이다. 실제 행동 결과를 기준으로 책임을 묻는 결과 기반 책임 원칙에 어긋나므로 ③이 부적절하다.

핵심 개념: 빅데이터의 위기 요인과 통제 방안은 사생활 침해→동의제에서 책임제로 전환, 책임 원칙 훼손→결과 기반 책임 원칙 고수, 데이터 오용→알고리즘 접근 허용으로 짝지어진다.
보기 검토: ①은 사생활 침해 위험을 낮추는 기술적 보호 조치, ②는 사생활 침해에 대한 통제 방안, ④는 데이터 오용에 대한 통제 방안이다.
학습 포인트: 익명화도 다른 자료와 결합하면 재식별 위험이 남으므로 위험을 '줄인다'는 표현이 적절하다.

11. 정답 ①

먼저 프로세스를 분류하고 흐름을 분석한 뒤 분석요건을 식별하고 정의하므로 ①이다. 구조와 흐름을 이해하지 않고 요건을 정의하거나 분류를 마지막에 놓는 배열은 기본 순서와 맞지 않는다.

핵심 개념: 상향식 접근법에서 분석 과제를 도출할 때는 업무 프로세스를 분류하고, 프로세스 흐름을 분석한 뒤, 분석이 필요한 요건을 식별하고 정의하는 순서로 진행한다.
보기 검토: ②는 흐름 분석 전에 요건 식별을 배치했고, ③은 분류를 마지막에, ④는 정의를 가장 먼저 놓았다. 탐색에서 구체화로 이어지는 흐름을 확인한다.
학습 포인트: 프로세스 분류(가치사슬·메가·메이저 프로세스) → 흐름 분석(프로세스 맵) → 요건 식별(의사결정 지점) → 요건 정의 순서로 외운다. 하향식의 문제 탐색→문제 정의→해결방안 탐색→타당성 검토와 구별한다.

12. 정답 ④

교재의 구성요소 구분에서는 ④ 분석 기법이 나머지 인력·프로세스·조직과 구별되는 답이다. 이는 기술이 분석 거버넌스에 전혀 필요 없다는 뜻이 아니다. 분석 인프라 등의 기술 기반은 별도로 다룰 수 있다.

핵심 개념: 분석 거버넌스는 분석을 지속적으로 수행하고 활용하도록 조직·인력·프로세스·관련 기반과 관리 체계를 연결한다. 개별 알고리즘의 이름과 전사 운영 체계는 같은 수준의 항목이 아니다.
보기 검토: ①은 전문성과 역할, ②는 수행 절차와 관리 흐름, ③은 책임과 협업 구조에 해당한다. ④의 영어 Technology와 한국어 분석 기법의 범위가 완전히 같지 않다는 점도 유의한다.
학습 포인트: 분석 거버넌스 체계의 구성요소는 조직(Organization), 과제 기획·운영 프로세스(Process), 분석 관련 시스템(System), 데이터(Data), 분석 관련 교육·마인드 육성 체계(Human Resource)이다. 데이터 거버넌스와 혼동하지 않는다.

13. 정답 ①

현재라는 높은 시급성과 쉬움이라는 낮은 난이도를 가진 ①이 제시된 비교에서 우선순위가 가장 높다. 같은 시급성이라면 실행 가능한 과제를, 같은 난이도라면 더 급한 과제를 우선 검토하는 취지이다.

핵심 개념: 과제 우선순위는 시급성과 난이도 등을 함께 고려하여 정한다. 지금 해결해야 하고 실행 부담이 낮은 과제는 빠른 성과를 얻기 위한 우선 후보가 된다.
보기 검토: ②는 쉬워도 미래 과제이고, ③은 급하지만 난도가 높으며, ④는 미래이면서 어렵다. 시급성과 난이도 한 축만 보지 않는다.
학습 포인트: 실제 사업에서는 법적 의무, 전략적 효과, 선행과제, 비용과 위험 등으로 순서가 달라질 수 있다. 쉬운 과제만 계속 수행하라는 원칙은 아니다. 이 문항은 두 기준만 제시한 교재상의 기본 비교로 해석한다.

14. 정답 ②

교재의 분석 기획 고려사항(가용 데이터 고려, 적절한 유스케이스 탐색, 장애요소에 대한 사전 계획 수립)과 비교하면 ② 데이터 정합성 검증을 상세한 자료 검증 작업으로 보아 나머지 대표 기획 고려사항과 구별한다. 정합성 검증이 필요 없거나 기획 중 품질 위험을 살피면 안 된다는 뜻이 아니다.

핵심 개념: 기획에서는 자료 유형과 확보 가능성, 활용 목적, 유스케이스, 수행 장애와 대안을 검토한다. 자료의 정합성과 품질도 중요하지만 구체적인 검증 수행은 준비·분석 단계의 작업과 구분될 수 있다.
보기 검토: ①은 가용 데이터의 유형을 파악하는 고려사항이다. ③은 실행 장애에 대비하는 계획, ④는 분석 결과의 적용 목적과 사례 탐색이다.
학습 포인트: 기획에서 품질 위험과 검증 계획을 정하는 일, 준비 단계에서 실제 자료를 검사하는 일은 연결되어 있다. 단계 구분 문제를 실제 업무의 엄격한 금지 규칙으로 확대하지 않는다.

15. 정답 ④

④가 이 순서를 따른다. 자료를 먼저 준비한 뒤 목적을 정하는 다른 보기와 달리 분석 기획이 출발점이다. 사용할 방법보다 해결할 업무 문제를 먼저 명확히 한다.

핵심 개념: 빅데이터 분석 방법론은 분석 기획→데이터 준비→데이터 분석→시스템 구현→평가 및 전개의 흐름이다. 문제와 목표를 정한 뒤 자료와 모형을 마련하고 적용·평가한다.
보기 검토: ①②③은 기획을 준비 또는 분석 뒤에 놓고, ③은 시스템 구현보다 평가·전개를 먼저 배치했다. 기본 단계의 선후관계와 맞지 않는다.
적용 예: 고장 예측 목표를 정하고 센서 자료를 준비한 뒤 모형을 학습하며, 운영 시스템에 연결하고 성능과 업무 효과를 평가한다. 실제로는 평가 결과에 따라 앞 단계로 돌아갈 수 있다. CRISP-DM의 여섯 단계 명칭과 현재 다섯 단계를 혼합하지 않는다.

16. 정답 ②

기초 현황을 집계하는 ②가 도입 단계에 대응한다. 미래 예측이나 경영진의 광범위한 활용, 프로세스 내재화는 상대적으로 발전된 상태의 설명이다.

핵심 개념: 분석 성숙도에서 도입 단계는 기초적인 실적 분석과 통계 작성부터 분석 활용을 시작하는 단계로 설명한다. 이후 예측 활용, 조직 전반 확산, 프로세스 내재화와 지속 개선으로 발전한다.
보기 검토: ①은 예측 활용, ③은 분석을 업무 프로세스에 정착시키는 상태, ④는 관리·의사결정 활용을 뜻한다. 제시된 활동 수준을 비교한다.
학습 포인트: CMMI 자체의 Initial·Managed 등 단계 명칭과 ADsP 교재의 도입·활용·확산·최적화라는 분석 성숙도 명칭은 동일하지 않다. 기반을 참고한 진단 체계라는 맥락으로 이해하고 CMMI의 세부 단계 번호와 이 문항의 답을 직접 같은 것으로 연결하지 않는다.

17. 정답 ④

가의 Bottom-up, 나의 프로토타이핑, 라의 데이터에서 패턴 발견이 적절하므로 ④이다. 다의 인과관계가 상관관계보다 중요하다는 설명은 상향식 탐색의 대표 강조점과 맞지 않는다.

핵심 개념: 상향식 접근은 명확한 문제를 먼저 고정하기보다 자료 탐색으로 패턴과 통찰을 발견하고 문제를 구체화하는 흐름이다. 프로토타입을 만들어 반복 확인하는 방식이 활용될 수 있다.
보기 검토: ①은 라를 빠뜨렸고, ②③은 다를 포함한다. 프로토타이핑은 자료와 문제를 구체화하며 반복하는 것이지 처음부터 정확한 해답을 보장하는 방법이 아니다.
학습 포인트: 상향식이 상관 패턴을 탐색한다고 인과관계가 중요하지 않다는 뜻은 아니다. 탐색 목적과 최종 인과적 의사결정에 필요한 증거는 다를 수 있다. 발견된 관계를 추가 검증 없이 원인이라고 결론내리지 않는다.

18. 정답 ②

데이터에 근거한 판단이 근거 없는 대안보다 바람직하다는 ②가 적절하다.

핵심 개념: 데이터 기반 의사결정은 직관이나 경험만이 아니라 자료와 분석 결과를 근거로 판단하는 것이다. 분석 결과와 업무 지식을 함께 사용하되 근거가 있는 판단을 우선한다.
보기 검토: ①④는 데이터를 보조·참고 수준으로 낮추어 데이터 기반 의사결정의 취지와 맞지 않는다. ③은 시각화가 패턴을 빠르게 전달해 의사결정을 돕는다는 점을 부정하여 틀리다.
학습 포인트: 데이터 기반이라도 자료의 품질·편향을 점검해야 한다. 데이터가 있다고 판단이 자동으로 옳아지는 것은 아니다.

19. 정답 ④

과제를 빠르게 수행하더라도 이행 과제를 분석할 때는 데이터 확보·기반 구축처럼 먼저 끝나야 하는 선행 과제와의 관계를 따져 실행 순서를 정한다. 선후관계를 고려하지 않는다는 ④가 틀리다.

핵심 개념: 과제 중심적 접근 방식은 당면한 과제를 빠르게 해결해 즉각적인 성과를 얻는 방식으로 Speed & Test, Quick-Win을 중시한다. 장기적인 마스터플랜 방식은 Accuracy & Deploy, 문제 해결을 위한 장기적 관점을 중시한다.
보기 검토: ①②③은 과제 중심적 접근의 특징이다.
학습 포인트: 마스터플랜의 우선순위 결정에는 시급성·난이도 외에 과제 간 선후관계(의존성)도 반영한다.

20. 정답 ④

기업 내부 관점에만 한정하면 시장과 경쟁 환경의 변화를 놓치므로 ④가 적절하지 않다.

핵심 개념: 전략적 통찰력이 있는 분석은 사업 성과를 좌우하는 핵심 요인에 집중하여 경쟁 우위와 차별화의 기회를 찾는 분석이다. 고객·경쟁사·시장 같은 외부 환경까지 함께 본다.
보기 검토: ①은 환경 변화 대응과 기회 발굴, ②는 분석의 양보다 통찰의 질이 중요하다는 점, ③은 의사결정에 미치는 긍정적 영향을 설명한다.
학습 포인트: 일차원적인 분석(부서 단위의 반복 업무 분석)을 넘어 전략적 통찰로 나아가야 사업 성과에 기여한다.

21. 정답 ①

명목척도에는 범주 간 의미 있는 순서가 없으므로 ①을 선택한다. 지역이나 혈액형에 임의의 숫자 코드를 붙여도 그 숫자 순서가 의미 있는 순위가 되지는 않는다.

핵심 개념: 스피어만 상관은 원 자료를 순위로 바꾸어 단조 관계를 평가한다. 순서가 있는 자료 또는 수치 자료를 순위화하여 활용할 수 있다.
보기 검토: ④ 서열척도는 순위가 있으며, ② 등간·③ 비율척도의 수치도 순위로 바꿀 수 있다. 동순위가 있으면 보통 평균 순위 등 적절한 처리를 반영한다.
학습 포인트: 스피어만을 범주형 자료 전체에 적용하는 것으로 외우지 않는다. 순서형 범주와 순서 없는 명목 범주를 구분한다. 수치 자료에 피어슨만 사용할 수 있는 것도 아니다. 스피어만은 모든 비선형 관계가 아니라 증가·감소 방향이 일관된 단조 관계에 적합하다.

22. 정답 ②

일련번호를 부여하고 첫 표본 이후 일정 간격으로 선택한다는 지문은 ② 계통추출이다. 적절한 확률표집을 위해 첫 시작점의 무작위 선택도 포함하여 이해한다.

핵심 개념: 계통추출은 모집단 목록에서 무작위 시작점을 정하고 일정 간격마다 표본을 뽑는다. 목록의 순서와 추출 간격에 주기적 관계가 있는지 살펴야 한다.
보기 검토: ① 단순무작위는 가능한 표본을 같은 확률로 선택하는 방식, ③ 층화는 층별 표본 선택, ④ 집락은 집단 단위를 선택하는 방식이다.
계산 예: 1000명 중 100명을 간격 10으로 뽑는다면 1~10 중 시작점을 무작위로 선택해 이후 10명마다 뽑는다. 예시는 원리를 설명하기 위한 값이다. 첫 개체를 항상 1번으로 고정하는 방식과 구별한다.

23. 정답 ④

품목 수가 늘어나면 가능한 항목 조합이 기하급수적으로 증가해 계산량이 크게 늘어나는 것이 연관분석의 대표적인 단점이다. 계산량이 거의 늘지 않는다는 ④는 장점이 아니라 틀린 설명이다.

핵심 개념: 연관분석은 거래 항목의 동시 발생을 If-then 규칙으로 표현하며 별도의 목적변수 없이 빈발항목과 규칙을 찾는다(비지도 학습).
보기 검토: ①은 해석이 쉬운 규칙 형태, ②는 목적변수 없이 탐색 가능, ③은 거래 자료를 그대로 쓸 수 있는 간편함으로 모두 장점이다.
학습 포인트: 연관분석의 단점은 품목 수 증가에 따른 계산량 증가, 거래가 적은 품목의 규칙 발견이 어려움 등이다. 유사 품목을 묶어(일반화) 계산량을 줄이는 방법을 함께 기억한다.

24. 정답 ④

일반적으로 K가 작을수록 국소 잡음에 민감해 과적합 위험이 커지고, K가 매우 크면 평균적인 판단으로 치우쳐 과소적합할 수 있다. 따라서 K가 커질수록 과대적합이라는 ④는 대표 경향을 뒤집었다.

핵심 개념: K-NN은 학습 관측값을 저장해 두고 새 관측값과 가까운 K개 이웃의 라벨이나 값을 이용한다. 복잡한 모수를 미리 적합하는 대신 예측 시 거리 탐색을 수행하는 지연학습의 대표 예이다.
보기 검토: ①은 자료 준비나 저장이 전혀 필요 없다는 뜻이 아니라 별도의 모수 학습이 적다는 취지이다. ②③은 가까운 이웃을 찾는 작동 방식이다.
학습 포인트: $K = 1$이면 한 이웃의 영향이 매우 크다. K를 키우면 경계가 보통 부드러워지지만 최적값은 검증으로 정한다. 거리 척도, 표준화, 불균형 라벨, 동률 처리에도 결과가 영향을 받는다.

25. 정답 ③

상자그림에는 평균이 표시되지 않으며, 평균과 중앙값의 크기 관계는 분포 모양에 따라 달라진다. '항상 크다'고 단정한 ③이 틀리다.

자료 확인: 상자 아래 경계가 $Q_1 = 5.1$, 위 경계가 $Q_3 = 6.4$, 위 수염 끝이 7.9로 표시되어 있다. 중앙선은 중앙값이며 평균을 표시하는 별도 기호는 없다.
계산 과정: $IQR = Q_3 - Q_1 = 6.4 - 5.1 = 1.3$이므로 ②는 맞다. Q1은 아래쪽 약 25%의 경계이므로 ④는 대략적인 사분위수 설명이다. 경계의 중복값과 계산법에 따라 정확히 25%가 아닐 수 있다.
보기 검토: ①의 7.9는 표시된 이상치가 없으므로 위 수염 끝을 최대값으로 읽는다. 일반 상자그림의 수염 끝은 이상치가 있으면 최대값이 아닐 수 있다.

26. 정답 ④

일반적인 t-검정은 평균에 대한 모수적 검정이므로 ④이다. ① 윌콕슨 순위합과 ③ 만-휘트니는 두 독립 집단의 순위에 기반한 대표 비모수 검정이고, ② runs 검정은 배열의 무작위성 등을 살핀다.

핵심 개념: 비모수 검정은 특정한 정규분포 모형의 모수 검정에 한정하지 않고 순위·부호·배열 등의 정보를 활용한다. 아무 가정도 필요 없는 검정이라는 뜻은 아니다.
보기 검토: 순위합 검정과 만-휘트니 검정은 통상 밀접하게 대응하는 두 표현이다. 대응 자료에 사용하는 윌콕슨 부호순위 검정과도 구별한다.
학습 포인트: 자료가 비정규라는 이유만으로 모든 검정 목적이 동일해지는 것은 아니다. 평균 차이, 분포 차이, 무작위성 중 무엇을 검정하는지 먼저 정한다. 비모수 검정도 표본 독립성이나 분포 모양 등 해석에 필요한 조건을 확인한다.

27. 정답 ③

모집단이 반드시 정규분포여야 한다는 ③은 틀리다. 모집단이 비정규여도 조건을 만족하고 표본이 충분히 크면 표본평균에 정규근사를 적용할 수 있다.

핵심 개념: 독립·동일분포 표본이 유한한 평균 μ와 분산 σ^2를 갖는 대표 조건에서, 표본 크기 n이 커지면 표준화한 표본평균의 분포가 정규분포로 가까워진다. 원래 개별 관측값의 분포가 정규로 바뀌는 것은 아니다.

보기 검토: ①은 표본평균의 표집분포를 뜻하는 것으로 보완해 읽고, ②는 대상이 표본평균임을 설명한다. ④는 비대칭이나 두꺼운 꼬리가 있으면 근사에 더 큰 표본이 필요할 수 있다는 일반적 경향이다. 고정된 $n = 30$이 모든 경우에 충분한 것은 아니다.

학습 포인트: $E(\bar{X}) = \mu$, $Var(\bar{X}) = \sigma^2/n$이므로 표본평균의 표준오차는 $\sigma/\sqrt{n}$이다. 표본평균의 분포에 관한 정리이며 개별 관측값의 분포가 정규로 바뀌는 것은 아니다.

28. 정답 ②

모집단이 정규분포를 따르면 모수 검정(t-검정 등)이 정보를 더 많이 활용해 검정력이 높다. 비모수 검정이 항상 더 좋다는 ②가 틀리다.

핵심 개념: 비모수 검정은 모집단 분포에 대한 가정(예: 정규성)이 없거나 약할 때 순위·부호 등을 이용해 검정한다. 부호 검정, 윌콕슨 검정, 만-휘트니 검정, 런 검정 등이 있다.

보기 검토: ①은 표본이 작아 분포를 확인하기 어려운 경우, ③은 순서만 의미 있는 서열척도 자료, ④는 분포 가정을 만족하지 못하는 경우로 모두 비모수 검정을 고려하는 상황이다.

학습 포인트: 비모수 검정도 관측값의 독립성 등 기본 조건은 필요하다. 아무 가정이 없는 검정이라는 뜻이 아니다.

29. 정답 ④

구간 분할은 연속형 변수를 범주로 나누는 전처리이며 시계열의 추세나 분산 변화를 제거하지 못하므로 ④가 적절하지 않다.

핵심 개념: 정상성은 평균·분산·시차별 공분산이 시간에 따라 일정한 성질이다. 비정상 시계열은 평균이 일정하지 않으면 차분, 분산이 일정하지 않으면 로그 등의 변환을 하고, 이상치가 있으면 처리해 정상화한다.

보기 검토: ① 차분은 평균의 추세를, ② 로그 변환은 분산의 변화를 안정시킨다. ③ 이상치 제거도 정상성 확보를 위한 전처리로 쓰인다.

학습 포인트: 정상성(stationarity), 정규성(normality), 정규화(normalization)는 서로 다른 개념이다.

30. 정답 ②

우유 포함 거래는 $10 + 40 + 20 = 70$건, 우유와 커피를 함께 포함한 거래는 $10 + 20 = 30$건이다. 신뢰도 $= 30/70 = 3/7 \approx 0.43$이므로 ②이다.

핵심 개념: 우유→커피 신뢰도는 우유를 포함한 거래 중 커피도 포함한 거래의 비율로 $P(\text{커피}|\text{우유}) = \dfrac{P(\text{우유} \cap \text{커피})}{P(\text{우유})}$이다.

보기 검토: ① 0.3은 전체 100건 중 동시 구매 30건으로 계산한 지지도이다. ③ 0.6은 커피 포함 50건 중 동시 구매 30건으로 계산한 역방향(커피→우유) 신뢰도이다. ④ 0.7은 우유 포함 거래의 비율 P(우유)이다.

학습 포인트: 지지도·신뢰도·향상도는 분모가 다르다. 향상도는 신뢰도 3/7을 $P(\text{커피}) = 0.5$로 나눈 $6/7 \approx 0.86$으로 1보다 작아 음의 연관이다.

31. 정답 ④

노드 C에는 Good 20개, Bad 30개로 전체 50개이다. 지니 지수 $= 1 - (20/50)^2 - (30/50)^2 = 1 - 0.16 - 0.36 = 0.48$이므로 ④이다.

핵심 개념: 분류나무의 지니 지수(불순도)는 $1 - \sum p_k^2$이며 노드 안에 범주가 얼마나 섞여 있는지 나타낸다.

보기 검토: 이진 분류에서는 $2p(1-p) = 2 \times 0.4 \times 0.6 = 0.48$로도 검산할 수 있다. 지니 지수는 한 범주만 있으면 0, 두 범주가 반씩 섞이면 최댓값 0.5이다.

학습 포인트: 경제학의 지니계수와 이름이 비슷하지만 다른 지표이다. 0.48은 분류 정확도 48%를 뜻하지 않는다.

32. 정답 ③

알려진 또는 고정 주기로 반복한다고 설명한 ③은 계절요인에 가까운 성격을 순환요인으로 연결했으므로 틀리다. 순환은 반복적 흐름이 있어도 주기 길이가 반드시 고정되어 있지는 않다.

핵심 개념: 추세는 장기적인 증가·감소, 계절은 정해진 주기의 반복, 순환은 경기 변동처럼 주기 길이와 진폭이 일정하지 않은 변동, 불규칙은 다른 성분으로 설명되지 않는 변동이다.

보기 검토: ①은 추세, ②는 계절, ④는 설명되지 않는 나머지 변동의 기본 정의와 맞다. 매년 같은 계절의 수요와 경기 확장·수축을 같은 종류로 묶지 않는다.

학습 포인트: 단순히 오르내린다는 사실만으로 계절성을 판정하지 않는다. 반복 주기, 장기 흐름, 설명 가능한 원인을 살핀다. 분해 방법에 따라 가법 모형 $Y = T + S + C + I$ 또는 곱셈형 구조를 고려할 수 있지만 이 문제는 요인 이름과 설명의 대응을 묻는다.

33. 정답 ④

$P(\text{사과}|\text{남학생}) = \dfrac{30}{30+40} = \dfrac{30}{70} = \dfrac{3}{7}$이므로 ④이다. 다른 보기의 3/4는 $30/(30+10)$으로 사과 선호자 중 남학생 비율을 계산한 역조건이다.

핵심 개념: 조건부확률은 이미 주어진 조건에 해당하는 집단으로 분모를 제한한다. 남학생이라는 조건이 주어졌으므로 전체 학생 수가 아니라 남학생 수를 기준으로 한다.

자료 확인: 표에서 남학생은 사과 30명, 딸기 40명으로 전체 70명이다. 여학생은 사과 10명, 딸기 20명이나 분모에 포함하지 않는다.

학습 포인트: P(A|B)와 P(B|A)는 일반적으로 다르다. 남학생이며 사과를 좋아할 전체 기준 확률은 $30/100 = 0.3$으로 또 다른 값이다. 문제에서 '남학생인 경우'를 확인한 뒤 행의 합을 분모로 정한다. 표에 포함된 범주가 서로 배타적인 응답이라는 조건에서 해석한다.

34. 정답 ③

100번의 추출이 서로 독립이므로 한 번도 뽑히지 않을 확률은 $(1 - 1/100)^{100} = (99/100)^{100} \approx 0.366$이고 ③이다.

핵심 개념: 부트스트랩은 크기 n인 자료에서 복원추출로 n개를 뽑아 표본을 만든다. 한 번 뽑을 때 특정 데이터가 선택되지 않을 확률은 1−1/n이다.

보기 검토: ①은 100번 모두 뽑힐 확률, ②는 근거 없는 식이며, ④도 '한 번도 뽑히지 않음' 사건과 구조가 맞지 않는다.

학습 포인트: n이 커지면 $(1 - 1/n)^n$은 $e^{-1} \approx 0.368$에 가까워진다. 그래서 부트스트랩 표본에는 원자료의 약 63.2%가 포함되고, 뽑히지 않은 약 36.8%(OOB 자료)는 랜덤포레스트 등에서 검증에 쓰인다.

35. 정답 ②

가에서 기준 설정, 다에서 빈발 1항목 찾기, 나에서 2항목 후보 구성·검토, 라에서 반복하여 더 큰 빈발집합 탐색이므로 ②이다. 기준을 정하기 전에 빈발 여부를 판정할 수 없다.

핵심 개념: Apriori는 빈발집합의 모든 부분집합도 빈발이라는 성질을 이용하여 후보 조합을 가지치기한다. 최소 지지도 조건을 먼저 정하고 단일 항목부터 크기를 늘린다.

보기 검토: ①은 단일 항목 검토보다 두 항목 탐색을 앞세우고, ③④는 최소 지지도 설정을 뒤로 배치해 기본 순서와 맞지 않는다. 후보를 생성했다고 모두 빈발이 되는 것은 아니며 거래 자료에서 실제 지지도를 계산한다.

학습 포인트: {A,B}가 비빈발이면 이를 포함한 {A,B,C}도 빈발일 수 없어 제거할 수 있다. 빈발항목집합 탐색과 신뢰도 조건으로 규칙을 생성하는 후속 단계를 구별한다. 최소 지지도의 포함 여부는 구현과 기준 문구를 확인한다.

36. 정답 ③

특정 조건이나 함수로 값을 만들어 별도 의미를 부여한다는 ③은 교재상의 파생변수 설명에 가깝다. 요약과 파생을 구분하는 질문에서 ③을 선택한다.

핵심 개념: 요약변수는 여러 기록을 기간·고객 등 분석 단위에 맞춰 집계한 변수이다. 총 구매액, 평균 구매 간격, 거래 횟수처럼 여러 모형에서 재사용할 수 있는 특징을 만든다.
보기 검토: ①은 공통 집계의 재활용성, ②는 정보 종합, ④는 분석용 데이터 마트에서의 중요성을 설명한다. 요약변수도 계산함수를 사용하므로 함수의 존재만으로 구분하지 않는다.
적용 예: 최근 3개월 총 구매금액은 요약변수, 구매금액과 활동 상태를 조합한 VIP 여부는 조건을 부여한 파생변수의 예이다. 실제 용어 사용에는 범위가 겹칠 수 있어 이 문제는 교재의 대표 정의를 기준으로 판정한다. 분석 단위와 기간을 명확히 해야 계산 결과가 일관된다.

37. 정답 ②

같은 집단의 다른 데이터에 적용해도 유사한 결과가 나오는 특성은 ② 일반화이다.

핵심 개념: 일반화(generalization)는 학습에 사용한 데이터뿐 아니라 같은 모집단에서 나온 새로운 데이터에도 모형이 안정적으로 비슷한 성능을 내는 성질이다.
보기 검토: ① 다양성, ③ 특정화는 모형 평가 기준의 용어가 아니며, ④ 구간화는 연속형 변수를 범주로 나누는 전처리 기법이다.
학습 포인트: 학습 데이터에만 지나치게 맞춘 과대적합 모형은 일반화 성능이 낮다. 일반화 성능은 검증·평가용 데이터로 확인한다.

38. 정답 ①

독립변수 사이 강한 상관이라는 지문은 ① 다중공선성이다. 회귀계수나 상관계수는 관계를 표현하는 수치이며 문제의 이름 자체가 아니다.

핵심 개념: 다중공선성은 회귀모형의 설명변수들이 강하게 선형 관련되어 개별 효과를 분리해 추정하기 어려운 문제이다. 완전한 선형 종속이면 일반적인 계수 추정이 유일하지 않을 수 있다.
보기 검토: ② 회귀계수는 다른 변수 조건에서의 효과를 나타내는 모수 추정, ④ 상관계수는 두 변수 관계의 지표이다. ③은 이 문제의 정해진 진단 명칭에 해당하지 않는다.
학습 포인트: 표준오차 증가, 계수의 불안정, 해석 어려움 등이 나타날 수 있다. 모든 쌍의 상관이 작더라도 여러 변수의 선형결합에서 문제가 생길 수 있어 VIF 등을 검토한다. 오차항의 독립성 가정과 설명변수끼리의 관련성을 혼동하지 않는다.

39. 정답 ④

두 변수 사이 상관이 클 때 이를 반영한 거리를 묻는 취지이므로 ④이다. 큰 상관 자체가 거리 계산 불가능을 뜻하는 것은 아니다.

핵심 개념: 마할라노비스 거리는 공분산 행렬을 이용하여 변수의 분산과 상관구조를 반영한다. $d^2 = (x-y)^T \Sigma^{-1} (x-y)$로 표현할 수 있다. 단위와 변수 간 중복 정보를 함께 고려하는 거리이다.
보기 검토: ① 맨해튼은 절댓값 차이 합, ② 유클리드는 제곱 차이 합의 제곱근이다. ③ 표준화 거리는 변수별 척도 차이를 줄일 수 있지만 일반적으로 전체 공분산의 비대각 상관구조까지 반영하지는 않는다.
학습 포인트: 공분산 행렬이 특이하면 역행렬을 그대로 사용할 수 없어 변수 선택이나 정규화된 추정 등이 필요하다. 상관이 높다는 이유만으로 항상 마할라노비스가 최적이라는 보장은 없고 자료 규모와 추정 안정성을 함께 확인한다.

40. 정답 ③

독립변수와 종속변수의 선형관계를 파악하는 것은 회귀분석의 목적이다. PCA는 종속변수 없이 변수들의 분산 구조를 요약하는 비지도 차원 축소 기법이므로 ③이 틀리다.

핵심 개념: PCA는 원 변수들의 선형결합으로 직교하는 주성분을 만들고 적은 성분으로 자료의 분산을 표현하는 차원 축소 방법이다. 반응변수를 직접 최적화하는 지도 예측모형은 아니다.
보기 검토: ①은 차원 축소, ②는 축소한 특징을 후속 예측모형에 사용 가능하다는 뜻, ④는 양의 분산 주성분 사이 무상관 성질로 적절하다. 차원 축소가 예측 성능을 반드시 높이지는 않는다.
학습 포인트: 원 변수의 상관과 주성분 사이 상관을 구별한다. 단위 차이가 크면 표준화 여부가 결과에 중요하다. 주성분 수는 누적 설명분산과 후속 목적 등을 함께 고려하고 무상관을 일반적 독립으로 확대하지 않는다.

41. 정답 ③

K에 따른 집단 내 제곱합(WSS) 그래프에서 감소 폭이 급격히 줄어드는 엘보(elbow) 지점을 적정 군집 수로 참고한다. 따라서 ③이다.

핵심 개념: K-means의 군집 수를 선택할 때 K에 따른 군집 내 제곱합 WCSS 또는 inertia의 감소를 그려 엘보 지점을 참고할 수 있다. K를 늘릴수록 감소 효과가 작아지는 곳을 살핀다.
보기 검토: ① 잔차 산점도는 회귀모형의 가정 점검, ② ROC 그래프는 분류 모형의 임계값별 성능, ④ 향상도 곡선은 분류 모형의 상위 등급별 성과 평가에 쓰인다.
학습 포인트: 실루엣 계수도 군집 수 판단에 쓰인다.

42. 정답 ④

독립사건의 동시 발생 확률은 곱으로 계산하므로 합이라고 한 ④가 틀리다.

핵심 개념: 두 사건이 독립이면 $P(A \cap B) = P(A)P(B)$이다. 배반(상호배타)이면 $P(A \cap B) = 0$이고 $P(A \cup B) = P(A) + P(B)$이다.
보기 검토: ①은 배반사건의 정의, ②는 큰수의 법칙, ③은 베이즈 정리 $P(A|B) = \dfrac{P(B|A)P(A)}{P(B)}$의 설명이다.
계산 예: $P(A) = 0.4$, $P(B) = 0.5$인 독립사건이면 $P(A \cap B) = 0.2$, $P(A \cup B) = 0.4 + 0.5 - 0.2 = 0.7$이다. 독립과 배반은 다른 개념이며, 확률이 0보다 큰 두 사건은 배반이면서 독립일 수 없다.

43. 정답 ②

귀무가설은 '회귀계수=0', 대립가설은 '회귀계수≠0'이므로 ②이다. p값이 유의수준보다 작으면 귀무가설을 기각하고 계수가 유의하다고 판단한다.

핵심 개념: 개별 회귀계수의 t-검정은 해당 설명변수가 종속변수에 영향이 없는지(계수=0)를 검정한다. 검정통계량은 $t = \dfrac{\text{추정 계수}}{\text{표준오차}}$이다.
보기 검토: ①은 가설을 반대로 놓았고, ③은 상관계수와 혼동했으며, ④는 기준값을 1로 잘못 두었다.
학습 포인트: 모형 전체의 유의성은 F-검정(H_0: 모든 회귀계수 $= 0$)으로 확인한다. 등호는 항상 귀무가설에 둔다.

44. 정답 ③

두 개체가 함께 포함될 확률은 $(10/100) \times (9/99) = 1/110$이므로 1/100이라는 ③이 틀리다. 각 개체의 포함 확률은 $10/100 = 0.1$이므로 ①④는 맞다.

핵심 개념: 100개 중 10개를 비복원 단순무작위추출하면 개체 번호와 관계없이 포함 확률이 동일하다. 한 개체의 포함을 이미 안다면 남은 99개에서 추가 9개가 포함된다.
보기 검토: 어떤 두 번호를 골라도 함께 포함될 확률은 $1/110$으로 같으므로 ②가 맞다. 1번이 포함되었다는 조건에서 2번이 포함될 조건부확률은 $9/99 = 1/11$이다.
학습 포인트: 비복원추출에서는 앞의 추출 결과에 따라 다음 확률이 달라지지만, 최종 표본에 포함될 확률은 모든 개체가 같다.

45. 정답 ③

군집 수가 정해져 있어도 계층적 군집(덴드로그램을 원하는 높이에서 자름), 혼합분포 군집, SOM 등 여러 방법을 쓸 수 있다. 반드시 K-means만 사용해야 한다는 ③이 틀리다.

핵심 개념: 군집분석은 묶으려는 대상에 맞춰 특징 벡터와 거리·유사도를 정의한다. 학생, 상품, 고객 중 무엇을 묶는지에 따라 관측 단위와 사용할 특징이 달라진다.
보기 검토: ①은 수치 점수 기반 K-means 활용, ②는 SOM의 저차원 격자 표현, ④는 자료 유형과 목적에 따른 특징·거리 선택으로 적절하다. 학생 점수도 척도와 표준화 여부를 검토해야 한다.
학습 포인트: 군집 방법은 자료의 형태, 이상치, 군집 모양, 해석 목적에 따라 고른다.

46. 정답 ④

회귀식에 age×job 교호작용 항이 없으므로 교호작용이 유의한지는 이 식으로 판단할 수 없다. ④가 부적절하다.

핵심 개념: 더미변수의 계수는 기준 집단과의 절편 차이를 나타낸다. 교호작용 항(age×job)이 없으면 두 집단의 age 기울기는 같다.
계산 과정: $job = 0$이면 $wage = 5632 + 1300 \times age$, $job = 1$이면 $wage = (5632 + 3721) + 1300 \times age = 9353 + 1300 \times age$이다. 절편만 다르고 기울기 1300은 같다.
보기 검토: ①은 절편 5632와 9353의 차이, ②③은 공통 기울기 1300으로 맞는 해석이다.
학습 포인트: 교호작용 항 $\beta_3(age \times job)$을 추가하면 $job = 1$ 집단의 기울기는 $1300 + \beta_3$로 달라질 수 있다.

47. 정답 ①

잔차 자유도 41, 독립변수 5개이므로 $n = 41 + 5 + 1 = 47$이다. 절편을 빼먹고 46개로 계산한 ①이 틀리다.

핵심 개념: 절편이 있는 다중회귀에서 잔차 자유도는 $n - p - 1$이다(n: 데이터 수, p: 독립변수 수).
보기 검토: ② Examination의 p값 0.315는 0.05보다 커서 유의하지 않으므로 맞다. ③ Agriculture 계수 −0.172로 음수이므로 맞다. ④ Adjusted R-squared는 0.671이다.
학습 포인트: F-statistic의 자유도(5, 41)에서도 독립변수 5개, 잔차 자유도 41을 읽을 수 있다. 회귀계수가 유의해도 관찰자료만으로 인과관계를 확정하지 않는다.

48. 정답 ③

$e^{\beta_2} = 0.489$이므로 다른 변수가 일정할 때 X_2가 1 증가하면 오즈가 0.489배가 된다. 따라서 ③이다. 오즈가 $1 - 0.489 = 0.511$, 즉 약 51.1% 감소한다는 뜻이다.

핵심 개념: 오즈(Odds)는 $\frac{P}{1-P}$이고 로짓(Logit)은 $\log(Odds)$이다. 계수 β는 설명변수가 1 증가할 때 로짓의 변화량이고, e^{β}는 오즈가 몇 배가 되는지(오즈비)를 나타낸다.
보기 검토: ①②는 오즈비를 로짓의 변화율로 잘못 해석했다. 로짓은 $\beta_2 = \log(0.489) \approx -0.715$만큼 변한다. ④는 감소를 증가로 바꾸었다.
학습 포인트: $e^{\beta_1} = 1.006$이면 X_1이 1 증가할 때 오즈가 약 0.6% 증가한다. 오즈비는 확률의 변화율이 아니다. 이 수치는 ISLR Default 데이터의 glm(default ~ balance + student) 결과(balance 1.0058, studentYes 0.4893)와 같다.

49. 정답 ①

오차제곱합이 크게 증가하는 지점을 군집 수 결정의 참고로 삼는 ①이 적절하다.

핵심 개념: 와드 연결법은 두 군집을 합쳤을 때 군집 내 오차제곱합의 증가량이 가장 작은 쌍을 병합한다. 증가량이 갑자기 커지는 단계는 서로 다른 군집을 억지로 합치기 시작한다는 신호이다.
보기 검토: ②③은 특정 연결법이 항상 최적이라고 단정해 틀리다. 연결법마다 장단점이 있고 자료에 따라 결과가 달라진다. ④처럼 군집 수를 미리 고정하는 규칙은 없다.
학습 포인트: 덴드로그램의 높이(병합 거리)가 크게 벌어지는 곳을 잘라 군집 수를 정하기도 한다. 업무 해석 가능성도 함께 본다.

50. 정답 ①

전체 6건 중 X 포함 4건(1·2·3·5), Y 포함 4건(1·2·4·5), X와 Y 동시 포함 3건(1·2·5)이다. 신뢰도 $= 3/4$, $P(Y) = 4/6 = 2/3$이므로 향상도 $= \frac{3/4}{2/3} = \frac{9}{8}$이고 ①이다.

핵심 개념: 향상도(X→Y) $= \frac{P(Y|X)}{P(Y)} = \frac{P(X \cap Y)}{P(X)P(Y)}$이다. 1보다 크면 양의 연관, 1이면 독립, 1보다 작으면 음의 연관이다.
보기 검토: ②는 역수, ③④는 분모·분자를 잘못 잡은 값이다.
학습 포인트: 향상도는 방향과 관계없이 같아 Y→X도 9/8이다. $9/8 > 1$이므로 X를 방문한 사람이 Y도 방문하는 경향이 우연보다 약간 높다.