ADsP 제44회 기출 복원문제

유형 2

정답·해설 수록본

총 50문항 · 4지선다 · 90분

1과목 데이터 이해 (1~10번)

1. 이용자가 원하는 정보를 신속하게 획득하기 위해 고려해야 할 데이터베이스 측면은?

① 정보 이용 측면
② 정보 관리 측면
③ 정보 기술 발전 측면
④ 사회 경제적 측면

정답 ①
이용자가 원하는 정보를 신속하게 획득한다는 목적이므로 ① 정보 이용 측면이다. 자료를 관리하는 내부 절차나 관련 기술 산업의 발전을 묻는 질문이 아니다.

핵심 개념: 데이터베이스는 저장된 정보를 찾고 활용할 수 있게 하는 체계이다. 교재의 정보 이용 측면은 이용자가 필요한 자료를 적시에 찾아 활용하는 특성을 설명한다.
보기 검토: ②는 자료 관리 기능과 운영, ③은 하드웨어·소프트웨어·네트워크 등의 기술 발전, ④는 사회·경제에 미치는 효과에 초점이 있다.
학습 포인트: 같은 데이터베이스라도 관점에 따라 설명 대상이 달라진다. 고객지원 담당자가 주문을 조회해 문의에 답하는 상황은 이용 관점이고, 관리자가 백업·접근 권한을 점검하는 것은 관리 관점이다. 지문의 주체가 이용자인지 관리자인지 먼저 확인한다.

2. 데이터 1제타바이트 크기에 해당하는 것으로 적절한 것은?

① 1024 테라바이트 (TB)
② 1024 요타바이트 (YB)
③ 1024 페타바이트 (PB)
④ 1024 엑사바이트 (EB)

정답 ④
교재에서 단계마다 1024배라고 설명한 관행을 적용하면 ④를 의도한 것으로 읽는다. 그러나 표준 십진 단위에서는 $1\,ZB = 10^{21}$ byte이고 $1\,EB = 10^{18}$ byte이므로 $1\,ZB = 1000\,EB$이다. 1024배 관계는 1 ZiB=1024 EiB라는 이진 단위 표기로 표현한다.

핵심 개념: 데이터 크기 단위의 순서는 KB→MB→GB→TB→PB→EB→ZB→YB이다. 제타는 엑사보다 한 단계 크다. 다만 십진 SI 접두어와 이진 접두어를 구별해야 한다.
보기 검토: ①③은 TB·PB로 단계가 다르고 ②는 ZB보다 큰 YB를 써 방향이 반대이다. ④도 ZB와 EB를 엄밀한 십진 단위로 읽으면 정확하지 않다.
학습 포인트: 시험에서는 교재 관행대로 단계마다 1024배로 계산한다. 엄밀한 표준 표기는 1 ZiB=1024 EiB(이진), 1 ZB=1000 EB(십진)이지만 출제 의도는 단위 순서이다.

3. 다음 중 데이터에 대한 설명으로 옳지 않은 것은?

① 이미지, 동영상은 비정형 데이터이다.
② 데이터에 따라 분석 방법이 달라질 수 있다.
③ HTML은 정형 데이터의 예이다.
④ 정형, 반정형, 비정형으로 구분할 수 있다.

정답 ③
HTML은 태그로 문서 구조를 표현하는 대표적인 반정형 자료이므로 정형이라고 한 ③이 틀리다. ①의 이미지·동영상은 내용 기준으로 일반적으로 비정형이며 ②④는 적절하다.

핵심 개념: 정형은 고정된 스키마와 행·열 구조를 갖는 자료, 반정형은 태그·키 같은 구조 단서를 포함하지만 고정 관계형 표와는 다른 자료, 비정형은 내용 자체가 고정된 필드 구조로 바로 표현되지 않는 자료이다.
보기 검토: 분석 방법은 숫자·텍스트·영상 등 자료의 형태와 목표에 따라 달라질 수 있다. 형식 구분은 숫자인지 문자인지만으로 정하지 않는다.
학습 포인트: 웹페이지의 표를 추출해 행·열 데이터로 변환할 수 있어도 원래 HTML 문서의 분류까지 정형으로 바뀌는 것은 아니다. 파일 형식, 담긴 내용, 분석을 위해 변환한 표현을 나누어 생각한다.

4. 기업에서 빅데이터를 활용하는 방안으로 적절하지 않은 것은?

① 마케팅: 적합한 지점의 위치를 선정한다.
② 재무관리: 거래처 리스트를 관리한다.
③ 공급처: 적정한 재고량을 결정한다.
④ 인력관리: 이직률을 예측한다.

정답 ②
②의 거래처 리스트 관리는 기본적인 자료 관리이므로 다른 보기의 예측·최적화와 구별되는 답이다. 재무 업무에는 부도 위험 예측, 이상 거래 탐지 등 분석 활용이 가능하다.

핵심 개념: 빅데이터 활용은 자료를 분석하여 패턴을 찾고 예측·최적화·의사결정에 연결하는 활동이다. 자료를 보관하거나 목록을 관리하는 활동만으로 분석 활용 사례가 충분히 설명되지는 않는다.
보기 검토: ①은 위치와 수요를 이용한 입지 선정, ③은 수요와 공급을 이용한 재고 결정, ④는 인력 자료를 이용한 이직 가능성 예측이다.
학습 포인트: 거래처 자료를 분석해 신용 위험이나 거래 패턴을 평가한다면 빅데이터 활용 사례가 될 수 있다. 이 보기는 분석 목적 없이 목록을 관리하는 활동이라 다른 보기와 구별된다.

출처: ADsP CBT youneedpython.github.io/ADsP-CBT · 복원 문제로 실제 시험과 다를 수 있습니다.

5. 커피를 구매한 사람이 탄산음료도 구매할지에 대한 예측을 하는 분석 기법은?

① 회귀분석
② 연관분석
③ 감정분석
④ 유전알고리즘

정답 ②
커피 구매와 탄산음료 구매의 동시 발생 관계를 묻는 장바구니 분석 문맥이므로 ②가 가장 적합하다. 커피 구매자의 음료 조합을 거래 단위로 살펴볼 수 있다.
핵심 개념: 연관분석은 거래 안에서 함께 발생하는 항목의 관계를 찾는다. A→B 규칙에서는 A를 포함한 거래 중 B도 포함하는 비율을 신뢰도로 평가할 수 있다.
보기 검토: ① 회귀는 설명변수와 반응변수의 관계를 모델링하고, ③ 감정분석은 문장 등의 감정·의견을 분류한다. ④ 유전자 알고리즘은 후보 조합을 탐색하는 최적화 방법이다.
학습 포인트: 특정 구매자의 구매 여부를 목표변수로 명시하면 별도의 분류모형을 설계할 수도 있다. 이 문항은 상품끼리 함께 구매되는 규칙을 묻는 취지이다. 규칙의 화살표는 인과관계를 증명하는 것이 아니며 지지도·신뢰도·향상도를 함께 검토한다.

6. 데이터 사이언스에 대한 설명 중 틀린 것은?

① 데이터 분석부터 설명 및 결과까지 전달한다.
② 데이터를 활용하여 정보와 인사이트를 창출한다.
③ 데이터베이스 구축 자체가 데이터 사이언스의 핵심 목적이다.
④ 통계학, 데이터마이닝, 기계학습 기법을 사용한다.

정답 ③
③은 데이터베이스 구축 자체를 핵심 목적으로 보아 틀리다. 데이터 사이언스의 핵심은 데이터에서 의미 있는 정보와 인사이트를 얻어 가치를 만드는 것이며, 저장 체계 구축은 이를 위한 기반이다.
핵심 개념: 데이터 사이언스는 자료의 수집·처리·분석·모델링·해석·결과 전달 등을 연결해 문제를 해결하는 분야이다. 통계와 컴퓨터 과학, 업무 지식을 함께 활용한다.
보기 검토: ①은 분석 결과의 설명·전달, ②는 정보와 인사이트 창출, ④는 통계학·데이터마이닝·기계학습 등 활용 기법을 설명하므로 적절하다.
학습 포인트: 데이터 사이언스는 분석 기술뿐 아니라 결과를 이해관계자에게 전달하는 커뮤니케이션까지 포함한다.

7. 데이터 분석가에 대한 설명으로 가장 적절하지 않은 것은?

① 도메인 전문가가 분석에 참여하면 더 깊은 통찰을 얻을 수 있다.
② 분석가는 분석 업무와 관리 업무를 동시에 수행할 수 없다.
③ 소통 능력, 팀워크 같은 소프트 스킬을 갖추면 좋다.
④ 분석가의 역할은 코딩만 하는 것으로 한정되지 않는다.

정답 ②
분석과 관리 업무를 동시에 수행할 수 없다고 단정한 ②가 틀리다. 분석 조직의 리더나 프로젝트 관리자가 분석 업무를 함께 수행하는 경우는 흔하다.
핵심 개념: 데이터 분석가는 업무 문제를 이해하고 분석 결과를 이해관계자와 소통하며, 필요하면 프로젝트 관리나 리더 역할도 함께 맡는다.
보기 검토: ①은 업무 지식(도메인)의 중요성, ③은 소프트 스킬, ④는 코딩 이외의 문제 정의·해석·전달 역할을 설명하므로 적절하다.
학습 포인트: 데이터 사이언티스트에게는 하드 스킬(이론 지식, 분석 기술)과 소프트 스킬(통찰력, 설득력 있는 전달, 협력)이 모두 요구된다.

8. 기온 변화에 따른 제품 판매량을 예측하는 데 가장 적합한 분석 방법은?

① 회귀분석
② 연관분석
③ 군집분석
④ 유전 알고리즘

정답 ①
기온에 따른 판매량이라는 수치를 예측하므로 ① 회귀분석이 적합하다. 단순선형 모형이라면 $\hat{y} = b_0 + b_1 \times$ 기온으로 표현한다.
핵심 개념: 회귀분석은 설명변수와 수치형 반응변수의 관계를 모형으로 만들어 값을 예측한다. 기온을 설명변수 X, 판매량을 반응변수 Y로 둔다.
보기 검토: ② 연관분석은 함께 발생하는 항목의 규칙, ③ 군집분석은 비슷한 대상의 묶음, ④ 유전 알고리즘은 최적 조합 탐색에 쓰인다.
학습 포인트: 기온과 판매량 사이 상관이 있어도 인과관계가 자동으로 증명되지는 않는다. 가격·행사·요일 등 다른 요인도 함께 검토한다.

9. 빅데이터 가치 산정이 어려운 이유에 대해 적절하지 않은 것은?

① 데이터를 누가, 언제 사용했는지 알기 어렵기 때문이다.
② 분석 기술의 발전으로 과거에 분석 불가했던 데이터를 분석할 수 있게 되었기 때문이다.
③ 빅데이터는 기존에 존재하지 않던 새로운 가치를 창출하기 때문이다.
④ 데이터 전문가의 증가로 데이터 분석 방법이 일반화되었기 때문이다.

정답 ④
전문가 증가와 분석 방법의 일반화라는 ④는 이 문항에서 가치 측정이 어려워지는 직접적인 대표 이유가 아니다. 다른 보기는 활용의 불확실성, 기술 변화, 새로운 가치 창출에 연결된다.
핵심 개념: 데이터 가치는 활용 주체와 시점, 분석 기술, 다른 자료와의 결합 방식에 따라 달라진다. 미래의 사용처와 새로운 가치가 모두 정해져 있지 않아 일정한 금액으로 평가하기 어렵다.
보기 검토: ①은 누가 어떤 방식으로 활용할지 예측하기 어려운 점, ②는 기술 발전으로 과거 자료의 활용 가능성이 달라지는 점, ③은 기존 평가 기준이 포착하지 못하는 가치가 생기는 점을 설명한다.
학습 포인트: 데이터의 저장 비용이나 수집 비용이 곧 활용 가치와 같지는 않다. 같은 거래 자료도 재고 최적화와 고객 분석에서 다른 성과를 만들 수 있다. 비용과 가치, 현재 활용과 미래 잠재 활용을 구별한다.

10. 빅데이터의 위기에 대한 대응 방안으로 가장 적절하지 않은 것은?

① 익명화 기술을 활용해 사생활 침해 위험을 줄인다.

② 사생활 침해 통제 방안으로 동의제에서 책임제로의 전환을 검토한다.

③ 잠재적 위협 요인만으로 개인에게 불이익을 준다.

④ 알고리즘 접근을 허용해 데이터 오용으로 인한 피해를 줄인다.

정답 ③

예측된 잠재적 위협만으로 개인에게 불이익을 주는 것은 책임 원칙 훼손 그 자체이다. 실제 행동 결과를 기준으로 책임을 묻는 결과 기반 책임 원칙에 어긋나므로 ③이 부적절하다.

핵심 개념: 빅데이터의 위기 요인과 통제 방안은 사생활 침해→동의제에서 책임제로 전환, 책임 원칙 훼손→결과 기반 책임 원칙 고수, 데이터 오용→알고리즘 접근 허용으로 짝지어진다.
보기 검토: ①은 사생활 침해 위험을 낮추는 기술적 보호 조치, ②는 사생활 침해에 대한 통제 방안, ④는 데이터 오용에 대한 통제 방안이다.
학습 포인트: 익명화도 다른 자료와 결합하면 재식별 위험이 남으므로 위험을 '줄인다'는 표현이 적절하다.

2과목 데이터 분석 기획 (11~20번)

11. 상향식 접근법의 순서로 올바른 것은?

① 프로세스 분류 → 프로세스 흐름 분석 → 분석요건 식별 → 분석요건 정의

② 프로세스 분류 → 분석요건 식별 → 프로세스 흐름 분석 → 분석요건 정의

③ 프로세스 흐름 분석 → 분석요건 식별 → 분석요건 정의 → 프로세스 분류

④ 분석요건 정의 → 분석요건 식별 → 프로세스 흐름 분석 → 프로세스 분류

정답 ①

먼저 프로세스를 분류하고 흐름을 분석한 뒤 분석요건을 식별하고 정의하므로 ①이다. 구조와 흐름을 이해하지 않고 요건을 정의하거나 분류를 마지막에 놓는 배열은 기본 순서와 맞지 않는다.

핵심 개념: 상향식 접근법에서 분석 과제를 도출할 때는 업무 프로세스를 분류하고, 프로세스 흐름을 분석한 뒤, 분석이 필요한 요건을 식별하고 정의하는 순서로 진행한다.
보기 검토: ②는 흐름 분석 전에 요건 식별을 배치했고, ③은 분류를 마지막에, ④는 정의를 가장 먼저 놓았다. 탐색에서 구체화로 이어지는 흐름을 확인한다.
학습 포인트: 프로세스 분류(가치사슬·메가·메이저 프로세스) → 흐름 분석(프로세스 맵) → 요건 식별(의사결정 지점) → 요건 정의 순서로 외운다. 하향식의 문제 탐색→문제 정의→해결방안 탐색→타당성 검토와 구별한다.

12. 데이터 분석 거버넌스 구성요소가 아닌 것은?

① 분석 인력 (human resource)

② 프로세스 (Process)

③ 분석 조직 (Organization)

④ 분석 기법 (Technology)

정답 ④

교재의 구성요소 구분에서는 ④ 분석 기법이 나머지 인력·프로세스·조직과 구별되는 답이다. 이는 기술이 분석 거버넌스에 전혀 필요 없다는 뜻이 아니다. 분석 인프라 등의 기술 기반은 별도로 다룰 수 있다.

핵심 개념: 분석 거버넌스는 분석을 지속적으로 수행하고 활용하도록 조직·인력·프로세스·관련 기반과 관리 체계를 연결한다. 개별 알고리즘의 이름과 전사 운영 체계는 같은 수준의 항목이 아니다.
보기 검토: ①은 전문성과 역할, ②는 수행 절차와 관리 흐름, ③은 책임과 협업 구조에 해당한다. ④의 영어 Technology와 한국어 분석 기법의 범위가 완전히 같지 않다는 점도 유의한다.
학습 포인트: 분석 거버넌스 체계의 구성요소는 조직(Organization), 과제 기획·운영 프로세스(Process), 분석 관련 시스템(System), 데이터(Data), 분석 관련 교육·마인드 육성 체계(Human Resource)이다. 데이터 거버넌스와 혼동하지 않는다.

13. 마스터 플랜 수립 시 우선 순위가 가장 높은 과제 선정 기준은?

① 난이도: 쉬움 / 시급성: 현재

② 난이도: 쉬움 / 시급성: 미래

③ 난이도: 어려움 / 시급성: 현재

④ 난이도: 어려움 / 시급성: 미래

정답 ①

현재라는 높은 시급성과 쉬움이라는 낮은 난이도를 가진 ①이 제시된 비교에서 우선순위가 가장 높다. 같은 시급성이라면 실행 가능한 과제를, 같은 난이도라면 더 급한 과제를 우선 검토하는 취지이다.

핵심 개념: 과제 우선순위는 시급성과 난이도 등을 함께 고려하여 정한다. 지금 해결해야 하고 실행 부담이 낮은 과제는 빠른 성과를 얻기 위한 우선 후보가 된다.
보기 검토: ②는 쉬워도 미래 과제이고, ③은 급하지만 난도가 높으며, ④는 미래이면서 어렵다. 시급성과 난이도 한 축만 보지 않는다.
학습 포인트: 실제 사업에서는 법적 의무, 전략적 효과, 선행과제, 비용과 위험 등으로 순서가 달라질 수 있다. 쉬운 과제만 계속 수행하라는 원칙은 아니다. 이 문항은 두 기준만 제시한 교재상의 기본 비교로 해석한다.

14. 데이터 분석 기획 시 고려사항이 아닌 것은?

① 데이터 유형 분류

② 데이터 정합성 검증

③ 장애요소에 대한 사전 계획 수립

④ 적절한 활용 방안과 유스케이스 탐색

정답 ②

교재의 분석 기획 고려사항(가용 데이터 고려, 적절한 유스케이스 탐색, 장애요소에 대한 사전 계획 수립)과 비교하면 ② 데이터 정합성 검증을 상세한 자료 검증 작업으로 보아 나머지 대표 기획 고려사항과 구별한다. 정합성 검증이 필요 없거나 기획 중 품질 위험을 살피면 안 된다는 뜻이 아니다.

핵심 개념: 기획에서는 자료 유형과 확보 가능성, 활용 목적, 유스케이스, 수행 장애와 대안을 검토한다. 자료의 정합성과 품질도 중요하지만 구체적인 검증 수행은 준비·분석 단계의 작업과 구분될 수 있다.
보기 검토: ①은 가용 데이터의 유형을 파악하는 고려사항이다. ③은 실행 장애에 대비하는 계획, ④는 분석 결과의 적용 목적과 사례 탐색이다.
학습 포인트: 기획에서 품질 위험과 검증 계획을 정하는 일, 준비 단계에서 실제 자료를 검사하는 일은 연결되어 있다. 단계 구분 문제를 실제 업무의 엄격한 금지 규칙으로 확대하지 않는다.

15. 데이터 분석 프로세스를 순서대로 나열한 것은?

① 데이터 준비 → 분석 기획 → 데이터 분석 → 시스템 구현 → 평가 및 전개
② 데이터 준비 → 데이터 분석 → 분석 기획 → 시스템 구현 → 평가 및 전개
③ 데이터 준비 → 데이터 분석 → 분석 기획 → 평가 및 전개 → 시스템 구현
④ 분석 기획 → 데이터 준비 → 데이터 분석 → 시스템 구현 → 평가 및 전개

정답 ④

④가 이 순서를 따른다. 자료를 먼저 준비한 뒤 목적을 정하는 다른 보기와 달리 분석 기획이 출발점이다. 사용할 방법보다 해결할 업무 문제를 먼저 명확히 한다.

핵심 개념: 빅데이터 분석 방법론은 분석 기획→데이터 준비→데이터 분석→시스템 구현→평가 및 전개의 흐름이다. 문제와 목표를 정한 뒤 자료와 모형을 마련하고 적용·평가한다.
보기 검토: ①②③은 기획을 준비 또는 분석 뒤에 놓고, ③은 시스템 구현보다 평가·전개를 먼저 배치했다. 기본 단계의 선후관계와 맞지 않는다.
적용 예: 고장 예측 목표를 정하고 센서 자료를 준비한 뒤 모형을 학습하며, 운영 시스템에 연결하고 성능과 업무 효과를 평가한다. 실제로는 평가 결과에 따라 앞 단계로 돌아갈 수 있다. CRISP-DM의 여섯 단계 명칭과 현재 다섯 단계를 혼합하지 않는다.

16. CMMI 모델 기반 분석 성숙도 단계 중 도입 단계에 해당되는 것은?

① 데이터로 미래 예측
② 실적 분석 및 통계 작성
③ 분석 프로세스 내재화
④ 경영진 분석 활용

정답 ②

기초 현황을 집계하는 ②가 도입 단계에 대응한다. 미래 예측이나 경영진의 광범위한 활용, 프로세스 내재화는 상대적으로 발전된 상태의 설명이다.

핵심 개념: 분석 성숙도에서 도입 단계는 기초적인 실적 분석과 통계 작성부터 분석 활용을 시작하는 단계로 설명한다. 이후 예측 활용, 조직 전반 확산, 프로세스 내재화와 지속 개선으로 발전한다.
보기 검토: ①은 예측 활용, ③은 분석을 업무 프로세스에 정착시키는 상태, ④는 관리·의사결정 활용을 뜻한다. 제시된 활동 수준을 비교한다.
학습 포인트: CMMI 자체의 Initial·Managed 등 단계 명칭과 ADsP 교재의 도입·활용·확산·최적화라는 분석 성숙도 명칭은 동일하지 않다. 기반을 참고한 진단 체계라는 맥락으로 이해하고 CMMI의 세부 단계 번호와 이 문항의 답을 직접 같은 것으로 연결하지 않는다.

17. 상향식 접근법의 특징으로 올바른 것만 고른 것은?

> 가) 인사이트와 지식을 얻는 Bottom-up 접근방식이다.
> 나) 정확한 문제해결을 위한 프로토타이핑 접근법을 이용한다.
> 다) 상관관계보다 인과관계가 중요하다.
> 라) 데이터를 통해 패턴을 발견하고 통찰을 얻는다.

① 가, 나
② 가, 다
③ 가, 나, 다
④ 가, 나, 라

정답 ④

가의 Bottom-up, 나의 프로토타이핑, 라의 데이터에서 패턴 발견이 적절하므로 ④이다. 다의 인과관계가 상관관계보다 중요하다는 설명은 상향식 탐색의 대표 강조점과 맞지 않는다.

핵심 개념: 상향식 접근은 명확한 문제를 먼저 고정하기보다 자료 탐색으로 패턴과 통찰을 발견하고 문제를 구체화하는 흐름이다. 프로토타입을 만들어 반복 확인하는 방식이 활용될 수 있다.
보기 검토: ①은 라를 빠뜨렸고, ②③은 다를 포함한다.
프로토타이핑은 자료와 문제를 구체화하며 반복하는 것이지 처음부터 정확한 해답을 보장하는 방법이 아니다.
학습 포인트: 상향식이 상관 패턴을 탐색한다고 인과관계가 중요하지 않다는 뜻은 아니다. 탐색 목적과 최종 인과적 의사결정에 필요한 증거는 다를 수 있다. 발견된 관계를 추가 검증 없이 원인이라고 결론내리지 않는다.

18. 데이터를 활용한 의사결정에 대한 주장으로 가장 적절한 것은?

① 도메인 지식에 의한 판단을 우선하고 데이터는 보조 역할만 한다.
② 데이터에 근거한 판단이 근거 없는 대안보다 바람직하다.
③ 시각화 같은 단순 표현은 의사결정에 큰 도움이 되지 않는다.
④ 주관과 직관을 유지하고 통계 분석은 참고용으로만 쓴다.

정답 ②

데이터에 근거한 판단이 근거 없는 대안보다 바람직하다는 ②가 적절하다.

핵심 개념: 데이터 기반 의사결정은 직관이나 경험만이 아니라 자료와 분석 결과를 근거로 판단하는 것이다. 분석 결과와 업무 지식을 함께 사용하되 근거가 있는 판단을 우선한다.
보기 검토: ①④는 데이터를 보조·참고 수준으로 낮추어 데이터 기반 의사결정의 취지와 맞지 않는다. ③은 시각화가 패턴을 빠르게 전달해 의사결정을 돕는다는 점을 부정하여 틀리다.
학습 포인트: 데이터 기반이라도 자료의 품질·편향을 점검해야 한다. 데이터가 있다고 판단이 자동으로 옳아지는 것은 아니다.

19. 과제 중심적 접근 방식의 데이터 분석에 대한 설명으로 옳지 않은 것은?

① 즉각적인 실행으로 성과를 도출하는 데 초점을 둔다.
② 속도와 검증(Speed & Test)을 중시한다.
③ 빠른 문제 해결(Quick-Win)을 목표로 한다.
④ 이행 과제 분석에서 과제 간 선후관계를 고려하지 않는다.

정답 ④
과제를 빠르게 수행하더라도 이행 과제를 분석할 때는 데이터 확보·기반 구축처럼 먼저 끝나야 하는 선행 과제와의 관계를 따져 실행 순서를 정한다. 선후관계를 고려하지 않는다는 ④가 틀리다.
핵심 개념: 과제 중심적 접근 방식은 당면한 과제를 빠르게 해결해 즉각적인 성과를 얻는 방식으로 Speed & Test, Quick-Win을 중시한다. 장기적인 마스터플랜 방식은 Accuracy & Deploy, 문제 해결을 위한 장기적 관점을 중시한다.
보기 검토: ①②③은 과제 중심적 접근의 특징이다.
학습 포인트: 마스터플랜의 우선순위 결정에는 시급성·난이도 외에 과제 간 선후관계(의존성)도 반영한다.

20. 전략적 통찰력이 있는 분석에 대한 설명으로 적절하지 않은 것은?

① 환경 변화에 빠르게 대응하고 새로운 기회를 찾을 수 있다.
② 분석을 많이 하는 것 자체가 핵심은 아니다.
③ 의사결정에 긍정적인 영향을 줄 수 있다.
④ 기업 내부 관점에만 한정하여 분석한다.

정답 ④
기업 내부 관점에만 한정하면 시장과 경쟁 환경의 변화를 놓치므로 ④가 적절하지 않다.
핵심 개념: 전략적 통찰력이 있는 분석은 사업 성과를 좌우하는 핵심 요인에 집중하여 경쟁 우위와 차별화의 기회를 찾는 분석이다. 고객·경쟁사·시장 같은 외부 환경까지 함께 본다.
보기 검토: ①은 환경 변화 대응과 기회 발굴, ②는 분석의 양보다 통찰의 질이 중요하다는 점, ③은 의사결정에 미치는 긍정적 영향을 설명한다.
학습 포인트: 일차원적인 분석(부서 단위의 반복 업무 분석)을 넘어 전략적 통찰로 나아가야 사업 성과에 기여한다.

3과목 데이터 분석 (21~50번)

21. 스피어만 분석 방법으로 분석할 수 없는 것은?

① 명목척도
② 등간척도
③ 비율척도
④ 서열척도

정답 ①
명목척도에는 범주 간 의미 있는 순서가 없으므로 ①을 선택한다. 지역이나 혈액형에 임의의 숫자 코드를 붙여도 그 숫자 순서가 의미 있는 순위가 되지는 않는다.

핵심 개념: 스피어만 상관은 원 자료를 순위로 바꾸어 단조 관계를 평가한다. 순서가 있는 자료 또는 수치 자료를 순위화하여 활용할 수 있다.
보기 검토: ④ 서열척도는 순위가 있으며, ② 등간·③ 비율척도의 수치도 순위로 바꿀 수 있다. 동순위가 있으면 보통 평균 순위 등 적절한 처리를 반영한다.
학습 포인트: 스피어만을 범주형 자료 전체에 적용하는 것으로 외우지 않는다. 순서형 범주와 순서 없는 명목 범주를 구분한다. 수치 자료에 피어슨만 사용할 수 있는 것도 아니다. 스피어만은 모든 비선형 관계가 아니라 증가·감소 방향이 일관된 단조 관계에 적합하다.

22. 모집단 개체에 1, 2, 3, …, n과 같은 일련번호를 부여 후 첫 번째 표본으로부터 일정 간격으로 표본을 선택하는 추출법은?

① 단순무작위추출
② 계통추출
③ 층화추출
④ 집락추출

정답 ②
일련번호를 부여하고 첫 표본 이후 일정 간격으로 선택한다는 지문은 ② 계통추출이다. 적절한 확률표집을 위해 첫 시작점의 무작위 선택도 포함하여 이해한다.

핵심 개념: 계통추출은 모집단 목록에서 무작위 시작점을 정하고 일정 간격마다 표본을 뽑는다. 목록의 순서와 추출 간격에 주기적 관계가 있는지 살펴야 한다.
보기 검토: ① 단순무작위는 가능한 표본을 같은 확률로 선택하는 방식, ③ 층화는 층별 표본 선택, ④ 집락은 집단 단위를 선택하는 방식이다.
계산 예: 1000명 중 100명을 간격 10으로 뽑는다면 1~10 중 시작점을 무작위로 선택해 이후 10명마다 뽑는다. 예시는 원리를 설명하기 위한 값이다. 첫 개체를 항상 1번으로 고정하는 방식과 구별한다.

23. 연관분석의 장점이 아닌 것은?

① 조건 반응(If - then) 기반으로 분석 결과 해석이 쉽다.
② 목적변수(반응변수)가 없어도 분석할 수 있다.
③ 데이터를 변환하지 않고 그대로 사용할 수 있어 간편하다.
④ 품목 수가 증가해도 계산량이 거의 늘어나지 않는다.

정답 ④
품목 수가 늘어나면 가능한 항목 조합이 기하급수적으로 증가해 계산량이 크게 늘어나는 것이 연관분석의 대표적인 단점이다. 계산량이 거의 늘지 않는다는 ④는 장점이 아니라 틀린 설명이다.

핵심 개념: 연관분석은 거래 항목의 동시 발생을 If-then 규칙으로 표현하며 별도의 목적변수 없이 빈발항목과 규칙을 찾는다(비지도 학습).
보기 검토: ①은 해석이 쉬운 규칙 형태, ②는 목적변수 없이 탐색 가능, ③은 거래 자료를 그대로 쓸 수 있는 간편함으로 모두 장점이다.
학습 포인트: 연관분석의 단점은 품목 수 증가에 따른 계산량 증가, 거래가 적은 품목의 규칙 발견이 어려움 등이다. 유사 품목을 묶어 (일반화) 계산량을 줄이는 방법을 함께 기억한다.

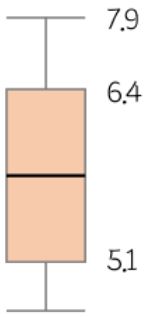
24. k-NN 알고리즘의 특징 중 틀린 것은?

① 사전 학습 없이 새 데이터 분류 가능하다.
② 가까운 그룹을 찾는다.
③ 가까운 k개 데이터를 탐색한다.
④ k 개수가 클수록 과대적합 문제가 발생할 수 있다.

정답 ④
일반적으로 K가 작을수록 국소 잡음에 민감해 과적합 위험이 커지고, K가 매우 크면 평균적인 판단으로 치우쳐 과소적합할 수 있다. 따라서 K가 커질수록 과대적합이라는 ④는 대표 경향을 뒤집었다.

핵심 개념: K-NN은 학습 관측값을 저장해 두고 새 관측값과 가까운 K개 이웃의 라벨이나 값을 이용한다. 복잡한 모수를 미리 적합하는 대신 예측 시 거리 탐색을 수행하는 지연학습의 대표 예이다.
보기 검토: ①은 자료 준비나 저장이 전혀 필요 없다는 뜻이 아니라 별도의 모수 학습이 적다는 취지이다. ②③은 가까운 이웃을 찾는 작동 방식이다.
학습 포인트: $K = 1$이면 한 이웃의 영향이 매우 크다. K를 키우면 경계가 보통 부드러워지지만 최적값은 검증으로 정한다. 거리 척도, 표준화, 불균형 라벨, 동률 처리에도 결과가 영향을 받는다.

25. 아래 Box plot에 대한 설명 중 틀린 것은?



① 데이터 최대값은 7.9이다.
② IQR은 1.3이다.
③ 평균은 중앙값보다 항상 크다.
④ 5.1보다 작은 데이터가 약 25% 있다.

정답 ③
상자그림에는 평균이 표시되지 않으며, 평균과 중앙값의 크기 관계는 분포 모양에 따라 달라진다. '항상 크다'고 단정한 ③이 틀리다.
자료 확인: 상자 아래 경계가 $Q_1 = 5.1$, 위 경계가 $Q_3 = 6.4$, 위 수염 끝이 7.9로 표시되어 있다. 중앙선은 중앙값이며 평균을 표시하는 별도 기호는 없다.
계산 과정: $IQR = Q_3 - Q_1 = 6.4 - 5.1 = 1.3$이므로 ②는 맞다.
Q1은 아래쪽 약 25%의 경계이므로 ④는 대략적인 사분위수 설명이다. 경계의 중복값과 계산법에 따라 정확히 25%가 아닐 수 있다.
보기 검토: ①의 7.9는 표시된 이상치가 없으므로 위 수염 끝을 최대값으로 읽는다. 일반 상자그림의 수염 끝은 이상치가 있으면 최대값이 아닐 수 있다.

26. 비모수 검정으로 적절하지 않은 것은?

① 윌콕슨 순위합 검정
② run 검정
③ 만-휘트니 검정
④ t-검정

정답 ④
일반적인 t-검정은 평균에 대한 모수적 검정이므로 ④이다. ① 윌콕슨 순위합과 ③ 만-휘트니는 두 독립 집단의 순위에 기반한 대표 비모수 검정이고, ② runs 검정은 배열의 무작위성 등을 살핀다.
핵심 개념: 비모수 검정은 특정한 정규분포 모형의 모수 검정에 한정하지 않고 순위·부호·배열 등의 정보를 활용한다. 아무 가정도 필요 없는 검정이라는 뜻은 아니다.
보기 검토: 순위합 검정과 만-휘트니 검정은 통상 밀접하게 대응하는 두 표현이다. 대응 자료에 사용하는 윌콕슨 부호순위 검정과도 구별한다.
학습 포인트: 자료가 비정규라는 이유만으로 모든 검정 목적이 동일해지는 것은 아니다. 평균 차이, 분포 차이, 무작위성 중 무엇을 검정하는지 먼저 정한다. 비모수 검정도 표본 독립성이나 분포 모양 등 해석에 필요한 조건을 확인한다.

27. 중심극한정리에 대한 설명으로 잘못된 것은?

① 표본의 크기가 커질수록 정규분포에 따른다.
② 표본 평균에 관한 설명이다.
③ 모집단이 정규분포를 따라야 한다.
④ 모집단이 비대칭일수록 표본의 크기가 커야 한다.

정답 ③
모집단이 반드시 정규분포여야 한다는 ③은 틀리다. 모집단이 비정규여도 조건을 만족하고 표본이 충분히 크면 표본평균에 정규근사를 적용할 수 있다.
핵심 개념: 독립·동일분포 표본이 유한한 평균 μ와 분산 σ^2를 갖는 대표 조건에서, 표본 크기 n이 커지면 표준화한 표본평균의 분포가 정규분포로 가까워진다. 원래 개별 관측값의 분포가 정규로 바뀌는 것은 아니다.
보기 검토: ①은 표본평균의 표집분포를 뜻하는 것으로 보완해 읽고, ②는 대상이 표본평균임을 설명한다. ④는 비대칭이나 두꺼운 꼬리가 있으면 근사에 더 큰 표본이 필요할 수 있다는 일반적 경향이다. 고정된 $n = 30$이 모든 경우에 충분한 것은 아니다.
학습 포인트: $E(\bar{X}) = \mu$, $Var(\bar{X}) = \sigma^2/n$이므로 표본평균의 표준오차는 $\sigma/\sqrt{n}$이다. 표본평균의 분포에 관한 정리이며 개별 관측값의 분포가 정규로 바뀌는 것은 아니다.

28. 비모수 검정에 대한 설명으로 잘못된 것은?

① 표본의 크기가 매우 작을 때 고려할 수 있다.
② 모집단이 정규분포에 가까우면 비모수 검정이 모수 검정보다 항상 더 좋다.
③ 서열척도처럼 평균·분산을 계산하기 어려운 자료에 적절할 수 있다.
④ 모집단의 분포 가정을 만족하기 어려울 때 사용할 수 있다.

정답 ②
모집단이 정규분포를 따르면 모수 검정(t-검정 등)이 정보를 더 많이 활용해 검정력이 높다. 비모수 검정이 항상 더 좋다는 ②가 틀리다.
핵심 개념: 비모수 검정은 모집단 분포에 대한 가정(예: 정규성)이 없거나 약할 때 순위·부호 등을 이용해 검정한다. 부호 검정, 윌콕슨 검정, 만-휘트니 검정, 런 검정 등이 있다.
보기 검토: ①은 표본이 작아 분포를 확인하기 어려운 경우, ③은 순서만 의미 있는 서열척도 자료, ④는 분포 가정을 만족하지 못하는 경우로 모두 비모수 검정을 고려하는 상황이다.
학습 포인트: 비모수 검정도 관측값의 독립성 등 기본 조건은 필요하다. 아무 가정이 없는 검정이라는 뜻이 아니다.

29. 시계열 데이터를 정상화하는 방법 중 적절하지 않은 것은?

① 차분
② 로그 변환
③ 이상치 제거
④ 구간 분할

정답 ④
구간 분할은 연속형 변수를 범주로 나누는 전처리이며 시계열의 추세나 분산 변화를 제거하지 못하므로 ④가 적절하지 않다.
핵심 개념: 정상성은 평균·분산·시차별 공분산이 시간에 따라 일정한 성질이다. 비정상 시계열은 평균이 일정하지 않으면 차분, 분산이 일정하지 않으면 로그 등의 변환을 하고, 이상치가 있으면 처리해 정상화한다.
보기 검토: ① 차분은 평균의 추세를, ② 로그 변환은 분산의 변화를 안정시킨다. ③ 이상치 제거도 정상성 확보를 위한 전처리로 쓰인다.
학습 포인트: 정상성(stationarity), 정규성(normality), 정규화(normalization)는 서로 다른 개념이다.

30. 다음 거래 내역에서 연관규칙 '우유 → 커피'의 신뢰도는?

거래 품목	거래 횟수
{우유, 커피, 과자}	10
{우유, 과자}	40
{커피, 과자, 캔디}	20
{우유, 커피, 캔디}	20
{과자, 캔디}	10

① 0.3

② $\frac{3}{7}$

③ 0.6

④ 0.7

정답 ②

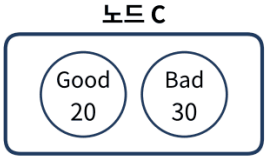
우유 포함 거래는 $10+40+20=70$건, 우유와 커피를 함께 포함한 거래는 $10+20=30$건이다. 신뢰도 $=30/70=3/7\approx0.43$이므로 ②이다.

핵심 개념: 우유→커피 신뢰도는 우유를 포함한 거래 중 커피도 포함한 거래의 비율로 $P(\text{커피}|\text{우유})=\frac{P(\text{우유}\cap\text{커피})}{P(\text{우유})}$이다.

보기 검토: ① 0.3은 전체 100건 중 동시 구매 30건으로 계산한 지지도이다. ③ 0.6은 커피 포함 50건 중 동시 구매 30건으로 계산한 역방향(커피→우유) 신뢰도이다. ④ 0.7은 우유 포함 거래의 비율 P(우유)이다.

학습 포인트: 지지도·신뢰도·향상도는 분모가 다르다. 향상도는 신뢰도 3/7을 $P(\text{커피})=0.5$로 나눈 $6/7\approx0.86$으로 1보다 작아 음의 연관이다.

31. 다음 의사결정나무 노드 C의 지니 지수로 적절한 것은?



① 0.3

② 0.32

③ 0.4

④ **0.48**

정답 ④

노드 C에는 Good 20개, Bad 30개로 전체 50개이다. 지니 지수 $=1-(20/50)^2-(30/50)^2=1-0.16-0.36=0.48$이므로 ④이다.

핵심 개념: 분류나무의 지니 지수(불순도)는 $1-\sum p_k^2$이며 노드 안에 범주가 얼마나 섞여 있는지 나타낸다.

보기 검토: 이진 분류에서는 $2p(1-p)=2\times0.4\times0.6=0.48$로도 검산할 수 있다. 지니 지수는 한 범주만 있으면 0, 두 범주가 반씩 섞이면 최댓값 0.5이다.

학습 포인트: 경제학의 지니계수와 이름이 비슷하지만 다른 지표이다. 0.48은 분류 정확도 48%를 뜻하지 않는다.

32. 시계열 데이터 분석에 대한 설명으로 적절하지 않은 것은?

① 추세요인: 일정한 방향으로 상승 또는 하락하는 경향을 보이는 요인

② 계절요인: 일정한 주기를 가지는 상하 반복의 규칙적인 변동의 요인

③ **순환요인: 알려진 주기 또는 고정된 주기로 반복되는 요인**

④ 불규칙요인: 설명할 수 없는 오차에 해당되는 요인

정답 ③

알려진 또는 고정 주기로 반복한다고 설명한 ③은 계절요인에 가까운 성격을 순환요인으로 연결했으므로 틀리다. 순환은 반복적 흐름이 있어도 주기 길이가 반드시 고정되어 있지는 않다.

핵심 개념: 추세는 장기적인 증가·감소, 계절은 정해진 주기의 반복, 순환은 경기 변동처럼 주기 길이와 진폭이 일정하지 않은 변동, 불규칙은 다른 성분으로 설명되지 않는 변동이다.

보기 검토: ①은 추세, ②는 계절, ④는 설명되지 않는 나머지 변동의 기본 정의와 맞다. 매년 같은 계절의 수요와 경기 확장·수축을 같은 종류로 묶지 않는다.

학습 포인트: 단순히 오르내린다는 사실만으로 계절성을 판정하지 않는다. 반복 주기, 장기 흐름, 설명 가능한 원인을 살핀다. 분해 방법에 따라 가법 모형 $Y=T+S+C+I$ 또는 곱셈형 구조를 고려할 수 있지만 이 문제는 요인 이름과 설명의 대응을 묻는다.

33. 아래 표는 남학생과 여학생의 선호 과일에 대한 빈도 교차표이다. 전체에서 1명을 뽑았을 때, 그 학생이 남학생인 경우 사과를 좋아할 확률은?

구분	사과	딸기
남학생	30	40
여학생	10	20

① $\frac{3}{5}$

② $\frac{7}{10}$

③ $\frac{3}{4}$

④ $\frac{3}{7}$

정답 ④

$P(\text{사과}|\text{남학생})=\frac{30}{30+40}=\frac{30}{70}=\frac{3}{7}$이므로 ④이다. 다른 보기의 3/4는 $30/(30+10)$으로 사과 선호자 중 남학생 비율을 계산한 역조건이다.

핵심 개념: 조건부확률은 이미 주어진 조건에 해당하는 집단으로 분모를 제한한다. 남학생이라는 조건이 주어졌으므로 전체 학생 수가 아니라 남학생 수를 기준으로 한다.

자료 확인: 표에서 남학생은 사과 30명, 딸기 40명으로 전체 70명이다. 여학생은 사과 10명, 딸기 20명이나 분모에 포함하지 않는다.

학습 포인트: P(A|B)와 P(B|A)는 일반적으로 다르다. 남학생이며 사과를 좋아할 전체 기준 확률은 $30/100=0.3$으로 또 다른 값이다. 문제에서 '남학생인 경우'를 확인한 뒤 행의 합을 분모로 정한다. 표에 포함된 범주가 서로 배타적인 응답이라는 조건에서 해석한다.

34. 크기가 100인 데이터에서 복원추출로 100번 뽑아 부트스트랩 표본 하나를 만들 때, 특정 데이터가 한 번도 뽑히지 않을 확률은?

① $(1/100)^{100}$
② $(1/100)^{99}$
③ $(1-1/100)^{100}$
④ $(1-(1/100)^{100})^{100}$

> **정답 ③**
> 100번의 추출이 서로 독립이므로 한 번도 뽑히지 않을 확률은 $(1-1/100)^{100} = (99/100)^{100} \approx 0.366$이고 ③이다.
> 핵심 개념: 부트스트랩은 크기 n인 자료에서 복원추출로 n개를 뽑아 표본을 만든다. 한 번 뽑을 때 특정 데이터가 선택되지 않을 확률은 1−1/n이다.
> 보기 검토: ①은 100번 모두 뽑힐 확률, ②는 근거 없는 식이며, ④도 '한 번도 뽑히지 않음' 사건과 구조가 맞지 않는다.
> 학습 포인트: n이 커지면 $(1-1/n)^n$은 $e^{-1} \approx 0.368$에 가까워진다. 그래서 부트스트랩 표본에는 원자료의 약 63.2%가 포함되고, 뽑히지 않은 약 36.8%(OOB 자료)는 랜덤포레스트 등에서 검증에 쓰인다.

35. Apriori 알고리즘의 수행 순서로 올바르게 나열한 것은?

가. 최소 지지도를 설정한다.
나. 찾은 개별 품목을 이용해 2가지 품목을 찾는다.
다. 개별 품목 중에서 최소 지지도가 넘는 품목을 찾는다.
라. 반복적으로 수행하여 최소 지지도가 넘는 빈발품목집합을 찾는다.

① 가 - 나 - 라 - 다
② 가 - 다 - 나 - 라
③ 다 - 가 - 나 - 라
④ 다 - 나 - 가 - 라

> **정답 ②**
> 가에서 기준 설정, 다에서 빈발 1항목 찾기, 나에서 2항목 후보 구성·검토, 라에서 반복하여 더 큰 빈발집합 탐색이므로 ②이다. 기준을 정하기 전에 빈발 여부를 판정할 수 없다.
> 핵심 개념: Apriori는 빈발집합의 모든 부분집합도 빈발이라는 성질을 이용하여 후보 조합을 가지치기한다. 최소 지지도 조건을 먼저 정하고 단일 항목부터 크기를 늘린다.
> 보기 검토: ①은 단일 항목 검토보다 두 항목 탐색을 앞세우고, ③④는 최소 지지도 설정을 뒤로 배치해 기본 순서와 맞지 않는다. 후보를 생성했다고 모두 빈발이 되는 것은 아니며 거래 자료에서 실제 지지도를 계산한다.
> 학습 포인트: {A,B}가 비빈발이면 이를 포함한 {A,B,C}도 빈발일 수 없어 제거할 수 있다. 빈발항목집합 탐색과 신뢰도 조건으로 규칙을 생성하는 후속 단계를 구별한다. 최소 지지도의 포함 여부는 구현과 기준 문구를 확인한다.

36. 요약 변수의 특징 중 틀린 것은?

① 많은 모델에서 공통으로 사용할 수 있어 재활용 가능성이 높다.
② 수집된 정보를 분석에 맞게 종합한 것이다.
③ 특정조건을 만족하거나 특정 함수에 의해 값을 만들어 의미를 부여한 변수이다.
④ 데이터 마트에서 중요한 변수이다.

> **정답 ③**
> 특정 조건이나 함수로 값을 만들어 별도 의미를 부여한다는 ③은 교재상의 파생변수 설명에 가깝다. 요약과 파생을 구분하는 질문에서 ③을 선택한다.
> 핵심 개념: 요약변수는 여러 기록을 기간·고객 등 분석 단위에 맞춰 집계한 변수이다. 총 구매액, 평균 구매 간격, 거래 횟수처럼 여러 모형에서 재사용할 수 있는 특징을 만든다.
> 보기 검토: ①은 공통 집계의 재활용성, ②는 정보 종합, ④는 분석용 데이터 마트에서의 중요성을 설명한다. 요약변수도 계산함수를 사용하므로 함수의 존재만으로 구분하지 않는다.
> 적용 예: 최근 3개월 총 구매금액은 요약변수, 구매금액과 활동 상태를 조합한 VIP 여부는 조건을 부여한 파생변수의 예이다. 실제 용어 사용에는 범위가 겹칠 수 있어 이 문제는 교재의 대표 정의를 기준으로 판정한다. 분석 단위와 기간을 명확히 해야 계산 결과가 일관된다.

37. 데이터마이닝 모형 평가 기준 중 같은 모집단의 다른 데이터에 적용해도 유사한 결과가 나오는 특성은?

① 다양성
② 일반화
③ 특정화
④ 구간화

> **정답 ②**
> 같은 집단의 다른 데이터에 적용해도 유사한 결과가 나오는 특성은 ② 일반화이다.
> 핵심 개념: 일반화(generalization)는 학습에 사용한 데이터뿐 아니라 같은 모집단에서 나온 새로운 데이터에도 모형이 안정적으로 비슷한 성능을 내는 성질이다.
> 보기 검토: ① 다양성, ③ 특정화는 모형 평가 기준의 용어가 아니며, ④ 구간화는 연속형 변수를 범주로 나누는 전처리 기법이다.
> 학습 포인트: 학습 데이터에만 지나치게 맞춘 과대적합 모형은 일반화 성능이 낮다. 일반화 성능은 검증·평가용 데이터로 확인한다.

38. 회귀분석의 독립변수들 간에 강한 상관관계가 나타나는 문제를 의미하는 것은?

① 다중공선성
② 회귀계수
③ 선형계수
④ 상관계수

> **정답 ①**
> 독립변수 사이 강한 상관이라는 지문은 ① 다중공선성이다. 회귀계수나 상관계수는 관계를 표현하는 수치이며 문제의 이름 자체가 아니다.
> 핵심 개념: 다중공선성은 회귀모형의 설명변수들이 강하게 선형 관련되어 개별 효과를 분리해 추정하기 어려운 문제이다. 완전한 선형 종속이면 일반적인 계수 추정이 유일하지 않을 수 있다.
> 보기 검토: ② 회귀계수는 다른 변수 조건에서의 효과를 나타내는 모수 추정, ④ 상관계수는 두 변수 관계의 지표이다. ③은 이 문제의 정해진 진단 명칭에 해당하지 않는다.
> 학습 포인트: 표준오차 증가, 계수의 불안정, 해석 어려움 등이 나타날 수 있다. 모든 쌍의 상관이 작더라도 여러 변수의 선형결합에서 문제가 생길 수 있어 VIF 등을 검토한다. 오차항의 독립성 가정과 설명변수끼리의 관련성을 혼동하지 않는다.

39. 두 변수의 상관관계가 클 때 유사도 거리를 측정하는 방법은?

① 맨하탄 거리
② 유클리드 거리
③ 표준화 거리
④ 마할라노비스 거리

> **정답 ④**
> 두 변수 사이 상관이 클 때 이를 반영한 거리를 묻는 취지이므로 ④이다. 큰 상관 자체가 거리 계산 불가능을 뜻하는 것은 아니다.
> 핵심 개념: 마할라노비스 거리는 공분산 행렬을 이용하여 변수의 분산과 상관구조를 반영한다. $d^2 = (x-y)^T \Sigma^{-1} (x-y)$로 표현할 수 있다. 단위와 변수 간 중복 정보를 함께 고려하는 거리이다.
> 보기 검토: ① 맨해튼은 절댓값 차이 합, ② 유클리드는 제곱 차이 합의 제곱근이다. ③ 표준화 거리는 변수별 척도 차이를 줄일 수 있지만 일반적으로 전체 공분산의 비대각 상관구조까지 반영하지는 않는다.
> 학습 포인트: 공분산 행렬이 특이하면 역행렬을 그대로 사용할 수 없어 변수 선택이나 정규화된 추정 등이 필요하다. 상관이 높다는 이유만으로 항상 마할라노비스가 최적이라는 보장은 없고 자료 규모와 추정 안정성을 함께 확인한다.

40. 주성분 분석에 대한 설명으로 잘못된 것은?

① 차원 축소 기능이 있다.
② 차원 축소로 예측에도 활용이 가능하다.
③ 독립변수와 종속변수의 선형관계를 파악하기 위한 분석이다.
④ 주성분 간에는 상관관계가 없다.

> **정답 ③**
> 독립변수와 종속변수의 선형관계를 파악하는 것은 회귀분석의 목적이다. PCA는 종속변수 없이 변수들의 분산 구조를 요약하는 비지도 차원 축소 기법이므로 ③이 틀리다.
> 핵심 개념: PCA는 원 변수들의 선형결합으로 직교하는 주성분을 만들고 적은 성분으로 자료의 분산을 표현하는 차원 축소 방법이다. 반응변수를 직접 최적화하는 지도 예측모형은 아니다.
> 보기 검토: ①은 차원 축소, ②는 축소한 특징을 후속 예측모형에 사용 가능하다는 뜻, ④는 양의 분산 주성분 사이 무상관 성질로 적절하다. 차원 축소가 예측 성능을 반드시 높이지는 않는다.
> 학습 포인트: 원 변수의 상관과 주성분 사이 상관을 구별한다. 단위 차이가 크면 표준화 여부가 결과에 중요하다. 주성분 수는 누적 설명분산과 후속 목적 등을 함께 고려하고 무상관을 일반적 독립으로 확대하지 않는다.

41. K-means 군집분석을 활용할 수 있는 그래프는?

① 잔차 산점도
② ROC 그래프
③ 집단 내 제곱합 그래프
④ 향상도 곡선

> **정답 ③**
> K에 따른 집단 내 제곱합(WSS) 그래프에서 감소 폭이 급격히 줄어드는 엘보(elbow) 지점을 적정 군집 수로 참고한다. 따라서 ③이다.
> 핵심 개념: K-means의 군집 수를 선택할 때 K에 따른 군집 내 제곱합 WCSS 또는 inertia의 감소를 그려 엘보 지점을 참고할 수 있다. K를 늘릴수록 감소 효과가 작아지는 곳을 살핀다.
> 보기 검토: ① 잔차 산점도는 회귀모형의 가정 점검, ② ROC 그래프는 분류 모형의 임계값별 성능, ④ 향상도 곡선은 분류 모형의 상위 등급별 성과 평가에 쓰인다.
> 학습 포인트: 실루엣 계수도 군집 수 판단에 쓰인다.

42. 확률에 대한 설명으로 잘못된 것은?

① 두 사건이 서로 배반이면 두 사건이 동시에 일어날 확률은 0이다.

② 한 사건 A가 일어날 확률을 P(A)라 할 때, n번의 반복시행에서 A가 일어난 횟수를 r이라 하면 상대도수 r/n은 n이 커짐에 따라 P(A)에 가까워진다.

③ 조건부 확률을 이용해 사전확률로부터 사후확률을 계산하는 것은 베이즈 정리이다.

④ 두 사건이 독립이면 동시에 일어날 확률은 두 사건 확률의 합이다.

정답 ④

독립사건의 동시 발생 확률은 곱으로 계산하므로 합이라고 한 ④가 틀리다.

핵심 개념: 두 사건이 독립이면 $P(A \cap B) = P(A)P(B)$이다. 배반(상호 배타)이면 $P(A \cap B) = 0$이고 $P(A \cup B) = P(A) + P(B)$이다.

보기 검토: ①은 배반사건의 정의, ②는 큰수의 법칙, ③은 베이즈 정리 $P(A|B) = \frac{P(B|A)P(A)}{P(B)}$의 설명이다.

계산 예: $P(A) = 0.4$, $P(B) = 0.5$인 독립사건이면 $P(A \cap B) = 0.2$, $P(A \cup B) = 0.4 + 0.5 - 0.2 = 0.7$이다. 독립과 배반은 다른 개념이며, 확률이 0보다 큰 두 사건은 배반이면서 독립일 수 없다.

43. 회귀분석에서 개별 회귀계수의 유의성을 검정하는 t-검정의 귀무가설과 대립가설로 적절한 것은?

① H_0: 회귀계수 $\neq 0$, H_1: 회귀계수 $= 0$

② H_0: 회귀계수 $= 0$, H_1: 회귀계수 $\neq 0$

③ H_0: 상관계수 $\neq 1$, H_1: 상관계수 $= 1$

④ H_0: 회귀계수 $= 1$, H_1: 회귀계수 $\neq 1$

정답 ②

귀무가설은 '회귀계수=0', 대립가설은 '회귀계수≠0'이므로 ②이다. p값이 유의수준보다 작으면 귀무가설을 기각하고 계수가 유의하다고 판단한다.

핵심 개념: 개별 회귀계수의 t-검정은 해당 설명변수가 종속변수에 영향이 없는지(계수=0)를 검정한다. 검정통계량은 $t = \frac{\text{추정 계수}}{\text{표준오차}}$이다.

보기 검토: ①은 가설을 반대로 놓았고, ③은 상관계수와 혼동했으며, ④는 기준값을 1로 잘못 두었다.

학습 포인트: 모형 전체의 유의성은 F-검정(H_0: 모든 회귀계수 $= 0$)으로 확인한다. 등호는 항상 귀무가설에 둔다.

44. 1~100번의 서로 다른 개체에서 비복원 단순무작위추출로 10개를 뽑는다. 옳지 않은 것은?

① 1번과 100번의 표본 포함 확률은 같다.

② 1번과 2번의 동시 포함 확률은 99번과 100번의 동시 포함 확률과 같다.

③ 1번과 2번이 모두 표본에 포함될 확률은 1/100이다.

④ 각 개체의 표본 포함 확률은 10/100이다.

정답 ③

두 개체가 함께 포함될 확률은 $(10/100) \times (9/99) = 1/110$이므로 1/100이라는 ③이 틀리다. 각 개체의 포함 확률은 $10/100 = 0.1$이므로 ①④는 맞다.

핵심 개념: 100개 중 10개를 비복원 단순무작위추출하면 개체 번호와 관계없이 포함 확률이 동일하다. 한 개체의 포함을 이미 안다면 남은 99개에서 추가 9개가 포함된다.

보기 검토: 어떤 두 번호를 골라도 함께 포함될 확률은 1/110으로 같으므로 ②가 맞다. 1번이 포함되었다는 조건에서 2번이 포함될 조건부확률은 $9/99 = 1/11$이다.

학습 포인트: 비복원추출에서는 앞의 추출 결과에 따라 다음 확률이 달라지지만, 최종 표본에 포함될 확률은 모든 개체가 같다.

45. 군집분석의 적용에 대한 설명으로 옳지 않은 것은?

① 여러 과목의 점수로 학생을 군집화할 때 K-means를 활용할 수 있다.

② SOM은 고차원 관측값을 낮은 차원의 격자에 배치하는 데 활용할 수 있다.

③ 군집을 3개로 나누려면 반드시 K-means만 사용해야 한다.

④ 군집화 대상에 맞는 특징과 유사도 또는 거리를 정해야 한다.

정답 ③

군집 수가 정해져 있어도 계층적 군집(덴드로그램을 원하는 높이에서 자름), 혼합분포 군집, SOM 등 여러 방법을 쓸 수 있다. 반드시 K-means만 사용해야 한다는 ③이 틀리다.

핵심 개념: 군집분석은 묶으려는 대상에 맞춰 특징 벡터와 거리·유사도를 정의한다. 학생, 상품, 고객 중 무엇을 묶는지에 따라 관측 단위와 사용할 특징이 달라진다.

보기 검토: ①은 수치 점수 기반 K-means 활용, ②는 SOM의 저차원 격자 표현, ④는 자료 유형과 목적에 따른 특징·거리 선택으로 적절하다. 학생 점수도 척도와 표준화 여부를 검토해야 한다.

학습 포인트: 군집 방법은 자료의 형태, 이상치, 군집 모양, 해석 목적에 따라 고른다.

46. job이 0 또는 1인 더미변수일 때 다음 회귀식의 해석으로 부적절한 것은? (모든 계수는 유의하다)

회귀식: wage = 5632 + 1300 × age + 3721 × job

① 두 집단(job=0, job=1)의 y절편이 다르다.
② age의 회귀계수는 두 집단에서 같다.
③ age가 1 증가할 때 wage의 증가량은 두 집단에서 같다.
④ age와 job의 교호작용이 유의하다.

정답 ④
회귀식에 age×job 교호작용 항이 없으므로 교호작용이 유의한지는 이 식으로 판단할 수 없다. ④가 부적절하다.

핵심 개념: 더미변수의 계수는 기준 집단과의 절편 차이를 나타낸다. 교호작용 항(age×job)이 없으면 두 집단의 age 기울기는 같다.
계산 과정: $job = 0$이면 $wage = 5632 + 1300 \times age$, $job = 1$이면 $wage = (5632 + 3721) + 1300 \times age = 9353 + 1300 \times age$이다. 절편만 다르고 기울기 1300은 같다.
보기 검토: ①은 절편 5632와 9353의 차이, ②③은 공통 기울기 1300으로 맞는 해석이다.
학습 포인트: 교호작용 항 $\beta_3(age \times job)$을 추가하면 $job = 1$ 집단의 기울기는 $1300 + \beta_3$로 달라질 수 있다.

47. 다음은 swiss 데이터에서 Fertility를 종속변수로 한 회귀분석 결과이다. 해석으로 부적절한 것은?

```
> summary(lm(Fertility ~ ., data = swiss))
Coefficients:
                 Estimate Std. Error t value Pr(>|t|)
(Intercept)      66.91518   10.70604   6.250 1.91e-07 ***
Agriculture      -0.17211    0.07030  -2.448  0.01873 *
Examination      -0.25801    0.25388  -1.016  0.31546
Education        -0.87094    0.18303  -4.758 2.43e-05 ***
Catholic          0.10412    0.03526   2.953  0.00519 **
Infant.Mortality  1.07705    0.38172   2.822  0.00734 **
Residual standard error: 7.165 on 41 degrees of freedom
Multiple R-squared:  0.7067,  Adjusted R-squared:  0.671
F-statistic: 19.76 on 5 and 41 DF,  p-value: 5.594e-10
```

① 잔차 자유도와 독립변수 수로 보아 데이터 개수는 46개이다.
② 모든 회귀계수가 유의수준 5%에서 유의한 것은 아니다.
③ 다른 변수가 같을 때 Agriculture가 증가하면 Fertility는 감소한다.
④ 조정결정계수(Adjusted R-squared)는 0.671이다.

정답 ①
잔차 자유도 41, 독립변수 5개이므로 $n = 41 + 5 + 1 = 47$이다. 절편을 빼먹고 46개로 계산한 ①이 틀리다.

핵심 개념: 절편이 있는 다중회귀에서 잔차 자유도는 $n - p - 1$이다(n: 데이터 수, p: 독립변수 수).
보기 검토: ② Examination의 p값 0.315는 0.05보다 커서 유의하지 않으므로 맞다. ③ Agriculture 계수 −0.172로 음수이므로 맞다. ④ Adjusted R-squared는 0.671이다.
학습 포인트: F-statistic의 자유도(5, 41)에서도 독립변수 5개, 잔차 자유도 41을 읽을 수 있다. 회귀계수가 유의해도 관찰자료만으로 인과관계를 확정하지 않는다.

48. 로지스틱 회귀모형 $\log \dfrac{P}{1-P} = \beta_0 + \beta_1 X_1 + \beta_2 X_2$에서 $e^{\beta_1} = 1.006$, $e^{\beta_2} = 0.489$일 때, X_2가 1 증가할 때의 해석으로 가장 적절한 것은? (P는 Y=1일 확률)

① 다른 변수가 일정할 때 Logit이 48.9% 감소한다.
② 다른 변수가 일정할 때 Logit이 48.9% 증가한다.
③ 다른 변수가 일정할 때 Odds가 0.489배가 된다.
④ 다른 변수가 일정할 때 Odds가 48.9% 증가한다.

정답 ③
$e^{\beta_2} = 0.489$이므로 다른 변수가 일정할 때 X_2가 1 증가하면 오즈가 0.489배가 된다. 따라서 ③이다. 오즈가 $1 - 0.489 = 0.511$, 즉 약 51.1% 감소한다는 뜻이다.

핵심 개념: 오즈(Odds)는 $\dfrac{P}{1-P}$이고 로짓(Logit)은 $\log(Odds)$이다. 계수 β는 설명변수가 1 증가할 때 로짓의 변화량이고, e^{β}는 오즈가 몇 배가 되는지(오즈비)를 나타낸다.
보기 검토: ①②는 오즈비를 로짓의 변화율로 잘못 해석했다. 로짓은 $\beta_2 = \log(0.489) \approx -0.715$만큼 변한다. ④는 감소를 증가로 바꾸었다.
학습 포인트: $e^{\beta_1} = 1.006$이면 X_1이 1 증가할 때 오즈가 약 0.6% 증가한다. 오즈비는 확률의 변화율이 아니다. 이 수치는 ISLR Default 데이터의 glm(default ~ balance + student) 결과(balance 1.0058, studentYes 0.4893)와 같다.

49. 계층적 군집분석에서 군집 수를 결정하는 방법에 대한 설명으로 가장 적절한 것은?

① 와드 연결법에서 오차제곱합이 크게 증가하는 지점을 참고할 수 있다.

② 단일 연결법이 군집 간 거리를 항상 최적으로 결정한다.

③ 중심 연결법이 모든 상황에서 가장 유리하다.

④ 군집 수는 항상 2~3개로 정하는 것이 가장 좋다.

정답 ①

오차제곱합이 크게 증가하는 지점을 군집 수 결정의 참고로 삼는 ①이 적절하다.

핵심 개념: 와드 연결법은 두 군집을 합쳤을 때 군집 내 오차제곱합의 증가량이 가장 작은 쌍을 병합한다. 증가량이 갑자기 커지는 단계는 서로 다른 군집을 억지로 합치기 시작한다는 신호이다.

보기 검토: ②③은 특정 연결법이 항상 최적이라고 단정해 틀리다. 연결법마다 장단점이 있고 자료에 따라 결과가 달라진다. ④처럼 군집 수를 미리 고정하는 규칙은 없다.

학습 포인트: 덴드로그램의 높이(병합 거리)가 크게 벌어지는 곳을 잘라 군집 수를 정하기도 한다. 업무 해석 가능성도 함께 본다.

50. 다음 거래 내역에서 연관규칙 'X → Y'의 향상도(Lift)는?

거래	품목
거래 1	{X, Y, Z}
거래 2	{X, Y, W}
거래 3	{X, R}
거래 4	{Y, Z}
거래 5	{X, Y, Z, W}
거래 6	{R}

① $\frac{9}{8}$

② $\frac{8}{9}$

③ $\frac{7}{8}$

④ $\frac{8}{7}$

정답 ①

전체 6건 중 X 포함 4건(1·2·3·5), Y 포함 4건(1·2·4·5), X와 Y 동시 포함 3건(1·2·5)이다. 신뢰도 $= 3/4$, $P(Y) = 4/6 = 2/3$이므로 향상도 $= \frac{3/4}{2/3} = \frac{9}{8}$이고 ①이다.

핵심 개념: 향상도(X→Y) $= \frac{P(Y|X)}{P(Y)} = \frac{P(X \cap Y)}{P(X)P(Y)}$이다. 1보다 크면 양의 연관, 1이면 독립, 1보다 작으면 음의 연관이다.

보기 검토: ②는 역수, ③④는 분모·분자를 잘못 잡은 값이다.

학습 포인트: 향상도는 방향과 관계없이 같아 Y→X도 9/8이다. $9/8 > 1$이므로 X를 방문한 사람이 Y도 방문하는 경향이 우연보다 약간 높다.