ADsP 제45회 기출 복원문제

유형 2

정답·해설 수록본

총 50문항 · 4지선다 · 90분

1과목 데이터 이해 (1~10번)

1. DIKW 모델에서 '데이터(Data)'에 대한 설명으로 가장 적절하지 않은 것은?

① 데이터는 정보의 기초가 되는 원시 자료이다.
② 데이터는 가공되지 않은 사실이나 관찰 결과이다.
③ 데이터는 해석 없이 존재하는 숫자나 문자 등의 값이다.
④ 데이터는 지식과 아이디어가 결합된 창의적 산물이다.

정답 ④

④의 지식과 아이디어를 결합한 창의적 산물은 원시 자료라는 데이터의 정의와 맞지 않는다. ①②③은 가공 전 사실이라는 공통된 성격을 설명한다.

핵심 개념: DIKW는 데이터, 정보, 지식, 지혜의 단계이다. 데이터는 측정값·기록처럼 의미를 해석하기 전의 원시 사실이며, 정보는 이를 정리하여 맥락과 의미를 부여한 결과이다. 지식은 정보 사이의 관계와 규칙을 이해한 것이고, 지혜는 이를 상황에 맞는 판단과 행동으로 연결하는 단계이다.
적용 예: 날짜별 매출액 기록은 데이터, 전월 대비 매출 증가율은 정보, 기온 상승과 판매 증가의 관계를 이해하는 것은 지식, 이 관계를 고려해 재고를 조정하는 판단은 지혜에 대응한다. 숫자라는 형식보다 의미 부여와 활용의 수준을 구분한다.

2. 빅데이터에 대한 설명으로 적절하지 않은 것은?

① 빅데이터는 비정형 데이터도 포함한다.
② 빅데이터로는 개인 맞춤화 서비스가 불가능하다.
③ 빅데이터는 대용량, 다양성, 속도 등을 특징으로 한다.
④ 빅데이터 분석을 통해 사용자의 행동을 예측할 수 있다.

정답 ②

고객의 구매 이력과 행동을 분석하면 관심 상품이나 이용 가능성을 추정하여 개인별 추천과 맞춤 서비스를 제공할 수 있다. 따라서 불가능하다는 ②는 틀리다. ①③④는 가능한 특성이나 활용을 설명한다.

핵심 개념: 빅데이터는 양뿐 아니라 생성·처리 속도, 형태의 다양성 등을 함께 고려하는 개념이다. 표 형태의 정형 자료, JSON 같은 반정형 자료, 사진·음성·문장 같은 비정형 자료를 포함할 수 있다.
학습 포인트: 맞춤화가 가능하다는 말은 예측이 항상 정확하거나 데이터가 많으면 자동으로 성능이 높아진다는 뜻은 아니다. 자료 품질, 분석 방법, 검증 결과에 따라 실제 성과가 달라진다. 시험에서는 '불가능하다'와 같은 단정 표현이 개념과 충돌하는지 먼저 확인한다.

3. 데이터베이스의 특징으로 적절하지 않은 것은?

① 데이터베이스는 일관성과 무결성을 유지한다.
② 데이터베이스는 여러 사용자가 동시에 접근할 수 있다.
③ 데이터베이스는 데이터의 중복을 최소화한다.
④ 데이터베이스는 사용자 모두가 동일한 목적을 가지고 데이터를 활용하도록 설계된다.

정답 ④

같은 고객 자료를 영업부는 판매 분석에, 배송부는 배송 처리에, 고객지원부는 문의 대응에 사용할 수 있다. 공동 이용은 동일한 목적을 강제한다는 뜻이 아니므로 ④가 틀리다. ②의 동시 접근과 ③의 중복 최소화는 대표 특징이다.

핵심 개념: 데이터베이스는 여러 업무와 사용자가 공동으로 활용할 수 있도록 자료를 구조화하여 저장한 집합이다. DBMS는 저장·검색·변경·접근 등을 관리하며 일관성과 무결성을 확보하도록 지원한다.
보기 검토: ①은 DBMS의 제약과 관리 기능을 포함한 취지로 읽는다. 데이터베이스를 만든 것만으로 모든 오류가 자동 제거되는 것은 아니다. ③도 물리적 중복이 절대로 없다는 뜻보다는 불필요한 중복을 통제한다는 의미이다. 복제나 백업처럼 의도된 중복은 존재할 수 있다.

4. 데이터의 일관성과 정확성을 유지하고 검증하는 DBMS의 특징은 무엇인가?

① 데이터의 다양성
② 데이터의 확장성
③ 데이터의 무결성
④ 데이터의 중복성

정답 ③

데이터의 정확성과 일관성을 유지·검증한다는 지문은 ③ 무결성에 해당한다. ① 다양성은 자료 형태와 종류, ② 확장성은 규모 증가에 대응하는 능력, ④ 중복성은 같은 자료가 반복 존재하는 성격이므로 질문과 다르다.

핵심 개념: 무결성은 데이터가 정해진 규칙을 만족하여 정확하고 일관된 상태를 유지하는 성질이다. 기본키의 유일성, 필수 항목의 값 존재, 외래키의 참조 관계, 허용 범위 등이 이를 위한 제약이다.
적용 예: 주문이 존재하지 않는 고객 번호를 참조하면 참조무결성을 위반한다. 음수가 허용되지 않는 수량에 −3을 입력하면 도메인 제약을 위반한다. 무결성은 접근 권한을 다루는 보안과 구별되지만, 실제 관리에서는 두 기능이 함께 필요하다.

5. 자동차 회사에서 엔지니어링과 에너지의 최적 조합을 통해 연료 효율성을 극대화하는 차량 설계 디자인 시 적합한 알고리즘은?

① 회귀분석
② 의사결정나무
③ k-최근접 이웃 (K-NN: K-Nearest Neighbors)
④ 유전자 알고리즘

정답 ④
차량 설계에서 여러 공학적 요소와 에너지 관련 조건의 조합을 비교하여 연료 효율을 높이는 상황은 최적화 문제이므로 ④가 가장 적합하다. 효율이나 비용을 적합도 함수로 정의하여 후보 조합을 평가한다.

핵심 개념: 유전자 알고리즘은 후보 해를 개체로 표현하고 선택·교차·돌연변이를 반복하여 목적함수가 좋은 해를 탐색하는 최적화 방법이다. 다양한 설계 요소의 조합을 탐색하는 문제에 활용할 수 있다.
보기 검토: ① 회귀는 설명·예측, ② 의사결정나무는 규칙 기반 분류·회귀, ③ K-NN은 가까운 관측값을 이용한 예측이 중심이다. 이 기법들이 설계 평가에 보조적으로 사용될 수는 있지만, 조합 탐색이라는 질문의 핵심에는 유전자 알고리즘이 대응한다. 탐색 결과가 반드시 전역 최적해라는 보장은 없다.

6. 개인정보 비식별화 기술에 대한 설명으로 가장 적절하지 않은 것은?

① 범주화 : 상세한 값을 일반적인 범주로 바꾸는 기법
② 가명처리 : 실제 정보 대신 가짜 값을 사용하는 기법
③ 총계처리 : 개별 값이 아닌 전체 집계 값을 사용하는 기법
④ 데이터마스킹 : 개인 정보 식별이 가능한 특정 데이터 값을 삭제하는 기법

정답 ④
교재 분류에서 식별 가능한 특정 값을 삭제하는 설명은 데이터 삭제에 대응하며, 데이터마스킹은 일부 값을 가리거나 대체하여 노출을 줄이는 방식으로 구분하므로 ④를 선택한다. 예를 들어 전화번호 일부를 별표로 가리는 것은 마스킹의 예이다.

핵심 개념: 범주화는 나이 37을 30대로 바꾸는 일반화이고, 가명처리는 실제 식별값을 다른 값으로 대체하는 방법이다. 총계처리는 개인별 수치 대신 집단 합계나 평균 등을 사용하는 방식이다.
표현 주의: 실무에서는 마스킹이라는 용어를 넓게 쓰기도 하므로 삭제와 마스킹의 경계가 항상 동일한 것은 아니다. 이 문제는 교재의 기법 이름 대응을 묻는다. 이름을 바꾸거나 일부 값을 가린 것만으로 모든 재식별 가능성이 사라진다고 판단해서는 안 된다. 개념 구분을 설명하는 문항이며 실제 자료 처리의 법적 적합성을 판정하는 문제는 아니다.

7. 빅데이터 분석 및 활용의 최종 목표로 가장 적절한 것은?

① 저장 용량 확보
② 데이터 수집 자동화
③ 새로운 가치 창출
④ 시스템 로그 분석

정답 ③
③ 새로운 가치 창출이 최종 목표에 해당한다. ① 저장 용량 확보와 ② 수집 자동화는 분석을 가능하게 하는 수단이며, ④ 시스템 로그 분석은 구체적인 분석 활동이다. 목표와 수단, 활동을 같은 수준으로 혼동하지 않는다.

핵심 개념: 분석의 목적은 데이터를 모으고 저장하는 활동 자체를 넘어서 문제 해결과 의사결정 개선을 통해 가치를 만드는 것이다. 가치에는 매출 증가, 비용 절감, 위험 감소, 서비스 개선 등이 포함된다.
적용 예: 설비 데이터를 저장하는 것은 기반 마련이고, 이를 분석해 고장 징후를 찾는 것은 분석 활동이다. 그 결과 불시 정지를 줄이고 운영 비용을 낮추는 것이 가치이다. 프로젝트를 기획할 때는 분석 성능뿐 아니라 실제 업무 결과를 어떤 지표로 확인할지도 정해야 한다.

8. 데이터 활용 사례로 적절하지 않은 것은?

① 마케팅 캠페인의 전환율을 분석해 타깃 고객층을 최적화한다.
② 사용자 후기를 분석해 만족도와 개선 지점을 파악한다.
③ 과거 가스 사용량으로 향후 24시간 공급량을 최적화한다.
④ 전문가 심층 면담만으로 업무 절차를 개선한다.

정답 ④
④는 데이터를 수집·분석하지 않고 몇몇 전문가의 의견만으로 절차를 바꾸는 정성적 조사에 가까우므로 데이터 활용 사례로 보기 어렵다.

핵심 개념: 데이터 활용 사례는 수집·축적한 데이터를 분석해 의사결정이나 업무 개선에 연결하는 경우이다. 숫자뿐 아니라 후기 같은 텍스트도 분석 대상이 된다.
보기 검토: ①은 캠페인 반응 데이터, ②는 후기 텍스트 데이터, ③은 사용량 시계열 데이터를 분석해 의사결정에 활용한다.
학습 포인트: 면담 기록도 체계적으로 수집해 분석하면 정성 데이터 분석이 될 수 있다. 이 문항의 핵심은 '만으로'처럼 데이터 분석 없이 판단하는지 여부이다.

9. 빅데이터 정보를 활용하는 방식으로 가장 적합하지 않은 것은?

① 개인정보를 대규모로 공유한다.
② 데이터를 익명화하여 연구에 활용한다.
③ 분석된 결과를 정책 수립에 반영한다.
④ 소비자 트렌드를 파악하여 제품을 개발한다.

정답 ①
①은 아무 조건 없이 개인정보를 대규모로 공유하는 표현이므로 이 문맥에서는 가장 부적절하다. 자료를 공유하는 규모 자체만으로 적절성 여부가 결정되는 것은 아니며 목적·범위·보호조치가 빠져 있다는 점이 문제이다.

핵심 개념: 데이터 활용은 목적과 필요한 범위를 정하고 정보 노출과 오용 위험을 함께 고려해야 한다. 연구 활용, 정책 반영, 제품 개발은 분석의 대표 목적이다.
보기 검토: ②는 연구 활용 전 식별 가능성을 낮추는 취지이나 익명화라는 이름만으로 위험이 없어지는 것은 아니다. ③④는 분석 결과를 의사결정으로 연결한다. 이 문항은 정보 활용의 일반적 방향을 묻는 학습 문제이며, 특정 개인정보 처리의 법적 허용 여부를 단정하는 근거로 사용하지 않는다.

10. 빅데이터 시대의 위기 요인에 대한 해결 방안으로 적합하지 않은 것은?

① 개인정보 활용에 대한 사전 동의 절차를 강화한다.

② 개인정보 사용자의 책임을 강화한다.

③ 결과 기반 책임 원칙을 강화한다.

④ 알고리즘 접근권과 설명 가능성을 확대한다.

정답 ①

빅데이터는 수집할 때 예상하지 못한 목적으로 재활용되므로 매번 사전 동의를 받는 방식에는 한계가 있다. 그래서 동의제에서 사용자 책임제로 전환할 것을 제시하며, 사전 동의 강화를 해결 방안으로 든 ①이 적합하지 않다.

핵심 개념: 빅데이터의 위기 요인과 통제 방안은 사생활 침해→동의에서 사용자 책임으로 전환, 책임 원칙 훼손→결과 기반 책임 원칙 고수, 데이터 오용→알고리즘 접근 허용으로 짝지어진다.
보기 검토: ②는 사생활 침해, ③은 책임 원칙 훼손(예측만으로 처벌하지 않고 실제 결과로 책임을 묻는다), ④는 데이터 오용에 대한 대응이다.
학습 포인트: 일반 상식으로는 동의 강화도 보호 수단처럼 보이지만, 시험에서는 위기 요인과 통제 방안의 대응 관계를 기준으로 판단한다.

2과목 데이터 분석 기획 (11~20번)

11. 분석방법은 알고 있으나 그 대상을 모를 때 적용하는 분석 기획 유형으로 적합한 것은?

① 진단
② 통찰
③ 솔루션
④ 최적화

정답 ②
지문은 방법을 알고 있고 대상을 모르는 조건이므로 ② 통찰에 해당한다. ③ 솔루션과 조건이 반대이며 ④ 최적화는 두 요소가 모두 명확해야 한다. ① 진단은 이 문항의 정해진 네 유형 명칭에 해당하지 않는다.

핵심 개념: 분석 대상과 분석 방법의 인지 여부에 따라 과제 도출 유형을 나눈다. 대상과 방법을 모두 알면 최적화, 대상은 알지만 방법을 모르면 솔루션, 방법은 알지만 대상은 모르면 통찰, 둘 다 모르면 발견이다.
적용 예: 이미 사용할 수 있는 군집화나 시각화 기법을 갖고 여러 자료를 탐색하면서 어디에 적용할지 새로운 문제를 찾는 경우를 생각할 수 있다. 기법 이름을 안다는 것과 해결할 업무 문제가 명확하다는 것을 구별하여 대상 O/X, 방법 O/X를 먼저 표시한다.

12. 상향식 접근 방법에 대한 설명 중 옳지 않은 것은?

① 비정형 문제 해결에 효과적이다.
② 직관과 경험을 통해 접근한다.
③ 문제 상황이 명확하지 않은 경우에 활용된다.
④ 문제가 명확히 정의되어 있는 경우 답을 찾는 기법이다.

정답 ④
④는 문제가 명확히 정의된 뒤 답을 찾는 방식으로 설명하여 상향식의 대표 특징과 맞지 않는다. ①③은 비정형·불명확한 문제 상황에 대응한다. 하향식 접근은 업무 문제에서 출발하여 정의와 해결방안을 좁혀 간다.

핵심 개념: 상향식 접근은 자료 탐색에서 패턴과 새로운 문제를 찾아내는 흐름이다. 문제나 분석 대상이 처음부터 명확하지 않은 상황에서 발견과 통찰을 얻는 데 적합하다.
보기 보완: ②의 직관과 경험은 탐색 가설을 만들거나 결과를 해석하는 데 도움을 줄 수 있지만 상향식 분석이 자료 없이 직감만으로 결론을 내리는 방법이라는 뜻은 아니다. 탐색 결과를 실제 자료와 추가 검증으로 확인해야 한다. 비지도학습은 상향식 탐색에 활용되는 대표 기법이다.

13. 전사 차원의 표준화된 데이터 관리 체계로 프로세스, 운영조직 등을 포함하는 것은?

① 데이터 품질
② 데이터 거버넌스
③ 데이터 시각화
④ 데이터 적재

정답 ②
전사 차원의 표준 관리 체계이며 프로세스와 운영조직을 포함한다는 지문은 ② 데이터 거버넌스에 해당한다. 개별 데이터 품질 관리보다 범위가 넓다.

핵심 개념: 데이터 거버넌스는 조직 전체에서 데이터를 어떤 원칙과 책임, 절차에 따라 관리하고 활용할지 정하는 체계이다. 표준, 품질, 관리 역할, 운영 프로세스 등을 일관되게 연결한다.
보기 검토: ① 데이터 품질은 정확성·완전성·일관성 등 자료 상태를 다룬다. ③ 시각화는 정보를 그림으로 표현하는 활동이고, ④ 적재는 자료를 저장 위치로 옮기는 처리이다. 고객 코드 기준을 누가 정하고 변경을 누가 승인하며 오류를 어떻게 수정할지 정하는 것은 거버넌스의 구체적 예이다.

14. 데이터 분석 성숙도 모델에서 분석 기법은 부족하나 조직 및 인력 준비도가 높아 분석을 바로 시행할 수 있는 기업의 수준은?

① 도입형
② 성숙형
③ 실험형
④ 분석 지향형

정답 ①
조직·인력 등 준비도는 높지만 분석 업무와 기법의 활용 수준(성숙도)이 낮아 바로 분석을 도입할 수 있는 기업은 ① 도입형이다.

핵심 개념: 분석 수준 진단은 준비도(조직·인력·기법·데이터·문화·인프라)와 성숙도(실제 분석 활용 수준) 두 축으로 기업을 네 유형으로 나눈다. 준비도와 성숙도가 모두 낮으면 준비형, 준비도는 높고 성숙도는 낮으면 도입형, 준비도는 낮고 성숙도는 높으면 정착형, 둘 다 높으면 확산형이다.
보기 검토: ② 성숙형, ③ 실험형, ④ 분석 지향형은 준비도·성숙도 사분면의 유형 이름이 아니다.
학습 포인트: '도입형=준비도는 갖췄으니 도입하면 된다', '정착형=이미 분석을 쓰고 있으나 기반이 부족해 정착이 필요하다'로 기억한다. 성숙도 단계(도입·활용·확산·최적화)와 사분면 유형 이름을 혼동하지 않는다.

15. 과제 우선순위 평가할 때 고려하는 기준으로 본원적 업무와의 직접적 연관성 및 해당 이슈가 해결되지 않을 경우의 위험이나 손실을 나타내는 것은?

① 기술적 난이도
② 전략적 필요성
③ 분석 도구 보유 여부
④ ROI (투자 대비 효과)

정답 ②
질문의 직접적인 업무 연관성과 미해결 위험은 ② 전략적 필요성에 대응한다. 단순히 기술이 어려운지 또는 도구를 보유했는지를 묻는 것이 아니다.
핵심 개념: 전략적 필요성은 과제가 본원적인 업무와 얼마나 직접 연결되고, 해결하지 않을 때 어떤 위험이나 손실이 발생하는지를 고려하는 기준이다. 전략적 중요성과 문제 해결의 필요성을 함께 본다.
보기 검토: ①은 기술적 실행 부담, ③은 수행 기반, ④ ROI는 투입 비용 대비 기대 효과를 다룬다. 예를 들어 핵심 생산설비의 고장 예측은 본원적 생산 업무와 직접 연결되고 미해결 시 정지 손실이 생긴다. 금전적 효과가 당장 크지 않아도 핵심 업무 위험을 줄이기 위해 우선 추진할 수 있다.

16. 하향식 접근법 분석 과제 도출 단계를 순서대로 나열한 것은?

> 가. 문제 정의
> 나. 문제 탐색
> 다. 타당성 검토
> 라. 해결방안 탐색

① 가 - 나 - 다 - 라
② 가 - 나 - 라 - 다
③ 나 - 가 - 라 - 다
④ 다 - 나 - 가 - 라

정답 ③
나 문제 탐색, 가 문제 정의, 라 해결방안 탐색, 다 타당성 검토의 순서이므로 ③이다. 먼저 탐색하지 않고 문제를 정의하거나 해결방안 없이 타당성을 검토하도록 배열한 보기는 기본 흐름과 맞지 않는다.
핵심 개념: 하향식 접근의 과제 도출 흐름은 문제 탐색→문제 정의→해결방안 탐색→타당성 검토이다. 업무 기회를 넓게 찾은 뒤 분석 가능한 문제로 구체화하고 해결 수단과 수행 가능성을 평가한다.
적용 예: 고객 이탈 증가를 발견하고, 다음 달 이탈 가능 고객을 예측할 문제로 정의한 뒤, 분류모형과 운영 개입 방안을 찾고, 자료 확보·성과·비용·시스템 적용 가능성을 검토한다. 실제 프로젝트에서는 결과에 따라 이전 단계로 되돌아갈 수 있다.

17. 분석 성숙도 진단 시 고려 대상이 아닌 것은?

① 조직 구조
② 기술 환경
③ 비용 부문
④ 분석 인력

정답 ③
이 문항의 정해진 진단 범주에서는 ③ 비용 부문이 나머지 조직·기술·인력과 구별되는 항목이다. 분석 비용이 실제 프로젝트에서 중요하지 않다는 뜻은 아니다. 질문이 어떤 모델의 조사 대상 분류를 묻는지 확인한다.
핵심 개념: 분석 수준 진단은 분석을 수행하고 활용할 조직의 역량과 기반을 점검한다. 조직과 인력, 업무 활용, 자료와 기법, 인프라 등 관련 영역을 살펴본다.
보기 검토: ①은 분석 조직의 역할과 협업, ②는 수행 환경과 기술 기반, ④는 전문 인력과 역량에 연결된다. 비용과 투자 타당성은 별도 기획·성과 평가에서 중요하게 다룬다. 일반적인 경영 평가와 교재의 분석 진단 항목을 같은 목록으로 취급하지 않는다.

18. 분석 과제에서 고려해야 할 5가지 요소 관련 내용으로 올바른 것은?

① 정확도를 낮추면 복잡도가 증가한다.
② 정확도를 높이면 복잡도가 상승할 수 있다는 것을 고려해야 한다.
③ 복잡도를 높이면 정확도가 무조건 상승한다.
④ 정확도는 분석과제 선정에 영향을 주지 않는다.

정답 ②
정확도를 높이려 할 때 복잡도가 상승할 수 있다는 ②는 이러한 상충 관계를 설명한다. '할 수 있다'는 조건부 표현이며 반드시 동시에 증가한다는 뜻은 아니다.
핵심 개념: 분석 과제에서는 정확도, 복잡도, 자료와 수행 자원 사이의 균형을 고려한다. 더 정교한 모형을 쓰면 계산·구현·운영 부담이 늘어날 수 있으며, 성능 향상이 비용에 비해 충분한지도 판단해야 한다.
보기 검토: ①은 정확도를 낮추면 복잡도가 증가한다고 일반화하여 근거가 없다. ③은 복잡도를 높이면 정확도가 무조건 상승한다고 단정하지만 과적합 때문에 새 자료 성능이 나빠질 수도 있다. ④는 정확도가 선정에 영향을 주지 않는다고 하여 틀리다. 학습 성능과 검증 성능, 구현 부담을 함께 평가해야 한다.

19. 아래 2가지를 설명하는 분석 태스크는?

> 데이터의 정합성을 검토하고 특성을 파악한다.
> 데이터를 시각화하고 요약하여 숨겨진 패턴 관계 이상값 등을 발견한다.

① 탐색적 데이터 분석

② 진단적 분석

③ 예측 모델링

④ 설명적 분석

정답 ①

정합성과 특성 검토, 시각화와 요약을 통한 숨은 패턴 발견은 ① EDA에 해당한다. 예를 들어 변수별 결측률을 확인하고 히스토그램·상자그림·산점도를 그리는 활동이다.

핵심 개념: 탐색적 데이터 분석 EDA는 자료의 형태·분포·관계·이상값을 시각화와 요약통계로 파악하는 과정이다. 분석 전 가정을 점검하고 다음 단계의 질문과 처리 방향을 찾는 데 활용한다.
보기 검토: ② 진단적 분석은 왜 그런 현상이 발생했는지 원인을 추적하는 맥락, ③ 예측 모델링은 목표값을 예측할 함수를 학습하는 과정이다. ④ 설명적 분석은 넓은 의미에서 일부 겹칠 수 있으나 제시된 활동을 직접 지칭하는 명칭은 EDA이다. 탐색에서 발견한 관계를 곧바로 인과관계로 확정하지 않는다.

20. 분석 기획 시 고려사항에 해당하지 않는 것은?

① 업무와의 연계성 검토

② 분석 대상과 적용범위 정의

③ 분석 목적과 활용 방안 명확화

④ 최신 분석기법으로 분석 진행

정답 ④

④처럼 최신 기법을 사용한다는 사실 자체를 기준으로 분석을 진행하는 것은 기획의 적절한 원칙이 아니다. 최신 기법이 필요한 경우도 있지만 결과를 설명하고 운영할 수 있는지까지 함께 고려해야 한다.

핵심 개념: 분석 기획은 해결할 업무 문제와 목표, 사용할 자료, 적용 범위, 결과의 활용 방안을 정하는 과정이다. 기법은 목적과 자료에 맞게 선택하는 수단이다.
보기 검토: ①은 분석이 업무 성과와 연결되는지, ②는 어디까지 분석하고 적용할지, ③은 무엇을 얻고 어떻게 사용할지를 명확히 한다. 단순한 모형이 충분한 성능과 설명력을 제공한다면 복잡한 최신 모형보다 적합할 수 있다. 문제→목표→자료→방법의 연결을 기억한다.

3과목 데이터 분석 (21~50번)

21. 척도에 대한 내용으로 올바르게 짝지어진 것은?

① 시험 점수는 명목척도이다.
② 고객 만족도 5점 척도는 비율척도이다.
③ 고향이 수도권/비수도권인지는 명목척도이다.
④ 몸무게 또는 나이는 명목척도이다.

정답 ③
수도권·비수도권은 지역 범주를 구분하므로 ③ 명목척도가 맞다. 0과 1로 코딩하더라도 1이 0보다 두 배 크다는 양적 의미가 생기지 않는다.
핵심 개념: 명목척도는 범주의 구분만 있으며 순서와 수치 간격의 의미가 없다. 서열척도에는 순서, 등간척도에는 같은 간격, 비율척도에는 간격과 의미 있는 절대영점이 있다.
보기 검토: ① 시험 점수를 명목으로 보는 것은 부적절하다. 다만 시험 점수의 정확한 척도 해석은 측정 설계에 따라 달라질 수 있다. ② 고객 만족도 5점은 보통 서열척도로 다루며 응답 간 간격이나 만족도의 비율을 자동 보장하지 않는다. ④ 몸무게와 경과시간으로 측정한 나이는 일반적으로 비율척도이다. 숫자 표시 여부와 측정 수준을 구별한다.

22. 범주형 자료 분석에 대한 설명 중 틀린 것은?

① 적합도 검정은 관찰도수와 기대도수가 얼마나 일치하는지를 검정한다.
② 범주의 특성에 따라 기대도수를 계산해 비교 기준으로 사용할 수 있다.
③ 동질성 검정은 여러 집단의 범주별 분포가 동일한지를 검정한다.
④ 독립성 검정은 서로 다른 요인들이 관찰값에 영향을 주는지를 검정한다.

정답 ④
독립성 검정은 한 모집단에서 관측한 두 범주형 변수가 서로 관련이 있는지(독립인지)를 검정한다. 여러 요인이 관찰값에 영향을 주는지 보는 것은 분산분석이나 회귀분석의 질문이므로 ④가 틀리다.
핵심 개념: 카이제곱 검정은 관찰도수 O와 기대도수 E로 $\chi^2 = \sum \frac{(O-E)^2}{E}$를 계산한다. 적합도 검정은 한 범주형 변수가 가정한 분포를 따르는지, 독립성 검정은 두 범주형 변수가 서로 독립인지, 동질성 검정은 여러 모집단의 범주 분포가 같은지를 본다.
보기 검토: ①은 적합도 검정의 정의, ②는 귀무가설 아래의 비율로 기대도수를 계산해 비교 기준으로 쓰는 절차, ③은 동질성 검정의 정의이다.
학습 포인트: 독립성 검정과 동질성 검정은 계산식이 같지만 표본을 뽑는 방식과 귀무가설의 표현이 다르다. 기대도수가 5보다 작은 칸이 많으면 근사의 정확도가 떨어진다.

23. 기술통계와 관련된 설명 중 틀린 것은?

① 결측치를 모두 0으로 변환하여 평균을 계산한다.
② 기술통계는 데이터를 요약하고 설명하는 데 사용된다.
③ 대표값으로는 평균, 중앙값, 최빈값 등이 있다.
④ 산포도는 데이터의 분포 범위를 파악할 수 있는 도구이다.

정답 ①
결측은 관측되지 않았다는 뜻이며 값이 0이라는 뜻이 아니다. 모든 결측을 0으로 바꾸면 평균과 분포가 왜곡될 수 있으므로 ①이 틀리다. 예를 들어 관측값 10,20과 결측 하나에서 관측값 기준 평균은 15지만 0 대체 후 평균은 10이 된다.
핵심 개념: 기술통계는 수집된 자료의 특성을 대표값과 산포도, 그림 등을 통해 요약한다. 평균·중앙값·최빈값은 중심을, 분산·표준편차·범위·사분위범위는 퍼짐을 나타낸다.
처리 기준: 결측 원인과 자료 특성에 따라 제외, 대체, 별도 표기 등을 선택하고 계산의 분모와 처리 방식을 명시한다. 평균 대체도 항상 적절한 것은 아니다. ②③④는 자료 요약이라는 기술통계의 기본 목적과 맞는다. 결측 처리 규칙이 통계량에 미치는 영향을 함께 해석한다.

24. 시계열 데이터의 정상성을 확보할 수 있는 방법으로 옳은 것은?

① 더미 변수화
② 정규화
③ 차분
④ 군집화

정답 ③
제시된 기법 중 정상성을 확보하기 위한 대표 처리는 ③ 차분이다. 계절성이 있는 자료에는 주기 s에 대해 $X_t - X_{t-s}$인 계절 차분을 고려한다.
핵심 개념: 차분은 인접 시점 값의 차이를 구하는 변환이다. 1차 차분은 $\Delta X_t = X_t - X_{t-1}$이며, 확률적 추세 때문에 평균이 변하는 비정상 시계열을 정상화하는 데 활용한다.
보기 검토: ① 더미 변수화는 범주 표현, ② 정규화는 척도 변환, ④ 군집화는 유사 집단 형성이므로 일반적인 정상화 방법과 다르다. 다만 차분 한 번으로 모든 비정상성이 해결되는 것은 아니다. 분산 변화에는 로그 변환 등을 고려할 수 있으며 불필요한 과도 차분도 피한다. 변환 후 시계열과 자기상관 등의 특성을 다시 확인한다.

25. 시계열 분해에 대한 설명 중 잘못된 것은?

① 계절요인은 일정한 주기로 반복되는 규칙적인 변동이다.
② 순환요인은 장기적인 주기로 나타나는 변동이다.
③ 불규칙요인은 다른 요인으로 설명되지 않는 우연적인 변동이다.
④ 추세요인은 짧은 순간마다 무작위로 상승과 하락을 반복하는 성분이다.

정답 ④
짧은 순간마다 무작위로 오르내리는 성분은 불규칙요인의 특징이다. 추세는 장기적·지속적인 방향성이므로 ④가 틀리다.
핵심 개념: 시계열은 추세·계절·순환·불규칙 요인으로 분해한다. 추세는 장기적인 증가·감소 방향, 계절은 요일·월·분기처럼 고정된 주기의 반복, 순환은 경기 변동처럼 주기가 일정하지 않은 장기 변동, 불규칙은 나머지 우연 변동이다.
보기 검토: ①③은 정의와 같다. ②의 순환요인은 장기 변동이지만 계절요인과 달리 주기 길이가 일정하지 않다는 점도 함께 기억한다.
학습 포인트: '고정 주기=계절', '불규칙한 긴 주기=순환', '방향성=추세', '나머지=불규칙'으로 구분한다.

26. 콜레스테롤에 대한 단순선형회귀의 절편 추정값이 96.04, x의 회귀계수 추정값이 1.97이다. 적합한 회귀식은?

① $\hat{y} = 1.97 + 96.04x$
② $\hat{y} = 96.04 - 1.97x$
③ $\hat{y} = -96.04 + 1.97x$
④ $\hat{y} = 96.04 + 1.97x$

정답 ④
절편 96.04와 기울기 1.97을 대입하면 $\hat{y} = 96.04 + 1.97x$이므로 ④이다. x가 1 증가할 때 예측 반응값은 1.97 증가한다. 확인용으로 $x = 10$이면 예측값은 $96.04 + 19.70 = 115.74$이다.

핵심 개념: 단순선형회귀의 적합식은 $\hat{y} = b_0 + b_1 x$이다. b_0는 절편, b_1은 기울기이며 추정값의 부호와 위치를 그대로 반영한다.
보기 검토: ①은 절편과 기울기의 위치를 바꾸었고, ②는 양의 기울기를 음수로, ③은 양의 절편을 음수로 바꾸었다. 절편은 $x = 0$일 때의 예측값이나, 0이 자료 범위 밖이면 실질적 해석에 주의한다. x의 단위와 정확한 원래 출력이 확인되지 않았으므로 임의 단위를 추가하지 않는다. 예측식을 안다고 계수의 유의성까지 알 수 있는 것은 아니다.

27. 선형회귀분석의 가정에 대한 설명 중 틀린 것은?

① 정규성: 잔차의 분포가 정규분포를 따른다.
② 독립성: 독립변수 간에는 서로 관련이 없다.
③ 등분산성: 모든 독립변수 잔차 분포에는 동일한 분산을 가진다.
④ 선형성: 독립변수와 종속변수 간에는 선형관계가 있다.

정답 ②
②는 독립성의 대상을 독립변수 사이로 잘못 설명하므로 틀리다. 여러 설명변수가 관련되어 있어도 완전한 선형 종속 등이 없으면 모형을 적합할 수 있다.

핵심 개념: 회귀의 독립성은 보통 관측값 또는 오차항 사이의 독립성을 뜻한다. 독립변수끼리 반드시 무관해야 한다는 가정이 아니다. 설명변수들이 강하게 관련되면 다중공선성 문제가 될 수 있지만 이것과 오차 독립성은 다르다.
보기 보완: ①의 정규성은 정확한 소표본 추론에서 오차항의 정규성을 가정하고 잔차로 진단한다는 취지이다. ③ 등분산성은 설명변수 값에 관계없이 조건부 오차분산이 일정하다는 뜻이다. ④는 현재 단순한 선형 관계 설명으로 읽으며, 일반 선형회귀는 모수에 선형이라는 더 넓은 의미를 가진다. 오차와 잔차도 개념상 구분한다.

28. 독립변수 후보 모두를 포함한 모형에서 변수를 하나씩 제거하는 변수선택법은?

① 후진 제거법
② 단계별 선택법
③ 교차검증법
④ 전진 선택법

정답 ①
'모두 포함'에서 시작하여 '제거'한다는 흐름이 ① 후진 제거법이다. ④ 전진 선택은 적은 변수 또는 절편만 있는 모형에서 변수를 추가하는 반대 방향이다. ② 단계별 선택은 추가와 제거를 함께 검토할 수 있다.

핵심 개념: 후진 제거법은 후보 설명변수를 모두 포함한 모형에서 출발하여 정해진 기준에 따라 변수를 하나씩 제거한다. p값, AIC 등 무엇을 기준으로 삼는지에 따라 결과가 달라질 수 있다.
보기 검토: ③ 교차검증은 자료를 나누어 새 자료에 대한 성능을 추정하는 평가 절차로 변수선택의 진행 방향을 지칭하지 않는다. 변수를 제거하면 남은 계수도 다시 추정해야 한다. 선택한 모형이 모든 후보 조합 중 최적이라는 보장은 없으므로 목적과 검증 성능을 함께 확인한다.

29. 주성분 분석에 대한 설명으로 틀린 것은?

① 각 주성분을 만들기 위한 가중치(계수)가 산출된다.
② 데이터의 변동이 큰 방향부터 순서대로 주성분을 추출한다.
③ 서로 상관이 없는 새로운 변수를 만들 수 있다.
④ 기존 변수의 개수를 늘려 차원을 확장하는 용도로만 사용된다.

정답 ④
PCA의 목적은 차원 축소이다. 주성분 개수는 원 변수 수를 넘지 않으므로 변수를 늘려 차원을 확장한다는 ④가 틀리다.

핵심 개념: PCA는 상관된 원 변수들의 선형결합으로 서로 무상관인 주성분을 만들고, 분산을 많이 설명하는 소수의 주성분만 남겨 차원을 줄인다.
보기 검토: ①은 고유벡터(적재량)로 각 변수의 가중치가 계산된다는 설명이다. ②는 첫 주성분이 분산을 가장 크게, 다음 주성분이 남은 분산을 차례로 설명한다는 뜻이다. ③은 서로 다른 주성분 사이의 상관이 0이라는 성질이다.
학습 포인트: 원 변수 사이의 상관이 높을수록 적은 수의 주성분으로 많은 분산을 설명할 수 있다. 주성분 수는 누적 설명 비율이나 스크리 그림으로 정한다.

30. 다음은 USArrests 데이터(미국 50개 주의 범죄 통계)에 표준화 주성분 분석을 수행한 결과이다. 해석으로 틀린 것은?

```
> pca <- prcomp(USArrests, scale = TRUE)
> summary(pca)
                          PC1    PC2    PC3     PC4
Standard deviation     1.5749 0.9949 0.5971 0.41645
Proportion of Variance 0.6201 0.2474 0.0891 0.04336
Cumulative Proportion  0.6201 0.8675 0.9566 1.00000
> pca[["rotation"]]
             PC1     PC2     PC3     PC4
Murder   -0.5359  0.4182 -0.3412  0.6492
Assault  -0.5832  0.1880 -0.2681 -0.7434
UrbanPop -0.2782 -0.8728 -0.3780  0.1339
Rape     -0.5434 -0.1673  0.8178  0.0890
```

① 주성분 2개로 4개 변수 분산의 86% 이상을 설명할 수 있다.
② PC2에 가장 크게 기여하는 변수는 UrbanPop이다.
③ PC3에 가장 크게 기여하는 변수는 Rape이다.
④ 전반적으로 Murder의 영향력이 가장 크다.

정답 ④

분산을 가장 많이 설명하는 PC1에서 절댓값이 가장 큰 변수는 Assault(0.5832)이고, Murder(0.5359)는 Rape(0.5434)보다도 작다. 따라서 Murder의 영향력이 전반적으로 가장 크다는 ④가 틀리다.

핵심 개념: Proportion of Variance는 각 주성분이 설명하는 분산 비율, Cumulative Proportion은 누적 비율이다. rotation(적재량)은 각 주성분을 만드는 원 변수의 가중치이며, 기여의 크기는 부호가 아니라 절댓값으로 비교한다.
보기 검토: ①은 PC2까지 누적 비율이 0.8675이므로 맞다. ②는 PC2에서 UrbanPop의 절댓값 0.8728이 가장 크다. ③은 PC3에서 Rape의 0.8178이 가장 크다.
학습 포인트: 적재량의 부호는 방향만 나타내며 주성분 전체의 부호가 바뀌어도 해석은 같다. 변수의 단위가 다르므로 scale = TRUE로 표준화한 뒤 분석했다.

31. 다음은 사료 종류(feed)에 따른 병아리 무게(weight) 자료의 요약 결과이다. 해석으로 옳지 않은 것은?

```
> summary(chickwts)
     weight             feed
 Min.   :108.0   casein   :12
 1st Qu.:204.5   horsebean:10
 Median :258.0   linseed  :12
 Mean   :261.3   meatmeal :11
 3rd Qu.:323.5   soybean  :14
 Max.   :423.0   sunflower:12
```

① weight 값의 약 25%는 1st Qu.(204.5)보다 크다.
② weight의 사분위수 범위(IQR)는 119이다.
③ 평균이 중앙값보다 크므로 오른쪽 꼬리가 긴 분포(양의 왜도)를 의심할 수 있다.
④ feed는 명목형 변수이다.

정답 ①

Q1보다 작은 값이 약 25%이므로 Q1보다 큰 값은 약 75%이다. 25%만 크다고 한 ①이 틀리다.

핵심 개념: 1st Qu.(Q1)는 아래쪽 약 25%의 경계, 3rd Qu.(Q3)는 약 75%의 경계이다. $IQR = Q_3 - Q_1$이며 가운데 약 50%의 퍼짐을 나타낸다.
보기 검토: ②는 $323.5 - 204.5 = 119$이다. ③은 평균 261.3이 중앙값 258.0보다 커서 오른쪽 꼬리를 의심할 수 있다는 해석이며, 차이가 작으므로 히스토그램 등으로 확인한다. ④ feed는 사료 이름을 구분하는 범주형(명목형) 변수이고 summary는 범주별 개수를 보여 준다.
학습 포인트: summary()는 수치형 변수에는 최솟값·사분위수·평균·최댓값을, 범주형(factor) 변수에는 범주별 빈도를 출력한다.

32. 상관계수에 대한 설명 중 틀린 것은?

① 상관계수는 -1에서 1 사이 값을 가진다.
② 상관계수가 0일 경우, 직선 상관관계가 없다.
③ 상관계수가 -1일 경우, 상관관계가 가장 약하다.
④ 상관계수는 두 변수 간의 직선관계를 측정한다.

정답 ③

$r = -1$은 가장 약한 관계가 아니라 완전한 음의 선형 관계이므로 ③이 틀리다. 한 변수가 증가할 때 다른 변수가 정확한 직선 관계로 감소하는 경우이다. $r = 1$과 강도는 같고 방향만 반대이다.

핵심 개념: 피어슨 상관계수 r은 두 변수의 선형 관계 방향과 강도를 나타낸다. $-1 \le r \le 1$이며 부호는 방향, 절댓값은 선형 관계의 강도이다.
보기 검토: ①④는 정의에 맞고, ②의 $r = 0$은 선형 상관이 없다는 뜻으로 읽는다. $r = 0$이어도 U자형 같은 비선형 관계가 존재할 수 있으며 일반적으로 독립을 보장하지 않는다. 상관계수는 각 변수의 분산이 0이면 정의되지 않는다. 상관이 크다는 사실만으로 인과관계를 확정하지 않는다.

33. 다음은 iris 데이터의 네 변수에 대한 상관계수 행렬이다. 해석으로 틀린 것은?

```
> round(cor(iris[, 1:4]), 3)
             Sepal.Length Sepal.Width Petal.Length Petal.Width
Sepal.Length        1.000      -0.118        0.872       0.818
Sepal.Width        -0.118       1.000       -0.428      -0.366
Petal.Length        0.872      -0.428        1.000       0.963
Petal.Width         0.818      -0.366        0.963       1.000
```

① Sepal.Length와 상관이 가장 높은 변수는 Petal.Length이다.

② 상관이 가장 낮은 변수 쌍은 Petal.Length와 Petal.Width이다.

③ Sepal.Length가 길수록 Sepal.Width는 약간 좁아지는 경향이 있다.

④ Petal.Length가 길수록 Petal.Width도 커지는 경향이 있다.

정답 ②

Petal.Length와 Petal.Width의 상관계수는 0.963으로 표에서 가장 강한 양의 상관이다. 가장 낮다고 한 ②가 틀리다. 절댓값이 가장 작은 쌍은 Sepal.Length와 Sepal.Width(−0.118)이다.

핵심 개념: 상관계수의 부호는 방향, 절댓값은 선형 관계의 강도를 나타낸다. 대각선의 1은 자기 자신과의 상관이므로 비교에서 제외한다.
보기 검토: ①은 Sepal.Length 행에서 0.872가 가장 크므로 맞다. ③은 −0.118로 약한 음의 상관이므로 약간 좁아지는 경향으로 읽을 수 있다. ④는 0.963의 강한 양의 상관이다.
학습 포인트: 전체 iris 자료의 Sepal.Length–Sepal.Width 상관은 음수지만 품종별로 나누면 양의 상관이 나타난다(심슨의 역설). 상관계수는 인과관계를 뜻하지 않는다.

34. 다음은 swiss 데이터에서 Fertility를 종속변수로, 나머지 5개 변수를 독립변수로 한 회귀분석 결과이다. 해석으로 옳지 않은 것은?

```
> summary(lm(Fertility ~ ., data = swiss))
Coefficients:
                 Estimate Std. Error t value Pr(>|t|)
(Intercept)      66.91518   10.70604   6.250 1.91e-07 ***
Agriculture      -0.17211    0.07030  -2.448  0.01873 *
Examination      -0.25801    0.25388  -1.016  0.31546
Education        -0.87094    0.18303  -4.758 2.43e-05 ***
Catholic          0.10412    0.03526   2.953  0.00519 **
Infant.Mortality  1.07705    0.38172   2.822  0.00734 **
Residual standard error: 7.165 on 41 degrees of freedom
Multiple R-squared:  0.7067,  Adjusted R-squared:  0.671
F-statistic: 19.76 on 5 and 41 DF,  p-value: 5.594e-10
```

① 이 모형은 Fertility 변동의 약 70.67%를 설명한다.

② 수정 결정계수(Adjusted R-squared)는 67.1%이다.

③ Education은 유의수준 5%에서 유의하다.

④ Education이 Fertility 변동의 원인이라고 단정할 수 있다.

정답 ④

관찰자료에 대한 회귀 결과는 변수 사이의 통계적 연관을 보여 줄 뿐이며 누락 변수·교란 요인·역인과 가능성을 배제하지 못한다. 유의하다는 이유로 원인이라고 단정한 ④가 틀리다.

핵심 개념: 결정계수 R^2는 표본에서 종속변수 변동 중 모형이 설명하는 비율이고, 수정 R^2는 설명변수 수를 반영해 조정한 값이다. 각 계수의 Pr(>|t|)는 그 계수가 0이라는 귀무가설에 대한 p값이다.
보기 검토: ①은 Multiple R-squared 0.7067, ②는 Adjusted R-squared 0.671이다. ③은 Education의 p값 2.43×10^{-5}이 0.05보다 작으므로 맞다. Education 계수 −0.871은 다른 변수가 같을 때 Education이 1 높으면 Fertility가 평균 0.871 낮다는 뜻이다.
학습 포인트: 수정 $R^2 = 1 - (1 - R^2)\dfrac{n-1}{n-p-1}$이다. 여기서 $n = 47$, $p = 5$이므로 $1 - 0.2933 \times 46/41 \approx 0.671$이다.

35. 모델이 참이라고 예측한 것 중에서 실제로도 참인 것은?

① 정밀도

② 정확도

③ 재현율

④ F1 점수

정답 ①

'모델이 참이라고 예측한 것 중 실제로도 참'이라는 질문은 ① 정밀도에 해당한다. 실제로 참인 것 중 얼마나 찾았는지를 묻는 재현율과 분모가 반대이다.

핵심 개념: 정밀도 Precision은 양성이라고 예측한 관측값 중 실제 양성의 비율이며 $\dfrac{TP}{TP+FP}$이다. 분모는 예측 양성 전체이다.
계산 예: 양성 예측 20건 중 실제 양성이 15건이면 정밀도 $= 15/20 = 0.75$이다. 이 수치는 개념을 설명하기 위한 예시이다. ② 정확도는 $\dfrac{TP+TN}{\text{전체}}$, ③ 재현율은 $\dfrac{TP}{TP+FN}$, ④ F1은 $\dfrac{2PR}{P+R}$이다. 불균형 자료에서는 정확도만으로 성능을 충분히 설명하기 어렵다. 어떤 사건을 양성으로 정했는지 먼저 확인한다.

36. 연속형 변수 간의 유사성 또는 거리를 측정하는 방법으로 적절하지 않은 것은?

① 맨하탄 거리
② 자카드 거리
③ 마할라노비스 거리
④ 유클리디안 거리

정답 ②
자카드는 집합의 교집합과 합집합 또는 이진 속성의 일치를 기반으로 하는 대표 유사도이므로 연속형 자료의 일반적인 거리 선택에서는 ②가 가장 부적절하다. 자카드 거리=1−자카드 유사도이다.
핵심 개념: 연속형 수치 벡터의 대표 거리는 유클리드, 맨해튼, 마할라노비스 등이다. 유클리드는 제곱 차이 합의 제곱근, 맨해튼은 절댓값 차이 합이며, 마할라노비스는 공분산 구조를 반영한다.
조건 주의: 수치 벡터에 대한 확장 자카드 등의 변형이 있으므로 연속형 자료에 어떤 형태로도 사용할 수 없다는 절대 명제는 아니다. ③은 공분산 행렬의 가역성 등을 확인해야 한다. 변수 단위가 다르면 거리에서 큰 척도의 변수가 지배할 수 있으므로 표준화와 거리 선택의 목적을 함께 검토한다.

37. ROC 곡선으로 가장 효율적인 도형을 이끌어냈을 때의 X, Y 좌표 값은?

① (0, 0)
② (1, 0)
③ (0, 1)
④ (1, 1)

정답 ③
거짓 양성이 없고 실제 양성을 모두 찾는 이상적인 지점은 $FPR = 0$, $TPR = 1$이므로 ③ (0,1)이다. 가로축을 특이도 자체로 바꾸어 읽지 않는다. 특이도는 1−FPR이다.
핵심 개념: 표준 ROC 곡선의 가로축은 거짓 양성률 $FPR = \frac{FP}{FP + TN}$, 세로축은 참 양성률 $TPR = \frac{TP}{TP + FN}$이다. 임계값을 바꾸면서 두 비율의 변화를 그린다.
보기 검토: (0,0)은 모두 음성으로 예측하는 극단, (1,1)은 모두 양성으로 예측하는 극단에 대응할 수 있다. (1,0)은 실제 방향과 반대로 분류하는 나쁜 지점이다. 실제 최적 임계값은 오분류 비용·유병률·운영 목표에 따라 달라지므로 모든 문제에서 왼쪽 위와의 단순 거리만으로 결정하지 않는다.

38. 다음 중 앙상블기법인 배깅(Bagging)과 부스팅(Boosting)에 대한 설명으로 적절한 것은?

① 배깅은 모델 간 상호의존성을 강조한다.
② 배깅은 약한 학습기를 순차적으로 학습시킨다.
③ 부스팅은 오버샘플링을 통해 데이터 수를 증가시킨다.
④ 부스팅은 잘못 분류된 데이터에 더 큰 가중치를 부여한다.

정답 ④
AdaBoost는 잘못 분류된 관측값의 상대적 가중치를 높여 다음 학습기가 어려운 사례에 더 주목하도록 하므로 ④가 대표적으로 맞다.
핵심 개념: 배깅은 부트스트랩 표본으로 여러 기저모형을 학습하고 예측을 결합하는 방법이다. 부스팅은 앞선 모형의 오차를 보완하도록 순차적으로 모형을 추가하는 방법이다.
보기 검토: ①②는 순차적 의존성을 배깅의 핵심으로 잘못 설명한다. 배깅의 기저모형은 서로의 오차를 순차적으로 보완하는 구조가 아니다. ③은 부스팅을 단순한 자료 수 증가로 오해했다. 모든 부스팅이 같은 표본 가중치 갱신식을 사용하는 것은 아니며, 그래디언트 부스팅은 손실의 기울기 등을 이용한다. 알고리즘별 구현과 일반 개념을 구분한다.

39. 인공신경망 모형에 대한 설명으로 틀린 것은?

① 예측 정확도가 높다.
② 설명력 있는 가중치를 산출할 수 있다.
③ 복잡한 패턴을 스스로 학습할 수 있다.
④ 다양한 비정형 데이터를 처리할 수 있다.

정답 ②
②를 '각 가중치를 명확한 변수 효과로 직접 설명할 수 있다'는 취지로 읽으면 부적절하다. 가중치가 존재하지 않는다는 뜻은 아니다. 여러 층의 상호작용과 비선형성 때문에 영향 해석이 복잡하다는 점이 핵심이다.
핵심 개념: 신경망은 가중치와 비선형 활성화함수를 조합하여 복잡한 함수를 학습한다. 가중치 자체는 실제로 계산되지만 깊은 네트워크의 개별 가중치를 선형회귀계수처럼 직접 해석하기는 어렵다.
보기 검토: ③④는 적절한 구조와 학습 조건에서 가능한 활용이다. ①의 높은 정확도는 가능한 장점이며 항상 다른 모형보다 높다는 보장은 없다. 설명가능성 기법을 활용할 수 있어도 모든 가중치가 자동으로 설명력 있는 계수가 되는 것은 아니다.

40. 로지스틱 회귀분석의 적용 사례로 적절한 것은?

① 주택 가격 예측
② 제품 수명 예측
③ 마케팅 성공 여부 예측
④ 키와 몸무게의 상관관계 분석

정답 ③
마케팅 성공 여부는 범주형 반응변수이므로 ③이 적합하다. ① 주택 가격과 ② 제품 수명은 표현대로라면 연속형 수치 예측이며, ④는 변수 간 관계를 요약하는 상관분석 문제이다.
핵심 개념: 이항 로지스틱 회귀는 성공·실패, 구매·미구매 같은 두 범주의 사건 발생 확률을 모델링한다. 선형예측값 η를 $p = \frac{1}{1 + e^{-\eta}}$로 변환하여 0과 1 사이 확률을 얻는다.
학습 포인트: 수명을 '특정 기간 안에 고장 여부'로 바꾸면 이항 분석이 가능하지만 이 보기에는 그런 조건이 없다. 로지스틱 회귀라는 이름의 회귀와 분류 활용을 혼동하지 않는다. 확률을 실제 범주로 바꾸려면 임계값을 정해야 하며 반드시 0.5여야 하는 것은 아니다. 계수는 로그오즈의 변화로 해석한다.

41. 의사결정나무에 대한 설명으로 틀린 것은?

① 가지치기를 통해 과적합을 방지할 수 있다.
② 자식마디의 순수도가 증가하도록 분류나무를 형성한다.
③ 지니 지수나 엔트로피를 기준으로 분할한다.
④ 가지치기를 통해 학습 데이터 세트에서의 정확도를 높일 수 있다.

정답 ④

학습 데이터 정확도를 높이는 것을 가지치기의 기본 효과로 제시한 ④는 부적절하다. 충분히 자란 트리를 단순화하면 훈련 오차는 증가하거나 그대로일 수 있고, 검증 성능은 좋아질 수 있다. 훈련 정확도 상승과 과적합 감소를 동일시하지 않는다.

핵심 개념: 가지치기는 불필요한 분기를 줄여 트리를 단순화하고 새 자료에 대한 일반화 성능을 개선하려는 절차이다. 학습 자료에 지나치게 맞춘 구조를 줄이는 것이 목적이다.
보기 검토: ①은 과적합 완화 취지이다. ②③은 분류나무에서 자식의 가중 평균 불순도가 낮아지는 분할을 찾는 설명이며, 각 자식 모두가 반드시 개별적으로 부모보다 순수해지는 보장은 없다. 회귀나무는 수치 반응에 맞는 분산·제곱오차 등의 기준을 사용한다. 가지치기가 항상 검증 성능 향상을 보장하는 것도 아니다.

42. K-means에 대한 설명으로 틀린 것은?

① 비지도 학습에 속하는 군집 알고리즘이다.
② 군집 개수 k를 알고리즘이 자동으로 선택해준다.
③ 클러스터의 중심점을 기준으로 군집을 형성한다.
④ 반복적으로 중심점을 재계산하며 수렴한다.

정답 ②

K를 자동으로 선택한다고 한 ②가 틀리다. 사용자가 여러 K 후보를 비교해 엘보·실루엣·업무 해석 등을 이용할 수 있지만 이것은 표준 K-means의 고정 K 학습 절차와 별도의 선택 과정이다.

핵심 개념: K-means는 군집 수 K를 정하고 관측값 배정과 중심 재계산을 반복하는 비지도학습이다. 표준 알고리즘은 군집 내 제곱거리 합을 줄이는 방향으로 진행한다.
보기 검토: ①③④는 대표적인 작동 방식이다. 유클리드 거리와 산술평균 중심을 이용하는 일반적 구현을 전제로 한다. 초기 중심에 따라 국소해가 달라질 수 있어 여러 초기화를 고려한다. 반복이 수렴했다고 전역 최적해를 찾았다는 뜻은 아니다. 거리 기반이므로 변수 척도와 이상치에도 영향을 받는다.

43. SOM에 대한 설명 중 틀린 것은?

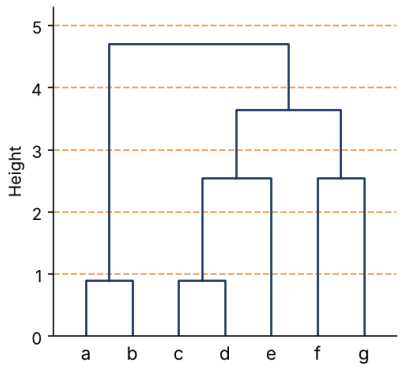
① SOM은 경쟁 학습 기반의 신경망이다.
② 차원을 축소해 시각화에 활용할 수 있다.
③ 입력 벡터와 가장 가까운 노드를 BMU라 한다.
④ 부분적으로(locally) 연결된다.

정답 ④

기본 SOM에서는 각 지도 노드가 입력의 모든 차원을 표현하는 가중치 벡터를 갖는다. 따라서 입력층과 지도 노드가 일부 차원끼리만 국소 연결된다는 뜻의 ④는 틀리다. 지도 노드 사이 이웃 관계와 입력 차원에 대한 연결은 다른 개념이다.

핵심 개념: SOM은 입력 벡터와 유사한 대표 벡터를 가진 지도 노드를 찾는 경쟁학습 기반의 비지도 신경망이다. 가장 가까운 노드가 BMU이며, BMU와 지도 위 이웃 노드의 대표 벡터를 입력 쪽으로 갱신한다.
보기 검토: ①은 경쟁학습, ②는 고차원 자료의 저차원 지도화, ③은 BMU의 정의와 맞다. 이웃 갱신이 BMU 주변 지도 노드에만 국소적으로 적용되는 것은 입력층과의 연결 구조와는 다른 개념이다. topology를 완벽하게 보존한다고 단정하지 않는다.

44. 아래 덴드로그램에서 Height=2일 때, 클러스터는 몇 개인가?



① 2개
② 3개
③ 4개
④ 5개

정답 ④

높이 2보다 낮은 약 0.9에서 a와 b가 합쳐지고 c와 d도 합쳐진다. e, f, g는 높이 2에서 아직 각각 따로 있다. 따라서 군집은 {a,b}, {c,d}, {e}, {f}, {g}의 다섯 개이고 ④이다.

핵심 개념: 덴드로그램을 높이 h에서 수평으로 자르면 그 선 아래에서 이미 연결된 관측값들이 하나의 군집을 이룬다. 선과 교차하는 독립 가지 수 또는 아래쪽 연결 묶음을 세면 된다.
확인 방법: 최초 7개 단일 군집에서 절단선 아래 합병이 두 번 이루어졌으므로 $7-2=5$로 검산할 수 있다. 약 2.5의 합병은 절단 높이보다 위에 있으므로 포함하지 않는다. 가지의 좌우 배치나 관측값 사이 수평 거리는 군집 수 기준이 아니며, 높이는 사용한 연결법의 합병 기준을 나타낸다.

45. 다음은 거래 데이터에서 버터와 빵의 구매 비율이다. 빵을 구매했을 때 버터도 함께 구매할 신뢰도(빵 → 버터)는?

버터(A)	빵(B)	버터+빵
0.6	0.8	0.6

① 향상도: 0.25
② 향상도: 1.25
③ 신뢰도: 0.6
④ 신뢰도: 0.75

정답 ④

빵→버터 신뢰도 $= 0.6/0.8 = 0.75$이므로 ④이다. 거래 5건으로 보면 빵을 포함한 4건 중 버터도 포함한 거래가 3건이다.

핵심 개념: 지지도는 $P(A \cap B)$, 빵→버터 신뢰도는 $P(\text{버터}|\text{빵}) = \dfrac{P(\text{버터} \cap \text{빵})}{P(\text{빵})}$, 향상도는 신뢰도를 $P(\text{버터})$로 나눈 값이다.
보기 검토: ③ 0.6은 지지도 $P(\text{버터} \cap \text{빵})$이다. 향상도는 $\dfrac{0.6}{0.6 \times 0.8} = 1.25$로 ② 값이 계산상 맞지만 질문은 신뢰도를 묻는다. ①의 0.25는 계산 근거가 없다.
학습 포인트: 신뢰도는 방향에 따라 다르다. 버터→빵 신뢰도는 $0.6/0.6 = 1$이다. 향상도는 방향과 관계없이 같다.

46. 연관분석에서 A → B일 경우, 지지도에 해당하는 것은?

① A가 나왔을 때 B도 나올 확률
② 전체 중에서 A와 B 동시에 구매할 확률
③ A가 발생한 경우 중 B도 발생한 비율
④ B가 발생한 경우 중 A도 발생한 비율

정답 ②
전체 중 동시 구매할 확률이라는 ②가 정의에 대응한다. ①③은 A가 있는 거래를 분모로 잡는 신뢰도 $P(B|A)$이고, ④는 역방향 신뢰도 $P(A|B)$이다.
핵심 개념: 연관규칙 A→B의 지지도는 전체 거래 중 A와 B를 함께 포함한 비율 $P(A \cap B)$이다. 규칙의 발생 빈도를 전체 거래 기준으로 나타내며 화살표 방향을 바꾸어도 같다.
계산 예: 전체 100건, A 포함 40건, 동시 포함 20건이라면 지지도는 $20/100 = 0.2$, A→B 신뢰도는 $20/40 = 0.5$이다. 같은 분자를 쓰더라도 분모가 달라지는 이유를 이해한다. 향상도는 신뢰도를 B의 전체 발생률로 나눈 값이다.

47. 군집분석에 대한 설명 중 틀린 것은?

① 비지도학습의 한 형태이다.
② K-means는 대표적인 군집화 기법이다.
③ 입력변수가 범주형일 경우 군집 분석을 할 수 없다.
④ 유클리디안 거리 등을 이용해 유사도를 측정할 수 있다.

정답 ③
범주형 입력이면 군집분석 자체를 할 수 없다는 ③은 틀리다. 범주형 자료에는 일치 여부 기반 비유사도와 K-modes 등을, 혼합 자료에는 적합한 거리나 K-prototypes 같은 방법을 고려할 수 있다.
핵심 개념: 군집분석은 정답 라벨 없이 관측값의 유사성을 이용해 집단을 찾는 비지도학습이다. 사용할 자료 유형에 맞는 거리와 군집 알고리즘을 선택해야 한다.
보기 검토: ①②는 기본 개념이고, ④의 유클리드 거리는 수치 자료에서 대표적으로 쓰인다. 범주형 코드를 임의 숫자로 바꿔 유클리드 거리를 적용하면 없는 순서·간격을 만들어낼 수 있어 주의한다. 군집 번호는 알고리즘이 만든 그룹 식별자이며 실제 정답 범주를 자동 발견한 것이라고 단정하지 않는다. 군집 결과의 업무 의미는 별도로 해석한다.

48. 다차원 척도법에 대한 설명으로 틀린 것은?

① 절대적 위치를 알 수 있다.
② 변수 간 거리 정보를 시각화한다.
③ 변수 간 유사성을 직관적으로 파악할 수 있다.
④ 데이터 구조를 2차원이나 3차원으로 축소해 표현할 수 있다.

정답 ①
절대적 위치를 알 수 있다는 ①은 부적절하다. 전체 그림을 회전·이동·반사해도 점 사이 거리가 같을 수 있으므로 좌표의 원점과 방향이 유일한 절대 의미를 갖는 것은 아니다. ②③④는 상대적 거리 구조의 표현이라는 취지로 맞다.
핵심 개념: MDS는 관측 대상 사이 거리 또는 비유사도를 저차원 공간의 상대적 배치로 표현한다. 가까운 대상과 먼 대상의 구조를 시각적으로 이해하는 것이 목적이다.
표현 보완: 보기에 쓰인 '변수 간'은 일반적으로 분석 대상 또는 관측값 사이의 비유사도를 뜻하는 문맥으로 읽는다. 자료를 무엇을 대상으로 구성했는지에 따라 변수 자체를 대상으로 삼을 수도 있다. 저차원화가 모든 원래 거리를 정확히 보존하는 것은 아니므로 왜곡이나 stress 등을 점검한다. PCA의 분산 최대화 목적과 구별한다.

49. 계통추출에 대한 설명으로 가장 적절한 것은?

① 모집단을 무작위로 몇 개의 집락으로 묶은 뒤 집락 전체를 추출한다.
② 모집단을 층으로 나누고 각 층에서 따로 추출한다.
③ 시작점을 무작위로 정한 뒤 일정한 간격마다 대상을 추출한다.
④ 표본평균이 가장 큰 대상만 선택한다.

정답 ③
③이 무작위 시작과 일정 간격이라는 두 특징을 갖는다. 예를 들어 1000명 중 100명을 간격 10으로 뽑는다면 시작점 1~10 중 하나를 무작위 선택하여 이후 10명마다 선택할 수 있다.
핵심 개념: 계통추출은 모집단 목록에서 무작위 시작점을 정한 뒤 일정 간격마다 표본을 선택하는 방법이다. 모집단 크기 N과 표본 크기 n에 따라 간격을 대략 N/n으로 정하며 실제 설계 방식에 맞게 조정한다.
보기 검토: ①은 집락추출, ②는 층화추출, ④는 확률표집의 원칙과 맞지 않는 임의 선택이다. 목록에 추출 간격과 같은 주기적 패턴이 있으면 편향 위험을 검토한다.

50. 스피어만·피어슨 상관분석에 대한 설명으로 가장 부적절한 것은?

① 스피어만은 범주형 변수의 선형관계를 설명한다.
② 피어슨 상관계수는 연속형 변수 간의 선형 관계를 분석할 때 사용된다.
③ 스피어만 상관계수는 서열형(순위형) 변수 간의 관계를 분석할 때 사용된다.
④ 스피어만 상관계수는 비선형 관계도 어느 정도 설명할 수 있다.

정답 ①
범주형 변수의 선형관계를 설명한다고 한 ①은 부적절하다. 순서가 없는 명목 범주에는 의미 있는 순위를 임의로 부여할 수 없다. 서열형 자료나 순위로 변환한 수치 자료는 스피어만 분석에 활용할 수 있다.
핵심 개념: 피어슨 상관은 수치 자료의 선형 관계를, 스피어만 상관은 순위를 이용한 단조 관계를 평가한다. 스피어만은 원래 값을 순위로 바꾼 뒤 그 순위의 상관을 계산하는 방식으로 이해할 수 있다.
보기 검토: ②③은 대표 용도이다. ④는 증가·감소 방향이 일관된 비선형 단조 관계를 어느 정도 포착한다는 의미로 읽는다. 모든 비선형 관계를 잘 탐지하는 것은 아니며 U자형처럼 비단조 관계는 약한 계수로 나타날 수 있다. 동순위가 있으면 그 처리 규칙을 반영한다. 어느 상관계수도 단독으로 인과관계를 증명하지 않는다.