ADsP 제46회 기출 복원문제

유형 2
정답·해설 수록본
총 50문항 · 4지선다 · 90분

1과목 데이터 이해 (1~10번)

1. DIKW 모델에 대한 설명과 용어가 가장 잘 연결된 것은?

> 가. A마트는 100원에, B마트는 500원에 연필을 판매한다.
> 나. 다른 제품들도 A마트가 B마트보다 저렴할 것이다.
> 다. 상대적으로 저렴한 A마트에서 연필을 사야겠다.
> 라. A마트는 연필 가격이 저렴하다.

① 가: 데이터, 나: 지혜, 다: 지식, 라: 정보
② 가: 데이터, 나: 정보, 다: 지식, 라: 지혜
③ 가: 정보, 나: 지혜, 다: 지식, 라: 데이터
④ 가: 지혜, 나: 정보, 다: 데이터, 라: 지식

정답 ①
가의 두 가격은 관측된 사실이므로 데이터이다. 라는 가격을 비교해 A마트가 상대적으로 저렴하다는 의미를 얻었으므로 정보이다. 다는 이 정보를 구매 행동에 적용하므로 이 문항의 분류에서는 지식이다. 나는 연필의 비교를 다른 상품의 구매 판단으로 확장하므로 지혜에 대응한다. 따라서 가 데이터, 나 지혜, 다 지식, 라 정보인 ①을 선택한다.

핵심 개념: DIKW는 데이터(Data), 정보(Information), 지식(Knowledge), 지혜(Wisdom)를 구분하는 틀이다. 같은 사실이라도 단순 관측인지, 비교를 통해 의미를 얻었는지, 행동에 적용했는지, 더 넓은 상황에 확장했는지에 따라 수준을 구분한다.
보기 검토: ②는 나를 정보, 라를 지혜로 잘못 연결한다. ③은 가격이라는 원시 사실인 가를 정보로, 비교 결과인 라를 데이터로 바꾼다. ④는 원시 사실을 지혜로, 구매 판단을 데이터로 연결해 수준이 뒤바뀐다.
학습 포인트: ‘A가 싸다’는 비교 정보와 ‘A에서 사겠다’는 적용 판단을 구별한다. 지혜는 더 넓은 맥락에서 적절한 판단을 하는 능력이다. 다만 한 상품이 싸다는 사실만으로 모든 상품이 싸다고 논리적으로 증명할 수는 없다. 이 보기는 DIKW 수준 구분을 위한 교재형 예시이지, 그 일반화가 실제로 타당하다는 증명은 아니다.

2. 데이터에 대한 설명으로 옳은 것은?

① 습도, 기온, 체온 데이터는 정성적 데이터이다.
② 정량적 데이터는 분석하기 매우 어렵다.
③ 정성적 데이터는 주로 비정형 형태로, 정량적 데이터에 비해 상대적으로 가공, 분석, 활용에 많은 비용과 기술이 필요하다.
④ 음성, 비디오, SNS 데이터는 반정형 데이터이다.

정답 ③
서술형 의견이나 음성처럼 정성적 특성을 담은 비정형 자료는 수치 자료보다 구조화·특징 추출·해석에 더 많은 처리가 필요한 경우가 많다. ③은 이러한 일반적인 경향을 설명한다. 예를 들어 고객 만족 점수는 바로 평균을 계산할 수 있지만 자유로운 후기 문장은 의미 분류나 감성 분석이 필요하다.

핵심 개념: 정량적 데이터는 수치로 측정하는 양이며, 정성적 데이터는 종류·성질·의견 등의 특성을 나타낸다. 정형·반정형·비정형은 자료의 구조에 따른 분류이므로 두 분류 기준을 완전히 같은 것으로 보아서는 안 된다.
보기 검토: ①의 습도·기온·체온은 숫자로 측정하므로 정량적 데이터이다. ②의 ‘매우 어렵다’는 일괄적 판단은 부적절하다. 자료와 목적에 따라 다르며 수치 자료에는 통계 처리가 비교적 직접적으로 적용된다. ④의 음성·비디오는 일반적으로 비정형 자료이다. SNS 전체도 텍스트·이미지·메타데이터가 섞여 있으므로 반정형이라고 일괄 분류할 수 없다.
학습 포인트: 정성적이라고 반드시 비정형인 것은 아니다. 성별·직업 같은 범주는 정성적 특성이지만 표의 열로 저장할 수 있다. SNS 내용을 JSON으로 전달할 때 JSON의 저장 형식은 반정형일 수 있어도 본문 내용의 의미 구조까지 정형화되는 것은 아니다.

출처: ADsP CBT youneedpython.github.io/ADsP-CBT · 복원 문제로 실제 시험과 다를 수 있습니다.

3. 데이터베이스의 특징으로 적절한 것은?

① 통합 데이터: 동일한 내용이 중복되어 있지 않다.

② 공유 데이터: 동일 사용자가 동일 데이터를 다른 목적으로 이용한다.

③ 운영 데이터: 데이터베이스에 저장된 데이터는 삭제가 불가하다.

④ 저장 데이터: 사용자가 접근 불가한 매체에 데이터가 저장된다.

정답 ①

통합 데이터는 여러 곳에 흩어진 자료를 함께 관리하면서 불필요한 중복을 줄이고 일관성을 유지하는 자료이다. ①의 표현은 이 교재상의 의미를 묻는다. 실제 설계에서 성능이나 가용성을 위해 일부 중복·복제를 둘 수 있으므로 '어떠한 물리적 중복도 존재하지 않는다'는 절대 명제로 확대해서는 안 된다.

핵심 개념: 데이터베이스는 통합된 데이터, 저장된 데이터, 운영에 필요한 데이터, 여러 이용자가 공유하는 데이터라는 성격을 갖는다. 각각 통합·저장·운영·공유가 무엇을 뜻하는지 구분해야 한다.

보기 검토: ②의 핵심은 동일 사용자의 다양한 이용이 아니라 여러 사용자·응용 프로그램의 공동 이용이다. ③의 운영 데이터는 조직의 업무 수행에 필요한 자료라는 뜻이며, 저장 후 삭제가 불가능하다는 뜻이 아니다. ④의 저장 데이터는 컴퓨터가 접근할 수 있는 저장 매체에 기록된 자료를 뜻한다. 접근 불가능한 매체라는 설명은 잘못됐다.

적용 예: 고객 정보를 영업·배송·고객지원 부서가 함께 이용하면 공유 데이터이다. 영업에 필요한 주문 정보는 운영 데이터이며, 이를 저장 장치에 보관하면 저장 데이터이다. 같은 고객의 주소를 일관되게 관리하는 것은 통합의 효과이다.

4. 기업 내부 데이터베이스에 대한 설명으로 옳지 않은 것은?

① OLTP는 데이터 조회 및 분석에 주로 사용된다.

② OLAP는 다차원의 데이터를 대화식으로 분석 및 통계 요약 정보를 제공한다.

③ OLTP는 트랜잭션을 실시간으로 처리하며 온라인 거래 처리에 사용된다.

④ OLTP는 거래입력, 수정, 삭제 등 온라인 거래 처리에 사용된다.

정답 ①

①의 '조회 및 분석에 주로 사용'은 이 문항에서 OLAP의 중심 역할을 설명한 것이다. OLTP를 주로 분석 시스템이라고 구분했으므로 옳지 않다. OLTP에서도 거래 수행에 필요한 조회는 빈번하게 발생하므로 'OLTP는 조회를 전혀 하지 않는다'고 이해해서는 안 된다.

핵심 개념: OLTP는 온라인 트랜잭션 처리, OLAP는 온라인 분석 처리를 뜻한다. OLTP는 주문·결제·예약 같은 업무 거래를 정확하고 신속하게 처리하고, OLAP는 누적 데이터를 요약하고 여러 관점에서 분석한다.

보기 검토: ②는 기간·지역·상품 같은 여러 차원에서 매출을 집계하는 OLAP의 특징이다. ③과 ④는 주문 입력, 재고 갱신, 거래 취소처럼 짧은 거래를 처리하는 OLTP의 특징이다. 온라인 거래의 입력·수정·삭제를 업무 규칙에 맞게 처리한다는 점에서 적절하다.

적용 예: 고객이 상품을 구매하며 주문 행이 추가되고 재고가 감소하는 것은 OLTP이다. 경영자가 최근 3년의 지역별·상품별 매출을 비교하는 것은 OLAP이다. 구별의 기준은 '조회가 있느냐'가 아니라 처리 목적과 업무 부하의 성격이다.

5. 데이터베이스의 다양한 측면 중 정보의 축적과 전달 측면에서 옳지 않은 것은?

① 검색가능성: 사용자가 필요한 정보를 검색할 수 있다.

② 기계가독성: 정보처리기기가 대량의 정보를 읽고 쓸 수 있다.

③ 원격조작성: 원거리 또는 온라인으로 이용 가능하다.

④ 정보관리성: 정보처리, 검색 관리 소프트웨어와 관련 하드웨어 그리고 정보 전송을 위한 네트워크 기술 발전을 견인한다.

정답 ④

④의 내용은 정보처리 소프트웨어·하드웨어·네트워크 기술 발전을 촉진한다는 기술·경제적 효과에 가깝다. '정보관리성'이라는 말과도 직접 맞지 않으며, 제시된 분류의 정보 축적·전달 측면에 해당하지 않는다.

핵심 개념: 이 문항은 데이터베이스가 정보를 축적하고 전달하는 특성과, 관련 산업·기술에 미치는 파급 효과를 구분한다. 검색가능성·기계가독성·원격조작성은 저장된 정보를 이용하는 직접적인 특성이다.

보기 검토: ① 검색가능성은 원하는 정보를 조건에 따라 찾을 수 있다는 뜻이다. ② 기계가독성은 사람만 읽을 수 있는 기록이 아니라 컴퓨터가 데이터를 읽고 처리할 수 있음을 말한다. ③ 원격조작성은 떨어진 장소에서도 통신망을 통해 데이터베이스를 이용할 수 있다는 뜻이다. 세 보기는 정보 접근과 처리에 직접 연결된다.

학습 포인트: 이름만 비슷하다고 정답으로 판단하지 말고 실제 설명의 대상이 '정보 이용 특성'인지 '기술 발전 효과'인지 살핀다. 이 문항은 SQL 문법이나 DBMS 내부 구현보다 교재상의 데이터베이스 의미와 분류 체계를 묻는 문제이다.

6. 데이터와 관련된 보기 중 설명이 옳은 것은?

가. OLTP는 다차원 데이터를 대화식으로 분석하고 복잡한 쿼리를 빠르게 처리하여 사용자에게 통찰을 제공하는 데이터 처리 기술이다.
나. ETL은 다양한 DBMS에서 데이터를 가져와 정리한 후, 분석에 적합한 형태로 최종 저장소에 저장하는 프로세스이다.
다. 데이터 마이닝은 대량의 데이터에서 숨겨진 패턴과 규칙을 찾아내어 의사결정에 활용하는 기법이다.

① 가

② 가, 나

③ 나, 다

④ 가, 나, 다

정답 ③

가는 다차원 분석과 복잡한 조회로 통찰을 얻는다고 설명하므로 OLTP가 아니라 OLAP에 해당한다. 나는 여러 원천에서 데이터를 추출하고 분석에 맞게 변환하여 적재하는 ETL의 설명이다. 다는 다량의 자료에서 유용한 패턴·규칙을 발견하는 데이터마이닝의 설명이다. 옳은 것은 나와 다이므로 ③이다.

핵심 개념: OLAP·ETL·데이터마이닝의 목적을 구별하는 조합형 문제이다. ETL은 Extract, Transform, Load의 순서이며, 추출한 자료를 정제·변환한 뒤 목적 저장소에 적재한다.

보기 검토: ①은 잘못된 가만 포함한다. ②는 옳은 나를 포함하지만 잘못된 가도 포함하고 옳은 다를 빠뜨린다. ④ 역시 가가 들어 있어 틀리다. 조합형에서는 각 문장의 참·거짓을 먼저 판단한 뒤 번호를 선택해야 한다.

적용 예: 판매 시스템에서 주문을 가져와 날짜 형식을 통일하고 분석 저장소에 쌓는 작업은 ETL이다. 그 자료를 지역·기간·제품별로 집계하는 것은 OLAP이며, 자주 함께 팔리는 상품 조합을 발견하는 것은 데이터마이닝이다.

7. 빅데이터 출현 배경으로 옳은 것은?

> 가. 기업 및 산업 분야의 운영 과정에서 대량의 데이터가 축적되었다.
> 나. 데이터를 활용한 과학적 연구 및 알고리즘 개발이 활발해졌다.
> 다. 데이터 처리, 저장, 분석을 위한 기술적 진보가 이루어졌다.

① 가
② 가, 나
③ 가, 다
④ 가, 나, 다

정답 ④
기업의 거래·로그·센서·인터넷 서비스가 대량의 자료를 축적했다는 가는 데이터 공급 측면이다. 과학적 연구와 알고리즘 개발이 활발해졌다는 나는 분석의 수요·방법 측면이다. 저장 장치·통신망·분산 처리 등의 기술 진보를 설명하는 다는 처리 가능성 측면이다. 세 요소 모두 배경이므로 ④이다.

핵심 개념: 빅데이터의 출현은 데이터 발생량의 증가만으로 설명되지 않는다. 데이터 축적, 분석 수요와 방법의 발전, 이를 처리할 기술 기반이 함께 형성되었다.
보기 검토: ①은 데이터 축적만 인정해 연구·기술의 역할을 제외한다. ②는 가와 나만 포함해 대량 처리를 가능하게 한 기술 기반을 빠뜨린다. ③은 분석 연구와 알고리즘 발전을 제외한다. 어느 한 요소만으로 오늘날의 빅데이터 분석 환경을 설명하기 어렵다.
학습 포인트: '많이 발생했다'와 '그 데이터를 활용할 수 있게 되었다'를 연결해서 이해한다. 자료가 많아도 저장·처리 비용이 지나치게 크거나 활용 목적이 없다면 대규모 분석의 가치가 실현되기 어렵다.

8. 빅데이터가 만들어낸 데이터 분석 방향의 변화로 옳은 것은?

① 데이터의 사후처리 방식에서 사전처리 중심으로 변화하였다.
② 데이터의 전수조사 방식에서 표본조사 중심으로 변화하였다.
③ 데이터의 질 중심에서 양 중심으로 변화하였다.
④ 데이터 간 상관관계에서 인과관계 중심으로 변화하였다.

정답 ③
③은 대량의 다양한 자료를 활용해 패턴을 발견하는 방향을 설명하므로 교재상의 '질에서 양'이라는 변화와 대응한다. 자료가 많으면 다양한 사례를 포착할 수 있고 과거에는 보기 어려웠던 패턴을 분석할 수 있다.

핵심 개념: ADsP의 빅데이터 가치 변화에서는 사전 처리에서 사후 처리로, 표본 중심에서 가능한 전체 자료 활용으로, 엄격한 소량 자료에서 대량 자료 활용으로, 인과 설명뿐 아니라 상관 패턴 활용으로의 이동을 설명한다. 이는 비교를 위한 경향이며 모든 분석의 절대 규칙은 아니다.
보기 검토: ①은 사후 처리로의 변화 방향을 반대로 썼다. ②는 전체에 가까운 자료를 활용할 수 있게 된 변화를 표본조사 중심이라고 반대로 설명했다. ④ 역시 관측된 상관관계를 활용하는 흐름을 인과관계 중심으로 바꿔 적었다.
학습 포인트: '양 중심'이 낮은 품질을 무조건 허용한다는 뜻은 아니다. 잘못된 값, 표본 선택 편향, 개인정보 문제는 데이터가 많아도 해결되지 않는다. 상관 패턴을 이용한 예측과 원인 규명을 위한 인과 분석도 목적이 다르다.

9. 빅데이터 시대의 위기 요인이 아닌 것은?

① 사생활 침해
② 기업 경쟁력 약화
③ 책임 원칙 문제
④ 데이터 오용

정답 ②
②의 기업 경쟁력 약화는 제시된 교재형 위기 분류의 대표 항목이 아니다. 빅데이터를 적절히 활용하면 고객 이해·운영 효율·신규 서비스 등에 도움이 될 수 있으므로 이 목록에서 제외되는 항목을 고르는 답은 ②이다.

핵심 개념: 빅데이터의 대표적인 위기 요인은 사생활 침해, 책임 원칙의 훼손, 데이터 오용이다. 활용 가능성이 커지는 만큼 개인의 정보와 의사결정에 미치는 영향을 함께 검토해야 한다.
보기 검토: ①은 여러 정보를 결합해 개인을 식별하거나 민감한 특성을 알아낼 수 있는 위험이다. ③은 예측된 미래 행동만으로 개인에게 책임을 묻는 등 책임 판단의 원칙이 훼손될 위험이다. ④는 자료의 편향·잘못된 분석·부적절한 활용으로 불리한 결과를 초래하는 위험이다.
학습 포인트: ②를 골랐다고 현실에서 데이터 활용이 경쟁력에 불이익을 줄 가능성이 전혀 없다는 뜻은 아니다. 질문은 특정 교재 분류의 대표 요인을 묻는다. 일반적인 현실 가능성과 시험의 분류 기준을 구분해야 한다.

10. 다음 중 분류 분석의 적용 사례로 옳지 않은 것은?

① 신용 등급 예측
② 스팸 메일 분류
③ 질병 진단 예측
④ 위치 및 면적을 이용한 아파트 가격 예측

정답 ④
④에서 아파트 가격은 보통 5억 원, 6억 2천만 원 같은 연속적인 수치로 예측한다. 따라서 위치·면적 등을 설명변수로 사용하는 회귀 문제에 해당한다.

핵심 개념: 분류는 범주형 결과를, 회귀는 수치형 결과를 예측한다. 어떤 알고리즘을 쓰는지보다 목표변수의 형태를 먼저 확인하는 것이 빠르다.
보기 검토: ①의 신용 등급을 A·B·C 등으로 예측하면 분류이다. ②는 스팸과 정상이라는 두 범주를 구분하는 이진 분류이다. ③은 질병 있음·없음 또는 질병 종류를 예측한다면 분류이다. '예측'이라는 단어가 있다고 모두 회귀인 것은 아니다.
적용 예: 아파트의 정확한 가격을 예측하면 회귀이지만 '고가·중가·저가'라는 범주를 예측하도록 목표를 정의하면 분류가 된다. 신용 위험도 점수 자체를 수치로 추정하는 문제와 그 점수를 등급으로 구분하는 문제도 목표변수에 따라 다르다.

2과목 데이터 분석 기획 (11~20번)

11. 데이터 분석 도입에 대한 설명으로 옳지 않은 것은?

① 분석 과제 우선순위를 선정해야 한다.

② 핵심 분석만 하지 않고 여러 개의 분석을 동시에 해야 한다.

③ 분석 도입을 위해 분석 과제를 도출해야 한다.

④ 효율적 분석을 위해 핵심 분석 과제에 집중해야 한다.

정답 ②

②는 핵심 분석에 집중하지 않고 여러 분석을 동시에 해야 한다고 단정한다. 인력·예산·데이터 준비가 부족한 상황에서 무조건 병행하면 어느 과제도 충분히 검증하지 못할 수 있다. 동시 수행은 과제 간 관계와 수행 역량을 고려해 결정해야 한다.

핵심 개념: 분석 도입에서는 해결할 업무 문제를 도출하고, 가치·시급성·실행 가능성으로 우선순위를 정하며, 제한된 자원을 중요한 과제에 배분한다. 과제의 수가 많다고 성과가 자동으로 커지지 않는다.

보기 검토: ①은 우선순위 선정의 필요성을 설명한다. ③은 도입 전에 구체적인 분석 과제를 찾아야 한다는 뜻이다. ④는 중요한 과제를 중심으로 효과를 확인하고 경험을 축적한다는 취지로 적절하다. 핵심 과제 집중과 장기적인 과제 확대는 양립할 수 있다.

적용 예: 재고 문제와 고객 이탈 문제를 모두 해결하고 싶어도 먼저 확보된 데이터와 담당 인력이 있는 과제를 수행할 수 있다. 성과를 검증한 뒤 분석 범위를 넓히는 것이 체계적인 도입이다. 동시에 수행 가능한 충분한 역량이 있는 조직이라면 병행 자체가 잘못인 것은 아니다.

12. 분석 주제 유형에 대한 설명으로 적절한 것은?

① 분석 대상과 분석 방법 모두 모르는 경우, 솔루션 개발을 통해 문제를 해결한다.

② 분석 대상은 알지만 분석 방법을 모르는 경우, 발견을 통해 문제를 해결한다.

③ 분석 대상과 분석 방법 모두 아는 경우, 최적화를 통해 문제를 해결한다.

④ 분석 대상은 모르지만 분석 방법은 아는 경우, 발견을 통해 문제를 해결한다.

정답 ③

③은 분석할 대상과 적용 방법을 모두 알고 있으므로 기존 방법을 더 잘 적용해 효과를 높이는 최적화 유형이다. 예를 들어 재고 부족을 줄이는 것이 목표이고 사용할 수요 예측·재고 최적화 방법을 알고 있다면 설정과 운영을 개선한다.

핵심 개념: 분석 주제 유형은 대상과 방법을 각각 알고 있는지에 따라 네 가지로 구분한다. 대상과 방법을 모두 알면 최적화, 대상은 알고 방법은 모르면 솔루션, 대상은 모르고 방법은 알면 통찰, 둘 다 모르면 발견에 대응한다.

보기 검토: ①의 둘 다 모르는 상황은 솔루션이 아니라 발견이다. ②의 대상만 아는 상황은 발견이 아니라 솔루션을 탐색하는 유형이다. ④의 방법만 아는 상황은 발견이 아니라 통찰이다. '모르는 것이 하나라도 있으면 발견'이라고 외우면 오답이 된다.

학습 포인트: 대상은 '무슨 업무 문제를 분석할 것인가', 방법은 '어떤 분석 기법으로 해결할 것인가'로 이해한다. 분석 기법은 알고 있지만 어느 업무에 적용하면 가치가 있는지 모른다면 방법을 보유한 상태에서 활용 대상을 찾는 통찰의 상황이다.

13. CRISP-DM 분석 방법론의 단계별 과정으로 옳은 것은?

① 데이터 이해 → 데이터 준비 → 업무 이해 → 모델링 → 평가 → 전개

② 데이터 이해 → 데이터 준비 → 모델링 → 평가 → 업무 이해 → 전개

③ 데이터 준비 → 데이터 이해 → 모델링 → 평가 → 업무 이해 → 전개

④ 업무 이해 → 데이터 이해 → 데이터 준비 → 모델링 → 평가 → 전개

정답 ④

④만 이 기본 흐름을 따른다. 업무 이해에서 문제·목표·제약을 정하고, 데이터 이해에서 자료의 내용·분포·품질을 조사한다. 데이터 준비에서 분석용 자료를 만들고, 모델링에서 분석 기법을 적용한다. 평가에서 분석 결과가 통계적 성능뿐 아니라 업무 목표에 맞는지 검토하며, 전개에서 실제 활용 방안을 실행한다.

핵심 개념: CRISP-DM의 기본 순서는 업무 이해, 데이터 이해, 데이터 준비, 모델링, 평가, 전개이다. 먼저 업무 목표를 분명히 해야 필요한 자료와 성공 기준을 정할 수 있다.

보기 검토: ①은 자료를 준비한 뒤 업무를 이해하도록 배치했다. ②는 모형을 평가한 뒤 업무 목적을 이해한다. ③은 자료를 이해하기 전에 준비 작업을 배치했다. 각각 필요한 선행 판단의 순서가 뒤바뀐다.

학습 포인트: 기본 순서를 외우되 실제 프로젝트는 한 방향으로만 진행되지 않는다는 점도 이해한다. 평가 결과 문제가 발견되면 데이터 준비나 모델링으로 돌아갈 수 있다. 전개 역시 서비스를 배포하는 경우뿐 아니라 분석 보고서와 업무 실행 계획으로 결과를 전달하는 경우를 포함한다.

14. 분석 과제 정의서에 대한 내용으로 옳지 않은 것은?

① 분석 프로젝트의 목표 달성을 위한 구체적인 방법 및 절차가 명시되어야 한다.

② 분석 과제의 목표 및 범위, 분석 결과 활용 방안 등이 포함되어야 한다.

③ 분석에 필요한 소스 데이터, 데이터 입수 및 분석 방법 등이 포함되어야 한다.

④ 활용 데이터는 내부 데이터로만 제한해야 한다.

정답 ④

④는 활용 자료를 내부 데이터로만 제한해야 한다고 단정한다. 과제의 목적에 따라 외부 공개자료·시장자료·날씨·인구통계 등도 활용할 수 있으므로 잘못된 설명이다. 외부 자료를 사용할 때는 접근 권한·품질·갱신 주기·결합 가능성을 검토한다.

핵심 개념: 분석 과제 정의서는 무엇을, 왜, 어느 범위에서, 어떤 자료와 방법으로 분석하고 결과를 어떻게 활용할지 명확히 하는 문서이다. 이해관계자 사이의 기대와 수행 범위를 맞추는 역할을 한다.

보기 검토: ①의 방법·절차는 수행 방향을 명확히 하는 요소이다. ②의 목표·범위·활용 방안은 과제의 가치와 완료 기준을 판단하는 요소이다. ③의 소스 데이터·입수 계획·분석 방법은 실행 가능성을 검토하는 요소이다. 분석을 시작하기 전에 서로 연결해 구체화할 필요가 있다.

적용 예: 지역별 상품 수요를 분석한다면 내부 매출 자료 외에 날씨나 지역 인구도 필요할 수 있다. 내부 자료만 사용한다는 규칙보다 업무 목표에 필요한 자료를 적법하고 신뢰할 수 있는 방식으로 확보하는 것이 중요하다.

15. 다음 문장에서 빈칸에 들어갈 용어는?

> 분석 모델의 성능을 평가할 때, 예측값과 실제값의 차이를 줄이는 것은 (가) 향상을 의미하며, 예측을 반복했을 때 예측들 간의 차이를 줄이는 것은 (나) 향상을 의미한다.

① 가: 정확도, 나: 정밀도

② 가: 정밀도, 나: 정확도

③ 가: 정확도, 나: 재현율

④ 가: 재현율, 나: 정확도

정답 ①

예측값과 실제값의 차이를 줄이면 실제값에 더 가까워지므로 가는 정확도이다. 반복 예측들의 차이를 줄이면 결과의 흩어짐이 작아지므로 나는 정밀도이다. 따라서 ①이다.

핵심 개념: 이 문항의 정확도와 정밀도는 측정·추정의 일반적인 의미이다. 정확도는 실제값에 가까운 정도이고, 정밀도는 반복 결과가 서로 가깝게 모이는 정도이다. 분류 성능지표 Accuracy·Precision을 계산하는 문제와 맥락이 다르다.

보기 검토: ②는 두 개념을 반대로 연결한다. ③과 ④의 재현율은 실제 양성 중 찾아낸 양성 비율을 뜻하므로 반복 결과의 일관성을 설명하지 않는다. 재현율은 44번에서 $\frac{TP}{TP+FN}$으로 다룬다.

적용 예: 실제 무게가 100g인데 110.0g·110.1g·109.9g으로 반복 측정되면 결과끼리는 가깝지만 실제값에서는 멀다. 즉 정밀도는 높고 정확도는 낮다. 99g·100g·101g처럼 실제값 근처에 모이면 두 측면이 모두 좋아진다. 같은 한글 '정밀도'라도 문맥에 따라 반복성 또는 분류 Precision을 뜻할 수 있으므로 정의를 확인한다.

16. 상향식 접근법에 대한 설명으로 옳지 않은 것은?

① 문제를 구체적으로 정의하기 어려운 경우에 적합하다.

② 확실한 구조와 데이터가 주어져야 한다.

③ 프로토타입을 만들어 반복적 시행착오를 통해 점진적인 개선을 이룬다.

④ 데이터 탐색과 실험, 테스트를 통해 문제 해결의 통찰을 얻는다.

정답 ②

②는 확실한 구조와 데이터가 주어져야 한다고 필수 조건처럼 말한다. 상향식에서는 구조가 불명확해도 탐색을 통해 구체화할 수 있으므로 이러한 단정이 부적절하다. 분석에 활용할 자료와 접근 가능성은 필요하지만, 문제 구조가 미리 확정되어야 한다는 의미는 아니다.

핵심 개념: 상향식 접근은 자료의 탐색과 반복적인 실험을 통해 문제와 가치 있는 패턴을 발견하는 방식이다. 처음부터 해결할 문제와 분석 구조가 완전히 정해져 있지 않은 상황에서 유용하다.

보기 검토: ①은 구체적인 문제를 정의하기 어려운 상황에서 적합하다는 설명이다. ③은 프로토타입으로 가설을 시험하고 반복적으로 개선한다는 설명이다. ④는 데이터 탐색·실험·테스트로 통찰을 얻는다는 설명이다. 모두 상향식의 특성과 맞는다.

적용 예: 고객 이탈의 원인을 처음부터 하나로 단정하지 않고 이용 기록을 살펴 새로운 고객군과 이용 패턴을 발견한다. 발견한 패턴을 바탕으로 업무 가설을 만들고 추가 분석을 수행할 수 있다. 자료에서 보인 상관 패턴이 곧바로 원인으로 확정되는 것은 아니다.

17. 하향식 접근법의 문제 탐색 단계에서 탐색 기법으로 옳지 않은 것은?

① 비즈니스 모델 기반 탐색

② 외부 참조 모델 탐색

③ 분석 유즈 케이스 탐색

④ 데이터 기반 탐색

정답 ④

④의 데이터 기반 탐색은 자료를 먼저 살펴 패턴과 문제를 발견하는 상향식 접근의 성격에 가깝다. 이 문항이 묻는 하향식 문제 탐색의 대표 기법 목록에서 제외되는 항목이다.

핵심 개념: 하향식 접근은 업무 목적과 문제에서 출발해 해결 과제를 정의한다. 문제 탐색에서는 비즈니스 모델, 외부 사례, 기존 분석 유즈 케이스를 참고하여 분석으로 해결할 수 있는 업무 문제를 찾는다.

보기 검토: ①은 제품·고객·운영 활동 등 비즈니스 모델의 구성과 가치 흐름에서 문제를 찾는다. ②는 유사 업종이나 외부의 성공 사례를 참고한다. ③은 기존 분석 적용 사례를 검토해 현재 업무에 적용할 문제를 찾는다. 세 항목은 문제와 업무 목적을 중심으로 탐색한다.

학습 포인트: '데이터를 이용하면 모두 상향식'은 잘못된 구분이다. 하향식도 실제 해결에는 데이터를 사용한다. 차이는 출발점이다. 매출 하락이라는 업무 문제를 정하고 필요한 자료를 찾으면 하향식이며, 자료를 먼저 탐색하다 예상하지 못한 고객군을 발견하면 상향식에 가깝다.

18. 우선순위 선정 기준에 대한 설명으로 옳지 않은 것은?

① 난이도는 데이터 확보, 기술, 인력 등의 측면을 고려한다.

② 시급성은 전략적 중요도를 핵심 기준으로 삼는다.

③ 시급성은 전략적 중요도와 데이터 분석 비용에 의해 결정된다.

④ 난이도는 낮고 시급성이 높은 과제를 우선적으로 수행한다.

정답 ③

③은 데이터 분석 비용을 시급성의 결정 요소로 섞었다. 비용이 의사결정 전반에 영향을 줄 수는 있지만 교재의 이 분류에서는 주로 수행 난이도·자원 측면과 연결해 판단한다. 따라서 제시된 기준 구분을 잘못 설명한 항목은 ③이다.

핵심 개념: 분석 과제의 우선순위에서는 시급성과 난이도를 구분한다. 시급성은 전략적 중요도와 업무상 긴급성·즉시 활용 필요성을, 난이도는 자료 확보·분석 기술·인력·자원 등의 수행 부담을 반영한다.

보기 검토: ①은 확보할 자료, 기술 수준, 수행 인력을 난이도의 요소로 본다는 설명이다. ②는 중요한 전략적 과제를 시급성 판단에서 고려한다는 설명이다. ④는 쉽게 실행할 수 있고 시급한 과제를 우선해 효과를 얻는 일반적인 원칙이다. 모두 적절하다.

적용 예: 현재 진행 중인 고객 이탈을 줄이는 과제는 시급할 수 있다. 그러나 외부 자료 구매와 새로운 분석 인력 확보가 필요하면 수행 난이도도 높다. 두 축을 따로 판단해야 '중요하므로 쉽다' 또는 '비용이 높으므로 시급하다'라는 혼동을 피할 수 있다.

19. 아래 과제 중에서 가장 먼저 해결해야 할 과제는?

> 과제 1 : 시급성은 높지만 난이도가 낮아 빠른 실행과 즉각적인 효과 측정 가능
> 과제 2 : 시급성은 낮고 난이도가 높아 신중한 계획 수립과 장기적 투자가 필요

① 과제 1

② 과제 2

③ 과제 1, 2 모두

④ 어떤 과제를 우선 수행할지 판단할 수 없음

정답 ①

과제 1은 지금 해결할 필요성이 높고 실행이 상대적으로 쉽다고 주어졌다. 과제 2는 긴급성이 낮으며 장기 투자와 준비가 필요하다. 제시된 두 축만으로 우선순위를 비교하면 과제 1을 먼저 수행하는 ①이 적절하다.

핵심 개념: 시급성이 높고 난이도가 낮은 과제는 빠르게 추진하여 초기 성과를 확인하기 좋은 과제이다. 이를 통해 분석의 효과를 검증하고 조직의 실행 경험을 축적할 수 있다.
보기 검토: ②는 시급성이 낮고 난이도가 높은 과제를 먼저 선택해 일반적인 우선 원칙과 어긋난다. ③은 두 과제를 동일한 우선순위로 처리한다는 취지이며, 제한된 자원에서 무엇을 먼저 할지 묻는 질문에 답하지 못한다. ④는 주어진 판단 정보가 충분하다는 점을 놓친다.
학습 포인트: '먼저 수행'과 '다른 과제는 폐기'는 다르다. 과제 2도 장기적 가치가 있다면 별도로 계획할 수 있다. 현실에서는 법적 의무, 선후 의존관계, 기대효과와 위험이 우선순위를 바꿀 수 있지만, 이 문제에는 그 추가 조건이 없으므로 제공된 조건을 따른다.

20. 데이터 분석 준비도 평가에 들어갈 내용으로 옳지 않은 것은?

① 조직 및 인력

② 분석 기술

③ 분석 데이터

④ 재무 상태

정답 ④

④의 재무 상태는 기업 전체의 경영·투자 능력을 평가하는 항목으로, 이 문항의 분석 준비도 구성 항목 자체는 아니다. 분석 예산 확보가 현실의 준비도와 무관하다는 뜻이 아니라 교재에서 구분한 대표 평가 영역에 포함되는지 묻는 것이다.

핵심 개념: 분석 준비도는 조직이 분석 업무를 실제로 수행할 기반을 갖추었는지 평가하는 관점이다. 대표적으로 분석 업무, 인력과 조직, 기법, 데이터, 문화, IT 인프라 등을 살핀다.
보기 검토: ①은 분석 담당자, 역할, 조직적 지원 체계를 확인한다. ②는 분석에 적용할 기술·기법·도구의 기반을 확인한다. ③은 분석에 필요한 자료의 보유 여부와 접근 가능성·품질을 확인한다. 세 요소가 부족하면 과제 실행이 어렵다.
학습 포인트: 준비도는 '분석을 수행할 기반이 얼마나 갖추어졌는가', 성숙도는 '분석을 얼마나 체계적이고 발전된 수준으로 활용하는가'라는 질문에 가깝다. 기업의 매출·자산 같은 일반 재무 상태와 분석 역량 진단의 항목을 혼동하지 않는다.

3과목 데이터 분석 (21~50번)

21. 결측값 처리에 대한 설명으로 옳은 것은?

① 결측값을 대체 시 기존 데이터의 평균값으로만 해야 한다.

② 결측값 대체는 표본 수는 유지하여 데이터 손실을 최소화하는 데 목적이 있다.

③ 결측값은 일반적으로 삭제하는 것이 가장 좋은 처리 방법이다.

④ 결측값을 대체하는 것으로 데이터의 편향이 유발되지는 않는다.

정답 ②

②는 결측값 대체가 행 삭제로 인한 표본 손실을 줄이고 관측 자료를 활용하려는 목적을 가진다는 뜻이다. 빈 값이 있는 모든 행을 제거하면 유용한 다른 변수의 정보까지 버릴 수 있다. 다만 대체가 실제 관측 정보를 새로 만들어 내거나 불확실성을 완전히 없애는 것은 아니다.

핵심 개념: 결측값은 관측되어야 할 값이 없거나 기록되지 않은 상태이다. 제거 또는 대체 방법을 선택할 때 결측 원인·비율·변수의 성격과 분석 목적을 함께 고려한다.

보기 검토: ①은 평균 외에도 중앙값·최빈값·모형 기반 대체·다중 대체 등 다양한 방법이 있어 틀리다. ③은 삭제가 항상 최선이라고 일반화해 틀리다. ④는 대체 방법과 결측 원인에 따라 편향이 생길 수 있으므로 틀리다. 특히 같은 평균을 반복 삽입하면 분산을 줄이고 변수 관계를 왜곡할 수 있다.

적용 예: 소득 미응답이 높은 소득군에 집중되어 있다면 전체 평균으로 채우는 것만으로 원래 분포를 회복하기 어렵다. 예측 모형을 만들 때 대체에 사용할 평균·모형은 학습 자료에서 구하고 검증·시험 자료에 적용해야 자료 누출을 피할 수 있다.

22. 가설 검정에 대한 설명으로 가장 옳지 않은 것은?

① p-value는 0과 1 사이의 값을 가지며 통계적 유의성 판단 기준이 된다.

② p-value가 작을수록 대립가설을 지지하는 증거가 된다.

③ p-value가 유의수준(α)보다 작으면 대립가설을 기각한다.

④ p-value가 유의수준(α)보다 크면 귀무가설을 기각하지 못한다.

정답 ③

③은 p값이 작을 때 대립가설을 기각한다고 반대로 썼다. 올바른 결론은 귀무가설을 기각하는 것이다. 예를 들어 $\alpha = 0.05$이고 $p = 0.01$이면 귀무가설 아래에서 관측 결과가 충분히 극단적이므로 귀무가설을 기각한다.

핵심 개념: 귀무가설 H_0를 기준으로 관측 결과의 극단성을 나타내는 값이 p값이다. 유의수준 α는 검정 전에 정하는 판단 기준이며, 통상 $p < \alpha$이면 귀무가설을 기각한다.

보기 검토: ①은 일반적인 검정에서 p값의 범위와 용도를 설명한다. ②는 검정 가정이 맞다는 전제에서 작은 p값이 귀무가설과 자료의 불일치를 더 크게 나타낸다는 취지이다. ④는 p값이 α보다 크면 귀무가설을 기각하지 못한다는 올바른 표현이다. p값이 크다고 귀무가설이 참이라고 증명된 것은 아니다.

학습 포인트: $p = 0.01$을 '귀무가설이 참일 확률 1%'라고 읽지 않는다. p값은 가설의 참일 확률이 아니라 가정한 모형 아래에서 계산한 자료의 극단성이다. 효과 크기와 실무적 중요성도 p값과 별도로 살핀다. 표본이 크면 작은 차이도 유의해질 수 있다.

23. 모집단에서 30대 남성 30명을 무작위 추출하여 평균 체중을 추정할 때, 설명으로 옳지 않은 것은?

① 표본평균은 모평균의 불편추정량이다.

② 표본 크기가 커지면 표본평균의 표준오차가 작아진다.

③ 점추정은 모수를 하나의 값으로 추정하는 방식이다.

④ 같은 모집단에서 표본을 다시 추출해도 표본평균은 항상 같은 값이다.

정답 ④

30명을 다시 뽑으면 포함되는 사람이 달라지므로 표본평균도 달라진다. 표본평균이 항상 같은 값이라고 한 ④가 틀렸다.

핵심 개념: 모집단 전체의 특성을 나타내는 수치(모평균 μ)는 모수이고, 표본으로 계산하는 표본평균 $\bar{X}$는 통계량이다. 통계량은 어떤 표본이 뽑히느냐에 따라 값이 달라지는 확률변수이며, 그 분포를 표본분포라고 한다.

보기 검토: ①은 무작위 표본에서 $E(\bar{X}) = \mu$이므로 맞다. ②는 표본평균의 표준오차가 $\sigma/\sqrt{n}$이므로 n이 커지면 작아진다. ③은 점추정의 정의이다. 모수가 포함될 범위를 구간으로 제시하는 것은 구간추정이다.

학습 포인트: $E(\bar{X}) = \mu$에서 μ는 모수이지만 $\bar{X}$ 자체는 통계량이다. 표본평균의 기대값이 모평균과 같다는 것(불편성)과 한 번 관측한 표본평균이 모평균과 같다는 것은 다르다.

24. 아래 확률분포에 대한 기대값은?

P(X=1) = 0.4
P(X=2) = 0.3
P(X=3) = 0.2
P(X=4) = 0.1

① 1.0

② 1.5

③ 2.0

④ 2.5

정답 ③

$E(X) = 1 \times 0.4 + 2 \times 0.3 + 3 \times 0.2 + 4 \times 0.1 = 0.4 + 0.6 + 0.6 + 0.4 = 2.0$이다. 따라서 ③이다. 단순히 값 1·2·3·4의 산술평균을 계산하면 2.5이지만, 각 값이 동일한 확률로 발생하지 않으므로 이 계산은 잘못된다.

핵심 개념: 이산확률변수의 기대값은 각 가능한 값에 그 값이 발생할 확률을 곱한 뒤 더한 가중평균이다. $E(X) = \sum x P(X = x)$로 계산한다.

자료 확인: 그림의 값은 $X = 1, 2, 3, 4$이고 대응 확률은 0.4,0.3,0.2,0.1이다. 확률의 합은 $0.4 + 0.3 + 0.2 + 0.1 = 1$이므로 확률분포 조건을 만족한다.

보기 검토: ①의 1.0은 확률의 합이며 기대값이 아니다. ②의 1.5는 주어진 곱의 합과 맞지 않는다. ④의 2.5는 확률을 무시한 값들의 산술평균에 해당한다.

학습 포인트: 기대값 2.0은 한 번 시행할 때 항상 2가 나온다는 뜻이 아니다. 같은 확률 구조의 시행을 충분히 반복했을 때 평균의 기준이 되는 값이다. 기대값은 가능한 값 사이에 놓이며 경우에 따라 실제로 발생할 수 없는 값이 될 수도 있다.

25. 다음 회귀분석 결과에서 결정계수 값은?

SSE(오차제곱합) = 200 SSR(회귀제곱합) = 300

① 0.33
② 0.4
③ 0.6
④ 0.67

정답 ③

$SST = 300 + 200 = 500$이고, $R^2 = 300/500 = 0.6$이다. 또는 $1 - 200/500 = 0.6$으로 계산할 수 있다. 따라서 ③이다.

핵심 개념: 절편을 포함한 일반적인 최소제곱 회귀에서는 전체 변동 SST를 회귀가 설명한 변동 SSR과 잔차 변동 SSE로 나누며 $SST = SSR + SSE$이다. 결정계수는 $R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$이다.

자료 확인: 그림에서 SSE는 오차제곱합 200, SSR은 회귀제곱합 300이라고 표시되어 있다. 여기서는 기호보다 그림의 한글 정의를 기준으로 해석한다. 문헌에 따라 SSR을 잔차제곱합의 기호로 사용하는 경우도 있으므로 이름을 확인해야 한다.

보기 검토: ②의 0.4는 잔차 변동이 전체 변동에서 차지하는 비율이다. ①의 0.33과 ④의 0.67은 적절한 분자·분모로 계산한 결정계수가 아니다. 회귀제곱합을 잔차제곱합만으로 나누는 $300/200$도 결정계수가 아니다.

학습 포인트: 0.6은 모형이 이 표본의 종속변수 변동 중 60%를 설명한다는 뜻이다. 예측의 60%가 정답이라는 의미도, 인과관계가 60% 증명됐다는 의미도 아니다. 훈련 자료에서 높은 R^2가 새로운 자료의 좋은 예측 성능을 보장하지도 않는다.

26. 일표본 t-검정 결과에 대한 설명으로 옳지 않은 것은?

p-value = 0.001 자유도(df) = 99 표본평균 = 51.5

① 유의수준 0.05에서 귀무가설을 기각하지 못한다.
② 전체 데이터 수는 100개이다.
③ 표본평균을 표준화한 검정통계량이 t분포를 따른다고 가정한다.
④ 확률변수가 정규분포를 따른다는 가정이 필요하다.

정답 ①

출력에는 $p = 0.001$, 자유도 99, 표본평균 51.5가 제시되어 있다. 일표본 검정에서 $n - 1 = 99$이므로 $n = 100$이다. 유의수준을 0.05로 정했다면 $0.001 < 0.05$이므로 귀무가설을 기각한다. 출력에서 유의수준 자체가 결정되는 것은 아니다.

핵심 개념: 일표본 t검정은 모집단 평균 μ가 가정한 값 μ_0와 같은지를 검정한다. 모집단 표준편차를 모를 때 검정통계량 $t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$을 사용하며, 정규 모집단의 독립 표본이라는 조건에서 H_0 아래 자유도 $n - 1$의 t분포를 따른다.

보기 검토: ①은 $p = 0.001$이 유의수준 0.05보다 작아 귀무가설을 기각해야 하므로 틀렸다. ②는 일표본 검정의 자유도 $n - 1 = 99$에서 $n = 100$이므로 맞다. ③은 귀무가설 아래 $t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$이 자유도 99의 t분포를 따른다는 설명으로 맞다. ④는 t검정의 정규 모집단 가정으로 맞으며, 표본이 크면 중심극한정리에 따라 근사적으로 적용할 수 있다.

27. 데이터 분포에서 중앙 50%의 흩어진 정도를 나타내는 지표는?

① 평균
② 표준편차
③ 중앙값
④ 사분위 범위

정답 ④

Q1은 대략 하위 25%의 경계, Q3는 대략 하위 75%의 경계이므로 그 사이의 자료가 중앙 50%에 해당한다. 이 구간의 흩어진 정도를 묻는 질문에는 ④가 맞는다. 예를 들어 $Q_1 = 10$, $Q_3 = 18$이면 $IQR = 8$이다.

핵심 개념: 사분위 범위 IQR은 제3사분위수 Q3에서 제1사분위수 Q1을 뺀 값이다. $IQR = Q_3 - Q_1$이며 자료의 가운데 약 50%가 퍼진 폭을 나타낸다.

보기 검토: ① 평균과 ③ 중앙값은 자료가 어디에 위치하는지 나타내는 중심 경향 지표이다. ② 표준편차는 평균에서 떨어진 정도를 전체 관측값에 대해 종합하는 산포 지표이며 중앙 50%의 폭을 직접 나타내는 값은 아니다.

학습 포인트: IQR은 양 끝의 극단값에 표준편차보다 덜 민감하다. 상자그림에서 상자의 아래·위 경계가 Q1·Q3이고 상자의 길이가 IQR이다. 흔히 $Q_1 - 1.5IQR$보다 작거나 $Q_3 + 1.5IQR$보다 큰 값을 이상치 후보로 표시하지만, 그 후보가 모두 잘못 입력된 자료라는 뜻은 아니다. 사분위수의 세부 계산 방식에 따라 작은 표본에서는 값이 달라질 수 있다.

28. 다차원척도법(MDS)의 활용 사례로 옳은 것은?

① 매출 예측
② 주택 가격 예측
③ 영화 간 유사성 분석 및 시각화
④ 고객 마케팅 효과 분석

정답 ③

③의 영화 간 유사성 분석과 시각화는 MDS의 목적에 맞는다. 관람객의 평가나 취향으로 영화 간 비유사도를 계산하고, 그 관계를 2차원 지도에 표시하면 유사한 영화군을 파악할 수 있다.

핵심 개념: 다차원척도법 MDS는 대상 사이의 거리 또는 비유사도를 입력으로 하여 낮은 차원의 좌표에 배치하는 방법이다. 비슷한 대상은 가깝고 다른 대상은 멀게 배치하여 관계를 시각적으로 이해하도록 한다.

보기 검토: ① 매출과 ② 주택 가격을 수치로 예측하는 문제는 일반적으로 회귀·예측 모델링의 직접적인 목적이다. ④ 고객 마케팅 효과의 예측이나 원인 추정도 MDS의 대표적인 직접 목적은 아니다. MDS 좌표를 후속 모형에 활용할 수 있지만 그 자체가 결과값을 예측하는 지도학습 모형은 아니다.

학습 포인트: PCA도 차원을 줄이지만 주로 원래 수치 변수의 분산을 보존하는 선형 축을 찾는다. MDS는 대상 간 거리 관계를 낮은 차원에서 재현하려 한다. 시각화 좌표를 읽을 때 축의 절대 의미보다 대상 사이의 상대적 위치·거리에 주목한다. 실제 축소에서는 거리의 일부 왜곡이 발생할 수 있다.

29. 독립변수 A, B에 대해 피어슨 상관계수가 0.8이고, p-value가 0.01일 때 옳은 것은?

① A와 B는 양의 선형 관계를 가지고 유의수준 0.05에서 통계적으로 유의하다.

② A의 값이 커짐에 따라 B의 값은 작아지는 경향을 보인다.

③ 유의 수준에 무관하게 상관계수는 통계적으로 유의하다.

④ 두 변수가 비선형 관계를 갖고 있을 가능성이 높다.

정답 ①

$r = 0.8 > 0$이므로 양의 선형 관계가 강하게 관측된다. 상관 검정의 $p = 0.01$은 $\alpha = 0.05$보다 작으므로 '모상관계수가 0'이라는 귀무가설을 기각한다. 제시된 조건을 함께 반영한 ①이 맞다.

핵심 개념: 피어슨 상관계수 r의 부호는 선형 관계의 방향, 절댓값은 선형 관계의 강도를 나타낸다. 상관계수와 그 p값은 서로 다른 질문에 답한다. r은 관측된 관계의 정도, p값은 가정한 귀무가설과 자료의 부합 정도를 나타낸다.

보기 검토: ②는 방향을 음의 관계로 반대로 설명한다. ③은 유의수준에 무관하다고 말해 틀리다. 예를 들어 $\alpha = 0.001$이라면 $p = 0.01$로 귀무가설을 기각하지 못한다. ④의 강한 비선형 관계 가능성을 이 수치만으로 판단할 수는 없다. 양의 선형 관계가 관측되었다는 해석이 가장 직접적이다.

학습 포인트: 제목의 '독립변수 A, B'는 분석에 사용하는 설명변수라는 뜻이며, 확률적으로 서로 독립이라는 뜻이 아니다. 또 $r = 0.8$이라도 A가 B의 원인이라고 확정할 수 없다. 관계를 파악할 때 산점도·이상치·표본 수·검정 가정을 함께 확인한다.

30. 아래 표에서 X, Y 두 변수의 표본 공분산은?

X	1	2	3	4	5
Y	2	4	5	6	8

① 3.5

② 4.0

③ 4.5

④ 5.0

정답 ①

X의 평균 편차는 $-2, -1, 0, 1, 2$이고 Y의 평균 편차는 $-3, -1, 0, 1, 3$이다. 대응 편차의 곱은 6,1,0,1,6이며 합은 14이다. 표본 공분산은 $\frac{14}{5-1} = \frac{14}{4} = 3.5$이므로 ①이다.

핵심 개념: 표본 공분산은 두 변수가 각각 평균에서 벗어난 정도를 곱한 뒤 합하고 $n-1$로 나눈 값이다. $s_{XY} = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{n-1}$이다. 분모가 n인 모집단 공분산과 구별한다.

자료 확인: $X = (1, 2, 3, 4, 5)$, $Y = (2, 4, 5, 6, 8)$이다. 대응되는 관측쌍은 다섯 개이며 $n = 5$이다. $\bar{x} = (1+2+3+4+5)/5 = 3$, $\bar{y} = (2+4+5+6+8)/5 = 5$이다.

보기 검토: ②의 4.0, ③의 4.5, ④의 5.0은 위 편차곱과 자유도로 얻는 값이 아니다. 분모를 n으로 잘못 쓰면 $14/5 = 2.8$이 되며 이것도 보기의 답과 맞지 않는다.

학습 포인트: 공분산이 양수이므로 X가 평균보다 큰 관측에서 Y도 평균보다 큰 경향이 있다. 공분산은 단위에 영향을 받으므로 서로 다른 자료의 관계 강도를 그대로 비교하기 어렵다. 이를 표준화한 지표가 상관계수이다.

31. 다음 중 주성분 분석(PCA)에 대한 설명으로 옳지 않은 것은?

① 주성분 분석은 비지도 학습이다.

② 분산을 극대화하는 방향으로 주성분을 생성한다.

③ 상관관계가 높은 변수들의 선형결합을 통해 차원을 축소하여 변수를 축약한다.

④ 주성분 수는 데이터 수만큼 생성이 가능하다.

정답 ④

④는 주성분 수를 관측 개체 수와 무조건 같게 생성할 수 있다고 일반화한다. 변수 수가 p라면 공분산 행렬의 축은 최대 p개이며, 평균을 제거한 n개 관측값에서 양의 분산을 갖는 주성분 수는 최대 $\min(p, n-1)$이다. 예를 들어 학생 100명에게서 변수 5개를 측정했다면 100개의 독립적인 주성분을 만들 수 없다.

핵심 개념: PCA는 목표변수의 정답 없이 원래 수치 변수의 선형결합으로 새로운 축을 만드는 비지도 차원 축소 방법이다. 첫 번째 주성분은 분산을 가장 많이 설명하고 다음 주성분은 이전 축과 직교하면서 남은 변동을 설명한다.

보기 검토: ①은 종속변수의 정답 없이 자료 구조를 분석하므로 맞다. ②는 분산을 크게 설명하는 방향을 찾는다는 설명이다. ③은 관련 변수의 공통 변동을 선형 결합으로 축약한다는 일반적인 용도 설명이다. 다만 원 변수 사이의 높은 상관이 PCA 수행의 필수 조건은 아니며, 축약 효율을 높이는 상황에 가깝다.

참고: $p \geq n$일 때 소프트웨어가 0분산 성분까지 포함해 n개를 반환하는 경우가 있어 '데이터 수만큼'이라는 표현만으로 모든 상황을 배제할 수는 없다. 변수 수와 행렬의 계수를 고려해야 한다. 이 문항의 의도는 관측 수와 변수 차원을 혼동한 ④를 고르는 것이다.

32. 데이터마이닝 수행 단계의 순서로 옳은 것은?

① 목적 설정 → 데이터 가공 → 데이터 준비 → 기법 적용 → 검증

② 목적 설정 → 데이터 준비 → 데이터 가공 → 기법 적용 → 검증

③ 데이터 가공 → 데이터 준비 → 목적 설정 → 기법 적용 → 검증

④ 데이터 가공 → 데이터 준비 → 기법 적용 → 목적 설정 → 검증

정답 ②

②는 이 흐름을 따른다. 목적 설정에서 해결할 문제를 정하고, 데이터 준비에서 원천 자료를 확보·선별한다. 데이터 가공에서 정제·변환·변수 생성을 수행한다. 기법 적용에서 적절한 알고리즘으로 패턴이나 예측 모형을 만들며, 검증에서 결과의 성능·안정성·업무 적합성을 평가한다.

핵심 개념: 데이터마이닝의 기본 흐름은 목적 설정, 데이터 준비, 데이터 가공, 기법 적용, 검증이다. 목적이 먼저 정해져야 필요한 자료와 평가 기준을 선택할 수 있다.

보기 검토: ①은 데이터를 준비하기 전에 가공한다. ③은 목적이 정해지기 전에 가공·준비부터 수행한다. ④는 기법까지 적용한 뒤에 목적을 설정해 성공 기준이 뒤늦게 생긴다. 제시된 기본 순서로는 모두 부적절하다.

적용 예: 고객 이탈 예측이 목적이라면 이탈 정의와 예측 시점을 먼저 정한 뒤 이용 이력을 확보한다. 결측 처리와 최근 사용량 변수 생성 후 분류 모형을 학습하고, 시간적으로 나중 자료에서 성능을 확인한다. 실제 프로젝트에서는 검증 결과에 따라 앞 단계로 돌아가지만 기본적인 선행 관계는 유지한다.

33. 다음 중 상관분석에 대한 설명으로 옳지 않은 것은?

① 상관계수의 통계적 유의성을 검정할 수 있다.

② 상관계수의 절대값이 1에 가까울수록 강한 선형 관계를 의미한다.

③ 상관 분석을 통해 독립 변수에 따른 종속 변수의 값을 예측할 수 있다.

④ 피어슨 상관계수는 연속형 변수에서 두 변수 간의 선형관계를 측정한다.

정답 ③

③은 상관분석 자체를 종속변수의 값을 예측하는 기법으로 설명한다. 상관계수 하나만으로 절편·기울기·단위에 맞는 예측값을 바로 얻을 수 없으므로 이 문항에서는 잘못된 설명이다. 예측식을 만들려면 회귀 등 추가적인 모형이 필요하다.

핵심 개념: 상관분석은 두 변수의 관계 방향과 강도를 요약하고, 회귀분석은 설명변수에 따른 결과변수의 조건부 평균이나 예측값을 모형으로 표현한다. 관계가 있다는 사실과 구체적인 예측식은 구분해야 한다.

보기 검토: ①은 적절한 가정 아래 모상관계수에 대한 검정이 가능하므로 맞다. ②는 절댓값이 1에 가까울수록 선형 관계가 강하다는 설명이다. ④는 피어슨 상관계수의 대표적인 용도를 말한다. 정규성 등의 가정은 상관계수를 계산하는 것과 유의성 검정을 수행하는 것에서 구분해서 살핀다.

학습 포인트: 단순회귀에서는 r과 표준편차를 이용해 기울기를 표현할 수 있지만 그것은 평균·표준편차 정보와 회귀 모형을 함께 사용하는 것이다. 상관이 크다고 원인이나 예측의 정확성이 자동으로 보장되지 않는다. $r = 0$이어도 U자형처럼 강한 비선형 관계가 있을 수 있다.

34. 다음 중 정상 시계열의 특징에 대한 설명으로 옳은 것은?

① 시점에 무관하게 평균과 분산이 일정하다.

② 시간의 흐름에 따라 변동성이 있다.

③ 특정 구간에서 일정한 값을 가진다.

④ 공분산은 시차에 의존하지 않고 시점에 의존한다.

정답 ①

①은 평균과 분산이 시점에 무관하게 일정하다고 설명한다. 정상 시계열에서는 값 자체는 매번 바뀌더라도 그 값이 변동하는 확률적 구조가 시간에 따라 유지된다.

핵심 개념: 이 문항은 약정상성을 기준으로 읽는다. 평균이 시간에 따라 변하지 않고, 분산이 유한하고 일정하며, 두 시점의 공분산이 시점 자체가 아니라 시차에만 의존하는 것이 핵심이다.

보기 검토: ②의 '변동성'이 시간에 따라 분산이 바뀐다는 의미라면 비정상성에 가깝다. 단순히 값이 변한다는 뜻이면 정상 자료도 변하므로 정답을 특정할 설명이 되지 않는다. ③은 특정 구간의 값이 일정하다는 사실만으로 전체 시계열의 정상성을 판단할 수 없어 부적절하다. ④는 공분산의 의존 대상을 반대로 썼다. 정상 시계열의 공분산은 시차에 의존한다.

적용 예: 평균 수준이 계속 상승하는 매출 자료는 추세로 인해 비정상일 수 있다. 평균 근처에서 일정한 변동 폭으로 움직이는 자료는 정상성의 후보가 된다. 추세에는 차분, 분산 변화에는 로그 등의 변환을 검토할 수 있지만 적용 후의 구조도 확인해야 한다. 평균·분산이 일정하다는 두 조건만으로 엄밀한 정상성의 모든 조건을 확인한 것은 아니다.

35. 로지스틱 회귀 결과의 해석으로 옳지 않은 것은?

> default의 Yes를 사건으로 하고 income과 balance를 설명변수로 사용한 이항 로지스틱 회귀이다.
> 계수 추정값: 절편 −11.54, income 0.00002081, balance 0.005647.
> income의 p값 0.0000299, balance의 p값 < 2×10^{-16}.

① 두 설명변수는 각각 유의수준 0.05에서 유의하다.

② income이 같으면 balance가 증가할수록 Yes의 예측 오즈가 커진다.

③ balance가 같으면 income이 증가할수록 Yes의 예측확률이 감소한다.

④ 회귀계수는 설명변수 한 단위 증가에 따른 로그 오즈의 변화량이다.

정답 ③

income의 계수가 양수이므로 balance를 고정하면 income 증가에 따라 로그 오즈·오즈·예측확률이 모두 증가한다. 감소한다고 말한 ③은 틀리다. sigmoid 변환은 입력이 커질수록 출력도 커지는 단조 증가 함수이다.

핵심 개념: 이항 로지스틱 회귀는 사건확률 p의 로그 오즈 $\log\frac{p}{1-p}$를 설명변수의 선형 결합으로 나타낸다. 여기서는 Yes가 사건이며 $\log\frac{p}{1-p} = -11.54 + 0.00002081 \times income + 0.005647 \times balance$이다.

보기 검토: ①은 income의 p값 0.0000299와 balance의 p값이 모두 0.05보다 작아 맞다. ②는 balance 계수가 양수이므로 맞다. ④는 회귀계수가 다른 변수를 고정했을 때 설명변수 한 단위 변화에 따른 로그 오즈 변화량이라는 정의이다.

계산 예: income 한 단위 증가의 오즈비는 $e^{0.00002081} \approx 1.00002081$이다. 1,000단위 증가라면 $e^{0.02081} \approx 1.02103$으로 오즈가 약 2.10% 증가한다. balance 한 단위 증가의 오즈비는 $e^{0.005647} \approx 1.005663$으로 약 0.566% 증가한다. 이것은 확률의 퍼센트포인트 증가와 다르다. 확률 변화량은 원래 p와 다른 변수의 값에 따라 달라진다.

36. 다음 중 분류 분석의 정의로 옳은 것은?

① 두 변수 간의 관계를 파악하고 예측하는 분석이다.

② 이미 분류된 데이터를 바탕으로 새로운 데이터가 속할 그룹을 예측하는 분석이다.

③ 데이터들 사이에 숨겨진 패턴 구조를 찾아내어 그룹화하는 분석이다.

④ 분석 데이터의 평균 또는 합을 예측하는 분석이다.

정답 ②

②는 이미 분류된 자료를 바탕으로 새로운 자료의 그룹을 예측한다는 정의이므로 맞다. 이메일과 스팸 여부가 함께 있는 사례를 학습하고 새 이메일의 범주를 예측하는 상황이 대표적이다.

핵심 개념: 분류는 범주를 알고 있는 학습 사례로 규칙을 학습하여 새로운 사례가 어느 범주에 속하는지 예측하는 지도학습이다. 이진 분류는 두 범주, 다중 분류는 세 개 이상 상호 배타적인 범주를 예측한다.

보기 검토: ①은 관계 파악과 예측이라는 설명으로 회귀를 포함한 여러 분석에 적용될 수 있어 분류의 구체적 정의가 아니다. ③은 정답 범주 없이 유사한 자료를 묶는 군집분석의 설명이다. ④는 평균·합 같은 수치형 결과를 예측하는 설명으로 분류와 다르다.

학습 포인트: 분류와 군집은 모두 그룹이라는 말을 사용할 수 있으나 정답 라벨의 존재가 다르다. 고객을 사전에 정한 이탈·유지 범주로 예측하면 분류이고, 고객의 구매 패턴을 보고 비슷한 집단을 새로 만들면 군집이다. 예측확률을 출력하더라도 최종 목표가 범주이면 분류 문제이다.

37. 다음 중 인공신경망(ANN)에 대한 설명으로 옳지 않은 것은?

① 이진 출력 노드에 sigmoid를 적용하는 은닉층 없는 신경망은 로지스틱 회귀의 함수 형태와 대응한다.

② 은닉층은 비선형 활성화 함수를 통해 복잡한 비선형 관계를 학습한다.

③ 렐루(ReLu) 함수는 입력값이 0보다 작으면 0으로, 0보다 크면 입력값을 그대로 출력한다.

④ 렐루(ReLu) 함수를 활성화 함수로 사용할 때, 은닉층이 없는 인공신경망은 로지스틱 회귀 모형과 동일한 특성을 가진다.

정답 ④

④의 ReLU는 $\max(0, z)$이며 출력 상한이 없다. 확률을 0과 1 사이로 변환하는 sigmoid와 다르므로 ReLU 출력만으로 로지스틱 회귀와 동일하다고 할 수 없다.

핵심 개념: 은닉층의 유무만으로 신경망과 로지스틱 회귀의 동일성을 판단할 수 없다. 입력의 가중합 $z = w^T x + b$에 이진 출력용 sigmoid를 적용하면 $p = \dfrac{1}{1+e^{-z}}$인 로지스틱 회귀의 함수 형태가 된다.

보기 검토: ①은 이진 출력 노드에 sigmoid를 사용한다는 조건이 있으므로 모형의 함수 형태는 로지스틱 회귀와 같다. 손실·정규화·최적화 설정까지 일치해야 학습 결과까지 같다고 말할 수 있다. ②는 비선형 활성화 함수가 복잡한 비선형 관계 학습을 가능하게 한다는 설명이다. ③은 ReLU의 정의로 맞으며 $z = 0$에서도 출력은 0이다.

학습 포인트: 모든 층에 선형 변환만 연속 적용하면 합성 결과도 하나의 선형 변환이다. 은닉층을 깊게 쌓는 것만으로 비선형성이 생기는 것은 아니다. 비선형 활성화 함수의 역할과 최종 출력의 의미를 함께 확인한다.

38. 단일 은닉층으로 구성된 다층 퍼셉트론에서 입력층 20개 노드, 은닉층 50개 노드, 출력층 3개로 구성될 때, 편향(Bias)을 제외한 가중치의 개수는?

① 73

② 150

③ 1150

④ 3000

정답 ③

입력층 20개와 은닉층 50개의 연결은 $20 \times 50 = 1000$개이다. 은닉층 50개와 출력층 3개의 연결은 $50 \times 3 = 150$개이다. 전체 가중치는 $1000 + 150 = 1150$개이므로 ③이다.

핵심 개념: 완전연결층에서는 앞 층의 모든 노드가 다음 층의 모든 노드와 연결된다. 두 층 사이의 가중치 수는 앞 층 노드 수와 다음 층 노드 수의 곱이다. 이 문제는 완전연결 MLP를 전제로 하며 편향은 제외한다.

보기 검토: ①의 73은 노드 수 20+50+3의 합으로 연결 가중치 수가 아니다. ②의 150은 은닉층에서 출력층으로 가는 연결만 계산한 값이다. ④의 3,000은 이 구조의 두 연결 행렬 크기에서 나오지 않는 값이다.

추가 계산: 편향까지 포함하면 은닉층에 50개, 출력층에 3개가 추가되므로 총 학습 파라미터는 $1150 + 50 + 3 = 1203$개이다. 일반적으로 층 크기가 $a \to b \to c$라면 가중치 수는 $ab + bc$, 편향 포함 파라미터 수는 $ab + b + bc + c$이다.

학습 포인트: '층 수', '노드 수', '연결 수', '파라미터 수'를 구분한다. 입력 노드는 자료를 전달하므로 이 계산에서 입력층 자체에 별도의 편향 20개를 더하지 않는다.

39. 로지스틱 시그모이드 함수의 출력 범위로 옳은 것은?

① $y \geq 1$

② 0 또는 1

③ $-1 \leq y \leq 1$

④ $0 < y < 1$

정답 ④

$z = 0$일 때 $y = 0.5$이고, z가 커지면 1에, 작아지면 0에 가까워진다. 유한한 z에서 0이나 1에 도달하지 않으므로 정확한 범위는 ④ $0 < y < 1$이다.

핵심 개념: 로지스틱 sigmoid는 $\sigma(z) = \dfrac{1}{1+e^{-z}}$이다. 유한한 실수 z에 대해 $e^{-z} > 0$이므로 분모는 항상 1보다 크고, 출력은 정확히 $0 < \sigma(z) < 1$이다.

보기 검토: ①의 $y \geq 1$은 출력이 항상 1보다 작으므로 틀리다. ②의 '0 또는 1'은 연속적인 확률 출력과 임계값으로 결정한 범주를 혼동한 설명이다. ③의 $-1 \leq y \leq 1$은 tanh의 범위($-1 < y < 1$)와 혼동하기 쉬운 표현이며 sigmoid의 범위가 아니다.

40. 앙상블 모형에 대한 설명으로 옳은 것은?

① 부스팅은 각 모델을 병렬 학습한 후 최종 결과를 보팅 방식으로 집계하여 통합한다.

② 부스팅은 이전 모델의 오차를 보완하기 위해 순차적으로 모형을 학습한다.

③ 앙상블 모델은 항상 단일 모형보다 정확한 분석 성능을 보여준다.

④ 배깅은 이전 모델이 잘못 예측한 데이터에 가중치를 두어 순차적으로 학습한다.

정답 ②

부스팅은 이전 모형이 잘못 예측한 사례에 더 큰 가중치를 두거나(AdaBoost) 남은 오차를 다음 모형이 학습하도록(경사 부스팅) 모형을 순차적으로 추가한다. 따라서 ②가 맞다.

핵심 개념: 앙상블은 여러 모형을 결합하는 상위 개념이고, 배깅과 부스팅은 서로 다른 결합 방식이다. 배깅은 재표집한 자료로 여러 모형을 만들고 결합하는 방식이며, 부스팅은 이전 단계의 부족함을 보완하도록 순차적으로 학습한다.

보기 검토: ①은 병렬 학습 후 투표로 결합하는 배깅의 설명이다. ③은 앙상블이 항상 더 좋다고 단정해 틀리다. 자료·모형·설정에 따라 단일 모형보다 성능이 낮을 수도 있다. ④는 부스팅의 순차적 가중 학습을 배깅에 붙여 틀리다. 배깅은 부트스트랩 표본으로 여러 모형을 독립적으로 학습해 결합한다.

41. 다음 중 인공신경망의 구조에 대한 설명으로 옳지 않은 것은?

① 입력층의 노드 수는 입력 데이터 특성 수에 따라 결정된다.
② 적은 은닉층은 과소적합 발생 가능성 및 복잡한 모델에는 부적합할 수 있다.
③ 모든 은닉층은 항상 동일한 개수의 노드로 구성되어야 한다.
④ 은닉층의 수는 모형의 복잡도와 학습 능력에 영향을 미친다.

정답 ③

③은 모든 은닉층이 항상 같은 수의 노드로 구성되어야 한다고 단정한다. 20→50→30→3 같은 구조도 가능하므로 틀리다. 층별 너비는 표현 능력·계산 비용·규제 효과 등을 고려해 결정한다.

핵심 개념: 신경망의 구조는 입력 특성 수, 은닉층의 수와 너비, 출력 과제에 따라 정한다. 각 은닉층의 노드 수는 같게 만들 수도 있고 다르게 만들 수도 있다.

보기 검토: ①은 일반적인 MLP에서 입력 노드 수가 전처리 후 특성 수와 대응한다는 설명이다. ②는 표현 능력이 부족한 구조가 복잡한 관계를 학습하지 못해 과소적합할 가능성을 말한다. ④는 깊이가 함수 표현 능력과 학습 과정에 영향을 준다는 설명이다. 세 항목은 '가능성'과 '영향'을 설명하므로 적절하다.

학습 포인트: 은닉층이 많거나 넓다고 성능이 항상 높아지는 것은 아니다. 파라미터 증가로 과적합 위험과 학습 비용이 커질 수 있다. 충분히 넓은 한 은닉층도 많은 함수를 근사할 수 있지만 실제 학습의 효율성·일반화는 자료와 구조에 따라 다르다. 검증 성능을 기준으로 구조를 평가한다.

42. 다층 퍼셉트론(MLP)에서 출력층의 결과가 다중 클래스(multiclass)일 때, 주로 사용하는 활성화 함수는?

① 렐루 (ReLu)
② 시그모이드 (Sigmoid)
③ 하이퍼볼릭 탄젠트 (Hyperbolic Tangent)
④ 소프트맥스 (Softmax)

정답 ④

softmax의 j번째 출력은 $p_j = \frac{e^{z_j}}{\sum_k e^{z_k}}$이다. 각 출력은 양수이며 모든 클래스의 출력 합이 1이므로 서로 배타적인 클래스 중 하나를 고르는 문제에 맞는다. 따라서 ④이다.

핵심 개념: 하나의 관측값이 여러 범주 중 정확히 하나에 속하는 다중 분류에서는 클래스별 점수를 확률처럼 해석할 수 있게 변환하는 softmax를 주로 사용한다. 출력 개수는 범주 개수와 대응한다.

보기 검토: ① ReLU는 출력 상한이 없어 클래스 확률을 합 1로 정규화하지 않는다. ② sigmoid는 이진 분류의 한 사건확률 또는 여러 라벨의 독립적인 여부를 표현하는 데 사용한다. ③ tanh는 출력이 음수일 수 있어 클래스별 확률을 직접 표현하는 대표 함수가 아니다.

계산 예: 세 클래스의 점수가 모두 같다면 각 출력은 $1/3$이다. 한 클래스의 점수가 상대적으로 커지면 그 클래스의 확률이 커지지만 다른 출력들과 함께 정규화된다.

학습 포인트: 다중 분류(multiclass)와 다중 라벨(multilabel)을 구분한다. 사진에 고양이 또는 개 중 하나를 붙이는 문제와, 한 사진에 사람·차량·동물이 동시에 있을 수 있는 문제는 다르다. 후자는 라벨별 sigmoid를 사용할 수 있다.

43. X축은 1-특이도(False Positive Rate)를, Y축은 민감도를 나타낸 그래프는?

① ROC 커브
② PR 커브
③ 산점도
④ 이익 곡선

정답 ①

특이도는 $\frac{TN}{TN+FP}$, 1−특이도는 $\frac{FP}{TN+FP}$이다. 민감도는 $\frac{TP}{TP+FN}$이다. 따라서 X축 FPR, Y축 TPR이라는 축 조합을 갖는 그래프는 ① ROC 곡선이다.

핵심 개념: ROC는 분류 임계값을 바꾸면서 거짓양성률 FPR과 참양성률 TPR의 관계를 그린 곡선이다. TPR은 민감도 또는 재현율과 같다.

보기 검토: ② PR 곡선은 보통 X축 재현율, Y축 정밀도이다. ③ 산점도는 두 수치 변수의 관측쌍을 표시하는 일반적인 그래프이다. ④ 이익 곡선은 선택한 대상 비율과 확보한 양성·성과 등을 비교하는 그래프로 ROC의 축 정의와 다르다.

적용 예: 실제 음성 90개 중 9개를 양성으로 잘못 분류했다면 $FPR = 9/90 = 0.1$이다. 실제 양성 10개 중 8개를 찾아내면 $TPR = 8/10 = 0.8$이며 ROC 위의 점은 (0.1,0.8)이다. 이상적인 위치는 (0,1)이다.

학습 포인트: AUC는 임계값을 변화시킨 전반적인 순위 구별 능력을 요약한다. AUC가 높아도 특정 임계값의 정밀도·재현율이 충분하다는 보장은 없으므로 실제 사용 목적에 맞는 기준을 별도로 선택한다.

44. 실제 값이 참(True)인 경우 모델이 참으로 올바르게 예측한 비율을 의미하는 지표는?

① 정확도 (Accuracy)
② 정밀도 (Precision)
③ 재현율 (Recall)
④ F1-Score

정답 ③

질문은 '실제 값이 참인 경우'를 기준으로 비율을 구한다. 따라서 분모에는 실제 양성 전체인 TP+FN이 들어가고, 분자에는 그중 찾아낸 TP가 들어간다. ③이 맞다.

핵심 개념: 실제 양성 중 예측도 양성인 비율은 재현율 $Recall = \frac{TP}{TP+FN}$이다. 실제 양성을 기준으로 얼마나 놓치지 않고 찾아냈는지 나타내며 민감도와 같은 의미이다.

보기 검토: ① 정확도는 $\frac{TP+TN}{TP+TN+FP+FN}$으로 전체 관측값에서 맞춘 비율이다. ② 정밀도는 $\frac{TP}{TP+FP}$로 예측 양성 중 실제 양성의 비율이다. ④ F1은 정밀도와 재현율의 조화평균이며 직접적으로 실제 양성에서 찾아낸 비율만을 뜻하지 않는다.

계산 예: 실제 양성이 20명이고 그중 16명을 양성으로 예측했다면 $TP = 16$, $FN = 4$, 재현율은 $16/20 = 0.8$이다. 예측 양성이 총 25명이라면 정밀도는 $16/25 = 0.64$로 별도의 값이다.

학습 포인트: 재현율은 '실제 양성 중 얼마나 찾았나', 정밀도는 '양성으로 예측한 것 중 얼마나 맞았나'로 기억한다. 양성이 드문 자료에서는 모두 음성으로 분류해도 정확도가 높게 나올 수 있어 정확도만으로 판단하지 않는다.

45. 분류나무의 평가 기준으로 사용되기 어려운 것은?

① 지니 지수
② 엔트로피 지수
③ 카이제곱 통계량
④ 잔차 제곱합

정답 ④
잔차제곱합은 연속적인 결과값과 예측값의 차이를 제곱해 더한 것으로, 범주형 결과를 직접 다루는 분류나무의 대표적인 노드 평가 기준은 아니다. 이 조건에서 ④를 선택한다.

핵심 개념: 분류나무의 결과는 범주이고 회귀나무의 결과는 수치이다. 분류나무는 노드의 범주 혼합 정도를, 회귀나무는 수치 예측 오차를 평가한다. 분할 기준과 가지치기 기준도 엄밀하게는 구분해야 한다.
보기 검토: ① 지니 불순도는 $1-\sum p_k^2$로 범주의 혼합 정도를 나타낸다. ② 엔트로피는 $-\sum p_k \log p_k$로 역시 범주 혼합을 나타낸다. ③ 카이제곱 통계량은 범주별 분포의 차이를 이용하며 CHAID 등의 분할 판단에 사용된다. 모두 분류나무의 분할·노드 평가와 연결할 수 있다.

46. K-Means 군집 분석에서 초기 군집 중심 설정 방법으로 옳은 것은?

① 데이터셋 내 모든 데이터의 평균을 군집 중심으로 설정한다.
② 데이터셋 내 모든 데이터의 중앙값을 군집 중심으로 설정한다.
③ 데이터셋 내 무작위로 선택된 임의의 K개 관측점을 설정한다.
④ 군집의 개수만큼 평균값을 설정한다.

정답 ③
③의 자료에서 K개 관측점을 무작위로 선택하는 방법은 가능한 초기화 방식이다. 실무에서는 초기 중심이 너무 가까워지는 문제를 줄이기 위해 K-means++ 같은 방식도 사용하지만 무작위 초기화 자체는 맞는 설명이다.

핵심 개념: K-means는 K개의 중심을 초기화한 뒤, 각 관측값을 가까운 중심에 할당하고 각 군집의 평균으로 중심을 갱신하는 과정을 반복한다. 초기 중심 선택과 이후 중심 갱신은 서로 다른 단계이다.
보기 검토: ①의 전체 자료 평균은 하나의 중심만 제공하므로 일반적인 $K>1$ 군집의 초기 중심을 구분해 주지 못한다. ②의 전체 자료 중앙값 역시 K개 군집 중심의 일반적 초기화 설명이 아니며, K-means의 중심 갱신은 군집별 평균이다. ④의 '군집 개수만큼 평균값'은 어떤 부분집합의 평균인지와 초기 할당이 제시되지 않아 초기화 절차를 설명하지 못한다.
학습 포인트: K-means는 초기값에 따라 서로 다른 지역 최적해로 수렴할 수 있다. 여러 초기값으로 반복하여 군집 내 제곱합이 작은 결과를 선택할 수 있다. 고정한 난수·자료·설정에서는 재현 가능한 결과를 얻을 수 있다.

47. 아래는 아이템별 거래 집합이다. Apriori 알고리즘을 적용하고 최소 지지도를 2로 설정했을 때, 길이가 가장 긴 빈발 항목 집합은?

> 아이템 거래 : {a, b}, {a, b, d}, {b, c, e}, {d, e}, {a, b, c, e}
> 최소 지지도 2는 비율 2가 아닌 최소 지지건수 2를 뜻한다.

① {a, b}
② {a, b, d}
③ {b, c, e}
④ {a, b, c, e}

정답 ③
단일 항목의 건수는 $a=3, b=4, c=2, d=2, e=3$으로 모두 기준을 만족한다. 길이 2 중 a·b는 3건, b·c는 2건, b·e는 2건, c·e는 2건이다. 길이 3의 {b,c,e}는 T_3와 T_5에서 2건이다. 길이 4의 {a,b,c,e}는 T_5에서만 1건이므로 탈락한다.

핵심 개념: 빈발 항목집합은 지정한 최소 지지도를 만족하는 항목 조합이다. 이 문제의 '2'는 비율이 아니라 최소 지지건수 2이다. 다섯 거래 중 적어도 두 거래에 함께 나타나야 한다.
자료 확인: 그림의 거래는 $T_1=\{a,b\}, T_2=\{a,b,d\}, T_3=\{b,c,e\}, T_4=\{d,e\}, T_5=\{a,b,c,e\}$이다.
보기 검토: ① {a,b}는 빈발이지만 길이 2이므로 최대 길이가 아니다. ② {a,b,d}는 T_2 한 건만 포함하여 기준을 충족하지 않는다. ③은 지지건수 2와 길이 3을 만족한다. ④는 길이는 길지만 한 건에만 나타나므로 빈발이 아니다.
학습 포인트: Apriori는 어떤 집합이 빈발이라면 모든 부분집합도 빈발이라는 성질을 이용한다. 빈발이 아닌 부분집합을 포함하는 후보는 제거할 수 있다. 최대 길이와 최대 지지건수는 다른 조건이다. {a,b}의 지지건수가 더 많아도 질문은 길이가 가장 긴 집합을 묻는다.

48. 다음 중 연관 분석에 대한 설명으로 옳지 않은 것은?

① 지지도는 전체 거래 중 특정 물건들이 동시에 나타나는 비율을 의미한다.
② 일반적으로 연관 분석 시 지지도보다 신뢰도가 더 중요하다.
③ 조건 반응(If - then) 기반으로 분석 결과에 대한 명확한 이해가 가능하다
④ 대표적인 예시로 장바구니 분석이 있다.

정답 ②
②는 신뢰도가 지지도보다 일반적으로 더 중요하다고 일괄적으로 순위를 정한다. 어떤 지표가 중요한지는 업무 목적과 규칙의 사용 방식에 따라 다르다. 드문 조합의 신뢰도가 높아도 전체 영향은 작을 수 있고, 흔한 결과 항목은 독립 관계에서도 신뢰도가 높게 나타날 수 있다.

핵심 개념: 연관규칙 A→B에서 지지도는 전체 거래에서 A와 B를 함께 포함하는 비율, 신뢰도는 A를 포함한 거래에서 B도 포함하는 비율이다. 향상도는 그 신뢰도를 B의 기본 발생률과 비교한 값이다.
보기 검토: ①은 공동 발생 비율이라는 지지도의 정의이다. ③은 'A가 있으면 B도 나타나는 경향'이라는 규칙 형태로 결과를 이해할 수 있다는 설명이다. ④의 장바구니 분석은 동시 구매 패턴을 찾는 대표 활용 사례이다. 다만 규칙의 방향이 상품 A의 구매가 B의 구매를 원인적으로 발생시킨다는 뜻은 아니다.
계산 예: 전체 거래의 90%가 우유를 포함하면, 커피 구매자 중 90%가 우유를 샀더라도 신뢰도 0.9만으로 특별한 연관이라고 말하기 어렵다. 향상도는 $0.9/0.9=1$이므로 독립적인 기준 발생률과 같은 수준이다.
학습 포인트: 지지도·신뢰도·향상도를 함께 보고 최소 거래건수와 활용 가치도 확인한다. 한 지표만 높다는 이유로 좋은 규칙이라고 결론 내리지 않는다.

49. 아래 특정 기간 동안 판매된 음료 구매 건 수를 통해 “커피 → 우유”의 지지도는?

구매 품목	구매건수
커피	100
우유	100
녹차	100
커피 + 우유	250
우유 + 녹차	200
녹차 + 커피	200
커피 + 우유 + 녹차	50

① 0.2
② 0.25
③ 0.3
④ 0.35

정답 ③
커피와 우유를 함께 포함하는 거래는 두 품목만 구매한 250건과 세 품목을 모두 구매한 50건이다. 따라서 지지도 $= (250 + 50)/1000 = 300/1000 = 0.3$이며 ③이다.

핵심 개념: A→B의 지지도는 $P(A \cap B)$이다. 규칙에 화살표가 있어도 지지도는 ‘전체 거래 중 두 항목이 함께 발생한 비율’이며 방향에 따라 바뀌지 않는다. 조건부확률인 신뢰도와 구분한다.
자료 해석: 표의 구매 범주를 서로 중복되지 않는 조합별 거래건수로 읽는다. 커피만 100, 우유만 100, 녹차만 100, 커피·우유만 250, 우유·녹차만 200, 녹차·커피만 200, 세 품목 모두 50으로 총 1,000건이다. 각 단일 항목의 100을 전체 항목 구매 총수라고 해석하면 공동 구매 250보다 작아 모순이 생기므로 조합별 범주라는 해석이 필요하다.
보기 검토: ②의 0.25는 세 품목 공동 구매 50건을 빠뜨린 값이다. ①의 0.2와 ④의 0.35는 해당 공동 구매 건수와 맞지 않는다. 세 품목 구매에서도 커피와 우유는 함께 나타나므로 반드시 포함한다.
추가 계산: 커피 포함 거래는 $100 + 250 + 200 + 50 = 600$건이다. 커피→우유의 신뢰도는 $300/600 = 0.5$로 지지도 0.3과 다르다.

50. 최장연결법을 이용한 군집분석 수행 결과에 대한 설명으로 옳지 않은 것은?

① 군집 간 거리는 가장 멀리 떨어진 개체들의 거리를 기준으로 한다.
② 군집 간 거리가 최소인 군집들을 순차적으로 합치면서 계층 구조를 형성한다.
③ 동일한 데이터와 방법으로 다시 분석하면 결과가 달라질 수 있다.
④ 이상치에 민감하며, 군집 간 거리가 이상치에 크게 영향을 받을 수 있다.

정답 ③
동일한 자료, 거리 계산, 전처리, 연결법과 동률 처리 규칙을 고정하면 응집형 계층 군집의 병합 절차는 결정적이다. 따라서 ‘다시 분석하면 결과가 달라질 수 있다’는 ③이 옳지 않다. 결과가 초기값에 따라 달라지는 것은 K-means의 특징이다.

핵심 개념: 최장연결법 complete linkage의 두 군집 A,B 사이 거리는 $d(A,B) = \max_{x \in A,\, y \in B} d(x,y)$이다. 각 단계에서는 이 군집 간 거리들이 가장 작은 두 군집을 합친다. ‘거리 정의에는 최대’, ‘다음 병합 선택에는 최소’가 사용되는 점을 구분한다.
보기 검토: ①은 군집 사이 모든 관측쌍의 거리 중 최댓값을 사용하므로 맞다. ②는 그 방식으로 계산한 군집 간 거리 중 가장 작은 쌍을 병합하므로 맞다. ④는 멀리 떨어진 한 관측값이 최댓값을 크게 바꿀 수 있어 이상치의 영향을 받는다는 설명으로 맞다.
학습 포인트: K-means의 초기화 의존성과 계층 군집의 결정적인 병합 절차를 구분한다. 계층적 방법이라고 이상치의 영향이 없는 것은 아니며, 최단·최장·평균·Ward 연결법의 거리 정의를 따로 익힌다.