ADsP 제47회 기출 복원문제

유형 2

정답·해설 수록본

총 50문항 · 4지선다 · 90분

1과목 데이터 이해 (1~10번)

1. 다음 암묵지와 형식지의 상호작용으로 옳은 것은?

① 공통화 → 표출화 → 연결화 → 내면화
② 공통화 → 표출화 → 내면화 → 연결화
③ 표출화 → 공통화 → 연결화 → 내면화
④ 표출화 → 연결화 → 공통화 → 내면화

정답 ①

암묵지 간 공유, 암묵지의 언어화, 형식지의 결합, 형식지의 체득 순서이다.

공통화는 경험과 관찰을 통해 암묵지를 다른 사람의 암묵지로 공유하는 과정이다. 예를 들어 숙련자의 작업을 옆에서 배우는 경우이다. 표출화는 그 요령을 설명문·매뉴얼처럼 형식지로 표현하는 과정이며, 연결화는 여러 문서와 자료를 결합해 새로운 형식지 체계를 만드는 과정이다. 내면화는 매뉴얼을 실제로 적용하며 개인의 숙련으로 체득하는 과정이다.

보기 판단: ①은 이 순서를 정확히 제시한다. ②는 형식지를 결합하기 전에 내면화를 배치하고, ③④는 암묵지 공유에서 시작하는 제시된 순환 순서를 따르지 않는다. 이 순환은 한 번으로 끝나지 않고 반복되며 조직의 지식이 확장된다.

2. 다음 DIKW 단계를 설명하는 것 중 다른 하나는 무엇인가?

① 이번 8월에 지난 1년 매출액의 50%가 집중되어 있다.
② 지난 1년 매출은 1월에서 6월까지 증가하였다.
③ 높은 여름 온도로 인해 올해 8월 매출액은 2000만원으로 예상된다.
④ 8월 구매 고객의 50%가 대부분 30대 남성 고객이다.

정답 ③

①②④는 과거 데이터를 요약한 정보이고 ③은 관계를 이용해 미래 매출을 예측하므로 정보보다 높은 단계이다.

DIKW는 데이터→정보→지식→지혜의 단계이다. 데이터는 개별 관측값, 정보는 데이터를 정리해 의미를 부여한 결과, 지식은 관계나 규칙을 이해해 설명·예측에 활용하는 단계이다. 지혜는 이를 바탕으로 상황에 맞는 판단과 행동을 선택하는 단계로 이해할 수 있다.

보기 판단: ①은 매출 집중 비율, ②는 과거 매출 추세, ④는 고객 구성 비율을 요약한 정보이다. ③은 온도와 매출의 관계를 활용해 미래 매출을 예상하므로 정보 단계를 넘어선다. 교재 예시처럼 파악한 패턴으로 새로운 상황을 추론하는 것을 지혜로 설명하는 자료도 있다. 단순히 숫자가 포함되었는지가 아니라 과거 사실의 요약인지 관계를 이용한 예측인지 구분한다.

3. 아래 설명에 대한 데이터베이스의 특성으로 올바른 것은?

> 대량의 정보를 정보처리 기기가 읽고 쓸 수 있는 기계 가독성을 가지며, 필요한 정보를 쉽게 찾을 수 있는 검색 가능성, 그리고 원거리에서도 활용할 수 있는 원격 조작성을 가진다.

① 정보 축적 및 전달 측면
② 정보 이용 측면
③ 정보 관리 측면
④ 정보기술발전 측면

정답 ①

기계 가독성·검색 가능성·원격 조작성은 정보 축적 및 전달 측면이다.

지문은 정보를 어떤 방식으로 저장하고 찾아서 전달할 수 있는지를 설명한다. 기계 가독성은 컴퓨터가 데이터를 읽고 처리할 수 있다는 뜻이고, 검색 가능성은 필요한 자료를 조건에 따라 찾아낼 수 있다는 뜻이다. 원격 조작성은 네트워크를 통해 떨어진 장소에서도 조회하거나 이용할 수 있다는 뜻이다.

보기 판단: ①이 세 특징을 묶는 교재상의 분류이다. ②는 정보를 사용하는 측면, ③은 관리하는 측면, ④는 기술 발전과의 관계라는 다른 분류이므로 지문의 핵심 용어와 직접 대응하지 않는다. 이 문제에서는 일반적인 DB의 장점을 나열하기보다 제시된 분류 명칭을 연결해야 한다.

4. 다음 중 개인정보를 타인이 알아볼 수 없도록 직접·간접 식별정보를 제거하거나 변형하여 재식별할 수 없게 처리하는 것을 의미하는 용어는?

① 표준화
② 익명화
③ 공용화
④ 내면화

정답 ②

개인을 알아볼 수 없도록 식별정보를 제거·변형하여 재식별할 수 없게 처리하는 것은 익명화이다.

핵심은 특정 개인을 알아볼 수 없도록 처리한다는 목적이다. 이름·연락처처럼 직접 식별하는 정보뿐 아니라 나이·지역·직업처럼 다른 자료와 결합해 개인을 추정하게 하는 간접 식별정보도 함께 고려한다. 이름 하나를 지우는 작업만으로 충분하다고 판단해서는 안 된다.

보기 판단: ②가 지문의 학습 개념에 대응한다. ① 표준화는 형식·단위·코드를 통일하는 작업, ③ 공용화는 공동 활용이라는 뜻, ④ 내면화는 지식을 개인의 경험으로 체득하는 과정이므로 목적이 다르다.

출처: ADsP CBT youneedpython.github.io/ADsP-CBT · 복원 문제로 실제 시험과 다를 수 있습니다.

5. 빅데이터의 기본 3V에 대한 설명으로 가장 적절하지 않은 것은?

① Volume : 기존 데이터베이스의 한계를 뛰어넘는 초대규모의 데이터 양

② Velocity : 실시간으로 데이터를 생성하고 빠르게 처리해야 하는 속도

③ Variety : 텍스트, 이미지, 영상, 음성 등 다양한 형태의 데이터 (정형, 반정형, 비정형)

④ Availability : 데이터가 필요할 때 데이터에 접근 할 수 있는 정도

정답 ④

기본 3V는 Volume, Velocity, Variety이다.

Volume은 데이터의 양, Velocity는 생성·유입·처리 속도, Variety는 데이터 형태와 출처의 다양성을 뜻한다. 예를 들어 대량의 거래 기록은 양, 실시간 센서 스트림은 속도, 표·사진·음성의 혼합은 다양성에 대응한다. 하나의 서비스에 세 특징이 동시에 나타날 수도 있다.

보기 판단: ①②③은 각각 기본 3V를 설명한다. ④ Availability는 필요할 때 접근하고 사용할 수 있는 가용성을 의미하지만 기본 3V의 항목은 아니다. 따라서 가용성이 중요하지 않다는 뜻이 아니라, 질문이 한정한 기본 분류에 포함되지 않는다는 이유로 ④를 선택한다.

6. 연관분석에 대한 설명으로 가장 적절하지 않은 것은?

① 상품이나 서비스를 구매하는 등 일련의 거래나 사건 안에 존재하는 항목 간의 일정한 연관 규칙을 발견하는 분석이다.

② 연관분석 중 한 종류로 장바구니 분석이 있다.

③ 연관분석은 변수 간 선형관계를 파악하는 분석 방법이다.

④ 대표적인 측정지표로 지지도, 신뢰도 및 향상도가 있다.

정답 ③

연관분석은 함께 발생하는 항목의 규칙을 찾는다. 변수 간 선형 관계의 분석과 구별한다.

연관분석은 거래 속 항목의 동시 출현을 이용하여 A→B와 같은 규칙을 찾는다. 지지도는 A와 B가 함께 포함된 거래의 비율, 신뢰도는 A가 있는 거래 중 B도 있는 비율, 향상도는 A가 있을 때의 B 발생 비율을 전체 B 발생 비율과 비교한 값이다.

보기 판단: ①은 정의, ②는 대표 활용, ④는 평가 지표로 옳다. ③의 선형관계는 피어슨 상관분석이나 선형회귀에서 다루는 내용이다. 연관규칙을 찾았다는 사실만으로 A가 B의 원인임이 증명되는 것은 아니다. 구매 순서나 인과관계와 동시 구매 규칙을 구별한다.

7. 다음 보기 중에서 빅데이터 분석 기법과 그 활용 예시가 적절하지 않은 것은?

① 군집분석 : 자동차 설계-제작을 반복하여 세대를 걸쳐 최적의 결과를 얻어낸다.

② 연관분석 : 고객의 장바구니 데이터를 분석하여 함께 구매할 가능성이 높은 상품을 찾는다.

③ 감정분석 : 고객의 리뷰를 긍정 및 부정으로 분류한다.

④ 사회관계망 분석 : SNS 내 사용자들의 상호관계를 이미지로 시각화한다.

정답 ①

세대를 반복하며 설계 조합을 개선하는 예시는 유전 알고리즘에 가깝고 군집분석이 아니다.

군집분석은 유사한 관측값을 같은 집단으로 묶는 방법이다. 유전 알고리즘은 후보 해를 만들고 선택·교차·돌연변이를 반복하여 더 좋은 해를 탐색하는 최적화 방법이다. 지문의 설계 조합을 세대별로 개선하는 예시는 후자의 특징에 가깝다.

보기 판단: ①은 군집분석과 최적화 예시를 잘못 연결했다. ②는 함께 구매되는 품목을 찾는 연관분석, ③은 리뷰의 정서를 판별하는 감정분석, ④는 사람을 노드·관계를 연결로 표현하는 사회관계망 분석과 연결된다. 감정분석은 단순 이진 분류뿐 아니라 중립이나 여러 감정을 구분하는 방식으로도 수행할 수 있다.

8. 빅데이터의 위기 요인과 해당 통제 방안에 대해 잘못 연결한 것을 모두 고르시오.

> 가. 사생활 침해 : 정보 제공자의 동의제에서 데이터 사용자의 책임제로 전환
> 나. 책임원칙 훼손 : 데이터 알고리즘 접근권 허용 및 객관적 인증방안 도입
> 다. 데이터 오용 : 결과 기반 책임 원칙 강조

① 가

② 가, 나

③ 나, 다

④ 가, 나, 다

정답 ③

알고리즘 접근과 검증은 데이터 오용 대응, 결과에 따른 책임은 책임원칙 훼손 대응이다. 따라서 나·다가 뒤바뀌었다.

가의 연결은 ADsP 교재에서 제시하는 위기 대응 관점에 따른 것이다. 데이터를 활용하는 주체에게 사용 책임을 강조하여 사생활 침해 위험을 통제한다는 취지로 이해한다. 실제 데이터 처리의 모든 동의 요건이 사라진다는 의미로 확대해서 읽지 않는다.

나·다 판단: 알고리즘의 접근·검증을 허용하고 객관적으로 인증하는 방안은 잘못된 분석이나 해석에 따른 데이터 오용 대응에 연결된다. 아직 발생하지 않은 행동을 예측만으로 제재하는 문제는 책임원칙 훼손이며 실제 결과에 근거한 책임을 강조하는 방안이 대응한다. 따라서 나와 다의 통제 방안이 서로 뒤바뀌었으므로 ③이다.

9. 아래에서 설명하는 데이터베이스 시스템은 무엇인가?

> 은행 거래, 온라인 쇼핑, 예약 등 실시간으로 발생하는 대규모 데이터 삽입, 업데이트, 삭제와 같은 짧고 빈번한 트랜잭션을 수시로 처리하는 정보 시스템

① OLAP
② **OLTP**
③ CRM
④ SCM

정답 ②

짧고 빈번한 거래를 실시간 처리하는 OLTP이다.

OLTP는 개별 업무 거래를 빠르고 일관되게 처리하는 시스템이다. 주문 등록, 결제, 계좌 이체처럼 짧고 빈번한 삽입·수정·삭제가 대표적이다. 여러 사용자가 동시에 처리하는 상황에서도 거래의 정합성을 유지하는 것이 중요하다.

보기 판단: ② OLTP가 지문의 목적과 일치한다. ① OLAP는 여러 기간·지역·상품을 집계하는 분석 질의에 초점을 둔다. ③ CRM은 고객 관계 관리, ④ SCM은 공급망 관리라는 업무 영역이다. CRM이나 SCM 내부에서 OLTP가 사용될 수 있지만 지문이 묻는 처리 방식의 명칭과는 구별해야 한다.

10. 데이터 사이언티스트에 대한 설명으로 적절하지 않은 것은?

① 데이터를 수집, 분석하여 숨겨진 패턴을 발견하고 예측 모델을 만들어 비즈니스 문제를 해결하고 새로운 가치를 창출하는 전문가이다.
② **개인 역량과 분석 능력이 최우선되며, 타인과의 의사소통 능력은 상대적으로 중요하지 않다.**
③ 통계, 프로그래밍, 머신러닝, 그리고 특정 산업 도메인 지식을 종합적으로 활용해 기업의 의사결정을 돕고 수익 증대나 비용 절감에 기여한다.
④ 문제 정의부터 모델 개발 및 배포까지 전 과정에 참여하며, AI 엔지니어 등 다른 직군과 협업하기도 한다.

정답 ②

분석 능력뿐 아니라 의사소통·협업 능력도 필요하다.

데이터 사이언티스트는 문제를 데이터 분석으로 바꾸고 결과를 업무 의사결정으로 연결한다. 따라서 통계·프로그래밍·머신러닝의 기술 역량과 함께 도메인 이해, 문제 정의, 결과 설명, 협업 역량이 필요하다. 분석 결과가 정확해도 사용자가 의미와 한계를 이해하지 못하면 활용하기 어렵다.

보기 판단: ①③④는 일반적인 역할과 협업 범위를 설명한다. ②는 의사소통의 중요성을 낮게 평가하므로 부적절하다. 업무 담당자에게 필요한 데이터를 확인하고, 개발자와 배포 조건을 조율하며, 의사결정자에게 결과의 근거를 전달하는 일도 분석 업무의 일부이다.

2과목 데이터 분석 기획 (11~20번)

11. 다음 중 분석 기획 단계에서 수행해야하는 업무로 가장 적절하지 않은 것은?

① 해결하려는 문제를 기반으로 분석 목적과 기대 효과를 명확하게 정의한다.

② 분석 정확도를 높이기 위해 최대한 복잡한 분석 모형을 설정한다.

③ 분석에 필요한 데이터의 종류와 양을 설정한다.

④ 분석 방해하는 장애 요소들에 대해 사전 계획을 수립한다.

정답 ②

기획 단계에는 목적·데이터·장애요인 검토가 필요하며 복잡도를 무조건 최대화하지 않는다.

분석 기획은 무엇을 해결할지, 어떤 성과를 기대할지, 필요한 데이터와 제약 조건이 무엇인지를 정하는 단계이다. 데이터 확보 가능성, 품질, 일정, 활용 방식 등을 검토한 뒤 문제에 맞는 분석 방법을 선정한다. 모형의 복잡성 자체는 성과 지표가 아니다.
보기 판단: ①은 목적과 기대 효과, ③은 데이터 요건, ④는 예상 장애에 대한 계획이므로 적절하다. ②는 복잡할수록 정확하다고 전제하지만 복잡한 모형은 과적합·설명 어려움·운영 비용을 증가시킬 수 있다. 단순한 기준 모형과 비교하고 검증 자료에서 목적에 맞는 성능을 평가해야 한다.

12. 다음 중 데이터 형태에 대한 설명으로 적절하지 않은 것은?

① 정형 데이터는 행/열로 구성된 스프레드시트 형태로 나타낼 수 있다.

② IoT 기기에서 생성되는 모든 로그 데이터는 정형 데이터이다.

③ 반정형 데이터는 메타정보나 태그 등으로 구조를 표현하지만 고정된 표 형태를 반드시 따르지는 않는다.

④ 대표적인 반정형 데이터로는 HTML, XML, JSON 등 웹 기반 데이터가 있다.

정답 ②

로그의 형식은 구현에 따라 달라진다. IoT에서 생성되는 모든 로그를 정형 데이터로 단정할 수 없다.

정형 데이터는 정해진 스키마와 필드에 맞춰 표 형태로 관리하기 쉽다. 반정형 데이터는 키·태그·계층 등 구조 정보가 있지만 모든 기록이 동일한 고정 열을 가져야 하는 것은 아니다. 비정형 데이터는 자유로운 문장·이미지·음성처럼 표 구조로 직접 표현하기 어려운 내용이다.
보기 판단: ①③④는 통상적인 분류 설명으로 적절하다. ②는 생성 장치만으로 데이터 형태를 단정한 오류이다. 같은 IoT 장치도 고정 열 CSV, JSON 메시지, 자유 형식 문자열을 출력할 수 있다. 분류는 IoT라는 출처 이름보다 실제 저장 형식과 구조를 보고 판단한다.

13. 다음 중 데이터 탐색 과정 단계에 대한 설명으로 적절하지 않은 것은?

① 구체적인 문제 해결 방안을 체계적으로 설계한다.

② 탐색 단계 결과를 통해 분석 방향과 방법을 구체화할 수 있다.

③ 외부에서 적절한 참조 모델을 통해 보다 분석 속도를 향상시킬 수 있다.

④ 분석 대상 데이터의 특성을 검토하고 주요 변수의 의미를 파악한다.

정답 ①

탐색은 데이터 특성과 분석 방향을 이해하는 단계이다. 상세 해결 방안의 설계와 구별한다.

탐색 단계에서는 데이터가 무엇을 의미하고 어떤 분석이 가능한지 파악한다. 변수 정의·분포·결측·이상치·관계를 확인하고 기존 사례나 참조 모델을 통해 분석 방향을 좁힐 수 있다. 이때 얻은 이해는 이후 분석 방법을 결정하는 근거가 된다.
보기 판단: ②④는 탐색의 직접적인 결과와 활동이고, ③은 적절한 참조 모델을 활용하여 탐색을 돕는 취지이다. ①의 구체적인 해결 방안을 체계적으로 설계하는 일은 상세한 설계 성격이 강하다. 다만 탐색과 설계가 완전히 단절되는 것은 아니며, 이 문항은 단계별 주된 목적의 차이를 묻는다.

14. 분석 과제 발굴 시 분석 대상은 명확하나 분석 방법은 모르는 경우 해당되는 분석주제는?

① 솔루션

② 통찰

③ 최적화

④ 발견

정답 ①

대상은 알고 방법을 모르는 경우 솔루션이다. 통찰은 대상을 모르고 방법을 아는 경우이다.

분석 대상과 방법의 인지 여부를 두 축으로 구분한다. 대상·방법을 모두 알면 최적화, 대상은 알지만 방법을 모르면 솔루션, 대상은 모르지만 방법을 알면 통찰, 둘 다 모르면 발견이다. 여기서 대상을 안다는 말은 해결하려는 업무 문제와 분석 목표가 구체적이라는 뜻이다.
보기 판단: ①이 대상은 명확하고 방법은 미정인 조건에 해당한다. ② 통찰은 적용할 분석 방법은 있지만 어디서 가치 있는 문제를 찾을지 탐색하는 경우, ③ 최적화는 기존 문제와 방법의 개선, ④ 발견은 문제와 방법을 함께 탐색하는 경우이다. 예를 들어 이탈 고객을 줄이는 목표는 정했지만 적절한 예측·실험 방법을 아직 선정하지 않았다면 솔루션 유형으로 볼 수 있다.

15. 상향식 접근 방식에 대한 설명으로 적절하지 않은 것은?

① 반복적 시행착오를 통한 문제 도출하는 프로토타이핑 접근 방식을 사용한다.

② 제시된 문제가 확실한 경우 체계적인 단계화로 문제 해결하는 방식이다.

③ 분석 주제 유형이 '통찰' 및 '발견'일 때 사용되는 방식이다.

④ 비지도 학습과 유사한 탐색적 분석 방식이다.

정답 ②

명확하게 정의된 문제에서 해결책을 찾는 체계적 절차는 하향식 접근의 특징이다.

상향식 접근은 데이터와 현상을 탐색하며 가치 있는 문제와 가설을 찾아가는 방식이다. 처음부터 목표가 완전히 정해져 있지 않을 수 있어 프로토타입을 만들고 결과를 살펴보며 반복적으로 과제를 구체화한다. 통찰·발견 유형과 연결해 이해할 수 있다.
보기 판단: ①③④는 탐색과 반복이라는 특징을 설명한다. ②는 이미 명확한 문제에서 출발해 단계적으로 해결책을 도출하는 하향식 접근에 가깝다. 비지도학습은 상향식 접근을 설명하는 유용한 비유이지만 상향식 프로젝트에서 지도학습을 절대 사용할 수 없다는 뜻은 아니다.

16. 분석 마스터 플랜 수립 시 우선 고려사항을 모두 고르시오.

가. 전략적 중요도
나. 비즈니스 성과
다. 실행 용이성

① 가

② 가, 나

③ 나, 다

④ 가, 나, 다

정답 ④

전략적 중요도, 비즈니스 성과, 실행 용이성을 모두 고려한다.

전략적 중요도는 조직의 목표와 얼마나 연결되는지, 비즈니스 성과는 매출·비용·위험·고객 경험 개선에 어떤 효과가 있는지, 실행 용이성은 데이터·기술·인력·일정 측면에서 실제 추진할 수 있는지를 평가하는 기준이다. 마스터 플랜은 과제 하나가 아니라 여러 과제의 우선순위와 추진 로드맵을 다룬다.
보기 판단: 가치만 크고 실행이 어려운 과제나 쉽게 구현되지만 효과가 작은 과제만을 우선할 수는 없다. 가·나·다를 함께 고려해야 하므로 ④이다. 조직 상황에 따라 가중치는 달라질 수 있으며, 세 기준을 고려한다는 말이 항상 동일 비중으로 점수를 주라는 뜻은 아니다.

17. 아래 설명에 해당되는 분석 성숙도 단계는 무엇인가?

분석이 막 시작되는 단계로 일부 부서에서만 분석이 활용되고 있으며 분석 가능한 환경과 기반 및 시스템을 구축하기 시작하는 단계이다.

① 도입

② 활용

③ 확산

④ 최적화

정답 ①

분석이 막 시작되어 일부 부서에서만 활용되고 분석 기반을 구축하기 시작하는 단계는 분석 성숙도의 도입 단계이다.

분석 성숙도는 조직이 실제 분석을 어느 수준까지 수행·활용하는지를 본다. 도입은 환경과 기반을 마련하며 일부 분석을 시작하는 단계, 활용은 업무에 분석을 적용하는 단계, 확산은 활용이 조직 전반으로 넓어지는 단계, 최적화는 분석을 지속적으로 개선하고 의사결정에 깊이 연결하는 단계이다.
보기 판단: 기반과 시스템 구축을 시작하고 일부 부서에서만 활용한다는 문구는 ① 도입에 대응한다. ②③④는 활용 범위와 정착 수준이 더 높다. 준비도는 수행할 기반의 확보 정도이며 성숙도와 다른 축이다. 준비도가 높고 성숙도가 낮다는 유형 문제의 답을 이 문항의 단계 답과 혼합해서는 안 된다.

18. 분석 업무를 별도의 전담 조직에서 담당하여 회사 차원의 우선순위에 따라 일괄 수행하는 분석 조직 유형은 무엇인가?

① 분산형 조직

② 협업형 조직

③ 집중형 조직

④ 기능 중심형 조직

정답 ③

회사 차원의 우선순위에 따라 전담 조직이 수행하면 집중형이다.

집중형은 중앙의 전담 분석 조직이 과제를 모아 회사 전체의 우선순위에 따라 수행하는 형태이다. 인력·방법·도구를 공유하고 표준을 일관되게 적용하는 데 유리하지만 현업 요구를 충분히 이해하도록 소통해야 한다.
보기 판단: ③이 지문의 전담 조직과 전사 우선순위에 일치한다. 기능 중심형은 각 업무 부서에서 분석을 수행하는 형태, 분산형은 분석 인력을 업무 조직에 배치해 현업과 가까이 일하는 형태로 구분한다. ② 협업형이라는 표현만으로는 지문의 중앙 전담 구조를 정확히 가리키지 못한다. 조직의 명칭보다 분석 인력의 소속과 과제 배정 방식이 판단 기준이다.

19. 데이터 거버넌스에 대한 설명으로 적절하지 않은 것은?

① 조직의 데이터를 안전하고 정확하며 신뢰할 수 있도록 관리하기 위한 정책, 프로세스, 표준, 역할, 기술을 정의하고 실행하는 체계적인 접근 방식이다.

② 구성 요소로는 원칙, 조직, 프로세스가 있다.

③ 데이터 표준용어 설정, 명명 규칙 수립 등 데이터 표준화 작업이 필요하다.

④ 데이터거버넌스는 전담 조직에서 독립적으로 운영되어야 한다.

정답 ④

데이터 거버넌스는 업무·IT·전담 조직 간 협업이 필요하다. 독립 운영을 단정한 ④가 부적절하다.

데이터 거버넌스는 누가 어떤 기준과 책임으로 데이터를 관리하고 활용할지를 정하는 체계이다. 원칙은 정책·표준, 조직은 역할과 책임, 프로세스는 실행 절차와 점검 방법에 대응한다. 용어·코드·명명 규칙을 통일하는 표준화도 핵심 활동이다.
보기 판단: ①②③은 체계와 구성 요소를 적절히 설명한다. ④는 전담 조직이 현업과 IT에서 분리되어 독립적으로 운영되어야 한다고 단정한다. 데이터의 의미는 현업이, 시스템 구현은 IT가, 정책과 조율은 전담 조직이 담당하는 등 협업이 필요하다. 전담 조직을 둔다는 것과 다른 부서의 참여 없이 운영한다는 것은 다르다.

20. 분석 준비도 평가 요소로 적절하지 않는 것은?

① 분석 업무에 투입 가능한 인력 및 조직

② 분석에 사용할 분석 기법

③ 분석에 활용할 데이터

④ 분석에 필요한 비용 및 예산

정답 ④

준비도의 대표 진단 영역과 비용·예산 계획을 구별한다. 인력·기법·데이터는 진단에 포함된다.

ADsP의 대표적인 분석 준비도 진단 영역은 분석 업무, 인력 및 조직, 분석 기법, 분석 데이터, 분석 문화, IT 인프라이다. 어떤 업무를 분석할 수 있는지, 수행 인력과 데이터·도구가 있는지, 조직이 결과를 활용할 준비가 되어 있는지를 살펴본다.
보기 판단: ①은 인력 및 조직, ②는 분석 기법, ③은 분석 데이터에 대응한다. ④는 위 대표 진단 영역의 명칭에 해당하지 않아 답이 된다. 비용과 예산이 프로젝트에서 중요하지 않다는 뜻은 아니다. 이 문제는 준비도 평가의 교재상 영역과 일반적인 자원·예산 계획을 구분하는 문제이다.

3과목 데이터 분석 (21~50번)

21. 절대적 기준인 영점(0)이 존재하는 척도는?

① 명목척도
② 서열척도
③ 등간척도
④ 비율척도

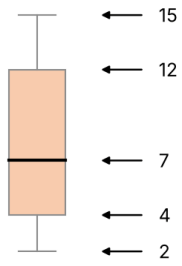
정답 ④
비율척도는 절대 영점이 있고 값의 비율이 의미를 갖는다.
명목척도는 혈액형처럼 분류만 가능하고, 서열척도는 만족도 등 순서를 표현하지만 간격이 동일하다고 보장하지 않는다. 등간척도는 간격 비교가 가능하지만 절대 영점이 없으며, 비율척도는 간격과 비율 모두 의미가 있고 절대 영점을 가진다.
보기 판단: ④가 정답이다. 길이·질량처럼 0이 해당 양의 부재를 뜻하면 20은 10의 두 배라고 말할 수 있다. 섭씨 0도는 온도의 부재가 아니므로 섭씨 20도가 10도보다 두 배 뜨겁다고 해석하지 않는다. 숫자로 표현되었다는 이유만으로 모두 비율척도가 되는 것은 아니다.

22. 다음 중 탐색적 데이터 분석(EDA)의 특징으로 적절하지 않은 것은?

① 데이터의 전반적인 구조를 파악하고 이상치 및 결측치를 발견하는 단계이다.
② 동일한 분석 결과를 얻기 위해 재현성을 검증하는 단계이다.
③ 상관관계 분석 및 시각화를 통해 종속변수에 영향을 주는 주요 독립변수를 탐색한다.
④ 변수의 개수, 데이터 타입 및 기초 통계량(평균, 중앙값)을 확인하는 단계이다.

정답 ②
EDA는 구조와 이상치·결측치 탐색이 중심이다. 재현성 검증 자체를 EDA의 주목적으로 볼 수는 없다.
EDA는 분석 전에 데이터의 특성과 문제를 파악하는 탐색 과정이다. 행·열 수, 자료형, 기초 통계량을 확인하고 시각화로 분포·관계·이상치·결측 패턴을 살핀다. 설명변수와 목표값 사이의 관련성을 탐색할 수 있지만 탐색만으로 인과관계를 확정하지 않는다.
보기 판단: ①③④는 EDA의 주요 활동이다. ②는 분석 절차와 환경을 다시 실행했을 때 결과가 재현되는지 확인하는 작업으로, EDA의 대표 목적과 다르다. EDA 코드도 재현 가능하게 작성하는 것이 바람직하지만 재현성 검증 자체를 EDA의 정의로 선택하면 안 된다.

23. 아래 Box Plot을 참고하여 이상치를 판단하는 하한과 상한의 값은?



① -4, 20
② -4, 24
③ -8, 20
④ -8, 24

정답 ④
$Q_1 = 4$, $Q_3 = 12$이므로 $IQR = 8$이다. 하한은 $4 - 1.5 \times 8 = -8$, 상한은 $12 + 1.5 \times 8 = 24$이다. 이 값은 이상치 판정 경계이며 관측 최솟값·최댓값이 아니다.
계산 순서: 1단계에서 상자의 아래 경계 $Q_1 = 4$와 위 경계 $Q_3 = 12$를 읽는다. 2단계에서 $IQR = Q_3 - Q_1 = 12 - 4 = 8$을 구한다. 3단계에서 $1.5 \times IQR = 12$를 계산한다. 4단계에서 하한 $= 4 - 12 = -8$, 상한 $= 12 + 12 = 24$를 얻으므로 ④이다.
오답 구분: ①②③은 하한 또는 상한을 잘못 계산한 조합이다. 두 경계는 이상치 후보를 정하는 울타리이며 실제 관측값의 최소·최대나 수염 끝과 같다고 할 수 없다. 일반적으로 −8 미만 또는 24 초과인 관측값을 이 규칙의 이상치 후보로 본다. 경계와 같은 값은 이 규칙에서 경계를 벗어난 값이 아니다.

24. 다음 중 가설검정의 제 1종 및 2종 오류 해석에 대한 설명으로 적절하지 않은 것은?

① 제 1종 오류는 귀무가설이 실제로는 참인데도 불구하고, 이를 기각하고 대립가설을 채택하는 오류이다.
② 제 2종 오류는 실제로는 대립가설이 참인데도 불구하고, 귀무가설을 기각하지 못하는 통계적 오류이다.
③ 유의수준(α)은 제 1종 오류의 최소 허용 한계이다.
④ 유의수준을 너무 작게 설정하면 2종 오류를 범할 확률이 높아진다.

정답 ③
유의수준은 제1종 오류 확률의 허용 상한이다. ③의 최소 허용이라는 표현이 틀리다. 제2종 오류는 귀무가설을 기각하지 못하는 오류이다.
제1종 오류는 참인 귀무가설을 기각하는 오류이고 그 확률을 α로 나타낸다. 제2종 오류는 실제 대립가설이 성립하는 상황에서 귀무가설을 기각하지 못하는 오류이며 확률을 β로 나타낸다. 검정력은 $1 - \beta$이다.
보기 판단: ①②는 두 오류의 정의이다. ③은 최소 허용 한계라는 표현이 틀렸으며 유의수준은 제1종 오류 확률의 허용 상한으로 이해한다. ④는 표본 크기·효과 크기·검정 방식 등 다른 조건을 고정했을 때 기각 기준을 엄격하게 하면 제2종 오류가 커질 수 있다는 뜻이다. 유의수준을 낮추면 모든 종류의 오류가 동시에 줄어드는 것은 아니다.

25. 다음 중 표본 조사에 대한 설명으로 적절하지 않은 것은?

① 표본 오차는 표본이 모집단을 완벽히 대표하지 못해 생기는 오차이다.

② 적절한 확률표집에서 다른 조건이 같으면 표본 크기 증가로 표본 오차가 대체로 감소한다.

③ 표본추출을 통해 비표본 오차를 최소화할 수 있다.

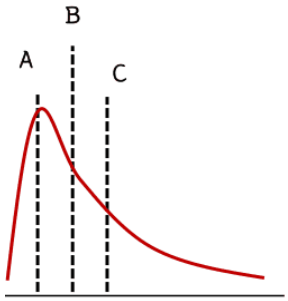
④ 비표본 오차는 표본의 크기나 추출 방법에 관계없이 발생가능하다.

정답 ③

비표본 오차는 측정·응답·누락·처리 과정에서도 생긴다. 표본추출 자체만으로 이를 최소화한다고 할 수 없다. 표본 확대 효과에는 적절한 추출 등의 조건이 필요하다.

표본 오차는 모집단의 일부만 조사하므로 표본마다 통계량이 달라지는 변동을 뜻한다. 비표본 오차는 설문 문구의 모호함, 응답 누락, 거짓 응답, 측정기 오류, 자료 입력·처리 오류 등에서 발생한다. 전수조사에서도 비표본 오차는 생길 수 있다.
보기 판단: ①은 표본 변동에 대한 설명이고 ②는 적절한 확률표집에서의 일반적 효과이다. ④는 표본 크기만으로 비표본 오차가 없어지지 않는다는 취지이다. ③처럼 표본을 추출했다는 사실만으로 비표본 오차가 최소화되지는 않는다. 표본 확대와 함께 측정·응답·처리의 품질을 별도로 관리해야 한다.

26. 다음 오른쪽 꼬리 분포에서 A, B, C에 해당되는 통계량은?



① A: 최빈값 / B: 평균 / C: 중앙값

② A: 최빈값 / B: 중앙값 / C: 평균

③ A: 평균 / B: 중앙값 / C: 최빈값

④ A: 중앙값 / B: 최빈값 / C: 평균

정답 ②

그림과 같은 전형적 단봉 오른쪽 꼬리 분포에서는 최빈값 < 중앙값 < 평균이다.

오른쪽 긴 꼬리에 있는 큰 값들은 평균을 오른쪽으로 끌어당긴다. 중앙값은 관측값의 순서상 가운데이므로 극단적인 큰 값의 크기에 평균보다 덜 민감하다. 최빈값은 분포에서 가장 자주 나타나는 위치에 해당한다.
그림 판단: 제시된 전형적인 단봉 오른쪽 꼬리 그림에서 왼쪽부터 A=최빈값, B=중앙값, C=평균이므로 ②이다. ①은 중앙값·평균의 위치를 바꾸고 ③④는 최빈값 위치를 맞추지 못했다. 이 순서는 해당 그림의 전형적 형태를 해석하는 규칙이며 모든 임의 분포에 예외 없이 성립하는 정리로 일반화하지 않는다.

27. 표본추출방법에 대한 설명으로 적절하지 않은 것은?

① 단순무작위추출법 : 표본 선택 확률을 모두 동일하게 무작위로 표본을 추출한다.

② 계통추출법 : 일련번호를 부여한 각 개체를 일정한 간격으로 나누고 각 구간에서 무작위 추출하는 방법이다.

③ 집락추출법 : 모집단을 여러 집락으로 나눈 뒤 일부 집락을 무작위로 선택하여 해당 집락의 구성원 전체를 조사한다.

④ 층화추출법 : 모집단을 서로 중복되지 않는 집단 및 층(strata)으로 구분하고 각 집단 내에서 표본을 무작위 추출한다.

정답 ②

계통추출은 임의 시작점을 정한 후 일정 간격마다 선택한다. 각 구간에서 별도로 무작위 추출한다는 설명은 표준 계통추출과 다르다.

계통추출은 시작점을 한 번 무작위로 정한 뒤 일정한 간격 k마다 선택한다. 예를 들어 1,000명 중 100명을 뽑을 때 간격 10으로 정하고 시작점이 7이면 7·17·27번처럼 선택한다. 매 구간마다 새 시작점을 무작위로 뽑는 설명과 다르다.
보기 판단: ②가 잘못된 설명이다. ① 단순무작위추출은 무작위로 표본을 선정한다. ③은 일부 집락을 뽑아 그 구성원 전체를 조사하는 1단계 집락추출의 예이다. ④ 층화추출은 모든 층에서 표본을 추출한다. 층화는 각 층을 대표하게 하는 것이 중요하고, 집락은 선택한 집락이 조사 단위가 된다는 차이를 기억한다.

28. 다음 중 통계적 유의성에 대한 설명으로 적절하지 않은 것은?

① 표본의 크기가 커질수록 표준 오차가 작아지므로, 신뢰구간의 길이는 점점 짧아진다.

② p-value가 클수록 귀무가설을 기각하고 대립가설을 채택할 확률이 높아진다.

③ 표본의 크기가 커질수록 아주 작은 차이도 통계적으로 유의미하게 나타날 가능성이 높아진다.

④ 신뢰수준을 95%에서 99%로 높이면 신뢰구간의 폭은 더 넓어지고, 정밀도는 떨어진다.

정답 ②

작은 p값일수록 귀무가설에 불리하다. p값은 귀무가설이 참일 확률이나 기각할 확률이 아니다.

p값은 귀무가설과 검정의 가정을 전제로 현재 결과 이상으로 극단적인 통계량이 나올 확률이다. $p \le \alpha$이면 귀무가설을 기각하는 판단 규칙을 사용한다. 따라서 p값이 커질수록 기각 가능성이 높다는 ②는 방향부터 잘못되었다. p값은 귀무가설이 참일 확률이 아니다.
나머지 보기: 다른 조건이 같을 때 표준오차는 대체로 표본 크기의 제곱근에 반비례하므로 ①은 신뢰구간 축소를 설명한다. ③은 큰 표본에서 작은 효과도 유의할 수 있다는 뜻이다. ④는 99% 구간이 95% 구간보다 넓다는 설명이다. 통계적 유의성과 실제 업무상 중요한 효과 크기는 함께 판단해야 한다.

29. 아래는 어느 학급의 수학 점수를 나타낸 상자그림(Boxplot)이다. 해석으로 옳지 않은 것은?

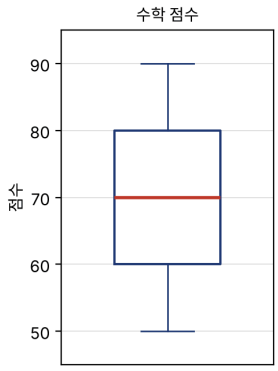


그림 정보: $Q_1 = 60$점, 중앙값 $= 70$점, $Q_3 = 80$점.

① 점수의 중앙값은 70점이다.
② 사분위수 범위(IQR)는 20점이다.
③ 전체 학생의 약 50%가 60점과 80점 사이에 있다.
④ 학생들의 평균 점수는 70점이다.

정답 ④
상자그림은 중앙값과 사분위수를 보여 줄 뿐 평균은 표시하지 않으므로, 평균이 70점이라고 단정한 ④가 틀렸다.
상자 안의 선이 중앙값(Q_2), 상자의 아래·위 경계가 Q_1·Q_3이다. 그림에서 $Q_1 = 60$, 중앙값 $= 70$, $Q_3 = 80$이므로 $IQR = 80 - 60 = 20$이고, 가운데 약 50%의 학생이 60~80점 사이에 있다.
보기 판단: ①②③은 그림에서 바로 읽을 수 있는 값이다. ④의 평균은 상자그림의 구성 요소가 아니며, 분포가 비대칭이면 중앙값과 평균이 달라질 수 있으므로 그림만으로 70점이라고 할 수 없다.

30. 다음은 주성분 분석(PCA) 결과 각 주성분의 분산 설명 비율이다. 누적 분산 비율이 80% 이상이 되도록 할 때 선택해야 할 최소 주성분의 수는?

분산 설명 비율: PC1 0.45, PC2 0.25, PC3 0.15, PC4 0.10, PC5 0.05

① 2
② 3
③ 4
④ 5

정답 ②
누적 분산 비율은 PC1 0.45, PC2까지 0.70, PC3까지 0.85이므로 처음으로 80%를 넘는 PC3까지, 즉 3개가 필요하다.
누적 설명 비율은 앞에서부터 분산 설명 비율을 더한 값이다. 0.45 → 0.70 → 0.85 → 0.95 → 1.00이므로 0.80 이상이 되는 최소 개수는 3개이다.
보기 판단: ① 2개는 누적 70%로 기준에 못 미치고, ③④는 기준을 만족하지만 최소 개수가 아니다.

31. 단순회귀모형에서 SSE가 20이고 샘플이 10이라면 MSE는 얼마인가?

① 2
② 2.22
③ 2.5
④ 30

정답 ③
절편을 포함하는 단순회귀의 잔차 자유도는 $n - 2 = 8$이다. $MSE = 20/8 = 2.5$이다. 일반적인 예측오차 평균 SSE/n과 구별한다.
회귀분석 분산분석표의 MSE는 잔차제곱합을 잔차 자유도로 나눈 값이다. 절편과 기울기 하나를 추정하는 단순회귀에서는 모수 2개를 추정하므로 잔차 자유도가 n−2이다. 여기서는 $n = 10$이므로 자유도 $= 8$, $MSE = \frac{SSE}{n-2} = \frac{20}{8} = 2.5$로 ③이다.
오답 판단: ①의 2는 $20/10$으로 관측 개수만 나눈 값이다. ②의 약 2.22는 $20/9$로 자유도 하나만 차감한 값이다. ④의 30은 제시된 공식과 맞지 않는다. 예측 성능 지표로 쓰는 평균제곱오차 SSE/n과 회귀 분산분석표의 잔차 평균제곱을 문맥에 따라 구별해야 한다.

32. 다중회귀분석에서 다중공선성을 해결할 수 있는 방안으로 적절하지 않은 것은?

① 라쏘 회귀 (Lasso)
② 릿지 회귀 (Ridge)
③ 엘라스틱넷 회귀 (Elastic Net)
④ 로지스틱 회귀 (Logistic)

정답 ④
라쏘·릿지·엘라스틱넷은 규제 방법이다. 로지스틱 회귀로 바꾸는 것만으로 다중공선성이 해결되지는 않는다.
규제 회귀는 계수 크기에 벌점을 부여하여 높은 설명변수 상관으로 인한 불안정성을 완화한다. 릿지는 L2 벌점으로 계수를 축소하고, 라쏘는 L1 벌점으로 일부 계수를 0으로 만들 수 있다. 엘라스틱넷은 L1·L2 벌점을 결합한다.
보기 판단: ①②③은 공선성의 영향을 완화하는 방법으로 사용할 수 있다. ④ 로지스틱 회귀는 범주형 결과의 확률을 모델링하는 방법이며 설명변수 사이의 상관을 자동으로 제거하지 않는다. 규제 없는 로지스틱 회귀에도 공선성 문제가 생길 수 있다. 라쏘 역시 강하게 상관된 변수 중 선택이 불안정할 수 있어 규제를 만능 해결책으로 단정하지 않는다.

33. 다중회귀분석에서 다중공선성에 대한 설명으로 적절하지 않은 것은?

① 다중공선성이 존재하더라도 회귀계수의 분산은 항상 동일하다.

② 독립변수 간 높은 상관관계로 회귀계수 추정이 불안정해진다.

③ 다중공선성은 VIF 지표로 측정 가능하다.

④ 높은 상관관계를 갖는 설명변수를 모형에서 제거하여 해결 가능하다.

정답 ①

높은 설명변수 상관은 계수 추정의 분산을 증가시키고 추정을 불안정하게 할 수 있다.

다중공선성은 설명변수 하나의 정보를 다른 설명변수들의 조합으로 상당 부분 설명할 수 있는 상황이다. 독립적인 정보가 적어 계수의 표준오차가 커지고 작은 자료 변화에도 계수 크기·부호가 달라질 수 있다. 완전 공선성에서는 일반적인 최소제곱 계수를 유일하게 정할 수 없다.

보기 판단: ①의 분산이 항상 동일하다는 주장은 틀리다. ②는 추정 불안정성, ③은 진단 지표, ④는 가능한 개선 방안이다. $VIF_j = \frac{1}{1-R_j^2}$이며 R_j^2는 해당 설명변수를 나머지 설명변수로 회귀한 결정계수이다. 제거할 변수는 상관만 보고 결정하지 않고 업무 의미와 정보 손실을 함께 고려한다.

34. 다음은 사립학교와 공립학교 학생의 시험 점수 차이를 비교하기 위해 R에서 독립표본 t-검정을 수행한 결과이다. 해석으로 옳지 않은 것은?

결과 요약: p-value = 0.031, 표본평균 사립 74.3점 · 공립 70.0점, 평균 차이(사립 − 공립)의 95% 신뢰구간 [0.42, 8.18]

① 유의수준 0.05에서 두 집단의 평균 점수 차이는 통계적으로 유의하다.

② 사립학교 표본의 평균 점수가 공립학교보다 4.3점 높다.

③ 평균 차이의 95% 신뢰구간은 0을 포함하지 않는다.

④ 유의수준 0.01에서도 귀무가설을 기각할 수 있다.

정답 ④

p-value 0.031은 0.05보다 작지만 0.01보다 크므로, 유의수준 1%에서는 귀무가설을 기각할 수 없다. 따라서 ④가 틀렸다.

독립표본 t-검정의 귀무가설은 두 집단의 평균이 같다는 것이다. $p = 0.031 < 0.05$이므로 5% 수준에서는 차이가 유의하고, 95% 신뢰구간 [0.42, 8.18]이 0을 포함하지 않는 것도 같은 결론이다. 표본평균 차이는 $74.3 - 70.0 = 4.3$점이다.

보기 판단: ①②③은 제시된 결과와 일치한다. ④는 $0.031 > 0.01$이므로 틀렸다. 유의수준을 낮추면 기각 기준이 엄격해지고, 99% 신뢰구간은 95% 구간보다 넓어 0을 포함할 수 있다.

35. mpg를 종속변수, hp·drat·wt를 설명변수로 회귀분석했다. drat의 p값은 0.05보다 크다. 다음 중 부적절한 것은?

① mpg를 hp·drat·wt로 설명하는 다중회귀모형이다.

② 현재 모형에서 drat 계수는 유의수준 5%에서 유의하지 않다.

③ drat을 제외할 때 절편·hp·wt의 기존 계수를 그대로 가져와 새 회귀식으로 확정한다.

④ drat을 제외한 모형을 사용하려면 다시 적합하고 새 계수를 확인해야 한다.

정답 ③

drat의 p값이 0.05보다 크다는 사실과 그 변수를 제외한 새 모형의 계수는 별개이다. 변수 삭제 후 다시 적합해야 한다. 기존 절편·hp·wt 계수를 그대로 사용하는 ③은 틀리다.

p값이 0.05보다 크면 현재 모형과 가정 아래에서 drat의 계수가 0과 다르다는 근거가 유의수준 5%에 충분하지 않다는 뜻이다. drat이 현실적으로 아무 영향도 없다는 증명이나 반드시 삭제하라는 명령은 아니다. 변수 선정은 목적·도메인·검증 성능 등을 함께 고려한다.

보기 판단: ①은 변수의 역할, ②는 현재 모형의 검정 판단, ④는 새 모형의 적합 절차로 옳다. ③은 변수 제거 후에도 기존 계수를 그대로 쓸 수 있다고 하여 틀리다. 최소제곱법은 포함된 변수 전체를 함께 사용해 계수를 추정하므로 drat을 빼면 hp·wt와 절편의 최적 값도 달라질 수 있다. 아래 재계산 예시에서 wt 계수와 절편이 실제로 바뀐다는 점을 확인한다.

검증 예시: R의 mtcars 32개 관측값에 절편을 포함한 최소제곱법 적용. mpg~hp+drat+wt의 계수는 절편 29.394934, hp −0.032230, drat 1.615049, wt −3.227954이며 drat p값 ≈0.198755이다. drat 삭제 후 mpg~hp+wt를 재적합하면 절편 37.227270, hp −0.031773, wt −3.877831로 바뀐다.

36. 다음 중 시계열 분석에 대한 설명으로 적절하지 않은 것은?

① 비정상 시계열인 경우 차분 및 변환을 통해 정상성을 확보할 수 있다.

② 정상 시계열인 경우 자기회귀(AR) 또는 이동평균(MA) 모형을 적용할 수 있다.

③ 백색잡음(White noise)은 대표적인 비정상 시계열이다.

④ 정상성 확보를 위해 평균이 일정하지 않으면 차분을, 분산이 일정하지 않으면 변환이 사용된다.

정답 ③

백색잡음은 평균·분산이 일정하고 서로 다른 시점의 공분산이 0인 대표적 약정상 과정이다.

약정상 시계열은 평균·분산이 시점에 따라 바뀌지 않고 공분산은 두 시점 사이의 간격에만 의존한다. 백색잡음은 평균 0, 일정한 유한 분산, 다른 시점 사이의 공분산 0을 갖는 대표적 약정상 과정이다. 예측할 일정한 추세가 없다는 것과 비정상이라는 것은 다르다.

보기 판단: ③이 잘못된 설명이다. ①④의 차분은 추세 등에 따른 평균 변화, 로그 등 변환은 분산 변화의 완화에 사용될 수 있다. 이러한 처리로 모든 비정상성이 반드시 해결되는 것은 아니며 처리 후 다시 점검한다. ②의 AR·MA도 정상성·모형 조건을 만족하는 형태를 적용한다는 취지로 읽는다.

37. 다음 중 변수 간의 단조적 비선형 관계를 파악하기에 적절한 지표는?

① 피어슨 상관계수
② 스피어만 상관계수
③ 코사인 유사도
④ 자카드 계수

정답 ②
스피어만은 순위에 기초한 단조 관계의 지표이다.
스피어만 상관계수는 원래 관측값을 순위로 바꾼 뒤 그 순위 사이의 상관을 계산한다. 한 변수가 증가할 때 다른 변수도 계속 증가하거나 계속 감소하는 단조 관계를 포착하므로 관계가 곡선이어도 순서가 유지된다면 적절하다.
보기 판단: ②가 정답이다. ① 피어슨은 선형관계의 크기와 방향에 초점을 둔다. ③ 코사인 유사도는 벡터의 방향 유사성, ④ 자카드는 집합의 교집합/합집합 비율이다. U자 관계처럼 증가·감소가 함께 나타나는 비단조 관계에서는 스피어만이 0에 가까워도 관계가 없다고 결론 내릴 수 없다.

38. 다음 중 ARIMA 모델에 대한 설명으로 적절하지 않은 것은?

① ARIMA (p, d, q) 형태로 표현되며 p, d, q는 각각 자기회귀 차수, 차분 차수, 이동평균 차수를 의미한다.
② 일반적으로 자기회귀 차수를 먼저 정하고, 차분 차수를 정한다.
③ 시계열 데이터의 과거 값과 오차를 이용해 미래를 예측하는 통계 모델이다.
④ 데이터를 정상 시계열로 변환하여 분석하므로 통계적 안정성이 높다.

정답 ②
통상 정상성 검토와 차분 차수 d 설정 후 ACF·PACF 등을 보고 p·q를 정한다.
ARIMA의 p는 자기회귀 차수, d는 차분 횟수, q는 이동평균 오차항 차수이다. 일반적인 절차는 시계열을 살펴 정상성을 검토하고 필요한 차분을 결정한 뒤, 차분된 자료의 ACF·PACF와 모형 비교·잔차 진단을 통해 p·q를 선정하는 것이다.
보기 판단: ①③은 정의와 예측 원리를 설명한다. ②는 자기회귀 차수를 먼저 정하는 것을 일반적인 순서로 제시하여 부적절하다. ④는 필요한 정상화 후 모델링한다는 취지로 제한해 읽는다. 차분한다고 예측 안정성이나 정확성이 자동 보장되지는 않으며 과차분, 구조 변화, 계절성도 점검해야 한다. 실무의 자동 모형 선정에서는 여러 차수를 함께 탐색할 수도 있다.

39. 다음은 신용카드 부채(Balance)를 종속변수로 하고 수입(Income)과 학생 여부(Student: 학생 = Yes)를 독립변수로 한 다중회귀분석 결과이다. 해석으로 옳지 않은 것은?

> 분석: lm(Balance ~ Income + Student, data = Credit)
> (Intercept): Estimate 211.1430, Std. Error 32.4572, t value 6.505, Pr(>|t|) 2.34×10^{-10}
> Income: Estimate 5.9843, Std. Error 0.5566, t value 10.751, Pr(>|t|) 7.82×10^{-24}
> StudentYes: Estimate 382.6705, Std. Error 65.3108, t value 5.859, Pr(>|t|) 9.78×10^{-9}
> R^2 = 0.2775, Adjusted R^2 = 0.2738

① 다른 변수가 같을 때 Income이 1 증가하면 Balance는 평균적으로 약 5.98 증가한다.
② 다른 변수가 같을 때 학생은 비학생에 비해 Balance가 평균적으로 약 382.67 높다.
③ Student 변수는 더미변수로 처리되어 기준 범주(비학생) 대비 효과를 나타낸다.
④ StudentYes의 회귀계수가 Income보다 크므로 Student가 Balance에 가장 중요한 변수이다.

정답 ④
회귀계수의 크기는 변수의 측정 단위에 따라 달라지므로, 계수가 크다는 이유만으로 더 중요한 변수라고 판단한 ④가 틀렸다.
Income 계수 5.9843은 다른 변수가 같을 때 Income 1단위(이 데이터에서는 1,000달러) 증가에 따른 Balance의 평균 증가량이고, StudentYes 계수 382.6705는 같은 Income에서 학생과 비학생의 평균 차이이다. Student는 Yes/No 범주형 변수이므로 비학생을 기준으로 한 더미변수로 들어간다.
보기 판단: ①②③은 출력과 일치한다. ④는 단위가 다른 계수를 직접 비교한 오류이다. 상대적 중요도는 표준화 계수, t값, 모형 비교 등으로 판단하며, 이 출력에서는 오히려 Income의 t값(10.751)이 StudentYes(5.859)보다 크다.

40. 다음 중 시계열 자료의 정상성에 대한 설명으로 적절하지 않은 것은?

① 분산은 시점에 의존하지 않는다.
② 공분산은 시차(Lag)에만 의존한다.
③ 시계열의 평균이 모든 시점에서 일정하다.
④ 시계열의 자기상관계수가 관측 시점이 흐를수록 반드시 감소한다.

정답 ④
약정상성은 일정한 평균·분산, 시차에만 의존하는 공분산으로 정의한다. 시점이 바뀔수록 ACF가 감소해야 한다는 조건은 없다.
약정상성의 세 조건은 $E(X_t)=\mu$로 일정, $Var(X_t)=\sigma^2$로 일정, $Cov(X_t, X_{t+h})=\gamma(h)$로 시차 h에만 의존함이다. 예를 들어 1월과 2월의 공분산과 6월과 7월의 공분산은 같은 시차 1의 관계로 다루어진다.
보기 판단: ①②③은 위 조건이다. ④는 달력상 시간이 흘러간다는 것과 시차가 커진다는 것을 혼동한다. 정상성은 동일 시차의 상관구조가 시간 위치에 따라 변하지 않는다는 조건이지 시간이 흐를수록 자기상관이 반드시 감소한다는 조건이 아니다. 시차에 따른 ACF도 모형에 따라 진동하거나 다양한 형태를 보일 수 있다.

41. 다음 중 소프트맥스 (Softmax) 활성화 함수로 옳은 것은?

① $f(a) = \dfrac{1}{1+e^{-a}}$

② $f(a_i) = \dfrac{e^{a_i}}{\sum_{j=1}^{k} e^{a_j}}$

③ $f(a) = \dfrac{e^{a} - e^{-a}}{e^{a} + e^{-a}}$

④ $f(a) = \max(0, a)$

정답 ②

각 지수값을 모든 범주의 지수값 합으로 나누므로 출력 확률의 합이 1이다.

소프트맥스의 k번째 출력은 $p_k = \dfrac{e^{z_k}}{\sum_j e^{z_j}}$이다. 각 출력은 양수이고 모두 합하면 분자들의 합과 분모가 같아져 1이 된다. 따라서 여러 상호 배타적 클래스의 예측 확률을 표현하는 출력층에 사용한다.
계산 예시: 입력 점수가 (0,0)이면 지수값은 (1,1), 합은 2이므로 출력은 (0.5,0.5)이다. 분모에 자기 지수값만 쓰거나 지수값 전체 합으로 나누지 않는 식은 이 정규화 조건을 만족하지 않는다. ②가 위 식에 해당한다. 클래스가 하나뿐인 소프트맥스는 출력이 항상 1이므로 43번의 이진 시그모이드와 구별해야 한다.

42. 앙상블 학습에 대한 설명으로 적절하지 않은 것은?

① 배깅(Bagging)은 복원추출 기반의 부트스트랩 샘플을 생성하여 각 샘플마다 학습시킨 후 모든 모델의 예측 결과를 하나로 합치는 방식이다.

② 부스팅(Boosting)은 개별 모델에 동일한 가중치를 부여하여 순차적으로 학습한다.

③ 보팅(Voting)은 각 모델 예측 결과 중 가장 많이 나온 결과를 최종 결과로 채택한다.

④ 랜덤포레스트(Random Forest)는 배깅 방식을 기반으로 하여 복수의 독립적인 의사결정나무를 생성 후 예측을 수행한다.

정답 ②

부스팅은 이전 모형의 오차를 보완하며 순차적으로 학습한다. 모든 모델에 항상 동일 가중치를 준다는 일반화가 틀리다.

배깅은 여러 부트스트랩 표본으로 모형을 학습하고 분류는 투표, 회귀는 평균 등으로 결합한다. 부스팅은 이전 단계의 오차나 손실을 보완하는 학습을 순차적으로 수행한다. 결합 가중치나 보완 방법은 알고리즘에 따라 달라진다.
보기 판단: ②는 개별 모델에 항상 동일 가중치를 준다는 일반화가 틀렸다. ①은 배깅의 정의, ③은 하드 보팅의 정의이다. 소프트 보팅은 확률을 결합한다. ④의 랜덤포레스트는 배깅과 노드별 변수 무작위 선택을 함께 사용한다. 나무를 별도로 학습할 수 있지만 같은 원자료를 이용하므로 통계적으로 완전히 독립이라는 뜻으로 해석하지 않는다.

43. 아래 설명에서 해당하는 활성화 함수는 무엇인가?

> 입력층이 직접 출력층으로 연결되고 출력층의 노드가 1개인 인공신경망에서 이 활성화 함수를 사용하면 로지스틱 회귀 모형과 작동 원리가 동일해진다.

① Sigmoid

② Tanh

③ ReLU

④ Softmax

정답 ①

출력 노드 하나에 시그모이드를 적용하면 이진 로지스틱 회귀와 같은 형태가 된다.

입력의 가중합을 $z = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$로 두면 시그모이드 출력은 $\sigma(z) = \dfrac{1}{1+e^{-z}}$이다. 이는 이진 로지스틱 회귀의 확률식과 같은 형태이다. 은닉층 없이 입력에서 출력 노드 하나로 직접 연결한다는 조건이 핵심이다.
보기 판단: ①이 정답이다. ② Tanh는 −1~1 범위여서 그 자체로 이 확률식이 아니다. ③ ReLU는 max(0,z)로 출력이 1을 넘을 수 있다. ④ 소프트맥스를 출력 하나에 적용하면 항상 1이다. 같은 확률식 형태라는 사실이 학습 손실·규제·최적화 설정까지 모두 자동으로 같다는 뜻은 아니다.

44. 아래 오분류표를 참고하여 민감도를 구하시오.

실제 \ 예측	True (P)	False (N)
True	200 (TP)	400 (FN)
False	100 (FP)	300 (TN)

① 0.33

② 0.5

③ 0.75

④ 0.8

정답 ①

오분류표에서 $TP = 200$, $FN = 400$이므로 민감도 $= \dfrac{200}{200+400} = \dfrac{1}{3} \approx 0.33$이다.

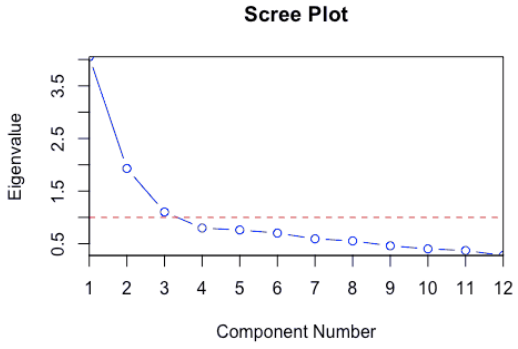
민감도는 실제 양성 중 양성으로 찾아낸 비율이며 재현율 또는 TPR이라고도 한다. 먼저 오분류표에서 실제 양성에 속하는 TP와 FN을 찾아야 한다. 표에서 $TP = 200$, $FN = 400$이므로 실제 양성 전체는 600이다.
계산: 민감도 $= \dfrac{TP}{TP+FN} = \dfrac{200}{600} = 0.333\cdots$이므로 반올림한 ① 0.33이다. 분모를 예측 양성 TP+FP로 잡으면 정밀도를 계산하게 되어 다른 지표가 된다. 특이도는 $\dfrac{TN}{TN+FP}$, 정확도는 $\dfrac{TP+TN}{\text{전체}}$이다. 표의 행·열 배치보다 실제·예측의 표제를 먼저 확인해야 한다.

45. 혼합분포군집 모델에서 최대가능도추정을 보완하기 위해 사용되는 분석 기법은?

① K-NN 알고리즘
② K-평균 알고리즘
③ Apriori 알고리즘
④ EM 알고리즘

정답 ④
EM은 잠재변수의 기대값 계산과 가능도 최대화 단계를 반복한다.
혼합모형에서는 각 관측값이 어느 성분에서 발생했는지 직접 관측되지 않는 잠재변수가 있다. 이 때문에 관측자료의 가능도를 직접 최적화하기 어려운 경우 EM 알고리즘을 사용할 수 있다. E단계는 현재 모수로 잠재 소속의 조건부 확률 등을 계산하고, M단계는 그 결과를 사용한 기대 로그가능도를 최대화하여 모수를 갱신한다.
보기 판단: ④가 정답이다. ① K-NN은 이웃 기반 예측, ② K-평균은 중심까지 거리 기반 군집화, ③ Apriori는 빈발 항목집합 탐색과 관련된다. EM은 반복 개선 알고리즘이지만 초기값에 따라 다른 국소해에 도달할 수 있어 항상 전역 최적해를 보장한다고 말하지 않는다.

46. 아래 주성분 분석(PCA)의 Scree plot을 통해 고유값이 1보다 큰 주성분을 선택할 때 주성분 수는?



① 1
② 3
③ 5
④ 7

정답 ②
Scree plot에서 고유값이 1보다 큰 주성분은 3개이므로 ②이다.
Scree plot의 가로축은 주성분 순서, 세로축은 고유값이다. PCA의 고유값은 각 주성분이 설명하는 분산에 해당한다. 이 문항은 고유값이 1보다 큰 성분을 선택하라는 기준을 명시했으므로 그림에서 그 조건을 만족하는 점을 세어 3개, 즉 ②로 읽는다.
기준 구분: Kaiser 기준의 1은 표준화 변수에 대한 상관행렬 기반 PCA에서 원래 변수 한 개의 분산 1과 비교하는 맥락에 특히 의미가 있다. Scree의 꺾이는 지점이나 누적 설명분산 기준과는 다르며, 군집 수를 정하는 엘보 방법과도 다르다.

47. 다음 중 군집분석 기법에 대한 설명으로 적절하지 않은 것은?

① DBSCAN은 밀도 기반 군집화 방식으로 초기 중심값 설정이 불필요하다.
② 가우시안 혼합 모델(GMM)은 EM 알고리즘을 사용하여 모델 매개변수를 추정하며, 초기 중심값 설정에 따라 그 결과가 달라질 수 있다.
③ 자기 조직화 지도(SOM)는 비지도 학습으로 차원축소와 군집화를 동시에 수행한다.
④ 자기 조직화 지도(SOM)는 경쟁층의 모든 노드에 동일한 수의 데이터가 할당된다.

정답 ④
SOM의 경쟁층 각 노드에 배정되는 관측 수가 모두 같아야 할 필요는 없다.
DBSCAN은 eps와 min_samples 같은 밀도 조건으로 군집을 구성하며 초기 중심이나 군집 개수 K를 직접 정하지 않는다. GMM은 분포들의 혼합으로 관측값을 설명하고 EM 등의 방법으로 모수를 추정하므로 초기화가 결과에 영향을 줄 수 있다. SOM은 입력의 유사성 구조를 저차원 경쟁층 지도에 반영하는 비지도 방법이다.
보기 판단: ①②③은 위 특징을 설명한다. ④는 모든 경쟁층 노드에 같은 수의 관측값이 배정된다고 단정하므로 틀리다. SOM은 관측값에 가장 잘 대응하는 노드와 주변 노드를 갱신하지만 각 노드의 배정 빈도를 균등하게 만드는 조건은 없다. 일부 노드에는 많은 자료가, 다른 노드에는 거의 없는 자료가 대응할 수 있다.

48. 군집분석에 대한 설명으로 적절하지 않은 것은?

① 계층적 군집분석은 덴드로그램을 통해 시각화하여 직관적으로 표현할 수 있다.
② K-평균 군집분석에서 초기 중심값 설정은 군집분석 결과에 영향을 주지 않는다.
③ 이상치(Outlier)나 소음(Noise) 데이터는 군집분석의 성능에 영향을 줄 수 있으므로 전처리 과정에서 제거할 필요가 있다.
④ DBSCAN 방식은 군집 개수를 미리 정할 필요가 없다.

정답 ②
K-평균은 초기 중심에 따라 결과가 달라질 수 있다.
K-평균은 초기 중심에서 시작해 관측값 배정과 중심 재계산을 반복하며 군집 내 제곱거리 합을 줄인다. 초기 중심이 다르면 다른 국소해에 도달할 수 있으므로 ②가 틀린 설명이다. 여러 초기화로 반복하거나 개선된 초기화 방법을 사용해 이 문제를 완화할 수 있다.
나머지 보기: ① 덴드로그램은 계층적 합병 구조를 시각화한다. ④ DBSCAN은 군집 개수를 직접 입력하지 않지만 밀도 매개변수는 설정해야 한다. ③의 이상치·잡음은 성능에 영향을 줄 수 있으므로 검토와 처리가 필요하다는 취지로 읽는다. 실제 희귀 집단이나 중요한 이상 사건일 수 있어 모든 이상치를 무조건 삭제하는 원칙은 적절하지 않다.

49. 다음 중 군집을 합병할 때 군집 내 오차 제곱합의 증가량이 가장 작은 쌍을 선택하는 연결법은?

① 중심 연결법
② 평균 연결법
③ 와드 연결법
④ 단일 연결법

정답 ③

Ward는 군집 합병으로 인한 군집 내 제곱합 증가가 가장 작은 쌍을 선택한다.

Ward 연결법은 현재 군집 중 두 군집을 합쳤을 때 군집 내 오차제곱합이 얼마나 증가하는지 비교하고 그 증가량이 가장 작은 쌍을 선택한다. 유클리드 거리 기반에서는 증가량이 $\frac{n_A n_B}{n_A + n_B} \|\text{중심}_A - \text{중심}_B\|^2$로 표현된다.
보기 판단: ③이 정답이다. ① 중심 연결은 군집 중심 사이 거리, ② 평균 연결은 두 군집의 관측값 쌍 거리의 평균, ④ 단일 연결은 관측값 쌍 거리의 최솟값을 이용한다. Ward는 합병에 따른 분산 증가를 기준으로 한다는 차이가 있다. 단계마다 최선의 쌍을 고르는 방식이 전체 가능한 군집 분할의 전역 최적성을 보장하는 것은 아니다.

50. 아래 특정 기간 동안 판매된 음료 구매 건 수를 통해 "우유 → 커피"의 지지도는?

> 거래 구성: 커피만 20건, 우유만 50건, 커피와 우유 동시 구매 30건, 전체 100건.

① 0.2
② 0.3
③ 0.4
④ 0.5

정답 ②

지지도는 두 품목을 함께 포함한 거래 수를 전체 거래 수로 나눈 값이므로 $30/100 = 0.3$이다. 방향과 관계없다.

거래 범주가 서로 겹치지 않도록 정리된 표에서 전체 거래는 $20 + 50 + 30 = 100$건이다. 우유와 커피를 모두 포함하는 거래는 30건이므로 지지도 $= P(\text{우유} \cap \text{커피}) = 30/100 = 0.3$, 정답은 ②이다. 화살표 방향은 지지도 계산에 영향을 주지 않는다.
지표 비교: 우유 구매는 우유만 50건과 동시 구매 30건을 더한 80건이므로 우유→커피의 신뢰도는 $30/80 = 0.375$이다. 커피 구매는 $20 + 30 = 50$건이므로 커피→우유의 신뢰도는 $30/50 = 0.6$이다. 향상도는 $\frac{0.375}{50/100} = 0.75$이다.