ADsP 제48회 기출 복원문제

유형 2
정답·해설 수록본
총 50문항 · 4지선다 · 90분

1과목 데이터 이해 (1~10번)

1. 지식 경영의 SECI 모델에 대한 설명으로 적절하지 않은 것은?

① 공통화는 암묵적 노하우를 타인에게 전달하는 과정이다.
② 표출화는 암묵적 노하우를 책 및 교재 등의 형식지로 전환하는 과정이다.
③ 연결화는 기존 형식지에 자신의 개인 지식까지 추가 및 보완하여 새로운 암묵지로 창출하는 과정이다.
④ 내면화는 축적된 형식지를 참고하여 다른 구성원들이 암묵적 지식으로 체화하는 과정이다.

정답 ③
연결화는 기존 형식지를 분류·편집·결합하여 새로운 형식지를 만드는 과정이다. 새로운 암묵지를 만든다는 ③이 틀렸다. 공통화는 암묵지→암묵지, 표출화는 암묵지→형식지, 내면화는 형식지→암묵지이다. 예를 들어 여러 매뉴얼을 종합하여 새 매뉴얼을 작성하는 활동은 연결화에 해당한다.

2. 아래 정성적 데이터와 정량적 데이터의 설명에 대해 옳은 것을 모두 고르시오

가. 빅데이터 환경에서 정량적 데이터는 정성적 데이터에 비해 분석 및 활용에 더 많은 비용과 고도의 기술이 요구되고 있다.
나. 정성적 데이터는 문자, 언어 등으로 구성되며 형태와 형식이 일정하지 않은 비정형인 경우가 많다.
다. 정성적 데이터는 구체적인 수치 형태로 표현되며, 정량적 데이터에 비해 저장과 분석이 용이한 장점이 있다.
라. 정량적 데이터는 정형화된 틀 안에서 대규모 데이터를 수집하고 일반화하는 데 용이하다.
마. 데이터는 있는 그대로의 객관적 사실을 부여하는 존재적 특성을 가지며 추론 및 예측의 근거로 활용되는 당위적 특성을 가진다.

① 가, 나, 라
② 나, 다, 라
③ 나, 라, 마
④ 다, 라, 마

정답 ③
옳은 설명은 나·라·마이다. 정성적 데이터는 문자·언어·관찰 기록처럼 수치 계산이 바로 어려운 형태를 포함한다. 정량적 데이터는 수치로 표현되어 비교·집계·통계 분석에 활용하기 쉽다. 가는 비용과 기술 부담의 비교 방향을 뒤집었으며, 다는 정량적 데이터의 특징을 정성적 데이터로 잘못 설명했다. 존재적 특성은 관측한 사실, 당위적 특성은 추론·예측의 근거라는 의미이다.

3. 다음 중 데이터베이스에 대한 설명으로 적절하지 않은 것은?

① 다수의 사용자가 동시에 공유하고 활용할 수 있도록 구조화하여 통합 저장한 데이터의 집합이다.
② 데이터의 중복을 최소화하고 일관성을 유지함으로써 데이터의 신뢰도를 높이는 시스템이다.
③ 응용 프로그램과 데이터가 서로 독립적으로 존재하여, 데이터 구조가 바뀌어도 응용 프로그램에는 영향을 주지 않는 독립성을 가진다.
④ 데이터베이스는 데이터, 정보, 지식, 저작물 등의 인식 가능한 모든 자료 포괄하기 때문에 그 자체로 구조적 체계를 갖지 않는다.

정답 ④
데이터베이스는 자료를 일정한 구조로 조직하여 저장하고 공동 활용하도록 구성한 집합이다. 자료의 범위가 넓다고 해서 구조적 체계가 없다는 결론은 성립하지 않는다. DBMS는 데이터베이스의 저장·검색·수정 등을 관리하는 소프트웨어이며, 데이터베이스와 DBMS 등을 포함한 운영 구성을 데이터베이스 시스템이라고 한다.

4. 다음 중 데이터베이스에 대한 특징으로 적절하지 않은 것은?

① 데이터베이스 내 동일 데이터가 중복되지 않는 '통합 데이터'이다.
② 컴퓨터가 접근 가능한 저장 매체에 데이터가 저장되어 있는 '저장 데이터'이다.
③ 다수의 사용자가 동시 접속 및 공유 가능한 '공용 데이터'이다.
④ 사용자가 데이터를 변경 및 갱신할 수 없는 '고정' 데이터이다.

정답 ④
데이터베이스는 지속적인 삽입·수정·삭제를 통해 현실의 상태를 반영하는 변화하는 데이터이다. 따라서 사용자가 변경하거나 갱신할 수 없는 고정 데이터라는 ④가 틀렸다. 실시간 접근성, 동시 공유, 통합 저장은 대표적 특징이다. 실제 수정 권한은 사용자별 접근 통제로 제한할 수 있지만, 그것이 데이터베이스 전체가 고정되어 있다는 뜻은 아니다.

5. 다음 중 '공부시간'에 따른 '시험성적'의 변화를 분석하기 위한 적절한 분석방법은?

① 연관분석
② 회귀분석
③ 군집분석
④ 교차분석

정답 ②
공부시간을 설명변수 X, 시험성적을 반응변수 Y로 두고 성적이 시간에 따라 어떻게 달라지는지 설명하거나 예측하므로 회귀분석이 적절하다. 연관분석은 함께 발생하는 항목의 규칙, 군집분석은 유사한 관측값의 그룹, 교차분석은 범주형 변수의 빈도와 관계를 다룬다. 회귀 관계를 확인했다고 인과효과가 자동으로 증명되는 것은 아니다.

6. 다음 중 빅데이터의 위기 요인으로 옳은 것을 모두 고르시오.

> 가. 사생활 침해
> 나. 데이터 오용
> 다. 익명화
> 라. 책임 원칙 훼손
> 마. 알고리즘 접근 허용

① 가, 나, 다
② 가, 나, 라
③ 나, 다, 라
④ 다, 라, 마

정답 ②
위기 요인은 가 사생활 침해, 나 데이터 오용, 라 책임 원칙 훼손이다. 익명화와 알고리즘 접근 허용은 위험 그 자체가 아니라 위험을 통제하는 방안으로 분류한다. 위기 요인과 대응 방안을 구분하여 조합을 선택해야 한다. 보기의 가·나·다 순서는 자료마다 다를 수 있으므로 실제 용어를 기준으로 판단한다.

7. 다음 중 빅데이터 활용을 위한 3대 기본요소가 아닌 것은?

① 데이터
② 프로세스
③ 인력
④ 기술

정답 ②
빅데이터 활용의 3대 기본요소는 데이터·기술·인력이다. 데이터는 분석할 재료, 기술은 처리·분석 방법과 도구, 인력은 이를 해석하고 활용하는 주체이다. 프로세스도 실제 프로젝트에 필요하지만 이 문항이 묻는 정해진 3요소에는 포함되지 않는다.

8. 데이터 사이언티스트에 대한 설명으로 적절하지 않은 것은?

① 알고리즘 해석을 통해 부당한 피해를 받은 개인 및 집단을 구제하고 법적인 조치를 수행하는 알고리즈미스트로의 역할도 병행해야 한다.
② 통계 및 수학적 원리를 활용하여 데이터의 신뢰성을 검증하고 모델을 설계하는 하드스킬이 요구된다.
③ 데이터 시각화와 스토리텔링을 통해 분석 결과의 핵심 메시지를 효과적으로 전달하는 소프트스킬이 요구된다.
④ 비즈니스 도메인 지식을 바탕으로 분석 결과를 전략적 인사이트로 변환할 수 있는 통찰력이 필요하다.

정답 ①
데이터 사이언티스트의 중심 역할은 데이터 분석·모델링·해석과 의사결정 지원이다. 알고리즘 때문에 발생한 피해의 구제와 책임 점검을 직접 맡는 역할은 교재의 알고리즈미스트 구분에 해당한다. 따라서 이를 데이터 사이언티스트가 반드시 병행해야 한다는 ①은 적절하지 않다. 통계·수학 역량, 결과 전달 능력, 업무 도메인 이해는 필요한 역량이다.

9. 다음 중 데이터 사이언스에 대한 설명으로 적절하지 않은 것은?

① 수집된 데이터의 결측치 처리 및 이상치 제거를 통해 데이터 품질과 분석의 정확도를 높일 수 있다.
② 가용 데이터를 활용해 패턴을 학습하고, 이를 바탕으로 미래 데이터에 대한 예측 및 분류가 가능하다.
③ 데이터 사이언티스트의 소프트스킬로는 알고리즘 이해와 분석 능력이 포함된다.
④ 탐색적 데이터 분석을 통해 시각화와 기초 통계량을 활용하여 데이터의 분포와 변수 간의 잠재적 관계를 파악할 수 있다.

정답 ③
알고리즘 이해와 분석 기법의 숙련은 하드스킬이다. 소프트스킬은 통찰력, 의사소통, 협업, 스토리텔링처럼 분석 결과를 이해시키고 실제 행동으로 연결하는 능력이다. 따라서 기술적 분석 능력을 소프트스킬로 분류한 ③이 틀렸다. 두 종류의 역량은 분석 업무에서 함께 필요하다.

10. 빅데이터 가치 패러다임 변환 과정을 순서대로 나열한 것은?

① Digitalization → Agency → Connection
② Digitalization → Connection → Agency
③ Connection → Agency → Digitalization
④ Connection → Digitalization → Agency

정답 ②
가치 패러다임은 Digitalization→Connection→Agency 순서이다. 먼저 현실의 정보를 디지털로 전환하고, 디지털 정보와 서비스가 연결되며, 이후 데이터와 지능을 활용한 대리·자동 수행으로 가치가 확장된다는 흐름이다. 세 단계의 영어 명칭과 순서를 함께 기억한다.

2과목 데이터 분석 기획 (11~20번)

11. 다음 중 분석방법은 알고 있으나, 분석 대상이나 문제 정의가 명확하지 않은 경우에 해당되는 분석 과제 도출유형은 무엇인가?

① 최적화 (Optimization)
② 통찰 (Insight)
③ 솔루션 (Solution)
④ 발견 (Discovery)

정답 ②
분석 방법은 알고 있으나 대상이나 해결할 문제가 불명확하면 통찰형이다. 대상과 방법을 모두 알면 최적화, 대상만 알면 솔루션, 둘 다 모르면 발견으로 구분한다. 이 문항은 방법 O·대상 X에 해당하므로 ② 통찰이다.

12. CRISP-DM 분석 방법론의 데이터 준비 단계에서 수행하는 활동 중 적절하지 않은 것은?

① 데이터 정제
② 데이터 통합
③ 데이터 탐색
④ 데이터 포맷팅

정답 ③
데이터 탐색은 데이터 이해 단계의 활동이다. 데이터 준비 단계에는 사용할 자료의 선택, 정제, 구성, 통합, 포맷 변경 등이 포함된다. 정제는 오류·결측 등을 다루고, 통합은 자료를 결합하며, 포맷팅은 분석에 필요한 형식으로 바꾸는 작업이다. 실제 업무에서는 탐색을 반복하더라도 방법론의 단계 구분을 기준으로 답한다.

13. 다음 중 상향식 접근 방식의 데이터 분석 방법으로 옳은 것은?

① 비즈니스 모델 기반 문제 탐색
② 외부 참조 모델(벤치마킹) 기반 문제 탐색
③ 비지도 학습
④ 가설 검정 분석

정답 ③
상향식 접근은 데이터를 탐색하여 패턴과 새로운 문제를 발견하는 흐름이며, 정답 라벨 없이 구조를 찾는 비지도학습이 대표적이다. 비즈니스 모델이나 외부 참조 모델에서 문제를 먼저 정하는 방식은 하향식 문제 탐색에 가깝다. 가설검정은 이미 설정한 가설을 검증하므로 이 문항의 대표 답은 비지도학습이다.

14. 데이터 분석 프로젝트의 품질관리에 대한 설명으로 가장 적절한 것은?

① 품질관리는 납기 단축만을 위한 활동이다.
② 품질보증은 완성된 산출물의 오류 수정만 의미한다.
③ 품질관리는 품질검토와 품질보증 활동을 포함한다.
④ 품질계획은 품질 기준과 무관하다.

정답 ③
품질관리는 품질검토와 품질보증 활동을 포함한다. 품질검토는 산출물이 기준을 충족하는지 확인하는 활동이고, 품질보증은 과정과 체계가 품질을 확보하도록 점검하는 활동이다. 납기 단축만으로 품질을 정의하거나, 보증을 완성품 오류 수정으로만 제한하거나, 품질계획이 기준과 무관하다고 설명한 나머지 보기는 적절하지 않다.

15. 다음 중 분석과제 우선순위에 대한 설명으로 옳은 것을 모두 고르시오.

> 가. 시급성은 데이터의 양과 범위에 따라 결정된다.
> 나. 난이도는 데이터 분석 기술의 복잡도, 분석 시스템의 활용도에 따라 결정된다.
> 다. 분석 과제의 전략적 중요성이 높아질수록 시급성도 높아진다.

① 가
② 가, 나
③ 나, 다
④ 가, 나, 다

정답 ③
나·다가 옳다. 기술 복잡도와 분석 시스템 활용도는 난이도에 영향을 주고, 전략적 중요성은 과제의 시급성을 판단하는 기준이다. 데이터 양과 범위는 주로 처리 부담과 난이도에 연결되므로 시급성을 그것만으로 결정한다는 가는 적절하지 않다.

16. 다음 중 분석 성숙도 모델에 대한 설명으로 적절하지 않은 것은?

① 분석 성숙도는 도입, 활용, 확산, 최적화 총 4단계로 구분하여 점검된다.
② 분석 성숙도 모델의 사분면 분석으로는 정착형, 확산형, 준비형, 도입형으로 구성된다.
③ 사분면 분석 중 정착형은 준비도가 낮으며 조직, 인력, 분석 업무 등 내부에서 제한적으로 사용되는 단계이다.
④ 분석 성숙도 평가는 유사업종 및 경쟁사와 성숙도 수준을 비교하는 것이 주요 목표이다.

정답 ④
분석 성숙도 평가의 주요 목표는 조직이 분석을 수행하고 결과를 활용하는 현재 수준을 진단하여 개선 목표와 방향을 정하는 것이다. 유사업종·경쟁사와의 비교는 목표 수준을 정할 때 참고하는 활동이지 평가의 주요 목표는 아니므로 ④가 부적절하다. 도입·활용·확산·최적화 단계와 준비도·성숙도를 함께 보는 사분면 구분을 구별한다. 정착형은 준비도가 낮고 성숙도가 높은 유형이며 일부 영역에 분석이 정착된 상태로 해석한다.

17. 다음 중 데이터분석 마스터플랜 수립 시 분석 과제 우선순위를 결정하기 위한 고려 요소로 적절하지 않은 것은?

① 비즈니스 성과
② 기술 적용 수준
③ 실행 용이성
④ 전략적 중요도

정답 ②
우선순위의 대표 고려 요소는 전략적 중요도, 비즈니스 성과, 실행 용이성이다. 기술 적용 수준 자체를 독립적인 최우선 판단 요소로 제시한 ②는 이 문항의 구분에 맞지 않는다. 기술 난이도는 실행 용이성 평가에 반영될 수 있으므로 기술을 전혀 고려하지 않는다는 뜻은 아니다.

18. 다음 중 분석 수준 진단을 위한 조사 대상으로 적절하지 않은 것은?

① 분석 기법
② 분석 데이터
③ 분석 문화
④ 분석 비즈니스 성과

> **정답 ④**
> 교재의 분석 수준 진단은 준비도와 성숙도 관점에서 데이터·기법·인프라·문화·업무·조직 등을 조사한다. 이 문항에서는 분석 비즈니스 성과가 정해진 조사 범주와 구별되는 항목이다. 실제 기업이 성과를 측정하지 않는다는 의미로 확대하면 안 된다. 성과 평가는 별도로 중요하지만 질문의 조사 항목 분류에 맞추어 ④를 선택한다.

19. 다음 중 데이터 분석을 위한 조직 구성 모델에 대한 설명으로 적절하지 않은 것은?

① 집중형 조직은 별도 독립적 분석 조직으로 구성되어 전사적 우선순위 관리가 용이하다.
② 집중형 조직은 독립적인 조직으로 분석을 진행하기 때문에 현업 부서와 중복 업무를 수행할 가능성이 높다.
③ 기능 중심형 조직은 별도 독립된 분석 조직 없이 각 현업 부서에서 직접 분석하여 전사적인 분석 관리가 어렵다.
④ 분산 조직은 데이터 분석 조직을 현업부서에 분산 배치시켜서 새로운 분석 기법을 현업에 신속한 실무적용이 어렵다.

> **정답 ④**
> 분산형 조직은 분석 인력을 현업에 배치하여 업무 이해와 실무 적용을 촉진한다. 따라서 새로운 분석 결과를 신속하게 적용하기 어렵다는 ④는 특징을 반대로 설명한 것이다. 집중형은 전사 우선순위 관리에 유리하고 현업과의 업무 중복 가능성이 있으며, 기능형은 각 부서가 분석하므로 전사 통합 관점이 약해질 수 있다.

20. 다음 중 데이터 거버넌스의 특징으로 적절하지 않은 것은?

① 데이터 거버넌스의 구성 요소로는 원칙, 조직, 프로세스가 포함된다.
② 데이터 거버넌스의 체계 요소로는 데이터 표준화, 관리체계, 저장소 관리뿐만 아니라 데이터 운용 비용까지 포함된다.
③ 데이터 표준화는 표준용어 정립, 명명 규칙 수립, 데이터 사전 구축 등이 포함된다.
④ 거버넌스 체계 구축 후에도 표준 준수 여부 확인을 위한 주기적 점검이 필요하다.

> **정답 ②**
> 이 문항은 교재에서 제시하는 데이터 거버넌스의 체계 요소 구분을 묻는다. 데이터 표준화·관리체계·저장소 관리·지속적 변화 관리와 교육이 핵심이며, 운용 비용을 같은 목록의 정해진 요소로 추가한 ②를 부적절한 설명으로 본다. 현실의 거버넌스에서 예산이나 비용을 다루는 일이 금지된다는 의미는 아니다.

3과목 데이터 분석 (21~50번)

21. 다음 중 상자그림(Boxplot)에 대한 설명으로 적절하지 않은 것은?

① 상자그림 내부의 수평선은 해당 데이터의 중앙값을 나타낸다.
② 사분위수 범위(IQR)는 전체 데이터의 50%가 분포하는 구간의 길이를 나타낸다.
③ IQR의 1.5배를 초과하여 벗어난 관측치는 이상치로 정의할 수 있다.
④ 상자그림의 폭과 길이 비교를 통해 해당 데이터의 관측치 개수를 파악할 수 있다.

> **정답 ④**
> 일반적인 상자그림은 중앙값, 사분위수, 분포의 퍼짐, 이상치 후보를 보여준다. 상자의 높이와 수염 길이는 값의 분포를 나타내며 관측치 수를 직접 의미하지 않는다. 따라서 폭과 길이를 비교하여 표본 수를 파악할 수 있다는 ④가 틀렸다. 표본 수에 비례하도록 폭을 따로 설계한 특수 상자그림은 예외이다. 이상치 기준은 Q1−1.5IQR 미만 또는 Q3+1.5IQR 초과이다.

22. 다음 중 데이터 이상값 탐지 및 처리 방법에 대한 설명으로 적절하지 않은 것은?

① 상자그림에서 사분위수 범위(IQR)의 1.5배를 기준으로 상한 및 하한 임계치를 설정하여 이상값을 식별한다.
② 데이터가 정규분포를 따른다고 가정할 때, 평균으로부터 표준편차의 3배 이상 떨어진 값을 이상값으로 판단한다.
③ 표본 평균의 표준오차 범위를 계산하여 해당 범위를 벗어나는 값을 이상값으로 처리한다.
④ 이상값을 삭제하는 대신 경우에 따라 평균, 중앙값 또는 회귀분석을 통한 예측값으로 바꾸어 데이터의 손실을 최소화할 수 있다.

> **정답 ③**
> 표본평균의 표준오차는 평균 추정의 불확실성을 나타내며 개별 관측값의 정상 범위를 뜻하지 않는다. 이를 벗어난 값을 모두 이상치로 처리하면 정상 관측값도 과도하게 제거할 수 있다. IQR 기준과 정규분포를 가정한 평균±3표준편차 기준은 이상치 후보 탐지에 사용된다. 후보 발견 후 오류인지 의미 있는 극단값인지 확인해야 하며 대치·삭제는 상황에 따라 결정한다.

23. 다음 중 통계적 추론에 대한 설명으로 적절하지 않은 것은?

① 구간 추정 방식으로 일정한 신뢰수준 하에서 모수가 포함될 것으로 기대되는 범위를 정하여 모수를 추정할 수 있다.
② 가설검정에 사용할 수 있는 검정통계량은 검정 방법과 무관하게 항상 하나로만 유일하게 결정된다.
③ 유의수준은 제1종 오류를 범할 수 있는 허용 한계로 가설 채택 여부를 결정하는 값이다.
④ p-value 값이 유의수준보다 작으면 귀무가설을 기각할 수 있다.

> **정답 ②**
> 검정통계량은 검정 목적, 자료 형태, 가정에 따라 t·F·카이제곱 등으로 달라진다. 어떤 가설에 적용할 수 있는 방법이 언제나 하나뿐이라는 ②는 틀렸다. 선택한 검정에서 하나의 관측 통계량을 계산하는 것과, 가능한 검정 방법이 유일하다는 주장은 다르다. p-value가 유의수준보다 작으면 해당 검정의 귀무가설을 기각한다.

24. 다음 중 회귀분석 모형 적합성을 판단하는 설명으로 적절하지 않은 것은?

① 회귀모형의 적합성을 판단하기 위해 잔차 산점도를 확인하며, 잔차가 특정 패턴 없이 무작위로 분포해야 모형의 가정이 충족된 것으로 본다.
② 다중회귀분석에서는 독립변수의 수가 늘어나면 결정계수가 무의미하게 높아지는 단점을 보완하기 위해 수정된 결정계수를 평가지표로 활용하기도 한다.
③ 회귀계수의 유의성은 t-검정으로 판단 가능하며, 해당 독립변수가 종속변수를 설명하는데 유의미한지 확인 가능하다.
④ 설명변수 간 상관계수를 확인하면 해당 회귀분석 모형의 적합성을 판단할 수 있다.

> **정답 ④**
> 설명변수들 사이의 상관계수는 주로 다중공선성의 단서를 살핀다. 이것만으로 모형이 종속변수를 잘 설명하거나 가정을 충족한다고 판단할 수 없다. 잔차 패턴, R^2·수정 R^2, 전체 모형의 F-검정, 회귀계수의 t-검정 등 목적별 지표를 구분하여 확인해야 한다.

25. 다음 중 절대 영점이 존재하지 않아 덧셈, 뺄셈 등의 양적 비교는 가능한 척도는?

① 명목척도
② 구간척도
③ 비율척도
④ 서열척도

> **정답 ②**
> 구간척도는 간격이 일정하지만 절대영점이 없다. 섭씨온도처럼 차이는 의미가 있어도 20도가 10도의 두 배라는 비율 해석은 할 수 없다. 비율척도는 절대영점이 있어 비율 비교도 가능하고, 명목척도는 분류, 서열척도는 순서를 나타낸다. 따라서 ② 구간척도이다.

26. 다음 중 가설검정에 대한 설명으로 적절하지 않은 것은?

① p-value가 미리 설정한 유의수준보다 작으면 귀무가설을 기각하고 대립가설을 채택한다.
② 귀무가설이 참이라는 가정하에 검정통계량의 값이 나타날 가능성이 작을수록 귀무가설을 채택한다.
③ 제2종 오류는 대립가설이 실제로 참임에도 불구하고, 귀무가설을 기각하지 못하고 채택하는 오류를 의미한다.
④ 검정력은 대립가설이 참일 때 이를 올바르게 판정하여 귀무가설을 기각할 확률로, $1-\beta$로 계산한다.

> **정답 ②**
> 귀무가설하에서 관측 결과 또는 더 극단적인 결과가 드물수록 귀무가설과 자료의 양립 가능성이 낮아진다. p-value가 작으면 귀무가설을 기각하는 방향이므로 이를 채택한다는 ②가 틀렸다. 제1종 오류는 참인 귀무가설의 기각, 제2종 오류는 거짓인 귀무가설을 기각하지 못하는 것이며 검정력은 1−β이다. 기각하지 못함은 참임의 입증과 구별한다.

27. 다음 중 교차분석에 대한 설명으로 적절하지 않은 것은?

① 통상적으로 관측 빈도와 기대 빈도의 차이를 측정하는 카이제곱 통계량을 사용한다.

② 독립성 검정은 두 범주형 변수 간에 서로 관련이 있는지, 아니면 통계적으로 서로 독립적인지 판단하기 위해 수행된다.

③ 동질성 검증은 서로 다른 관찰 집단 간에 해당 변수의 분포가 동일한지를 확인하기 위해 수행된다.

④ 교차분석은 두 변수가 연속형 변수인 경우에도 분석이 가능하다.

정답 ④

교차분석은 범주형 변수의 교차표와 빈도에 기초한다. 연속형 값은 필요하다면 범주로 구간화한 뒤 사용할 수 있지만, 연속형인 원자료 그대로를 범주형 교차분석에 적용할 수 있다는 ④는 부적절하다. 독립성 검정은 한 모집단 내 변수의 관련성, 동질성 검정은 집단별 범주 분포의 동일성을 살핀다.

28. 변수 X와 Y의 상관계수가 0.5일 때, 다음 중 옳은 설명은?

① (X+0.3)과 Y의 상관계수는 0.8이다.

② (2X)와 Y의 상관계수는 1이다.

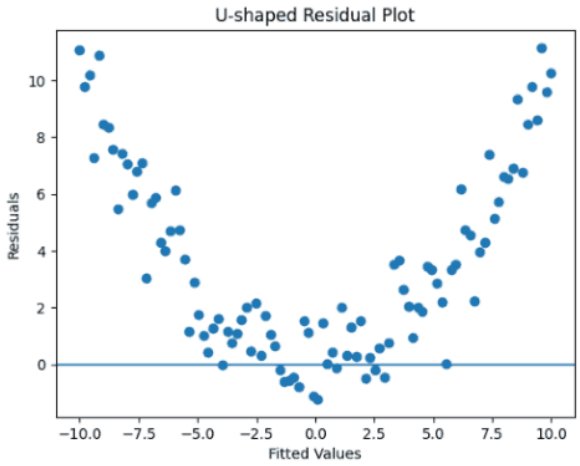
③ (X+0.3)과 (Y+0.2)의 상관계수는 0.5이다.

④ (-X)와 (-2Y)의 상관계수는 1이다.

정답 ③

상관계수는 각 변수에 상수를 더해도 변하지 않는다. 양수 배율로 확대해도 변하지 않고, 한 변수만 음수로 곱하면 부호가 반전된다. 두 변수 모두 음수로 곱하면 부호 반전이 두 번 발생하여 원래 상관계수와 같다. 따라서 ③은 0.5로 옳으며, ②와 ④도 1이 아니라 0.5이다. 이는 분산이 0이 아닌 변수의 Pearson 상관계수 성질이다.

29. 회귀분석에 따른 잔차도가 아래 그림과 같을 때, 해당 분석의 해석으로 옳은 것은?



① 잔차가 0을 중심으로 고르게 분포하므로 회귀모형이 적합하다.

② 릿지, 라쏘 모델을 사용하여 해당 분석 결과의 과적합 문제를 해결해야 한다.

③ 독립변수와 종속변수 간 비선형성이 확인되어 비선형 모델을 적용해야 한다.

④ 해당 잔차도 그래프는 변수에 이상치(outlier)가 많아서 발생한 패턴이다

정답 ③

잔차가 U자형 등의 체계적인 곡선 패턴을 보이면 단순한 선형 관계를 충분히 표현하지 못한 가능성을 검토한다. 다항항이나 변수 변환 등 관계 형태를 보완하는 접근이 적절하다. 릿지·라쏘는 계수 규제를 통한 과적합 완화 기법이며 곡선 관계 문제를 자동으로 해결하지 않는다. 그림만으로 이상치가 많다고 단정할 수는 없다.

30. 다음 중 통계적 추론에 대한 설명으로 적절하지 않은 것은?

① 통계적 추론은 표본 통계량을 토대로 모집단의 모수를 추측하는 과정이다.

② 신뢰수준은 주어진 신뢰구간에 모수가 포함할 확률이다.

③ 표본의 크기가 일정할 때, 신뢰수준을 높이면 신뢰구간의 길이는 더 길어진다.

④ 신뢰수준이 일정할 때, 표본의 크기가 커질수록 신뢰구간의 길이는 더 좁아진다.

정답 ②

빈도주의에서 모수는 고정되어 있고 표본을 반복 추출하면 신뢰구간이 달라진다. 95% 신뢰수준은 같은 방법으로 만든 구간이 반복적으로 참 모수를 포함하는 비율이 95%라는 뜻이다. 이미 계산된 특정 구간에 고정된 모수가 들어갈 확률을 95%라고 정의한 ②는 엄밀한 설명이 아니다. 같은 조건에서 신뢰수준이 높으면 구간은 넓어지고 표본 수가 많으면 좁아지는 경향이 있다.

31. 같은 환자 10명에게 수면유도제 A와 B를 각각 투여하고 수면시간 증가량(시간)을 측정하여 대응표본 t-검정을 수행한 결과이다. 해석으로 적절하지 않은 것은?

> 분석: t.test(A, B, paired = TRUE)
> t = −4.0621, df = 9, p-value = 0.002833
> 평균 차이(A − B) = −1.58, 95% 신뢰구간: [−2.4599, −0.7001]

① 같은 환자에게 두 약을 모두 투여했으므로 대응표본 t-검정을 사용하는 것이 적절하다.

② 유의수준 0.05에서 두 약물의 평균 효과 차이는 통계적으로 유의하다.

③ A 약물의 평균 수면시간 증가량이 B 약물보다 1.58시간 길다.

④ 평균 차이의 95% 신뢰구간은 0을 포함하지 않는다.

정답 ③

평균 차이(A − B)가 −1.58로 음수이므로 A의 증가량은 B보다 1.58시간 짧다. 따라서 ③이 틀렸다. 같은 대상에 두 처리를 적용했으므로 대응표본 검정이 적절하고(①), p-value 0.002833 < 0.05이므로 차이가 유의하며(②), 신뢰구간 [−2.46, −0.70]이 0을 포함하지 않는 것도 같은 결론이다(④). 차이의 부호를 해석할 때는 어느 쪽에서 어느 쪽을 뺐는지 먼저 확인한다.

32. 주성분 분석에 대한 설명으로 적절하지 않은 것은?

① 주성분 분석을 통해 차원을 축소시켜 다중공선성 문제를 해결할 수 있다.

② 제1주성분에서 제2주성분으로 숫자가 커질수록 각 주성분이 설명하는 분산의 크기도 지속 증가한다.

③ 제1주성분은 전체 데이터의 변동을 가장 많이 설명하는 축이다.

④ 일반적으로 고윳값이 1 이상인 주성분만을 선택하거나, 누적 기여율이 70~90% 이상이 되는 지점까지의 주성분을 사용한다.

정답 ②

제1주성분은 가능한 방향 중 분산을 가장 많이 설명하며, 제2주성분은 제1주성분과 직교하는 방향 중 다음으로 많이 설명한다. 따라서 각 주성분의 분산은 번호가 커질수록 감소하거나 같아지고 증가하지 않는다. PCA는 분산 보존을 기준으로 차원을 줄이며, 변수 단위가 크게 다르면 표준화 여부를 검토한다. 직교·무상관을 일반적인 확률적 독립성과 동일시하지 않는다.

33. 프로야구 선수의 연봉(단위: 백만 원)을 종속변수로 하고 타율, 홈런, 경력 등을 설명변수로 한 다중회귀분석 결과의 해석으로 적절하지 않은 것은?

> 주요 결과
> 타율: p-value ≈ 4.8×10^{-5}
> 홈런: 회귀계수 = 8.94, p-value ≈ 4.1×10^{-6}
> 경력: p-value = 0.2052
> 결정계수(R^2) = 0.563

① 타율과 홈런은 유의수준 0.05에서 연봉에 유의한 영향을 미친다.

② 다른 변수가 같을 때 홈런이 1개 증가하면 연봉은 평균 약 894만 원 증가한다.

③ 경력은 유의수준 0.05에서 유의하지 않다.

④ 결정계수가 0.563이므로 이 모형은 연봉 변동의 약 75%를 설명한다.

정답 ④

결정계수 0.563은 표본에서 연봉 변동의 약 56.3%를 모형이 설명한다는 뜻이므로 75%라고 한 ④가 틀렸다. 타율($p \approx 4.8\times10^{-5}$)과 홈런($p \approx 4.1\times10^{-6}$)은 0.05보다 작아 유의하고, 경력($p = 0.2052$)은 유의하지 않다. 홈런 계수 8.94의 단위가 백만 원이므로 8.94백만 원, 즉 약 894만 원이다. 다중회귀 계수는 다른 설명변수를 고정했을 때의 평균 변화로 해석한다.

34. 로지스틱 회귀분석에 대한 설명으로 적절하지 않은 것은?

① 로지스틱 회귀모형의 연결함수로는 시그모이드 함수를 사용한다.

② 합격/불합격과 같은 이진 분류 문제를 해결하는데 적합한 회귀분석이다.

③ 오즈(Odds)는 범주A에 속할 확률을 범주B에 속할 확률로 나눈값이다.

④ 종속변수인 로짓(Logit)과 독립변수는 서로 선형적 관계를 가진다.

정답 ①

일반적인 로지스틱 회귀의 연결함수는 $\text{logit}(p)=\log[p/(1-p)]$이다. 시그모이드 $p=1/(1+\exp(-\eta))$는 선형 예측값 η를 확률로 바꾸는 역연결함수이다. 따라서 연결함수를 시그모이드라고 한 ①이 틀렸다. 오즈는 $p/(1-p)$이고, 로그오즈를 설명변수의 선형 결합으로 모델링한다.

35. 두 숫자형 변수 간의 선형 관계에 대한 설명으로 적절하지 않은 것은?

① 상관계수는 -1 이상, 1 이하의 값을 가지며, 1이나 -1에 가까울수록 두 변수 간의 선형 관계가 강함을 의미한다.

② 0에 가까운 상관계수는 두 변수 사이에 선형적인 관계가 거의 없음을 의미한다.

③ 높은 상관계수가 두 변수 간의 인과관계를 보장하지는 않는다.

④ 상관계수의 부호가 음수라면 두 변수는 서로 반비례 관계로 볼 수 있다.

정답 ④

음의 상관계수는 한 변수가 커질 때 다른 변수가 작아지는 선형 경향을 의미한다. 엄밀한 반비례는 $Y=k/X$ 형태이므로 음의 상관관계만으로 반비례를 확정할 수 없다. 상관계수가 0에 가까워도 비선형 관계가 존재할 수 있으며, 높은 상관관계 역시 인과관계의 증거로 충분하지 않다.

36. 다음 중 분해시계열의 주요 요인(Decomposition Factors)으로 적절하지 않은 것은?

① 추세요인
② 규칙요인
③ 계절요인
④ 순환요인

정답 ②
분해시계열의 대표 요인은 추세·계절·순환·불규칙 요인이다. 규칙요인은 이 목록의 구성 요소가 아니므로 ②가 답이다. 추세는 장기 방향, 계절은 일정한 달력 주기로 반복하는 변동, 순환은 고정 주기가 아닌 장기적 변동, 불규칙은 나머지 우연적 변동으로 구분한다.

37. ChickWeight 데이터에서 사료(Diet, 4종류)에 따른 병아리 체중(weight)의 차이를 일원배치 분산분석으로 검정한 결과이다. 해석으로 적절하지 않은 것은?

분석: aov(weight ~ Diet, data = ChickWeight)
Diet: Df = 3, Sum Sq = 155863, Mean Sq = 51954, F = 10.81, Pr(>F) = 6.43×10^{-7}
Residuals: Df = 574, Sum Sq = 2758693, Mean Sq = 4806

① 귀무가설은 네 사료 집단의 평균 체중이 모두 같다는 것이다.
② 유의수준 0.05에서 사료 집단 간 평균 체중에 차이가 있다고 볼 수 있다.
③ 분산분석 결과만으로 어느 사료 집단 사이에 차이가 있는지 알 수 있다.
④ 구체적으로 어느 집단 간에 차이가 있는지 확인하려면 사후검정이 필요하다.

정답 ③
분산분석의 F검정은 모든 집단의 평균이 같다는 귀무가설을 기각할지만 알려 준다. p-value $6.43 \times 10^{-7} < 0.05$이므로 적어도 한 집단의 평균이 다르다고 판단하지만, 어느 쌍이 다른지는 Tukey HSD 같은 사후검정으로 확인해야 한다. 따라서 ③이 틀렸다. 집단이 4개이므로 처리 자유도는 4 − 1 = 3이다. ChickWeight에는 같은 병아리의 반복 측정이 섞여 있으므로 실제 분석에서는 그 구조도 고려한다.

38. 다음 중 비정상 시계열 데이터를 정상 시계열로 변환하기 위해 사용되는 방법으로 적절한 것은?

① 지수평활법
② 선형 회귀 분석
③ 차분
④ 결측치 처리

정답 ③
추세 때문에 평균이 시간에 따라 달라지는 경우 차분 $\Delta Yt = Yt - Yt-1$을 검토한다. 차분은 연속한 시점의 차이를 이용하여 추세를 제거하는 대표적 변환이다. 지수평활은 예측·평활 기법이고 결측치 처리는 누락값을 다루므로 정상성을 직접 보장하지 않는다. 모든 비정상성을 한 번의 차분으로 해결할 수 있는 것은 아니므로 변환 후 다시 확인한다.

39. 다음 중 데이터 분할 방식에 대한 설명으로 적절하지 않은 것은?

① 훈련용 데이터는 모델이 데이터 패턴을 학습하고 가중치를 조정하는데 사용된다.
② 검증용 데이터는 모델의 과대 및 과소 적합 조정 시 사용된다.
③ 검증용 데이터는 해당 모델의 최종 성능을 평가 시 활용된다.
④ 평가용 데이터는 모델의 객관적인 성능 측정을 위해 학습에 활용되지 않은 데이터이다.

정답 ③
학습 데이터는 모수 학습, 검증 데이터는 모형과 하이퍼파라미터 선택, 테스트 데이터는 선택이 끝난 최종 모형의 성능 평가에 사용한다. 따라서 검증 데이터를 최종 성능 평가용이라고 한 ③이 틀렸다. 테스트 결과를 보며 반복적으로 모형을 선택하면 테스트 정보가 선택 과정에 유입되어 평가가 낙관적으로 편향될 수 있다.

40. 아래 보기에서 데이터 마이닝 추진 단계를 순서대로 나열한 것은?

가. 데이터 준비
나. 목적 정의
다. 기법 적용
라. 데이터 가공
마. 검증

① 가→나→라→다→마
② 나→가→다→라→마
③ 나→가→라→다→마
④ 나→다→가→라→마

정답 ③
목적 정의→데이터 준비→데이터 가공→데이터 마이닝 기법 적용→검증 순서이다. 해결하려는 목적을 먼저 정하고 자료를 확보한 뒤 분석 가능한 형태로 정리하여 모형을 적용한다. 마지막에는 결과가 목적에 부합하는지 평가한다. 실제 프로젝트는 결과에 따라 앞 단계로 돌아갈 수 있지만 문항은 기본 추진 순서를 묻는다.

41. 다음 중 의사결정나무 모델에 대한 설명으로 적절하지 않은 것은?

① 데이터 분류 기준으로는 지니 지수 및 엔트로피, 카이제곱 통계량이 활용된다.
② 연속형 변수인 경우, 의사결정나무 모형은 학습 데이터에 대해 항상 예측 정확도 100%의 모델 구현이 가능하다.
③ 하위 노드로 내려갈수록 데이터 불순도는 점차 감소한다.
④ 불필요한 분기를 제거하는 가지치기를 통해 모델의 일반화 성능을 향상시킬 수 있다.

정답 ②
연속형 반응변수는 회귀나무로 예측하며 분류 정확도 100%라는 표현을 그대로 적용할 수 없다. 자료 중복, 서로 다른 반응값, 분할 제한 등이 있으므로 학습자료를 항상 완벽하게 맞춘다는 보장도 없다. 가지치기는 복잡한 분기를 줄여 과적합을 완화한다. 개별 자식 노드의 불순도가 언제나 더 작다는 절대적 주장보다는 분할의 가중 평균 불순도 감소로 이해한다.

42. 다음 중 인공신경망 모형에서 입력층에서 전달된 신호의 합을 출력값으로 변환하여 다음 층으로 전달하는 함수는?

① 연결 함수
② 활성화 함수
③ 출력 함수
④ 가중치 함수

정답 ②
뉴런은 가중합과 편향을 계산한 뒤 활성화 함수를 적용하여 다음 층에 전달할 값을 만든다. sigmoid·tanh·ReLU 등이 대표적이다. 가중치는 신호의 영향 크기를 조절하는 값이고, 활성화 함수는 계산된 입력을 변환하는 함수이다. 비선형 활성화는 신경망이 복잡한 관계를 표현하는 데 중요한 역할을 한다.

43. 다음 중 변수 간 상관관계를 고려하여 통계적 거리를 측정하는 방법은?

① 유클리드 거리
② 맨해튼 거리
③ 체비셰프 거리
④ 마할라노비스 거리

정답 ④
마할라노비스 거리는 공분산 행렬을 이용하여 변수의 분산과 상관구조를 반영한다. $d^2=(x-\mu)^T\Sigma^{-1}(x-\mu)$이며, 유클리드 거리는 제곱 차이 합의 제곱근, 맨해튼 거리는 절댓값 차이 합, 체비셰프 거리는 최대 절댓값 차이이다. 역행렬 사용에는 공분산 행렬의 가역성 등을 확인해야 한다.

44. 다음 중 아래 설명이 나타내는 모델 성능 평가 지표는?

> 정밀도(Precision)와 재현율(Recall)의 조화평균으로 계산되며, 특히 데이터가 불균형한 상황에서 모델의 성능을 객관적으로 평가할 수 있다.

① 특이도 (Specificity)
② 정확도 (Accuracy)
③ F1-score
④ FP rate

정답 ③
F1=2PR/(P+R)=2TP/(2TP+FP+FN)으로 정밀도와 재현율의 조화평균이다. 정밀도는 양성 예측 중 실제 양성의 비율이고 재현율은 실제 양성 중 찾은 비율이다. 둘 중 하나가 낮으면 F1도 낮아진다. 불균형 자료에서 정확도보다 유용할 수 있지만 TN을 직접 반영하지 않으므로 항상 유일하게 적절한 지표는 아니다. ④ FP rate(위양성률)는 실제 음성 중 양성으로 잘못 예측한 비율 FP/(FP+TN)이다.

45. 연관규칙 분석에서 지지도(Support) 계산방식으로 옳은 것은?

① A를 포함하는 거래 중 A와 B가 동시에 거래되는 비율
② 전체 거래 중 A와 B가 동시에 포함된 거래 비율
③ A가 구매되지 않았을 때 B의 구매확률
④ A가 구매되지 않았을 때 B의 구매확률에 비해, A가 구매되었을 때 B의 구매확률이 증가한 비율

정답 ②
지지도는 전체 거래 중 A와 B가 동시에 발생한 비율 $P(A\cap B)$이다. A 거래를 분모로 쓰는 $P(B|A)$는 신뢰도이다. 지지도와 신뢰도는 분자에 같은 동시 거래 건수가 들어갈 수 있어도 분모가 다르다. 지지도는 규칙의 전체 발생 빈도, 신뢰도는 선행항목 A가 있을 때 후행항목 B의 발생 비율을 나타낸다.

46. '이름'과 '성별'로 구성된 고객 데이터에서 이름 변수와 성별 변수가 독립적으로 각각 10%의 결측값을 가지고 있다. 이 때 이름 또는 성별 중 하나라도 결측값이 존재하는 고객 데이터를 모두 삭제 시 전체 데이터 중 삭제되는 데이터의 비중은?

① 10%
② 15%
③ 19%
④ 23%

정답 ③
삭제되지 않으려면 두 항목 모두 관측되어야 한다. 결측이 독립이므로 완전한 행의 비율은 0.9×0.9=0.81이며 삭제 비율은 1−0.81=0.19이다. 합사건 공식으로도 0.1+0.1−0.1×0.1=0.19이다. 20%로 단순 합산하면 두 항목 모두 결측인 1%를 중복 계산한다. 19%는 이 가정하의 기대 비율이다.

47. 두 군집이 합쳐졌을 때 군집 내 오차 제곱합(SSE)이 가장 적게 증가하는 방향으로 병합되는 군집분석 연결법은?

① 중심 연결법
② 완전 연결법
③ 와드 연결법
④ 평균 연결법

정답 ③
와드 연결법은 두 군집을 합칠 때 군집 내 제곱합이 증가하는 정도를 계산하고 그 증가량이 최소인 쌍을 선택한다. 평균 연결법은 군집 간 관측값 거리의 평균, 완전 연결법은 가장 먼 거리, 중심 연결법은 중심 간 거리 등을 이용한다. 와드법은 보통 제곱 유클리드 거리와 연결되므로 단순히 최소 관측값 거리로 합친다는 설명과 구별한다.

48. 정형 데이터의 구조를 탐색할 때 반응변수 없이 적용할 수 있는 기법은?

① 로지스틱 회귀분석
② 의사결정나무 분류
③ K-평균 군집분석
④ 선형회귀분석

정답 ③
K-평균은 정답 라벨이나 반응변수 없이 유사한 관측값을 K개의 군집으로 묶는 비지도학습이다. 나머지 보기는 반응변수를 이용하는 지도학습 기법이다. 로지스틱 회귀와 의사결정나무 분류는 범주 예측, 선형회귀는 수치 예측에 사용한다. 군집 번호는 실제 정답 라벨을 자동으로 알아낸 결과가 아니라 분석 후 해석할 그룹이다.

49. 아래 품목별 거래 건수 테이블에서 연관규칙 A → B의 신뢰도는?

품목	구매건수
A	100
B	50
C	150
A, C	150
A, D	50
A, B, C	200
A, B, C, D	100
B, C, D	100

① 40 %

② 50 %

③ 60 %

④ 65 %

정답 ②

신뢰도(A→B)=A와 B 동시 거래 수/A 거래 수이다. A 거래는 A 100+A,C 150+A,D 50+A,B,C 200+A,B,C,D 100=600건이다. 그중 B도 포함한 거래는 200+100=300건이므로 300/600=0.5=50%이다. 표의 전체 거래는 900건이므로, 전체를 분모로 쓰면 지지도 300/900 ≈ 33.3%가 된다. 이를 신뢰도와 혼동하지 않는다. A를 포함하지 않은 거래는 신뢰도 분모에 넣지 않는다.

50. 다음 중 향상도(Lift)에 대한 설명으로 적절한 것은?

① 향상도는 'A와 B가 각각 독립적으로 일어날 확률의 곱'을 'A와 B가 동시에 일어날 확률'로 나누어 계산된다.

② 향상도가 1보다 크면 해당 규칙은 양의 상관성을 가진다.

③ 향상도가 0일 때, 두 거래품목 간에는 상관성이 없다.

④ 향상도가 0보다 작을 때, 음의 상관성을 가진다.

정답 ②

향상도=P(A∩B)/[P(A)P(B)]=P(B|A)/P(B)이다. 1보다 크면 독립일 때보다 함께 발생할 비율이 높고, 1이면 독립 기준과 같으며, 1보다 작으면 함께 발생할 비율이 낮다. 정의되는 경우 음수가 될 수 없다. ①은 비율을 거꾸로 적었고 ③은 독립 기준을 0으로 혼동했으며 ④도 불가능한 음수 값을 설명한다. 향상도가 높아도 충분한 거래 수와 실무적 의미를 추가로 검토해야 한다.