ADsP 제49회 기출 복원문제

유형 2

정답·해설 수록본

총 50문항 · 4지선다 · 90분

1과목 데이터 이해 (1~10번)

1. 데이터 웨어하우스(DW)와 데이터 마트(DM)에 대한 설명으로 옳은 것은?

① 데이터 마트는 전사의 모든 데이터를 통합하여 저장하는 중앙 저장소이다.

② 데이터 웨어하우스와 데이터 마트를 구분하는 기준은 제공자의 기능 및 제공 범위이다.

③ 데이터 마트는 데이터 웨어하우스에서 특정 부서나 주제 영역의 분석 목적에 맞게 추출한 부분집합이다.

④ 데이터 웨어하우스는 단기적인 운영 거래를 실시간으로 처리하기 위한 OLTP 시스템이다.

정답 ③

③은 데이터 웨어하우스에서 특정 부서나 주제의 데이터를 추출하는 종속형 데이터마트에 대한 옳은 설명이다. 전사 데이터를 통합 저장하는 것은 데이터 웨어하우스이며, OLTP는 운영 거래 처리에 초점을 둔다. 데이터마트에는 DW에 의존하지 않고 별도로 구축하는 독립형도 있으므로 모든 데이터마트를 DW의 부분집합으로만 정의해서는 안 된다.

2. 다음 중 암묵지를 형식지로 전환하는 과정에 해당하는 것은?

① 표출화(Externalization)

② 공통화(Socialization)

③ 내면화(Internalization)

④ 연결화(Combination)

정답 ①

지식 변환(SECI) 모델에서 암묵지 → 형식지는 표출화이다. 공통화는 암묵지 → 암묵지, 연결화는 형식지 → 형식지, 내면화는 형식지 → 암묵지이다.

3. 데이터, 정보, 지식에 대한 설명으로 옳지 않은 것은?

① 데이터는 가공하면 곧바로 지식이 된다.

② 데이터는 관찰이나 측정을 통해 수집한 객관적 사실이다.

③ 정보는 데이터를 가공·처리하여 의미를 부여한 것이다.

④ 지식은 정보를 구조화하고 경험과 맥락을 결합하여 판단에 활용할 수 있게 한 것이다.

정답 ①

데이터를 가공·처리하면 '정보'가 되고, 정보를 구조화하여 유의미한 규칙을 찾아 내재화한 것이 '지식'이다. 데이터가 곧바로 지식이 되는 것이 아니므로 ①이 틀리다.

4. 다음 중 DIKW 피라미드의 분류가 나머지와 다른 하나는?

① 8월 반도체 총매출 중 내수 판매가 차지하는 비중은 32%이다.

② 이 제품은 날씨가 더워질수록 잘 팔리므로, 여름철 재고를 미리 늘려두는 것이 좋다.

③ 최근 강수량이 늘어 우산 매출이 증가했으므로, 장마철에 맞춰 우산을 매장 입구에 배치한다.

④ 금리가 오르면 대출 수요가 줄어드는 경향이 있으므로, 금리 인상기에는 보수적으로 자금을 운용한다.

정답 ①

①은 매출 자료를 가공해 내수 비중이라는 의미를 얻은 정보(Information)이다. ②·③·④는 관계나 패턴을 해석하고 행동 방안을 제안하는 설명이므로 단순한 정보인 ①과 구별된다. 행동·전략을 포함한 사례는 교재의 분류 방식에 따라 지식 또는 지혜의 경계에서 설명될 수 있으므로 나머지를 모두 지식으로 단정하지 않는다.

5. 데이터베이스의 다양한 측면 중 '정보관리 측면'의 특징으로 가장 적절한 것은?

① 원격지에서 네트워크를 통해 접속하여 정보를 이용할 수 있다.

② 사용자가 필요로 할 때 언제든지 원하는 정보를 이용할 수 있다.

③ 정보를 체계적으로 축적하고 전달하는 데 중점을 둔다.

④ 일정한 구조에 따라 데이터를 저장하며, 저장된 데이터는 갱신 및 수정이 가능하다.

정답 ④

정답 의도는 ④이다. 정보관리 측면에서는 일정한 질서와 구조에 따라 정보를 정리·저장·검색·갱신하는 특징에 주목한다. ①은 원격조작성, ②는 이용 시점의 접근성, ③은 축적·전달에 초점을 둔 표현이다. 다만 ③의 체계적 축적은 정보관리와도 의미가 겹칠 수 있어 이 문항의 구분은 교재상 분류 맥락에서 해석해야 한다.

6. 데이터베이스 및 DBMS에 대한 설명으로 옳지 않은 것은?

① DBMS는 사용자와 데이터베이스 사이에서 데이터의 저장·검색·관리를 담당하는 소프트웨어이다.

② 데이터베이스는 여러 사용자가 데이터를 동시에 공유하여 사용할 수 있다.

③ 데이터베이스는 자료의 종류와 관계없이 항상 2차원 테이블 구조로만 구성된다.

④ 데이터베이스는 데이터의 중복을 최소화하여 일관성을 유지하려는 통합된 데이터의 집합이다.

정답 ③

데이터베이스는 관계형(2차원 테이블)뿐 아니라 계층형, 네트워크형, 객체지향형, NoSQL(문서·키-값·그래프) 등 다양한 구조로 구성될 수 있다. ①·②·④는 DBMS의 역할, 공용 데이터, 통합 데이터에 대한 옳은 설명이다.

7. OLTP와 OLAP에 대한 설명으로 옳은 것은?

① OLTP는 장기간 축적된 데이터를 바탕으로 비정형적인 의사결정 분석을 수행한다.

② OLAP는 다차원 데이터를 다양한 관점에서 분석하는 것을 주된 목적으로 한다.

③ OLTP는 비정형 데이터만, OLAP는 정형 데이터만 처리할 수 있다.

④ OLAP는 실시간으로 발생하는 거래(트랜잭션)를 신속하게 처리하는 데 최적화되어 있다.

정답 ②

OLAP는 다차원 데이터를 여러 관점에서 분석하여 의사결정을 지원하는 것이 목적이다. ① 장기간 축적된 데이터로 의사결정 분석을 수행하는 것은 OLTP가 아니라 OLAP이다. ③ 두 방식 모두 주로 정형 데이터를 다룬다. ④ 실시간 거래(트랜잭션) 처리에 최적화된 것은 OLTP이다.

8. 빅데이터 시대의 위기 요인과 그에 대한 통제 방안에 대한 설명 중 옳은 것을 모두 고른 것은?

가. 데이터 익명화는 사생활 침해의 근본 요인을 완전히 차단할 수 있으므로, 익명화 기술의 빠른 발전만으로 문제를 해결할 수 있다.
나. 책임 원칙 훼손에 대한 통제 방안으로, 예측에 근거한 처벌이 아니라 행위의 결과에 따라 책임을 묻는 '결과 기반 책임 원칙'을 적용해야 한다.
다. 사생활 침해 문제의 통제 방안으로, 데이터 사용자가 활용 결과에 책임지는 '책임제'에서 개인정보 활용에 대한 '동의제'로 전환해야 한다.
라. 데이터 오남용의 폐해는 정보 주체 본인이 스스로 감수하면 되므로 별도의 통제 장치는 필요하지 않다.
마. 데이터의 오용을 막기 위해 알고리즘의 부작용을 분석·중재하는 전문가인 '알고리즈미스트'를 활용할 수 있다.

① 가, 나

② 나, 마

③ 다, 라

④ 나, 다, 마

정답 ②

나(책임 원칙 훼손 → 결과 기반 책임 원칙)와 마(데이터 오용 → 알고리즈미스트 활용)가 옳다. 가는 익명화만으로 사생활 침해를 완전히 차단할 수 없으므로 틀리다. 다는 방향이 반대이다. 사생활 침해의 통제 방안은 '동의제'에서 '책임제'로 전환하는 것이다. 라는 통제 장치가 필요하므로 틀리다.

9. 다음 데이터 크기 단위를 작은 것부터 큰 것 순으로 올바르게 나열한 것은?

① 페타바이트(PB) < 엑사바이트(EB) < 제타바이트(ZB) < 요타바이트(YB)

② 엑사바이트(EB) < 페타바이트(PB) < 제타바이트(ZB) < 요타바이트(YB)

③ 페타바이트(PB) < 제타바이트(ZB) < 엑사바이트(EB) < 요타바이트(YB)

④ 테라바이트(TB) < 엑사바이트(EB) < 페타바이트(PB) < 제타바이트(ZB)

정답 ①

데이터 크기 단위는 KB < MB < GB < TB < PB < EB < ZB < YB 순으로 커진다.

10. 생물의 진화 과정(선택·교배·돌연변이)을 모방하여 여러 해 중에서 점진적으로 최적의 해를 찾아가는 분석 기법은?

① 유전자 알고리즘(Genetic Algorithm)

② 인공신경망(Artificial Neural Network)

③ 의사결정나무(Decision Tree)

④ 회귀분석(Regression Analysis)

정답 ①

유전자 알고리즘은 선택·교배·돌연변이 등 생물의 진화 과정을 모방하여 세대를 거치며 최적해를 찾아가는 최적화 기법이다.

2과목 데이터 분석 기획 (11~20번)

11. 분석 주제 유형은 '분석 대상(What)'과 '분석 방법(How)'을 알고 있는지 여부에 따라 구분된다. 다음 설명 중 옳지 않은 것은?

① 분석 대상은 알지만 분석 방법을 모르는 경우는 솔루션(Solution) 유형이다.

② 분석 대상과 분석 방법을 모두 아는 경우는 솔루션(Solution) 유형이다.

③ 분석 대상은 모르지만 분석 방법을 아는 경우는 통찰(Insight) 유형이다.

④ 분석 대상과 분석 방법을 모두 모르는 경우는 발견(Discovery) 유형이다.

정답 ②

분석 대상과 방법을 모두 아는 경우는 최적화(Optimization) 유형이다. 대상만 알면 솔루션(Solution), 방법만 알면 통찰(Insight), 둘 다 모르면 발견(Discovery)이다.

12. 빅데이터 분석 방법론의 평가 및 전개(Deploying) 단계에 대한 설명으로 옳지 않은 것은?

① 프로젝트의 성과를 평가·정리하고 분석 프로젝트를 종료한다.

② 시스템 구현 계획만 수립하고 운영·모니터링 계획은 고려하지 않는다.

③ 모델 발전 계획을 수립하여 차기 분석 기획에 반영한다.

④ 단순 분석 보고서로 종료되는 과제는 시스템 구현 단계를 거치지 않고 평가 및 전개 단계를 수행할 수 있다.

정답 ②

평가 및 전개 단계에서는 모델 발전 계획 수립과 프로젝트 평가 및 보고를 수행한다. 모델의 생명주기를 정하고 주기적인 평가·유지보수(모니터링) 방안을 마련해야 하므로 ②가 틀리다. ④ 시스템 구현 단계는 필요한 경우에만 수행하며, 보고서로 끝나는 과제는 데이터 분석 단계에서 바로 평가 및 전개 단계로 넘어간다.

13. 위험을 최소화하기 위해 단계마다 위험 분석 과정을 포함하며, 위험 부담이 큰 대규모 프로젝트에 적합한 소프트웨어 개발 모델은?

① 폭포수 모형(Waterfall Model)

② 프로토타이핑 모형(Prototyping Model)

③ 나선형 모형(Spiral Model)

④ KDD 모형

정답 ③

나선형 모형은 반복 개발 과정마다 위험 분석을 수행하여 위험을 최소화하는 모델로, 대규모·고위험 프로젝트에 적합하다.

14. 정확도(Accuracy)와 정밀도(Precision)에 대한 설명으로 옳지 않은 것은?

① 모델의 안정성 측면에서는 정확도가 정밀도보다 더 중요하다.

② 정확도는 실제값과 예측(측정)값의 차이가 작은 정도를 의미한다.

③ 정밀도는 여러 번 반복 측정했을 때 결과가 일관되게 나오는 정도를 의미한다.

④ 분석 모형의 활용 목적에 따라 정확도와 정밀도 중 무엇을 우선할지 달라질 수 있다.

정답 ①

①이 틀리다. 이 문항은 측정·분석 기획 맥락의 정확도와 정밀도를 비교한다. 정확도는 측정 또는 예측 결과가 실제값에 가까운 정도이고, 정밀도는 반복 결과가 일관되게 모이는 정도이다. 안정성을 설명할 때는 정밀도에 주목한다. 여기서 Precision은 이진 분류의 정밀도 TP/(TP+FP)와 문맥이 다르며, 정확도·정밀도의 우선순위는 목적에 따라 달라진다.

15. 다음은 상향식 접근 방식(Bottom-up Approach)에 대한 설명이다. 빈칸 (ㄱ)과 (ㄴ)에 들어갈 용어로 가장 적절한 것은?

> 상향식 접근 방식은 명확한 문제 정의에서 출발하는 하향식과 달리, 데이터를 먼저 탐색하면서 의미 있는 (ㄱ)을(를) 통해 새로운 (ㄴ)을(를) 얻어가는 방식이다. 즉 데이터 자체로부터 패턴을 찾아내며 분석을 진행한다.

① ㄱ: 발견(Discovery) / ㄴ: 통찰(Insight)

② ㄱ: 정의(Definition) / ㄴ: 검증(Validation)

③ ㄱ: 통찰(Insight) / ㄴ: 정의(Definition)

④ ㄱ: 검증(Validation) / ㄴ: 발견(Discovery)

정답 ①

상향식 접근은 문제 정의가 어려울 때 데이터를 먼저 탐색하여 '발견(Discovery)'을 통해 '통찰(Insight)'을 얻는 방식이다.

16. 하향식 접근 방식(Top-down Approach)에 대한 설명으로 가장 적절한 것은?

① 문제를 정의하지 않고 데이터 조합을 반복하여 통찰을 찾는다.

② 비지도 학습으로 발견한 패턴만으로 분석 과제를 확정한다.

③ 인식된 문제나 전략으로부터 분석 대상(What)을 정의하고 해결 방안을 탐색한다.

④ 분석 대상과 방법을 모두 모르는 발견(Discovery) 유형에만 적용된다.

정답 ③

하향식 접근은 문제가 주어졌을 때 무엇(What)을 분석할지 먼저 정의하고, 문제 탐색 → 문제 정의 → 해결 방안 탐색 → 타당성 검토 순으로 과제를 도출한다. ①·②는 데이터에서 출발하는 상향식 접근의 설명이고, ④의 발견 유형은 상향식 접근이 적합한 경우이다.

17. 데이터 분석의 하향식·상향식 접근 방식에 대한 설명으로 적절하지 않은 것은?

① 상향식 접근은 데이터를 탐색하며 발견(Discovery)에서 통찰(Insight)로 나아가는 과정을 거친다.

② 상향식 접근은 전통적인 문제 분석 방식을 비판하기 위해 등장한 방법론이다.

③ 하향식 접근은 무엇(What)이 문제인지를 먼저 정의하는 데 중심을 둔다.

④ 하향식 접근은 명확히 정의되지 않은 새로운 문제를 탐색하는 데에는 한계가 있다.

정답 ②

상향식 접근은 기존 하향식 접근의 한계를 '극복·보완'하기 위한 방법이지, 전통적 방식을 비판하기 위해 등장한 것이 아니다. ① 상향식은 발견에서 통찰로 나아가고, ③·④ 하향식은 문제가 주어졌을 때 이를 먼저 정의하고 해법을 찾는 방식이라 새로운 문제 탐색에는 한계가 있다.

18. 데이터 분석 과제를 중장기적 관점에서 수행하기 위한 분석 마스터플랜 수립 방법으로 가장 적절한 것은?

① 정보전략계획(ISP)을 통해 중장기 마스터플랜을 수립한다.

② 개별 과제 단위로 분석을 곧바로 적용(분석 적용)한다.

③ 구성원이 분석을 일상 업무로 받아들이도록 내재화한다.

④ 분석 결과를 전사로 비즈니스 확산시킨다.

정답 ①

분석 마스터플랜은 정보전략계획(ISP) 방법론을 활용하여 중장기 관점에서 수립한다. ②·③·④는 마스터플랜 수립 방법이 아니라 분석 적용·내재화·확산 단계의 활동이다.

19. 다음 설명에 해당하는 데이터 분석 조직 구조로 가장 적절한 것은?

> 전사의 분석 업무를 별도의 분석 전담 조직에서 총괄하여 수행한다. 이로 인해 분석 전담 조직과 현업 부서 사이에 업무가 이원화되거나 중복·갈등이 발생할 수 있다.

① 집중 구조

② 기능 구조

③ 분산 구조

④ 매트릭스 구조

정답 ①

집중 구조는 전사 분석 업무를 별도의 전담 조직(DSCoE)이 담당하며, 현업 부서와 분석 업무가 이원화·중복될 가능성이 있다. 기능 구조는 각 부서가 직접 분석을 수행하고, 분산 구조는 전담 조직 인력을 현업 부서에 배치한다.

20. 협의의 분석 플랫폼 구성요소에 포함되지 않는 것은?

① 데이터 처리 프레임워크

② 분석 엔진

③ 분석 라이브러리

④ 운영체제(OS)

정답 ④

협의의 분석 플랫폼은 데이터 처리 프레임워크, 분석 엔진, 분석 라이브러리로 구성된다. 운영체제와 하드웨어, 분석 애플리케이션, 분석 서비스 제공 엔진·API는 광의의 분석 플랫폼에 포함된다.

3과목 데이터 분석 (21~50번)

21. 두 연속형 변수 사이의 관계를 한눈에 파악하기에 가장 적절한 그래프는?

① 막대그래프
② 산점도
③ 원그래프
④ 상자그림

> **정답 ②**
> 산점도는 두 연속형 변수를 가로축과 세로축에 놓고 점으로 나타내어 관계의 방향과 강도, 선형성, 이상값을 한눈에 볼 수 있다.
> 막대그래프와 원그래프는 범주형 자료의 빈도·비율을, 상자그림은 한 변수의 분포를 요약하는 데 쓴다.

22. 가설검정에 대한 설명으로 옳지 않은 것은?

① 귀무가설(H_0)은 일반적으로 '차이가 없다' 또는 '효과가 없다'를 의미하는 기본 가설이다.
② 유의수준(α)은 귀무가설이 참인데도 기각하는 제1종 오류의 허용 확률이다.
③ 대립가설(H_1)은 연구자가 주장하거나 입증하고자 하는 가설이다.
④ p-value가 유의수준보다 크면(높으면) 귀무가설을 기각한다.

> **정답 ④**
> p-value가 유의수준보다 '작을' 때 귀무가설을 기각한다.
> 유의수준보다 크면 귀무가설을 기각하지 못한다.

23. 다음 확률 및 확률분포에 대한 설명 중 옳지 않은 것은?

① 배반사건(서로소)인 두 사건은 독립사건이 아닐 수 있다.
② 독립사건인 두 사건은 배반사건이 아닐 수 있다.
③ 연속확률분포에서 확률밀도함수(PDF)의 함숫값은 항상 0과 1 사이의 값을 갖는다.
④ 이산확률분포에서 확률질량함수(PMF)의 함숫값은 0과 1 사이의 값을 갖는다.

> **정답 ③**
> 확률밀도함수의 함숫값은 0 이상이기만 하면 되고 1보다 클 수 있다 (예: 구간 [0, 0.5]의 균등분포는 f(x) = 2). 1이 되어야 하는 것은 전체 면적이다. ①·② 확률이 0보다 큰 두 사건이 배반이면 독립이 아니고, 독립인 두 사건은 동시에 일어날 수 있으므로 배반이 아닐 수 있다.

24. 회귀 모형에 대한 설명으로 옳지 않은 것은?

① 회귀계수는 일반적으로 최소제곱법(OLS)으로 추정한다.
② 모형의 설명력은 −1에서 1 사이의 값을 갖는 결정계수(R^2)로 평가한다.
③ 잔차 분석을 통해 정규성·등분산성 등 모형의 가정을 점검한다.
④ 결정계수(R^2)가 1에 가까울수록 모형의 설명력이 높다.

> **정답 ②**
> ②가 틀리다. 절편을 포함한 일반적인 최소제곱회귀를 학습 자료에서 평가하면 결정계수 R^2는 0~1이다. −1~1은 상관계수의 범위이다.
> 다만 테스트 자료에서 계산한 R^2나 절편 없는 모형 등에서는 음수가 나올 수 있으므로 R^2가 항상 0~1이라고 단정하지 않는다. 잔차 분석은 오차항의 정규성·등분산성 등 가정을 점검하는 데 활용한다.

25. 표본 추출 방법에 대한 설명으로 틀린 것은?

① 계통 추출법은 첫 표본을 무작위로 정한 뒤 일정한 간격으로 표본을 추출한다.
② 층화 추출법은 모집단을 동질적인 여러 집단(층)으로 나눈 후 각 층에서 표본을 추출한다.
③ 집락(군집) 추출법은 각 집락의 내부가 동질적이도록 구성하여 추출한다.
④ 단순 무작위 추출법은 모든 표본이 뽑힐 확률이 동일하도록 임의로 추출한다.

> **정답 ③**
> ③이 틀리다. 층화추출은 층 내부가 동질적이고 층 사이가 이질적이도록 구분한 뒤 각 층에서 표본을 뽑는다. 집락추출은 모집단을 집락으로 나누고 일부 집락을 선택하여 조사하는 방식이다. 효율적인 집락 설계에서는 집락 내부가 모집단처럼 이질적이고 집락 간 특성이 비슷한 것이 이상적이다. 이는 설계의 바람직한 성질이며 현실의 모든 집락이 반드시 이 조건을 만족한다는 뜻은 아니다.

26. 이상값(Outlier)에 대한 설명으로 옳지 않은 것은?

① 이상값은 입력 오류, 측정 오류, 표본추출 오차 등 다양한 원인으로 발생할 수 있다.
② 이상값은 일반적으로 데이터 전처리 단계에서 탐색하고 처리한다.
③ 사분위수 범위(IQR)나 상자그림(Box plot), 산점도 등을 이용해 이상값을 판별할 수 있다.
④ 이상값은 분석 결과를 왜곡하므로 발견되면 반드시 모두 제거해야 한다.

> **정답 ④**
> 이상값이 항상 오류인 것은 아니며 의미 있는 정보를 담고 있을 수 있다(예: 이상 거래 탐지). 원인과 분석 목적에 따라 제거, 대체, 변환, 유지 중에서 선택한다.

27. 확률변수 X가 1, 2, 3의 값을 가지며 P(X=1) = 1/6, P(X=2) = 1/2, P(X=3) = 1/3이다. X의 기댓값으로 옳은 것은?

① 2
② 7/6
③ 11/6
④ 13/6

> **정답 ④**
> 확률의 합은 1/6+1/2+1/3=1이다.
> $E(X)=\Sigma x P(X=x)=1\times(1/6)+2\times(1/2)+3\times(1/3)=13/6$이므로 정답은 ④이다.

28. 어떤 변수 x를 y = ax + b (단, a > 0)로 선형변환했을 때, 다음 통계량 중 그 값이 변하지 않는 것은?

① 왜도(Skewness)
② 표준편차
③ 평균
④ 중앙값

> **정답 ①**
> 왜도는 표준화된 값의 세제곱 평균이므로 a > 0인 선형변환에서 변하지 않는다. 평균과 중앙값은 a배 후 b만큼 이동하고, 표준편차는 a배가 된다.

29. 두 변수 x와 y의 상관계수가 0.2일 때, −2x + 1과 y − 1의 상관계수는?

① -0.2
② 0.2
③ 0.4
④ -0.4

> **정답 ①**
> 상관계수는 각 변수에 상수를 더해도 변하지 않고, 양수를 곱해도 변하지 않으며, 음수를 곱하면 부호만 바뀐다. x에 −2가 곱해졌으므로 상관계수는 −0.2이다.

30. 분산분석에 대한 다음 설명의 참·거짓을 순서대로 바르게 나타낸 것은?

> ㄱ. 이원분산분석은 독립변수(요인)가 하나일 때만 사용하는 분석 방법이다.
> ㄴ. 두 집단만 비교하는 특수한 경우 F통계량은 t통계량의 제곱과 같다.

① 참, 참
② 참, 거짓
③ 거짓, 참
④ 거짓, 거짓

> **정답 ③**
> ㄱ은 거짓이다. 이원분산분석은 요인이 두 개이며, 하나이면 일원분산분석이다. ㄴ은 동일한 자료·동일한 가정의 두 독립 집단 평균 비교에서 참이다. 등분산 독립표본 t검정과 두 집단 일원분산분석은 $F=t^2$ 관계를 갖는다. 모든 F검정과 모든 t검정에 적용되는 관계는 아니다. 출제 의도에 따라 거짓, 참인 ③을 고른다.

31. 시계열의 정상성(Stationarity)에 대한 설명으로 옳지 않은 것은?

① 시계열 데이터의 각 관측값은 서로 독립이다.
② 평균이 모든 시점에서 일정하다.
③ 분산이 모든 시점에서 일정하다.
④ 공분산은 특정 시점에 의존하지 않고 시차(time lag)에만 의존한다.

> **정답 ①**
> 정상성의 조건은 평균이 일정하고, 분산이 일정하며, 공분산이 시점이 아닌 시차에만 의존하는 것이다. 관측값 간의 독립은 조건이 아니며, 시계열 자료는 일반적으로 자기상관을 가진다.

32. 다음 상자그림 요약에 대한 설명으로 옳지 않은 것은?

어떤 수면제를 복용한 20명의 '수면시간 증가량(시간)'을 측정하여 상자그림으로 요약한 결과는 다음과 같다.

최솟값	Q1	중앙값(Q2)	Q3	최댓값
−1.0	0.0	1.2	2.5	4.0

① 수면시간 증가량의 최댓값은 4.0시간이다.
② 적어도 절반(50%)의 사람은 수면시간이 1.2시간 이상 증가했다.
③ 일부 사람은 수면시간이 오히려 감소(증가량이 음수)하였다.
④ 정확히 5명의 수면시간이 감소하였다.

> **정답 ④**
> ④가 틀리다. 요약표는 상자그림의 다섯 수치(최솟값·Q1·중앙값·Q3·최댓값)이다. 최댓값 4.0과 최솟값 −1.0에서 ①·③을 확인할 수 있다. 20개 자료의 통상적인 중앙값이 1.2라면 절반 이상은 1.2 이상이므로 ②도 맞다. Q1=0.0이라는 사실만으로 음수인 관측값이 정확히 5개라고 단정할 수 없다. 사분위수 계산법과 경계값에 동률이 있는지에 따라 해석도 달라질 수 있다.

33. 다음 중 분류(Classification) 모형에 해당하지 않는 것은?

① 다중 회귀분석
② 인공신경망
③ 의사결정나무
④ 로지스틱 회귀분석

> **정답 ①**
> 다중 회귀분석은 연속형 종속변수를 예측하는 회귀 모형이다. 인공신경망, 의사결정나무, 로지스틱 회귀분석은 범주형 종속변수의 분류에 사용할 수 있다.

34. 다음은 어떤 변수의 사분위수이다. 1.5 × IQR 기준의 이상값 판정에 대한 설명으로 옳지 않은 것은?

> Q1 = 12, Q3 = 16

① IQR은 Q3 − Q1이므로 4이다.
② 이상값의 하한은 Q1 + 1.5 × IQR, 상한은 Q3 − 1.5 × IQR로 계산한다.
③ 이상값의 하한은 6, 상한은 22이다.
④ 6보다 작거나 22보다 큰 값은 이상값으로 판정할 수 있다.

> **정답 ②**
> IQR=Q3−Q1=16−12=4이다. 하한 울타리는 Q1−1.5IQR=6, 상한 울타리는 Q3+1.5IQR=22이다. 하한보다 작거나 상한보다 큰 값이 이상값 후보이며 경계와 같은 값은 이 기준으로 제외하지 않는다. ②는 부호를 뒤집었으므로 틀리다.

35. 시계열의 구성요소와 해당 요인의 연결이 잘못된 것은?

① 추세 요인 - 장기적인 변동 요인
② 순환 요인 - 중장기적인 변동 요인
③ 계절 요인 - 단기적(계절적) 변동 요인
④ 불규칙 요인 - 장기적인 변동 요인

> **정답 ④**
> 불규칙 요인은 추세·순환·계절 요인으로 설명되지 않는 우연한 단기적 변동이다. 장기적인 변동은 추세 요인이다.

36. 다차원척도법(MDS, Multidimensional Scaling)에 대한 설명으로 옳지 않은 것은?

① 개체들 간의 거리(유사성)를 바탕으로 개체를 저차원 공간에 시각화한다.
② 계량적 MDS는 비율척도나 구간척도로 측정된 데이터를 이용한다.
③ 비계량적 MDS는 순서척도로 측정된 데이터를 이용한다.
④ 개체 간 비유사성을 기준으로 동질적인 그룹(군집)을 형성하는 것이 목적이다.

정답 ④
다차원척도법은 개체 간 거리(비유사성)를 보존하면서 개체를 저차원 공간의 점으로 표현하여 상대적 위치와 구조를 시각화하는 기법이다. 동질적인 그룹을 형성하는 것은 군집분석의 목적이다.

37. 표본오차와 비표본오차에 대한 설명으로 옳지 않은 것은?

① 표본오차는 표본이 모집단을 완전히 대표하지 못해 발생하는 오차이다.
② 일반적으로 표본 크기를 늘리면 표본오차는 줄어드는 경향이 있다.
③ 비표본오차는 조사·입력·집계 과정의 실수 등으로 발생하는 오차이다.
④ 비표본오차는 표본 크기를 늘릴수록 함께 줄어든다.

정답 ④
비표본오차는 조사 설계, 응답, 입력, 집계 과정의 잘못으로 생기는 오차이므로 표본 크기를 늘려도 줄지 않으며, 조사 규모가 커지면 오히려 늘어날 수 있다.

38. 다음 중 데이터 분석 기법에 대한 설명으로 옳지 않은 것은?

① 회귀분석은 변수들 간의 관계를 분석하여 값을 예측하는 데 활용된다.
② 군집분석은 미래의 값을 예측하기 위한 대표적인 예측 기법이다.
③ 연관분석은 항목들이 함께 발생하는 규칙(관계)을 찾는 기법이다.
④ 분류분석은 데이터를 사전에 정의된 범주(class)로 나누는 기법이다.

정답 ②
군집분석은 유사한 개체끼리 집단으로 묶는 비지도 학습 기법으로, 미래 값을 예측하는 기법이 아니다. 예측에는 회귀분석이나 시계열분석 등을 사용한다.

39. 다음 중 이산형 확률분포가 아닌 것은?

① 이항분포(Binomial)
② 초기하분포(Hypergeometric)
③ 기하분포(Geometric)
④ 지수분포(Exponential)

정답 ④
지수분포는 사건 사이의 대기 시간을 나타내는 연속형 확률분포이다. 이항분포, 초기하분포, 기하분포는 모두 이산형 확률분포이다.

40. 앙상블(Ensemble) 학습에 대한 설명으로 옳은 것은?

① 앙상블은 하나의 단일 모형만을 정교하게 학습시켜 성능을 높이는 방법이다.
② 배깅(Bagging)과 부스팅(Boosting)은 대표적인 앙상블 기법이다.
③ 랜덤 포레스트는 앙상블이 아닌 단일 의사결정나무 모형이다.
④ 앙상블 모형은 항상 개별 모형보다 결과 해석이 쉽다.

정답 ②
②가 옳다. 앙상블은 여러 모델을 결합하는 방법이며 배깅과 부스팅이 대표적이다. 랜덤 포레스트는 부트스트랩 표본과 특성 무작위 선택 등을 사용하는 트리 앙상블이다. 여러 모델을 결합하면 일반화 성능이 개선될 수 있지만 항상 개선되는 것은 아니다. 해석의 용이성도 모델 종류에 따라 다르므로 항상 개별 모델보다 쉽다는 ④는 틀리다.

41. 서포트 벡터 머신(SVM)에 대한 설명으로 옳지 않은 것은?

① 두 클래스 사이의 마진(margin)을 최대화하는 초평면(hyperplane)을 찾아 분류한다.
② 서포트 벡터는 결정 경계(초평면)에 가장 가까이 위치한 데이터 포인트이다.
③ 커널 함수는 고차원 데이터를 저차원으로 변환하여 계산을 단순화하는 역할을 한다.
④ 선형으로 분리되지 않는 데이터도 커널 기법을 이용하면 분류할 수 있다.

정답 ③
③이 틀리다. 커널은 특징 공간에서의 내적을 원래 입력을 이용해 계산하는 함수이며 비선형 결정 경계를 구성하는 데 활용된다. 고차원 데이터를 저차원으로 축소하는 기법으로 설명하면 안 된다. 고차원 특징을 명시적으로 모두 생성해야 하는 것도 아니다. 서포트 벡터는 결정 경계를 정하는 데 기여하는 표본이며, 하드 마진에서는 마진 경계에 위치하고 소프트 마진에서는 마진 내부나 오분류된 표본도 포함될 수 있다.

42. 결측값(Missing Value) 처리에 대한 설명으로 옳지 않은 것은?

① 완전 분석법(Complete Case)은 결측값이 포함된 행(케이스)을 제거하고 분석한다.
② 평균 대치법은 결측값을 해당 변수의 평균값으로 채워 넣는다.
③ 단순 대치법은 결측값을 하나의 추정치로 대체하는 방법이다.
④ 완전 분석법은 결측값을 평균으로 대치하여 모든 데이터를 그대로 활용하는 방법이다.

정답 ④
완전 분석법은 결측값이 있는 행을 모두 제거하고 완전한 자료만으로 분석하는 방법이다. 결측값을 평균으로 채우는 것은 평균 대치법이다.

43. 인공신경망에서 각 층의 노드 수는 줄이고 은닉층의 수는 늘렸을 때 나타날 수 있는 현상으로 가장 적절한 것은?

① 모델 구조가 전체적으로 단순해진다.
② 모델의 학습 시간이 짧아진다.
③ 역전파 과정에서 기울기 소실(vanishing gradient) 문제가 발생할 수 있다.
④ 표현할 수 있는 함수의 복잡도가 감소한다.

> **정답 ③**
> ③이 가장 적절하다. 은닉층이 깊어지면 활성화함수와 가중치 상태 등에 따라 역전파 기울기가 반복적으로 작아져 앞쪽 층이 충분히 학습되지 않는 기울기 소실이 발생할 수 있다. 항상 발생하는 것은 아니며 활성화함수·초기화·잔차 연결 등으로 완화할 수 있다. 노드 수를 줄이고 층을 늘린다는 정보만으로 전체 파라미터 수, 학습 시간, 표현 능력의 증감을 확정할 수는 없다.

44. 다음 이진 분류 결과의 혼동행렬(Confusion Matrix)에서 F1 점수(F1-score)는?

	예측 = 긍정	예측 = 부정
실제 = 긍정	TP = 3	FN = 8
실제 = 부정	FP = 5	TN = 10

① 6/19
② 6/17
③ 3/8
④ 3/11

> **정답 ①**
> 정밀도 = TP/(TP + FP) = 3/8, 재현율 = TP/(TP + FN) = 3/11이다. F1 = 2 × 정밀도 × 재현율 ÷ (정밀도 + 재현율) = 2TP/(2TP + FP + FN) = 6/(6 + 5 + 8) = 6/19이다.

45. 의사결정나무에서 마디(노드)를 분리하는 기준에 대한 설명으로 적절하지 않은 것은?

① 카이제곱 통계량의 p-value가 작아지는 방향으로 분리한다.
② 지니 지수(Gini Index)가 최대가 되는 방향으로 분리한다.
③ 엔트로피 지수가 작아지는 방향으로 분리한다.
④ 분산 감소량이 커지는 방향으로 분리한다.

> **정답 ②**
> 지니 지수는 불순도 지표이므로 분리 후 지니 지수가 '작아지는' 방향으로 분리한다. 카이제곱 통계량의 p-value와 엔트로피는 작아지는 방향, 분산 감소량은 커지는 방향이 맞다.

46. 어떤 노드에 속한 데이터 10개가 모두 하나의 클래스에만 속하고 다른 클래스의 개수는 0일 때(즉 완전히 한 범주로 몰려 있을 때), 이 노드의 지니 지수(Gini Index)와 엔트로피(Entropy)를 순서대로 바르게 나타낸 것은?

① 1, 1
② 1,0
③ 0, 1
④ 0, 0

> **정답 ④**
> 한 클래스의 비율이 p = 1이므로 지니 지수 = $1 - 1^2 = 0$, 엔트로피 = $-1 \times \log_2 1 = 0$이다. 완전히 순수한 노드는 두 지표가 모두 0이다.

47. 계층적 군집분석의 와드 연결법(Ward's method)에 대한 설명으로 옳은 것은?

① 두 군집에 속한 개체 사이의 거리 중 가장 먼 거리를 기준으로 군집을 병합한다.
② 두 군집의 중심(centroid) 사이의 거리를 기준으로 군집을 병합한다.
③ 두 군집 사이의 가장 가까운 거리를 기준으로 군집을 병합한다.
④ 군집 내 오차제곱합(SSE)의 증가가 최소가 되도록 군집을 병합한다.

> **정답 ④**
> 와드 연결법은 두 군집을 합칠 때 군집 내 오차제곱합(SSE)의 증가량이 최소가 되도록 병합한다. ①은 최장(완전) 연결법, ②는 중심 연결법, ③은 최단(단일) 연결법이다.

48. 맨해튼 거리(Manhattan distance)와 유클리디안 거리(Euclidean distance)에 대한 설명으로 옳지 않은 것은?

① 맨해튼 거리는 항상 유클리디안 거리보다 작거나 같다.
② 유클리디안 거리는 두 점을 잇는 직선(최단) 거리이다.
③ 맨해튼 거리는 각 차원(좌표) 차이의 절댓값을 모두 더한 값이다.
④ 맨해튼 거리는 격자(바둑판) 형태의 경로를 따라 이동한 거리와 같다.

> **정답 ①**
> 맨해튼 거리는 항상 유클리디안 거리보다 크거나 같다. 예: (0, 0)과 (3, 4) 사이의 맨해튼 거리는 3 + 4 = 7, 유클리디안 거리는 5이다.

49. 거래 100건 중 기저귀(A)를 포함한 거래는 51건, 맥주(B)를 포함한 거래는 50건, 두 품목을 모두 포함한 거래는 34건이다. 연관규칙 'A → B'에 대한 설명으로 옳지 않은 것은?

① 지지도(support)는 0.34이다.
② 신뢰도(confidence)는 약 0.67이다.
③ 신뢰도(confidence)는 0.34이다.
④ 향상도(lift)는 약 1.33으로 1보다 크다.

> **정답 ③**
> 지지도 = 34/100 = 0.34, 신뢰도 = $P(A \cap B)/P(A)$ = 34/51 ≈ 0.67, 향상도 = 0.67 ÷ (50/100) ≈ 1.33이다. ③은 지지도 값을 신뢰도로 잘못 쓴 것이다.

50. 다음 거래 데이터에서 연관규칙 'B → C'의 지지도(support)는?

전체 거래 10건 중 품목 B를 포함한 거래는 7건, 품목 C를 포함한 거래는 6건이며, B와 C를 동시에 포함한 거래는 5건이다.

① 0.7
② 0.6
③ 0.5
④ 0.71

> **정답 ③**
> 지지도 = B와 C를 동시에 포함한 거래 수 ÷ 전체 거래 수 = 5/10 = 0.5이다. 참고로 신뢰도는 5/7 ≈ 0.71이다.