# ADsP 제50회 기출 복원문제

유형 2
정답·해설 수록본
총 50문항 · 4지선다 · 90분

## 1과목 데이터 이해 (1~10번)

**1. 다음은 DIKW 피라미드의 각 단계를 설명한 것이다. 각 단계의 명칭과 설명이 옳지 않은 것은?**

① D는 Data로, 아직 가공되지 않은 상태에서 관찰·측정을 통해 수집한 있는 그대로의 객관적 사실을 의미한다.
**② I는 Insight로, 데이터를 가공·처리하여 데이터 간의 관계 속에서 의미를 도출한 것을 의미한다.**
③ K는 Knowledge로, 정보를 구조화하여 유의미한 규칙이나 패턴을 파악하고 이를 일반화한 것을 의미한다.
④ W는 Wisdom으로, 지식의 축적과 근본 원리에 대한 이해를 바탕으로 도출되는 창의적인 아이디어를 의미한다.

**정답 ②**
DIKW의 I는 Information(정보)이다. 데이터를 처리하여 의미를 얻는 단계이며 Insight가 아니다.

**2. 데이터의 표현 단위와 그 특징에 대한 설명으로 옳지 않은 것은?**

**① 바이트(Byte)는 컴퓨터가 데이터를 처리하는 최소 단위로서, 0 또는 1 중 하나의 값만을 가진다.**
② 1바이트(Byte)는 일반적으로 8개의 비트(Bit)로 구성되며, 하나의 문자를 표현하는 기본 단위로 사용된다.
③ 데이터의 크기 단위는 킬로바이트(KB), 메가바이트(MB), 기가바이트(GB), 테라바이트(TB) 순으로 커진다.
④ 여러 개의 필드(Field)가 모여 하나의 레코드(Record)를 이루고, 레코드가 모여 하나의 파일(File)을 구성한다.

**정답 ①**
0 또는 1을 표현하는 단위는 비트(Bit)이다. 바이트는 보통 8비트로 구성된다. 문자에 필요한 바이트 수는 인코딩에 따라 달라진다.

**3. 암묵지(Tacit Knowledge)와 형식지(Explicit Knowledge)에 대한 설명으로 옳지 않은 것은?**

**① 암묵지는 문서나 매뉴얼의 형태로 겉으로 드러난 유형의 지식이므로, 다른 사람에게 쉽고 빠르게 전달·공유할 수 있다.**
② 형식지는 언어·문자·기호 등을 통해 표현되어 외부로 드러난 지식으로, 교과서나 업무 매뉴얼이 이에 해당한다.
③ 공통화(Socialization)는 개인이 가진 암묵지가 경험의 공유를 통해 다른 사람의 암묵지로 전달되는 과정이다.
④ 표출화(Externalization)는 개인에게 내재된 암묵지를 문서나 매체에 저장·가공·분석하여 형식지로 만드는 과정이다.

**정답 ①**
암묵지는 경험·숙련으로 체득하여 언어로 표현하기 어려운 지식이다. 문서·매뉴얼로 명시한 지식은 형식지이다. 공통화는 암묵지→암묵지, 표출화는 암묵지→형식지이다.

**4. 데이터베이스의 일반적인 특성에 대한 설명으로 옳지 않은 것은?**

**① 데이터의 일관성을 확보하기 위해 동일한 데이터를 여러 테이블에 중복하여 저장하는 것을 원칙으로 한다.**
② 여러 사용자가 서로 다른 목적으로 하나의 데이터베이스를 동시에 공유하여 이용할 수 있다.
③ 이용자의 검색·질의에 대하여 즉시 처리하고 응답할 수 있는 실시간 접근성을 갖는다.
④ 삽입·삭제·갱신을 통해 데이터가 계속 변화하면서도 항상 현재의 정확한 데이터를 유지한다.

**정답 ①**
데이터베이스는 불필요한 중복을 줄여 일관성을 유지한다. 모든 동일 데이터를 중복 저장하는 것이 원칙은 아니다. 동시 공유, 실시간 접근, 계속적 변화는 일반적 특성이다.

**5. 다음 상황에서 A기업이 도입을 검토해야 할 데이터 저장소로 가장 적절한 것은?**

> A기업은 전사 데이터를 통합 관리하기 위해 데이터 웨어하우스 구축을 검토하였으나, 비용과 구축 기간이 지나치게 크다는 문제에 직면하였다. 그럼에도 마케팅 부서에서는 온라인 판매 데이터를 활용한 분석을 즉시 수행하고자 한다. 이 경우 특정 부서나 업무 주제의 목적에 맞추어 필요한 데이터만 모아 구성한 소규모 저장소에 투자하는 방안을 고려할 수 있다.

① 스프레드시트(Spreadsheet)
② 빅데이터(Big Data)
③ 텍스트마이닝(Text Mining)
**④ 데이터마트(Data Mart)**

**정답 ④**
데이터마트는 특정 부서나 주제를 위한 분석 저장소이다. 전사 데이터웨어하우스보다 범위를 좁혀 필요한 데이터를 제공할 수 있다.


출처: ADsP CBT youneedpython.github.io/ADsP-CBT · 복원 문제로 실제 시험과 다를 수 있습니다.

**6. 다음 중 SCM과 CRM에 관한 설명으로 옳은 것만을 모두 고른 것은?**

> 가. CRM은 원자재의 조달부터 제품의 유통에 이르는 과정을 관리하는 데 집중한다.
> 나. SCM은 부품의 조달에서부터 최종 소비자에게 제품이 전달되기까지 공급망 전체의 물류와 정보 흐름을 최적화한다.
> 다. CRM은 온라인 환경에서만, SCM은 오프라인 환경에서만 적용할 수 있다.
> 라. CRM은 데이터베이스를 활용하지 않지만, SCM은 데이터베이스를 기반으로 운영된다.
> 마. CRM과 SCM은 기업 내부 프로세스를 지원한다는 점에서 서로 밀접한 관련이 있다.

① 가, 나
② 나, 다
**③ 나, 마**
④ 라, 마

**정답 ③**
나와 마가 옳다. 가는 SCM에 대한 설명이다(CRM은 고객관계관리). 다는 CRM과 SCM 모두 온·오프라인에 적용되므로 틀리다. 라는 CRM도 고객 데이터베이스를 기반으로 하므로 틀리다. 나는 SCM의 정의이고, 마는 둘 다 기업 내부 프로세스를 지원하는 솔루션이므로 옳다.

**7. 다음 지문의 괄호 안에 들어갈 내용으로 가장 적절한 것은?**

> 빅데이터 시대에는 데이터의 양이 급격히 증가하고 분석 기술이 발달함에 따라, '왜 그런 일이 일어났는지' 정확한 원인을 밝히지 못하더라도 '무슨 일이 일어나고 있는지'를 빠르게 파악하여 대응하는 방식이 중요해졌다. 이에 따라 데이터 분석의 초점이 ( )(으)로 변화하고 있다.

**① 인과관계 → 상관관계**
② 질(Quality) → 양(Quantity)
③ 사전처리 → 사후처리
④ 표본조사 → 전수조사

**정답 ①**
지문은 '왜'(원인)보다 '무엇'(현상)을 빠르게 파악하는 변화를 말하므로 인과관계 → 상관관계이다. 질 → 양, 사전처리 → 사후처리, 표본조사 → 전수조사도 빅데이터가 가져온 변화이지만 지문 내용과 맞지 않는다.

**8. 빅데이터 분산 처리 기술인 맵리듀스(MapReduce)에 대한 설명으로 가장 적절한 것은?**

① 데이터 처리 과정에서 결측치와 이상치를 자동으로 보정하여 데이터 품질을 향상시키는 기술이다.
② 관계형 데이터베이스(RDBMS)를 기반으로 정형 데이터만을 분산 처리하는 방식이다.
③ 데이터를 여러 노드에 분산 저장하기 때문에 개인정보 보호와 보안성이 자동으로 향상된다.
**④ 저렴한 범용 서버 여러 대를 묶어 병렬로 처리하므로 대규모 데이터 처리 시 비용을 절감할 수 있다.**

**정답 ④**
맵리듀스는 Map과 Reduce 작업을 여러 노드에서 분산·병렬 수행한다. 범용 서버를 활용할 수 있으며 결측치 보정이나 보안을 자동으로 보장하지 않는다.

**9. 다음 중 데이터 분석 방법과 그 적용 사례의 연결이 옳지 않은 것은?**

① 연관분석(장바구니 분석) — 마트에서 함께 구매되는 상품 조합을 찾아내어 매대 진열과 묶음 할인에 활용한다.
② 회귀분석 — 광고비 지출액, 매장 면적 등의 변수를 이용하여 다음 분기의 매출액을 예측한다.
**③ 소셜네트워크 분석 — 신상품 출시 후 개선점을 파악하기 위해 구매 고객을 대상으로 설문조사를 실시한다.**
④ 군집분석 — 구매 패턴이 비슷한 고객들을 몇 개의 집단으로 나누어 집단별 마케팅 전략을 수립한다.

**정답 ③**
소셜네트워크 분석은 사람·조직 등의 연결 관계와 구조를 분석한다. 고객 설문조사를 한다는 사실만으로 소셜네트워크 분석이 되지는 않는다.

**10. 다음 중 데이터 사이언티스트에게 요구되는 소프트 스킬(Soft Skill)에 해당하는 것만을 모두 고른 것은?**

> 가. 데이터 분석에 필요한 이론과 다양한 분석 기법에 대한 지식
> 나. 분석 도구를 활용하여 대용량 데이터를 처리하는 프로그래밍 능력
> 다. 문제의 본질을 파고드는 호기심과 비판적 시각
> 라. 분석 결과를 이해관계자에게 명확히 전달하는 의사소통 능력
> 마. 스토리텔링을 통해 상대방을 이해시키고 설득하는 능력

① 가, 나
② 가, 나, 다
**③ 다, 라, 마**
④ 나, 다, 라

**정답 ③**
호기심·비판적 시각, 의사소통, 스토리텔링은 소프트 스킬이다. 이론·분석 기법 지식과 프로그래밍 능력은 하드 스킬에 해당한다.

## 2과목 데이터 분석 기획 (11~20번)

**11. 다음 (가)~(다)의 설명에 해당하는 것을 순서대로 올바르게 연결한 것은?**

> (가) 전사 차원에서 분석 업무를 지속적으로 관리·통제하기 위한 마스터플랜과 관리 체계를 수립하는 것
> (나) 분석 과제의 발굴부터 수행·관리, 결과 공유에 이르는 일련의 절차를 표준화하여 운영하는 것
> (다) 구성원의 분석 역량과 데이터 기반 의사결정 문화를 확산시키기 위해 지속적으로 시행하는 것

① 거버넌스 프로세스 – 데이터 마이닝 – 교육
**② 분석 거버넌스 체계 – 프로세스 – 교육**
③ 조직 – 프로세스 – 교육
④ 분석 거버넌스 체계 – 조직 – 시스템

**정답 ②**
전사적 관리 체계는 분석 거버넌스, 과제 발굴·수행·공유의 표준 절차는 프로세스, 역량·문화 확산 활동은 교육이다.

**12. 분석 준비도와 분석 성숙도를 진단한 결과, 두 가지 모두 낮은 수준으로 평가된 기업의 분석 수준 유형으로 가장 적절한 것은?**

① 도입형
② 정착형
**③ 준비형**
④ 확산형

**정답 ③**
준비도와 성숙도가 모두 낮으면 준비형이다. 준비도는 높고 성숙도는 낮으면 도입형, 준비도는 낮고 성숙도는 높으면 정착형, 둘 다 높으면 확산형이다.

**13. 데이터 분석 과제를 발굴하는 상향식 접근법(Bottom-Up Approach)에 대한 설명으로 가장 적절한 것은?**

① 해결해야 할 문제가 명확하게 정의된 상태에서 그 원인을 논리적으로 규명해 나가는 방식이다.
② 분석 목표를 먼저 확정한 뒤 그 목표에 필요한 데이터만 선별적으로 수집하여 가설을 검증한다.
**③ 데이터를 먼저 탐색하면서 의미 있는 패턴이나 이상징후를 찾아내고, 이를 토대로 문제를 새롭게 정의해 나간다.**
④ 문제 탐색 → 문제 정의 → 해결방안 탐색 → 타당성 검토의 순서로 과제를 도출한다.

**정답 ③**
상향식 접근은 데이터 탐색에서 패턴을 발견하여 문제와 과제를 도출한다. 명확한 문제에서 해결책을 찾는 절차는 하향식 접근의 특징이다.

**14. 다음 중 기업의 분석 성숙도를 진단할 때 평가하는 영역에 해당하지 않는 것은?**

① 비즈니스 프로세스
② 조직
③ 시스템(IT)
**④ 서비스**

**정답 ④**
분석 성숙도 평가 영역은 비즈니스, 조직·역량, IT이다. 서비스는 독립적인 평가 영역에 해당하지 않는다.

**15. 다음 중 머신러닝을 활용한 데이터 분석의 수행 절차를 올바르게 나열한 것은?**

① 데이터셋 선택 → 비즈니스 도메인 이해 → 데이터 변환 → 데이터 전처리 → 실행
**② 비즈니스 도메인 이해 → 데이터셋 선택 → 데이터 전처리 → 데이터 변환 → 실행**
③ 비즈니스 도메인 이해 → 데이터 전처리 → 데이터 변환 → 데이터셋 선택 → 실행
④ 데이터 전처리 → 데이터셋 선택 → 비즈니스 도메인 이해 → 데이터 변환 → 실행

**정답 ②**
도메인을 이해한 후 데이터셋을 선택하고 결측·오류 등을 전처리한다. 이어 분석에 적합하게 데이터를 변환하고 분석을 실행한다.

**16. 다음 중 정형 데이터, 반정형 데이터, 비정형 데이터의 예를 순서대로 올바르게 나열한 것은?**

**① 수요 예측에 사용되는 관계형 데이터베이스의 판매 실적 테이블 – 웹로그 – 유튜브 영상**
② 웹로그 – 유튜브 영상 – 관계형 데이터베이스의 거래 내역 테이블
③ 유튜브 영상 – XML 형식의 센서 데이터 – ERP 시스템의 매출 테이블
④ CSV 파일 – SNS에 게시된 사진 이미지 – HTML 문서

**정답 ①**
관계형 테이블은 정형 데이터, 구조 정보가 포함된 웹로그는 반정형 데이터, 영상은 비정형 데이터이다. ②는 반정형–비정형–정형, ③은 비정형–반정형–정형 순이고, ④는 이미지(비정형)와 HTML(반정형)의 순서가 바뀌어 있다.

**17. CRISP-DM 방법론의 모델링(Modeling) 단계에서 수행하는 업무(Task)에 해당하지 않는 것은?**

① 모델링 기법 선택
② 모델 테스트 계획 설계
**③ 모델 적용성 평가**
④ 모델 작성

**정답 ③**
모델 적용성 평가는 평가 단계에서 비즈니스 목적에 맞는지 확인하는 업무이다. 모델링 단계에는 기법 선택, 테스트 설계, 모델 작성, 모델 평가가 포함된다. 모델 평가와 모델 적용성 평가를 구분한다.

**18. 기업이 분석 준비도와 분석 성숙도를 진단하는 목적으로 가장 적절한 것은?**

**① 현재의 분석 수준을 객관적으로 파악하고, 향후 분석 역량을 향상시키기 위한 목표와 방향을 설정하기 위해서이다.**

② 경쟁사보다 우위에 있음을 대외적으로 홍보하기 위한 마케팅 자료를 확보하기 위해서이다.

③ 분석 조직 구성원 개개인의 성과를 평가하여 인사고과에 반영하기 위해서이다.

④ 미래 시점의 매출액과 이익을 오차 없이 정확하게 예측하기 위해서이다.

> **정답 ①**
> 현재 분석 수준을 진단하여 개선 목표와 추진 방향을 정하기 위한 것이다. 미래 성과를 오차 없이 보장하거나 개인 인사평가만을 위한 진단은 아니다.

**19. 분석 프로젝트의 관리에 대한 설명으로 옳지 않은 것은?**

**① 처음 수립한 분석 계획은 도중에 변경하지 않고 그대로 완수하는 것이 바람직하다.**

② 분석 프로젝트는 데이터의 크기·복잡도·다양성 등 데이터 자체의 특성을 고려하여 관리해야 한다.

③ 모델의 정확도와 해석 가능성은 서로 상충(트레이드오프)하는 경우가 있으므로 분석 목적에 맞게 조정해야 한다.

④ 분석 결과가 실제 업무에 활용될 수 있도록 이해관계자와 지속적으로 소통하며 진행해야 한다.

> **정답 ①**
> 데이터 탐색 결과와 업무 요구에 따라 분석 계획을 조정할 수 있어야 한다. 초기 계획을 변경 없이 완수하는 것이 항상 바람직하지는 않다.

**20. 기업에 데이터 분석 체계를 도입하고 정착시키기 위한 추진 단계를 올바른 순서로 나열한 것은?**

① 도입 → 확산 및 고도화 → 유효성 검증

② 유효성 검증 → 도입 → 확산 및 고도화

**③ 도입 → 유효성 검증 → 확산 및 고도화**

④ 유효성 검증 → 확산 및 고도화 → 도입

> **정답 ③**
> 분석 로드맵은 '데이터 분석체계 도입 → 데이터 분석 유효성 검증 → 데이터 분석 확산과 고도화'의 3단계로 추진한다. 도입 단계에서 과제를 정의하고, 검증 단계에서 파일럿으로 효과를 확인한 뒤 전사로 확산한다.

## 3과목 데이터 분석 (21~50번)

**21. 다음과 같은 로지스틱 회귀모형에서 설명변수 $x$가 1만큼 증가할 때 로짓(logit) 값의 변화로 옳은 것은?**

$$p = \frac{1}{1 + e^{(4.6 - 0.6x)}}$$

① 0.6 감소한다
**② 0.6 증가한다**
③ $e^{-0.6}$배 증가한다
④ $e^{0.6}$배 증가한다

**정답 ②**
$logit(p) = ln\frac{p}{1-p} = -4.6 + 0.6x$ 이다. $x$가 1 증가하면 로짓은 0.6 증가한다. 오즈(odds)는 $e^{0.6}$배가 되며, 이는 로짓의 변화량과 구분해야 한다.

**22. 시계열 모형에 대한 설명으로 옳은 것은?**

① AR 모형은 정상성을 가정하지 않는다.
② MA 모형은 비정상 시계열 자료에만 적용할 수 있다.
**③ AR 모형과 MA 모형은 모두 정상성을 가정한다.**
④ ARMA 모형은 반드시 차분한 자료에만 사용할 수 있다.

**정답 ③**
AR·MA·ARMA는 정상 시계열 분석의 기본 모형이다. AR 모형은 계수에 대한 정상성 조건을 만족해야 하며, 유한 차수 MA 모형은 유한 분산 백색잡음 아래에서 정상적이다. 비정상 시계열은 원인에 따라 차분이나 로그·Box-Cox 변환 등을 검토한다. ARIMA는 차분 차수 d를 포함한다. 이미 정상인 자료에는 차분이 필수적이지 않으므로 ④는 틀리다.

**23. 아래 상황에서 검정 결과로 가장 적절한 것은?**

공정한 동전인지 확인하기 위해 동전을 5번 던졌더니 5번 모두 앞면이 나왔다. 귀무가설 $H_0 : p = 0.5$ 에 대하여 유의수준 5%에서 양측검정을 수행하고자 한다.

① p-value = $\frac{1}{16}$ 이므로 귀무가설을 기각한다.
**② p-value = $\frac{1}{16}$ 이므로 귀무가설을 기각하지 않는다.**
③ p-value = $\frac{1}{32}$ 이므로 귀무가설을 기각한다.
④ p-value = $\frac{1}{32}$ 이므로 귀무가설을 기각하지 않는다.

**정답 ②**
공정한 동전에서 5번 모두 앞면일 확률은 $(1/2)^5 = 1/32$이다. 양측검정은 모두 뒷면인 경우도 포함하므로 p-value $= 2/32 = 1/16 = 0.0625$이다. 0.05보다 크므로 귀무가설을 기각하지 않는다.

**24. 표준화된 두 변수 A와 B의 상관계수가 약 0.1일 때, 상관행렬을 이용하여 주성분분석(PCA)을 수행하였다. 마지막 주성분으로 가장 적절한 것은?**

**① $\frac{1}{\sqrt{2}}A - \frac{1}{\sqrt{2}}B$**
② $\frac{1}{\sqrt{2}}A + \frac{1}{\sqrt{2}}B$
③ $-A$
④ $B$

**정답 ①**
상관행렬 $\left(\begin{pmatrix} 1 & 0.1 \\ 0.1 & 1 \end{pmatrix}\right)$의 고유값은 1.1과 0.9이다. 마지막 주성분은 작은 고유값(0.9)의 방향인 $(A - B)/\sqrt{2}$이다. 고유벡터의 부호를 반대로 해도 같은 주성분 방향이다.

**25. 이동평균모형(MA)은 현재의 시계열 값을 무엇의 선형결합으로 표현하는가?**

① 과거의 관측값
② 과거와 현재의 관측값
③ 과거의 오차항
**④ 과거와 현재의 오차항**

**정답 ④**
MA(q)는 현재와 과거의 오차항을 선형결합하여 현재 값을 표현한다. 과거 관측값을 사용하는 AR과 구분한다.

**26. 다음 중 자기회귀모형(AR)을 나타내는 식으로 가장 적절한 것은?**

[기호 설명]
$Z_t$ : 현재 시점 $t$의 시계열 관측값
$Z_{t-1}, Z_{t-2}$ : 과거 시점의 관측값
$\phi$ : 자기회귀(AR) 계수
$\theta$ : 이동평균(MA) 계수
$a_t$ : 백색잡음(오차항)

① $Z_t = a_t - \theta_1 a_{t-1}$
**② $Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + a_t$**
③ $Z_t = \theta_1 a_{t-1} + a_t$
④ $Z_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2}$

**정답 ②**
②는 과거 관측값 $Z_{t-1}$, $Z_{t-2}$와 현재 오차항 $a_t$로 구성된 AR(2)이다. 나머지는 오차항들의 조합으로 구성된 MA 모형이다.

**27. 아래 자료에서 연관규칙 [우유 → 빵]의 향상도(Lift)를 계산한 값으로 옳은 것은?**

어느 편의점의 거래 12건을 우유와 빵의 구매 조합에 따라 분류한 결과는 다음과 같다.

| 구매 조합 | 우유만 구매 | 빵만 구매 | 우유·빵 동시 구매 | 둘 다 미구매 | 합계 |
|---|---|---|---|---|---|
| 거래 건수 | 2건 | 2건 | 4건 | 4건 | 12건 |

① $\frac{2}{3}$

② $\frac{3}{4}$

③ $1$

**④ $\frac{4}{3}$**

**정답 ④**

$P(\text{우유}) = 6/12$, $P(\text{빵}) = 6/12$, $P(\text{우유} \cap \text{빵}) = 4/12$이다. 향상도 $= \frac{4/12}{(6/12)(6/12)} = \frac{4}{3}$이다. 신뢰도 $4/6 = 2/3$와 혼동하지 않는다.

**28. 아래 주성분분석 결과를 해석한 내용 중 잘못된 것은?**

어떤 데이터에 주성분분석(PCA)을 수행한 결과의 일부는 다음과 같다.

| Importance of components | Standard deviation | Proportion of Variance | Cumulative Proportion |
|---|---|---|---|
| PC1 | 2.04629 | 0.41873 | 0.41873 |
| PC2 | 1.62533 | 0.26417 | 0.68290 |
| PC3 | 0.98189 | 0.09641 | 0.77931 |
| PC4 | 0.83976 | 0.07052 | 0.84983 |
| PC5 | 0.66978 | 0.04486 | 0.89469 |
| PC6 | 0.54909 | 0.03015 | 0.92484 |
| PC7 | 0.44900 | 0.02016 | 0.94500 |

① 분산 설명력이 80%를 넘으려면 주성분이 4개 이상 필요하다.

② 분산을 가장 많이 설명하는 주성분의 설명력은 약 41.9%이다.

**③ 분석에 사용된 원래 변수의 개수는 모두 7개이다.**

④ 2차원으로 축소한다면 손실되는 정보의 비율은 약 31.7%이다.

**정답 ③**

결과의 '일부'만 제시되었고 PC7까지의 누적 설명력이 94.5%이므로 주성분이 더 존재한다. 총분산은 PC1 분산 ÷ 설명비율 = $2.04629^2 \div 0.41873 \approx 10$이므로, 상관행렬(표준화) 기반 PCA라면 원래 변수는 10개이다. 따라서 ③이 틀리다. ① PC4까지 누적 84.98%로 처음 80%를 넘는다. ② PC1 설명력은 41.87%이다. ④ 2차원 축소 시 손실은 $1 - 0.68290 = 0.3171$이다.

**29. 모집단에서 추출한 표본을 이용하여 계산한 평균, 분산, 표준편차 등의 수치를 무엇이라 하는가?**

① 모수

② 전수조사

③ 표본추출

**④ 통계량**

**정답 ④**

표본에서 계산한 평균·분산 등은 통계량이다. 모집단을 설명하는 수치는 모수이다.

**30. 정규분포를 따르는 데이터에서 평균으로부터 표준편차의 3배 이상 떨어진 값을 이상치로 판단하는 탐지 기법은?**

**① ESD**

② IQR

③ K-means

④ DBSCAN

**정답 ①**

정답은 ①이다. 이 문항은 평균에서 3표준편차 이상 떨어진 값을 이상치로 판단하는 기준을 ESD로 설명하는 출제 맥락이다. 다만 엄밀한 일반화 ESD(Generalized Extreme Studentized Deviate) 검정은 표본 크기·유의수준·검토할 이상치 수 등을 반영한 임계값을 사용하므로 단순한 3σ 규칙과 구분해야 한다. IQR 방법은 일반적으로 Q1−1.5×IQR 미만 또는 Q3+1.5×IQR 초과를 이상치로 판단한다. K-means와 DBSCAN은 군집분석 기법이다.

**31. 아래 로지스틱 회귀분석 결과에 대한 해석 중 옳지 않은 것은?**

어느 카드사 고객 자료를 이용하여 연체 여부(default)를 종속변수로, 학생 여부(student)와 카드 잔고(balance)를 설명변수로 하는 로지스틱 회귀분석을 수행한 R 출력 결과는 다음과 같다.

```
Call:
glm(formula = default ~ student + balance, family = binomial,
data = credit)

Deviance Residuals:
Min 1Q Median 3Q Max
-2.4578 -0.1422 -0.0559 -0.0203 3.7435

Coefficients:
Estimate Std. Error z value Pr(>|z|)
(Intercept) -10.600000 0.491800 -21.553 <2e-16 ***
studentYes -0.700000 0.283900 -2.466 0.0137 *
balance 0.005600 0.000230 24.348 <2e-16 ***
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 2920.6 on 9999 degrees of freedom
Residual deviance: 1571.7 on 9997 degrees of freedom
AIC: 1577.7

Number of Fisher Scoring iterations: 8
```

연체확률은 $p = \frac{1}{1+e^{-z}}$, $z = -10.6 - 0.7 \times studentYes + 0.0056 \times balance$ 로 계산하며, $z$ 값에 따른 연체확률 $p$의 근삿값은 아래와 같다.

| z값 | 연체확률 p |
|---|---|
| **-5.0** | 0.0067 |
| **-5.1** | 0.0061 |
| **-5.2** | 0.0055 |
| **-5.3** | 0.0050 |
| **-5.4** | 0.0045 |
| **-5.5** | 0.0041 |
| **-5.6** | 0.0037 |
| **-5.7** | 0.0033 |
| **-5.8** | 0.0030 |
| **-5.9** | 0.0027 |
| **-6.0** | 0.0025 |

① 잔고가 1,000일 때 학생의 연체확률은 약 0.0033이다.

② 잔고가 1,000일 때 학생이 아닌 사람의 연체확률은 약 0.0067이다.

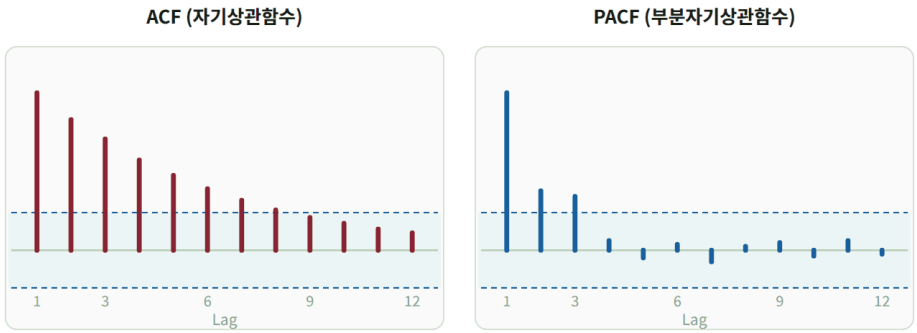
③ 잔고가 1,200일 때 학생의 연체확률은 0.0033보다 높다.

**④ 잔고가 1,200일 때 학생이 아닌 사람의 연체확률은 0.0067보다 낮다.**

**정답 ④**

학생·잔고 1,000: $z = -10.6 - 0.7 + 5.6 = -5.7$, $p \approx 0.0033$이다. 비학생·잔고 1,000: $z = -5.0$, $p \approx 0.0067$이다. 잔고가 1,200이면 $z$가 각각 $-4.58$, $-3.88$로 커져 연체확률이 모두 증가한다. 따라서 ④가 틀리다.

**32.** 어떤 시계열 자료의 표본 자기상관함수(ACF)와 부분자기상관함수(PACF)를 시차(lag) 12까지 그린 결과는 다음과 같다. 아래 상관도표를 근거로 판단할 때 가장 적절한 ARMA($p$, $q$) 모형은?




파란 점선은 유의성 한계선(약 ±0.196)

① ARMA(2, 0)
② ARMA(0, 2)
**③ ARMA(3, 0)**
④ ARMA(0, 3)

**정답 ③**
ACF는 점진적으로 감소하고 PACF는 시차 3까지 유의하며 이후 절단되는 형태이다. AR(3)의 전형적 패턴이므로 ARMA(3,0)이다.

**33.** 연관규칙 A → B의 방향을 B → A로 바꾸었을 때 지지도·신뢰도·향상도에 관한 설명 중 틀린 것은?

① 향상도는 바뀌지 않는다.
② 지지도는 바뀌지 않는다.
③ 신뢰도는 조건부확률에 기반한다.
**④ 신뢰도는 바뀌지 않는다.**

**정답 ④**
지지도 $P(A \cap B)$와 향상도 $\dfrac{P(A \cap B)}{P(A)P(B)}$는 방향에 무관하다.
신뢰도는 $P(B \mid A)$와 $P(A \mid B)$로 분모가 달라 일반적으로 바뀐다.
특수하게 같을 수는 있으나 항상 같다는 주장은 틀리다.

**34.** 분류 자료에서 특정 범주에 속한 사례 수가 다른 범주에 비해 지나치게 적어, 모델이 해당 범주를 제대로 학습하지 못하는 현상을 무엇이라 하는가?

① 과소적합
② 과대적합
③ 기울기 소실
**④ 범주 불균형**

**정답 ④**
클래스별 사례 수가 크게 차이 나는 문제는 범주 불균형이다. 소수 클래스의 성능을 별도로 점검하고 적절한 평가 지표와 샘플링·가중치를 고려한다.

**35.** 아래 회귀분석 결과에 대한 해석 중 틀린 것은?

어느 카드사 고객 자료를 이용하여 카드 잔고(balance)를 종속변수로, 수입(income)과 학생 여부(student)를 설명변수로 하는 선형회귀분석을 수행한 R 출력 결과는 다음과 같다.

```
Call:
lm(formula = balance ~ income + student, data = credit)

Residuals:
Min 1Q Median 3Q Max
-762.37 -341.75 -45.28 323.63 817.19

Coefficients:
Estimate Std. Error t value Pr(>|t|)
(Intercept) 211.14280 74.53120 2.833 0.006435 **
income 0.00670 0.00230 2.913 0.005164 **
studentYes 382.67050 105.68410 3.621 0.000640 ***
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 391.8 on 55 degrees of freedom
Multiple R-squared: 0.2775, Adjusted R-squared: 0.2512
F-statistic: 10.56 on 2 and 55 DF, p-value: 0.0001312
```

① income과 studentYes의 회귀계수는 모두 유의수준 5%에서 통계적으로 유의하다.
② 다른 조건이 같다면 학생은 학생이 아닌 사람보다 잔고가 평균 약 382.7 높다.
**③ 수입이 잔고를 증가시키는 정도는 학생인지 아닌지에 따라 달라진다.**
④ 이 모형이 잔고의 변동을 설명하는 정도는 약 27.75%이다.

**정답 ③**
모형에 income×student 상호작용항이 없으므로 수입의 기울기 0.00670은 학생 여부와 관계없이 동일하다. 학생은 절편이 382.67 높을 뿐이다. 두 계수 모두 p < 0.05이며 $R^2 = 0.2775$이다.

**36. 다중회귀분석에서 잔차(residual)에 관한 설명으로 틀린 것은?**

① 잔차의 평균은 0이다.

② 잔차는 정규분포를 따른다고 가정한다.

③ 독립변수와 잔차는 서로 상관되지 않아야 한다.

**④ 종속변수와 잔차는 서로 상관되지 않아야 한다.**

> **정답 ④**
> 절편을 포함한 일반적인 최소제곱회귀에서는 잔차의 평균이 0이고, 잔차는 설명변수 및 적합값과 직교한다. 그러나 y = ŷ + e이므로 종속변수와 잔차가 무상관이어야 한다는 조건은 없다. 따라서 ④가 틀리다. 정규성은 엄밀히 잔차 자체가 아니라 오차항에 대한 가정이다. 종속변수와 잔차의 표본 상관계수는 절편 포함 최소제곱회귀에서 두 변수의 분산이 양수일 때 $\sqrt{(1-R^2)}$이다.

**37. 확률의 기본 성질에 대한 설명 중 잘못된 것은?**

① 임의의 사건 $A$에 대하여 $0 \le P(A) \le 1$ 이다.

② 전체 표본공간의 확률은 1이다.

③ 사건 $A$의 여사건에 대하여 $P(A\text{의여사건}) = 1 - P(A)$ 이다.

**④ 서로 독립인 두 사건의 확률의 합은 두 사건의 합집합의 확률과 같다.**

> **정답 ④**
> $P(A \cup B) = P(A) + P(B) - P(A \cap B)$이다. 독립이면 $P(A \cap B) = P(A)P(B)$이며 일반적으로 0이 아니다. 확률의 합이 합집합의 확률이 되는 조건은 독립이 아니라 배반이다.

**38. 크기가 $d$인 자료에서 복원추출로 $d$개를 뽑아 부트스트랩(bootstrap) 표본을 만들 때, 특정 관측값 하나가 한 번도 뽑히지 않을 확률은?**

① $\frac{1}{d}$

② $1-(\frac{1}{d})^d$

**③ $(1-\frac{1}{d})^d$**

④ $1-(1-\frac{1}{d})^d$

> **정답 ③**
> 한 번 추출할 때 특정 관측값을 뽑지 않을 확률은 $1-\frac{1}{d}$이다. 독립적으로 $d$번 복원추출하므로 한 번도 뽑히지 않을 확률은 $(1-\frac{1}{d})^d$ 이며, $d$가 크면 약 $e^{-1} \approx 0.368$이다.

**39. 시계열 자료를 정상화(stationarize)하기 위한 처리에 관한 설명으로 적절한 것은?**

**① 평활화는 변동을 완만하게 만들어 주지만 그 자체로 정상성을 보장하지는 않는다.**

② 추세가 뚜렷한 시계열도 로그 변환만 적용하면 항상 정상 시계열이 된다.

③ 계절성이 존재하는 자료는 차분을 하면 오히려 비정상 시계열이 된다.

④ 분산이 시간에 따라 변하는 경우에는 차분을 통해 분산을 일정하게 만든다.

> **정답 ①**
> 평활화는 변동을 줄이지만 정상성을 보장하지 않는다. 추세는 차분, 계절성은 계절차분, 분산의 변화는 로그·Box-Cox 변환 등을 고려한다. 처리 후 정상성을 다시 확인한다.

**40. 의사결정나무의 정지규칙(stopping rule)으로 적절하지 않은 것은?**

**① 분할로 얻는 정보이득이 미리 정한 최소 임계값을 초과하면 정지한다.**

② 노드에 속한 자료의 수가 최소 기준 이하가 되면 정지한다.

③ 트리의 깊이가 설정한 최대치에 도달하면 정지한다.

④ 추가로 분할하여도 순도의 개선 효과가 충분하지 않으면 정지한다.

> **정답 ①**
> 정보이득이 충분히 크면 분할을 계속할 근거가 된다. 최소 개선량에 미달하거나 노드 자료 수가 작거나 최대 깊이에 도달했을 때 분할을 멈춘다.

**41. 아래 분산분석표에 대한 설명 중 틀린 것은?**

단순선형회귀분석을 수행한 결과 얻은 분산분석표(ANOVA)의 일부는 다음과 같다. 괄호는 값이 생략된 칸이다.

| 요인 | 제곱합 | 자유도 | 제곱평균 | F value | Pr(>F) |
|---|---|---|---|---|---|
| 회귀 | 120 | 1 | ( ) | 60 | 1.28e-06 |
| 잔차 | ( ) | ( ) | ( ) | | |
| 총합 | 150 | 16 | | | |

① 이 회귀모형은 유의수준 5%에서 통계적으로 유의하다.

**② 오차 분산의 불편추정량은 0.2이다.**

③ 이 모형의 결정계수는 $\frac{4}{5}$ 이다.

④ 분석에 사용된 데이터의 크기는 17개이다.

> **정답 ②**
> 잔차제곱합 $= 150 - 120 = 30$, 잔차 자유도 $= 16 - 1 = 15$이므로 오차분산의 불편추정량 $MSE = 30/15 = 2$이다(0.2가 아니다). $R^2 = 120/150 = 4/5$, $n = 16 + 1 = 17$, $F = 120/2 = 60$이다.

**42. 인공신경망에서 사용하는 활성화함수에 관한 설명으로 틀린 것은?**

① 시그모이드 함수의 출력 범위는 0에서 1 사이이다.
② ReLU 함수는 입력이 음수인 구간에서 0을 출력한다.
③ 계단함수는 임계값을 기준으로 0 또는 1을 출력한다.
**④ 쌍곡탄젠트(tanh) 함수의 출력 범위는 0에서 1 사이이다.**

> **정답 ④**
> tanh의 출력 범위는 $-1$과 $1$ 사이이다. 시그모이드는 0과 1 사이, ReLU는 $max(0, x)$, 계단함수는 임계값에 따라 0 또는 1을 출력한다.

**43. 공분산(Covariance)의 특성에 관한 설명 중 틀린 것은?**

① 공분산의 부호를 통해 두 변수 관계의 방향을 알 수 있다.
② 공분산의 값은 변수의 측정 단위에 영향을 받는다.
**③ 공분산의 값은 항상 −1과 1 사이의 값을 갖는다.**
④ 공분산이 양수이면 두 변수가 같은 방향으로 움직이는 경향이 있다.

> **정답 ③**
> $-1$~$1$ 범위의 지표는 상관계수이다. 공분산은 측정 단위와 스케일에 영향을 받아 그 범위를 벗어날 수 있다. 부호는 두 변수가 함께 움직이는 방향을 나타낸다.

**44. 다음 (가)~(다)의 설명에 해당하는 분류 알고리즘을 순서대로 올바르게 연결한 것은?**

> (가) 종속변수가 범주형일 때 로짓 변환과 시그모이드 함수를 이용하여 각 범주에 속할 확률을 추정한다.
> (나) 서로 다른 클래스 사이의 간격(마진)을 최대화하는 초평면을 찾아 분류한다.
> (다) 새로운 데이터와 가장 가까운 K개의 이웃을 찾아 다수결로 범주를 결정한다.

**① 로지스틱 회귀 – SVM – KNN**
② SVM – KNN – 로지스틱 회귀
③ KNN – 로지스틱 회귀 – SVM
④ SVM – 로지스틱 회귀 – KNN

> **정답 ①**
> 로짓·시그모이드로 확률을 추정하는 것은 로지스틱 회귀, 최대 마진 초평면은 SVM, 가까운 K개 이웃의 다수결은 KNN이다.

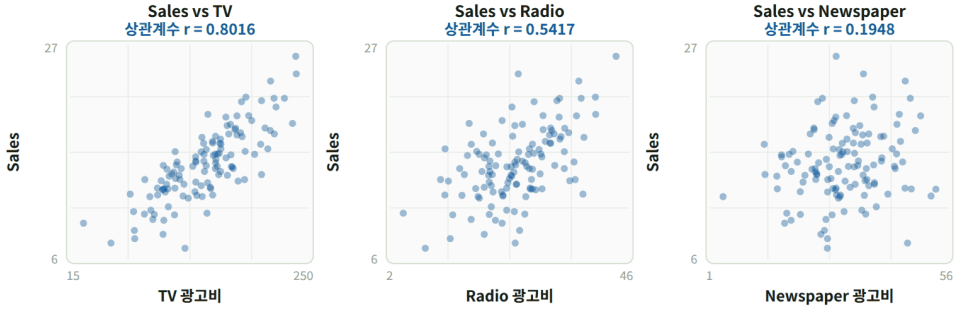
**45. 앙상블(Ensemble) 학습에 관한 설명으로 적절하지 않은 것은?**

**① 앙상블에 사용하는 개별 모델들 사이의 상관관계가 높을수록 예측 정확도가 향상된다.**
② 여러 모델을 결합하므로 단일 모델보다 일반화 성능이 좋아질 수 있다.
③ 여러 모델의 예측 결과를 투표나 평균 등의 방법으로 결합한다.
④ 개별 모델들의 다양성(Diversity)을 확보하는 것이 중요하다.

> **정답 ①**
> 모델들이 유사한 오류를 내면 결합의 이점이 작아진다. 적절한 개별 성능과 오류의 다양성을 확보하는 것이 중요하며 상관관계가 높을수록 항상 정확도가 향상되는 것은 아니다.

**46. 아래 산점도를 해석한 내용 중 적절하지 않은 것은?**

어느 회사가 여러 지역에서 집행한 매체별 광고비(TV · Radio · Newspaper)와 매출액(Sales)의 관계를 산점도로 나타내고 각 상관계수를 함께 표시한 결과는 다음과 같다.




점 하나가 관측치 하나(총 120건)이며, 축 양끝의 숫자는 각 변수의 최솟값과 최댓값이다.

① TV 광고비와 Sales 사이에는 양의 상관관계가 나타난다.
② TV 광고비와 Sales 사이에는 비교적 강한 선형적 관련성이 존재한다.
③ TV 광고비가 높은 관측치에서 Sales도 높게 나타나는 경향이 있다.
**④ TV 광고비를 늘리면 Sales가 증가한다는 것을 알 수 있다.**

> **정답 ④**
> TV와 Sales의 상관계수는 0.8016으로 비교적 강한 양의 관련성을 보인다. 관측 산점도만으로 광고비 증가가 매출 증가의 원인이라고 확정할 수는 없다. 인과 추론에는 추가 설계와 분석이 필요하다.

**47. 분석 모델을 구축할 때 학습용·검증용·테스트용 데이터의 분할에 관한 설명으로 옳은 것은?**

**① 학습용 데이터에는 일반적으로 검증용이나 테스트용보다 더 많은 비율을 할당한다.**

② 검증용 데이터는 모델의 최종 성능을 평가하기 위해서만 사용한다.

③ 테스트용 데이터를 이용하여 모델의 파라미터를 학습시킨다.

④ 세 종류의 데이터는 항상 동일한 비율로 나누어야 한다.

**정답 ①**

일반적으로 학습 데이터 비중을 크게 둔다. 학습 데이터는 파라미터 학습, 검증 데이터는 모델·하이퍼파라미터 선택, 테스트 데이터는 최종 성능 평가에 사용한다. 동일 비율은 필수가 아니다.

**48. 의사결정나무에서 사용하는 지니지수(Gini index)에 대한 설명으로 틀린 것은?**

① 지니지수는 노드의 불순도를 나타내는 지표이다.

② 노드에 한 가지 클래스만 존재하면 지니지수는 0이 된다.

③ 지니지수가 작을수록 해당 노드는 순수하다고 볼 수 있다.

**④ 지니지수가 낮아질수록 노드의 불순도는 높아진다.**

**정답 ④**

$Gini = 1 - \sum_k pk2$ 이다. 한 클래스만 있으면 0이며 값이 작을수록 순수하다. 지니지수 감소를 불순도 증가로 해석한 ④는 틀리다.

**49. 아래 혼동행렬로부터 계산한 오분류율(Error Rate)로 옳은 것은?**

어떤 분류 모델의 예측 결과를 정리한 혼동행렬(Confusion Matrix)은 다음과 같다.

| | 예측 = True | 예측 = False | 합계 |
|---|---|---|---|
| **실제 = True** | 40 | 90 | 130 |
| **실제 = False** | 60 | 60 | 120 |
| **합계** | 100 | 150 | 250 |

① 0.20

② 0.40

③ 0.55

**④ 0.60**

**정답 ④**

오분류는 FN = 90과 FP = 60으로 총 150건이다. 오분류율 $= (90 + 60)/250 = 0.60$이다. 정확도는 $(40 + 60)/250 = 0.40$이다.

**50. 밀도 기반 군집분석 기법인 DBSCAN에 관한 설명으로 틀린 것은?**

① 군집의 개수 K를 사전에 지정할 필요가 없다.

② 밀도가 낮은 영역의 관측치를 노이즈(이상치)로 분류할 수 있다.

③ 반달 모양이나 오목한 형태 등 비구형 군집도 탐색할 수 있다.

**④ DBSCAN은 군집 간 거리를 이용해 단계적으로 병합하는 계층적 군집분석 방법이다.**

**정답 ④**

DBSCAN은 이웃 반경과 최소 이웃 수를 이용하는 밀도 기반 방법이다. 군집 수를 미리 지정하지 않고 비구형 군집과 노이즈를 탐색할 수 있다. 단계적 병합은 계층적 군집분석의 설명이다.