ADsP 데이터분석 준전문가 · 1과목 데이터 이해

# 1과목 데이터 이해 쉽게 이해하는 핵심 정리

초보자를 위한 설명 · 시험에 중요한 내용 중심 · 단원마다 출제 유형과 함정 정리

| | |
|---|---|
| **1단원** | 데이터와 정보 (1장 1절) |
| **2단원** | 데이터베이스와 활용 (1장 2~3절) |
| **3단원** | 빅데이터의 이해와 가치 (2장 1~2절) |
| **4단원** | 빅데이터의 위기 요인과 미래 (2장 3~4절) |
| **5단원** | 데이터 사이언스와 전략 인사이트 (3장) |

**보는 법**

· 노란 상자 = 한 문장 요약·외우는 법 · 초록 상자 = 시험 출제 유형과 함정

# 1단원 데이터와 정보 (1장 1절)

**한 문장 요약:** 데이터는 **가공하지 않은 사실**입니다. 이것을 가공하면 정보가, 정리해서 내 것으로 만들면 지식이, 여기에 아이디어를 더하면 지혜가 됩니다(**DIKW**). 사람 머릿속 지식(암묵지)과 문서로 된 지식(형식지)이 서로 바뀌는 과정(**SECI**)도 함께 배웁니다.

## 1. 데이터란?

- **데이터(Data)** = 있는 그대로의 **객관적 사실(fact)**입니다. 다른 데이터와 관계를 맺기 전에는 **그 자체로 의미가 중요하지 않습니다.**
- 데이터는 **추론·예측·전망·추정의 근거**가 됩니다.
- **존재적 특성:** 객관적 사실 / **당위적 특성:** 추론·추정의 근거

| 구분 | 정성적 데이터 | 정량적 데이터 |
|---|---|---|
| 형태 | **언어, 문자** (설문 응답 글, SNS 글) | **수치, 기호, 도형** (키, 매출, 온도) |
| 구조 | 주로 **비정형** | 주로 **정형** |
| 저장·검색·분석 | **비용과 기술이 많이 듦** | 상대적으로 쉬움 |

**정형 · 반정형 · 비정형**

| 정형 | 반정형 | 비정형 |
|---|---|---|
| 정해진 형식(표, 행과 열) | 형식은 있지만 값과 구조가 함께 들어 있음 | 정해진 형식이 없음 |
| 관계형 DB, 엑셀 | **XML, HTML, JSON**, 로그 | **텍스트, 이미지, 영상, 음성** |

## 2. 데이터의 단위

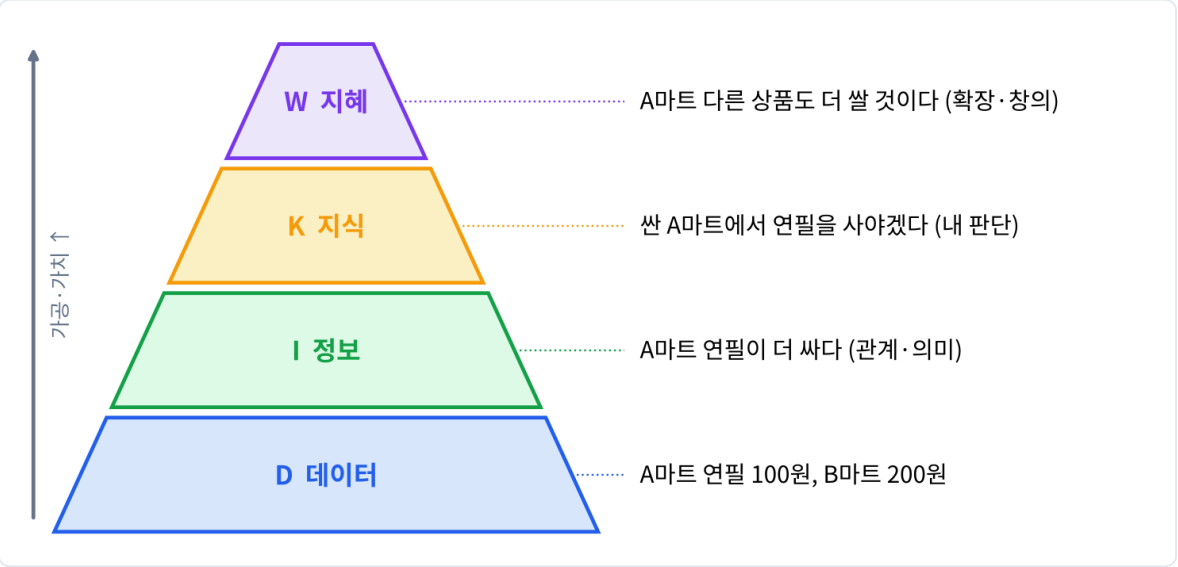
- **비트(bit)** = 0 또는 1 하나로, 컴퓨터가 처리하는 **가장 작은 단위**입니다.
- **바이트(byte)** = 8비트입니다. 영문 한 글자를 나타냅니다.
- 그 위로는 1,024배씩 커집니다.




▲ 데이터 단위: 킬로부터 요타까지, 한 칸 올라갈 때마다 1,024배

**외우기:** "**킬·메·기·테·페·엑·제·요**"(KB, MB, GB, TB, PB, EB, ZB, YB). 빅데이터는 보통 **테라·페타** 이상을 말합니다.

## 3. DIKW 피라미드




▲ 아래에서 위로 갈수록 가공되고 가치가 높아진다 (마트 연필 예시)

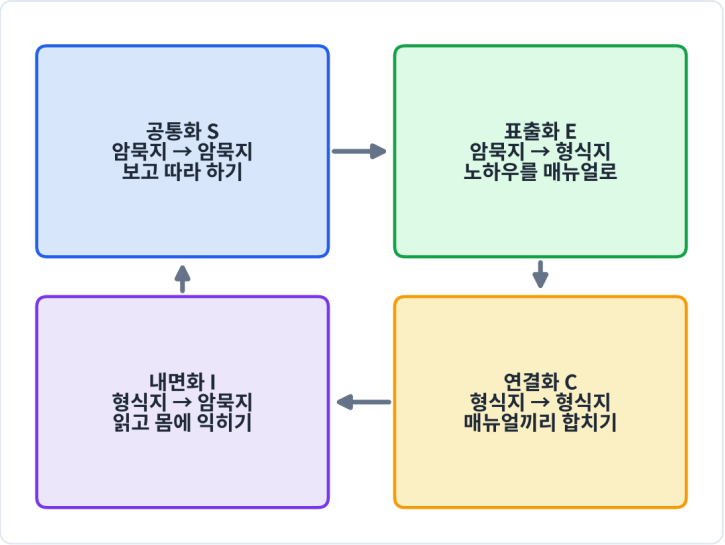
| 단계 | 뜻 | 마트 연필 예시 |
|---|---|---|
| **D 데이터** | 가공하지 않은 **개별 사실** | A마트 연필 100원, B마트 연필 200원 |
| **I 정보** (Information) | 데이터를 가공·처리해 **데이터 사이 관계에서 의미**를 도출 | A마트 연필이 **더 싸다** |
| **K 지식** | 정보를 구조화하고 **개인의 경험과 결합**해 내 것으로 만든 것 | 상대적으로 싼 A마트에서 **연필을 사야겠다** |
| **W 지혜** | 지식에 **아이디어를 결합**한 창의적 산물 | A마트의 **다른 상품도** B마트보다 쌀 것이다 |

- **I는 Information(정보)**입니다. Insight가 아닙니다.
- **데이터를 가공하면 곧바로 지식이 되지는 않습니다.** 반드시 정보 단계를 거칩니다.
- 구분 요령은 이렇습니다.
- **숫자 그대로**면 데이터입니다.
- **비교·비율·관계**가 보이면 정보입니다. 예: "총매출 중 내수 비중 32%"는 계산된 관계라서 **정보**입니다.
- **"~해야겠다"**(나의 판단과 행동)면 지식입니다.
- **"~일 것이다"**(다른 상황으로 넓힌 예측)면 지혜입니다.

## 4. 암묵지와 형식지, SECI 모델

| | 암묵지 (Tacit) | 형식지 (Explicit) |
|---|---|---|
| 뜻 | 학습과 경험으로 **개인에게 쌓인**, 겉으로 드러나지 않는 지식 | **문서·매뉴얼**처럼 형상화된 지식 |
| 예 | 김치 담그는 손맛, 자전거 타는 감각 | 레시피 책, 업무 매뉴얼, 교과서 |
| 공유 | **어려움** (말로 전하기 힘듦) | **쉬움** (전달·공유가 빠름) |

**SECI 모델** (노나카의 지식 창조 과정): 암묵지와 형식지가 서로 바뀌며 지식이 커집니다.




▲ 공통화 → 표출화 → 연결화 → 내면화 (S → E → C → I)

| 단계 | 변환 | 예 |
|---|---|---|
| **공통화** (Socialization) | 암묵지 → **암묵지** | 선배 옆에서 보고 따라 하며 배움 |
| **표출화** (Externalization) | 암묵지 → **형식지** | 선배의 노하우를 매뉴얼로 씀 |
| **연결화** (Combination) | 형식지 → **형식지** | 여러 매뉴얼을 합쳐 새 매뉴얼을 만듦 |
| **내면화** (Internalization) | 형식지 → **암묵지** | 매뉴얼을 읽고 익혀 내 몸에 익힘 |

**외우기:** 순서는 **S-E-C-I**(공 → 표 → 연 → 내)입니다. "**표**출 = **표**(문서)로 꺼냄", "**내**면 = **내** 안으로"로 외웁니다.

### 시험에는 이렇게 나옵니다 · 출제 유형과 함정

- **DIKW 정의 바꿔치기:**
- "데이터는 지식과 아이디어가 결합된 창의적 산물" → 틀림 (그건 **지혜**)
- "I는 **Insight**" → 틀림 (**Information**)
- "데이터는 가공하면 곧바로 지식" → 틀림
- **DIKW 예시 분류:** 보기 4개 중 단계가 다른 하나 고르기, 가~라 예시를 D·I·K·W와 짝짓기 → 위 구분 요령(숫자 / 관계 / ~해야겠다 / ~일 것이다)으로 풉니다.
- **정성·정량:** "**정량적** 데이터가 분석 비용이 더 많이 든다" → 틀림 (**정성적**이 더 듦). 정성적 = 문자·언어, 주로 비정형
- **데이터 단위:** "**바이트**가 최소 단위로 0 또는 1" → 틀림 (그건 **비트**). PB < EB < ZB < YB 순서
- **SECI:** 순서는 공통화 → 표출화 → 연결화 → 내면화. 암묵지를 형식지로 바꾸는 것은 **표출화**. "연결화는 새로운 **암묵지**를 창출" → 틀림 (연결화는 형식지 → **형식지**)
- **암묵지:** "암묵지는 문서 형태라 공유가 쉽다" → 틀림 (그건 **형식지**)

# 2단원 데이터베이스와 활용 (1장 2~3절)

**한 문장 요약:** 데이터베이스는 데이터를 **여러 사람이 여러 목적으로 쓸 수 있게 정리해 둔 창고**입니다. 하루하루 거래를 처리하는 **OLTP**, 모아서 분석하는 **OLAP·데이터 웨어하우스**, 기업이 쓰는 **ERP·CRM·SCM** 같은 시스템의 특징과 차이가 시험에 자주 나옵니다.

## 1. 데이터베이스와 DBMS

- **데이터베이스(DB):** 체계적으로 **수집·축적**해서 다양한 용도와 방법으로 쓸 수 있게 **일정한 구조**로 정리한 데이터의 모음입니다. 그 자체로 **구조적 체계**를 가집니다.
- **DBMS**(DataBase Management System): DB를 만들고, 저장하고, 고치고, 꺼내 쓰게 해 주는 **관리 소프트웨어**입니다. 예: Oracle, MySQL
- DBMS에는 관계형(**표**), 객체지향형, 네트워크형 등이 있습니다. **항상 2차원 표인 것은 아닙니다.**
- DBMS는 **무결성**(데이터의 **정확성과 일관성** 유지), 보안, 동시 접근 제어, 회복 기능을 제공합니다.
- **SQL:** DB를 다루는 언어입니다.
- 정의 **DDL**: CREATE, ALTER, DROP
- 조작 **DML**: SELECT, INSERT, UPDATE, DELETE
- 제어 **DCL**: GRANT, REVOKE

## 2. 데이터베이스의 특징 4가지

| 특징 | 뜻 | 쉬운 말 |
|---|---|---|
| **통합된 데이터** | 같은 내용이 **중복되지 않음** | 한 곳에 한 번만 |
| **저장된 데이터** | 컴퓨터가 접근할 수 있는 **저장 매체**에 저장 | 컴퓨터 안에 |
| **공용 데이터** | 여러 사용자가 **서로 다른 목적**으로 함께 이용 | 모두가 각자 용도로 |
| **변화되는 데이터** | 새 데이터 추가, 기존 데이터 **갱신·삭제**에도 현재의 정확한 데이터를 유지 | 계속 바뀜 |

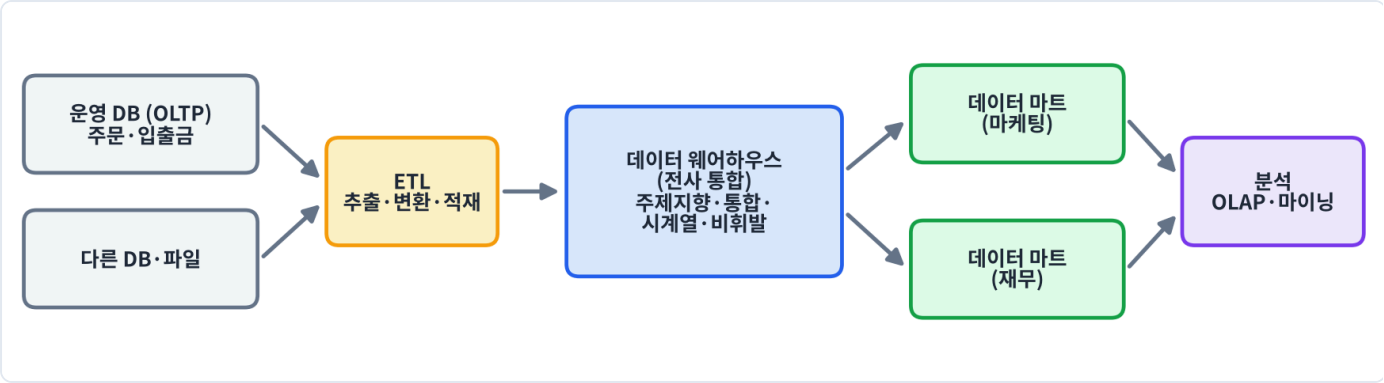
> **외우기:** "**통·저·공·변**" (통합, 저장, 공용, 변화)

## 3. 데이터베이스의 다양한 측면

| 측면 | 내용 |
|---|---|
| **정보의 축적·전달** | **기계 가독성**(기계가 읽고 씀), **검색 가능성**(쉽게 찾음), **원격 조작성**(멀리서도 이용) |
| **정보 이용** | 이용자가 원하는 정보를 **정확하고 경제적으로** 빠르게 얻음 |
| **정보 관리** | 정보를 **일정한 구조에 따라 체계적으로** 저장하고, **추가·갱신**이 쉬움 |
| **정보기술 발전** | 정보처리·검색·관리 **소프트웨어, 하드웨어, 네트워크 기술의 발전을 이끔** |
| **경제·산업** | 경제·산업 활동의 효율성을 높이고 국민 생활의 편의를 높이는 **인프라** |

## 4. OLTP와 OLAP, 데이터 웨어하우스

| | OLTP | OLAP |
|---|---|---|
| 풀네임 | On-Line **Transaction** Processing | On-Line **Analytical** Processing |
| 하는 일 | 실시간 **거래 처리**: 짧고 빈번한 입력·수정·삭제 | **다차원 분석**: 여러 관점(기간·지역·상품)으로 집계·조회 |
| 예 | 은행 입출금, 온라인 주문, 예약 | 지역별·월별 매출 분석 |
| 데이터 | 현재의 상세 데이터 | 요약·이력 데이터 |




▲ 운영 DB(OLTP) → ETL → 데이터 웨어하우스 → 데이터 마트 → 분석(OLAP·데이터 마이닝)

- **ETL**(Extract, Transform, Load): 여러 DB에서 데이터를 **추출**해 **정리·변환**한 뒤 **적재**하는 과정입니다.
- **데이터 웨어하우스(DW):** 분석을 위해 **전사의 데이터를 통합**해 둔 저장소입니다.
- 특징 4가지: **주제 지향성, 통합성, 시계열성**(시간 이력 보관), **비휘발성**(읽기 위주, 자주 바뀌지 않음)
- **데이터 마트(DM):** DW에서 **특정 부서나 주제**에 맞게 추린 **부분집합**입니다. DW보다 작고 빨리 만들 수 있습니다.
- **데이터 마이닝:** 대량의 데이터에서 **숨은 패턴과 규칙**을 찾아내는 것입니다.

## 5. 기업 내부 데이터베이스 솔루션

| 약자 | 풀네임 | 하는 일 |
|---|---|---|
| **ERP** | Enterprise Resource Planning (전사적 자원 관리) | 인사·재무·생산·물류 등 기업 자원을 **통합 관리** |
| **CRM** | Customer Relationship Management (고객 관계 관리) | **고객** 데이터로 마케팅·고객 유지 |
| **SCM** | Supply Chain Management (공급망 관리) | 원자재 **조달 → 생산 → 유통 → 소비자**까지 공급망 최적화 |
| **BI** | Business Intelligence | 데이터를 모아 **리포트·대시보드**로 의사결정 지원 (과거·현재 중심) |
| **BA** | Business Analytics | 통계·예측 분석으로 **미래와 최적화**까지 (BI보다 진보) |
| **KMS** | Knowledge Management System | 조직의 **지식**을 공유·관리 |

- **CRM은 고객, SCM은 공급망**입니다. 둘 다 **온라인·오프라인 모두**에 적용됩니다.

### 시험에는 이렇게 나옵니다 · 출제 유형과 함정

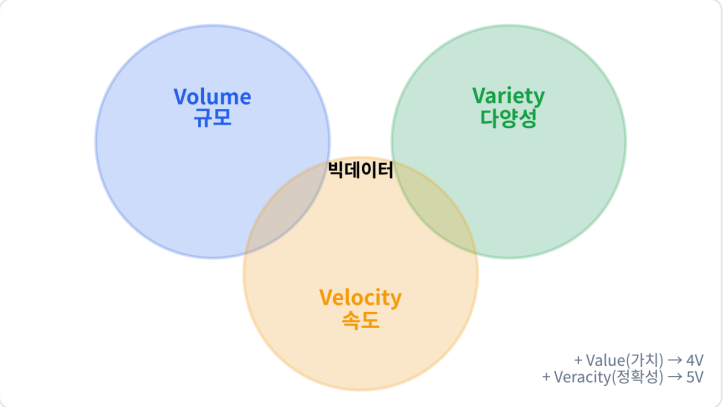
- **DB 특징:**
- "모든 사용자가 **동일한 목적**으로 활용" → 틀림 (**서로 다른** 목적, 공용)
- "일관성을 위해 **중복 저장**이 원칙" → 틀림 (통합 = **중복 없음**)
- "**고정** 데이터라 갱신 불가" → 틀림 (변화되는 데이터)
- "그 자체로 **구조적 체계가 없다**" → 틀림
- "**항상 2차원 표**로만 구성" → 틀림
- **DBMS:** 데이터의 일관성·정확성을 유지하는 특징 → **무결성**
- **DB의 측면 구분:**
- 기계 가독성·검색 가능성·원격 조작성 → **정보의 축적·전달** 측면
- "일정한 구조로 저장하고 갱신·수정 가능" → **정보 관리** 측면
- SW·HW·네트워크 발전 견인 → **정보기술 발전** 측면. 이것을 "정보 관리"라고 바꿔 놓는 함정이 나옵니다.
- **OLTP·OLAP:** "OLTP는 **조회·분석**에 주로 사용" → 틀림 (그건 OLAP). 실시간 거래를 짧고 빈번하게 처리하는 시스템 → **OLTP**

- **DW·DM:** DM은 DW에서 특정 부서·주제에 맞게 뽑은 **부분집합**. "전사 DW는 비용이 너무 크고 마케팅 부서가 당장 분석하고 싶다" → **데이터 마트**
- **ETL·데이터 마이닝** 설명이 맞는지 고르는 보기형도 나옵니다.
- **CRM·SCM:** "**CRM**이 원자재 조달~유통 관리" → 틀림 (그건 **SCM**). "CRM은 온라인만, SCM은 오프라인만" → 틀림

# 3단원 빅데이터의 이해와 가치 (2장 1~2절)

**한 문장 요약:** 빅데이터는 **너무 크고(Volume), 다양하고(Variety), 빠르게 생겨서(Velocity)** 기존 방법으로는 다루기 어려운 데이터입니다. 빅데이터는 분석 방식 자체를 바꿨고(**사전 → 사후, 표본 → 전수, 질 → 양, 인과 → 상관**), 최종 목표는 **새로운 가치 창출**입니다.

## 1. 빅데이터의 정의: 3V




▲ 빅데이터의 기본 3V. 여기에 가치(Value)·정확성(Veracity)을 더해 4V, 5V라고도 한다

| V | 뜻 | 예 |
|---|---|---|
| **Volume** (규모) | 데이터의 **양**이 매우 큼 | 테라·페타바이트 이상 |
| **Variety** (다양성) | 정형·반정형·**비정형** 등 종류가 다양 | 텍스트, 영상, 센서, 로그 |
| **Velocity** (속도) | 생성·처리 **속도**가 빠름 | 실시간 SNS, 센서 데이터 |
| Value (가치) | 4V에서 추가: 비즈니스 **가치** | |
| Veracity (정확성) | 5V에서 추가: 데이터의 **신뢰성** | |

- **Availability**(가용성), **Visualization**은 기본 3V가 **아닙니다.**
- 정의는 관점에 따라 다릅니다. **데이터 자체**(규모가 큰 데이터)로 보기도 하고, 이를 다루는 **기술·인재·프로세스까지 포함**하는 넓은 개념으로 보기도 합니다.

## 2. 빅데이터의 출현 배경

| 분야 | 배경 |
|---|---|
| **산업계** | 고객·운영 데이터가 대량으로 **축적**됨 → 양이 질을 바꿈(양질 전환) |
| **학계** | 인간 게놈, 기후, 천문학처럼 **거대 데이터를 다루는 연구** 증가 |
| **기술** | **디지털화**, 저장 비용 하락, 인터넷·모바일 보급, **클라우드**, 분산 처리 기술 발전 |

## 3. 빅데이터를 비유하면

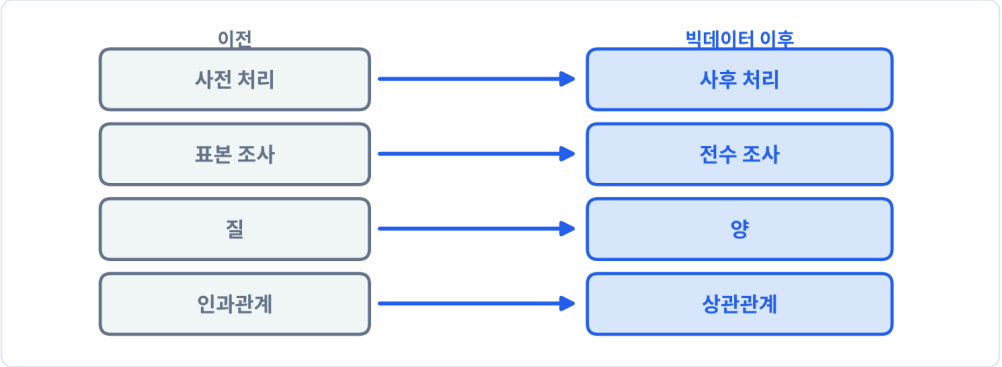
| 비유 | 뜻 |
|---|---|
| **산업혁명의 석탄·철** | 모든 산업의 생산성을 끌어올리는 **기반** |
| **21세기의 원유** | 새로운 산업을 만드는 **연료** |
| **렌즈** | 현미경처럼 이전에 **보이지 않던 것**을 보여 줌 (예: 구글 독감 트렌드) |
| **플랫폼** | 여러 서비스가 올라가는 **공동 활용의 기반** (예: 페이스북) |

## 4. 빅데이터 가치 패러다임의 변화

**Digitalization(디지털화) → Connection(연결) → Agency(에이전시)**

- 디지털화: 아날로그를 디지털로 바꿈
- 연결: 디지털화된 정보와 대상이 서로 **연결**됨
- 에이전시: 복잡한 연결을 **효과적으로 관리**해 주는 단계 (지금 우리가 들어선 단계)

## 5. 빅데이터가 만든 본질적 변화 4가지




▲ 데이터 분석 방식의 네 가지 변화

| 이전 | 이후 | 뜻 |
|---|---|---|
| **사전 처리** | **사후 처리** | 미리 정해진 형식으로 걸러 모으지 않고, 일단 모은 뒤 필요할 때 가공 |
| **표본 조사** | **전수 조사** | 처리 비용이 낮아져 전체를 분석 |
| **질** | **양** | 데이터가 많으면 일부 오류가 있어도 좋은 결과 |
| **인과관계** | **상관관계** | "왜"를 몰라도 "무엇"이 일어나는지 빨리 파악해 대응 |

## 6. 빅데이터 활용의 3대 요소

| 요소 | 뜻 |
|---|---|
| **데이터** | 모든 것을 데이터로 만드는 **데이터화**(datafication) |
| **기술** | 진화하는 **알고리즘**, 인공지능 |
| **인력** | **데이터 사이언티스트**, 알고리즈미스트 |

**"프로세스"는 3대 요소가 아닙니다.**

## 7. 빅데이터의 가치를 산정하기 어려운 이유

| 이유 | 설명 |
|---|---|
| **데이터 활용 방식** | 재사용·재조합·다목적 활용이 일반화되어, **누가 언제 어디서** 활용할지 알 수 없음 |
| **새로운 가치 창출** | 이전에 없던 가치를 만들어서 기존 기준으로 측정하기 어려움 |
| **분석 기술의 발전** | 지금은 가치 없는 데이터도 새 분석 기법이 나오면 **큰 가치**를 가질 수 있음 |

빅데이터 분석·활용의 **최종 목표는 새로운 가치 창출**입니다. 기업은 혁신·경쟁력·생산성을, 정부는 환경 탐색·상황 분석·미래 대응을, 개인은 맞춤형 서비스를 얻습니다.

## 8. 빅데이터 활용 기본 테크닉 7가지

| 기법 | 질문 | 활용 예 |
|---|---|---|
| **연관 규칙 학습** | 어떤 것이 **함께** 일어나나? | 커피를 사는 사람은 탄산음료도 많이 사나? (장바구니 분석) |
| **유형 분석** (분류) | 이것은 **어느 그룹**에 속하나? | 문서 분류, 고객 등급 분류, 스팸 메일 |
| **유전자 알고리즘** | **최적의 해**는? (진화를 흉내 냄: 선택·교배·돌연변이) | 연료 효율이 가장 좋은 차량 설계, 택배 차량 배치 |
| **기계 학습** | 학습해서 **예측**하면? | 넷플릭스 영화 추천 |
| **회귀 분석** | X가 변하면 Y는 **얼마나** 변하나? | 공부 시간에 따른 성적, 나이에 따른 만족도 |
| **감정 분석** | 글에 담긴 **긍정·부정**은? | 호텔 리뷰, 신제품 SNS 반응 |
| **소셜 네트워크 분석** | 누가 **영향력** 있는 사람인가? | 고객 간 관계, 인플루언서 찾기 |

- **분류와 회귀를 구분하세요.** 결과가 **범주**(그룹, 등급)면 분류이고, **숫자**(가격, 성적)면 회귀입니다. 예: "아파트 가격 예측"은 회귀입니다.
- **연관분석**은 "함께 일어나는 규칙"을 찾는 것이지, 변수 사이의 **선형관계**를 보는 것이 아닙니다(그건 회귀·상관).

## 9. 빅데이터 처리 기술

| 기술 | 설명 |
|---|---|
| **하둡(Hadoop)** | 대용량 데이터를 여러 컴퓨터에 나눠 저장(HDFS)하고 처리하는 오픈소스 프레임워크 |
| **맵리듀스 (MapReduce)** | 작업을 나눠(Map) 여러 서버에서 **병렬 처리**한 뒤 합침(Reduce). **저렴한 범용 서버** 여러 대로 처리해 **비용 절감** |
| **NoSQL** | 정해진 표 구조 없이 비정형 데이터를 유연하게 저장하는 DB |

### 시험에는 이렇게 나옵니다 · 출제 유형과 함정

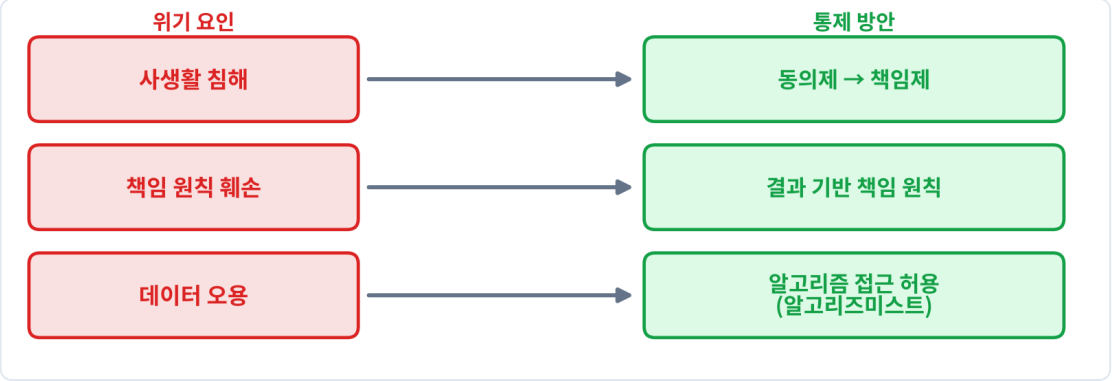
- **3V:** 기본 3V는 Volume·Variety·Velocity. "**Availability**" 같은 엉뚱한 V를 함정 보기로 냅니다.
- **본질적 변화:**
- "질 중심에서 **양** 중심" → 맞음
- "'왜'보다 '무엇'을 빨리 파악" → **인과관계 → 상관관계**
- 방향을 거꾸로 쓴 보기(양 → 질, 전수 → 표본)가 함정입니다.
- **출현 배경:** 산업계 축적, 학계 연구, 기술 발전 → 셋 다 맞음
- **3대 요소:** 데이터·기술·인력. "**프로세스**"는 아님
- **가치 패러다임: Digitalization → Connection → Agency**
- **최종 목표: 새로운 가치 창출**. "빅데이터로는 개인 맞춤 서비스가 **불가능**" → 틀림

- **기법과 사례 짝짓기 (매회 나옴):**
- 진화를 흉내 내 최적의 해 찾기 → **유전자 알고리즘** (군집분석 아님)
- "아파트 가격 예측"을 **분류** 사례라고 함 → 틀림 (회귀)
- 공부시간에 따른 성적 변화 → **회귀**
- 설문조사를 **소셜 네트워크 분석**이라고 함 → 틀림
- "연관분석은 **선형관계**를 파악" → 틀림
- **맵리듀스:** 저렴한 범용 서버 여러 대로 **병렬 처리** → 비용 절감

# 4단원 빅데이터의 위기 요인과 미래 (2장 3~4절)

**한 문장 요약:** 빅데이터에는 **사생활 침해, 책임 원칙 훼손, 데이터 오용**이라는 세 가지 위기가 있습니다. 해결책은 각각 **동의에서 책임으로, 결과 기반 책임 원칙, 알고리즘 접근 허용(알고리즘미스트)**입니다. 이 짝짓기가 매회 출제됩니다.

## 1. 위기 요인과 통제 방안




▲ 위기 요인 3가지와 통제 방안의 짝

| 위기 요인 | 무슨 일? | 통제 방안 |
|---|---|---|
| **사생활 침해** | 여러 데이터를 조합해 개인을 알아내고 사생활을 침해 (SNS 글로 여행 중인 집을 노린 절도) | 개인정보 제공자의 **'동의제' → 사용자의 '책임제'**로 전환 |
| **책임 원칙 훼손** | 예측만으로 **아직 하지 않은 일**에 불이익 (범죄 예측으로 체포, 신용 예측으로 대출 거절) | **결과 기반 책임 원칙** 고수: 실제 **행동의 결과**에 대해서만 책임을 물음 |
| **데이터 오용** | 데이터나 알고리즘이 틀렸는데 그대로 믿고 판단해 피해 | **알고리즘 접근 허용**, 객관적 인증 방안, **알고리즈미스트** |

- **알고리즈미스트(Algorithmist):** 알고리즘을 해석해서, 그 때문에 **부당하게 피해를 본 사람을 구제**하는 전문 인력입니다. 데이터 사이언티스트와는 **별개의 직업**입니다.
- **왜 '동의'만으로는 안 될까?** 데이터가 너무 많고 활용 방식이 다양해서, 제공자가 매번 동의하는 방식으로는 막을 수 없습니다. 그래서 **사용하는 쪽이 책임**을 지게 합니다. "사전 동의 절차 **강화**"는 해결책이 아닙니다.
- **익명화도 완전한 해결책은 아닙니다.** 여러 데이터를 결합하면 다시 식별될 수 있기 때문입니다.

## 2. 개인정보 비식별화 기술

개인을 알아볼 수 없게 데이터를 바꾸는 기술입니다.

| 기법 | 방법 | 예 |
|---|---|---|
| **가명 처리** | 식별 값을 **다른 값으로 대체** | 홍길동 → 임꺽정, 회원 A |
| **총계 처리** | 개별 값 대신 **합계·평균** | 각자의 키 → 반 평균 키 |
| **데이터 삭제** | 식별 가능한 값을 **삭제** | 주민번호 열 삭제 |
| **데이터 범주화** | 정확한 값을 **범위·구간**으로 | 35세 → 30대 |
| **데이터 마스킹** | 일부를 ***, 공백, 노이즈**로 가림 | 홍**, 010-****-1234 |

- **익명화:** 다른 정보와 결합해도 **다시 식별할 수 없게**(재식별 불가) 처리하는 것입니다.
- **가명화(가명 처리): 추가 정보가 있으면 다시 식별할 수 있는** 수준으로 처리하는 것입니다.

## 3. 빅데이터 활용 방식과 미래

- **데이터:** 모든 것이 데이터가 됩니다(**데이터화**, datafication). 사물인터넷(IoT)으로 사람과 사물 모두에서 데이터가 나옵니다.
- **기술:** 진화하는 알고리즘과 인공지능이 데이터를 분석합니다.
- **인력:** 데이터 사이언티스트와 **알고리즈미스트**가 필요합니다.
- **올바른 활용:** 데이터를 활용해 서비스를 개선하고 의사결정을 하는 것입니다. 개인정보를 무분별하게 **대규모로 공유**하는 것은 올바른 활용이 아닙니다.

### 시험에는 이렇게 나옵니다 · 출제 유형과 함정

- **위기 요인 고르기:** 사생활 침해·책임 원칙 훼손·데이터 오용 → 위기 요인. **익명화**, **알고리즘 접근 허용**은 통제 **방안**이고 위기 요인이 아닙니다. "**기업 경쟁력 약화**"도 위기 요인이 아닙니다.
- **짝짓기 (가장 자주):**
- 사생활 침해 ↔ **동의제 → 책임제**
- 책임 원칙 훼손 ↔ **결과 기반 책임 원칙**
- 데이터 오용 ↔ **알고리즘 접근 허용**
- 짝을 서로 바꿔 놓은 보기를 모두 고르게 합니다.
- **해결 방안이 아닌 것:** "개인정보 활용의 **사전 동의 절차 강화**" → 아님 (책임제로 전환). "익명화 기술만 발전하면 **완전히** 해결" → 틀림
- **비식별화:** "**데이터 마스킹**은 식별 가능한 값을 **삭제**" → 틀림 (가리기·대체. 삭제는 **데이터 삭제**). 재식별할 수 없게 처리 → **익명화**
- **알고리즈미스트:** "**데이터 사이언티스트**가 피해자 구제와 법적 조치까지 병행해야 한다" → 틀림 (그건 별도 전문가인 알고리즈미스트)
- **활용 방식:** "개인정보를 **대규모로 공유**" → 적절하지 않음. "전문가 면담**만으로** 업무 개선" → 데이터 활용 사례가 아님

# 5단원 데이터 사이언스와 전략 인사이트 (3장)

**한 문장 요약:** 빅데이터의 핵심은 **크기가 아니라 인사이트**입니다. 데이터에서 의미를 뽑아 **가치를 만드는 학문**이 데이터 사이언스이고, 이를 하는 사람이 데이터 사이언티스트입니다. 사이언티스트에게는 기술(**하드 스킬**)뿐 아니라 소통·통찰력(**소프트 스킬**)이 중요합니다.

## 1. 빅데이터 분석, 무엇이 중요한가

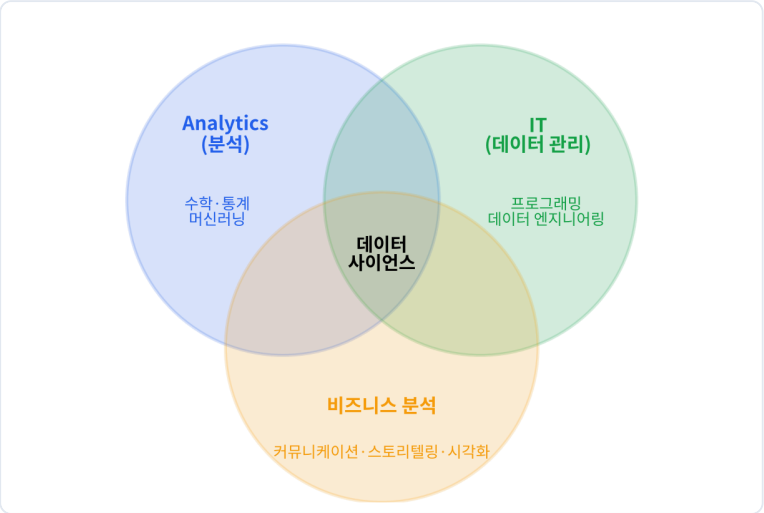
- **빅데이터 회의론:** 큰 투자를 했지만 효과가 없던 과거 경험(예: CRM 도입 실패)과, 성공 사례가 실제로는 빅데이터가 아닌 기존 분석이었던 경우 때문에 생긴 회의적 시각입니다.

- **크기보다 인사이트:** 데이터가 많다고 좋은 결과가 나오지 않습니다. **어떤 질문을 던지고 어떤 인사이트를 얻느냐**가 중요합니다.
- **전략적 통찰이 없는 분석의 함정:** 단순히 남들이 하는 분석을 따라 하면(**일차적 분석**) 차별화가 어렵습니다.

| 일차적 분석 | 전략 도출 가치 기반 분석 |
|---|---|
| 부서 단위의 **운영 효율** 개선 (재고 관리, 고객 이탈 감지) | 사업 **전체의 전략**과 환경 변화를 고려한 분석 |
| 업계 내부 문제에만 초점 | 사업 성과를 좌우하는 **핵심 요인**과 새로운 기회 탐색 |

## 2. 데이터 사이언스란?

- **데이터로부터 의미 있는 정보를 추출하는 학문**입니다.
- **통계학과의 차이:** 통계학은 주로 **정형 데이터**를 분석합니다. 데이터 사이언스는 **정형·비정형을 모두** 다루고, 분석뿐 아니라 이를 **구현하고 전달하는 과정까지** 포함하는 더 넓은 개념입니다.
- 데이터 마이닝과 비교하면, 데이터 마이닝은 **분석**에 초점을 두고 데이터 사이언스는 분석에서 **구현·전달까지** 아우릅니다.




▲ 데이터 사이언스의 세 영역: 분석 · IT · 비즈니스

| 영역 | 내용 |
|---|---|
| **Analytics** (분석) | 수학, 통계, 확률 모델, 머신러닝, 패턴 인식 |
| **IT** (데이터 관리) | 프로그래밍, 데이터 엔지니어링, 데이터 웨어하우징, 고성능 컴퓨팅 |
| **비즈니스 분석** | 커뮤니케이션, 프레젠테이션, **스토리텔링**, 시각화 |

## 3. 데이터 사이언티스트의 역량

| 하드 스킬 (Hard Skill) | 소프트 스킬 (Soft Skill) |
|---|---|
| 빅데이터에 대한 **이론적 지식** (관련 기법 이해, 방법론 습득) | **통찰력 있는 분석**: 창의적 사고, **호기심**, 논리적 **비판** |
| 분석 기술의 **숙련도** (최적의 분석 설계, 노하우 축적, **프로그래밍**) | **설득력 있는 전달**: **스토리텔링**, 시각화 |
| | **다분야 간 협력**: **커뮤니케이션** |

- **알고리즘 이해, 분석 기법 지식, 프로그래밍은 하드 스킬**입니다. 소프트 스킬로 잘못 짝지은 보기가 함정입니다.
- 데이터 사이언티스트는 혼자 분석만 잘하면 되는 사람이 아닙니다. **의사소통과 협력이 매우 중요합니다.**
- **가트너가 제시한 데이터 사이언티스트 요구 역량:** 데이터 관리, 분석 모델링, 비즈니스 분석, 소프트 스킬

## 4. 인문학이 다시 주목받는 이유

| 변화 | 내용 |
|---|---|
| 단순 세계화 → **복잡한 세계화** | 비즈니스가 다양한 문화와 맞물리면서 문화·사람에 대한 이해가 중요해짐 |
| 제품 생산 → **서비스** | 고객에게 어떤 **경험**을 줄지가 경쟁력 |
| 생산 → **시장 창조** | 기술보다 **새로운 시장을 만드는 능력**이 중요해짐 |

## 5. 분석의 한계: 모델은 가정에 기댄다

- 모든 분석 모델은 **가정**을 바탕으로 합니다. 가정이 현실과 다르면 결과도 틀립니다. 예: 금융위기 전 위험 모델은 "집값은 계속 오른다"는 가정을 깔고 있었습니다.
- 정량 분석이라도 **해석에는 사람의 주관**이 들어갑니다.
- 그래서 데이터 사이언티스트에게는 결과를 **비판적으로 보는 시각**이 필요합니다.

### 시험에는 이렇게 나옵니다 · 출제 유형과 함정

- **소프트 스킬 고르기 (자주 나옴):** 호기심·비판적 시각, 의사소통, 스토리텔링, 협력 → **소프트**. 이론·분석 기법 지식, 프로그래밍, 알고리즘 이해 → **하드**. "소프트 스킬에 **알고리즘 이해와 분석 능력**이 포함된다" → 틀림
- **사이언티스트의 자세:** "개인 분석 능력이 최우선이고 **의사소통은 상대적으로 중요하지 않다**" → 틀림
- **데이터 사이언스:** "통계학처럼 **정형 데이터만**" → 틀림 (정형·비정형 모두). 분석 + 구현 + 전달까지 포함
- **알고리즈미스트와 구분:** 피해 구제는 알고리즈미스트의 일입니다(4단원).
- **인사이트:** 빅데이터 가치의 핵심은 데이터 크기가 아니라 **인사이트**입니다. "데이터가 많을수록 항상 좋은 결과" → 틀림