1장 데이터 마트·탐색적 분석 · 회차별 기출 (45~50회)

정답·해설 (보완판)

쉬운 설명 PDF 2단원(1장 3절) 순서대로 정리

총 9문항 · 문항 끝에 출처(회차·번호) 표시

2단원 탐색적 분석, 결측값과 이상값 (1장 3절)

탐색적 데이터 분석 (EDA)

1. 다음 중 탐색적 데이터 분석(EDA)의 특징으로 적절하지 않은 것은? 47회 22번

① 데이터의 전반적인 구조를 파악하고 이상치 및 결측치를 발견하는 단계이다.

② 동일한 분석 결과를 얻기 위해 재현성을 검증하는 단계이다.

③ 상관관계 분석 및 시각화를 통해 종속변수에 영향을 주는 주요 독립변수를 탐색한다.

④ 변수의 개수, 데이터 타입 및 기초 통계량(평균, 중앙값)을 확인하는 단계이다.

정답 ②

EDA는 구조와 이상치·결측치 탐색이 중심이다. 재현성 검증 자체를 EDA의 주목적으로 볼 수는 없다.

EDA는 분석 전에 데이터의 특성과 문제를 파악하는 탐색 과정이다. 행·열 수, 자료형, 기초 통계량을 확인하고 시각화로 분포·관계·이상치·결측 패턴을 살핀다. 설명변수와 목표값 사이의 관련성을 탐색할 수 있지만 탐색만으로 인과관계를 확정하지 않는다.

보기 판단: ①③④는 EDA의 주요 활동이다. ②는 분석 절차와 환경을 다시 실행했을 때 결과가 재현되는지 확인하는 작업으로, EDA의 대표 목적과 다르다. EDA 코드도 재현 가능하게 작성하는 것이 바람직하지만 재현성 검증 자체를 EDA의 정의로 선택하면 안 된다.

💡 **쉽게 이해하기** EDA(탐색적 데이터 분석)는 요리 전에 **냉장고를 열어 재료를 훑어보는** 단계입니다. 무엇이 있는지(변수·타입), 상한 것은 없는지(이상치·결측치), 어떤 재료가 잘 어울리는지(상관·시각화)를 봅니다. '같은 결과가 다시 나오는지 확인'하는 **재현성 검증**은 분석이 끝난 뒤의 일이라 EDA의 특징이 아닙니다.

결측값

2. 결측값 처리에 대한 설명으로 옳은 것은? 46회 21번

① 결측값을 대체 시 기존 데이터의 평균값으로만 해야 한다.

② 결측값 대체는 표본 수는 유지하여 데이터 손실을 최소화하는 데 목적이 있다.

③ 결측값은 일반적으로 삭제하는 것이 가장 좋은 처리 방법이다.

④ 결측값을 대체하는 것으로 데이터의 편향이 유발되지는 않는다.

정답 ②

②는 결측값 대체가 행 삭제로 인한 표본 손실을 줄이고 관측 자료를 활용하려는 목적을 가진다는 뜻이다. 빈 값이 있는 모든 행을 제거하면 유용한 다른 변수의 정보까지 버릴 수 있다. 다만 대체가 실제 관측 정보를 새로 만들어 내거나 불확실성을 완전히 없애는 것은 아니다.

핵심 개념: 결측값은 관측되어야 할 값이 없거나 기록되지 않은 상태이다. 제거 또는 대체 방법을 선택할 때 결측 원인·비율·변수의 성격과 분석 목적을 함께 고려한다.

보기 검토: ①은 평균 외에도 중앙값·최빈값·모형 기반 대체·다중 대체 등 다양한 방법이 있어 틀리다. ③은 삭제가 항상 최선이라고 일반화해 틀리다. ④는 대체 방법과 결측 원인에 따라 편향이 생길 수 있으므로 틀리다. 특히 같은 평균을 반복 삽입하면 분산을 줄이고 변수 관계를 왜곡할 수 있다.

적용 예: 소득 미응답이 높은 소득군에 집중되어 있다면 전체 평균으로 채우는 것만으로 원래 분포를 회복하기 어렵다. 예측 모형을 만들 때 대체에 사용할 평균·모형은 학습 자료에서 구하고 검증·시험 자료에 적용해야 자료 누출을 피할 수 있다.

💡 **쉽게 이해하기** 결측값 대체는 빈칸을 그럴듯한 값으로 채워서 **행을 버리지 않으려는** 것입니다(표본 수 유지). 채우는 방법은 평균만 있는 게 아니고(중앙값, 회귀 예측, 다중 대치 등), 채운 값이 실제와 다르면 **편향이 생길 수 있습니다.** 무조건 삭제도 정답이 아닙니다.

3. '이름'과 '성별'로 구성된 고객 데이터에서 이름 변수와 성별 변수가 독립적으로 각각 10%의 결측값을 가지고 있다. 이 때 이름 또는 성별 중 하나라도 결측값이 존재하는 고객 데이터를 모두 삭제 시 전체 데이터 중 삭제되는 데이터의 비중은?

48회 46번

① 10%
② 15%
③ 19%
④ 23%

> **정답 ③**
> 삭제되지 않으려면 두 항목 모두 관측되어야 한다. 결측이 독립이므로 완전한 행의 비율은 0.9×0.9=0.81이며 삭제 비율은 1−0.81=0.19이다. 합사건 공식으로도 0.1+0.1−0.1×0.1=0.19이다. 20%로 단순 합산하면 두 항목 모두 결측인 1%를 중복 계산한다. 19%는 이 가정하의 기대 비율이다.

💡 **쉽게 이해하기** '하나라도 결측'은 거꾸로 생각하면 쉽습니다. **둘 다 멀쩡할 확률** = 0.9 × 0.9 = 0.81 (독립이라 곱). 그러면 하나라도 빠진 행 = 1 − 0.81 = **0.19 = 19%**. 10% + 10% = 20%로 더하면 '둘 다 빠진 1%'를 두 번 센 것이라 틀립니다.

4. 결측값(Missing Value) 처리에 대한 설명으로 옳지 않은 것은?

49회 42번

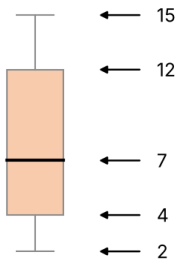
① 완전 분석법(Complete Case)은 결측값이 포함된 행(케이스)을 제거하고 분석한다.
② 평균 대치법은 결측값을 해당 변수의 평균값으로 채워 넣는다.
③ 단순 대치법은 결측값을 하나의 추정치로 대체하는 방법이다.
④ 완전 분석법은 결측값을 평균으로 대치하여 모든 데이터를 그대로 활용하는 방법이다.

> **정답 ④**
> 완전 분석법은 결측값이 있는 행을 모두 제거하고 완전한 자료만으로 분석하는 방법이다. 결측값을 평균으로 채우는 것은 평균 대치법이다.

💡 **쉽게 이해하기** **완전 분석법** = 빈칸이 하나라도 있는 행을 **통째로 버리고** 남은 완전한 행만 쓰는 방법입니다. 평균으로 채우는 것은 **평균 대치법**입니다. ④는 두 방법을 섞어 놓은 함정입니다.

이상값

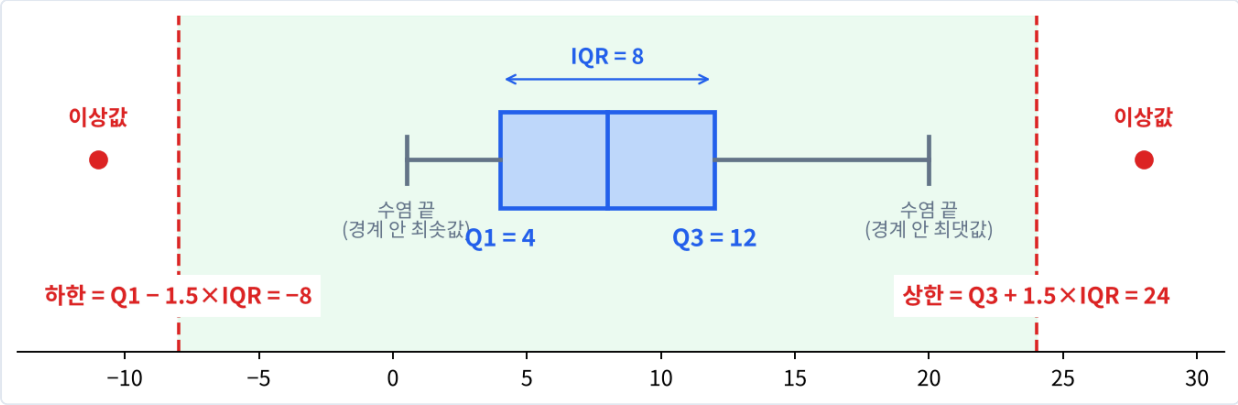
5. 아래 Box Plot을 참고하여 이상치를 판단하는 하한과 상한의 값은? 47회 23번



① -4, 20
② -4, 24
③ -8, 20
④ -8, 24

> **정답 ④**
> $Q_1 = 4$, $Q_3 = 12$이므로 $IQR = 8$이다. 하한은 $4 - 1.5 \times 8 = -8$, 상한은 $12 + 1.5 \times 8 = 24$이다. 이 값은 이상치 판정 경계이며 관측 최솟값·최댓값이 아니다.
> 계산 순서: 1단계에서 상자의 아래 경계 $Q_1 = 4$와 위 경계 $Q_3 = 12$를 읽는다. 2단계에서 $IQR = Q_3 - Q_1 = 12 - 4 = 8$을 구한다. 3단계에서 $1.5 \times IQR = 12$를 계산한다. 4단계에서 하한 $= 4 - 12 = -8$, 상한 $= 12 + 12 = 24$를 얻으므로 ④이다.
> 오답 구분: ①②③은 하한 또는 상한을 잘못 계산한 조합이다. 두 경계는 이상치 후보를 정하는 울타리이며 실제 관측값의 최소·최대나 수염 끝과 같다고 할 수 없다. 일반적으로 −8 미만 또는 24 초과인 관측값을 이 규칙의 이상치 후보로 본다. 경계와 같은 값은 이 규칙에서 경계를 벗어난 값이 아니다.

💡 **쉽게 이해하기** 상자그림에서 상자의 아래 끝 = Q1 = 4, 위 끝 = Q3 = 12. IQR(상자 길이) = 12 − 4 = 8. 울타리는 상자에서 **IQR의 1.5배**만큼 밖: 하한 = 4 − 12 = **−8**, 상한 = 12 + 12 = **24**. 이 울타리 밖의 점이 이상치입니다.



▲ 47회 23번 · 상자(Q1~Q3) 길이가 IQR, 상자에서 1.5 × IQR 밖이 이상값

6. 다음은 어떤 변수의 사분위수이다. 1.5 × IQR 기준의 이상값 판정에 대한 설명으로 옳지 않은 것은? 49회 34번

Q1 = 12, Q3 = 16

① IQR은 Q3 − Q1이므로 4이다.

② **이상값의 하한은 Q1 + 1.5 × IQR, 상한은 Q3 − 1.5 × IQR로 계산한다.**

③ 이상값의 하한은 6, 상한은 22이다.

④ 6보다 작거나 22보다 큰 값은 이상값으로 판정할 수 있다.

정답 ②

IQR=Q3−Q1=16−12=4이다. 하한 울타리는 Q1−1.5IQR=6, 상한 울타리는 Q3+1.5IQR=22이다. 하한보다 작거나 상한보다 큰 값이 이상값 후보이며 경계와 같은 값은 이 기준으로 제외하지 않는다. ②는 부호를 뒤집었으므로 틀리다.

💡 **쉽게 이해하기** 울타리는 상자 **바깥쪽**으로 칩니다. 아래 울타리는 Q1에서 **빼고**(12 − 6 = 6), 위 울타리는 Q3에 **더합니다**(16 + 6 = 22). ②는 부호를 거꾸로 써서 울타리를 상자 안쪽으로 넣어 버린 틀린 식입니다.

7. 다음 중 데이터 이상값 탐지 및 처리 방법에 대한 설명으로 적절하지 않은 것은? 48회 22번

① 상자그림에서 사분위수 범위(IQR)의 1.5배를 기준으로 상한 및 하한 임계치를 설정하여 이상값을 식별한다.

② 데이터가 정규분포를 따른다고 가정할 때, 평균으로부터 표준편차의 3배 이상 떨어진 값을 이상값으로 판단한다.

③ **표본 평균의 표준오차 범위를 계산하여 해당 범위를 벗어나는 값을 이상값으로 처리한다.**

④ 이상값을 삭제하는 대신 경우에 따라 평균, 중앙값 또는 회귀분석을 통한 예측값으로 바꾸어 데이터의 손실을 최소화할 수 있다.

정답 ③

표본평균의 표준오차는 평균 추정의 불확실성을 나타내며 개별 관측값의 정상 범위를 뜻하지 않는다. 이를 벗어난 값을 모두 이상치로 처리하면 정상 관측값도 과도하게 제거할 수 있다. IQR 기준과 정규분포를 가정한 평균±3표준편차 기준은 이상치 후보 탐지에 사용된다. 후보 발견 후 오류인지 의미 있는 극단값인지 확인해야 하며 대치·삭제는 상황에 따라 결정한다.

💡 **쉽게 이해하기** 이상값 탐지 방법은 **IQR 1.5배**(상자그림)와 **평균 ± 3 표준편차**(정규분포)가 대표입니다. **표준오차**는 '표본평균이 얼마나 흔들리나'를 재는 값이라 개별 데이터가 이상한지 판단하는 기준이 아닙니다. 표준오차는 표준편차보다 훨씬 작아서 이걸 쓰면 정상 데이터 대부분이 이상값이 됩니다.

8. 이상값(Outlier)에 대한 설명으로 옳지 않은 것은? 49회 26번

① 이상값은 입력 오류, 측정 오류, 표본추출 오차 등 다양한 원인으로 발생할 수 있다.

② 이상값은 일반적으로 데이터 전처리 단계에서 탐색하고 처리한다.

③ 사분위수 범위(IQR)나 상자그림(Box plot), 산점도 등을 이용해 이상값을 판별할 수 있다.

④ 이상값은 분석 결과를 왜곡하므로 발견되면 반드시 모두 제거해야 한다.

> **정답 ④**
> 이상값이 항상 오류인 것은 아니며 의미 있는 정보를 담고 있을 수 있다(예: 이상 거래 탐지). 원인과 분석 목적에 따라 제거, 대체, 변환, 유지 중에서 선택한다.

💡 **쉽게 이해하기** 이상값은 **무조건 삭제하지 않습니다.** 입력 실수면 고치거나 지우지만, 실제로 일어난 특별한 값(예: VIP 고객의 큰 구매, 사기 거래)이면 오히려 중요한 정보입니다. 원인을 확인한 뒤 삭제·대체·유지를 정합니다.

9. 정규분포를 따르는 데이터에서 평균으로부터 표준편차의 3배 이상 떨어진 값을 이상치로 판단하는 탐지 기법은? 50회 30번

① ESD

② IQR

③ K-means

④ DBSCAN

> **정답 ①**
> 정답은 ①이다. 이 문항은 평균에서 3표준편차 이상 떨어진 값을 이상치로 판단하는 기준을 ESD로 설명하는 출제 맥락이다. 다만 엄밀한 일반화 ESD(Generalized Extreme Studentized Deviate) 검정은 표본 크기·유의수준·검토할 이상치 수 등을 반영한 임계값을 사용하므로 단순한 3σ 규칙과 구분해야 한다. IQR 방법은 일반적으로 Q1−1.5×IQR 미만 또는 Q3+1.5×IQR 초과를 이상치로 판단한다. K-means와 DBSCAN은 군집분석 기법이다.

💡 **쉽게 이해하기** 정규분포에서 평균 ± 3σ 안에 데이터의 99.7%가 들어갑니다. 그 밖은 1,000개 중 3개꼴인 아주 드문 값이라 이상치로 봅니다. 이 기준이 **ESD**(Extreme Studentized Deviation)입니다. IQR은 사분위수 기준, K-means·DBSCAN은 군집 기법입니다.

빠른 정답표

1	②	2	②	3	③	4	④	5	④	6	②	7	③	8	④	9	①

자주 나오는 함정

- EDA는 데이터 구조 파악·이상치/결측치 발견 단계 · **재현성 검증**은 EDA의 특징이 아님
- 결측값 대체는 **평균만** 쓰는 것이 아님 · 완전 분석법은 결측 행을 **삭제** → 표본 감소 · 평균 대치는 분산을 **과소**추정
- 두 변수가 독립적으로 각 10% 결측 → 하나라도 결측인 행 = 1 − 0.9 × 0.9 = **19%**
- IQR = Q3 − Q1 · 하한 Q1 − 1.5 IQR, 상한 Q3 + 1.5 IQR · 평균 ± 3σ 기준 → **ESD**
- 이상값은 **무조건 삭제**하지 않음 (원인 확인 후 처리)