ADsP 데이터분석 준전문가 · 3과목 1장 R 기초와 데이터 마트

3과목 1장
R 기초와 데이터 마트

초보자를 위한 설명 · 시험에 중요한 내용 중심 · 단원마다 출제 유형과 함정 정리

1단원	R 기초와 데이터 마트 (1장 1~2절)
2단원	탐색적 분석, 결측값과 이상값 (1장 3절)

보는 법
· 노란 상자 = 한 문장 요약·외우는 법 · 초록 상자 = 시험 출제 유형과 함정

1단원 R 기초와 데이터 마트 (1장 1~2절)

한 문장 요약: R은 데이터 분석용 언어이고, 데이터를 담는 그릇(**벡터·행렬·리스트·데이터프레임**)의 차이가 기본입니다. 데이터 마트는 분석 목적에 맞게 데이터를 모은 것이며, 그 안에서 **요약변수와 파생변수**를 만듭니다. 최근 기출(45~50회)에는 R 문법보다 **결측값·이상값**(2단원)이 훨씬 많이 나왔습니다.

1. R의 데이터 구조



▲ R의 데이터 구조: 같은 타입만 담는 그릇과 섞어 담는 그릇

구조	차원	담을 수 있는 타입	만드는 함수
벡터	1차원	**한 가지 타입만** (숫자면 숫자만)	`c(1, 2, 3)`
행렬	2차원	한 가지 타입만	`matrix(1:6, nrow = 2)`
배열	3차원 이상	한 가지 타입만	`array(1:24, dim = c(2, 3, 4))`
리스트	1차원	**서로 다른 타입**을 함께 (벡터·데이터프레임도 넣을 수 있음)	`list(이름 = "A", 점수 = c(90, 80))`
데이터프레임	2차원	**열마다 다른 타입** 가능, 열의 길이는 같음 (엑셀 표와 비슷)	`data.frame(x = 1:3, y = c("a", "b", "c"))`

- 벡터에 숫자와 문자를 섞으면 **모두 문자로 바뀝니다**. 예: `c(1, "a")` → `"1" "a"`
- **팩터(factor):** 범주형 변수입니다(성별, 등급). 수준(levels)을 가집니다.

특수한 값

값	뜻	예
NA	**결측값** (Not Available, 값이 없음)	설문 무응답
NaN	수학적으로 정의되지 않음 (Not a Number)	`0 / 0`
NULL	**아무것도 없음** (빈 객체)	아직 아무것도 넣지 않은 변수
Inf	무한대	`1 / 0`

2. 자주 쓰는 함수

함수	하는 일
`seq(1, 10, by = 2)` / `rep(1, 3)`	수열 만들기 / 반복
`cbind()` / `rbind()`	열로 붙이기 / 행으로 붙이기
`head()`, `str()`, `summary()`	앞부분 보기, **구조** 보기, **요약 통계**(최솟값·사분위수·평균·최댓값)
`apply(x, 1, f)` / `apply(x, 2, f)`	행렬의 **행(1)** / **열(2)**마다 함수 적용
`lapply()` / `sapply()`	결과를 **리스트**로 / **벡터(간단한 형태)**로
`tapply(x, 그룹, f)`	**그룹별**로 함수 적용
`is.na()`, `na.omit()`	결측값 확인 / 결측값이 있는 행 제거

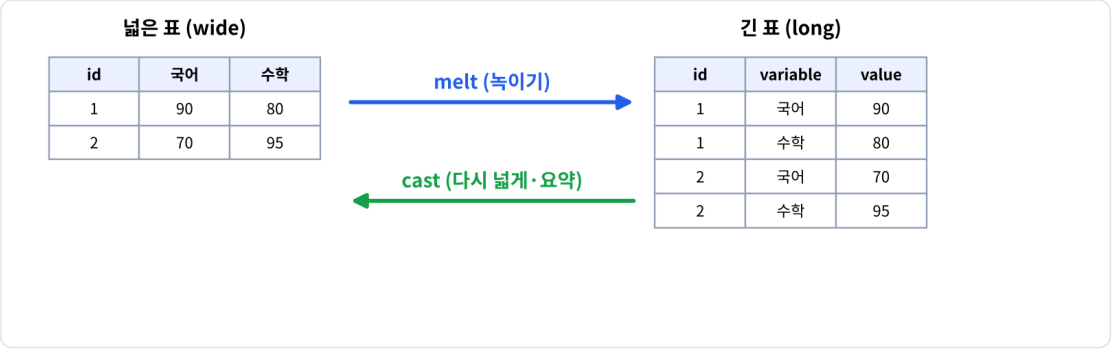
3. 데이터 마트

- **데이터 마트**는 데이터 웨어하우스에서 **특정 분석 목적**(부서, 주제)에 맞게 데이터를 뽑아 모은 것입니다. 분석 모델의 입력 데이터를 만드는 곳입니다.

	요약변수	파생변수
뜻	수집된 정보를 분석 목적에 맞게 **종합(집계)**한 변수	특정 조건이나 함수로 **새 의미를 부여**한 변수
예	기간별 **구매 금액·횟수**, 상품별 구매 금액	**주 구매 매장**, 근무 시간 중 구매 여부, 선호 상품군
특징	가장 기본적인 변수. **재활용성이 높음**	**주관적**일 수 있어 **논리적 타당성**이 필요

R로 데이터 마트 만들기

패키지	하는 일
reshape	**melt**: 넓은 표 → 긴 표(id 변수 기준으로 녹임) / **cast**: 긴 표 → 넓은 표(요약하며 재구성)
sqldf	R에서 **SQL 문**으로 데이터 처리
plyr	**split-apply-combine**: 나누고, 함수를 적용하고, 합침. 함수 이름 앞 두 글자가 입력·출력 형태 (ddply = 데이터프레임 → 데이터프레임)
data.table	데이터프레임보다 **빠른 검색·정렬**(key 설정)



▲ melt는 넓은 표를 긴 표로, cast는 다시 넓은 표로

시험에는 이렇게 나옵니다 · 출제 유형과 함정

- 45~50회에는 R 문법을 직접 묻는 문항이 **거의 없었습니다.** 대신 아래 개념은 보기 속 설명으로 나올 수 있으니 알아 둡니다.
- 벡터·행렬은 **한 타입**, 리스트·데이터프레임은 **여러 타입**
- **NA = 결측**, NaN = 정의 불가, NULL = 빈 객체
- `apply` 의 1 = 행, 2 = 열

- **요약변수 vs 파생변수:** 구매 금액·횟수처럼 집계 → **요약변수**. 주 구매 매장처럼 의미 부여 → **파생변수**. "파생변수는 **객관적**이라 타당성 검토가 필요 없다" → 틀림
- **reshape:** melt(녹이기, 넓은 → 긴), cast(다시 넓게). sqldf = SQL, plyr = split-apply-combine

2단원 탐색적 분석, 결측값과 이상값 (1장 3절)

한 문장 요약: 본격 분석 전에 데이터를 **둘러보고(EDA)**, 비어 있는 값(**결측값**)은 채우거나 빼고, 튀는 값(**이상값**)은 찾아서 판단합니다. 결측값 대치 방법과 **IQR·ESD 이상값 기준**이 매회 나옵니다.

1. 탐색적 데이터 분석 (EDA)

- 가설을 세우기 **전에** 데이터를 **요약하고 시각화**해서 특징과 패턴, 이상값을 **탐색**하는 단계입니다. 통계학자 **존 튜키**가 제안했습니다.
- **4가지 주제: 저항성**(이상값에 덜 흔들리는 중앙값 등) 강조, **잔차** 계산, 자료 변수의 **재표현**(로그 변환 등), **그래프**를 통한 현시성
- **재현성 검증 단계가 아닙니다.** 탐색이 목적입니다.

2. 결측값 (Missing Value)

결측값의 종류

종류	뜻	예
완전 무작위 결측 (MCAR)	결측이 **아무 변수와도 관계없이** 무작위로 생김	설문지 한 장이 우연히 젖음
무작위 결측 (MAR)	결측이 **다른 관측 변수**와 관련 있음	남성이 체중 문항에 덜 응답
비무작위 결측 (MNAR)	결측이 **그 변수 자체의 값**과 관련 있음	소득이 높은 사람이 소득을 숨김

결측값 처리 방법



▲ 결측값 처리 방법 한눈에 보기

방법	설명	장단점
완전 분석법	결측값이 있는 행을 **삭제**하고 남은 데이터만 분석	쉬움 / 데이터가 줄어 **효율성 손실**, 편향 가능
평균 대치법	결측값을 **평균**(비조건부)이나 **회귀 예측값**(조건부)으로 채움	표본 수 유지 / 모두 같은 값이라 퍼짐이 줄어 **표준오차가 과소 추정**됨
단순 확률 대치법	평균 대신 **비슷한 다른 관측값**으로 확률적으로 채움. **Hot-deck**(비슷한 응답자의 값), **Nearest Neighbor**(가장 가까운 이웃의 값)	평균 대치의 **과소 추정 문제를 보완**
다중 대치법	대치를 **여러 번(m번)** 해서 데이터셋을 m개 만들고, 각각 분석한 뒤 결과를 **결합**	**대치 → 분석 → 결합** 3단계. 불확실성까지 반영

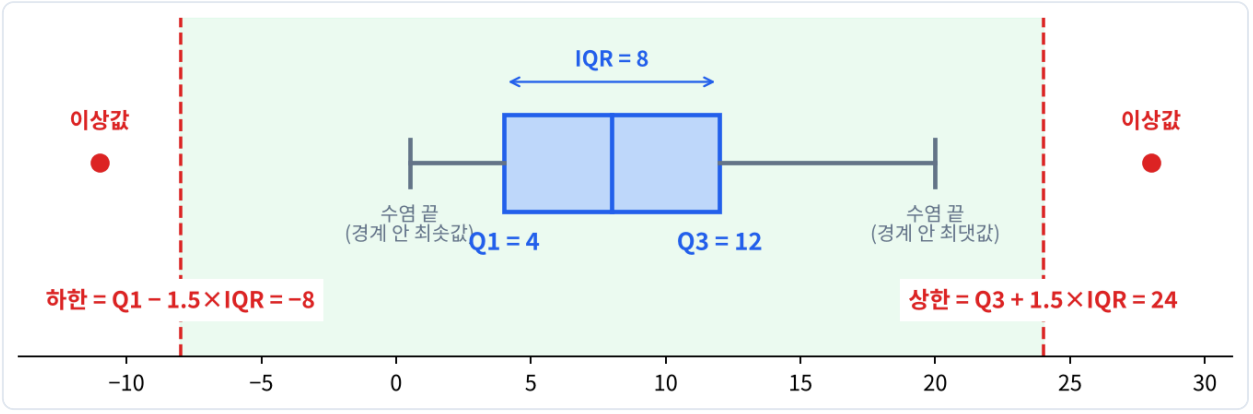
- **결측값을 채우는(대치) 목적: 표본 수를 유지**해서 데이터 손실을 줄이는 것입니다.
- **K=1 vs K=4 (최근접 이웃):** K=1이면 가장 가까운 이웃 **1개의 값**으로 채우고, K=4면 가까운 **4개 값의 평균**으로 채웁니다.
- **R 함수:** `is.na()`, `complete.cases()` (결측 없는 행 찾기), `centralImputation()` (평균·중앙값 대치), `knnImputation()` (KNN 대치), `amelia()` (다중 대치)

3. 이상값 (Outlier)

- **이상값:** 다른 값들과 **동떨어진** 값입니다.
- **종류:**
- **잘못 입력된** 값(bad data): 제거합니다.
- **분석 목적에 맞지 않는** 값: 제거합니다.
- 의도하지 않았지만 **분석에 포함해야 하는** 값
- **의도된** 이상값: 카드 **사기(fraud)** 탐지처럼 이상값 자체가 분석 대상입니다.
- 그래서 이상값을 **반드시 모두 제거하지는 않습니다.** 처리하기 전에 **원인을 파악**해야 합니다.

이상값 판단 기준

방법	기준
ESD (Extreme Studentized Deviation)	평균 ± **3 × 표준편차** 밖 (정규분포에서 약 0.3%)
기하평균 기준	기하평균 ± 2.5 × 표준편차 밖
사분위수(IQR) 기준, 상자그림	**Q1 − 1.5 × IQR** 미만 또는 **Q3 + 1.5 × IQR** 초과 (IQR = Q3 − Q1)



▲ 상자그림의 이상값 경계: Q1 = 4, Q3 = 12이면 IQR = 8, 경계는 −8과 24

계산 예: Q1 = 4, Q3 = 12 → IQR = 8 → 1.5 × 8 = 12 → 하한 = 4 − 12 = **−8**, 상한 = 12 + 12 = **24**

처리 방법: 절단(trimming, 이상값 제거)과 **조정**(winsorizing, 이상값을 상한·하한 값으로 바꿈)이 있습니다.

시험에는 이렇게 나옵니다 · 출제 유형과 함정

- **EDA:** "**재현성**을 검증하는 단계" → 틀림
- **결측값:**
- "결측값 대체의 목적은 **표본 수 유지**" → 맞음
- "완전 분석법은 결측값을 **평균으로 대치**" → 틀림 (그건 평균 대치. 완전 분석법은 **삭제**)
- "평균 대치는 표준오차를 **과대** 추정" → 틀림 (**과소**)
- 다중 대치 순서: **대치 → 분석 → 결합**
- **결측 확률 계산:** 이름과 성별이 각각 독립적으로 10% 결측이면, 하나라도 결측일 확률 = 1 − 0.9 × 0.9 = **19%**. 10% + 10% = 20%로 답하게 유도하는 함정입니다.
- **이상값 (매회 나옴):**
- 평균에서 표준편차 3배 이상 떨어진 값 → **ESD**
- IQR 기준: "하한 Q1 **+** 1.5IQR, 상한 Q3 **−** 1.5IQR" → 틀림 (하한은 Q1 **−**, 상한은 Q3 **+**)
- 상자그림 그림을 주고 하한·상한 계산
- "이상값은 발견되면 **반드시 모두 제거**" → 틀림
- "**표준오차** 범위를 벗어나면 이상값" → 틀림 (표준오차가 아니라 표준편차·IQR 기준)