2장 통계 분석 · 회차별 기출 (45~50회)

정답·해설 (보완판)

쉬운 설명 PDF 1~9단원 순서대로 정리

총 94문항 · 문항 끝에 출처(회차·번호) 표시

1단원 통계 개요·확률 기초 기본 성질	· 척도, 표본추출 · 표본조사 · 통계량, 기술통계 · 사분위수 · 상자그림, 확률의	1~15번 (15문항)
2단원 확률분포	· 확률분포	16~17번 (2문항)
3단원 기댓값·분산, 왜도·첨도, 공분산·상관계수	· 기댓값, 왜도 · 선형변환, 공분산 · 상관계수	18~27번 (10문항)
4단원 추정·가설검정·비모수 검정	· 추정 · 표본오차, 가설검정 · 오류 · p-value	28~37번 (10문항)
5단원 t-검정·분산분석·교차분석·상관분석	· t-검정, 분산분석 · 교차분석, 상관분석 · 산점도	38~51번 (14문항)
6단원 회귀분석 ① 개요~결과 해석	· 회귀 가정 · 잔차, 회귀 결과 해석 · 결정계수	52~65번 (14문항)
7단원 회귀분석 ② 다중공선성·변수 선택	· 다중공선성 · 변수 선택	66~68번 (3문항)
8단원 다변량 분석: MDS·PCA	· 주성분분석 (PCA), 다차원 척도법 (MDS)	69~79번 (11문항)
9단원 시계열 분석	· 정상성 · 정상화, 시계열 모형 (AR · MA · ARIMA), 분해 시계열 · 시계열 일반	80~94번 (15문항)

1단원 통계 개요·확률 기초

척도

1. 척도에 대한 내용으로 올바르게 짝지어진 것은? 45회 21번

① 시험 점수는 명목척도이다.
② 고객 만족도 5점 척도는 비율척도이다.
③ 고향이 수도권/비수도권인지는 명목척도이다.
④ 몸무게 또는 나이는 명목척도이다.

정답 ③

수도권·비수도권은 지역 범주를 구분하므로 ③ 명목척도가 맞다. 0과 1로 코딩하더라도 1이 0보다 두 배 크다는 양적 의미가 생기지 않는다.

핵심 개념: 명목척도는 범주의 구분만 있으며 순서와 수치 간격의 의미가 없다. 서열척도에는 순서, 등간척도에는 같은 간격, 비율척도에는 간격과 의미 있는 절대영점이 있다.
보기 검토: ① 시험 점수를 명목으로 보는 것은 부적절하다. 다만 시험 점수의 정확한 척도 해석은 측정 설계에 따라 달라질 수 있다. ② 고객 만족도 5점은 보통 서열척도로 다루며 응답 간 간격이나 만족도의 비율을 자동 보장하지 않는다. ④ 몸무게와 경과시간으로 측정한 나이는 일반적으로 비율척도이다. 숫자 표시 여부와 측정 수준을 구별한다.

💡 **쉽게 이해하기** 숫자로 적혀 있어도 그 숫자가 **무엇을 알려 주는지**로 척도를 정합니다. 수도권=1, 비수도권=0으로 적어도 '1이 0보다 크다'는 뜻이 없는 **이름표**라서 명목척도입니다. 만족도 5점은 순서만 있으니 **서열**, 몸무게·나이는 0이 '없음'을 뜻하니 **비율**입니다.

2. 절대적 기준인 영점(0)이 존재하는 척도는? 47회 21번

① 명목척도
② 서열척도
③ 등간척도
④ 비율척도

정답 ④

비율척도는 절대 영점이 있고 값의 비율이 의미를 갖는다.

명목척도는 혈액형처럼 분류만 가능하고, 서열척도는 만족도 등 순서를 표현하지만 간격이 동일하다고 보장하지 않는다. 등간척도는 간격 비교가 가능하지만 절대 영점이 없으며, 비율척도는 간격과 비율 모두 의미가 있고 절대 영점을 가진다.
보기 판단: ④가 정답이다. 길이·질량처럼 0이 해당 양의 부재를 뜻하면 20은 10의 두 배라고 말할 수 있다. 섭씨 0도는 온도의 부재가 아니므로 섭씨 20도가 10도보다 두 배 뜨겁다고 해석하지 않는다. 숫자로 표현되었다는 이유만으로 모두 비율척도가 되는 것은 아니다.

💡 **쉽게 이해하기 절대 영점** = 0이 '하나도 없음'을 뜻하는 것. 0kg은 무게가 없음이라 20kg은 10kg의 2배라고 말할 수 있습니다(비율척도). 0℃는 '온도 없음'이 아니라서 20℃가 10℃의 2배 덥다고 할 수 없습니다(등간척도).

3. 다음 중 절대 영점이 존재하지 않아 덧셈, 뺄셈 등의 양적 비교는 가능한 척도는? 48회 25번

① 명목척도
② 구간척도
③ 비율척도
④ 서열척도

> **정답 ②**
> 구간척도는 간격이 일정하지만 절대영점이 없다. 섭씨온도처럼 차이는 의미가 있어도 20도가 10도의 두 배라는 비율 해석은 할 수 없다. 비율척도는 절대영점이 있어 비율 비교도 가능하고, 명목척도는 분류, 서열척도는 순서를 나타낸다. 따라서 ② 구간척도이다.

💡 **쉽게 이해하기** 온도계를 떠올리세요. 10℃와 20℃의 **차이(10도)**는 의미가 있지만 '2배'는 의미가 없습니다. 이렇게 **더하기·빼기는 되고 곱하기·나누기는 안 되는** 척도가 구간(등간)척도입니다.

표본추출 · 표본조사 · 통계량

4. 계통추출에 대한 설명으로 가장 적절한 것은? 45회 49번

① 모집단을 무작위로 몇 개의 집락으로 묶은 뒤 집락 전체를 추출한다.
② 모집단을 층으로 나누고 각 층에서 따로 추출한다.
③ 시작점을 무작위로 정한 뒤 일정한 간격마다 대상을 추출한다.
④ 표본평균이 가장 큰 대상만 선택한다.

> **정답 ③**
> ③이 무작위 시작과 일정 간격이라는 두 특징을 갖는다. 예를 들어 1000명 중 100명을 간격 10으로 뽑는다면 시작점 1~10 중 하나를 무작위 선택하여 이후 10명마다 선택할 수 있다.
> 핵심 개념: 계통추출은 모집단 목록에서 무작위 시작점을 정한 뒤 일정 간격마다 표본을 선택하는 방법이다. 모집단 크기 N과 표본 크기 n에 따라 간격을 대략 N/n으로 정하며 실제 설계 방식에 맞게 조정한다.
> 보기 검토: ①은 집락추출, ②는 층화추출, ④는 확률표집의 원칙과 맞지 않는 임의 선택이다. 목록에 추출 간격과 같은 주기적 패턴이 있으면 편향 위험을 검토한다.

💡 **쉽게 이해하기** **계통**(系統)추출 = 줄 세워 놓고 **일정 간격**으로 뽑기. 출석부 1~10번 중 하나(예: 7번)만 제비뽑기로 정한 뒤 17번, 27번… 처럼 10칸마다 뽑습니다. 무작위는 **처음 한 번**뿐입니다.

5. 표본추출방법에 대한 설명으로 적절하지 않은 것은? 47회 27번

① 단순무작위추출법 : 표본 선택 확률을 모두 동일하게 무작위로 표본을 추출한다.
② 계통추출법 : 일련번호를 부여한 각 개체를 일정한 간격으로 나누고 각 구간에서 무작위 추출하는 방법이다.
③ 집락추출법 : 모집단을 여러 집락으로 나눈 뒤 일부 집락을 무작위로 선택하여 해당 집락의 구성원 전체를 조사한다.
④ 층화추출법 : 모집단을 서로 중복되지 않는 집단 및 층(strata)으로 구분하고 각 집단 내에서 표본을 무작위 추출한다.

> **정답 ②**
> 계통추출은 임의 시작점을 정한 후 일정 간격마다 선택한다. 각 구간에서 별도로 무작위 추출한다는 설명은 표준 계통추출과 다르다.
> 계통추출은 시작점을 한 번 무작위로 정한 뒤 일정한 간격 k마다 선택한다. 예를 들어 1,000명 중 100명을 뽑을 때 간격 10으로 정하고 시작점이 7이면 7·17·27번처럼 선택한다. 매 구간마다 새 시작점을 무작위로 뽑는 설명과 다르다.
> 보기 판단: ②가 잘못된 설명이다. ① 단순무작위추출은 무작위로 표본을 선정한다. ③은 일부 집락을 뽑아 그 구성원 전체를 조사하는 1단계 집락추출의 예이다. ④ 층화추출은 모든 층에서 표본을 추출한다. 층화는 각 층을 대표하게 하는 것이 중요하고, 집락은 선택한 집락이 조사 단위가 된다는 차이를 기억한다.

💡 **쉽게 이해하기** 계통추출의 함정 문장 '각 구간에서 무작위 추출'은 구간마다 제비뽑기를 새로 하는 것이라 틀립니다. 계통추출은 **시작점만 무작위**이고 이후는 기계적으로 간격을 지킵니다.

6. 표본 추출 방법에 대한 설명으로 틀린 것은? 49회 25번

① 계통 추출법은 첫 표본을 무작위로 정한 뒤 일정한 간격으로 표본을 추출한다.

② 층화 추출법은 모집단을 동질적인 여러 집단(층)으로 나눈 후 각 층에서 표본을 추출한다.

③ 집락(군집) 추출법은 각 집락의 내부가 동질적이도록 구성하여 추출한다.

④ 단순 무작위 추출법은 모든 표본이 뽑힐 확률이 동일하도록 임의로 추출한다.

정답 ③

③이 틀리다. 층화추출은 층 내부가 동질적이고 층 사이가 이질적이도록 구분한 뒤 각 층에서 표본을 뽑는다. 집락추출은 모집단을 집락으로 나누고 일부 집락을 선택하여 조사하는 방식이다. 효율적인 집락 설계에서는 집락 내부가 모집단처럼 이질적이고 집락 간 특성이 비슷한 것이 이상적이다. 이는 설계의 바람직한 성질이며 현실의 모든 집락이 반드시 이 조건을 만족한다는 뜻은 아니다.

💡 **쉽게 이해하기** 학교로 비유: **층화** = 학년별로 나눠 **모든 학년**에서 조금씩 뽑기(학년 안은 비슷한 학생끼리 = 동질). **집락** = 반 몇 개를 골라 그 반 **전원** 조사(한 반 안에는 여러 유형이 섞여 있어야 좋음 = 이질). 집락(Cluster, 클러스터) = 군집과 같은 말입니다.

7. 다음 중 표본 조사에 대한 설명으로 적절하지 않은 것은? 47회 25번

① 표본 오차는 표본이 모집단을 완벽히 대표하지 못해 생기는 오차이다.

② 적절한 확률표집에서 다른 조건이 같으면 표본 크기 증가로 표본 오차가 대체로 감소한다.

③ 표본추출을 통해 비표본 오차를 최소화할 수 있다.

④ 비표본 오차는 표본의 크기나 추출 방법에 관계없이 발생가능하다.

정답 ③

비표본 오차는 측정·응답·누락·처리 과정에서도 생긴다. 표본추출 자체만으로 이를 최소화한다고 할 수 없다. 표본 확대 효과에는 적절한 추출 등의 조건이 필요하다.

표본 오차는 모집단의 일부만 조사하므로 표본마다 통계량이 달라지는 변동을 뜻한다. 비표본 오차는 설문 문구의 모호함, 응답 누락, 거짓 응답, 측정기 오류, 자료 입력·처리 오류 등에서 발생한다. 전수조사에서도 비표본 오차는 생길 수 있다.
보기 판단: ①은 표본 변동에 대한 설명이고 ②는 적절한 확률표집에서의 일반적 효과이다. ④는 표본 크기만으로 비표본 오차가 없어지지 않는다는 취지이다. ③처럼 표본을 추출했다는 사실만으로 비표본 오차가 최소화되지는 않는다. 표본 확대와 함께 측정·응답·처리의 품질을 별도로 관리해야 한다.

💡 **쉽게 이해하기** **표본오차** = 일부만 조사해서 생기는 **운**의 차이(표본을 늘리면 줄어듦). **비표본오차** = 질문을 잘못 만들거나 거짓 응답·입력 실수로 생기는 **실수**(표본을 늘려도 안 줄어듦). 표본을 뽑는다고 실수가 사라지지는 않습니다.

8. 모집단에서 추출한 표본을 이용하여 계산한 평균, 분산, 표준편차 등의 수치를 무엇이라 하는가? 50회 29번

① 모수

② 전수조사

③ 표본추출

④ 통계량

정답 ④

표본에서 계산한 평균·분산 등은 통계량이다. 모집단을 설명하는 수치는 모수이다.

💡 **쉽게 이해하기** **모**집단의 값 = **모**수(μ 뮤, σ 시그마), **표**본으로 계산한 값 = **통계량**(x̄ 엑스바, s 에스). '모는 모수, 표본은 통계량'으로 외웁니다.

기술통계 · 사분위수 · 상자그림

9. 기술통계와 관련된 설명 중 틀린 것은? 45회 23번

① 결측치를 모두 0으로 변환하여 평균을 계산한다.

② 기술통계는 데이터를 요약하고 설명하는 데 사용된다.

③ 대표값으로는 평균, 중앙값, 최빈값 등이 있다.

④ 산포도는 데이터의 분포 범위를 파악할 수 있는 도구이다.

정답 ①

결측은 관측되지 않았다는 뜻이며 값이 0이라는 뜻이 아니다. 모든 결측을 0으로 바꾸면 평균과 분포가 왜곡될 수 있으므로 ①이 틀리다. 예를 들어 관측값 10,20과 결측 하나에서 관측값 기준 평균은 15지만 0 대체 후 평균은 10이 된다.

핵심 개념: 기술통계는 수집된 자료의 특성을 대표값과 산포도, 그림 등을 통해 요약한다. 평균·중앙값·최빈값은 중심을, 분산·표준편차·범위·사분위범위는 퍼짐을 나타낸다.
처리 기준: 결측 원인과 자료 특성에 따라 제외, 대체, 별도 표기 등을 선택하고 계산의 분모와 처리 방식을 명시한다. 평균 대체도 항상 적절한 것은 아니다. ②③④는 자료 요약이라는 기술통계의 기본 목적과 맞는다. 결측 처리 규칙이 통계량에 미치는 영향을 함께 해석한다.

💡 **쉽게 이해하기** 결측(NA, 엔에이) = '**모른다**'이지 '0점'이 아닙니다. 시험을 못 본 학생을 0점 처리하면 반 평균이 억울하게 내려가는 것과 같습니다. 예: 10, 20, 결측 → 결측 제외 평균 15, 0으로 바꾸면 10.

10. 데이터 분포에서 중앙 50%의 흩어진 정도를 나타내는 지표는? 46회 27번

① 평균
② 표준편차
③ 중앙값
④ 사분위 범위

정답 ④

Q1은 대략 하위 25%의 경계, Q3는 대략 하위 75%의 경계이므로 그 사이의 자료가 중앙 50%에 해당한다. 이 구간의 흩어진 정도를 묻는 질문에는 ④가 맞는다. 예를 들어 $Q_1 = 10$, $Q_3 = 18$이면 $IQR = 8$이다.

핵심 개념: 사분위 범위 IQR은 제3사분위수 Q3에서 제1사분위수 Q1을 뺀 값이다. $IQR = Q_3 - Q_1$이며 자료의 가운데 약 50%가 퍼진 폭을 나타낸다.
보기 검토: ① 평균과 ③ 중앙값은 자료가 어디에 위치하는지 나타내는 중심 경향 지표이다. ② 표준편차는 평균에서 떨어진 정도를 전체 관측값에 대해 종합하는 산포 지표이며 중앙 50%의 폭을 직접 나타내는 값은 아니다.
학습 포인트: IQR은 양 끝의 극단값에 표준편차보다 덜 민감하다. 상자그림에서 상자의 아래·위 경계가 Q1·Q3이고 상자의 길이가 IQR이다. 흔히 $Q_1 - 1.5IQR$보다 작거나 $Q_3 + 1.5IQR$보다 큰 값을 이상치 후보로 표시하지만, 그 후보가 모두 잘못 입력된 자료라는 뜻은 아니다. 사분위수의 세부 계산 방식에 따라 작은 표본에서는 값이 달라질 수 있다.

💡 **쉽게 이해하기** **IQR**(아이큐알, Interquartile Range 인터쿼타일 레인지) = Q3 − Q1 = 상자그림의 **상자 길이**. 키 순서로 줄 세웠을 때 **가운데 절반**(25%~75%) 학생들이 얼마나 넓게 퍼져 있는지입니다.

11. 다음은 사료 종류(feed)에 따른 병아리 무게(weight) 자료의 요약 결과이다. 해석으로 옳지 않은 것은? 45회 31번

```
> summary(chickwts)
     weight             feed
 Min.   :108.0   casein   :12
 1st Qu.:204.5   horsebean:10
 Median :258.0   linseed  :12
 Mean   :261.3   meatmeal :11
 3rd Qu.:323.5   soybean  :14
 Max.   :423.0   sunflower:12
```

① weight 값의 약 25%는 1st Qu.(204.5)보다 크다.
② weight의 사분위수 범위(IQR)는 119이다.
③ 평균이 중앙값보다 크므로 오른쪽 꼬리가 긴 분포(양의 왜도)를 의심할 수 있다.
④ feed는 명목형 변수이다.

정답 ①

Q1보다 작은 값이 약 25%이므로 Q1보다 큰 값은 약 75%이다. 25%만 크다고 한 ①이 틀리다.

핵심 개념: 1st Qu.(Q1)는 아래쪽 약 25%의 경계, 3rd Qu.(Q3)는 약 75%의 경계이다. $IQR = Q_3 - Q_1$이며 가운데 약 50%의 퍼짐을 나타낸다.
보기 검토: ②는 $323.5 - 204.5 = 119$이다. ③은 평균 261.3이 중앙값 258.0보다 커서 오른쪽 꼬리를 의심할 수 있다는 해석이며, 차이가 작으므로 히스토그램 등으로 확인한다. ④ feed는 사료 이름을 구분하는 범주형(명목형) 변수이고 summary는 범주별 개수를 보여 준다.
학습 포인트: summary()는 수치형 변수에는 최솟값·사분위수·평균·최댓값을, 범주형(factor) 변수에는 범주별 빈도를 출력한다.

📋 **출력 읽는 법**

`summary(chickwts)`	chickwts(치크웨이츠) 데이터를 요약하라
`weight` 열	숫자형 → 최솟값(Min)·1사분위(1st Qu.)·중앙값(Median)·평균(Mean)·3사분위(3rd Qu.)·최댓값(Max)
`feed` 열	범주형 → 범주별 **개수**(casein 12마리 등)
`1st Qu. 204.5`	아래에서 25% 지점 → 이보다 큰 값은 **75%**
`IQR`	323.5 − 204.5 = 119
`Mean 261.3 > Median 258`	평균이 중앙값보다 큼 → 오른쪽 꼬리 의심

💡 **쉽게 이해하기** Q1(1st Qu.)은 '아래에서 25%' 지점입니다. 100명을 키 순으로 세우면 25번째쯤 되는 사람의 키라서, 그보다 큰 사람은 **75명**입니다. ①은 이것을 거꾸로 말했습니다.

12. 아래는 어느 학급의 수학 점수를 나타낸 상자그림(Boxplot)이다. 해석으로 옳지 않은 것은? 47회 29번

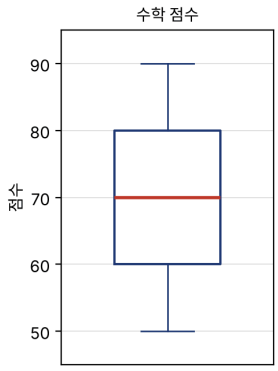


그림 정보: $Q_1 = 60$점, 중앙값 $= 70$점, $Q_3 = 80$점.

① 점수의 중앙값은 70점이다.
② 사분위수 범위(IQR)는 20점이다.
③ 전체 학생의 약 50%가 60점과 80점 사이에 있다.
④ 학생들의 평균 점수는 70점이다.

정답 ④
상자그림은 중앙값과 사분위수를 보여 줄 뿐 평균은 표시하지 않으므로, 평균이 70점이라고 단정한 ④가 틀렸다.
상자 안의 선이 중앙값(Q_2), 상자의 아래·위 경계가 Q_1·Q_3이다. 그림에서 $Q_1 = 60$, 중앙값 $= 70$, $Q_3 = 80$이므로 $IQR = 80 - 60 = 20$이고, 가운데 약 50%의 학생이 60~80점 사이에 있다. 보기 판단: ①②③은 그림에서 바로 읽을 수 있는 값이다. ④의 평균은 상자그림의 구성 요소가 아니며, 분포가 비대칭이면 중앙값과 평균이 달라질 수 있으므로 그림만으로 70점이라고 할 수 없다.

💡 **쉽게 이해하기** 상자그림(Boxplot, 박스플롯)이 보여 주는 것은 **다섯 숫자**(최솟값·Q1·중앙값·Q3·최댓값)와 이상값뿐입니다. **평균은 그림에 없습니다.** 중앙값이 70이어도 평균은 다를 수 있습니다.

13. 다음 중 상자그림(Boxplot)에 대한 설명으로 적절하지 않은 것은? 48회 21번

① 상자그림 내부의 수평선은 해당 데이터의 중앙값을 나타낸다.
② 사분위수 범위(IQR)는 전체 데이터의 50%가 분포하는 구간의 길이를 나타낸다.
③ IQR의 1.5배를 초과하여 벗어난 관측치는 이상치로 정의할 수 있다.
④ 상자그림의 폭과 길이 비교를 통해 해당 데이터의 관측치 개수를 파악할 수 있다.

정답 ④
일반적인 상자그림은 중앙값, 사분위수, 분포의 퍼짐, 이상치 후보를 보여준다. 상자의 높이와 수염 길이는 값의 분포를 나타내며 관측치 수를 직접 의미하지 않는다. 따라서 폭과 길이를 비교하여 표본 수를 파악할 수 있다는 ④가 틀렸다. 표본 수에 비례하도록 폭을 따로 설계한 특수 상자그림은 예외이다. 이상치 기준은 Q1−1.5IQR 미만 또는 Q3+1.5IQR 초과이다.

💡 **쉽게 이해하기** 상자그림은 값의 **위치와 퍼짐**을 그린 것이지 **몇 명인지(개수)**를 그린 것이 아닙니다. 10명이든 1,000명이든 같은 모양의 상자가 나올 수 있습니다.

14. 다음 상자그림 요약에 대한 설명으로 옳지 않은 것은? 49회 32번

어떤 수면제를 복용한 20명의 '수면시간 증가량(시간)'을 측정하여 상자그림으로 요약한 결과는 다음과 같다.

최솟값	Q1	중앙값(Q2)	Q3	최댓값
−1.0	0.0	1.2	2.5	4.0

① 수면시간 증가량의 최댓값은 4.0시간이다.
② 적어도 절반(50%)의 사람은 수면시간이 1.2시간 이상 증가했다.
③ 일부 사람은 수면시간이 오히려 감소(증가량이 음수)하였다.
④ 정확히 5명의 수면시간이 감소하였다.

정답 ④
④가 틀리다. 요약표는 상자그림의 다섯 수치(최솟값·Q1·중앙값·Q3·최댓값)이다. 최댓값 4.0과 최솟값 −1.0에서 ①·③을 확인할 수 있다. 20개 자료의 통상적인 중앙값이 1.2라면 절반 이상은 1.2 이상이므로 ②도 맞다. Q1=0.0이라는 사실만으로 음수인 관측값이 정확히 5개라고 단정할 수 없다. 사분위수 계산법과 경계값에 동률이 있는지에 따라 해석도 달라질 수 있다.

📋 **출력 읽는 법**

다섯 숫자 요약	최솟값 −1.0 / Q1 0.0 / 중앙값 1.2 / Q3 2.5 / 최댓값 4.0
최솟값 −1.0	음수 = 수면시간이 **줄어든** 사람이 있음
중앙값 1.2	절반 이상이 1.2시간 이상 증가
Q1 = 0.0	아래 25%의 경계가 0이라는 뜻일 뿐, 음수인 사람이 **정확히 몇 명**인지는 알 수 없음

💡 **쉽게 이해하기** 다섯 숫자 요약은 '경계선'만 알려 줍니다. Q1 = 0이라고 해서 감소한 사람이 정확히 5명(20명의 25%)이라고 할 수 없습니다. 0인 사람이 여러 명일 수도 있기 때문입니다.

확률의 기본 성질

15. 확률의 기본 성질에 대한 설명 중 잘못된 것은? 50회 37번

① 임의의 사건 A에 대하여 $0 \leq P(A) \leq 1$ 이다.
② 전체 표본공간의 확률은 1이다.
③ 사건 A의 여사건에 대하여 $P(A\text{의여사건}) = 1 - P(A)$ 이다.
④ 서로 독립인 두 사건의 확률의 합은 두 사건의 합집합의 확률과 같다.

> **정답 ④**
> $P(A \cup B) = P(A) + P(B) - P(A \cap B)$이다. 독립이면 $P(A \cap B) = P(A)P(B)$이며 일반적으로 0이 아니다. 확률의 합이 합집합의 확률이 되는 조건은 독립이 아니라 배반이다.

💡 **쉽게 이해하기** 주사위로 확인: 1이 나오는 사건과 2가 나오는 사건은 **동시에 일어날 수 없으므로(배반)** 그냥 더해 2/6입니다. 주사위 두 번에서 '첫 번째 1'과 '두 번째 1'은 **독립**인데 둘 다 1인 경우(1/36)가 겹치므로 그냥 더하면 안 됩니다. **독립 = 곱, 배반 = 합**.

빠른 정답표

1	③	2	④	3	②	4	③	5	②	6	③	7	③	8	④	9	①	10	④
11	①	12	④	13	④	14	④	15	④										

자주 나오는 함정

- 절대 영점이 있으면 **비율척도**, 없지만 덧셈·뺄셈 가능하면 **등간(구간)척도**
- 계통 = **첫 표본만** 무작위 후 일정 간격 · 집락 내부는 **이질**, 층 내부는 **동질**
- 표본의 평균·분산·표준편차 = **통계량**, 모집단의 값 = 모수
- 상자그림으로 **평균·데이터 개수**는 알 수 없음 · 상자 = 중앙 50%(IQR)
- 독립이면 동시 확률은 **곱**, 확률의 합 = 합집합 확률은 **배반**일 때

2단원 확률분포

확률분포

16. 다음 확률 및 확률분포에 대한 설명 중 옳지 않은 것은? 49회 23번

① 배반사건(서로소)인 두 사건은 독립사건이 아닐 수 있다.
② 독립사건인 두 사건은 배반사건이 아닐 수 있다.
③ 연속확률분포에서 확률밀도함수(PDF)의 함숫값은 항상 0과 1 사이의 값을 갖는다.
④ 이산확률분포에서 확률질량함수(PMF)의 함숫값은 0과 1 사이의 값을 갖는다.

> **정답 ③**
> 확률밀도함수의 함숫값은 0 이상이기만 하면 되고 1보다 클 수 있다 (예: 구간 [0, 0.5]의 균등분포는 f(x) = 2). 1이 되어야 하는 것은 전체 면적이다. ①·② 확률이 0보다 큰 두 사건이 배반이면 독립이 아니고, 독립인 두 사건은 동시에 일어날 수 있으므로 배반이 아닐 수 있다.

💡 **쉽게 이해하기** **PMF**(피엠에프, 확률질량함수) = 막대 **높이**가 확률 → 0~1. **PDF**(피디에프, 확률밀도함수) = 곡선 아래 **넓이**가 확률 → 높이는 1을 넘을 수 있음. 폭이 0.5인 구간에 넓이 1을 담으려면 높이가 2가 되어야 하는 것과 같습니다.

17. 다음 중 이산형 확률분포가 아닌 것은? 49회 39번

① 이항분포(Binomial)
② 초기하분포(Hypergeometric)
③ 기하분포(Geometric)
④ 지수분포(Exponential)

> **정답 ④**
> 지수분포는 사건 사이의 대기 시간을 나타내는 연속형 확률분포이다. 이항분포, 초기하분포, 기하분포는 모두 이산형 확률분포이다.

💡 **쉽게 이해하기** 이름이 비슷한 함정: **기하분포**(지오메트릭) = 첫 성공까지 **몇 번**(세기 → 이산), **지수분포**(익스포넨셜) = 다음 사건까지 **얼마나 오래**(시간 → 연속). '세면 이산, 재면 연속'.

빠른 정답표

16	③	17	④

자주 나오는 함정

- **기하분포**(첫 성공까지 횟수) = 이산, **지수분포**(다음 사건까지 시간) = 연속
- PDF 함숫값은 1을 넘을 수 있음 (확률은 **넓이**)

3단원 기댓값·분산, 왜도·첨도, 공분산·상관계수

기댓값

18. 아래 확률분포에 대한 기대값은? 46회 24번

P(X=1) = 0.4 P(X=2) = 0.3 P(X=3) = 0.2 P(X=4) = 0.1

① 1.0
② 1.5
③ 2.0
④ 2.5

정답 ③

$E(X) = 1 \times 0.4 + 2 \times 0.3 + 3 \times 0.2 + 4 \times 0.1 = 0.4 + 0.6 + 0.6 + 0.4 = 2.0$이다. 따라서 ③이다. 단순히 값 1·2·3·4의 산술평균을 계산하면 2.5이지만, 각 값이 동일한 확률로 발생하지 않으므로 이 계산은 잘못된다.

핵심 개념: 이산확률변수의 기대값은 각 가능한 값에 그 값이 발생할 확률을 곱한 뒤 더한 가중평균이다. $E(X) = \sum x P(X = x)$로 계산한다.

자료 확인: 그림의 값은 $X = 1, 2, 3, 4$이고 대응 확률은 0.4,0.3,0.2,0.1이다. 확률의 합은 $0.4 + 0.3 + 0.2 + 0.1 = 1$이므로 확률분포 조건을 만족한다.

보기 검토: ①의 1.0은 확률의 합이며 기대값이 아니다. ②의 1.5는 주어진 곱의 합과 맞지 않는다. ④의 2.5는 확률을 무시한 값들의 산술평균에 해당한다.

학습 포인트: 기대값 2.0은 한 번 시행할 때 항상 2가 나온다는 뜻이 아니다. 같은 확률 구조의 시행을 충분히 반복했을 때 평균의 기준이 되는 값이다. 기대값은 가능한 값 사이에 놓이며 경우에 따라 실제로 발생할 수 없는 값이 될 수도 있다.

💡 **쉽게 이해하기** 기댓값 E(X)(이 엑스) = 값 × 확률을 모두 더한 **가중평균**. 뽑기 게임에서 꽝이 자주 나오면 평균 상금이 낮아지는 것처럼, 자주 나오는 값에 더 큰 무게를 줍니다. 1·2·3·4를 그냥 평균 내면(2.5) 확률을 무시한 것입니다.

19. 확률변수 X가 1, 2, 3의 값을 가지며 P(X=1) = 1/6, P(X=2) = 1/2, P(X=3) = 1/3이다. X의 기댓값으로 옳은 것은? 49회 27번

① 2
② 7/6
③ 11/6
④ 13/6

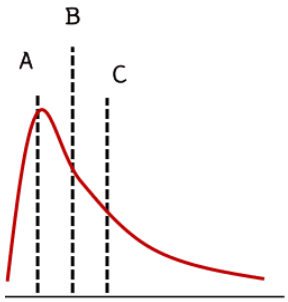
정답 ④

확률의 합은 1/6+1/2+1/3=1이다.
E(X)=ΣxP(X=x)=1×(1/6)+2×(1/2)+3×(1/3)=13/6이므로 정답은 ④이다.

💡 **쉽게 이해하기** 분수 계산이 헷갈리면 분모를 6으로 통일하세요. 1×1/6 + 2×3/6 + 3×2/6 = (1 + 6 + 6)/6 = **13/6**. 먼저 확률의 합이 1인지(1/6 + 3/6 + 2/6 = 1) 확인하면 실수가 줄어듭니다.

왜도 · 선형변환

20. 다음 오른쪽 꼬리 분포에서 A, B, C에 해당되는 통계량은? 47회 26번



① A: 최빈값 / B: 평균 / C: 중앙값
② A: 최빈값 / B: 중앙값 / C: 평균
③ A: 평균 / B: 중앙값 / C: 최빈값
④ A: 중앙값 / B: 최빈값 / C: 평균

정답 ②

그림과 같은 전형적 단봉 오른쪽 꼬리 분포에서는 최빈값 < 중앙값 < 평균이다.

오른쪽 긴 꼬리에 있는 큰 값들은 평균을 오른쪽으로 끌어당긴다. 중앙값은 관측값의 순서상 가운데이므로 극단적인 큰 값의 크기에 평균보다 덜 민감하다. 최빈값은 분포에서 가장 자주 나타나는 위치에 해당한다.

그림 판단: 제시된 전형적인 단봉 오른쪽 꼬리 그림에서 왼쪽부터 A=최빈값, B=중앙값, C=평균이므로 ②이다. ①은 중앙값·평균의 위치를 바꾸고 ③④는 최빈값 위치를 맞추지 못했다. 이 순서는 해당 그림의 전형적 형태를 해석하는 규칙이며 모든 임의 분포에 예외 없이 성립하는 정리로 일반화하지 않는다.

💡 **쉽게 이해하기** **평균은 꼬리를 따라갑니다.** 연봉 조사에서 몇몇 억대 연봉자가 평균을 끌어올리는 것과 같습니다. 오른쪽 꼬리면 왼쪽부터 **최빈값(봉우리) → 중앙값 → 평균** 순서입니다.

21. 어떤 변수 x를 y = ax + b (단, a > 0)로 선형변환했을 때, 다음 통계량 중 그 값이 변하지 않는 것은? 49회 28번

① 왜도(Skewness)
② 표준편차
③ 평균
④ 중앙값

> **정답 ①**
> 왜도는 표준화된 값의 세제곱 평균이므로 a > 0인 선형변환에서 변하지 않는다. 평균과 중앙값은 a배 후 b만큼 이동하고, 표준편차는 a배가 된다.

> 💡 **쉽게 이해하기** 단위를 바꾸는 것(cm → m, ×0.01)이나 모두에게 점수를 더해 주는 것(+10)은 분포의 **위치와 크기**만 바꾸고 **모양**은 그대로 둡니다. 왜도(스큐니스)는 모양(기울어짐)이라 그대로이고, 평균·중앙값·표준편차는 바뀝니다.

공분산 · 상관계수

22. 아래 표에서 X, Y 두 변수의 표본 공분산은? 46회 30번

X	1	2	3	4	5
Y	2	4	5	6	8

① 3.5
② 4.0
③ 4.5
④ 5.0

> **정답 ①**
> X의 평균 편차는 $-2, -1, 0, 1, 2$이고 Y의 평균 편차는 $-3, -1, 0, 1, 3$이다. 대응 편차의 곱은 6,1,0,1,6이며 합은 14이다. 표본 공분산은 $\frac{14}{5-1} = \frac{14}{4} = 3.5$이므로 ①이다.
> 핵심 개념: 표본 공분산은 두 변수가 각각 평균에서 벗어난 정도를 곱한 뒤 합하고 $n-1$로 나눈 값이다. $s_{XY} = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{n-1}$이다. 분모가 n인 모집단 공분산과 구별한다.
> 자료 확인: $X = (1, 2, 3, 4, 5)$, $Y = (2, 4, 5, 6, 8)$이다. 대응되는 관측쌍은 다섯 개이며 $n = 5$이다. $\bar{x} = (1+2+3+4+5)/5 = 3$, $\bar{y} = (2+4+5+6+8)/5 = 5$이다.
> 보기 검토: ②의 4.0, ③의 4.5, ④의 5.0은 위 편차곱과 자유도로 얻는 값이 아니다. 분모를 n으로 잘못 쓰면 $14/5 = 2.8$이 되며 이것도 보기의 답과 맞지 않는다.
> 학습 포인트: 공분산이 양수이므로 X가 평균보다 큰 관측에서 Y도 평균보다 큰 경향이 있다. 공분산은 단위에 영향을 받으므로 서로 다른 자료의 관계 강도를 그대로 비교하기 어렵다. 이를 표준화한 지표가 상관계수이다.

> 💡 **쉽게 이해하기** 공분산은 '두 변수의 편차를 곱해서 평균'낸 것입니다. 순서: ① 평균 구하기(x̄ = 3, ȳ = 5) → ② 각자 편차 → ③ 짝끼리 곱하기(6, 1, 0, 1, 6) → ④ 합 14 → ⑤ **n − 1 = 4**로 나누기 = 3.5. 표본이라 n이 아니라 n − 1로 나눕니다.

23. 공분산(Covariance)의 특성에 관한 설명 중 틀린 것은? 50회 43번

① 공분산의 부호를 통해 두 변수 관계의 방향을 알 수 있다.
② 공분산의 값은 변수의 측정 단위에 영향을 받는다.
③ 공분산의 값은 항상 −1과 1 사이의 값을 갖는다.
④ 공분산이 양수이면 두 변수가 같은 방향으로 움직이는 경향이 있다.

> **정답 ③**
> -1~1 범위의 지표는 상관계수이다. 공분산은 측정 단위와 스케일에 영향을 받아 그 범위를 벗어날 수 있다. 부호는 두 변수가 함께 움직이는 방향을 나타낸다.

> 💡 **쉽게 이해하기** 공분산(코배리언스)은 **단위에 따라 크기가 변합니다** (m → cm로 바꾸면 100배). 그래서 −1~1 같은 고정 범위가 없습니다. 범위가 −1~1인 것은 단위를 없앤 **상관계수**입니다.

24. 상관계수에 대한 설명 중 틀린 것은? 45회 32번

① 상관계수는 -1에서 1 사이 값을 가진다.
② 상관계수가 0일 경우, 직선 상관관계가 없다.
③ 상관계수가 -1일 경우, 상관관계가 가장 약하다.
④ 상관계수는 두 변수 간의 직선관계를 측정한다.

> **정답 ③**
> $r = -1$은 가장 약한 관계가 아니라 완전한 음의 선형 관계이므로 ③이 틀리다. 한 변수가 증가할 때 다른 변수가 정확한 직선 관계로 감소하는 경우이다. $r = 1$과 강도는 같고 방향만 반대이다.
> 핵심 개념: 피어슨 상관계수 r은 두 변수의 선형 관계 방향과 강도를 나타낸다. $-1 \le r \le 1$이며 부호는 방향, 절댓값은 선형 관계의 강도이다.
> 보기 검토: ①④는 정의에 맞고, ②의 $r = 0$은 선형 상관이 없다는 뜻으로 읽는다. $r = 0$이어도 U자형 같은 비선형 관계가 존재할 수 있으며 일반적으로 독립을 보장하지 않는다. 상관계수는 각 변수의 분산이 0이면 정의되지 않는다. 상관이 크다는 사실만으로 인과관계를 확정하지 않는다.

> 💡 **쉽게 이해하기** 상관계수는 **부호 = 방향, 절댓값 = 강도**입니다. −1은 '가장 약함'이 아니라 '반대 방향으로 **완벽하게** 일직선'입니다. 시소처럼 한쪽이 올라가면 다른 쪽이 정확히 내려가는 관계입니다.

25. 두 숫자형 변수 간의 선형 관계에 대한 설명으로 적절하지 않은 것은? 48회 35번

① 상관계수는 -1 이상, 1 이하의 값을 가지며, 1이나 -1에 가까울수록 두 변수 간의 선형 관계가 강함을 의미한다.

② 0에 가까운 상관계수는 두 변수 사이에 선형적인 관계가 거의 없음을 의미한다.

③ 높은 상관계수가 두 변수 간의 인과관계를 보장하지는 않는다.

④ 상관계수의 부호가 음수라면 두 변수는 서로 반비례 관계로 볼 수 있다.

> **정답 ④**
> 음의 상관계수는 한 변수가 커질 때 다른 변수가 작아지는 선형 경향을 의미한다. 엄밀한 반비례는 Y=k/X 형태이므로 음의 상관관계만으로 반비례를 확정할 수 없다. 상관계수가 0에 가까워도 비선형 관계가 존재할 수 있으며, 높은 상관관계 역시 인과관계의 증거로 충분하지 않다.

💡 **쉽게 이해하기** '음의 상관'은 한쪽이 커질 때 다른 쪽이 **작아지는 경향**일 뿐, 수학의 반비례(y = k/x, 곡선)와는 다릅니다. 운동량이 늘수록 체중이 줄어드는 경향은 있지만 정확히 반비례하지는 않는 것과 같습니다.

26. 변수 X와 Y의 상관계수가 0.5일 때, 다음 중 옳은 설명은? 48회 28번

① (X+0.3)과 Y의 상관계수는 0.8이다.

② (2X)와 Y의 상관계수는 1이다.

③ (X+0.3)과 (Y+0.2)의 상관계수는 0.5이다.

④ (-X)와 (-2Y)의 상관계수는 1이다.

> **정답 ③**
> 상관계수는 각 변수에 상수를 더해도 변하지 않는다. 양수 배율로 확대해도 변하지 않고, 한 변수만 음수로 곱하면 부호가 반전된다. 두 변수 모두 음수로 곱하면 부호 반전이 두 번 발생하여 원래 상관계수와 같다. 따라서 ③은 0.5로 옳으며, ②와 ④도 1이 아니라 0.5이다. 이는 분산이 0이 아닌 변수의 Pearson 상관계수 성질이다.

💡 **쉽게 이해하기** 상관계수는 점들이 만드는 **모양**만 봅니다. 더하기(+0.3)는 점들을 옆으로 옮길 뿐이라 그대로, 양수 곱하기는 늘이기라 그대로, **음수 곱하기만 좌우를 뒤집어 부호가 바뀝니다**. 두 번 뒤집으면 (−X, −2Y) 원래대로 돌아옵니다.

27. 두 변수 x와 y의 상관계수가 0.2일 때, −2x + 1과 y − 1의 상관계수는? 49회 29번

① -0.2

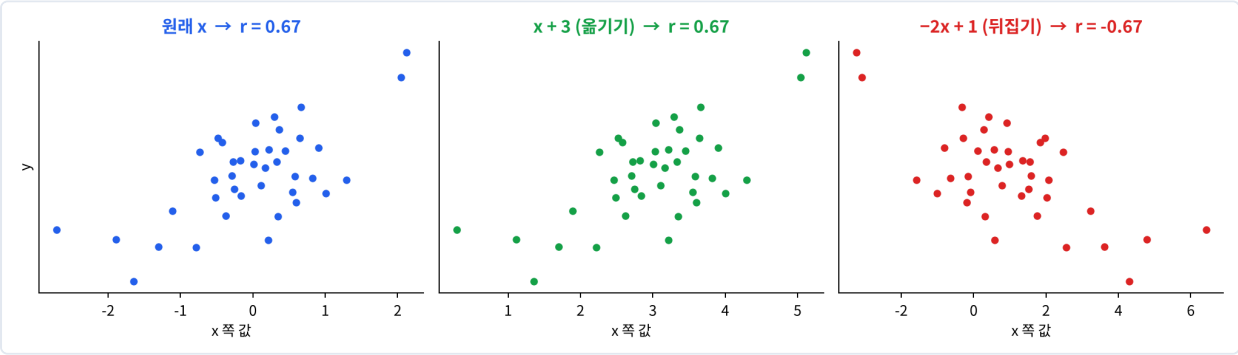
② 0.2

③ 0.4

④ -0.4

> **정답 ①**
> 상관계수는 각 변수에 상수를 더해도 변하지 않고, 양수를 곱해도 변하지 않으며, 음수를 곱하면 부호만 바뀐다. x에 −2가 곱해졌으므로 상관계수는 −0.2이다.

💡 **쉽게 이해하기** **더하기·빼기는 무시, 곱하기는 부호만 확인.** −2x + 1에서 +1은 무시, ×(−2)는 음수라 부호만 반대. y − 1은 무시. 크기(0.2)는 절대 변하지 않으므로 0.4가 될 수 없습니다 → −0.2.



▲ 49회 29번 · 상관계수와 변환: 옮기거나 늘려도 모양은 같고, 음수를 곱하면 좌우가 뒤집혀 부호만 바뀐다

빠른 정답표

18	③	19	④	20	②	21	①	22	①	23	③	24	③	25	④	26	③	27	①

자주 나오는 함정

- 기댓값 = Σ(값 × 확률) · 단순 평균이나 확률의 합으로 답하게 유도
- 오른쪽 꼬리: 최빈값 < 중앙값 < **평균** · y = ax + b(a > 0)에도 **왜도**는 불변
- r = −1은 가장 **강한** 음의 관계 · 공분산은 범위 제한 없음 · 표본 공분산은 ÷ (n − 1)
- +상수, ×양수 → 상관계수 불변 · ×음수 → **부호만** 반전

4단원 추정·가설검정·비모수 검정

추정 · 표본오차

28. 모집단에서 30대 남성 30명을 무작위 추출하여 평균 체중을 추정할 때, 설명으로 옳지 않은 것은? 46회 23번

① 표본평균은 모평균의 불편추정량이다.
② 표본 크기가 커지면 표본평균의 표준오차가 작아진다.
③ 점추정은 모수를 하나의 값으로 추정하는 방식이다.
④ 같은 모집단에서 표본을 다시 추출해도 표본평균은 항상 같은 값이다.

정답 ④

30명을 다시 뽑으면 포함되는 사람이 달라지므로 표본평균도 달라진다. 표본평균이 항상 같은 값이라고 한 ④가 틀렸다.

핵심 개념: 모집단 전체의 특성을 나타내는 수치(모평균 μ)는 모수이고, 표본으로 계산하는 표본평균 $\bar{X}$는 통계량이다. 통계량은 어떤 표본이 뽑히느냐에 따라 값이 달라지는 확률변수이며, 그 분포를 표본분포라고 한다.

보기 검토: ①은 무작위 표본에서 $E(\bar{X}) = \mu$이므로 맞다. ②는 표본평균의 표준오차가 $\sigma/\sqrt{n}$이므로 n이 커지면 작아진다. ③은 점추정의 정의이다. 모수가 포함될 범위를 구간으로 제시하는 것은 구간추정이다.

학습 포인트: $E(\bar{X}) = \mu$에서 μ는 모수이지만 $\bar{X}$ 자체는 통계량이다. 표본평균의 기대값이 모평균과 같다는 것(불편성)과 한 번 관측한 표본평균이 모평균과 같다는 것은 다르다.

💡 **쉽게 이해하기** 표본평균은 '뽑을 때마다 달라지는 값'입니다. 반에서 5명을 뽑아 키 평균을 내면, 다시 뽑을 때마다 다른 5명이 걸려 평균이 매번 조금씩 다릅니다. 그래서 **표준오차**(스탠다드 에러) 같은 '흔들림의 크기'를 따지는 것입니다.

29. 다음 중 통계적 추론에 대한 설명으로 적절하지 않은 것은? 48회 23번

① 구간 추정 방식으로 일정한 신뢰수준 하에서 모수가 포함될 것으로 기대되는 범위를 정하여 모수를 추정할 수 있다.
② 가설검정에 사용할 수 있는 검정통계량은 검정 방법과 무관하게 항상 하나로만 유일하게 결정된다.
③ 유의수준은 제1종 오류를 범할 수 있는 허용 한계로 가설 채택 여부를 결정하는 값이다.
④ p-value 값이 유의수준보다 작으면 귀무가설을 기각할 수 있다.

정답 ②

검정통계량은 검정 목적, 자료 형태, 가정에 따라 t·F·카이제곱 등으로 달라진다. 어떤 가설에 적용할 수 있는 방법이 언제나 하나뿐이라는 ②는 틀렸다. 선택한 검정에서 하나의 관측 통계량을 계산하는 것과, 가능한 검정 방법이 유일하다는 주장은 다르다. p-value가 유의수준보다 작으면 해당 검정의 귀무가설을 기각한다.

💡 **쉽게 이해하기** 같은 질문이라도 데이터 종류에 따라 쓰는 '자'가 다릅니다. 평균 비교는 **t**, 분산 비교는 **F**, 범주형은 **χ^2**(카이제곱). 검정통계량이 '항상 하나뿐'이라는 말은 틀립니다.

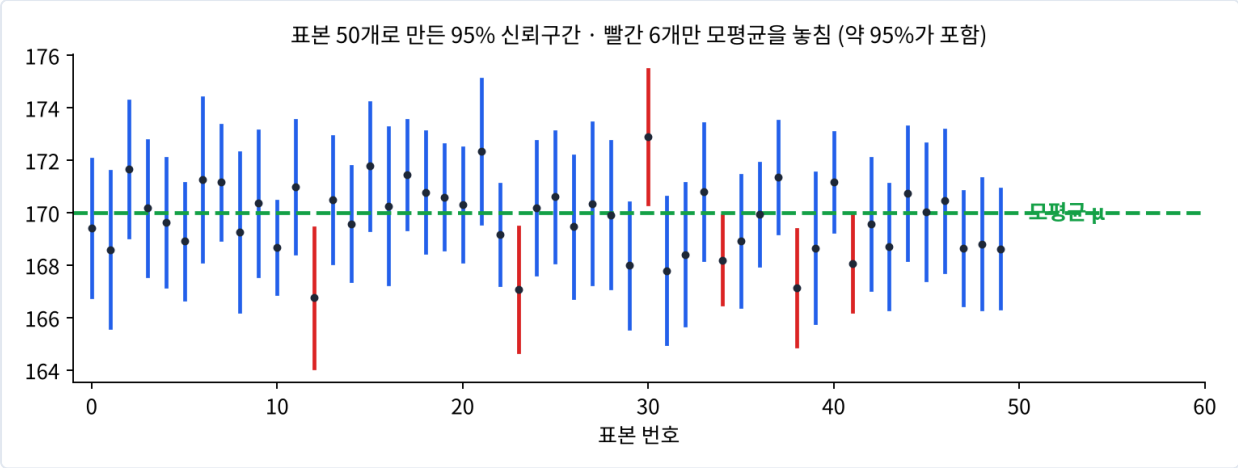
30. 다음 중 통계적 추론에 대한 설명으로 적절하지 않은 것은? 48회 30번

① 통계적 추론은 표본 통계량을 토대로 모집단의 모수를 추측하는 과정이다.
② 신뢰수준은 주어진 신뢰구간에 모수가 포함할 확률이다.
③ 표본의 크기가 일정할 때, 신뢰수준을 높이면 신뢰구간의 길이는 더 길어진다.
④ 신뢰수준이 일정할 때, 표본의 크기가 커질수록 신뢰구간의 길이는 더 좁아진다.

정답 ②

빈도주의에서 모수는 고정되어 있고 표본을 반복 추출하면 신뢰구간이 달라진다. 95% 신뢰수준은 같은 방법으로 만든 구간이 반복적으로 참 모수를 포함하는 비율이 95%라는 뜻이다. 이미 계산된 특정 구간에 고정된 모수가 들어갈 확률을 95%라고 정의한 ②는 엄밀한 설명이 아니다. 같은 조건에서 신뢰수준이 높으면 구간은 넓어지고 표본 수가 많으면 좁아지는 경향이 있다.

💡 **쉽게 이해하기** **고리 던지기 비유**: 말뚝(진짜 평균)은 고정, 고리(신뢰구간)는 던질 때마다 위치가 다름. 95%는 '이 방법으로 100번 던지면 약 95번 걸리는 **실력**'입니다. 이미 던진 고리 하나는 걸렸거나 안 걸렸거나 둘 중 하나라 '확률 95%'라고 말할 수 없습니다.



▲ 48회 30번 · 같은 방법으로 신뢰구간 50개를 만들면 대부분이 진짜 평균(초록 점선)을 포함하고, 빨간 몇 개만 놓친다

31. 표본오차와 비표본오차에 대한 설명으로 옳지 않은 것은?

49회 37번

① 표본오차는 표본이 모집단을 완전히 대표하지 못해 발생하는 오차이다.
② 일반적으로 표본 크기를 늘리면 표본오차는 줄어드는 경향이 있다.
③ 비표본오차는 조사·입력·집계 과정의 실수 등으로 발생하는 오차이다.
④ 비표본오차는 표본 크기를 늘릴수록 함께 줄어든다.

> **정답 ④**
> 비표본오차는 조사 설계, 응답, 입력, 집계 과정의 잘못으로 생기는 오차이므로 표본 크기를 늘려도 줄지 않으며, 조사 규모가 커지면 오히려 늘어날 수 있다.

💡 **쉽게 이해하기** 표본오차 = **운**(사람을 더 많이 조사하면 줄어듦), 비표본오차 = **실수**(질문지 오류·거짓 응답·입력 실수). 조사 인원을 늘리면 실수할 기회가 오히려 늘 수도 있습니다.

가설검정 · 오류 · p-value

32. 가설 검정에 대한 설명으로 가장 옳지 않은 것은? 46회 22번

① p-value는 0과 1 사이의 값을 가지며 통계적 유의성 판단 기준이 된다.
② p-value가 작을수록 대립가설을 지지하는 증거가 된다.
③ p-value가 유의수준(α)보다 작으면 대립가설을 기각한다.
④ p-value가 유의수준(α)보다 크면 귀무가설을 기각하지 못한다.

> **정답 ③**
> ③은 p값이 작을 때 대립가설을 기각한다고 반대로 썼다. 올바른 결론은 귀무가설을 기각하는 것이다. 예를 들어 $\alpha = 0.05$이고 $p = 0.01$이면 귀무가설 아래에서 관측 결과가 충분히 극단적이므로 귀무가설을 기각한다.
> 핵심 개념: 귀무가설 H_0를 기준으로 관측 결과의 극단성을 나타내는 값이 p값이다. 유의수준 α는 검정 전에 정하는 판단 기준이며, 통상 $p < \alpha$이면 귀무가설을 기각한다.
> 보기 검토: ①은 일반적인 검정에서 p값의 범위와 용도를 설명한다. ②는 검정 가정이 맞다는 전제에서 작은 p값이 귀무가설과 자료의 불일치를 더 크게 나타낸다는 취지이다. ④는 p값이 α보다 크면 귀무가설을 기각하지 못한다는 올바른 표현이다. p값이 크다고 귀무가설이 참이라고 증명된 것은 아니다.
> 학습 포인트: $p = 0.01$을 '귀무가설이 참일 확률 1%'라고 읽지 않는다. p값은 가설의 참일 확률이 아니라 가정한 모형 아래에서 계산한 자료의 극단성이다. 효과 크기와 실무적 중요성도 p값과 별도로 살핀다. 표본이 크면 작은 차이도 유의해질 수 있다.

💡 **쉽게 이해하기** 판단 규칙은 하나: **p가 작으면 H_0(에이치 제로)를 버린다.** 기각되는 것은 언제나 **귀무가설**입니다. '대립가설을 기각'이라는 표현이 나오면 일단 의심하세요.

33. 다음 중 가설검정의 제 1종 및 2종 오류 해석에 대한 설명으로 적절하지 않은 것은? 47회 24번

① 제 1종 오류는 귀무가설이 실제로는 참인데도 불구하고, 이를 기각하고 대립가설을 채택하는 오류이다.

② 제 2종 오류는 실제로는 대립가설이 참인데도 불구하고, 귀무가설을 기각하지 못하는 통계적 오류이다.

③ 유의수준(α)은 제 1종 오류의 최소 허용 한계이다.

④ 유의수준을 너무 작게 설정하면 2종 오류를 범할 확률이 높아진다.

> **정답 ③**
> 유의수준은 제1종 오류 확률의 허용 상한이다. ③의 최소 허용이라는 표현이 틀리다. 제2종 오류는 귀무가설을 기각하지 못하는 오류이다.
> 제1종 오류는 참인 귀무가설을 기각하는 오류이고 그 확률을 α로 나타낸다. 제2종 오류는 실제 대립가설이 성립하는 상황에서 귀무가설을 기각하지 못하는 오류이며 확률을 β로 나타낸다. 검정력은 $1-\beta$이다.
> 보기 판단: ①②는 두 오류의 정의이다. ③은 최소 허용 한계라는 표현이 틀렸으며 유의수준은 제1종 오류 확률의 허용 상한으로 이해한다. ④는 표본 크기·효과 크기·검정 방식 등 다른 조건을 고정했을 때 기각 기준을 엄격하게 하면 제2종 오류가 커질 수 있다는 뜻이다. 유의수준을 낮추면 모든 종류의 오류가 동시에 줄어드는 것은 아니다.

💡 **쉽게 이해하기** 화재경보기 비유: **1종 오류** = 불이 없는데 울림(거짓 경보), **2종 오류** = 불이 났는데 안 울림(놓침). 유의수준 α(알파)는 거짓 경보를 '**최대** 5%까지만' 참겠다는 상한선입니다. 경보기를 둔하게 만들면(α↓) 진짜 불을 놓칠 위험(β 베타)이 커집니다.

34. 다음 중 통계적 유의성에 대한 설명으로 적절하지 않은 것은? 47회 28번

① 표본의 크기가 커질수록 표준 오차가 작아지므로, 신뢰구간의 길이는 점점 짧아진다.

② p-value가 클수록 귀무가설을 기각하고 대립가설을 채택할 확률이 높아진다.

③ 표본의 크기가 커질수록 아주 작은 차이도 통계적으로 유의미하게 나타날 가능성이 높아진다.

④ 신뢰수준을 95%에서 99%로 높이면 신뢰구간의 폭은 더 넓어지고, 정밀도는 떨어진다.

> **정답 ②**
> 작은 p값일수록 귀무가설에 불리하다. p값은 귀무가설이 참일 확률이나 기각할 확률이 아니다.
> p값은 귀무가설과 검정의 가정을 전제로 현재 결과 이상으로 극단적인 통계량이 나올 확률이다. $p \leq \alpha$이면 귀무가설을 기각하는 판단 규칙을 사용한다. 따라서 p값이 커질수록 기각 가능성이 높다는 ②는 방향부터 잘못되었다. p값은 귀무가설이 참일 확률이 아니다.
> 나머지 보기: 다른 조건이 같을 때 표준오차는 대체로 표본 크기의 제곱근에 반비례하므로 ①은 신뢰구간 축소를 설명한다. ③은 큰 표본에서 작은 효과도 유의할 수 있다는 뜻이다. ④는 99% 구간이 95% 구간보다 넓다는 설명이다. 통계적 유의성과 실제 업무상 중요한 효과 크기는 함께 판단해야 한다.

💡 **쉽게 이해하기** p값 = '귀무가설이 맞다면 이런 결과가 나올 확률'. **p가 크다 = 운으로 흔히 생기는 결과** → 기각할 이유가 없음. p가 클수록 기각 가능성이 높다는 ②는 방향이 정반대입니다. 신뢰수준을 99%로 올리면 '더 확실하게' 맞히려고 범위를 넓히므로 덜 구체적(덜 정밀)해집니다.

35. 다음 중 가설검정에 대한 설명으로 적절하지 않은 것은? 48회 26번

① p-value가 미리 설정한 유의수준보다 작으면 귀무가설을 기각하고 대립가설을 채택한다.

② 귀무가설이 참이라는 가정하에 검정통계량의 값이 나타날 가능성이 작을수록 귀무가설을 채택한다.

③ 제2종 오류는 대립가설이 실제로 참임에도 불구하고, 귀무가설을 기각하지 못하고 채택하는 오류를 의미한다.

④ 검정력은 대립가설이 참일 때 이를 올바르게 판정하여 귀무가설을 기각할 확률로, $1-\beta$로 계산한다.

> **정답 ②**
> 귀무가설하에서 관측 결과 또는 더 극단적인 결과가 드물수록 귀무가설과 자료의 양립 가능성이 낮아진다. p-value가 작으면 귀무가설을 기각하는 방향이므로 이를 채택한다는 ②가 틀렸다.
> 제1종 오류는 참인 귀무가설의 기각, 제2종 오류는 거짓인 귀무가설을 기각하지 못하는 것이며 검정력은 1−β이다. 기각하지 못함은 참임의 입증과 구별한다.

💡 **쉽게 이해하기** 'H_0가 맞다면 이런 결과가 나올 가능성이 작다' = **운으로 보기 어렵다** → H_0를 **버림**(기각). 가능성이 작을수록 채택한다는 ②는 반대로 말했습니다.

36. 가설검정에 대한 설명으로 옳지 않은 것은? 49회 22번

① 귀무가설(H_0)은 일반적으로 '차이가 없다' 또는 '효과가 없다'를 의미하는 기본 가설이다.

② 유의수준(α)은 귀무가설이 참인데도 기각하는 제1종 오류의 허용 확률이다.

③ 대립가설(H_1)은 연구자가 주장하거나 입증하고자 하는 가설이다.

④ p-value가 유의수준보다 크면(높으면) 귀무가설을 기각한다.

> **정답 ④**
> p-value가 유의수준보다 '작을' 때 귀무가설을 기각한다. 유의수준보다 크면 귀무가설을 기각하지 못한다.

💡 **쉽게 이해하기** **p < α → 기각**, p ≥ α → 기각 못함. 동전 비유: 공정한 동전에서 앞면 6번(p = 0.75)은 흔한 일이라 '공정하다'를 뒤집을 이유가 없습니다. 9번(p = 0.02)이어야 의심합니다.

37. 아래 상황에서 검정 결과로 가장 적절한 것은? 50회 23번

> 공정한 동전인지 확인하기 위해 동전을 5번 던졌더니 5번 모두 앞면이 나왔다. 귀무가설 $H_0 : p = 0.5$ 에 대하여 유의수준 5%에서 양측검정을 수행하고자 한다.

① p-value = $\frac{1}{16}$ 이므로 귀무가설을 기각한다.

② p-value = $\frac{1}{16}$ 이므로 귀무가설을 기각하지 않는다.

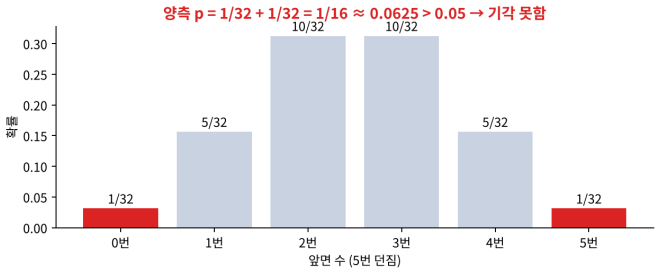
③ p-value = $\frac{1}{32}$ 이므로 귀무가설을 기각한다.

④ p-value = $\frac{1}{32}$ 이므로 귀무가설을 기각하지 않는다.

정답 ②

공정한 동전에서 5번 모두 앞면일 확률은 $(1/2)^5 = 1/32$이다. 양측검정은 모두 뒷면인 경우도 포함하므로 p-value $= 2/32 = 1/16 = 0.0625$이다. 0.05보다 크므로 귀무가설을 기각하지 않는다.

💡 **쉽게 이해하기** **양측검정**은 '너무 많이 나온 쪽'과 '너무 적게 나온 쪽' **양쪽 끝**을 모두 봅니다. 앞면 5번(1/32)만 세면 한쪽만 본 것이고, 반대쪽 끝인 뒷면 5번(1/32)도 더해 **2/32 = 1/16 ≈ 0.0625**. 0.05보다 크니 기각 못합니다.



▲ 50회 23번 · 공정한 동전 5번: 양측검정의 p값은 양쪽 끝(앞면 5번, 뒷면 5번) 막대를 더한 1/16

빠른 정답표

28	④	29	②	30	②	31	④	32	③	33	③	34	②	35	②	36	④	37	②

자주 나오는 함정

- **p < α → H_0 기각** · 방향을 뒤집은 보기(p가 크면 기각, 대립가설 기각)가 단골
- 유의수준 = 1종 오류의 **최대** 허용 확률 · α를 줄이면 β 증가
- 신뢰수준 ↑ → 구간 넓어짐, n ↑ → 좁아짐 · 신뢰수준은 이 구간에 모수가 있을 "확률"이 아님
- 비표본오차는 표본 크기와 무관 · 양측 p는 한쪽 확률 × 2

5단원 t-검정·분산분석·교차분석·상관분석

t-검정

38. 일표본 t-검정 결과에 대한 설명으로 옳지 않은 것은? 46회 26번

> p-value = 0.001
> 자유도(df) = 99
> 표본평균 = 51.5

① 유의수준 0.05에서 귀무가설을 기각하지 못한다.
② 전체 데이터 수는 100개이다.
③ 표본평균을 표준화한 검정통계량이 t분포를 따른다고 가정한다.
④ 확률변수가 정규분포를 따른다는 가정이 필요하다.

정답 ①

출력에는 $p = 0.001$, 자유도 99, 표본평균 51.5가 제시되어 있다. 일표본 검정에서 $n - 1 = 99$이므로 $n = 100$이다. 유의수준을 0.05로 정했다면 $0.001 < 0.05$이므로 귀무가설을 기각한다. 출력에서 유의수준 자체가 결정되는 것은 아니다.

핵심 개념: 일표본 t검정은 모집단 평균 μ가 가정한 값 μ_0와 같은지를 검정한다. 모집단 표준편차를 모를 때 검정통계량 $t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$을 사용하며, 정규 모집단의 독립 표본이라는 조건에서 H_0 아래 자유도 $n - 1$의 t분포를 따른다.

보기 검토: ①은 $p = 0.001$이 유의수준 0.05보다 작아 귀무가설을 기각해야 하므로 틀렸다. ②는 일표본 검정의 자유도 $n - 1 = 99$에서 $n = 100$이므로 맞다. ③은 귀무가설 아래 $t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$이 자유도 99의 t분포를 따른다는 설명으로 맞다. ④는 t검정의 정규 모집단 가정으로 맞으며, 표본이 크면 중심극한정리에 따라 근사적으로 적용할 수 있다.

📋 출력 읽는 법

`p-value = 0.001`	p값. 0.001 < 0.05 → H_0 기각 (평균이 기준값과 다르다)
`df = 99`	자유도(디에프). 일표본은 n − 1 → **n = 100**
`표본평균 51.5`	표본에서 계산한 평균(통계량)

💡 **쉽게 이해하기** 일표본 t-검정 = '우리 반 평균이 50점이라는 말이 맞나?'처럼 **한 집단 평균을 기준값**과 비교하는 검정입니다. 자유도(degrees of freedom, 디그리즈 오브 프리덤)는 평균을 하나 계산하느라 1을 쓰므로 n − 1입니다.

39. 다음은 사립학교와 공립학교 학생의 시험 점수 차이를 비교하기 위해 R에서 독립표본 t-검정을 수행한 결과이다. 해석으로 옳지 않은 것은? 47회 34번

> 결과 요약: p-value = 0.031, 표본평균 사립 74.3점 · 공립 70.0점, 평균 차이(사립 − 공립)의 95% 신뢰구간 [0.42, 8.18]

① 유의수준 0.05에서 두 집단의 평균 점수 차이는 통계적으로 유의하다.
② 사립학교 표본의 평균 점수가 공립학교보다 4.3점 높다.
③ 평균 차이의 95% 신뢰구간은 0을 포함하지 않는다.
④ 유의수준 0.01에서도 귀무가설을 기각할 수 있다.

정답 ④

p-value 0.031은 0.05보다 작지만 0.01보다 크므로, 유의수준 1%에서는 귀무가설을 기각할 수 없다. 따라서 ④가 틀렸다.

독립표본 t-검정의 귀무가설은 두 집단의 평균이 같다는 것이다. $p = 0.031 < 0.05$이므로 5% 수준에서는 차이가 유의하고, 95% 신뢰구간 [0.42, 8.18]이 0을 포함하지 않는 것도 같은 결론이다. 표본평균 차이는 $74.3 - 70.0 = 4.3$점이다.

보기 판단: ①②③은 제시된 결과와 일치한다. ④는 $0.031 > 0.01$이므로 틀렸다. 유의수준을 낮추면 기각 기준이 엄격해지고, 99% 신뢰구간은 95% 구간보다 넓어 0을 포함할 수 있다.

📋 출력 읽는 법

`p-value = 0.031`	0.031 < 0.05 → 5%에서 유의 / 0.031 > 0.01 → **1%에서는 유의하지 않음**
`사립 74.3, 공립 70.0`	표본평균 차이 = 4.3점
`95% 신뢰구간 [0.42, 8.18]`	두 끝이 모두 양수 → **0을 포함하지 않음** → 5%에서 유의 (p < 0.05와 같은 결론)

💡 **쉽게 이해하기** 유의수준은 '커트라인'입니다. p = 0.031은 0.05 커트라인은 넘었지만(합격), 0.01이라는 **더 엄격한 커트라인**은 넘지 못합니다(불합격). 문제에서 **α가 몇인지** 꼭 확인하세요.

40. 같은 환자 10명에게 수면유도제 A와 B를 각각 투여하고 수면시간 증가량(시간)을 측정하여 대응표본 t-검정을 수행한 결과이다. 해석으로 적절하지 않은 것은? 48회 31번

> 분석: t.test(A, B, paired = TRUE)
> t = −4.0621, df = 9, p-value = 0.002833
> 평균 차이(A − B) = −1.58, 95% 신뢰구간: [−2.4599, −0.7001]

① 같은 환자에게 두 약을 모두 투여했으므로 대응표본 t-검정을 사용하는 것이 적절하다.

② 유의수준 0.05에서 두 약물의 평균 효과 차이는 통계적으로 유의하다.

③ A 약물의 평균 수면시간 증가량이 B 약물보다 1.58시간 길다.

④ 평균 차이의 95% 신뢰구간은 0을 포함하지 않는다.

정답 ③

평균 차이(A − B)가 −1.58로 음수이므로 A의 증가량은 B보다 1.58시간 짧다. 따라서 ③이 틀렸다. 같은 대상에 두 처리를 적용했으므로 대응표본 검정이 적절하고(①), p-value 0.002833 < 0.05이므로 차이가 유의하며(②), 신뢰구간 [−2.46, −0.70]이 0을 포함하지 않는 것도 같은 결론이다(④). 차이의 부호를 해석할 때는 어느 쪽에서 어느 쪽을 뺐는지 먼저 확인한다.

📋 출력 읽는 법

`t.test(A, B, paired = TRUE)`	대응표본(페어드) t-검정: 같은 사람에게 A, B 모두 측정
`t = −4.0621`	t 통계량(음수 = A가 B보다 작은 쪽)
`df = 9`	쌍의 수 − 1 → 환자 **10명**
`p-value = 0.002833`	0.05보다 작음 → 유의
`평균 차이(A − B) = −1.58`	**음수** → A가 B보다 1.58시간 **짧음**
`95% 신뢰구간 [−2.46, −0.70]`	모두 음수 → 0 미포함 → 유의

💡 **쉽게 이해하기** 차이의 부호는 '**누가 누구를 뺐나**'로 읽습니다. A − B = −1.58이면 A에서 B를 뺐더니 음수 → A가 더 작습니다. 키 차이(나 − 동생) = −3cm면 내가 3cm 작은 것과 같습니다.

분산분석 · 교차분석

41. ChickWeight 데이터에서 사료(Diet, 4종류)에 따른 병아리 체중(weight)의 차이를 일원배치 분산분석으로 검정한 결과이다. 해석으로 적절하지 않은 것은? 48회 37번

> 분석: aov(weight ~ Diet, data = ChickWeight)
> Diet: Df = 3, Sum Sq = 155863, Mean Sq = 51954, F = 10.81, Pr(>F) = 6.43×10^{-7}
> Residuals: Df = 574, Sum Sq = 2758693, Mean Sq = 4806

① 귀무가설은 네 사료 집단의 평균 체중이 모두 같다는 것이다.
② 유의수준 0.05에서 사료 집단 간 평균 체중에 차이가 있다고 볼 수 있다.
③ 분산분석 결과만으로 어느 사료 집단 사이에 차이가 있는지 알 수 있다.
④ 구체적으로 어느 집단 간에 차이가 있는지 확인하려면 사후검정이 필요하다.

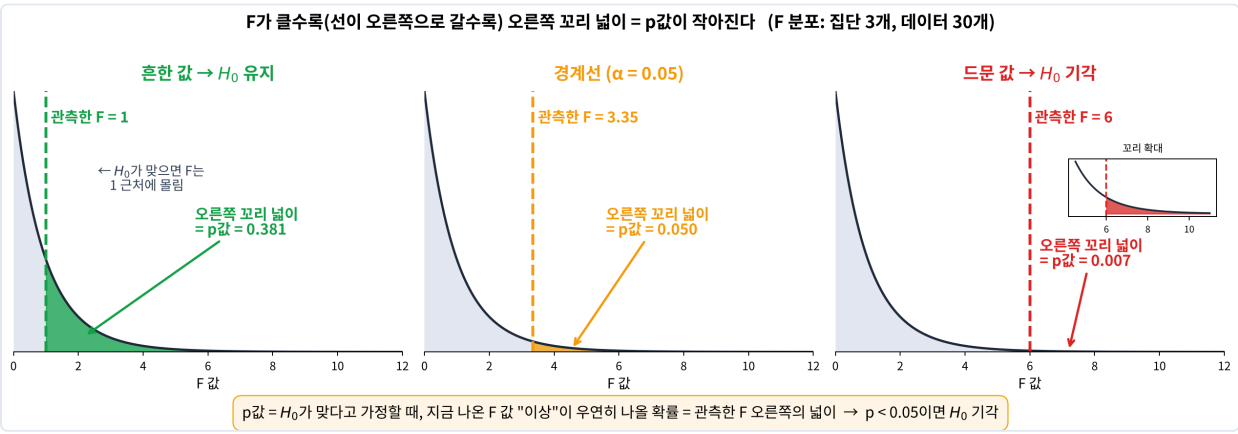
정답 ③

분산분석의 F검정은 모든 집단의 평균이 같다는 귀무가설을 기각할지만 알려 준다. p-value $6.43 \times 10^{-7} < 0.05$이므로 적어도 한 집단의 평균이 다르다고 판단하지만, 어느 쌍이 다른지는 Tukey HSD 같은 사후검정으로 확인해야 한다. 따라서 ③이 틀렸다. 집단이 4개이므로 처리 자유도는 4 − 1 = 3이다. ChickWeight에는 같은 병아리의 반복 측정이 섞여 있으므로 실제 분석에서는 그 구조도 고려한다.

📋 출력 읽는 법

`aov(weight ~ Diet, ...)`	분산분석(에이오브이): 사료(Diet)에 따라 체중(weight)이 다른가
`Df 3 / 574`	집단 수 − 1 = 3 → 사료 **4종** / 데이터 − 집단 수 = 574 → 데이터 **578개**
`Sum Sq`	제곱합: 집단 간 155,863 / 집단 내 2,758,693
`Mean Sq`	제곱평균 = 제곱합 ÷ Df: 51,954 / 4,806
`F value = 10.81`	51,954 ÷ 4,806 = 집단 간 분산이 집단 내 분산의 약 11배
`Pr(>F) = 6.43×10⁻⁷`	p값(피알 그레이터 댄 에프). 0.05보다 훨씬 작음 → 적어도 한 사료는 다름

💡 **쉽게 이해하기** 분산분석은 '**어딘가 다른 반이 있다**'고 알려 주는 화재경보기입니다. **어느 반인지**는 Tukey(투키) 같은 **사후검정**으로 짝마다 확인해야 합니다.



▲ 48회 37번 · F가 클수록 오른쪽 꼬리 넓이(p값)가 작아진다. 이 문제의 F = 10.81은 꼬리 아주 끝이라 p가 0에 가깝다

42. 분산분석에 대한 다음 설명의 참·거짓을 순서대로 바르게 나타낸 것은? 49회 30번

> ㄱ. 이원분산분석은 독립변수(요인)가 하나일 때만 사용하는 분석 방법이다.
> ㄴ. 두 집단만 비교하는 특수한 경우 F통계량은 t통계량의 제곱과 같다.

① 참, 참
② 참, 거짓
③ 거짓, 참
④ 거짓, 거짓

정답 ③
ㄱ은 거짓이다. 이원분산분석은 요인이 두 개이며, 하나이면 일원분산분석이다. ㄴ은 동일한 자료·동일한 가정의 두 독립 집단 평균 비교에서 참이다. 등분산 독립표본 t검정과 두 집단 일원분산분석은 $F=t^2$ 관계를 갖는다. 모든 F검정과 모든 t검정에 적용되는 관계는 아니다. 출제 의도에 따라 거짓, 참인 ③을 고른다.

💡 **쉽게 이해하기** **일원** = 요인 1개(사료만), **이원** = 요인 2개(사료 × 온도). '이'는 숫자 2입니다. 두 집단만 비교할 때는 분산분석 F가 t-검정 t의 제곱과 같아져 두 방법이 같은 결론을 냅니다.

43. 범주형 자료 분석에 대한 설명 중 틀린 것은? 45회 22번

① 적합도 검정은 관찰도수와 기대도수가 얼마나 일치하는지를 검정한다.
② 범주의 특성에 따라 기대도수를 계산해 비교 기준으로 사용할 수 있다.
③ 동질성 검정은 여러 집단의 범주별 분포가 동일한지를 검정한다.
④ 독립성 검정은 서로 다른 요인들이 관찰값에 영향을 주는지를 검정한다.

정답 ④
독립성 검정은 한 모집단에서 관측한 두 범주형 변수가 서로 관련이 있는지(독립인지)를 검정한다. 여러 요인이 관찰값에 영향을 주는지 보는 것은 분산분석이나 회귀분석의 질문이므로 ④가 틀리다.
핵심 개념: 카이제곱 검정은 관찰도수 O와 기대도수 E로 $\chi^2 = \sum \frac{(O-E)^2}{E}$를 계산한다. 적합도 검정은 한 범주형 변수가 가정한 분포를 따르는지, 독립성 검정은 두 범주형 변수가 서로 독립인지, 동질성 검정은 여러 모집단의 범주 분포가 같은지를 본다.
보기 검토: ①은 적합도 검정의 정의, ②는 귀무가설 아래의 비율로 기대도수를 계산해 비교 기준으로 쓰는 절차, ③은 동질성 검정의 정의이다.
학습 포인트: 독립성 검정과 동질성 검정은 계산식이 같지만 표본을 뽑는 방식과 귀무가설의 표현이 다르다. 기대도수가 5보다 작은 칸이 많으면 근사의 정확도가 떨어진다.

💡 **쉽게 이해하기** **독립성 검정** = 범주형 두 개가 '**같이 다니나**?'(성별과 선호 브랜드, 대등한 관계, 표 안에는 사람 수). '여러 요인이 **관찰값(숫자)**에 영향을 주나?'는 요인 → 결과의 방향이 있는 질문이라 분산분석·회귀입니다.

44. 다음 중 교차분석에 대한 설명으로 적절하지 않은 것은? 48회 27번

① 통상적으로 관측 빈도와 기대 빈도의 차이를 측정하는 카이제곱 통계량을 사용한다.
② 독립성 검정은 두 범주형 변수 간에 서로 관련이 있는지, 아니면 통계적으로 서로 독립적인지 판단하기 위해 수행된다.
③ 동질성 검증은 서로 다른 관찰 집단 간에 해당 변수의 분포가 동일한지를 확인하기 위해 수행된다.
④ 교차분석은 두 변수가 연속형 변수인 경우에도 분석이 가능하다.

정답 ④
교차분석은 범주형 변수의 교차표와 빈도에 기초한다. 연속형 값은 필요하다면 범주로 구간화한 뒤 사용할 수 있지만, 연속형인 원자료 그대로를 범주형 교차분석에 적용할 수 있다는 ④는 부적절하다. 독립성 검정은 한 모집단 내 변수의 관련성, 동질성 검정은 집단별 범주 분포의 동일성을 살핀다.

💡 **쉽게 이해하기** 교차분석은 교차표(행 × 열)에 **사람 수를 세어** 넣는 분석입니다. 키·몸무게 같은 연속형은 칸을 만들 수 없으므로 그대로는 못 씁니다. 꼭 쓰려면 '160 미만 / 160 이상'처럼 구간으로 나눠 범주로 바꿔야 합니다.

상관분석 · 산점도

45. 다음 중 상관분석에 대한 설명으로 옳지 않은 것은? 46회 33번

① 상관계수의 통계적 유의성을 검정할 수 있다.
② 상관계수의 절대값이 1에 가까울수록 강한 선형 관계를 의미한다.
③ 상관 분석을 통해 독립 변수에 따른 종속 변수의 값을 예측할 수 있다.
④ 피어슨 상관계수는 연속형 변수에서 두 변수 간의 선형관계를 측정한다.

정답 ③

③은 상관분석 자체를 종속변수의 값을 예측하는 기법으로 설명한다. 상관계수 하나만으로 절편·기울기·단위에 맞는 예측값을 바로 얻을 수 없으므로 이 문항에서는 잘못된 설명이다. 예측식을 만들려면 회귀 등 추가적인 모형이 필요하다.

핵심 개념: 상관분석은 두 변수의 관계 방향과 강도를 요약하고, 회귀분석은 설명변수에 따른 결과변수의 조건부 평균이나 예측값을 모형으로 표현한다. 관계가 있다는 사실과 구체적인 예측식은 구분해야 한다.
보기 검토: ①은 적절한 가정 아래 모상관계수에 대한 검정이 가능하므로 맞다. ②는 절댓값이 1에 가까울수록 선형 관계가 강하다는 설명이다. ④는 피어슨 상관계수의 대표적인 용도를 말한다. 정규성 등의 가정은 상관계수를 계산하는 것과 유의성 검정을 수행하는 것에서 구분해서 살핀다.
학습 포인트: 단순회귀에서는 r과 표준편차를 이용해 기울기를 표현할 수 있지만 그것은 평균·표준편차 정보와 회귀 모형을 함께 사용하는 것이다. 상관이 크다고 원인이나 예측의 정확성이 자동으로 보장되지 않는다. $r = 0$이어도 U자형처럼 강한 비선형 관계가 있을 수 있다.

💡 **쉽게 이해하기** 상관분석은 '둘이 **같이 움직이나**?'까지만 알려줍니다. '공부 1시간 더 하면 몇 점 오르나?' 같은 **예측식**은 회귀분석(lm, 엘엠)이 만듭니다.

46. 독립변수 A, B에 대해 피어슨 상관계수가 0.8이고, p-value가 0.01일 때 옳은 것은? 46회 29번

① A와 B는 양의 선형 관계를 가지고 유의수준 0.05에서 통계적으로 유의하다.
② A의 값이 커짐에 따라 B의 값은 작아지는 경향을 보인다.
③ 유의 수준에 무관하게 상관계수는 통계적으로 유의하다.
④ 두 변수가 비선형 관계를 갖고 있을 가능성이 높다.

정답 ①

$r = 0.8 > 0$이므로 양의 선형 관계가 강하게 관측된다. 상관 검정의 $p = 0.01$은 $\alpha = 0.05$보다 작으므로 '모상관계수가 0'이라는 귀무가설을 기각한다. 제시된 조건을 함께 반영한 ①이 맞다.

핵심 개념: 피어슨 상관계수 r의 부호는 선형 관계의 방향, 절댓값은 선형 관계의 강도를 나타낸다. 상관계수와 그 p값은 서로 다른 질문에 답한다. r은 관측된 관계의 정도, p값은 가정한 귀무가설과 자료의 부합 정도를 나타낸다.
보기 검토: ②는 방향을 음의 관계로 반대로 설명한다. ③은 유의수준에 무관하다고 말해 틀리다. 예를 들어 $\alpha = 0.001$이라면 $p = 0.01$로 귀무가설을 기각하지 못한다. ④의 강한 비선형 관계 가능성을 이 수치만으로 판단할 수는 없다. 양의 선형 관계가 관측되었다는 해석이 가장 직접적이다.
학습 포인트: 제목의 '독립변수 A, B'는 분석에 사용하는 설명변수라는 뜻이며, 확률적으로 서로 독립이라는 뜻이 아니다. 또 $r = 0.8$이라도 A가 B의 원인이라고 확정할 수 없다. 관계를 파악할 때 산점도·이상치·표본 수·검정 가정을 함께 확인한다.

💡 **쉽게 이해하기** 상관계수 r = 0.8은 '관계의 크기', p = 0.01은 '그 관계가 우연인지' 판정입니다. 두 숫자는 다른 질문의 답입니다. p = 0.01은 α = 0.05에서는 유의하지만 α = 0.001이라면 유의하지 않으므로 '유의수준과 무관'하지 않습니다.

47. 다음은 iris 데이터의 네 변수에 대한 상관계수 행렬이다. 해석으로 틀린 것은? 45회 33번

```
> round(cor(iris[, 1:4]), 3)
             Sepal.Length Sepal.Width Petal.Length Petal.Width
Sepal.Length        1.000      -0.118        0.872       0.818
Sepal.Width        -0.118       1.000       -0.428      -0.366
Petal.Length        0.872      -0.428        1.000       0.963
Petal.Width         0.818      -0.366        0.963       1.000
```

① Sepal.Length와 상관이 가장 높은 변수는 Petal.Length이다.

② 상관이 가장 낮은 변수 쌍은 Petal.Length와 Petal.Width이다.

③ Sepal.Length가 길수록 Sepal.Width는 약간 좁아지는 경향이 있다.

④ Petal.Length가 길수록 Petal.Width도 커지는 경향이 있다.

정답 ②

Petal.Length와 Petal.Width의 상관계수는 0.963으로 표에서 가장 강한 양의 상관이다. 가장 낮다고 한 ②가 틀리다. 절댓값이 가장 작은 쌍은 Sepal.Length와 Sepal.Width(−0.118)이다.

핵심 개념: 상관계수의 부호는 방향, 절댓값은 선형 관계의 강도를 나타낸다. 대각선의 1은 자기 자신과의 상관이므로 비교에서 제외한다.
보기 검토: ①은 Sepal.Length 행에서 0.872가 가장 크므로 맞다. ③은 −0.118로 약한 음의 상관이므로 약간 좁아지는 경향으로 읽을 수 있다. ④는 0.963의 강한 양의 상관이다.
학습 포인트: 전체 iris 자료의 Sepal.Length–Sepal.Width 상관은 음수지만 품종별로 나누면 양의 상관이 나타난다(심슨의 역설). 상관계수는 인과관계를 뜻하지 않는다.

📋 출력 읽는 법

`cor(iris[, 1:4])`	iris(아이리스) 1~4열의 상관계수 행렬(피어슨)
`대각선 1.000`	자기 자신과의 상관 → 비교에서 제외
`Petal.Length–Petal.Width 0.963`	표에서 **가장 강한** 양의 상관
`Sepal.Length–Sepal.Width −0.118`	절댓값이 **가장 작음** → 가장 약한 관계
`행렬은 대칭`	위 삼각형과 아래 삼각형이 같은 값

💡 **쉽게 이해하기** '상관이 낮다'는 **절댓값이 작다**는 뜻입니다. −0.118처럼 0에 가까운 값이 가장 약하고, 0.963처럼 1에 가까운 값이 가장 강합니다. Sepal(시펄, 꽃받침), Petal(페털, 꽃잎).

48. 스피어만·피어슨 상관분석에 대한 설명으로 가장 부적절한 것은? 45회 50번

① 스피어만은 범주형 변수의 선형관계를 설명한다.

② 피어슨 상관계수는 연속형 변수 간의 선형 관계를 분석할 때 사용된다.

③ 스피어만 상관계수는 서열형(순위형) 변수 간의 관계를 분석할 때 사용된다.

④ 스피어만 상관계수는 비선형 관계도 어느 정도 설명할 수 있다.

정답 ①

범주형 변수의 선형관계를 설명한다고 한 ①은 부적절하다. 순서가 없는 명목 범주에는 의미 있는 순위를 임의로 부여할 수 없다. 서열형 자료나 순위로 변환한 수치 자료는 스피어만 분석에 활용할 수 있다.

핵심 개념: 피어슨 상관은 수치 자료의 선형 관계를, 스피어만 상관은 순위를 이용한 단조 관계를 평가한다. 스피어만은 원래 값을 순위로 바꾼 뒤 그 순위의 상관을 계산하는 방식으로 이해할 수 있다.
보기 검토: ②③은 대표 용도이다. ④는 증가·감소 방향이 일관된 비선형 단조 관계를 어느 정도 포착한다는 의미로 읽는다. 모든 비선형 관계를 잘 탐지하는 것은 아니며 U자형처럼 비단조 관계는 약한 계수로 나타날 수 있다. 동순위가 있으면 그 처리 규칙을 반영한다. 어느 상관계수도 단독으로 인과관계를 증명하지 않는다.

💡 **쉽게 이해하기** **피어슨 = 값 그대로(직선), 스피어만 = 순위로(한 방향)**. 순위를 매기려면 순서가 있어야 하는데, 혈액형·성별 같은 명목 범주는 1등·2등을 정할 수 없어서 스피어만도 쓸 수 없습니다.

49. 다음 중 변수 간의 단조적 비선형 관계를 파악하기에 적절한 지표는? 47회 37번

① 피어슨 상관계수

② 스피어만 상관계수

③ 코사인 유사도

④ 자카드 계수

정답 ②

스피어만은 순위에 기초한 단조 관계의 지표이다.

스피어만 상관계수는 원래 관측값을 순위로 바꾼 뒤 그 순위 사이의 상관을 계산한다. 한 변수가 증가할 때 다른 변수도 계속 증가하거나 계속 감소하는 단조 관계를 포착하므로 관계가 곡선이어도 순서가 유지된다면 적절하다.
보기 판단: ②가 정답이다. ① 피어슨은 선형관계의 크기와 방향에 초점을 둔다. ③ 코사인 유사도는 벡터의 방향 유사성, ④ 자카드는 집합의 교집합/합집합 비율이다. U자 관계처럼 증가·감소가 함께 나타나는 비단조 관계에서는 스피어만이 0에 가까워도 관계가 없다고 결론 내릴 수 없다.

💡 **쉽게 이해하기** **단조(單調)** = 한 방향으로만 감. 계속 오르거나 계속 내리기만 하면 곡선이어도 됩니다. 스피어만(ρ, 로)은 값을 등수로 바꾸므로 곡선이어도 등수 순서가 같으면 1에 가깝게 나옵니다.

50. 두 연속형 변수 사이의 관계를 한눈에 파악하기에 가장 적절한 그래프는? 49회 21번

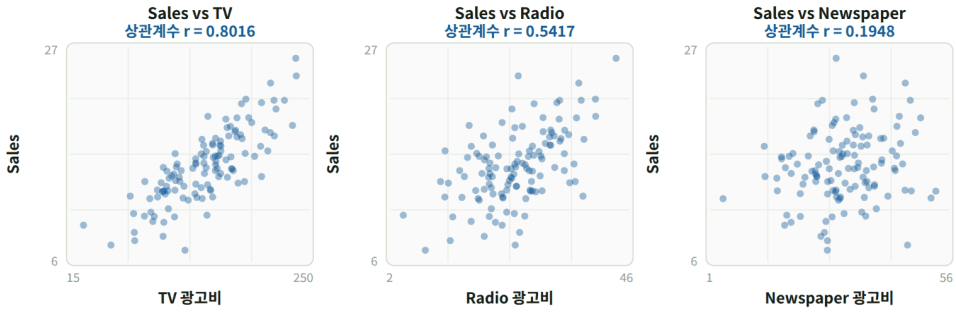
① 막대그래프
② 산점도
③ 원그래프
④ 상자그림

> **정답 ②**
> 산점도는 두 연속형 변수를 가로축과 세로축에 놓고 점으로 나타내어 관계의 방향과 강도, 선형성, 이상값을 한눈에 볼 수 있다.
> 막대그래프와 원그래프는 범주형 자료의 빈도·비율을, 상자그림은 한 변수의 분포를 요약하는 데 쓴다.

💡 **쉽게 이해하기** 두 숫자 변수 → 가로축·세로축에 점을 찍는 **산점도**(스캐터 플롯). 막대·원그래프는 범주의 개수·비율, 상자그림은 **한 변수**의 분포를 봅니다.

51. 아래 산점도를 해석한 내용 중 적절하지 않은 것은? 50회 46번

어느 회사가 여러 지역에서 집행한 매체별 광고비(TV · Radio · Newspaper)와 매출액(Sales)의 관계를 산점도로 나타내고 각 상관계수를 함께 표시한 결과는 다음과 같다.



점 하나가 관측치 하나(총 120건)이며, 축 양끝의 숫자는 각 변수의 최솟값과 최댓값이다.

① TV 광고비와 Sales 사이에는 양의 상관관계가 나타난다.
② TV 광고비와 Sales 사이에는 비교적 강한 선형적 관련성이 존재한다.
③ TV 광고비가 높은 관측치에서 Sales도 높게 나타나는 경향이 있다.
④ TV 광고비를 늘리면 Sales가 증가한다는 것을 알 수 있다.

> **정답 ④**
> TV와 Sales의 상관계수는 0.8016으로 비교적 강한 양의 관련성을 보인다. 관측 산점도만으로 광고비 증가가 매출 증가의 원인이라고 확정할 수는 없다. 인과 추론에는 추가 설계와 분석이 필요하다.

💡 **쉽게 이해하기** 아이스크림 판매와 물놀이 사고는 상관이 높지만 원인은 **더운 날씨**입니다. 산점도와 상관계수(0.8)는 '**같이 움직인다**'까지만 말해 줄 뿐, '늘리면 증가한다'는 **인과**는 증명하지 못합니다.

빠른 정답표

38	①	39	④	40	③	41	③	42	③	43	④	44	④	45	③	46	①	47	②
48	①	49	②	50	②	51	④												

자주 나오는 함정

- 출력의 **자유도**로 표본 수 역산 (일표본 n = df + 1) · **α가 0.05인지 0.01인지** 확인 · 차이(A − B)의 **부호** 확인
- ANOVA는 기각 후 **사후검정** · 교차분석은 **범주형**, 관계 유무만
- 상관 ≠ 인과 · 예측은 회귀분석 · 단조 비선형 → **스피어만** · 두 연속형 관계 → 산점도

6단원 회귀분석 ① 개요~결과 해석

회귀 가정 · 잔차

52. 선형회귀분석의 가정에 대한 설명 중 틀린 것은? 45회 27번

① 정규성: 잔차의 분포가 정규분포를 따른다.

② 독립성: 독립변수 간에는 서로 관련이 없다.

③ 등분산성: 모든 독립변수 잔차 분포에는 동일한 분산을 가진다.

④ 선형성: 독립변수와 종속변수 간에는 선형관계가 있다.

정답 ②

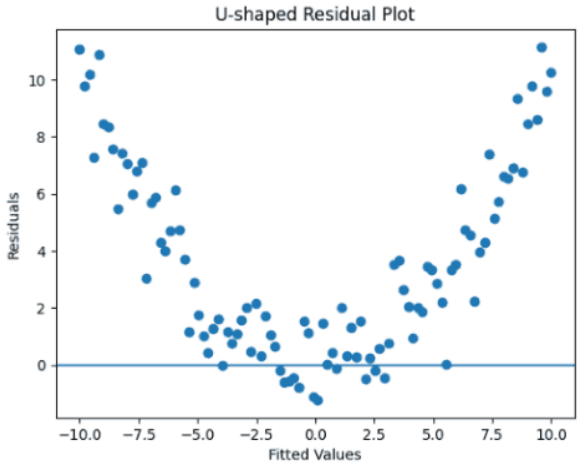
②는 독립성의 대상을 독립변수 사이로 잘못 설명하므로 틀리다. 여러 설명변수가 관련되어 있어도 완전한 선형 종속 등이 없으면 모형을 적합할 수 있다.

핵심 개념: 회귀의 독립성은 보통 관측값 또는 오차항 사이의 독립성을 뜻한다. 독립변수끼리 반드시 무관해야 한다는 가정이 아니다. 설명변수들이 강하게 관련되면 다중공선성 문제가 될 수 있지만 이것과 오차 독립성은 다르다.

보기 보완: ①의 정규성은 정확한 소표본 추론에서 오차항의 정규성을 가정하고 잔차로 진단한다는 취지이다. ③ 등분산성은 설명변수 값에 관계없이 조건부 오차분산이 일정하다는 뜻이다. ④는 현재 단순한 선형 관계 설명으로 읽으며, 일반 선형회귀는 모수에 선형이라는 더 넓은 의미를 가진다. 오차와 잔차도 개념상 구분한다.

💡 **쉽게 이해하기** 회귀의 **독립성**은 **'잔차(오차)끼리** 서로 영향을 주지 않는다'는 뜻입니다. 오늘의 예측 실수가 내일 실수에 영향을 주면 안 된다는 것이죠. 독립변수끼리 관련이 높은 것은 별개의 문제 (**다중공선성**)입니다.

53. 회귀분석에 따른 잔차도가 아래 그림과 같을 때, 해당 분석의 해석으로 옳은 것은? 48회 29번



① 잔차가 0을 중심으로 고르게 분포하므로 회귀모형이 적합하다.

② 릿지, 라쏘 모델을 사용하여 해당 분석 결과의 과적합 문제를 해결해야 한다.

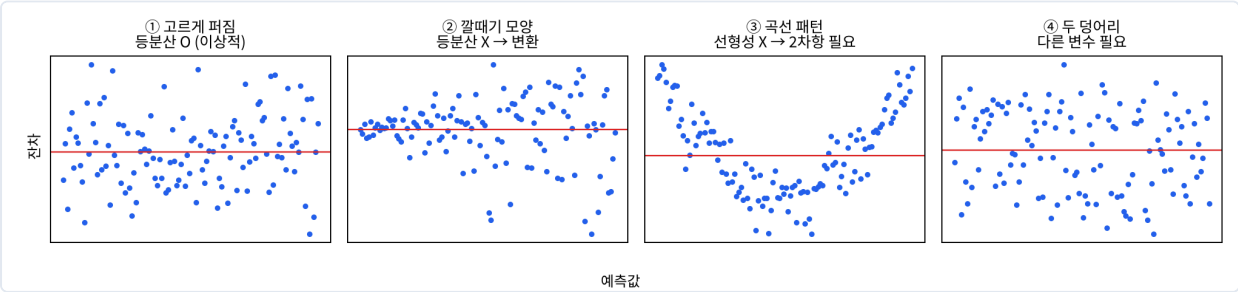
③ 독립변수와 종속변수 간 비선형성이 확인되어 비선형 모델을 적용해야 한다.

④ 해당 잔차도 그래프는 변수에 이상치(outlier)가 많아서 발생한 패턴이다

정답 ③

잔차가 U자형 등의 체계적인 곡선 패턴을 보이면 단순한 선형 관계를 충분히 표현하지 못한 가능성을 검토한다. 다항항이나 변수 변환 등 관계 형태를 보완하는 접근이 적절하다. 릿지·라쏘는 계수 규제를 통한 과적합 완화 기법이며 곡선 관계 문제를 자동으로 해결하지 않는다. 그림만으로 이상치가 많다고 단정할 수는 없다.

💡 **쉽게 이해하기** 잔차도(레지듀얼 플롯)가 **U자**로 휘었다 = 직선으로 그은 회귀선이 실제 곡선 관계를 못 따라감. 해결책은 직선을 곡선으로 바꾸는 것(x^2 항 추가, 비선형 모델)입니다. 릿지·라쏘는 과적합 해결책이라 상관없습니다.



▲ 48회 29번 · 잔차도 4가지: ① 고르게 흩어짐(좋음) ② 깔때기(등분산 위반) ③ U자(선형성 위반 → 이 문제) ④ 정규성 확인

54. 다중회귀분석에서 잔차(residual)에 관한 설명으로 틀린 것은? 50회 36번

① 잔차의 평균은 0이다.
② 잔차는 정규분포를 따른다고 가정한다.
③ 독립변수와 잔차는 서로 상관되지 않아야 한다.
④ 종속변수와 잔차는 서로 상관되지 않아야 한다.

정답 ④
절편을 포함한 일반적인 최소제곱회귀에서는 잔차의 평균이 0이고, 잔차는 설명변수 및 적합값과 직교한다. 그러나 y = ŷ + e이므로 종속변수와 잔차가 무상관이어야 한다는 조건은 없다. 따라서 ④가 틀리다. 정규성은 엄밀히 잔차 자체가 아니라 오차항에 대한 가정이다. 종속변수와 잔차의 표본 상관계수는 절편 포함 최소제곱회귀에서 두 변수의 분산이 양수일 때 $\sqrt{(1-R^2)}$이다.

💡 **쉽게 이해하기** y(실제값) = ŷ(예측값) + e(잔차)이므로 y 안에는 잔차가 **들어 있습니다**. 그래서 y와 잔차는 상관이 있을 수밖에 없습니다. 상관이 없어야 하는 것은 **독립변수(x)와 잔차**입니다.

회귀 결과 해석 · 결정계수

55. 콜레스테롤에 대한 단순선형회귀의 절편 추정값이 96.04, x의 회귀계수 추정값이 1.97이다. 적합한 회귀식은? 45회 26번

① $\hat{y} = 1.97 + 96.04x$
② $\hat{y} = 96.04 - 1.97x$
③ $\hat{y} = -96.04 + 1.97x$
④ $\hat{y} = 96.04 + 1.97x$

정답 ④
절편 96.04와 기울기 1.97을 대입하면 $\hat{y} = 96.04 + 1.97x$이므로 ④이다. x가 1 증가할 때 예측 반응값은 1.97 증가한다. 확인용으로 $x = 10$이면 예측값은 $96.04 + 19.70 = 115.74$이다.
핵심 개념: 단순선형회귀의 적합식은 $\hat{y} = b_0 + b_1 x$이다. b_0는 절편, b_1은 기울기이며 추정값의 부호와 위치를 그대로 반영한다.
보기 검토: ①은 절편과 기울기의 위치를 바꾸었고, ②는 양의 기울기를 음수로, ③은 양의 절편을 음수로 바꾸었다. 절편은 $x = 0$일 때의 예측값이나, 0이 자료 범위 밖이면 실질적 해석에 주의한다. x의 단위와 정확한 원래 출력이 확인되지 않았으므로 임의 단위를 추가하지 않는다. 예측식을 안다고 계수의 유의성까지 알 수 있는 것은 아니다.

💡 **쉽게 이해하기** 회귀식은 중학교 일차함수 y = **b** + **a**x와 같습니다. 절편(Intercept, 인터셉트) 96.04가 앞, 기울기(계수) 1.97이 x 앞에 붙습니다. 부호를 그대로 옮기면 ŷ(와이햇) = 96.04 + 1.97x.

56. 다음 회귀분석 결과에서 결정계수 값은? 46회 25번

SSE(오차제곱합) = 200
SSR(회귀제곱합) = 300

① 0.33
② 0.4
③ 0.6
④ 0.67

정답 ③
$SST = 300 + 200 = 500$이고, $R^2 = 300/500 = 0.6$이다. 또는 $1 - 200/500 = 0.6$으로 계산할 수 있다. 따라서 ③이다.
핵심 개념: 절편을 포함한 일반적인 최소제곱 회귀에서는 전체 변동 SST를 회귀가 설명한 변동 SSR과 잔차 변동 SSE로 나누며 $SST = SSR + SSE$이다. 결정계수는 $R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$이다.
자료 확인: 그림에서 SSE는 오차제곱합 200, SSR은 회귀제곱합 300이라고 표시되어 있다. 여기서는 기호보다 그림의 한글 정의를 기준으로 해석한다. 문헌에 따라 SSR을 잔차제곱합의 기호로 사용하는 경우도 있으므로 이름을 확인해야 한다.
보기 검토: ②의 0.4는 잔차 변동이 전체 변동에서 차지하는 비율이다. ①의 0.33과 ④의 0.67은 적절한 분자·분모로 계산한 결정계수가 아니다. 회귀제곱합을 잔차제곱합만으로 나누는 $300/200$도 결정계수가 아니다.
학습 포인트: 0.6은 모형이 이 표본의 종속변수 변동 중 60%를 설명한다는 뜻이다. 예측의 60%가 정답이라는 의미도, 인과관계가 60% 증명됐다는 의미도 아니다. 훈련 자료에서 높은 R^2가 새로운 자료의 좋은 예측 성능을 보장하지도 않는다.

💡 **쉽게 이해하기** **R²**(알 제곱, 결정계수) = 설명한 부분 ÷ 전체 = SSR ÷ (SSR + SSE) = 300 ÷ 500 = 0.6. '평균으로 찍을 때의 오차 중 60%를 회귀식이 줄였다'는 뜻입니다. SSR = Sum of Squares Regression(회귀), SSE = Sum of Squares Error(오차).

57. 단순회귀모형에서 SSE가 20이고 샘플이 10이라면 MSE는 얼마인가? 47회 31번

① 2
② 2.22
③ 2.5
④ 30

> **정답 ③**
> 절편을 포함하는 단순회귀의 잔차 자유도는 $n-2=8$이다. $MSE=20/8=2.5$이다. 일반적인 예측오차 평균 SSE/n과 구별한다.
> 회귀분석 분산분석표의 MSE는 잔차제곱합을 잔차 자유도로 나눈 값이다. 절편과 기울기 하나를 추정하는 단순회귀에서는 모수 2개를 추정하므로 잔차 자유도가 n−2이다. 여기서는 $n=10$이므로 자유도 $=8$, $MSE=\frac{SSE}{n-2}=\frac{20}{8}=2.5$로 ③이다.
> 오답 판단: ①의 2는 $20/10$으로 관측 개수만 나눈 값이다. ②의 약 2.22는 $20/9$로 자유도 하나만 차감한 값이다. ④의 30은 제시된 공식과 맞지 않는다. 예측 성능 지표로 쓰는 평균제곱오차 SSE/n과 회귀 분산분석표의 잔차 평균제곱을 문맥에 따라 구별해야 한다.

💡 **쉽게 이해하기** MSE(엠에스이, Mean Squared Error) = SSE ÷ **잔차 자유도**. 단순회귀는 절편과 기울기 2개를 추정했으므로 잔차 자유도 = n − **2** = 8. 20 ÷ 8 = 2.5. n(10)으로 나누면 2가 되는 함정입니다.

58. 다음 중 회귀분석 모형 적합성을 판단하는 설명으로 적절하지 않은 것은? 48회 24번

① 회귀모형의 적합성을 판단하기 위해 잔차 산점도를 확인하며, 잔차가 특정 패턴 없이 무작위로 분포해야 모형의 가정이 충족된 것으로 본다.
② 다중회귀분석에서는 독립변수의 수가 늘어나면 결정계수가 무의미하게 높아지는 단점을 보완하기 위해 수정된 결정계수를 평가지표로 활용하기도 한다.
③ 회귀계수의 유의성은 t-검정으로 판단 가능하며, 해당 독립변수가 종속변수를 설명하는데 유의미한지 확인 가능하다.
④ 설명변수 간 상관계수를 확인하면 해당 회귀분석 모형의 적합성을 판단할 수 있다.

> **정답 ④**
> 설명변수들 사이의 상관계수는 주로 다중공선성의 단서를 살핀다. 이것만으로 모형이 종속변수를 잘 설명하거나 가정을 충족한다고 판단할 수 없다. 잔차 패턴, R^2·수정 R^2, 전체 모형의 F-검정, 회귀계수의 t-검정 등 목적별 지표를 구분하여 확인해야 한다.

💡 **쉽게 이해하기** 모형이 '잘 맞는지'는 **F(모형 전체), t(각 변수), R^2(설명력), 잔차도(가정)**로 봅니다. 설명변수끼리의 상관은 '**변수들이 서로 겹치는지**(다중공선성)'를 보는 것이라 모형 적합성 판단 도구가 아닙니다.

59. 회귀 모형에 대한 설명으로 옳지 않은 것은? 49회 24번

① 회귀계수는 일반적으로 최소제곱법(OLS)으로 추정한다.
② 모형의 설명력은 −1에서 1 사이의 값을 갖는 결정계수(R^2)로 평가한다.
③ 잔차 분석을 통해 정규성·등분산성 등 모형의 가정을 점검한다.
④ 결정계수(R^2)가 1에 가까울수록 모형의 설명력이 높다.

> **정답 ②**
> ②가 틀리다. 절편을 포함한 일반적인 최소제곱회귀를 학습 자료에서 평가하면 결정계수 R^2는 0~1이다. −1~1은 상관계수의 범위이다. 다만 테스트 자료에서 계산한 R^2나 절편 없는 모형 등에서는 음수가 나올 수 있으므로 R^2가 항상 0~1이라고 단정하지 않는다. 잔차 분석은 오차항의 정규성·등분산성 등 가정을 점검하는 데 활용한다.

💡 **쉽게 이해하기** 범위 외우기: **상관계수 r: −1~1**(방향이 있음), **결정계수 R^2: 0~1**(설명 비율, 몇 %). '퍼센트'에 음수는 없다고 생각하면 됩니다.

60. 다음은 swiss 데이터에서 Fertility를 종속변수로, 나머지 5개 변수를 독립변수로 한 회귀분석 결과이다. 해석으로 옳지 않은 것은?

45회 34번

```
> summary(lm(Fertility ~ ., data = swiss))
Coefficients:
                 Estimate Std. Error t value Pr(>|t|)
(Intercept)      66.91518   10.70604   6.250 1.91e-07 ***
Agriculture      -0.17211    0.07030  -2.448  0.01873 *
Examination      -0.25801    0.25388  -1.016  0.31546
Education        -0.87094    0.18303  -4.758 2.43e-05 ***
Catholic          0.10412    0.03526   2.953  0.00519 **
Infant.Mortality  1.07705    0.38172   2.822  0.00734 **
Residual standard error: 7.165 on 41 degrees of freedom
Multiple R-squared:  0.7067,  Adjusted R-squared:  0.671
F-statistic: 19.76 on 5 and 41 DF,  p-value: 5.594e-10
```

① 이 모형은 Fertility 변동의 약 70.67%를 설명한다.
② 수정 결정계수(Adjusted R-squared)는 67.1%이다.
③ Education은 유의수준 5%에서 유의하다.
④ Education이 Fertility 변동의 원인이라고 단정할 수 있다.

정답 ④

관찰자료에 대한 회귀 결과는 변수 사이의 통계적 연관을 보여 줄 뿐이며 누락 변수·교란 요인·역인과 가능성을 배제하지 못한다. 유의하다는 이유로 원인이라고 단정한 ④가 틀리다.

핵심 개념: 결정계수 R^2는 표본에서 종속변수 변동 중 모형이 설명하는 비율이고, 수정 R^2는 설명변수 수를 반영해 조정한 값이다. 각 계수의 Pr(>|t|)는 그 계수가 0이라는 귀무가설에 대한 p값이다.

보기 검토: ①은 Multiple R-squared 0.7067, ②는 Adjusted R-squared 0.671이다. ③은 Education의 p값 2.43×10^{-5}이 0.05보다 작으므로 맞다. Education 계수 −0.871은 다른 변수가 같을 때 Education이 1 높으면 Fertility가 평균 0.871 낮다는 뜻이다.

학습 포인트: 수정 $R^2 = 1 - (1 - R^2)\dfrac{n-1}{n-p-1}$이다. 여기서 $n = 47, p = 5$이므로 $1 - 0.2933 \times 46/41 \approx 0.671$이다.

📋 출력 읽는 법

`lm(Fertility ~ ., data = swiss)`	swiss(스위스) 데이터에서 Fertility(출산율)를 나머지 모든 변수(.)로 설명
`Estimate`	회귀계수. Education −0.871 → 교육 1 증가 시 출산율 평균 0.871 감소
`Pr(>|t|)`, 별표	Education 2.43e-05 *** → 유의. Examination 0.315 → 유의하지 않음
`41 degrees of freedom`	잔차 자유도 = n − 5 − 1 → n = **47**
`Multiple R-squared 0.7067`	출산율 변동의 **70.67%** 설명
`Adjusted R-squared 0.671`	변수 수만큼 벌점을 준 설명력 67.1%
`F-statistic 19.76, p 5.594e-10`	모형 **전체**가 유의

💡 **쉽게 이해하기** '유의하다' = **우연이 아닌 관계가 있다**까지입니다. 회귀도 '교육이 높은 지역은 출산율이 낮다'는 **연관**을 보여 줄 뿐, 교육이 **원인**이라고 단정할 수 없습니다(소득·도시화 같은 다른 요인이 숨어 있을 수 있음).

61. mpg를 종속변수, hp·drat·wt를 설명변수로 회귀분석했다. drat의 p값은 0.05보다 크다. 다음 중 부적절한 것은?

47회 35번

① mpg를 hp·drat·wt로 설명하는 다중회귀모형이다.
② 현재 모형에서 drat 계수는 유의수준 5%에서 유의하지 않다.
③ drat을 제외할 때 절편·hp·wt의 기존 계수를 그대로 가져와 새 회귀식으로 확정한다.
④ drat을 제외한 모형을 사용하려면 다시 적합하고 새 계수를 확인해야 한다.

정답 ③

drat의 p값이 0.05보다 크다는 사실과 그 변수를 제외한 새 모형의 계수는 별개이다. 변수 삭제 후 다시 적합해야 한다. 기존 절편·hp·wt 계수를 그대로 사용하는 ③은 틀리다.

p값이 0.05보다 크면 현재 모형과 가정 아래에서 drat의 계수가 0과 다르다는 근거가 유의수준 5%에 충분하지 않다는 뜻이다. drat이 현실적으로 아무 영향도 없다는 증명이나 반드시 삭제하라는 명령은 아니다. 변수 선정은 목적·도메인·검증 성능 등을 함께 고려한다.

보기 판단: ①은 변수의 역할, ②는 현재 모형의 검정 판단, ④는 새 모형의 적합 절차로 옳다. ③은 변수 제거 후에도 기존 계수를 그대로 쓸 수 있다고 하여 틀리다. 최소제곱법은 포함된 변수 전체를 함께 사용해 계수를 추정하므로 drat을 빼면 hp·wt와 절편의 최적 값도 달라질 수 있다. 아래 재계산 예시에서 wt 계수와 절편이 실제로 바뀐다는 점을 확인한다.

검증 예시: R의 mtcars 32개 관측값에 절편을 포함한 최소제곱법 적용. mpg~hp+drat+wt의 계수는 절편 29.394934, hp −0.032230, drat 1.615049, wt −3.227954이며 drat p값 ≈0.198755이다. drat 삭제 후 mpg~hp+wt를 재적합하면 절편 37.227270, hp −0.031773, wt −3.877831로 바뀐다.

💡 **쉽게 이해하기** 회귀계수는 **함께 들어간 변수들이 서로 나눠 가진 몫**입니다. 한 변수(drat)를 빼면 그 몫이 다른 변수에 재분배되어 남은 계수도 바뀝니다. 그래서 반드시 **다시 적합(재분석)**해야 합니다. 예: wt −3.23 → −3.88, 절편 29.39 → 37.23.

62. 다음은 신용카드 부채(Balance)를 종속변수로 하고 수입(Income)과 학생 여부(Student: 학생 = Yes)를 독립변수로 한 다중회귀분석 결과이다. 해석으로 옳지 않은 것은?

47회 39번

분석: lm(Balance ~ Income + Student, data = Credit)
(Intercept): Estimate 211.1430, Std. Error 32.4572, t value 6.505, Pr(>|t|) 2.34×10^{-10}
Income: Estimate 5.9843, Std. Error 0.5566, t value 10.751, Pr(>|t|) 7.82×10^{-24}
StudentYes: Estimate 382.6705, Std. Error 65.3108, t value 5.859, Pr(>|t|) 9.78×10^{-9}
R^2 = 0.2775, Adjusted R^2 = 0.2738

① 다른 변수가 같을 때 Income이 1 증가하면 Balance는 평균적으로 약 5.98 증가한다.
② 다른 변수가 같을 때 학생은 비학생에 비해 Balance가 평균적으로 약 382.67 높다.
③ Student 변수는 더미변수로 처리되어 기준 범주(비학생) 대비 효과를 나타낸다.
④ StudentYes의 회귀계수가 Income보다 크므로 Student가 Balance에 가장 중요한 변수이다.

정답 ④
회귀계수의 크기는 변수의 측정 단위에 따라 달라지므로, 계수가 크다는 이유만으로 더 중요한 변수라고 판단한 ④가 틀렸다.

Income 계수 5.9843은 다른 변수가 같을 때 Income 1단위(이 데이터에서는 1,000달러) 증가에 따른 Balance의 평균 증가량이고, StudentYes 계수 382.6705는 같은 Income에서 학생과 비학생의 평균 차이이다. Student는 Yes/No 범주형 변수이므로 비학생을 기준으로 한 더미변수로 들어간다.
보기 판단: ①②③은 출력과 일치한다. ④는 단위가 다른 계수를 직접 비교한 오류이다. 상대적 중요도는 표준화 계수, t값, 모형 비교 등으로 판단하며, 이 출력에서는 오히려 Income의 t값(10.751)이 StudentYes(5.859)보다 크다.

📋 출력 읽는 법

`lm(Balance ~ Income + Student, data = Credit)`	Credit(크레딧) 표에서 부채를 수입·학생 여부로 설명
`Income 5.9843`	수입 1단위(천 달러) 증가 → 부채 평균 5.98 증가
`StudentYes 382.6705`	**더미변수**(학생 = 1, 비학생 = 0) → 학생은 비학생보다 382.67 많음
`Pr(>|t|)`	세 계수 모두 매우 작음 → 모두 유의
`t value`	Income 10.751 > StudentYes 5.859
`R² 0.2775 / Adj. 0.2738`	부채 변동의 약 27.8% 설명

💡 **쉽게 이해하기** 회귀계수는 '**1단위당** 효과'라서 단위가 다르면 크기를 비교할 수 없습니다. 수입을 달러로 바꾸면 계수가 0.006이 되지만 영향력은 그대로입니다. 중요도는 **t 값이나 표준화 계수**로 봅니다(여기서는 오히려 Income의 t가 더 큼).

63. 프로야구 선수의 연봉(단위: 백만 원)을 종속변수로 하고 타율, 홈런, 경력 등을 설명변수로 한 다중회귀분석 결과의 해석으로 적절하지 않은 것은? 48회 33번

주요 결과
타율: p-value ≈ 4.8×10^{-5}
홈런: 회귀계수 = 8.94, p-value ≈ 4.1×10^{-6}
경력: p-value = 0.2052
결정계수(R^2) = 0.563

① 타율과 홈런은 유의수준 0.05에서 연봉에 유의한 영향을 미친다.
② 다른 변수가 같을 때 홈런이 1개 증가하면 연봉은 평균 약 894만 원 증가한다.
③ 경력은 유의수준 0.05에서 유의하지 않다.
④ 결정계수가 0.563이므로 이 모형은 연봉 변동의 약 75%를 설명한다.

정답 ④
결정계수 0.563은 표본에서 연봉 변동의 약 56.3%를 모형이 설명한다는 뜻이므로 75%라고 한 ④가 틀렸다. 타율($p \approx 4.8\times10^{-5}$)과 홈런($p \approx 4.1\times10^{-6}$)은 0.05보다 작아 유의하고, 경력($p = 0.2052$)은 유의하지 않다. 홈런 계수 8.94의 단위가 백만 원이므로 8.94백만 원, 즉 약 894만 원이다. 다중회귀 계수는 다른 설명변수를 고정했을 때의 평균 변화로 해석한다.

📋 출력 읽는 법

타율 $p \approx 4.8\times10^{-5}$	0.05보다 작음 → 유의
홈런 계수 8.94, $p \approx 4.1\times10^{-6}$	유의. 연봉 단위가 **백만 원** → 8.94백만 원 = **894만 원**
경력 $p = 0.2052$	0.05보다 큼 → 유의하지 않음
$R^2 = 0.563$	연봉 변동의 **56.3%** 설명

💡 **쉽게 이해하기** R^2 0.563은 그대로 **56.3%**로 읽으면 됩니다. 75%처럼 다른 숫자를 들이미는 함정입니다. 또 계수를 읽을 때는 **단위**(백만 원)를 꼭 붙여서 894만 원으로 바꿔 읽습니다.

64. 아래 회귀분석 결과에 대한 해석 중 틀린 것은? 50회 35번

어느 카드사 고객 자료를 이용하여 카드 잔고(balance)를 종속변수로, 수입(income)과 학생 여부(student)를 설명변수로 하는 선형회귀분석을 수행한 R 출력 결과는 다음과 같다.

```
Call:
lm(formula = balance ~ income + student, data = credit)

Residuals:
Min 1Q Median 3Q Max
-762.37 -341.75 -45.28 323.63 817.19

Coefficients:
Estimate Std. Error t value Pr(>|t|)
(Intercept) 211.14280 74.53120 2.833 0.006435 **
income 0.00670 0.00230 2.913 0.005164 **
studentYes 382.67050 105.68410 3.621 0.000640 ***
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 391.8 on 55 degrees of freedom
Multiple R-squared: 0.2775, Adjusted R-squared: 0.2512
F-statistic: 10.56 on 2 and 55 DF, p-value: 0.0001312
```

① income과 studentYes의 회귀계수는 모두 유의수준 5%에서 통계적으로 유의하다.

② 다른 조건이 같다면 학생은 학생이 아닌 사람보다 잔고가 평균 약 382.7 높다.

③ 수입이 잔고를 증가시키는 정도는 학생인지 아닌지에 따라 달라진다.

④ 이 모형이 잔고의 변동을 설명하는 정도는 약 27.75%이다.

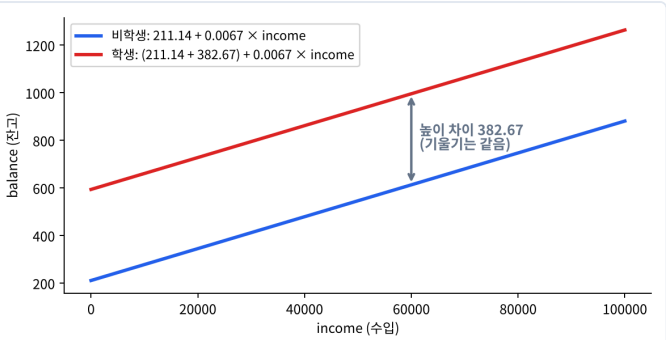
정답 ③

모형에 income×student 상호작용항이 없으므로 수입의 기울기 0.00670은 학생 여부와 관계없이 동일하다. 학생은 절편이 382.67 높을 뿐이다. 두 계수 모두 p < 0.05이며 $R^2 = 0.2775$이다.

📋 출력 읽는 법

`Call: lm(balance ~ income + student)`	잔고를 수입·학생 여부로 설명 (교호작용 항 **없음**)
`Residuals`	잔차의 최솟값·사분위수·최댓값(시험에서는 거의 안 물음)
`income 0.00670 (p 0.0052, **)`	유의. 수입의 기울기는 학생·비학생 **똑같이** 0.0067
`studentYes 382.67 (p 0.0006, ***)`	유의. 학생은 비학생보다 382.67 높음 (절편만 차이)
`Signif. codes`	*** <0.001, ** <0.01, * <0.05 → p값 구간 표시
`391.8 on 55 degrees of freedom`	잔차 자유도 55 = n − 2 − 1 → n = **58**
`R² 0.2775 / Adj. 0.2512`	설명력 27.75% / 벌점 반영
`F 10.56 on 2 and 55 DF, p 0.00013`	모형 전체 유의

💡 **쉽게 이해하기** 더미변수만 넣은 모형은 학생·비학생 두 직선이 **평행**합니다. 학생 여부는 선의 **높이**만 바꾸고 **기울기**(수입의 효과)는 바꾸지 않습니다. 기울기까지 달라진다고 말하려면 income * student 같은 **교호작용 항**이 있어야 합니다.



▲ 50회 35번 · 교호작용 항이 없으면 두 직선은 평행: 기울기(수입 효과)는 같고 높이만 382.67 차이

65. 아래 분산분석표에 대한 설명 중 틀린 것은? 50회 41번

단순선형회귀분석을 수행한 결과 얻은 분산분석표(ANOVA)의 일부는 다음과 같다. 괄호는 값이 생략된 칸이다.

요인	제곱합	자유도	제곱평균	F value	Pr(>F)
회귀	120	1	( )	60	1.28e-06
잔차	( )	( )	( )		
총합	150	16			

① 이 회귀모형은 유의수준 5%에서 통계적으로 유의하다.

② 오차 분산의 불편추정량은 0.2이다.

③ 이 모형의 결정계수는 $\frac{4}{5}$ 이다.

④ 분석에 사용된 데이터의 크기는 17개이다.

정답 ②

잔차제곱합 $= 150 - 120 = 30$, 잔차 자유도 $= 16 - 1 = 15$이므로 오차분산의 불편추정량 $MSE = 30/15 = 2$이다(0.2가 아니다). $R^2 = 120/150 = 4/5$, $n = 16 + 1 = 17$, $F = 120/2 = 60$이다.

📋 출력 읽는 법

SSE (빈칸)	SST − SSR = 150 − 120 = **30**
잔차 자유도 (빈칸)	총 16 − 회귀 1 = **15**
MSR (빈칸)	120 ÷ 1 = 120
MSE (빈칸)	30 ÷ 15 = **2** ← 오차 분산의 불편추정량
F 확인	120 ÷ 2 = 60 ✔
R^2	120 ÷ 150 = 4/5
데이터 수	총 자유도 16 = n − 1 → n = 17

💡 **쉽게 이해하기** 빈칸 표는 공식 4개로 채웁니다: ① 총 = 회귀 + 잔차 (제곱합·자유도 모두), ② 제곱평균 = 제곱합 ÷ 자유도, ③ F = MSR ÷ MSE, ④ R^2 = SSR ÷ SST. **불편추정량** = 치우침 없이 추정한 값 = MSE입니다.

빠른 정답표

52	②	53	③	54	④	55	④	56	③	57	③	58	④	59	②	60	④	61	③
62	④	63	④	64	③	65	②												

자주 나오는 함정

- F → 모형 전체, t → 각 회귀계수, **R^2 = SSR/SST** (0~1)
- 잔차 df = n − k − 1 · MSE = SSE ÷ 잔차 df
- U자 잔차도 → 비선형 · 잔차는 **독립변수**와 무상관
- 변수를 빼면 **다시 분석** · 계수 크기로 변수 중요도 비교 불가 · 회귀로 인과 단정 불가

7단원 회귀분석 ② 다중공선성·변수 선택

다중공선성 · 변수 선택

66. 다중회귀분석에서 다중공선성을 해결할 수 있는 방안으로 적절하지 않은 것은? 47회 32번

① 라쏘 회귀 (Lasso)
② 릿지 회귀 (Ridge)
③ 엘라스틱넷 회귀 (Elastic Net)
④ 로지스틱 회귀 (Logistic)

정답 ④

라쏘·릿지·엘라스틱넷은 규제 방법이다. 로지스틱 회귀로 바꾸는 것만으로 다중공선성이 해결되지는 않는다.

규제 회귀는 계수 크기에 벌점을 부여하여 높은 설명변수 상관으로 인한 불안정성을 완화한다. 릿지는 L2 벌점으로 계수를 축소하고, 라쏘는 L1 벌점으로 일부 계수를 0으로 만들 수 있다. 엘라스틱넷은 L1·L2 벌점을 결합한다.
보기 판단: ①②③은 공선성의 영향을 완화하는 방법으로 사용할 수 있다. ④ 로지스틱 회귀는 범주형 결과의 확률을 모델링하는 방법이며 설명변수 사이의 상관을 자동으로 제거하지 않는다. 규제 없는 로지스틱 회귀에도 공선성 문제가 생길 수 있다. 라쏘 역시 강하게 상관된 변수 중 선택이 불안정할 수 있어 규제를 만능 해결책으로 단정하지 않는다.

💡 **쉽게 이해하기** 다중공선성 = 독립변수끼리 너무 닮아서 '누가 얼마나 힘을 썼는지' 못 나누는 문제. 계수에 **벌점**을 줘서 누르는 라쏘(L1)·릿지(L2)·엘라스틱넷이 해결책입니다. 로지스틱(로지스틱)은 Y가 범주형일 때 쓰는 **다른 종류의 회귀**일 뿐 해결책이 아닙니다.

67. 다중회귀분석에서 다중공선성에 대한 설명으로 적절하지 않은 것은? 47회 33번

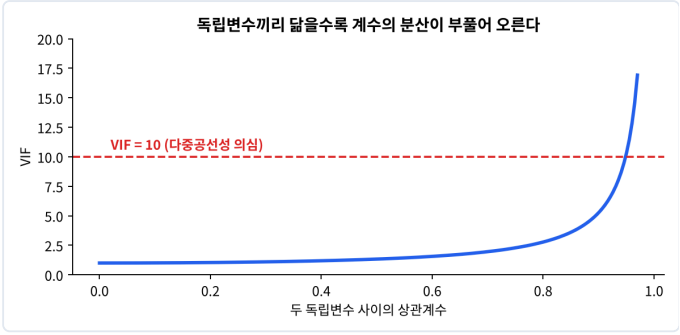
① 다중공선성이 존재하더라도 회귀계수의 분산은 항상 동일하다.
② 독립변수 간 높은 상관관계로 회귀계수 추정이 불안정해진다.
③ 다중공선성은 VIF 지표로 측정 가능하다.
④ 높은 상관관계를 갖는 설명변수를 모형에서 제거하여 해결 가능하다.

정답 ①

높은 설명변수 상관은 계수 추정의 분산을 증가시키고 추정을 불안정하게 할 수 있다.

다중공선성은 설명변수 하나의 정보를 다른 설명변수들의 조합으로 상당 부분 설명할 수 있는 상황이다. 독립적인 정보가 적어 계수의 표준오차가 커지고 작은 자료 변화에도 계수 크기·부호가 달라질 수 있다. 완전 공선성에서는 일반적인 최소제곱 계수를 유일하게 정할 수 없다.
보기 판단: ①의 분산이 항상 동일하다는 주장은 틀리다. ②는 추정 불안정성, ③은 진단 지표, ④는 가능한 개선 방안이다. $VIF_j = \frac{1}{1-R_j^2}$이며 R_j^2는 해당 설명변수를 나머지 설명변수로 회귀한 결정계수이다. 제거할 변수는 상관만 보고 결정하지 않고 업무 의미와 정보 손실을 함께 고려한다.

💡 **쉽게 이해하기** 두 사람이 늘 붙어 다니며 짐을 들면 각자 몇 kg 들었는지 알 수 없어 추정이 **흔들립니다**(분산 증가). 이 흔들림이 몇 배로 부풀었는지가 **VIF**(브이아이에프, 분산팽창요인)이고, 10을 넘으면 의심합니다.



▲ 47회 33번 · 독립변수끼리 상관이 높을수록 VIF(회귀계수 분산이 부푼 정도)가 급격히 커진다

68. 독립변수 후보 모두를 포함한 모형에서 변수를 하나씩 제거하는 변수선택법은? 45회 28번

① 후진 제거법
② 단계별 선택법
③ 교차검증법
④ 전진 선택법

정답 ①

'모두 포함'에서 시작하여 '제거'한다는 흐름이 ① 후진 제거법이다. ④ 전진 선택은 적은 변수 또는 절편만 있는 모형에서 변수를 추가하는 반대 방향이다. ② 단계별 선택은 추가와 제거를 함께 검토할 수 있다.

핵심 개념: 후진 제거법은 후보 설명변수를 모두 포함한 모형에서 출발하여 정해진 기준에 따라 변수를 하나씩 제거한다. p값, AIC 등 무엇을 기준으로 삼는지에 따라 결과가 달라질 수 있다.
보기 검토: ③ 교차검증은 자료를 나누어 새 자료에 대한 성능을 추정하는 평가 절차로 변수선택의 진행 방향을 지칭하지 않는다. 변수를 제거하면 남은 계수도 다시 추정해야 한다. 선택한 모형이 모든 후보 조합 중 최적이라는 보장은 없으므로 목적과 검증 성능을 함께 확인한다.

💡 **쉽게 이해하기** 장바구니 비유: **후진**(백워드) 제거 = 꽉 찬 장바구니에서 필요 없는 것을 하나씩 **빼기**. **전진**(포워드) 선택 = 빈 장바구니에 하나씩 **담기**. 단계별(스텝와이즈) = 담으면서 중간에 빼기도 함.

빠른 정답표

66	④	67	①	68	①

자주 나오는 함정

- 다중공선성 = 독립변수끼리 상관 → 계수 분산 **증가** · **VIF > 10** · 해결: 제거, PCA, 릿지·라쏘
- 후진제거 = 전체에서 하나씩 **제거**, 전진선택 = 하나씩 **추가**

8단원 다변량 분석: MDS·PCA

주성분분석 (PCA)

69. 주성분 분석에 대한 설명으로 틀린 것은? 45회 29번

① 각 주성분을 만들기 위한 가중치(계수)가 산출된다.
② 데이터의 변동이 큰 방향부터 순서대로 주성분을 추출한다.
③ 서로 상관이 없는 새로운 변수를 만들 수 있다.
④ 기존 변수의 개수를 늘려 차원을 확장하는 용도로만 사용된다.

정답 ④
PCA의 목적은 차원 축소이다. 주성분 개수는 원 변수 수를 넘지 않으므로 변수를 늘려 차원을 확장한다는 ④가 틀리다.

핵심 개념: PCA는 상관된 원 변수들의 선형결합으로 서로 무상관인 주성분을 만들고, 분산을 많이 설명하는 소수의 주성분만 남겨 차원을 줄인다.
보기 검토: ①은 고유벡터(적재량)로 각 변수의 가중치가 계산된다는 설명이다. ②는 첫 주성분이 분산을 가장 크게, 다음 주성분이 남은 분산을 차례로 설명한다는 뜻이다. ③은 서로 다른 주성분 사이의 상관이 0이라는 성질이다.
학습 포인트: 원 변수 사이의 상관이 높을수록 적은 수의 주성분으로 많은 분산을 설명할 수 있다. 주성분 수는 누적 설명 비율이나 스크리 그림으로 정한다.

💡 **쉽게 이해하기** PCA(피씨에이, 주성분분석)는 성적 5과목을 '종합 실력', '문과·이과 성향' 2개로 **요약**하는 것처럼 변수를 **줄이는**(차원 축소) 방법입니다. 늘리는 용도가 아닙니다.

70. 다음 중 주성분 분석(PCA)에 대한 설명으로 옳지 않은 것은? 46회 31번

① 주성분 분석은 비지도 학습이다.
② 분산을 극대화하는 방향으로 주성분을 생성한다.
③ 상관관계가 높은 변수들의 선형결합을 통해 차원을 축소하여 변수를 축약한다.
④ 주성분 수는 데이터 수만큼 생성이 가능하다.

정답 ④
④는 주성분 수를 관측 개체 수와 무조건 같게 생성할 수 있다고 일반화한다. 변수 수가 p라면 공분산 행렬의 축은 최대 p개이며, 평균을 제거한 n개 관측값에서 양의 분산을 갖는 주성분 수는 최대 $\min(p, n-1)$이다. 예를 들어 학생 100명에게서 변수 5개를 측정했다면 100개의 독립적인 주성분을 만들 수 없다.

핵심 개념: PCA는 목표변수의 정답 없이 원래 수치 변수의 선형결합으로 새로운 축을 만드는 비지도 차원 축소 방법이다. 첫 번째 주성분은 분산을 가장 많이 설명하고 다음 주성분은 이전 축과 직교하면서 남은 변동을 설명한다.
보기 검토: ①은 종속변수의 정답 없이 자료 구조를 분석하므로 맞다. ②는 분산을 크게 설명하는 방향을 찾는다는 설명이다. ③은 관련 변수의 공통 변동을 선형 결합으로 축약한다는 일반적인 용도 설명이다. 다만 원 변수 사이의 높은 상관이 PCA 수행의 필수 조건은 아니며, 축약 효율을 높이는 상황에 가깝다.
참고: $p \geq n$일 때 소프트웨어가 0분산 성분까지 포함해 n개를 반환하는 경우가 있어 '데이터 수만큼'이라는 표현만으로 모든 상황을 배제할 수는 없다. 변수 수와 행렬의 계수를 고려해야 한다. 이 문항의 의도는 관측 수와 변수 차원을 혼동한 ④를 고르는 것이다.

💡 **쉽게 이해하기** 주성분은 변수들이 만드는 공간의 **새 축**입니다. 변수 2개(키, 몸무게)면 평면이라 축도 최대 2개입니다. 사람을 100명 모아도 평면이 3차원이 되지는 않으므로 주성분은 최대 **변수 수**만큼입니다.

71. 주성분 분석에 대한 설명으로 적절하지 않은 것은? 48회 32번

① 주성분 분석을 통해 차원을 축소시켜 다중공선성 문제를 해결할 수 있다.
② 제1주성분에서 제2주성분으로 숫자가 커질수록 각 주성분이 설명하는 분산의 크기도 지속 증가한다.
③ 제1주성분은 전체 데이터의 변동을 가장 많이 설명하는 축이다.
④ 일반적으로 고윳값이 1 이상인 주성분만을 선택하거나, 누적 기여율이 70~90% 이상이 되는 지점까지의 주성분을 사용한다.

정답 ②
제1주성분은 가능한 방향 중 분산을 가장 많이 설명하며, 제2주성분은 제1주성분과 직교하는 방향 중 다음으로 많이 설명한다. 따라서 각 주성분의 분산은 번호가 커질수록 감소하거나 같아지고 증가하지 않는다. PCA는 분산 보존을 기준으로 차원을 줄이며, 변수 단위가 크게 다르면 표준화 여부를 검토한다. 직교·무상관을 일반적인 확률적 독립성과 동일시하지 않는다.

💡 **쉽게 이해하기** 피자를 나눌 때 매번 '**남은 것 중 가장 큰 조각**'부터 떼어 가는 것과 같습니다. PC1이 가장 크고 PC2, PC3…로 갈수록 담는 정보(분산)가 **줄어듭니다**.

72. 다음은 USArrests 데이터(미국 50개 주의 범죄 통계)에 표준화 주성분 분석을 수행한 결과이다. 해석으로 틀린 것은?

45회 30번

```
> pca <- prcomp(USArrests, scale = TRUE)
> summary(pca)
                          PC1    PC2    PC3     PC4
Standard deviation     1.5749 0.9949 0.5971 0.41645
Proportion of Variance 0.6201 0.2474 0.0891 0.04336
Cumulative Proportion  0.6201 0.8675 0.9566 1.00000
> pca[["rotation"]]
             PC1     PC2     PC3     PC4
Murder   -0.5359  0.4182 -0.3412  0.6492
Assault  -0.5832  0.1880 -0.2681 -0.7434
UrbanPop -0.2782 -0.8728 -0.3780  0.1339
Rape     -0.5434 -0.1673  0.8178  0.0890
```

① 주성분 2개로 4개 변수 분산의 86% 이상을 설명할 수 있다.

② PC2에 가장 크게 기여하는 변수는 UrbanPop이다.

③ PC3에 가장 크게 기여하는 변수는 Rape이다.

④ 전반적으로 Murder의 영향력이 가장 크다.

정답 ④

분산을 가장 많이 설명하는 PC1에서 절댓값이 가장 큰 변수는 Assault(0.5832)이고, Murder(0.5359)는 Rape(0.5434)보다도 작다. 따라서 Murder의 영향력이 전반적으로 가장 크다는 ④가 틀리다.

핵심 개념: Proportion of Variance는 각 주성분이 설명하는 분산 비율, Cumulative Proportion은 누적 비율이다. rotation(적재량)은 각 주성분을 만드는 원 변수의 가중치이며, 기여의 크기는 부호가 아니라 절댓값으로 비교한다.

보기 검토: ①은 PC2까지 누적 비율이 0.8675이므로 맞다. ②는 PC2에서 UrbanPop의 절댓값 0.8728이 가장 크다. ③은 PC3에서 Rape의 0.8178이 가장 크다.

학습 포인트: 적재량의 부호는 방향만 나타내며 주성분 전체의 부호가 바뀌어도 해석은 같다. 변수의 단위가 다르므로 scale = TRUE로 표준화한 뒤 분석했다.

📋 출력 읽는 법

`prcomp(USArrests, scale = TRUE)`	USArrests(유에스 어레스츠) 4개 변수를 표준화 후 PCA
`Standard deviation`	주성분의 표준편차. 제곱 = 고윳값(2.48, 0.99, 0.36, 0.17)
`Proportion of Variance`	각 주성분의 설명 비율(프러포션 오브 배리언스)
`Cumulative Proportion`	누적 비율. PC2까지 **0.8675**
`rotation(로테이션)`	주성분 계수(적재량, 로딩). 기여도는 **절댓값**으로 비교
`PC1 열`	Assault 0.583이 최대 → Murder(0.536)는 1위가 아님

💡 **쉽게 이해하기** rotation 표는 '이 주성분을 만들 때 각 변수를 얼마나 섞었나'입니다. **절댓값이 크면 기여가 크고**, 부호(−)는 방향일 뿐입니다(전체 부호를 뒤집어도 같은 주성분). '전반적 영향력'은 가장 중요한 **PC1**을 기준으로 봅니다.

73. 다음은 주성분 분석(PCA) 결과 각 주성분의 분산 설명 비율이다. 누적 분산 비율이 80% 이상이 되도록 할 때 선택해야 할 최소 주성분의 수는? 47회 30번

> 분산 설명 비율: PC1 0.45, PC2 0.25, PC3 0.15, PC4 0.10, PC5 0.05

① 2

② 3

③ 4

④ 5

정답 ②

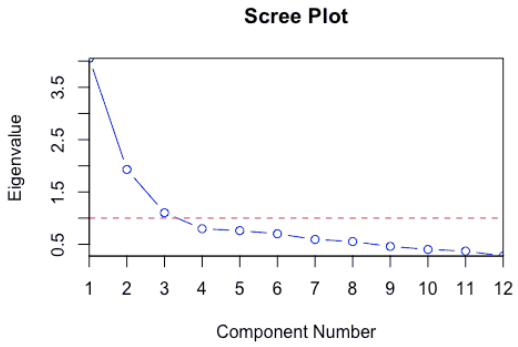
누적 분산 비율은 PC1 0.45, PC2까지 0.70, PC3까지 0.85이므로 처음으로 80%를 넘는 PC3까지, 즉 3개가 필요하다.

누적 설명 비율은 앞에서부터 분산 설명 비율을 더한 값이다. 0.45 → 0.70 → 0.85 → 0.95 → 1.00이므로 0.80 이상이 되는 최소 개수는 3개이다.

보기 판단: ① 2개는 누적 70%로 기준에 못 미치고, ③④는 기준을 만족하지만 최소 개수가 아니다.

💡 **쉽게 이해하기** 앞에서부터 더해 가다 **처음으로 0.80을 넘는 곳**에서 멈춥니다. 0.45 → 0.70(아직 부족) → **0.85**(넘음) → PC3까지, 3개.

74. 아래 주성분 분석(PCA)의 Scree plot을 통해 고유값이 1보다 큰 주성분을 선택할 때 주성분 수는? 47회 46번



① 1
② 3
③ 5
④ 7

정답 ②

Scree plot에서 고유값이 1보다 큰 주성분은 3개이므로 ②이다.

Scree plot의 가로축은 주성분 순서, 세로축은 고유값이다. PCA의 고유값은 각 주성분이 설명하는 분산에 해당한다. 이 문항은 고유값이 1보다 큰 성분을 선택하라는 기준을 명시했으므로 그림에서 그 조건을 만족하는 점을 세어 3개, 즉 ②로 읽는다.
기준 구분: Kaiser 기준의 1은 표준화 변수에 대한 상관행렬 기반 PCA에서 원래 변수 한 개의 분산 1과 비교하는 맥락에 특히 의미가 있다. Scree의 꺾이는 지점이나 누적 설명분산 기준과는 다르며, 군집 수를 정하는 엘보 방법과도 다르다.

📋 출력 읽는 법

가로축	주성분 번호
세로축	고윳값(그 주성분이 담은 분산)
기준선 1	고윳값 1보다 위에 있는 점을 셈 → 3개

💡 **쉽게 이해하기** 스크리(scree) = 산비탈 아래 **돌무더기**. 그래프가 절벽처럼 떨어지다가 돌무더기처럼 완만해집니다. 이 문제는 '고윳값 1 이상' 기준을 주었으므로 **세로 1보다 위에 있는 점**만 세면 됩니다.

75. 아래 주성분분석 결과를 해석한 내용 중 잘못된 것은? 50회 28번

어떤 데이터에 주성분분석(PCA)을 수행한 결과의 일부는 다음과 같다.

Importance of components	Standard deviation	Proportion of Variance	Cumulative Proportion
PC1	2.04629	0.41873	0.41873
PC2	1.62533	0.26417	0.68290
PC3	0.98189	0.09641	0.77931
PC4	0.83976	0.07052	0.84983
PC5	0.66978	0.04486	0.89469
PC6	0.54909	0.03015	0.92484
PC7	0.44900	0.02016	0.94500

① 분산 설명력이 80%를 넘으려면 주성분이 4개 이상 필요하다.
② 분산을 가장 많이 설명하는 주성분의 설명력은 약 41.9%이다.
③ 분석에 사용된 원래 변수의 개수는 모두 7개이다.
④ 2차원으로 축소한다면 손실되는 정보의 비율은 약 31.7%이다.

정답 ③

결과의 '일부'만 제시되었고 PC7까지의 누적 설명력이 94.5%이므로 주성분이 더 존재한다. 총분산은 PC1 분산 ÷ 설명비율 = $2.04629^2 \div 0.41873 \approx 10$이므로, 상관행렬(표준화) 기반 PCA라면 원래 변수는 10개이다. 따라서 ③이 틀리다. ① PC4까지 누적 84.98%로 처음 80%를 넘는다. ② PC1 설명력은 41.87%이다. ④ 2차원 축소 시 손실은 $1 - 0.68290 = 0.3171$이다.

📋 출력 읽는 법

`Standard deviation`	제곱하면 고윳값(PC1: $2.046^2 = 4.19$)
`Proportion of Variance`	PC1 = 0.419 → 가장 큰 설명력 41.9%
`Cumulative Proportion`	PC3 0.779 → PC4 **0.850**에서 처음 80% 넘음
`마지막 행 PC7 = 0.945`	100%가 아님 → **주성분이 더 있음** → 변수는 7개보다 많음
`고윳값 합`	4.19 ÷ 0.419 ≈ 10 → 표준화 PCA라면 변수 10개
`2차원 손실`	1 − 0.683 = 0.317

💡 **쉽게 이해하기** 표가 PC7에서 끝났다고 변수가 7개인 것은 아닙니다. 누적이 **100%가 아니면 아직 남은 주성분이 있다**는 뜻입니다. 시험지에 '결과의 일부'라고 쓰여 있으면 특히 주의하세요.

76. 표준화된 두 변수 A와 B의 상관계수가 약 0.1일 때, 상관행렬을 이용하여 주성분분석(PCA)을 수행하였다. 마지막 주성분으로 가장 적절한 것은? 50회 24번

① $\frac{1}{\sqrt{2}}A - \frac{1}{\sqrt{2}}B$

② $\frac{1}{\sqrt{2}}A + \frac{1}{\sqrt{2}}B$

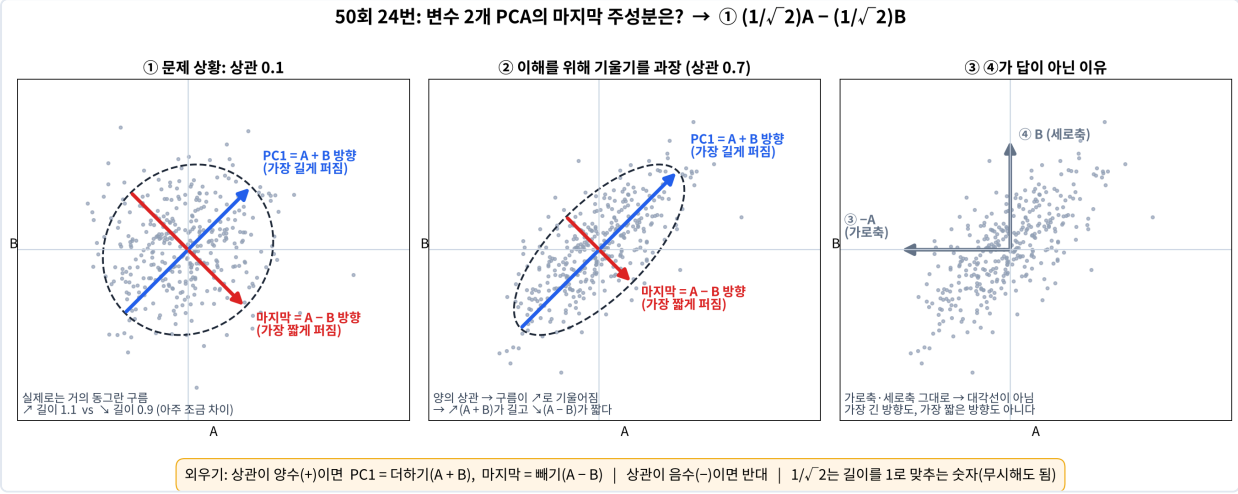
③ $-A$

④ B

정답 ①

상관행렬 ($\begin{pmatrix} 1 & 0.1 \\ 0.1 & 1 \end{pmatrix}$)의 고유값은 1.1과 0.9이다. 마지막 주성분은 작은 고유값(0.9)의 방향인 $(A - B)/\sqrt{2}$이다. 고유벡터의 부호를 반대로 해도 같은 주성분 방향이다.

💡 **쉽게 이해하기** 변수 2개 PCA에서 상관이 **양수**면 점 구름이 ↗로 살짝 기울어 **더한 방향(A + B)**이 가장 길고(PC1), 직각인 **뺀 방향(A − B)**이 가장 짧습니다(마지막). 1/√2는 길이를 1로 맞추는 숫자라 무시해도 됩니다. 상관이 음수면 반대입니다.



▲ 50회 24번 · 양의 상관이면 ↗(A + B)가 PC1, ↘(A − B)가 마지막 주성분. ③ −A, ④ B는 가로·세로축이라 답이 아니다

다차원 척도법 (MDS)

77. 다차원 척도법에 대한 설명으로 틀린 것은? 45회 48번

① 절대적 위치를 알 수 있다.

② 변수 간 거리 정보를 시각화한다.

③ 변수 간 유사성을 직관적으로 파악할 수 있다.

④ 데이터 구조를 2차원이나 3차원으로 축소해 표현할 수 있다.

정답 ①

절대적 위치를 알 수 있다는 ①은 부적절하다. 전체 그림을 회전·이동·반사해도 점 사이 거리가 같을 수 있으므로 좌표의 원점과 방향이 유일한 절대 의미를 갖는 것은 아니다. ②③④는 상대적 거리 구조의 표현이라는 취지로 맞다.

핵심 개념: MDS는 관측 대상 사이 거리 또는 비유사도를 저차원 공간의 상대적 배치로 표현한다. 가까운 대상과 먼 대상의 구조를 시각적으로 이해하는 것이 목적이다.

표현 보완: 보기에 쓰인 '변수 간'은 일반적으로 분석 대상 또는 관측값 사이의 비유사도를 뜻하는 문맥으로 읽는다. 자료를 무엇을 대상으로 구성했는지에 따라 변수 자체를 대상으로 삼을 수도 있다.

저차원화가 모든 원래 거리를 정확히 보존하는 것은 아니므로 왜곡이나 stress 등을 점검한다. PCA의 분산 최대화 목적과 구별한다.

💡 **쉽게 이해하기** MDS(엠디에스, 다차원 척도법)는 도시 사이 **거리표만으로 지도를 그리는** 것과 같습니다. 지도를 돌리거나 뒤집어도 도시끼리의 거리는 같으므로 '누가 누구와 가까운지'(**상대적 위치**)만 알 수 있고, 절대적 위치는 알 수 없습니다.

78. 다차원척도법(MDS)의 활용 사례로 옳은 것은? 46회 28번

① 매출 예측
② 주택 가격 예측
③ 영화 간 유사성 분석 및 시각화
④ 고객 마케팅 효과 분석

정답 ③
③의 영화 간 유사성 분석과 시각화는 MDS의 목적에 맞는다. 관람객의 평가나 취향으로 영화 간 비유사도를 계산하고, 그 관계를 2차원 지도에 표시하면 유사한 영화군을 파악할 수 있다.
핵심 개념: 다차원척도법 MDS는 대상 사이의 거리 또는 비유사도를 입력으로 하여 낮은 차원의 좌표에 배치하는 방법이다. 비슷한 대상은 가깝고 다른 대상은 멀게 배치하여 관계를 시각적으로 이해하도록 한다.
보기 검토: ① 매출과 ② 주택 가격을 수치로 예측하는 문제는 일반적으로 회귀·예측 모델링의 직접적인 목적이다. ④ 고객 마케팅 효과의 예측이나 원인 추정도 MDS의 대표적인 직접 목적은 아니다. MDS 좌표를 후속 모형에 활용할 수 있지만 그 자체가 결과값을 예측하는 지도학습 모형은 아니다.
학습 포인트: PCA도 차원을 줄이지만 주로 원래 수치 변수의 분산을 보존하는 선형 축을 찾는다. MDS는 대상 간 거리 관계를 낮은 차원에서 재현하려 한다. 시각화 좌표를 읽을 때 축의 절대 의미보다 대상 사이의 상대적 위치·거리에 주목한다. 실제 축소에서는 거리의 일부 왜곡이 발생할 수 있다.

💡 **쉽게 이해하기** MDS는 '**비슷한 것끼리 가깝게**' 그려 주는 지도 만들기입니다. 영화·브랜드·제품 간 유사성 지도가 대표 사례이고, 매출·가격처럼 숫자를 맞히는 **예측**은 회귀의 일입니다.

79. 다차원척도법(MDS, Multidimensional Scaling)에 대한 설명으로 옳지 않은 것은? 49회 36번

① 개체들 간의 거리(유사성)를 바탕으로 개체를 저차원 공간에 시각화한다.
② 계량적 MDS는 비율척도나 구간척도로 측정된 데이터를 이용한다.
③ 비계량적 MDS는 순서척도로 측정된 데이터를 이용한다.
④ 개체 간 비유사성을 기준으로 동질적인 그룹(군집)을 형성하는 것이 목적이다.

정답 ④
다차원척도법은 개체 간 거리(비유사성)를 보존하면서 개체를 저차원 공간의 점으로 표현하여 상대적 위치와 구조를 시각화하는 기법이다. 동질적인 그룹을 형성하는 것은 군집분석의 목적이다.

💡 **쉽게 이해하기** MDS의 목적은 **보여 주기(시각화)**입니다. 그림을 보고 사람이 비슷한 무리를 짐작할 수는 있지만, 그룹을 정식으로 **나누는** 것은 군집분석(클러스터링)의 일입니다. 계량 = 숫자 거리(구간·비율), 비계량 = 순서만(서열).

빠른 정답표

69	④	70	④	71	②	72	④	73	②	74	②	75	③	76	①	77	①	78	③
79	④																		

자주 나오는 함정

- 주성분 개수: **누적 기여율 70~80%**, 스크리 그림 꺾이는 지점, 고윳값 1 이상
- PCA는 차원 **축소** · PC 번호가 커질수록 설명력 **감소** · 주성분은 최대 **변수 수**만큼
- MDS: **상대적 위치**만 · 목적은 시각화(군집 아님) · Stress 낮을수록 좋음

9단원 시계열 분석

정상성 · 정상화

80. 시계열 데이터의 정상성을 확보할 수 있는 방법으로 옳은 것은?

45회 24번

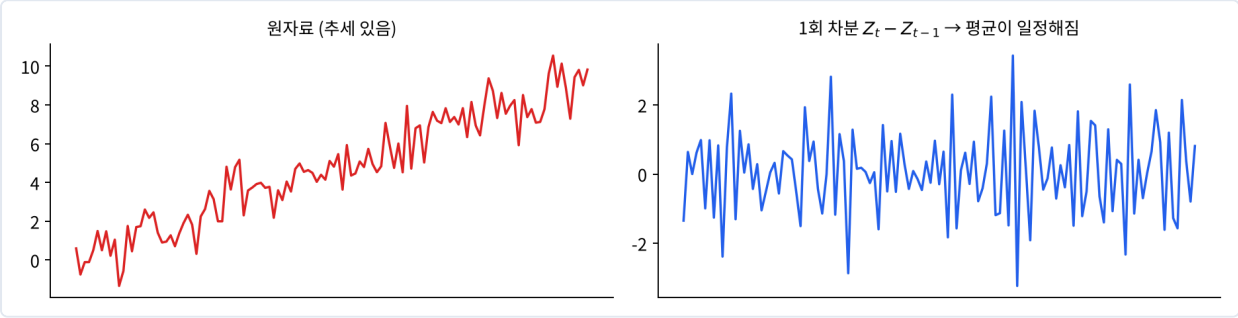
① 더미 변수화
② 정규화
③ 차분
④ 군집화

정답 ③

제시된 기법 중 정상성을 확보하기 위한 대표 처리는 ③ 차분이다. 계절성이 있는 자료에는 주기 s에 대해 $X_t - X_{t-s}$인 계절 차분을 고려한다.

핵심 개념: 차분은 인접 시점 값의 차이를 구하는 변환이다. 1차 차분은 $\Delta X_t = X_t - X_{t-1}$이며, 확률적 추세 때문에 평균이 변하는 비정상 시계열을 정상화하는 데 활용한다.
보기 검토: ① 더미 변수화는 범주 표현, ② 정규화는 척도 변환, ④ 군집화는 유사 집단 형성이므로 일반적인 정상화 방법과 다르다. 다만 차분 한 번으로 모든 비정상성이 해결되는 것은 아니다. 분산 변화에는 로그 변환 등을 고려할 수 있으며 불필요한 과도 차분도 피한다. 변환 후 시계열과 자기상관 등의 특성을 다시 확인한다.

💡 **쉽게 이해하기** **차분**(差分) = '오늘 값 − 어제 값'. 계속 오르는 매출 그래프도 '얼마나 올랐나'만 보면 평균이 일정해집니다. 더미변수·정규화·군집화는 정상성과 관계없는 작업입니다.



▲ 45회 24번 · 추세가 있는 원자료(왼쪽)를 1번 차분하면 평균이 일정한 시계열(오른쪽)이 된다

81. 다음 중 정상 시계열의 특징에 대한 설명으로 옳은 것은?

46회 34번

① 시점에 무관하게 평균과 분산이 일정하다.
② 시간의 흐름에 따라 변동성이 있다.
③ 특정 구간에서 일정한 값을 가진다.
④ 공분산은 시차에 의존하지 않고 시점에 의존한다.

정답 ①

①은 평균과 분산이 시점에 무관하게 일정하다고 설명한다. 정상 시계열에서는 값 자체는 매번 바뀌더라도 그 값이 변동하는 확률적 구조가 시간에 따라 유지된다.

핵심 개념: 이 문항은 약정상성을 기준으로 읽는다. 평균이 시간에 따라 변하지 않고, 분산이 유한하고 일정하며, 두 시점의 공분산이 시점 자체가 아니라 시차에만 의존하는 것이 핵심이다.
보기 검토: ②의 '변동성'이 시간에 따라 분산이 바뀐다는 의미라면 비정상성에 가깝다. 단순히 값이 변한다는 뜻이면 정상 자료도 변하므로 정답을 특정할 설명이 되지 않는다. ③은 특정 구간의 값이 일정하다는 사실만으로 전체 시계열의 정상성을 판단할 수 없어 부적절하다. ④는 공분산의 의존 대상을 반대로 썼다. 정상 시계열의 공분산은 시차에 의존한다.

적용 예: 평균 수준이 계속 상승하는 매출 자료는 추세로 인해 비정상일 수 있다. 평균 근처에서 일정한 변동 폭으로 움직이는 자료는 정상성의 후보가 된다. 추세에는 차분, 분산 변화에는 로그 등의 변환을 검토할 수 있지만 적용 후의 구조도 확인해야 한다. 평균·분산이 일정하다는 두 조건만으로 엄밀한 정상성의 모든 조건을 확인한 것은 아니다.

💡 **쉽게 이해하기** **정상(定常) 시계열** = 성격이 변하지 않는 사람. 값은 매일 오르내려도 평소 수준(평균)과 기복의 크기(분산)는 언제나 비슷합니다. 공분산은 '**며칠 떨어졌나(시차)**'로만 정해지고 '언제냐(시점)'와는 무관합니다.

82. 다음 중 시계열 자료의 정상성에 대한 설명으로 적절하지 않은 것은? 47회 40번

① 분산은 시점에 의존하지 않는다.
② 공분산은 시차(Lag)에만 의존한다.
③ 시계열의 평균이 모든 시점에서 일정하다.
④ 시계열의 자기상관계수가 관측 시점이 흐를수록 반드시 감소한다.

> **정답 ④**
> 약정상성은 일정한 평균·분산, 시차에만 의존하는 공분산으로 정의한다. 시점이 바뀔수록 ACF가 감소해야 한다는 조건은 없다.
> 약정상성의 세 조건은 $E(X_t) = \mu$로 일정, $Var(X_t) = \sigma^2$로 일정, $Cov(X_t, X_{t+h}) = \gamma(h)$로 시차 h에만 의존함이다. 예를 들어 1월과 2월의 공분산과 6월과 7월의 공분산은 같은 시차 1의 관계로 다루어진다.
> 보기 판단: ①②③은 위 조건이다. ④는 달력상 시간이 흘러간다는 것과 시차가 커진다는 것을 혼동한다. 정상성은 동일 시차의 상관 구조가 시간 위치에 따라 변하지 않는다는 조건이지 시간이 흐를수록 자기상관이 반드시 감소한다는 조건이 아니다. 시차에 따른 ACF도 모형에 따라 진동하거나 다양한 형태를 보일 수 있다.

💡 **쉽게 이해하기** 정상성의 조건은 **'같은 간격이면 언제 재도 관계가 같다'**입니다. 1월-2월의 관계와 6월-7월의 관계가 같으면 됩니다. '시간이 흐를수록 자기상관이 반드시 줄어든다'는 조건은 없습니다.

83. 시계열의 정상성(Stationarity)에 대한 설명으로 옳지 않은 것은? 49회 31번

① 시계열 데이터의 각 관측값은 서로 독립이다.
② 평균이 모든 시점에서 일정하다.
③ 분산이 모든 시점에서 일정하다.
④ 공분산은 특정 시점에 의존하지 않고 시차(time lag)에만 의존한다.

> **정답 ①**
> 정상성의 조건은 평균이 일정하고, 분산이 일정하며, 공분산이 시점이 아닌 시차에만 의존하는 것이다. 관측값 간의 독립은 조건이 아니며, 시계열 자료는 일반적으로 자기상관을 가진다.

💡 **쉽게 이해하기** 시계열은 원래 **어제가 오늘에 영향을 주는** 자료입니다(자기상관). 정상 시계열이라고 해서 관측값끼리 독립이 되는 것은 아닙니다. 그 의존 관계가 시간이 지나도 **일정하게 유지**된다는 것이 정상성입니다.

84. 다음 중 비정상 시계열 데이터를 정상 시계열로 변환하기 위해 사용되는 방법으로 적절한 것은? 48회 38번

① 지수평활법
② 선형 회귀 분석
③ 차분
④ 결측치 처리

> **정답 ③**
> 추세 때문에 평균이 시간에 따라 달라지는 경우 차분 $\Delta Yt = Yt - Yt-1$을 검토한다. 차분은 연속한 시점의 차이를 이용하여 추세를 제거하는 대표적 변환이다. 지수평활은 예측·평활 기법이고 결측치 처리는 누락값을 다루므로 정상성을 직접 보장하지 않는다. 모든 비정상성을 한 번의 차분으로 해결할 수 있는 것은 아니므로 변환 후 다시 확인한다.

💡 **쉽게 이해하기** 평균이 계속 변하는(추세가 있는) 비정상 시계열 → **차분**으로 정상화. 지수평활법은 그래프를 매끄럽게 만드는 **예측** 기법이고, 정상성을 만들어 주지는 않습니다.

85. 시계열 자료를 정상화(stationarize)하기 위한 처리에 관한 설명으로 적절한 것은? 50회 39번

① 평활화는 변동을 완만하게 만들어 주지만 그 자체로 정상성을 보장하지는 않는다.
② 추세가 뚜렷한 시계열도 로그 변환만 적용하면 항상 정상 시계열이 된다.
③ 계절성이 존재하는 자료는 차분을 하면 오히려 비정상 시계열이 된다.
④ 분산이 시간에 따라 변하는 경우에는 차분을 통해 분산을 일정하게 만든다.

> **정답 ①**
> 평활화는 변동을 줄이지만 정상성을 보장하지 않는다. 추세는 차분, 계절성은 계절차분, 분산의 변화는 로그·Box-Cox 변환 등을 고려한다. 처리 후 정상성을 다시 확인한다.

💡 **쉽게 이해하기** **평균이 변함 → 차분, 분산이 변함 → 로그 변환**(짝을 바꾸는 함정이 단골). 평활(스무딩)은 그래프를 부드럽게 할 뿐 정상성을 보장하지 않습니다.

시계열 모형 (AR · MA · ARIMA)

86. 다음 중 ARIMA 모델에 대한 설명으로 적절하지 않은 것은? 47회 38번

① ARIMA (p, d, q) 형태로 표현되며 p, d, q는 각각 자기회귀 차수, 차분 차수, 이동평균 차수를 의미한다.

② 일반적으로 자기회귀 차수를 먼저 정하고, 차분 차수를 정한다.

③ 시계열 데이터의 과거 값과 오차를 이용해 미래를 예측하는 통계 모델이다.

④ 데이터를 정상 시계열로 변환하여 분석하므로 통계적 안정성이 높다.

정답 ②

통상 정상성 검토와 차분 차수 d 설정 후 ACF·PACF 등을 보고 p·q를 정한다.

ARIMA의 p는 자기회귀 차수, d는 차분 횟수, q는 이동평균 오차항 차수이다. 일반적인 절차는 시계열을 살펴 정상성을 검토하고 필요한 차분을 결정한 뒤, 차분된 자료의 ACF·PACF와 모형 비교·잔차 진단을 통해 p·q를 선정하는 것이다.

보기 판단: ①③은 정의와 예측 원리를 설명한다. ②는 자기회귀 차수를 먼저 정하는 것을 일반적인 순서로 제시하여 부적절하다. ④는 필요한 정상화 후 모델링한다는 취지로 제한해 읽는다. 차분한다고 예측 안정성이나 정확성이 자동 보장되지는 않으며 과차분, 구조 변화, 계절성도 점검해야 한다. 실무의 자동 모형 선정에서는 여러 차수를 함께 탐색할 수도 있다.

💡 **쉽게 이해하기** ARIMA(아리마, p, d, q)를 정하는 순서: 먼저 **d(차분 횟수)**로 정상 시계열을 만든 다음, 그 자료의 ACF·PACF를 보고 **p, q**를 정합니다. 집을 지을 때 땅을 평평하게 고른(차분) 다음 기둥을 세우는 (p, q) 것과 같습니다.

87. 시계열 모형에 대한 설명으로 옳은 것은? 50회 22번

① AR 모형은 정상성을 가정하지 않는다.

② MA 모형은 비정상 시계열 자료에만 적용할 수 있다.

③ AR 모형과 MA 모형은 모두 정상성을 가정한다.

④ ARMA 모형은 반드시 차분한 자료에만 사용할 수 있다.

정답 ③

AR·MA·ARMA는 정상 시계열 분석의 기본 모형이다. AR 모형은 계수에 대한 정상성 조건을 만족해야 하며, 유한 차수 MA 모형은 유한 분산 백색잡음 아래에서 정상적이다. 비정상 시계열은 원인에 따라 차분이나 로그·Box-Cox 변환 등을 검토한다. ARIMA는 차분 차수 d를 포함한다. 이미 정상인 자료에는 차분이 필수적이지 않으므로 ④는 틀리다.

💡 **쉽게 이해하기** AR(에이알)·MA(엠에이)·ARMA는 모두 **정상 시계열**용 모형입니다. 비정상이면 먼저 차분해서 정상으로 만든 뒤 쓰는데, 이것을 합친 것이 **ARIMA**입니다. 이미 정상인 자료는 차분할 필요가 없습니다.

88. 이동평균모형(MA)은 현재의 시계열 값을 무엇의 선형결합으로 표현하는가? 50회 25번

① 과거의 관측값

② 과거와 현재의 관측값

③ 과거의 오차항

④ 과거와 현재의 오차항

정답 ④

MA(q)는 현재와 과거의 오차항을 선형결합하여 현재 값을 표현한다. 과거 관측값을 사용하는 AR과 구분한다.

💡 **쉽게 이해하기** **MA(이동평균) = 과거 충격의 여파**. 오늘 기분 = 평소 기분 + **오늘** 생긴 일 + **어제·그제** 생긴 일의 여파. 오차항(충격)에 현재 a_t도 포함되므로 '과거와 현재의 오차항'입니다. 과거 **관측값**을 쓰는 것은 AR.

89. 다음 중 자기회귀모형(AR)을 나타내는 식으로 가장 적절한 것은? 50회 26번

[기호 설명]
Z_t : 현재 시점 t의 시계열 관측값
Z_{t-1}, Z_{t-2} : 과거 시점의 관측값
ϕ : 자기회귀(AR) 계수
θ : 이동평균(MA) 계수
a_t : 백색잡음(오차항)

① $Z_t = a_t - \theta_1 a_{t-1}$

② $Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + a_t$

③ $Z_t = \theta_1 a_{t-1} + a_t$

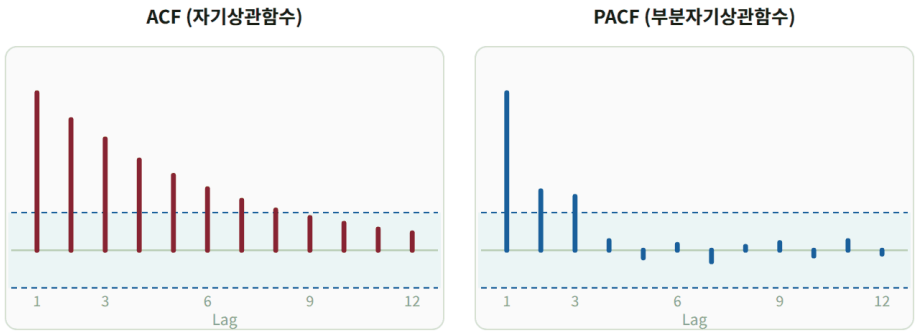
④ $Z_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2}$

정답 ②

②는 과거 관측값 Z_{t-1}, Z_{t-2}와 현재 오차항 a_t로 구성된 AR(2)이다. 나머지는 오차항들의 조합으로 구성된 MA 모형이다.

💡 **쉽게 이해하기** 식에서 **Z(관측값)가 오른쪽에 있으면 AR, a(오차)만 있으면 MA**입니다. ② Z_t = φ₁Z_{t−1} + φ₂Z_{t−2} + a_t는 과거 관측값 2개 → AR(2). φ는 '파이', θ는 '세타'라고 읽습니다.

90. 어떤 시계열 자료의 표본 자기상관함수(ACF)와 부분자기상관함수(PACF)를 시차(lag) 12까지 그린 결과는 다음과 같다. 아래 상관도표를 근거로 판단할 때 가장 적절한 ARMA(p, q) 모형은? 50회 32번



파란 점선은 유의성 한계선(약 ±0.196)

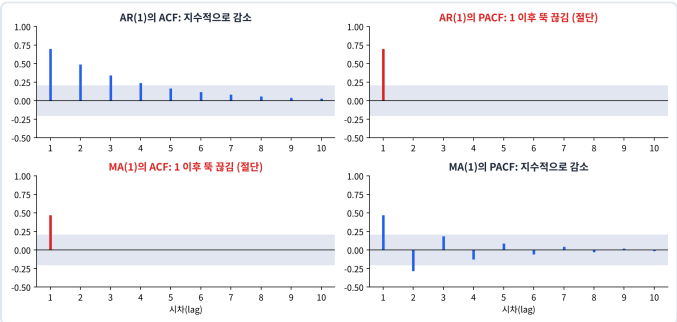
① ARMA(2, 0)
② ARMA(0, 2)
③ ARMA(3, 0)
④ ARMA(0, 3)

> **정답 ③**
> ACF는 점진적으로 감소하고 PACF는 시차 3까지 유의하며 이후 절단되는 형태이다. AR(3)의 전형적 패턴이므로 ARMA(3,0)이다.

📋 출력 읽는 법

가로축 Lag(래그)	몇 시점 전과 비교했나(시차)
파란 점선 ±0.196	유의성 한계선(±1.96/√n → n ≈ 100). 안쪽 막대는 '0과 같다'
ACF	lag 8 정도까지 천천히 줄어듦 → 끊기지 않음(tail off)
PACF	lag 1·2·3만 점선 밖, 4부터 안 → **3에서 절단**
판정	PACF가 끊김 → AR, 끊긴 시차 3 → p = 3 → ARMA(3, 0)

💡 **쉽게 이해하기** ARMA(**p**, **q**): p = 과거 **관측값** 몇 개(AR 차수, **PACF**로 찾음), q = 과거 **충격** 몇 개(MA 차수, **ACF**로 찾음). 'P는 AR 쪽'으로 외우면 됩니다. 이 그래프는 PACF가 3에서 끊기고 ACF는 안 끊기므로 p = 3, q = 0입니다.



▲ 50회 32번 · AR은 PACF가 차수 이후 뚝 끊기고, MA는 ACF가 뚝 끊긴다 (그림은 차수 1의 예)

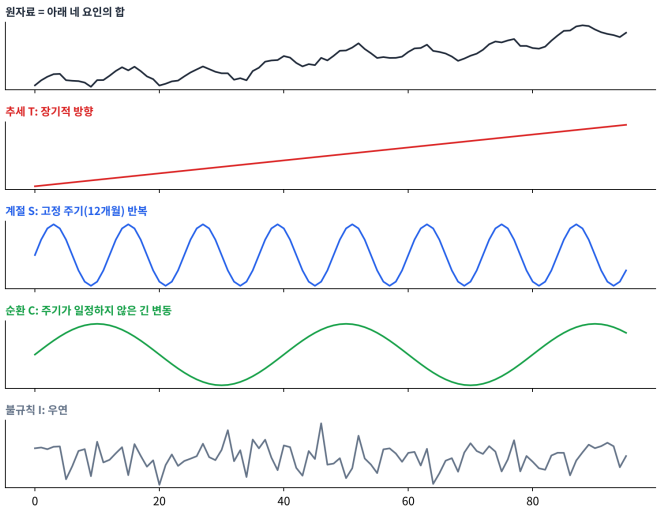
분해 시계열 · 시계열 일반

91. 시계열 분해에 대한 설명 중 잘못된 것은? 45회 25번

① 계절요인은 일정한 주기로 반복되는 규칙적인 변동이다.
② 순환요인은 장기적인 주기로 나타나는 변동이다.
③ 불규칙요인은 다른 요인으로 설명되지 않는 우연적인 변동이다.
④ 추세요인은 짧은 순간마다 무작위로 상승과 하락을 반복하는 성분이다.

> **정답 ④**
> 짧은 순간마다 무작위로 오르내리는 성분은 불규칙요인의 특징이다. 추세는 장기적·지속적인 방향성이므로 ④가 틀리다.
>
> 핵심 개념: 시계열은 추세·계절·순환·불규칙 요인으로 분해한다. 추세는 장기적인 증가·감소 방향, 계절은 요일·월·분기처럼 고정된 주기의 반복, 순환은 경기 변동처럼 주기가 일정하지 않은 장기 변동, 불규칙은 나머지 우연 변동이다.
> 보기 검토: ①③은 정의와 같다. ②의 순환요인은 장기 변동이지만 계절요인과 달리 주기 길이가 일정하지 않다는 점도 함께 기억한다.
> 학습 포인트: '고정 주기=계절', '불규칙한 긴 주기=순환', '방향성=추세', '나머지=불규칙'으로 구분한다.

💡 **쉽게 이해하기** 분해 시계열 4요인 외우기: **추세** = 장기 방향(인구 증가), **계절** = 고정 주기(여름마다 아이스크림), **순환** = 들쭉날쭉한 긴 주기(경기), **불규칙** = 나머지 우연. '순간마다 무작위로 오르내림'은 불규칙의 설명입니다.



▲ 45회 25번 · 원자료 = 추세 + 계절(고정 주기) + 순환(비고정 주기) + 불규칙(우연)

92. 다음 중 분해시계열의 주요 요인(Decomposition Factors)으로 적절하지 않은 것은? 48회 36번

① 추세요인
② 규칙요인
③ 계절요인
④ 순환요인

> **정답 ②**
> 분해시계열의 대표 요인은 추세·계절·순환·불규칙 요인이다. 규칙요인은 이 목록의 구성 요소가 아니므로 ②가 답이다. 추세는 장기 방향, 계절은 일정한 달력 주기로 반복하는 변동, 순환은 고정 주기가 아닌 장기적 변동, 불규칙은 나머지 우연적 변동으로 구분한다.

💡 **쉽게 이해하기** 분해 요인은 **추·계·순·불**(추세·계절·순환·불규칙) 네 가지입니다. '규칙요인'이라는 이름은 없습니다. 오히려 반대말인 **불**규칙요인이 있습니다.

93. 시계열의 구성요소와 해당 요인의 연결이 잘못된 것은? 49회 35번

① 추세 요인 - 장기적인 변동 요인
② 순환 요인 - 중장기적인 변동 요인
③ 계절 요인 - 단기적(계절적) 변동 요인
④ 불규칙 요인 - 장기적인 변동 요인

> **정답 ④**
> 불규칙 요인은 추세·순환·계절 요인으로 설명되지 않는 우연한 단기적 변동이다. 장기적인 변동은 추세 요인이다.

💡 **쉽게 이해하기** 불규칙 요인은 지진·파업처럼 **갑자기 생기는 짧은** 변동입니다. 장기적인 변동은 추세 요인입니다.

94. 다음 중 시계열 분석에 대한 설명으로 적절하지 않은 것은? 47회 36번

① 비정상 시계열인 경우 차분 및 변환을 통해 정상성을 확보할 수 있다.
② 정상 시계열인 경우 자기회귀(AR) 또는 이동평균(MA) 모형을 적용할 수 있다.
③ 백색잡음(White noise)은 대표적인 비정상 시계열이다.
④ 정상성 확보를 위해 평균이 일정하지 않으면 차분을, 분산이 일정하지 않으면 변환이 사용된다.

> **정답 ③**
> 백색잡음은 평균·분산이 일정하고 서로 다른 시점의 공분산이 0인 대표적 약정상 과정이다.
>
> 약정상 시계열은 평균·분산이 시점에 따라 바뀌지 않고 공분산은 두 시점 사이의 간격에만 의존한다. 백색잡음은 평균 0, 일정한 유한 분산, 다른 시점 사이의 공분산 0을 갖는 대표적 약정상 과정이다.
> 예측할 일정한 추세가 없다는 것과 비정상이라는 것은 다르다.
> 보기 판단: ③이 잘못된 설명이다. ①④의 차분은 추세 등에 따른 평균 변화, 로그 등 변환은 분산 변화의 완화에 사용될 수 있다. 이러한 처리로 모든 비정상성이 반드시 해결되는 것은 아니며 처리 후 다시 점검한다. ②의 AR·MA도 정상성·모형 조건을 만족하는 형태를 적용한다는 취지로 읽는다.

💡 **쉽게 이해하기** **백색잡음**(화이트 노이즈) = 평균 0, 분산 일정, 서로 상관 없는 완전 무작위 값. TV 지직거리는 화면처럼 패턴은 없지만 성격(평균·분산)은 늘 같아서 **대표적인 정상** 시계열입니다. '예측할 수 없다'와 '비정상'은 다른 말입니다.

빠른 정답표

80	③	81	①	82	④	83	①	84	③	85	①	86	②	87	③	88	④	89	②
90	③	91	④	92	②	93	④	94	③										

자주 나오는 함정

- 정상성: 평균 일정(→ **차분**), 분산 일정(→ **변환**), 공분산은 **시차**에만 의존 · 정상이어도 독립은 아님
- **AR → PACF** 절단, **MA → ACF** 절단 · MA는 항상 정상
- ARIMA(p, d, q)의 d = 차분 횟수 · d = 0이면 ARMA
- 계절 = **고정** 주기, 순환 = **비고정** 주기