ADsP 데이터분석 준전문가 · 3과목 2장 통계 분석

쉽게 이해하는 통계 분석

초보자를 위한 설명 · 시험에 중요한 내용 중심 · 단원마다 출제 유형과 함정 정리

1단원	통계 개요·확률 기초
2단원	확률분포
3단원	기댓값·분산, 왜도·첨도, 공분산·상관계수
4단원	추정·가설검정·비모수 검정
5단원	t-검정·분산분석·교차분석·상관분석
6단원	회귀분석 ① 개요~결과 해석
7단원	회귀분석 ② 다중공선성·변수 선택·고급 회귀
8단원	다변량 분석: MDS·PCA
9단원	시계열 분석

보는 법

· 노란 상자 = 한 문장 요약·외우는 법 · 초록 상자 = 시험 출제 유형과 함정

· R 코드는 시험에 나오는 함수와 출력 읽는 법만 넣었습니다(출력 숫자는 읽는 법을 보여 주는 예시).

1단원 통계 개요·확률 기초

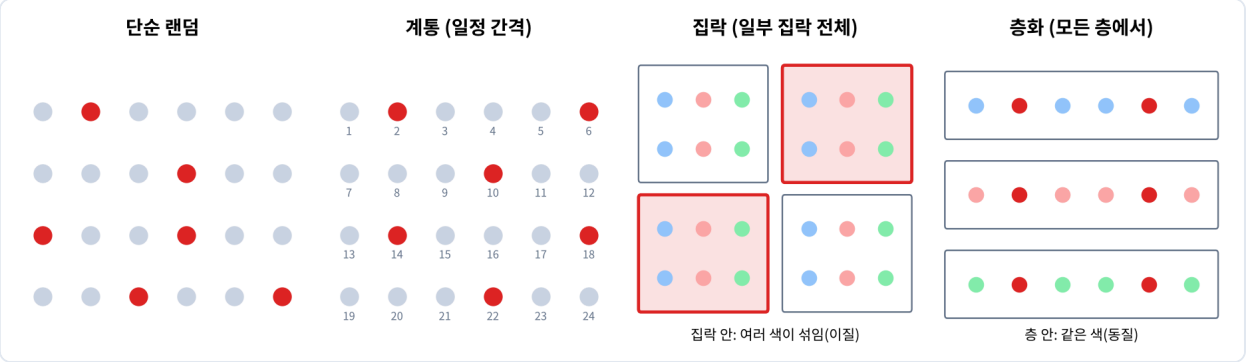
한 문장 요약: 통계는 **일부(표본)를 보고 전체(모집단)를 알아내는 기술**입니다. 이를 위해 표본을 **잘 뽑는 법**(표본추출), 데이터의 **종류**(척도), **확률**의 기본 규칙을 먼저 배웁니다.

1. 모집단과 표본

용어	뜻	예
모집단	알고 싶은 대상 **전체**	한국 대학생 전체
표본	모집단에서 **뽑은 일부**	뽑힌 대학생 1,000명
전수조사	모집단 **전체**를 조사	인구주택총조사
표본조사	**표본만** 조사해서 모집단을 추정	여론조사
모수	모집단의 값 (보통 모름)	μ(뮤, 평균), σ(시그마, 표준편차)
통계량	표본으로 계산한 값	$\bar{x}$(엑스바, 표본평균), s(에스, 표본표준편차)

- 표본 결과를 모집단 전체로 **일반화**하므로, 표본이 모집단을 잘 닮았는지(**대표성**)가 가장 중요합니다.
- **신뢰수준 95%, 오차범위 ±3%p:** 같은 방식으로 조사를 100번 하면 약 95번은 진짜 값이 결과 ±3%p 안에 든다는 뜻입니다. "100번"은 비율을 설명하려는 예입니다.
- **%와 %p:** 실업률이 2%에서 10%가 되면 **8%p**(퍼센트포인트) 상승입니다. 단순히 뺀 값입니다. 원래 값 대비로는 **400%** 상승입니다(8 ÷ 2 × 100).

2. 표본추출 방법



▲ 빨간 점 = 뽑힌 표본. 계통은 일정 간격, 집락은 묶음 통째로, 층화는 모든 층에서 조금씩

방법	방식	핵심
단순 랜덤	모두 같은 확률로 무작위 추출	제비뽑기
계통	번호를 매긴 뒤 **첫 표본만 무작위**, 이후 **K번째마다** 추출	일정 간격
집락(군집)	모집단을 여러 묶음으로 나누고, **일부 묶음을 골라 그 안을 전부** 조사	묶음 **내부는 이질적**(작은 모집단처럼 섞임)
층화	모집단을 층(성별, 학년 등)으로 나누고 **모든 층**에서 무작위 추출	층 **내부는 동질적**, 층끼리는 다름

- **집락 = 군집**입니다. 둘 다 Cluster를 옮긴 말이고, 시험에는 주로 "**집락**"으로 나옵니다. 3장의 군집분석과는 다른 개념입니다.
- 층화 추출 중 층 비율대로 뽑으면 **비례 층화**, 비율과 다르게 뽑으면 **불비례 층화**입니다.

3. 측정과 척도

척도는 측정한 값에 담긴 **정보의 수준**입니다. 위로 갈수록 할 수 있는 계산이 늘어납니다.



▲ 척도는 위로 갈수록 정보가 하나씩 쌓인다

척도	이름의 뜻	할 수 있는 것	예
명목	이름(名目)만 붙임. 숫자는 이름표	**구분**	성별, 혈액형, 지역
서열	순서(序列)가 있음	구분 + **순서**	학년, 만족도 5점, 선호 순위
등간(구간)	간격(間)이 같음	+ **덧셈·뺄셈**	온도(℃), 지수
비율	비율(몇 배)을 말할 수 있음	+ **곱셈·나눗셈**	키, 무게, 나이, 가격, 점수

- 명목·서열은 **질적(범주형)** 척도이고, 등간·비율은 **양적(수치형)** 척도입니다.
- **등간과 비율을 가르는 것은 '0'의 의미입니다.** 0℃는 "온도가 없음"이 아니라서 20℃가 10℃의 2배라고 할 수 없습니다(등간). 0kg은 "무게가 없음"이라서 20kg은 10kg의 2배입니다(비율). 이렇게 진짜 '없음'을 뜻하는 0을 **절대 영점**이라고 합니다.



▲ 척도별 정보 수준과 쓸 수 있는 대표 분석 방법

4. 기술통계와 추리통계

	기술통계	추리(추론)통계
목적	가진 데이터 **자체를 요약**	표본으로 **모집단을 추측**
도구	평균, 중앙값, 분산, 표준편차, 그래프	추정, 가설검정, 신뢰구간
예	우리 반 평균 75점	전국 고3 평균은 73~77점 (95%)

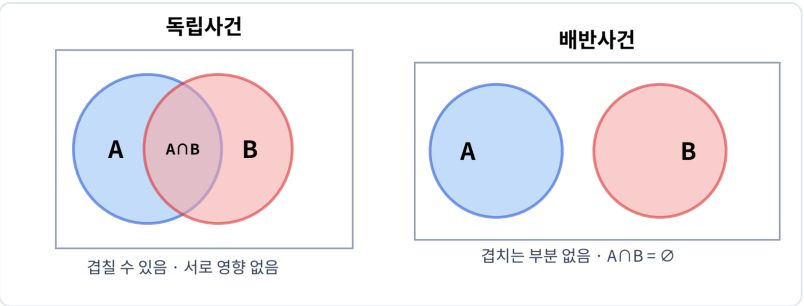
- **편차**(deviation, 값 − 평균), **분산**(편차²의 평균), **표준편차**(√분산)는 기술통계의 대표 도구입니다. 표준편차는 편차의 '**표준적인**(보통의) 크기'라는 뜻이고, 자세한 내용은 3단원에서 다룹니다.

5. 확률의 기초

- **확률** P(A) = A가 일어나는 경우의 수 ÷ 전체 경우의 수이며, 항상 0~1입니다.
- **조건부 확률 P(B|A) = P(A∩B) ÷ P(A): "A가 일어났을 때** B의 확률"입니다. "피 비 기븐 에이"라고 읽고, 세로 막대 | 는 "~이 주어졌을 때(given)"라는 뜻입니다. 계산할 때는 **분모를 조건 집단(A)으로 바꿉니다.**

예: 남학생 70명(사과 30, 딸기 40)과 여학생 30명이 있으면, P(사과 | 남학생) = 30 ÷ 70 = **3/7**입니다. 분모가 전체 100명이 아니라 남학생 70명입니다.

구분	독립사건	배반사건
뜻	서로 **영향을 주지 않음**	**동시에 일어날 수 없음**
식	**P(A∩B) = P(A) × P(B)**	**A∩B = ∅** (공집합)
동시에 일어날 확률	두 확률의 **곱**	**0**
둘 중 하나라도 일어날 확률	P(A) + P(B) − P(A)P(B)	**P(A) + P(B)**
예	주사위 2번 던져 둘 다 1 → 1/6 × 1/6	동전 1번의 앞면과 뒷면



▲ 독립은 겹칠 수 있고, 배반은 겹치는 부분이 없다

독립 식은 어디서 나올까? 조건부 확률 식을 바꾸면 P(A∩B) = P(A) × P(B|A)입니다. 독립이면 A가 일어나도 B의 확률이 그대로이므로 P(B|A) = P(B)이고, 그래서 **P(A∩B) = P(A) × P(B)**가 됩니다.

6. 확률변수 → 확률분포 → 확률함수

동전을 2번 던지는 예로 보겠습니다.

결과	뒤뒤	앞뒤	뒤앞	앞앞
확률	1/4	1/4	1/4	1/4
X = 앞면 개수	0	1	1	2

X	0	1	2	합
P(X)	1/4	**2/4**	1/4	1

- **확률변수:** 결과를 **숫자로 바꾼 것**입니다. 여기서는 X = 앞면 개수입니다.

- **확률분포:** 같은 숫자끼리 확률을 **모아 정리한 표**입니다. X = 1은 '앞뒤'와 '뒤앞' 두 경우라서 2/4가 됩니다.
- **확률함수:** 값을 넣으면 확률이 나오는 **식**입니다. $P(X = x) = {}_2C_x \times (1/2)^2$에서 ${}_2C_x$는 경우의 수(조합)이고, $(1/2)^2$는 결과 하나의 확률입니다. 예를 들어 x = 1이면 ${}_2C_1 = 2$이므로 $2 \times 1/4 = 2/4$입니다. 시험에 공식 계산은 거의 나오지 않으므로 **흐름만** 이해하면 됩니다.
- 이 표를 막대그래프로 그리면 다음 단원의 **이산확률분포**가 됩니다.

시험에는 이렇게 나옵니다 · 출제 유형과 함정

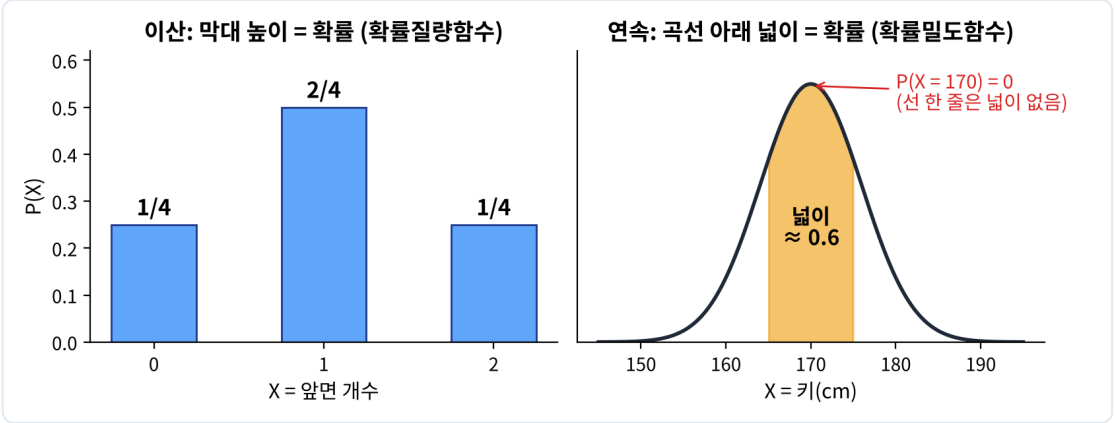
- **표본추출:**
- "계통 추출은 각 구간에서 무작위로 뽑는다" → 틀림 (**첫 표본만** 무작위, 이후 일정 간격)
- "집락 내부는 동질적" → 틀림 (집락 내부는 **이질적**, **층** 내부가 동질적)
- 상황 설명을 주고 방법 이름 고르기: "학교 몇 곳을 골라 그 학교 학생 전부 조사" → **집락**, "학년별로 나눠 각 학년에서 뽑음" → **층화**
- **척도:** "절대 영점이 있는 척도" → **비율**. "절대 영점은 없지만 덧셈·뺄셈 가능" → **등간(구간)**. 만족도 5점은 숫자지만 **서열**, 시험 점수·나이·무게는 **비율**, 혈액형·성별은 **명목**
- **모수와 통계량:** 표본의 평균·분산·표준편차는 **통계량**, 모집단의 값은 **모수**
- **독립·배반:** "독립이면 동시에 일어날 확률은 두 확률의 **합**" → 틀림 (**곱**). "독립인 두 사건 확률의 합 = 합집합 확률" → 틀림 (그건 **배반**). **배반사건은 독립이 아닙니다.** A가 일어나면 B는 절대 일어나지 못하므로 서로 영향을 줍니다.
- **조건부 확률 계산:** 분모를 **조건 집단**으로 바꾸는지 확인합니다. P(사과 | 남학생)과 P(남학생 | 사과)는 값이 다릅니다.

2단원 확률분포

한 문장 요약: 확률분포란 **어떤 값이 얼마나 자주 나오는지**를 정리한 것입니다. **세는 값**(몇 개, 몇 번)이면 이산, **재는 값**(키, 시간)이면 연속입니다.

1. 확률변수의 두 종류

	이산확률변수	연속확률변수
값	**셀 수 있음** (0, 1, 2, …)	**셀 수 없음** (170.1cm, 170.12cm, …)
확률을 나타내는 함수	**PMF** (확률질량함수)	**PDF** (확률밀도함수)
확률 구하는 법	각 값의 확률을 **더함** (Σ)	곡선 아래 **넓이**를 구함 (∫)
한 값의 확률	값이 있음	**0**, 즉 P(X = a) = 0

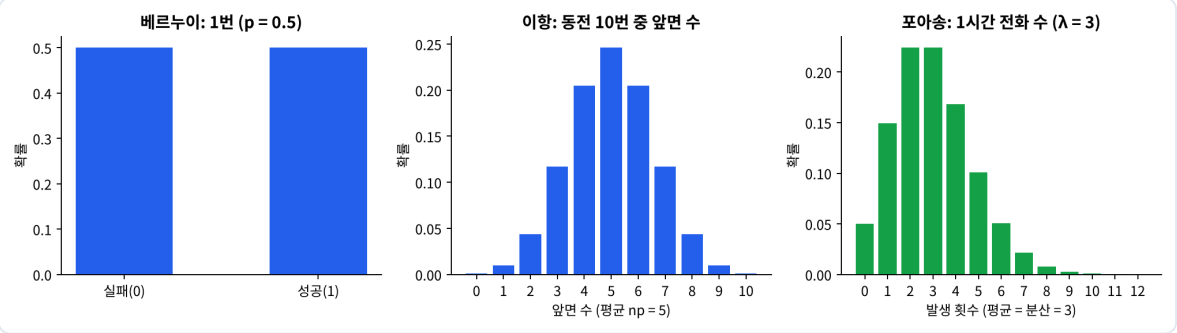


▲ 이산은 막대 높이가 확률, 연속은 곡선 아래 넓이가 확률

- **연속형은 왜 한 점의 확률이 0일까?** 키가 정확히 170.000000…cm인 사람은 사실상 없습니다. 그래서 연속형은 "165~175cm 사이일 확률"처럼 **구간**으로만 확률을 말합니다.
- **PDF의 높이는 확률이 아니라 밀도입니다.** 넓이가 확률이므로, 구간이 아주 좁으면 높이가 1보다 커도 넓이는 1을 넘지 않습니다. 그래서 **PDF 값은 1을 넘을 수 있습니다.**

2. 이산확률분포: "몇 번?"을 세는 분포

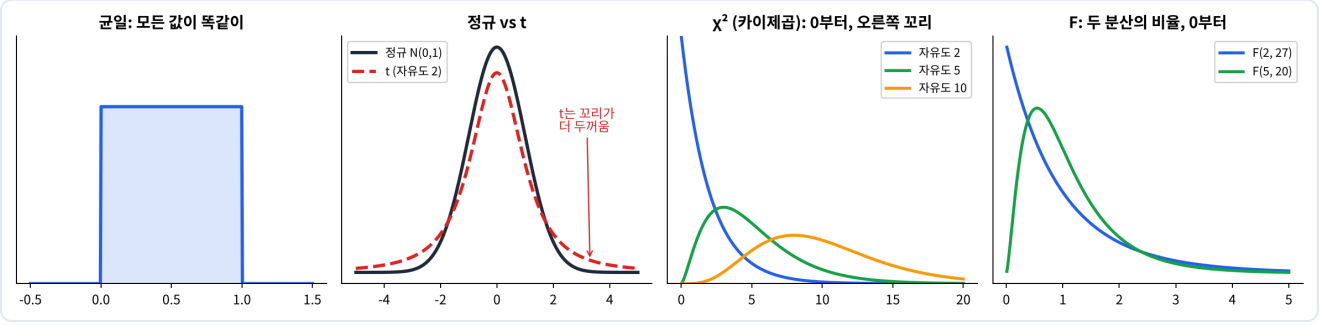
분포	상황	예	알아 둘 것
베르누이	성공/실패를 **한 번**	동전 1번	성공 확률 p
이항	베르누이를 **n번** 반복해 성공 횟수	동전 10번 중 앞면 수	평균 = **np**
기하	**처음 성공할 때까지** 시도 횟수	주사위에서 처음 1이 나올 때까지	
다항	결과가 **3가지 이상**	주사위 10번에서 눈별 횟수	
포아송	**정해진 시간·공간 안의** 발생 횟수	1시간 동안 걸려 온 전화 수, 책 1쪽의 오타 수	**평균 = 분산 = λ**(람다)



▲ 대표 이산분포의 모양

3. 연속확률분포: "얼마나?"를 재는 분포

분포	모양	주로 쓰는 곳
균일	평평한 직사각형 (모든 값이 똑같이 나옴)	
정규	평균 근처가 가장 많은 **종 모양**, 좌우 대칭	키, 몸무게, 점수
t	정규와 비슷하지만 **꼬리가 더 두꺼움**	**평균** 검정
χ^2 (카이제곱)	0부터 시작, 오른쪽 꼬리가 김	**범주형** 자료 검정, 분산 검정
F	두 χ^2의 **비율**, 0부터 시작	**등분산** 검정, **분산분석**
지수	다음 사건까지 걸리는 **시간**	



▲ 연속분포의 모양: t는 정규보다 꼬리가 두껍고, χ^2와 F는 0부터 시작한다

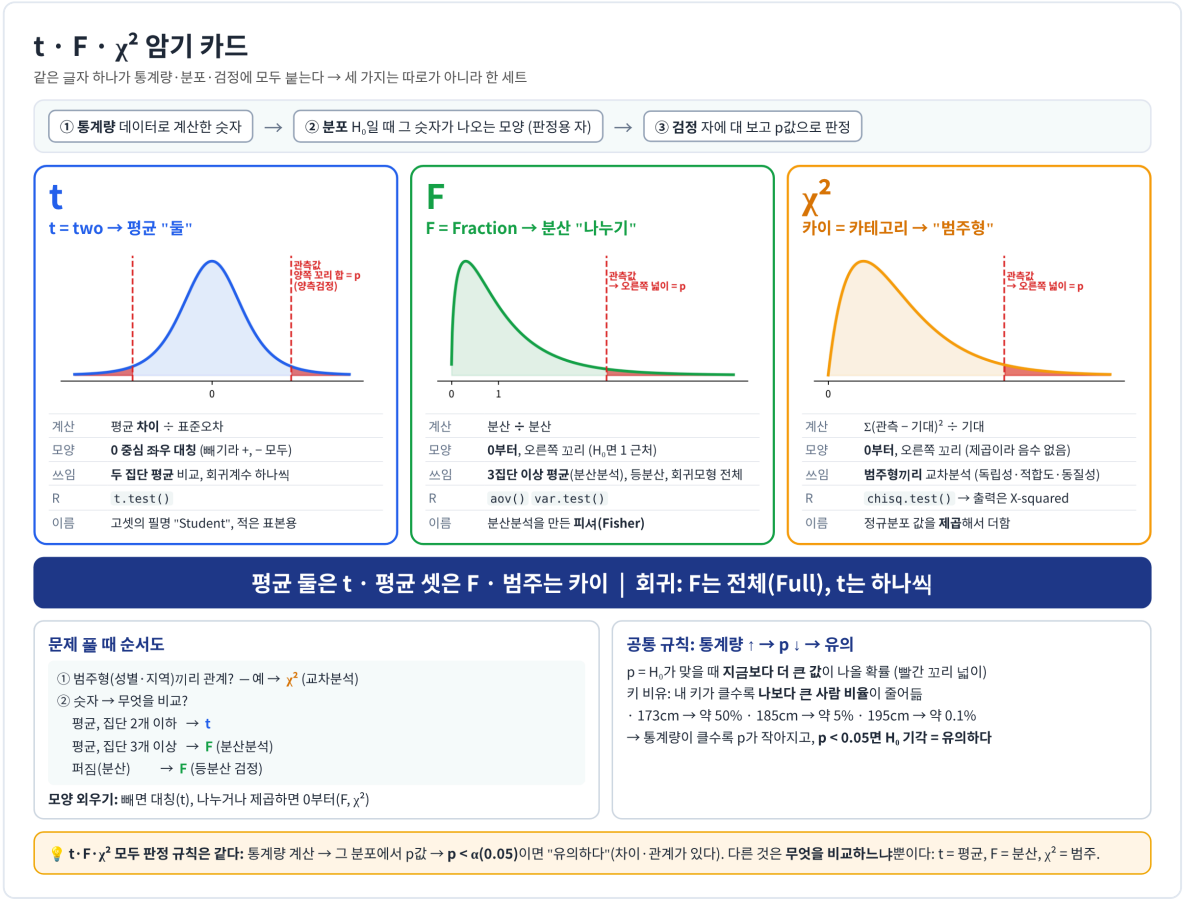
- **정규분포 N(μ, σ²):** "엔 뮤 시그마 제곱"이라고 읽고, 평균 μ, 분산 σ^2인 정규분포라는 뜻입니다.
- **표준정규분포 N(0, 1):** 평균 0, 표준편차 1로 맞춘 정규분포로, **Z분포**("제트 분포")라고도 합니다. **Z = (X − μ) ÷ σ**로 바꾸면 단위가 달라도 같은 기준(표준편차 몇 개만큼 떨어졌나)으로 비교할 수 있습니다.

- **t분포:** 실제로는 모집단 분산을 모르는 경우가 대부분이라 표본으로 추정합니다. 표본이 작으면 불확실하므로 극단값이 나올 여지를 더 크게 잡은 분포입니다. **자유도가 커질수록 정규분포에 가까워집니다.**
- **χ^2 기호:** 정확한 기호는 그리스 문자 **χ(카이)**입니다. 교재 글꼴에서 소문자 x처럼 보여도 "**카이제곱**"으로 읽습니다. R 출력에는 `X-squared`로 나오는데, 이것도 카이제곱 통계량입니다.

4. 자유도 (df)

- **자유롭게 고를 수 있는 값의 개수**를 자유도라고 하며, R 출력에는 `df` (degrees of freedom)로 표시됩니다.
- 예: 숫자 3개의 평균이 10이면 합은 30입니다. 앞의 두 숫자는 마음대로 정할 수 있지만 마지막 숫자는 자동으로 정해집니다. 그래서 자유도는 3 − 1 = **2**입니다.
- 평균을 하나 계산할 때마다 자유도가 1씩 줄어서, 보통 **n − 1**이 됩니다.

> **외우기: t = 평균, χ^2 = 범주형(교차분석)·분산, F = 등분산·분산분석**



▲ t · F · χ^2 한 장 암기카드: 무엇을 비교하나, 모양, 쓰는 검정

시험에는 이렇게 나옵니다 · 출제 유형과 함정

- **분포 분류:** "이산형이 **아닌** 것은?" → **지수분포**(연속). **기하분포**(처음 성공까지의 **횟수**)는 이산형이고, **지수분포**(다음 사건까지의 **시간**)는 연속형입니다. 이름이 비슷해서 함정으로 나옵니다.
- **분포와 쓰임 짝짓기:** 모분산을 모를 때의 평균 검정 → **t**, 범주형의 독립성 검정 → **χ^2**
- **연속형 성질:** "PDF 함숫값은 항상 0~1 사이" → **틀림** (확률은 넓이)
- 이항분포·포아송의 평균(np, λ)은 개념만 알면 됩니다. 확률 공식을 직접 계산하는 문제는 최근에 거의 없습니다.

3단원 기댓값·분산, 왜도·첨도, 공분산·상관계수

한 문장 요약: 기댓값·분산은 변수 하나의 **중심과 퍼짐**을, 왜도·첨도는 분포의 **모양**을, 공분산·상관계수는 **두 변수가 함께 움직이는 관계**를 나타냅니다.

1. 기댓값: "평균적으로 얼마가 나올까?"

E(X) = Σ (값 × 그 값이 나올 확률)

- "이 엑스"라고 읽습니다. E는 **Expectation**(기대)의 첫 글자입니다.
- 값마다 나올 확률이 다를 때 쓰는 **가중평균**입니다.

예: 뽑기 게임

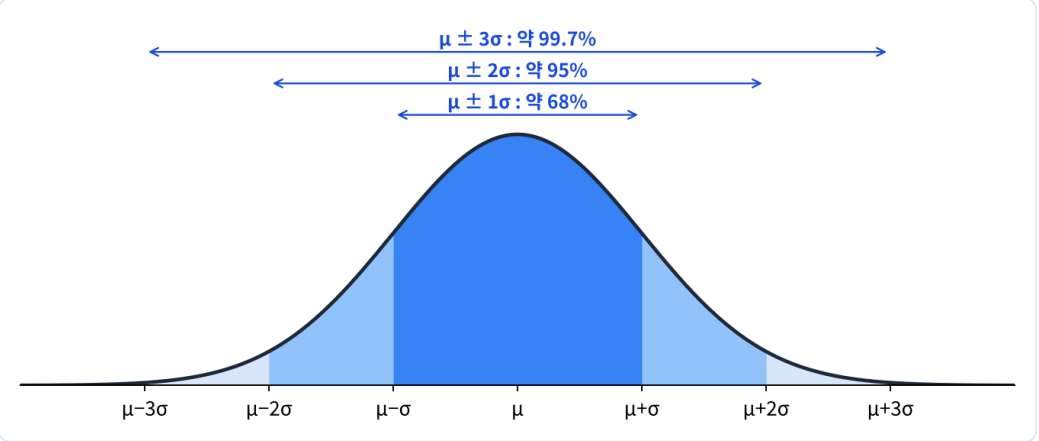
상금	0원	1,000원	10,000원
확률	0.7	0.2	0.1

- E(X) = 0×0.7 + 1,000×0.2 + 10,000×0.1 = **1,200원**. 아주 많이 하면 한 번에 평균 1,200원쯤 받는다는 뜻입니다.
- (0 + 1,000 + 10,000) ÷ 3 = 3,667원처럼 **단순 평균을 내면 틀립니다.**

2. 분산과 표준편차: "평균에서 얼마나 퍼져 있나?"

개념	계산	의미
편차	값 − 평균	평균에서 떨어진 정도 (합하면 항상 0)
분산 Var(X)	편차²의 평균	퍼진 정도. 단위가 제곱이라 읽기 어려움
표준편차	√분산	원래 단위의 퍼짐: "평균에서 **보통 이만큼** 떨어져 있다"

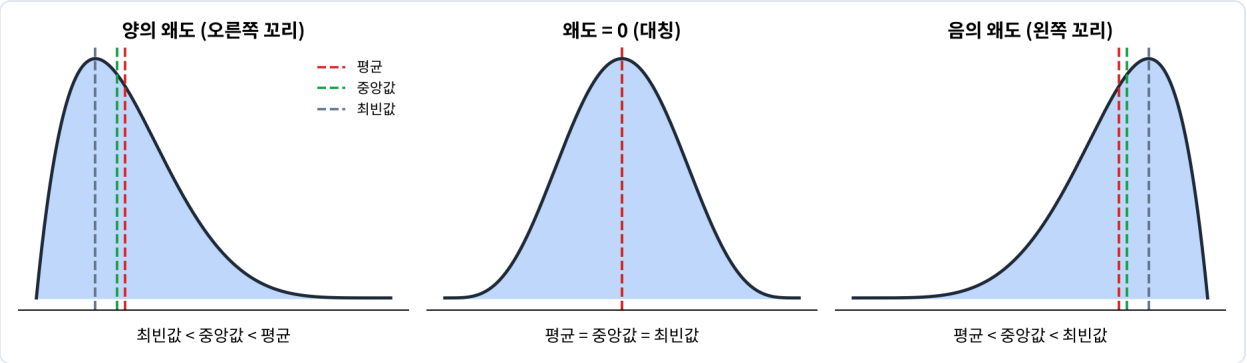
예를 들어 A반 점수가 68, 70, 72이고 B반이 40, 70, 100이면, 두 반은 **평균이 같아도 퍼짐이 다릅니다.** 그래서 평균과 표준편차를 **함께** 봐야 합니다.



▲ 정규분포에서 평균 ± 표준편차 1, 2, 3개 범위에 들어가는 비율 (68-95-99.7 규칙)

3. 왜도: "어느 쪽으로 기울었나?"

왜도	꼬리	대표값 순서	예
0	좌우 대칭	평균 = 중앙값 = 최빈값	키
양수(+)	**오른쪽**으로 김	최빈값 < 중앙값 < **평균**	**소득**
음수(−)	**왼쪽**으로 김	**평균** < 중앙값 < 최빈값	쉬운 시험 점수

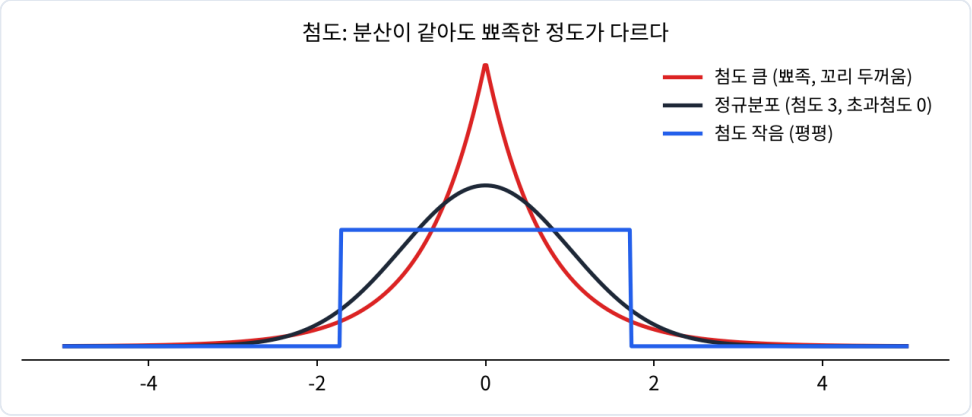


▲ 꼬리 방향에 따라 평균·중앙값·최빈값의 위치가 바뀐다

평균은 꼬리를 따라갑니다. 9명의 연봉이 3천만 원이고 1명이 30억 원이면, 평균은 약 3억 2,700만 원으로 끌려가지만 중앙값은 3천만 원 그대로입니다.

4. 첨도: "얼마나 뾰족한가?"

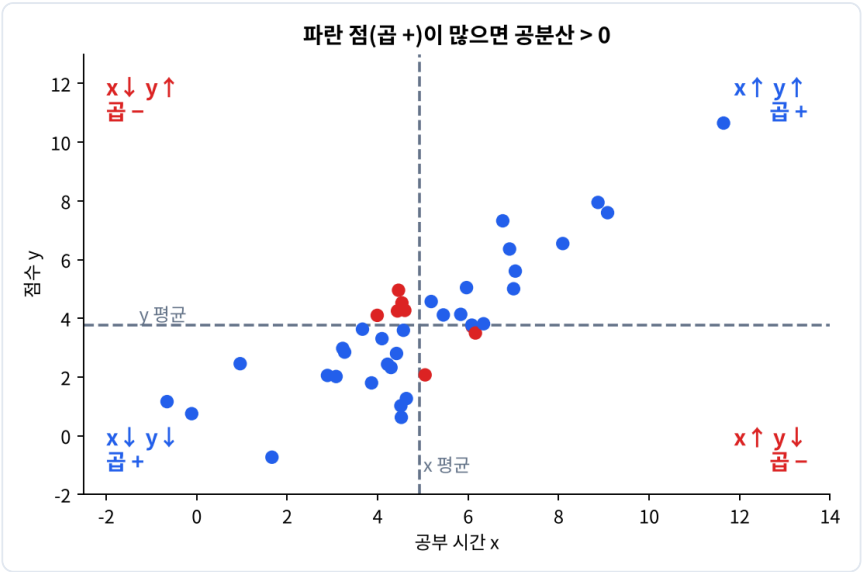
정규분포(첨도 3)를 기준으로 **뾰족하고 꼬리가 두꺼우면 첨도가 큽니다.** 3을 뺀 값(초과첨도)을 쓰기도 하며, 시험에는 개념만 나옵니다.



▲ 분산이 같아도 뾰족한 정도는 다를 수 있다

5. 공분산: "두 변수가 같은 방향으로 움직이나?"

- **공(共) = 함께**, 즉 공분산은 "두 변수가 **함께** 흩어지는 정도"입니다. 영어로는 **co**variance라고 합니다.
- 분산은 편차를 자기 자신과 곱하고$(x - \bar{x}) \times (x - \bar{x})$, 공분산은 다른 변수의 편차와 곱합니다$(x - \bar{x}) \times (y - \bar{y})$.



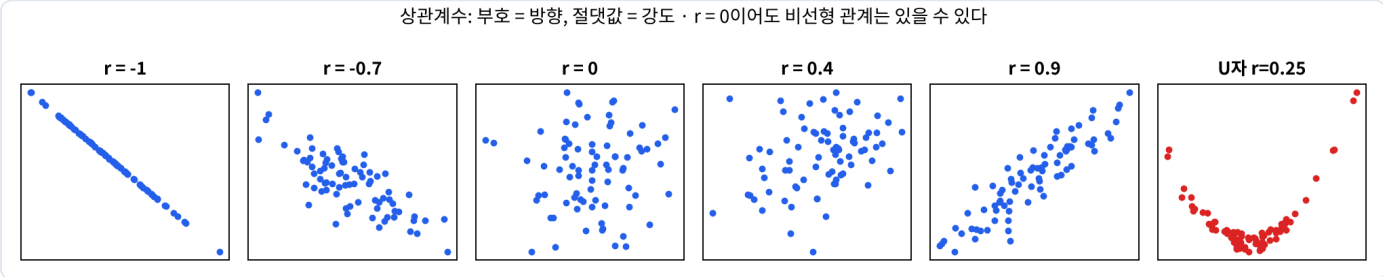
▲ 편차곱의 부호: 같은 방향이면 +, 반대 방향이면 −

공분산	뜻	예
양수	같이 커짐	공부 시간 ↑ → 점수 ↑
음수	하나가 커지면 다른 것은 작아짐	운동량 ↑ → 체중 ↓
0 근처	함께 움직이지 않음	키와 점수

공분산의 단점: 단위에 따라 값이 달라집니다(m → cm로 바꾸면 100배). 그래서 공분산으로는 **방향만** 알 수 있고 **강도는 알 수 없습니다.** 범위 제한도 없습니다.

6. 상관계수: 공분산의 단점을 고친 값

- **상관(相關) = 서로 관계가 있음**이고, 영어로는 co-relation, 즉 correlation입니다.
- 공분산을 두 표준편차로 나눠 **단위를 없앤 값**이며, 항상 **−1 ~ +1** 사이입니다.
- **부호는 방향**, **절댓값은 강도**를 나타냅니다. −0.9가 +0.3보다 **더 강한** 관계입니다.



▲ 상관계수 값과 산점도 모양. 맨 오른쪽처럼 U자 관계는 r ≈ 0이 될 수 있다

많이 틀리는 세 가지

1. **r = −1**은 "약한" 관계가 아니라 **가장 강한** 음의 관계입니다.
2. **r = 0**이 "관계 없음"을 뜻하지는 않습니다. **직선** 관계가 없다는 뜻일 뿐, U자 같은 곡선 관계는 있을 수 있습니다.
3. **상관 ≠ 인과:** 아이스크림 판매량과 물놀이 사고는 상관이 높지만, 실제 원인은 둘 다 더운 날씨입니다.

변수 변환	상관계수
모든 값에 상수를 **더함** (+10)	**그대로**
양수를 곱함 (×2, 단위 변경)	**그대로**
음수를 곱함 (×(−1))	**부호만** 반대

시험에는 이렇게 나옵니다 · 출제 유형과 함정

- **기댓값 계산:** P(X=1)=0.4, P(X=2)=0.3, P(X=3)=0.2, P(X=4)=0.1 → 1×0.4 + 2×0.3 + 3×0.2 + 4×0.1 = **2.0**. 단순 평균(2.5)이나 확률의 합(1.0)을 함정 보기로 냅니다.
- **왜도 그림:** 오른쪽 꼬리 분포에서 왼쪽부터 **최빈값 → 중앙값 → 평균**입니다. "평균 > 중앙값이면 오른쪽 꼬리"는 맞는 설명입니다.
- **상관계수 성질:** "−1이면 가장 약하다" → **틀림**. "음의 상관 = **반비례**" → **틀림**. "상관 0.8이니 광고비를 늘리면 매출이 **증가한다**" → **틀림** (인과 아님)
- **변환 계산:** r(x, y) = 0.2일 때 r(−2x + 1, y − 1) = **−0.2**. r(X + 0.3, Y + 0.2) = **그대로**
- **공분산:** "공분산은 −1과 1 사이" → **틀림** (그건 상관계수). 표본 공분산은 편차곱의 합 ÷ **(n − 1)**
- **선형변환 y = ax + b(a > 0)에도 변하지 않는 것** → **왜도** (평균·중앙값·표준편차는 변함)

4단원 추정·가설검정·비모수 검정

> **한 문장 요약: 추정**은 표본으로 모집단의 값을 **짐작**하는 것이고, **가설검정**은 표본으로 어떤 주장이 맞는지 **판단**하는 것입니다. 2장에서 시험에 가장 많이 나오는 부분입니다.

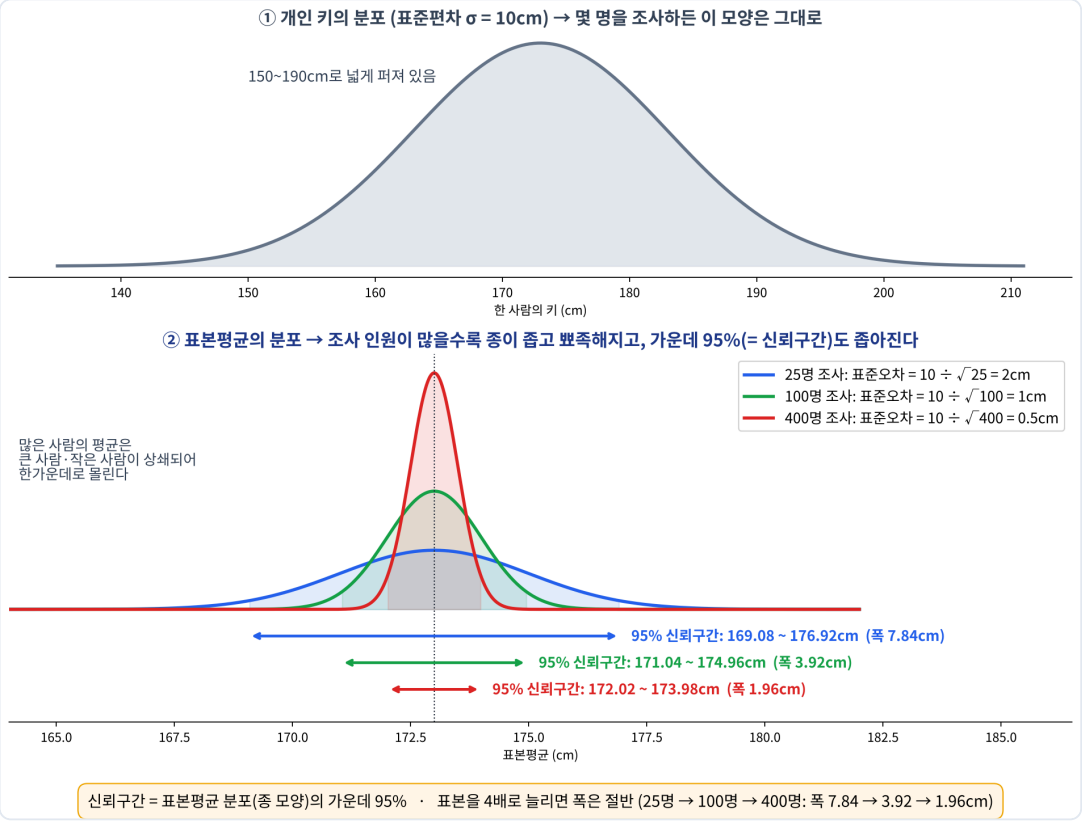
1. 추정: "모집단의 값은 얼마쯤일까?"

방법	말하는 방식	예 (100명 평균 키 170cm)
점추정	값 **하나**	"평균 키는 170cm"
구간추정	**범위**	"평균 키는 168~172cm (신뢰수준 95%)"

표본을 다시 뽑으면 평균이 매번 조금씩 달라지므로, **범위로 말하는 편이 더 정직합니다.**

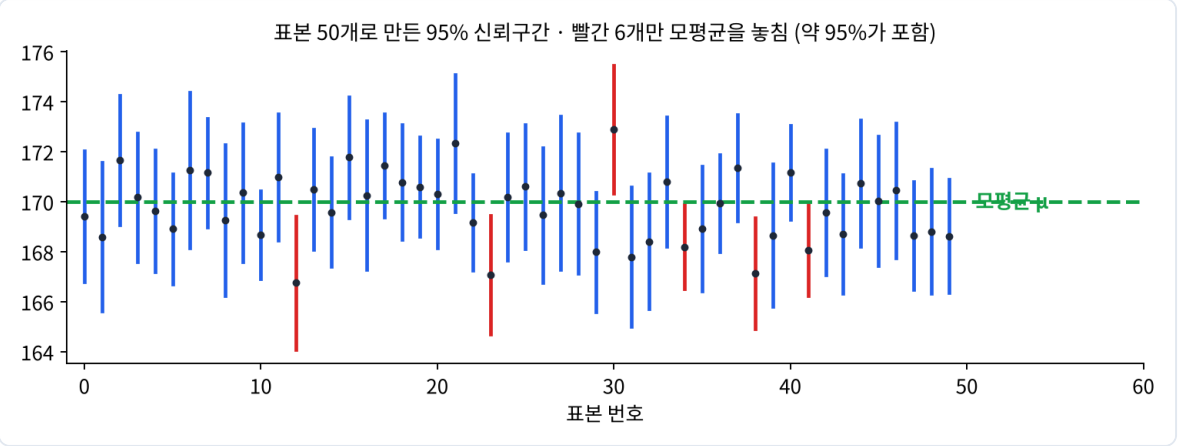
바꾸면	신뢰구간 폭	비유
신뢰수준 ↑ (95% → 99%)	**넓어짐**	더 확실히 잡으려면 그물을 넓게 던져야 함
표본 수 n ↑	**좁아짐**	정보가 많을수록 정밀해짐

왜 n이 늘면 좁아지나? 사람 한 명 한 명의 키는 그대로 넓게 퍼져 있습니다. 그러나 **여러 명의 평균**은 큰 사람과 작은 사람이 서로 상쇄되어 진짜 평균 근처에 몰립니다. 표본평균의 퍼짐(표준오차)은 **σ/√n**이라서, **n을 4배로 늘리면 폭이 절반**이 됩니다. "폭이 좁다"는 것은 "평균은 이 범위 안"이라고 **더 정밀하게** 말할 수 있다는 뜻입니다.



▲ 개인 키의 분포(위)는 그대로이고, 표본평균의 분포(아래)가 n이 커질수록 뾰족해져 95% 구간 폭이 7.84 → 3.92 → 1.96cm로 준다

신뢰수준 95%의 정확한 뜻: 같은 방법으로 표본을 **100번** 뽑아 구간을 100개 만들면, 그중 **약 95개**가 진짜 평균을 포함한다는 뜻입니다. "100번"은 비율을 설명하려고 든 예이고, 조사를 실제로 100번 한다는 뜻은 아닙니다. 진짜 평균은 고정된 값이라서, "**이** 구간에 들어 있을 확률이 95%"라고 말하면 틀린 표현입니다.



▲ 표본 50개로 만든 95% 신뢰구간: 빨간 구간만 진짜 평균을 놓쳤다

	표본오차	비표본오차
원인	**우연**(뽑힌 표본이 모집단과 조금 다름)	**실수**(질문 설계, 거짓 응답, 입력 오류)
표본 크기와의 관계	n ↑ → 줄어듦	**관계없음**

2. 가설검정: 재판에 비유하기

재판	가설검정
피고는 **무죄로 추정**	**귀무가설 H_0**: "차이·효과·관계가 **없다**(= 같다)"
검사가 증명하려는 것: 유죄	**대립가설 H_1**: 연구자가 주장하고 싶은 것
증거가 충분하면 유죄	증거가 충분하면 **H_0 기각** → H_1 채택
증거가 부족하면 무죄	**H_0 기각 못함** ("없다"가 증명된 것은 아님)

- **귀무(歸無)** = "없음(無)으로 돌아간다"이고, 영어로는 **null** hypothesis입니다.
- H_0는 "에이치 제로" 또는 "에이치 영"으로, H_1은 "에이치 원"으로 읽습니다. H는 Hypothesis의 첫 글자입니다.
- **왜 '없다'를 먼저 세울까?** "효과가 있다"는 3kg, 5kg…처럼 경우가 무한하지만, "차이 = 0"은 **딱 하나**라서 확인할 수 있습니다. 그래서 이것을 **반박**하는 방식으로 증명합니다.
- 핵심은 **등호(=)**입니다. "평균은 50g이다", "정규분포를 따른다"처럼 '없다'라는 말이 없어도 등호가 있으면 H_0입니다.
- **검정(檢定)** = 검사해서 판정한다는 뜻입니다. 영어로는 test입니다.

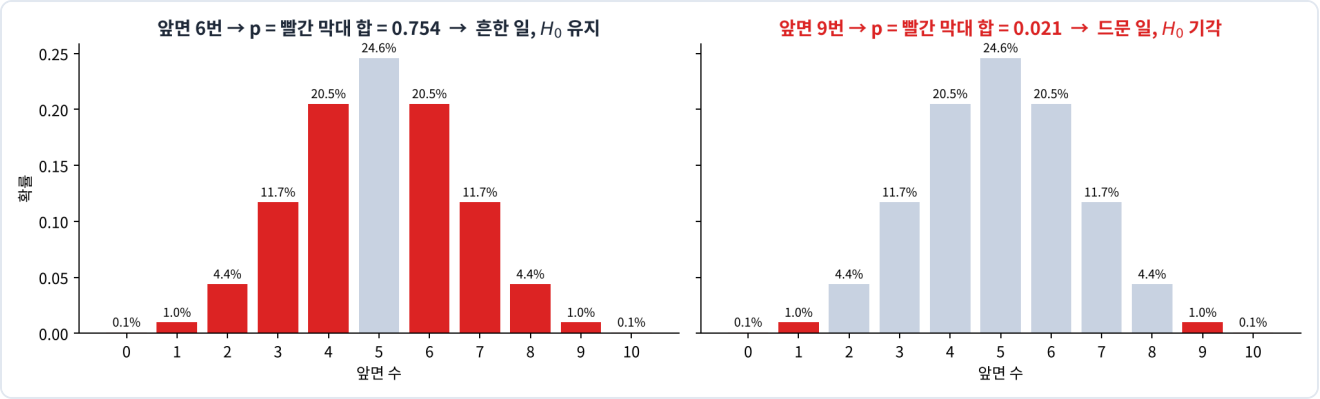
분석	H_0
t-검정 · 분산분석	평균이 **같다**
상관분석 · 회귀분석	상관계수 · 회귀계수 **= 0**
독립성 검정	두 변수는 **독립**

3. p-value(유의확률): "우연이라고 보기에 얼마나 드문가?"

p-value = H_0가 맞다고 가정할 때, 지금 결과 또는 그보다 더 극단적인 결과가 나올 확률

동전 10번 던지기 (H_0: 공정한 동전, 양측검정)

- 앞면 **6번**은 기대값 5에서 1만 벗어났습니다. 6번 이상(0~4번 포함 양쪽)이 나올 확률 = 772/1,024 ≈ **0.754** → 흔한 일 → **기각 못함**
- 앞면 **10번**: 10번 또는 0번이 나올 확률 = 2/1,024 ≈ **0.002** → 드문 일 → **H_0 기각**



▲ 공정한 동전 10번: 앞면 6번은 흔한 일, 9번 이상은 드문 일

앞면 수	6	7	8	9	10
p (양측)	0.754	0.344	0.109	**0.021**	**0.002**
판단	유지	유지	유지	기각	기각

- 실제 분석에서는 **검정통계량(t, F, χ^2)을 계산한 뒤, 분포에서 그보다 극단적인 쪽의 넓이**를 p-value로 구합니다. **통계량이 클수록 p는 작아집니다.**

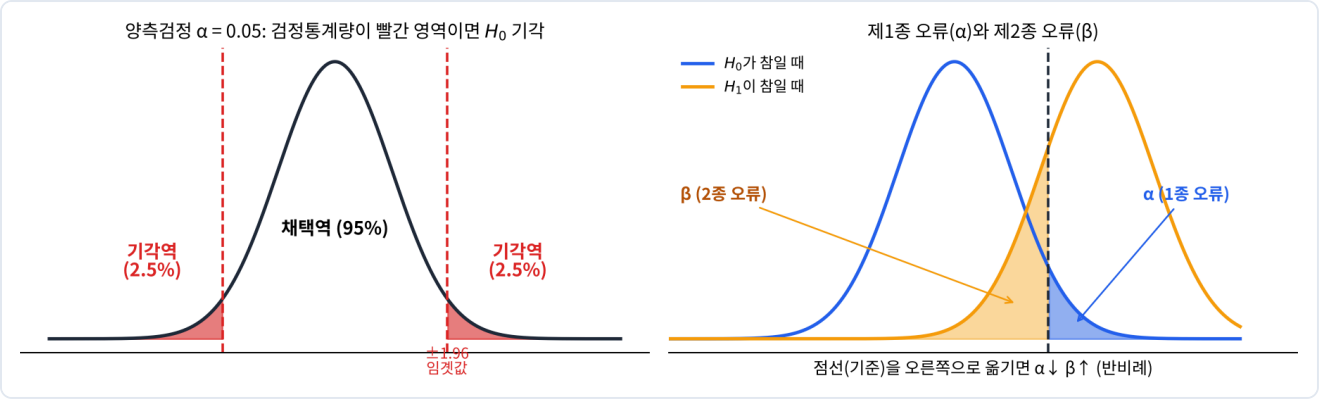
판단 규칙 (가장 중요): p < α(보통 0.05) → H_0 기각, p ≥ α → 기각 못함. **"p가 작으면 H_0를 버린다"**

용어	뜻
유의수준 α	미리 정하는 기준(보통 0.05) = 제1종 오류 확률의 **최대 허용치**
기각역	검정통계량이 여기 들어오면 H_0 기각
임곗값	기각역의 경계 (양측 α = 0.05이면 ±1.96)
양측 / 단측	"다르다(≠)" → 양쪽 꼬리 / "크다·작다" → 한쪽 꼬리

4. 제1종 오류와 제2종 오류

실제 \ 판단	H_0 기각 못함	H_0 기각
H_0 참	정답	**제1종 오류 α**: 없는데 있다고 함 (거짓 양성)
H_0 거짓	**제2종 오류 β**: 있는데 놓침 (거짓 음성)	정답, **검정력 = 1 − β**

- **예:** 화재경보기(H_0: 불 없음)에서 요리 연기에 울리면 **1종**, 불이 났는데 안 울리면 **2종**입니다. 재판에서는 무고한 사람을 유죄로 하면 **1종**, 진범을 풀어 주면 **2종**입니다.
- **이름의 유래:** 네이만과 피어슨이 "첫 번째·두 번째 종류의 오류"라고 부른 **순서 이름**입니다. 더 심각하다고 본 1종 오류를 먼저 통제하므로 **α를 먼저 정합니다.**
- **α와 β는 시소처럼 반대로 움직입니다.** 기준을 깐깐하게 하면(α↓) 놓치는 경우가 늘어납니다(β↑). 둘 다 줄이는 방법은 **표본 수를 늘리는 것**뿐입니다.
- **유의수준은 '1종 오류 자체'가 아닙니다.** 1종 오류가 일어날 **확률의 최대 허용치**입니다.



▲ 왼쪽: 기각역(양쪽 끝 2.5%씩) / 오른쪽: α와 β의 관계

5. 비모수 검정: 정규분포를 가정할 수 없을 때

모수 검정(t-검정, 분산분석)은 정규분포를 가정합니다. 이 가정을 쓸 수 없으면 값 대신 **순위**를 쓰는 **비모수 검정**을 씁니다. 표본이 아주 작을 때, 정규성이 깨질 때, **서열척도**일 때, 이상치가 있을 때가 여기에 해당합니다.

모수	비모수
평균	**중앙값**
피어슨 상관	**스피어만**
t-검정	부호 검정, **윌콕슨** 부호순위, **만-휘트니**
분산분석	**크러스컬-윌리스**

외우기: 사람 이름이 붙은 검정(윌콕슨, 만-휘트니, 크러스컬-윌리스, 스피어만, 프리드만)과 런·부호 검정은 대부분 **비모수**입니다. **t-검정과 ANOVA는 모수**입니다.

시험에는 이렇게 나옵니다 · 출제 유형과 함정

- **p-value 판단 방향 뒤집기 (가장 많음):** "p가 α보다 **크면** H_0 기각" → 틀림. "p가 작으면 **대립가설** 기각" → 틀림. "p가 **클수록** 기각 확률이 높다" → 틀림.
- **유의수준 정의:** "제1종 오류의 **최소** 허용 한계" → 틀림 (**최대**). "α를 너무 작게 하면 2종 오류가 커진다" → 맞음.
- **오류 정의 바꿔치기:** "H_0 **참**인데 **기각** → 1종", "H_0 **거짓**인데 채택 → 2종". 검정력 = **1 − β**
- **신뢰구간:** "신뢰수준 ↑ → 구간 넓어짐" → 맞음. "신뢰수준은 이 구간에 모수가 포함될 **확률**" → 틀림.
- **비표본오차는 표본을 늘리면 줄어든다** → 틀림
- **계산:** 동전 5번이 모두 앞면일 때 양측 $p = (1/2)^5 \times \mathbf{2} = 1/16 \approx 0.0625 > 0.05$이므로 **기각 못함**. 1/32로 답하게 유도하는 함정입니다.
- **비모수가 아닌 것 → t-검정**

5단원 t-검정·분산분석·교차분석·상관분석

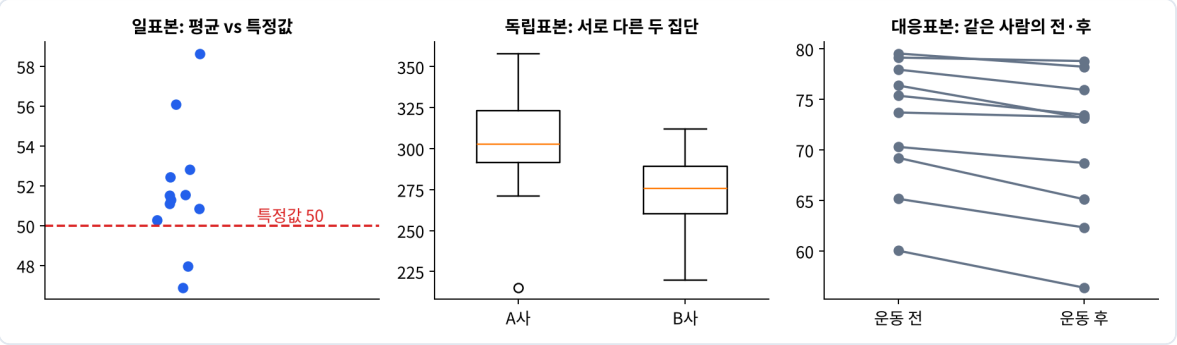
한 문장 요약: 4단원의 가설검정을 실제 상황에 적용하는 **도구 4가지**입니다. 무엇을 비교하느냐에 따라 도구를 고르고, 판단 규칙은 모두 **$p < 0.05$이면 H_0 기각**입니다.

알고 싶은 것	도구	예
평균 비교 (집단 **2개 이하**)	**t-검정**	남녀 평균 키가 다른가?
평균 비교 (집단 **3개 이상**)	**분산분석(ANOVA)**	A·B·C 반 평균이 다른가?
범주형 변수끼리의 관계	**교차분석(χ^2)**	성별과 선호 브랜드는 관계가 있나?
숫자형 변수끼리의 관계	**상관분석**	공부 시간과 점수는 관계가 있나?

1. t-검정: 평균이 다른가?

- **t 분포를 이용하는 검정**입니다. 기네스 맥주 회사 직원 고셋이 **적은 표본**으로 품질을 판단하려고 만들었고, 필명 "Student"로 발표해서 **스튜던트 t 분포**라고 부릅니다.

종류	비교 대상	예
일표본	한 집단의 평균 vs **특정 숫자**	지우개 평균 무게는 50g인가?
독립표본	**서로 다른** 두 집단	A회사와 B회사의 급여
대응표본	**같은 사람**의 전·후	다이어트 전·후 체중



▲ 세 가지 t-검정이 비교하는 대상

- **사람이 다르면 독립표본, 같은 사람을 두 번 재면 대응표본**입니다. 대응표본은 차이값(후 − 전)만 보므로 개인차가 제거됩니다.
- 독립표본은 먼저 **등분산 검정(F 검정)**으로 두 집단의 퍼짐이 같은지 확인합니다.

R 출력에서 볼 곳 (대응표본 예)

```
t.test(before, after, paired = TRUE)
t = 5.4772, df = 9, p-value = 0.0001958
95 percent confidence interval:  1.12  2.68
mean difference  1.9
```

- **p-value**를 α와 비교합니다. 이 예는 0.0002 < 0.05이므로 **기각**입니다.
- **df(자유도)로 데이터 수를 역산**합니다.

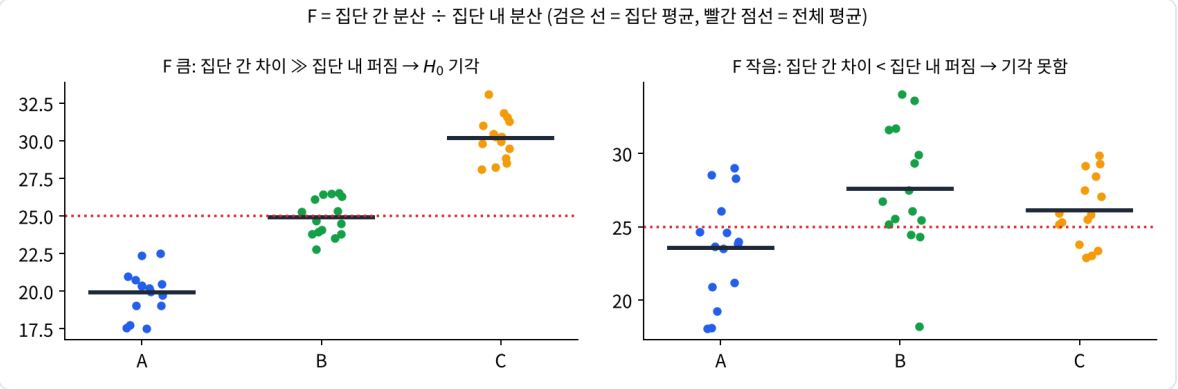
분석	df	df = 9이면
일표본·대응표본	$n - 1$	**10개(10쌍)**
독립표본(등분산)	$n_1 + n_2 - 2$	두 집단 합쳐 11개

- **신뢰구간에 0이 없으면** 차이가 유의하다는 뜻입니다.
- **차이의 부호를 확인**합니다. 평균 차이(A − B)가 **음수**면 A가 **작습니다**.

2. 분산분석(ANOVA): 집단 3개 이상의 평균 비교

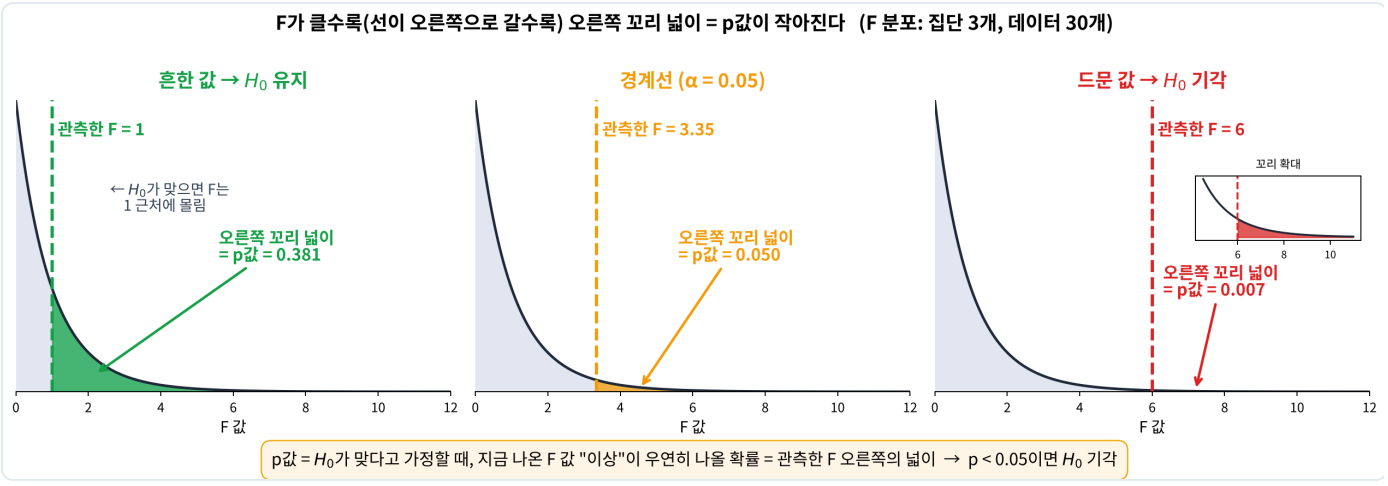
- t-검정을 A-B, A-C, B-C로 여러 번 하면 **1종 오류가 쌓입니다.** 그래서 한 번에 비교합니다.

- **평균을 비교하는데 왜 '분산'분석일까?** F = **집단 간 분산 ÷ 집단 내 분산**으로 판단하기 때문입니다. F는 이를 만든 **피셔(Fisher)**의 첫 글자입니다.



▲ 왼쪽: 반끼리 차이가 크고 반 안은 고름 → F 큼 / 오른쪽: 반 안이 들쭉날쭉 → F 작음

F가 크면 p가 왜 작아질까? H_0가 맞으면 F는 대개 1 근처에 나옵니다. p는 관측한 F의 **오른쪽 꼬리 넓이**이므로, F가 클수록 꼬리가 얇아지고 p가 작아집니다.



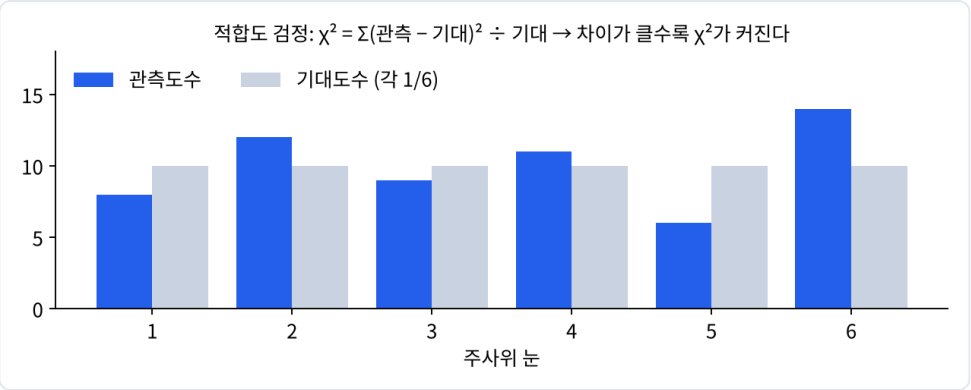
▲ F가 커질수록(선이 오른쪽으로 갈수록) p값 = 오른쪽 꼬리 넓이가 작아진다

- **H_0: 모든 집단 평균이 같다**, H_1: **적어도 하나**는 다르다
- H_0를 기각해도 **어느 집단이 다른지는 모릅니다.** 그래서 **사후검정**(Tukey, Scheffe, Duncan 등)으로 확인합니다.
- **일원** = 요인 1개(반별), **이원** = 요인 2개(반 × 성별)입니다. 이원에서는 **교호작용**도 봅니다.
- 조건은 **정규성, 등분산성, 독립성**입니다.

3. 교차분석: 범주형끼리 관계가 있나?

- 교차표로 개수를 세고, **관측도수와 기대도수의 차이**를 χ^2로 계산합니다. 차이가 클수록 χ^2가 커집니다.

검정	질문	예
적합도	관측이 **예상한 분포**와 맞나?	주사위 60번 → 각 눈이 10번씩?
독립성	두 범주형 변수가 **관계없나**?	성별과 브랜드 선호
동질성	여러 집단의 분포가 **같나**?	나라별 브랜드 선호 비율



▲ 적합도 검정: 관측도수(파랑)와 기대도수(회색)의 차이

```
chisq.test(table(gender, brand))
X-squared = 7.32, df = 2, p-value = 0.0257
```

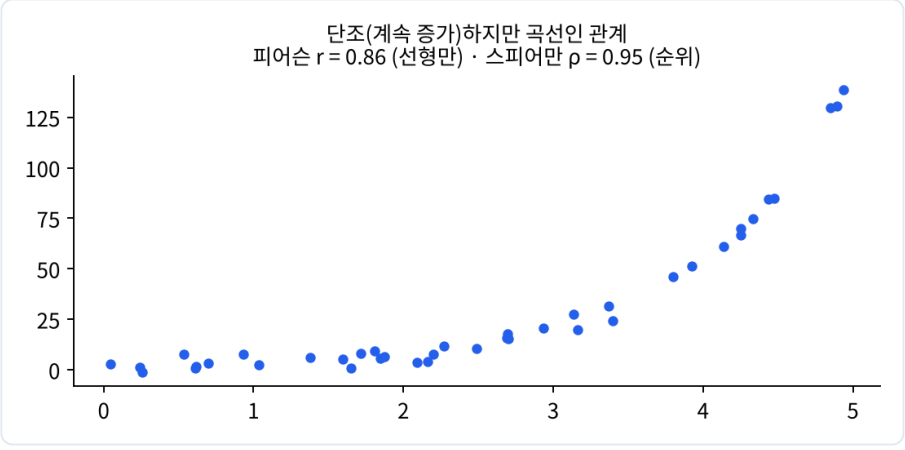
- `X-squared`가 카이제곱 통계량입니다. p < 0.05이면 "관계가 있다"입니다.
- 독립성 검정은 관계의 **유무**만 알려 주고, **강도**는 알려 주지 않습니다.

4. 상관분석: 숫자형끼리 관계가 있나?

- **H_0: 상관계수 = 0**입니다. 교재 예(공부 시간과 점수, 10명)는 r = 0.736, p = 0.015 < 0.05 → **유의한 양의 상관**입니다.
- 관계를 눈으로 볼 때는 **산점도**를 쓰고, 여러 변수를 한 번에 볼 때는 **산점도 행렬**을 씁니다.

```
cor.test(time, score, method = "pearson")
t = 3.0811, df = 8, p-value = 0.01511
cor 0.7366
```

피어슨	스피어만
값 그대로 계산	**순위**로 바꿔 계산
연속형, 정규성 가정 (모수)	**서열척도** 가능 (비모수)
직선 관계	계속 오르거나 내리면 곡선도 가능 (**단조** 관계)



▲ 단조 곡선 관계에서는 스피어만이 더 크게 나온다

시험에는 이렇게 나옵니다 · 출제 유형과 함정

- **R 출력 해석 (가장 많음):**
- 일표본 p = 0.001 → "기각하지 **못한다**" → 틀림. df = 99 → **n = 100**
- 독립표본 p = 0.031 → "유의수준 **0.01**에서도 기각" → 틀림. **α가 0.05인지 0.01인지** 확인합니다.
- 대응표본 평균 차이(A − B) = −1.58 → "A가 B보다 1.58 **길다**" → 틀림 (A가 **짧음**)

- **분산분석:** "분산분석만으로 **어느 집단이** 다른지 안다" → 틀림 (사후검정 필요). "이원분산분석은 독립변수가 **하나**" → 틀림.
- **교차분석:** "두 변수가 **연속형**이어도 가능" → 틀림 (범주형). "독립성 검정은 여러 요인이 관찰값에 영향을 주는지 검정" → 틀림 (분산분석·회귀).
- **상관분석:** "상관분석으로 종속변수를 **예측**" → 틀림 (예측은 회귀). 단조 비선형 관계 → **스피어만**. 두 연속형 변수 관계를 보는 그래프 → **산점도**.

6단원 회귀분석 ① 개요~결과 해석

한 문장 요약: 회귀분석은 **원인(X)으로 결과(Y)를 설명하고 예측하는 식**을 만드는 것입니다. 상관분석이 "관계가 있나?"까지라면, 회귀분석은 **"X가 1 늘면 Y는 얼마나 변하나?"**를 알려 줍니다. 거의 모든 내용이 시험에 나오고, 특히 **R 출력 해석**이 중요합니다.

1. 회귀식과 용어

예: 배기량(X)과 연비(Y) → 연비 = 16.83 − 2.44 × 배기량. 배기량이 2.5L면 16.83 − 2.44 × 2.5 ≈ **10.7km/L**로 **예측**할 수 있습니다.

용어	다른 이름	예
독립변수 X	설명변수, 원인변수	배기량
종속변수 Y	반응변수, 결과변수	연비
절편 β_0	Intercept	16.83 (X = 0일 때 Y)
회귀계수 β_1	기울기	−2.44 (**X 1 증가 → Y 2.44 감소**)

중학교에서 배운 y = ax + b와 같은 구조입니다.

종류	특징	식
단순 회귀	X **1개**, 직선	$Y = \beta_0 + \beta_1 X + \varepsilon$
다중 회귀	X **2개 이상**	$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots + \varepsilon$
다항 회귀	X 1개로 **곡선**	$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \varepsilon$
로지스틱 회귀	Y가 **범주형** (합격/불합격)	$\log(p/(1-p)) = \beta_0 + \beta_1 X$

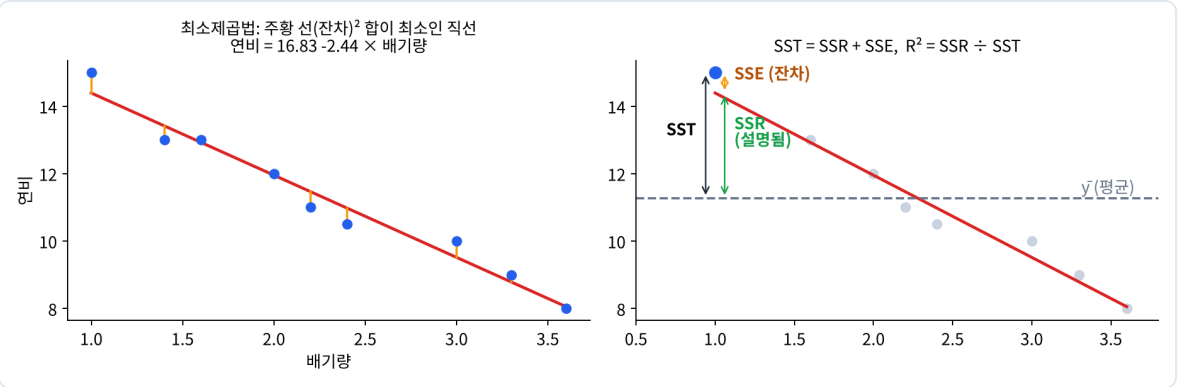
- **구분 요령:** 단순·다중은 **X의 개수**, 다항은 **X의 차수**, 로지스틱은 **Y의 종류**로 나눕니다.
- **다항회귀도 선형회귀입니다.** "선형"은 그래프 모양이 아니라 **β에 대해 일차식**이라는 뜻입니다. X^2은 데이터로 계산한 숫자일 뿐이라 $Z = X^2$로 바꾸면 다중회귀와 같은 모양이 됩니다. 반면 $Y = \beta_0 \cdot e^{(\beta_1 X)}$처럼 β가 지수에 있으면 비선형입니다.
- **로지스틱:** 결과 p는 항상 0~1 사이(S자 곡선)이고, 0.5 이상이면 1로 분류합니다. X가 1 늘면 **오즈가 e^{β_1}배**가 됩니다.

이름의 유래: 골턴이 부모와 자녀의 키를 연구했을 때, 키가 아주 큰 부모의 자녀도 **평균 쪽으로 돌아가는(회귀하는)** 경향이 있었습니다.

모형 = 모델: 같은 말입니다(model). 통계에서는 "모형", 머신러닝에서는 "모델"을 주로 씁니다.

2. 최소제곱법: 직선을 정하는 법

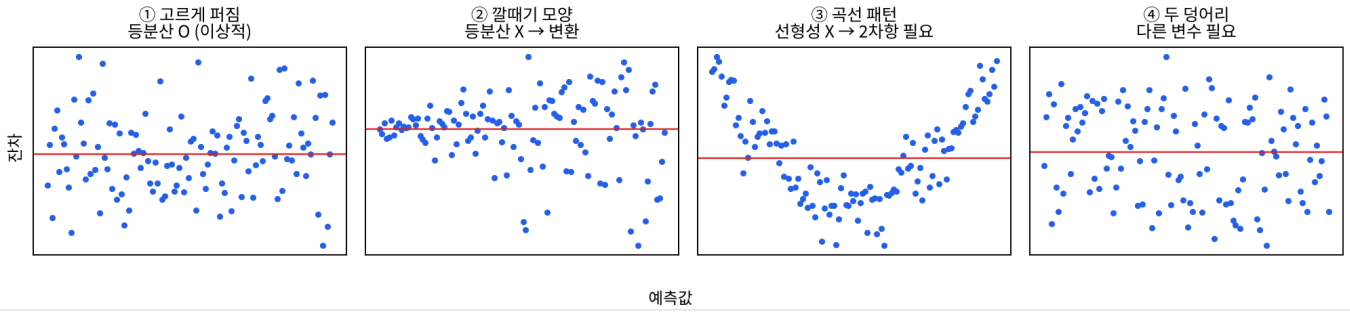
- **잔차** = 실제값 − 예측값, 즉 점과 직선 사이의 세로 거리입니다.
- **잔차 제곱의 합(SSE)이 가장 작은 직선**을 고릅니다. 제곱하는 이유는 +와 −가 서로 상쇄되지 않게 하려는 것입니다.
- **오차**는 모집단(진짜 식) 기준이라 알 수 없고, **잔차**는 표본으로 만든 식 기준이라 계산할 수 있습니다.



▲ 왼쪽: 잔차 제곱합이 최소인 직선 / 오른쪽: SST = SSR + SSE

3. 회귀분석의 4가지 가정 (잔차로 확인)

가정	뜻	확인
선형성	X와 Y가 직선 관계	산점도
독립성	**잔차**끼리 영향이 없음	더빈-왓슨 검정
등분산성	잔차가 어디서나 **고르게** 퍼짐	잔차도
정규성	잔차가 **정규분포**	Q-Q plot, 샤피로-윌크



▲ 잔차도 읽기: ① 고르게 흩어짐(좋음) ② 깔때기(등분산 위반) ③ U자(선형성 위반 → 2차항 추가) ④ 정규성 확인

4. 결과는 세 가지를 확인합니다

순서	질문	보는 것	판단
①	식 **전체**가 쓸모 있나?	**F-검정** p값	p < 0.05 → 모형 유의
②	**각 변수**가 쓸모 있나?	각 변수의 **t-검정** p값 (t = 계수 ÷ 표준오차)	p < 0.05 → 그 변수 유의
③	얼마나 잘 설명하나?	**결정계수 R^2**	0~1, 1에 가까울수록 좋음

변동의 분해: SST = SSR + SSE

약자	풀네임	뜻
SST	Sum of Squares **Total**	실제값이 평균에서 퍼진 **전체**
SSR	Sum of Squares **Regression**	회귀식이 **설명한** 부분
SSE	Sum of Squares **Error**	회귀식이 **설명하지 못한** 부분

- **R^2 = SSR ÷ SST.** R^2 = 0.65이면 Y 변동의 **65%를 설명한다**는 뜻입니다.
- R^2는 **0~1**이고 음수가 될 수 없습니다. 회귀계수(기울기)와 결정계수(설명력)는 **다른 것**입니다.
- R^2는 쓸모없는 변수를 넣어도 커지므로, 다중회귀에서는 **수정된 R^2**(Adjusted)를 봅니다.
- 다른 책에서는 SSR을 Residual(잔차)로 쓰기도 합니다. 시험은 **교재 기준(SSR = 회귀)**으로 기억하면 됩니다.

5. R 출력 읽기

```
summary(lm(Y ~ X))
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  16.8291     0.4142   40.63 1.43e-09 ***
X            -2.4371     0.1707  -14.27 1.97e-06 ***
Residual standard error: 0.4277 on 7 degrees of freedom
Multiple R-squared:  0.9668,  Adjusted R-squared:  0.962
F-statistic: 203.7 on 1 and 7 DF,  p-value: 1.97e-06
```

위치	읽기
`Estimate`	**회귀식 Y = 16.83 − 2.44X**
`Pr(>|t|)`, `***`	각 변수의 p값 (별이 많을수록 유의)
`Multiple R-squared`	**96.7% 설명**
`on 7 degrees of freedom`	잔차 df = **n − k − 1** → 7 = n − 1 − 1 → **n = 9**
`F-statistic ... p-value`	모형 전체가 유의

분산분석표 (`anova()` 출력: 변수 행의 `Sum Sq` = SSR, `Residuals` 행 = SSE)

요인	제곱합	자유도	제곱평균	F
회귀	SSR	k	MSR = SSR ÷ k	MSR ÷ MSE
잔차	SSE	n − k − 1	**MSE = SSE ÷ (n − k − 1)**	
총	SST	n − 1		

시험에는 이렇게 나옵니다 · 출제 유형과 함정

- **회귀식 쓰기:** 절편 96.04, 계수 1.97 → $\hat{y}$ **= 96.04 + 1.97x**
- **계산:**
- R^2 = SSR ÷ SST
- 단순회귀에서 SSE = 20, n = 10 → MSE = 20 ÷ (10 − 2) = **2.5**
- 회귀 SS 120, 총 SS 150, 총 df 16 → SSE = 30, 잔차 df = 15 → MSE = **2**, R^2 = **4/5**, n = **17**
- **가정:** 단순회귀의 독립성은 **잔차**에 대한 가정입니다. **U자 잔차도** → 비선형성이므로 비선형 모델이나 2차항이 필요합니다. "**종속변수**와 잔차는 무상관" → 틀림 (**독립변수**와 무상관).
- **해석 함정:**
- "R^2는 **−1~1**" → 틀림 (0~1)
- R^2 = 0.563 → "약 75% 설명" → 틀림 (**56.3%**)
- "회귀로 **원인이라고 단정**" → 틀림
- "계수가 크니 **더 중요한 변수**" → 틀림 (단위가 다름)
- "유의하지 않은 변수를 빼고 **기존 계수를 그대로**" → 틀림 (다시 분석해야 함)
- "**설명변수 간 상관계수**로 모형 적합성 판단" → 틀림 (F, R^2, 잔차로 판단)

7단원 회귀분석 ② 다중공선성·변수 선택·고급 회귀

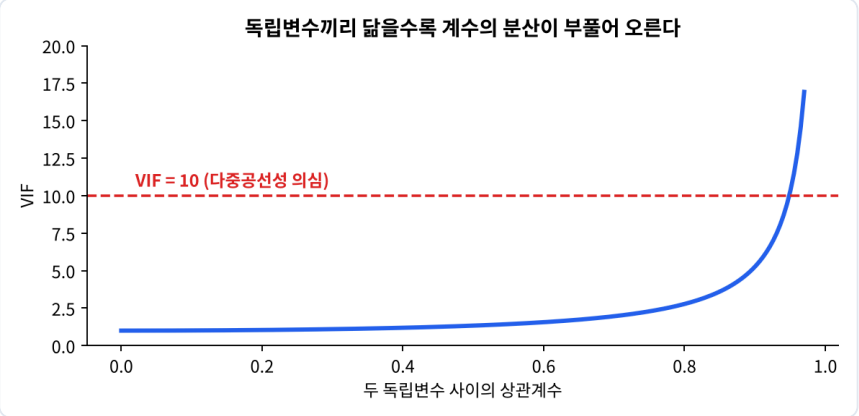
한 문장 요약: 6단원가 회귀식을 **만들고 읽는 법**이었다면, 7단원는 **더 좋은 회귀식을 만드는 법**입니다. 변수끼리 너무 닮은 문제(**다중공선성**), 변수를 고르는 법(**변수 선택**), 과적합을 막는 법(**정규화**)을 다룹니다.

1. 다중선형회귀

- X가 여러 개인 회귀입니다. 예: 집값 = 마당 면적 + 집 면적 + 주차 대수 + 편의점 거리
- 해석 방법은 6단원와 같습니다. **F → 모형 전체, t → 각 변수, 수정된 R^2 → 설명력**
- p > 0.05인 변수는 빼고 **다시 분석**합니다.

2. 다중공선성: 독립변수끼리 너무 친한 문제

- **독립변수들끼리 강한 상관관계가 있는 것**을 다중공선성이라고 합니다.
- 예: 집 면적과 방 개수를 함께 넣으면, 집값이 오른 게 면적 때문인지 방 개수 때문인지 구분하지 못합니다.
- 그 결과 **회귀계수의 분산이 커져서 불안정**해집니다. 데이터가 조금만 바뀌어도 계수가 크게 흔들리고 부호가 바뀌기도 합니다.



▲ 독립변수끼리 상관이 높을수록 VIF가 급격히 커진다

진단 신호	설명
R^2는 높은데 각 변수의 p가 큼	전체로는 잘 맞는데 개별 변수는 유의하지 않음
독립변수끼리 상관계수가 높음	상관계수 행렬로 확인
VIF > 10	분산팽창요인(Variance Inflation Factor): 계수의 분산이 몇 배로 부풀었나

해결 방법: ① 문제 변수 **제거** ② **주성분분석(PCA)**으로 합치기 ③ **릿지** 등 정규화

3. 변수 선택: 어떤 변수를 넣을까?

방법	방식	비유
전진선택법	빈 모형에서 하나씩 **추가**	빈 장바구니에 하나씩 담기
후진제거법	전부 넣고 하나씩 **제거**	꽉 찬 장바구니에서 하나씩 빼기
단계별 방법	추가하면서 제거도 함께 검토	담으면서 중간중간 정리

p > 0.05인 변수는 한꺼번에 빼지 않고 하나씩 뺍니다. p값이 가장 큰 변수 1개를 빼고 다시 분석하면, 남은 변수들의 p값이 바뀝니다. 비슷한 변수끼리 설명력을 나눠 갖고 있다가 하나가 빠지면 다른 하나가 유의해질 수 있기 때문입니다.

선택 기준 AIC, BIC: 잘 맞을수록 점수가 좋아지고, 변수가 많을수록 **벌점**을 줍니다. **둘 다 작을수록 좋은 모형**입니다. **BIC**가 벌점이 더 커서 더 단순한 모형을 고릅니다. **멜로우 Cp**는 Cp가 모수 개수 p와 비슷하거나 작으면 좋은 모형입니다.

```
step(lm(price ~ ., data = house), direction = "backward")
Start:  AIC=814.3
price ~ dist + area + popul + park + yard
         Df Sum of Sq    RSS    AIC

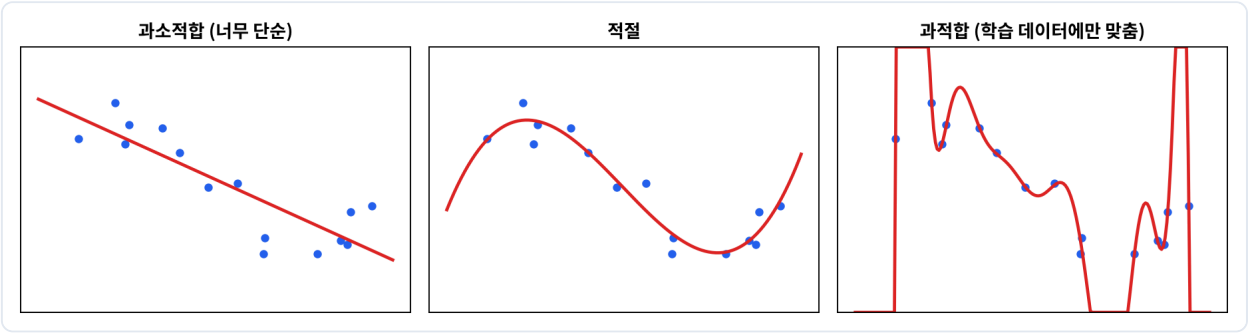
- popul   1      38.1  51022  812.4
<none>                 50984  814.3
...                             (나머지 - 변수 행 생략)

Step:  AIC=812.4
price ~ dist + area + park + yard
```

- direction: `"forward"` 전진선택, `"backward"` 후진제거, `"both"` 단계별. 출력에서 **`-`는 빼 보기, `+`는 넣어 보기**입니다. 후진제거법이므로 `-` 행만 나옵니다.
- popul을 **빼면 AIC가 814.3 → 812.4로 작아지므로** 제거됩니다. 더 빼서 AIC가 줄어드는 변수가 없으면 멈춥니다.
- 교재 실습에서는 세 방법 모두 dist, area, park, yard를 선택했습니다.
- 출력은 AIC가 **가장 작은** 모형을 최종 선택합니다.

4. 과적합과 정규화

	과소적합	적절	과적합
모델	너무 단순	적당	**너무 복잡**
학습 데이터 성능	낮음	좋음	**아주 높음**
새 데이터 성능	낮음	좋음	**낮음**
비유	공부 안 함	원리 이해	**기출 답만 통째로 외움**

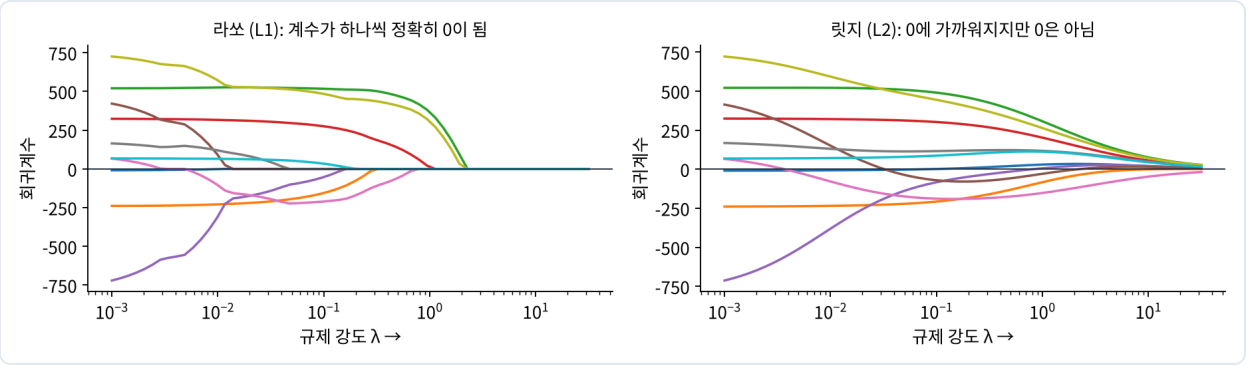


▲ 과소적합 · 적절 · 과적합

과적합은 인공지능 모델만의 문제가 아닙니다. 회귀를 포함해 **데이터로 학습한 모든 예측 모형**에서 생깁니다.

정규화 선형회귀: 과적합되면 계수가 지나치게 커지므로, **계수 크기에 벌점**을 줘서 누릅니다.

방법	벌점	결과
라쏘 (L1)	계수 **절댓값** 합	일부 계수를 **정확히 0**으로 만들어 **변수 선택** 효과
릿지 (L2)	계수 **제곱** 합	**0에 가깝게** 줄이지만 0은 아님. **다중공선성 완화**
엘라스틱넷	L1 + L2	둘을 합침



▲ 규제를 세게 할수록: 라쏘는 계수가 0이 되고, 릿지는 0에 가까워질 뿐이다

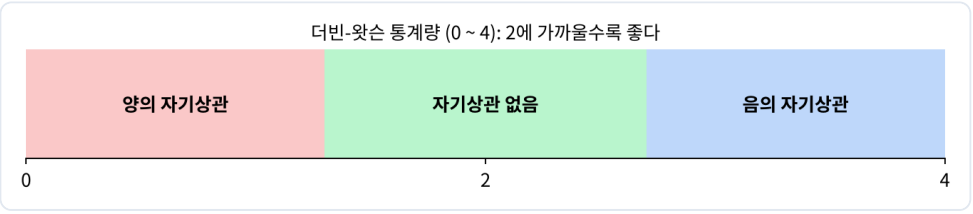
외우기: Lasso는 변수를 **L**ose(잃음)하고, 릿지는 줄이기만 합니다.

5. 그 밖의 고급 내용

일반화 선형회귀(GLM): Y가 정규분포 연속형이 아닐 때 연결 함수로 변환해서 씁니다.

종류	Y	예
로지스틱	범주형(0/1)	합격/불합격
포아송	횟수	사고 건수

더빈-왓슨 검정: 잔차끼리 독립인지(**자기상관**) 확인합니다. 범위는 0~4이고 **2 근처가 좋습니다.**



▲ 더빈-왓슨 통계량 읽기

회귀 평가 지표 (작을수록 좋음)

약자	풀네임	계산
MAE	Mean Absolute Error	평균 |실제 − 예측|
MSE	Mean Squared Error	평균 (실제 − 예측)², 큰 오차에 민감
RMSE	Root MSE	√MSE, 원래 단위
MAPE	Mean Absolute Percentage Error	오차 비율(%)의 평균

시험에는 이렇게 나옵니다 · 출제 유형과 함정

- **다중공선성 (가장 자주):** "독립변수들 간 강한 상관 문제는?" → **다중공선성**. "다중공선성이 있어도 회귀계수의 분산은 **항상 동일**" → 틀림 (**커짐**). "해결 방안이 **아닌** 것" → **로지스틱 회귀** (라쏘·릿지·엘라스틱넷·PCA·변수 제거는 해결책)
- **변수 선택:** "모든 변수를 넣은 모형에서 하나씩 제거" → **후진제거법**. 전진과 후진의 설명을 바꿔 놓은 보기가 함정으로 나옵니다.
- **함께 알아 둘 것:** 라쏘 = 계수 **0**, 릿지 = **0에 가깝게** / AIC·BIC는 **작을수록** 좋음 / 더빈-왓슨 **2** = 자기상관 없음 / 과적합 = 새 데이터에서 성능 ↓

8단원 다변량 분석: MDS·PCA

한 문장 요약: 변수가 많아 한눈에 보기 어려운 데이터를 **간단하게** 만드는 방법입니다. **MDS**는 개체 사이 **거리**를 **지도**로 그리고, **PCA**는 비슷한 변수를 **합쳐 개수를 줄입니다.**

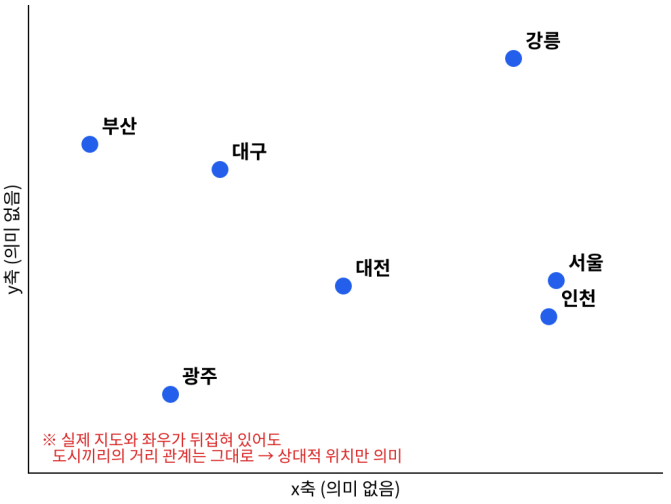
1. 다차원 척도법 (MDS, Multidimensional Scaling)

비유: 도시 사이 **거리표만** 있어도, 거리를 최대한 지키도록 점을 찍으면 대략적인 **지도**가 됩니다. MDS가 바로 이 일을 합니다.

① 입력: 도시 사이 거리표 (km)

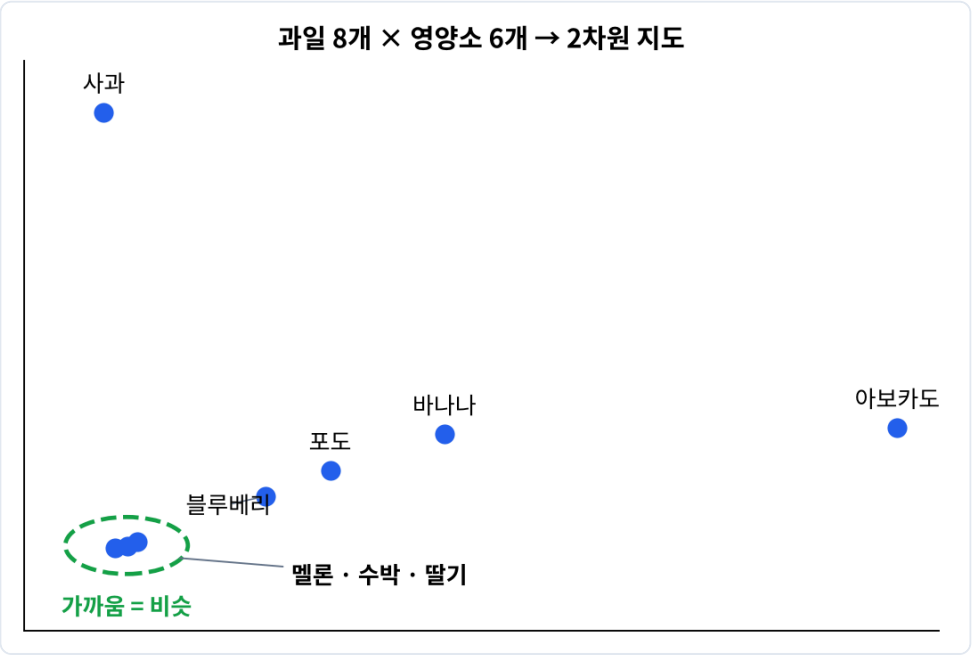
	서울	인천	대전	대구	광주	부산	강릉
서울	-	27	140	236	268	323	170
인천	27	-	137	243	256	329	196
대전	140	137	-	120	140	198	205
대구	236	243	120	-	173	87	210
광주	268	256	140	173	-	196	339
부산	323	329	198	87	196	-	286
강릉	170	196	205	210	339	286	-

② 출력: 거리만으로 그린 2차원 지도



▲ 거리표(입력)만으로 2차원 지도(출력)를 그린다. 좌우가 뒤집혀도 거리 관계는 같다

교재 예시: 과일 8개 × 영양소 6개는 6차원이라 볼 수 없습니다. 2차원 지도로 그리면 멜론·수박·딸기가 **가까이** 모이므로 영양소가 비슷하다는 것을 알 수 있습니다. 사과와 아보카도는 **멀리** 떨어집니다.



▲ 가까울수록 비슷한 과일

- **x축, y축 자체에는 의미가 없습니다.** 누가 누구와 가까운지, 즉 **상대적 위치**만 봅니다. **절대적 위치는 알 수 없습니다.**
- 거리는 주로 **유클리디안 거리**(직선거리)로 계산합니다.
- 목적은 **시각화**입니다. 그룹을 만드는 군집분석과는 다릅니다.

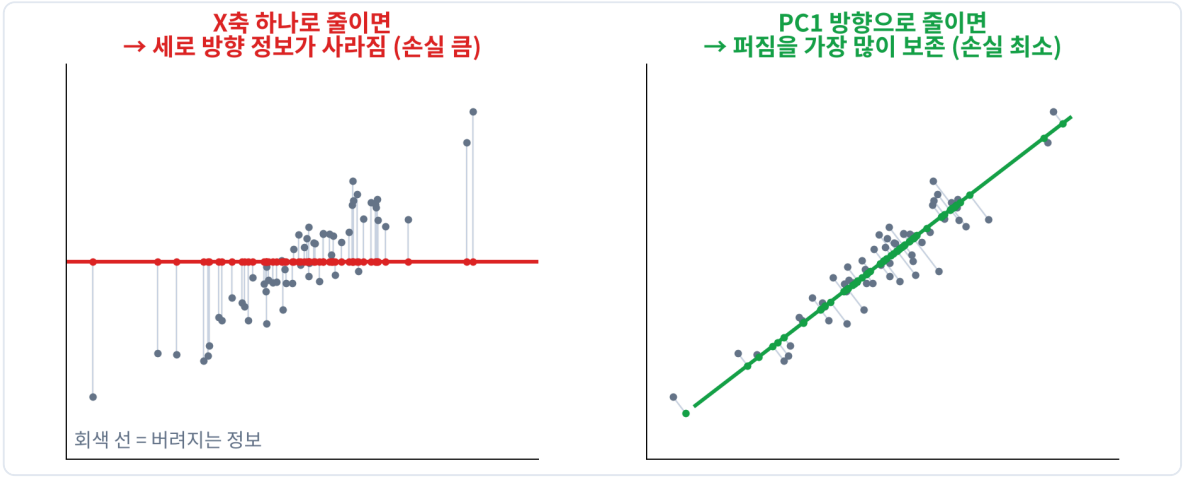
적합도 Stress: 지도 위 거리가 원래 거리와 얼마나 어긋났는지 나타냅니다. **0~1이고 낮을수록 좋습니다.**

Stress	0	0~0.05	0.05~0.1	0.1~0.15	0.15 이상
적합도	완벽	**매우 우수**	우수	보통	**나쁨**

계량적 MDS	비계량적 MDS
구간·비율척도 (실제 거리 숫자)	**서열척도** (순서만 있음)
`cmdscale(dist(x), k = 2)`	`MASS::isoMDS(dist(x), k = 2)`

2. 주성분분석 (PCA, Principal Component Analysis)

비유: 국어·영어·수학·과학·사회 5개 점수는 서로 상관이 높습니다(잘하는 학생은 대체로 다 잘함). 이것을 **PC1 = 종합 학업 능력**, **PC2 = 문과·이과 성향**으로 요약하면 **5개를 2개로** 줄일 수 있습니다. 주성분은 원래 변수에 **가중치(계수)**를 곱해 더한 것입니다.

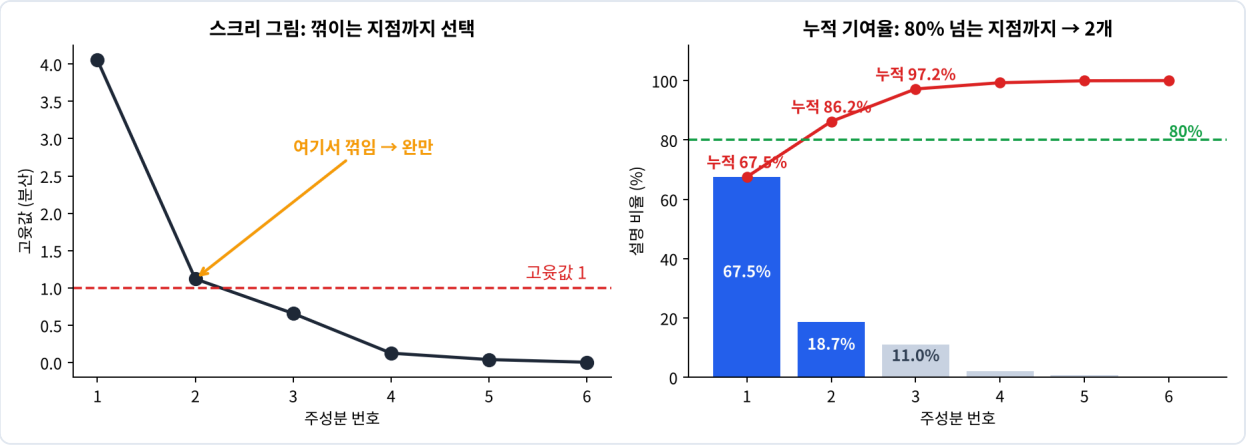


▲ 데이터를 한 축으로 줄일 때: X축으로 줄이면 손실이 크고, PC1 방향으로 줄이면 손실이 가장 작다

- **PC1** = 분산(퍼짐)이 **가장 큰 방향**, 즉 정보 손실이 가장 적은 방향입니다.
- **PC2** = PC1과 **직각(직교)**이면서 남은 분산이 가장 큰 방향입니다. 그래서 **주성분끼리는 상관이 없습니다.**
- **PC1 > PC2 > PC3 …** 순으로 설명력이 **감소**합니다. 주성분은 최대 **변수 수**만큼 만들 수 있습니다.
- 정답이 없는 데이터에 쓰므로 **비지도 학습**입니다.
- **쓰는 이유: 차원 축소**(분석·시각화가 쉬워짐), **다중공선성 해결**, 군집·회귀 성능 향상

주성분은 몇 개 쓸까?

기준	방법
누적 기여율	앞에서부터 더해 **70~80% 이상**이 되는 지점까지
스크리 그림	그래프가 **꺾여 완만해지는** 지점까지
고윳값	**1 이상**인 주성분 (표준화 기준, 평균 고윳값보다 큰 것)



▲ 교재 과일 데이터: 세 기준 모두 주성분 2개

R 출력 읽기

```
summary(prcomp(fruit, scale = TRUE))
                          PC1    PC2    PC3
Standard deviation     2.0131 1.0585 0.8109
Proportion of Variance 0.6755 0.1867 0.1096
Cumulative Proportion  0.6755 0.8622 0.9718
```

- **Proportion** = 그 주성분 하나의 설명 비율, **Cumulative** = 누적 설명 비율입니다. PC2까지 **86.2%**이므로 **2개**를 씁니다.
- 2개로 줄였을 때 손실은 1 − 0.862 = **13.8%**입니다.
- **Standard deviation² = 고윳값**입니다 ($2.01^2 \approx 4.05$).
- 주성분 계수(로딩)의 **절댓값이 큰 변수**가 그 주성분에 영향을 많이 줍니다.
- **biplot(바이플롯):** 관측값(점)과 변수(화살표) **두 가지**를 한 그림에 그립니다. 화살표가 **가로** 방향이면 PC1, **세로** 방향이면 PC2와 관련이 큽니다.

3. MDS vs PCA

	MDS	PCA
무엇으로?	개체 사이 **거리**	변수의 **분산·상관**
결과	개체의 **지도**	새로운 **변수(주성분)**
축의 의미	**없음**	계수로 해석 가능
좋은지 판단	**Stress** (낮을수록)	**누적 기여율**, 스크리 그림

시험에는 이렇게 나옵니다 · 출제 유형과 함정

- **주성분 개수 계산 (자주 나옴):**
- 설명 비율 0.45, 0.25, 0.15 → 0.70에서 0.85가 되므로 누적 80% 이상 최소 **3개**
- 고윳값 4.0, 1.9, 1.1, 0.6 → 1 이상은 **3개**
- **출력 해석 함정:**
- PC7까지만 보여 준 결과로 "원래 변수는 **7개**" → 틀림. 누적이 100%가 아니면 주성분이 **더 있습니다.**
- "2차원으로 줄이면 손실은 1 − 누적 비율" → 맞음
- 한 주성분의 계수만 보고 "**전반적으로** 영향이 가장 크다" → 틀림
- **PCA 개념:** 차원 **확장** → 틀림 (**축소**). 번호가 커질수록 설명력 **증가** → 틀림 (**감소**). 주성분은 **데이터 수**만큼 → 틀림 (최대 **변수 수**). 비지도 학습 → 맞음.
- **MDS: 절대적 위치**를 알 수 있다 → 틀림. 목적은 **군집 형성** → 틀림 (시각화). 활용 사례 → **영화·브랜드 간 유사성 지도**

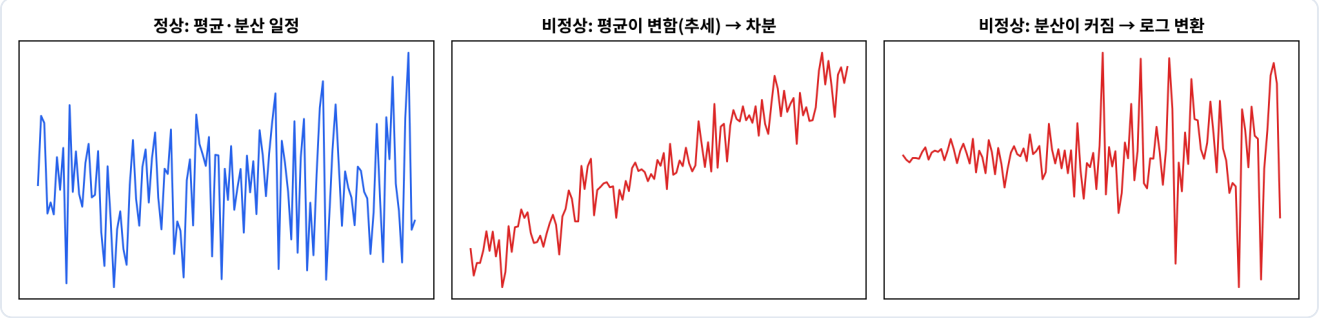
9단원 시계열 분석

한 문장 요약: 시계열은 **시간 순서대로 기록된 데이터**입니다(일별 주가, 월별 매출, 연도별 강물 유량). 순서를 섞으면 안 되고, 어제 값이 오늘 값에 영향을 줍니다. 목적은 과거 패턴으로 **미래를 예측**하는 것입니다.

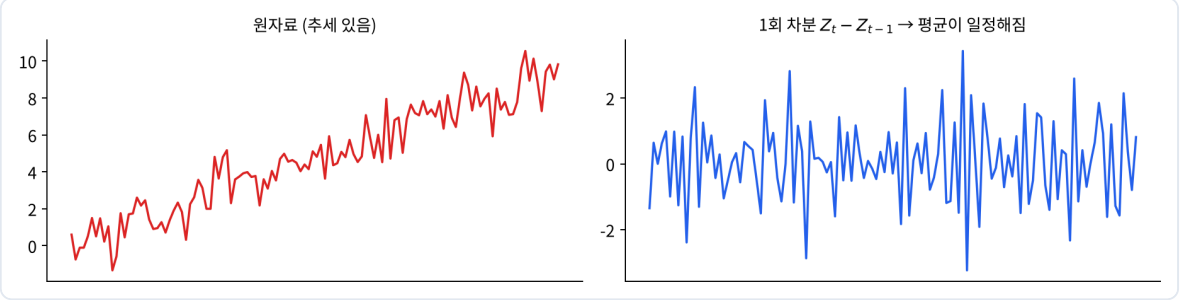
1. 정상성: 시계열 분석의 출발점

비유: 정상 시계열은 "성격이 변하지 않는 사람"입니다. 언제 만나도 평소 기분(평균)과 감정 기복(분산)이 비슷하므로 다음 행동을 예측할 수 있습니다.

정상성 조건	뜻	아니면 이렇게 고침
① **평균이 일정**	계속 오르거나 내리는 추세가 없음	**차분** (오늘 − 어제)
② **분산이 일정**	출렁임 크기가 시점과 무관	**로그 변환** 등 변환
③ **공분산은 시차에만 의존**	두 시점의 관계는 "몇 칸 떨어졌나"로만 정해지고 "언제냐"와는 무관	



▲ 왼쪽: 정상 / 가운데: 평균이 변함(추세) → 차분 / 오른쪽: 분산이 커짐 → 로그 변환



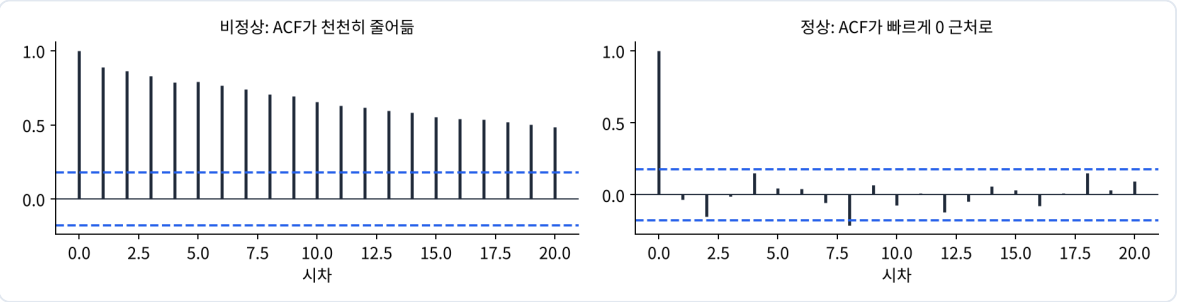
▲ 추세가 있는 원자료를 1번 차분하면 평균이 일정해진다

- 대부분의 실제 시계열은 **비정상**입니다. 그래서 먼저 정상으로 바꾼 뒤 분석합니다.
- **백색잡음:** 평균 0, 분산 일정, 서로 상관이 없는 완전 무작위 값입니다. 대표적인 정상 시계열이고, 모형에서 "예측할 수 없는 오차" 역할을 합니다.
- **정상 시계열이라고 관측값끼리 독립인 것은 아닙니다.** 자기상관이 있을 수 있습니다.

2. 자기상관: ACF와 PACF

- **자기상관:** 자기 자신의 **과거 값**과의 상관입니다(오늘 기온과 어제 기온).
- **ACF(자기상관함수):** 1칸, 2칸… 떨어진 값과의 상관을 **중간 영향까지 포함해서** 봅니다.
- **PACF(부분자기상관함수): 중간 시점의 영향을 빼고** 그 시차만의 순수한 상관을 봅니다.
- 비유하면 엄마와 할머니가 닮은 데는 "중간(엄마의 엄마)"을 통한 부분이 있습니다. ACF는 그 부분을 포함하고, PACF는 뺍니다.

- **비정상이면 ACF가 왜 천천히 줄까?** 추세가 있으면 값이 한동안 계속 평균보다 아래, 한동안 계속 위에 머뭅니다. 그래서 10칸, 20칸 떨어진 값과 짝지어도 같은 쪽에 있어 상관이 높게 남습니다. 정상 시계열은 금방 평균으로 돌아오므로 과거를 빨리 잊습니다.

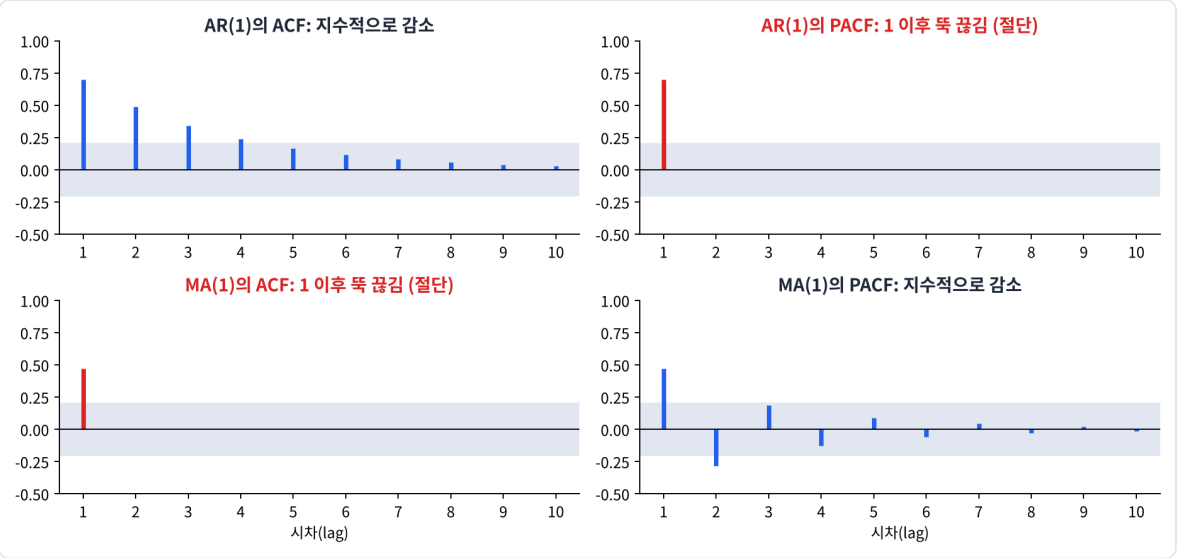


▲ 비정상 시계열은 ACF가 천천히 줄고, 정상 시계열은 ACF가 빠르게 0 근처로 간다

3. 시계열 모형: AR, MA, ARIMA

모형	오늘 값을 무엇으로 설명?	판별
AR(p) 자기회귀	과거 **관측값** p개	**PACF가 p 이후 절단**, ACF는 지수적으로 감소
MA(q) 이동평균	과거 **백색잡음(충격)** q개	**ACF가 q 이후 절단**, PACF는 지수적으로 감소

- **AR(1):** $Y_t = \varphi \cdot Y_{t-1} + \varepsilon_t$. 오늘 값 = 어제 값 × φ + 오늘의 새 충격. φ = 0.7이면 오늘은 어제와 0.7, 그제와는 어제를 거쳐 0.7 × 0.7 = 0.49만큼 닮습니다. 그래서 ACF는 0.7, 0.49, 0.34…로 줄고, 어제를 빼고 보는 PACF는 그제와의 직접 관계가 0이라 시차 1에서 끊깁니다.
- **MA(1):** $Y_t = \varepsilon_t + \theta \cdot \varepsilon_{t-1}$. 오늘은 어제의 **충격**만 이어받습니다. 오늘과 그제는 공유하는 충격이 없어 ACF가 시차 1에서 끊깁니다.
- 여기서 **지수적 감소**는 0.7 → 0.49 → 0.34처럼 **곱하기로 빠르게** 줄어 몇 시차 안에 0 근처로 가는 것입니다. 위 비정상 시계열처럼 **거의 줄지 않는 것**과 다릅니다.



▲ AR(1)은 PACF가 1 이후 뚝 끊기고, MA(1)은 ACF가 1 이후 뚝 끊긴다

> **외우기: AR → PACF, MA → ACF**. "P"는 AR 쪽에 붙는다고 외우면 됩니다. **MA 모형은 항상 정상**입니다.

- **ARMA(p, q)** = AR + MA이고, 정상 시계열에 씁니다.
- **ARIMA(p, d, q):** 비정상 시계열을 **d번 차분**해서 ARMA로 만든 것입니다.
- p = AR 차수, **d = 차분 횟수**, q = MA 차수
- **d = 0이면 ARMA(p, q)**, p = 0이면 IMA(d, q), q = 0이면 ARI(p, d)

- 예: ARIMA(1, 2, 0) → 2번 차분 후 AR(1)

R 흐름 (출력 읽는 법)

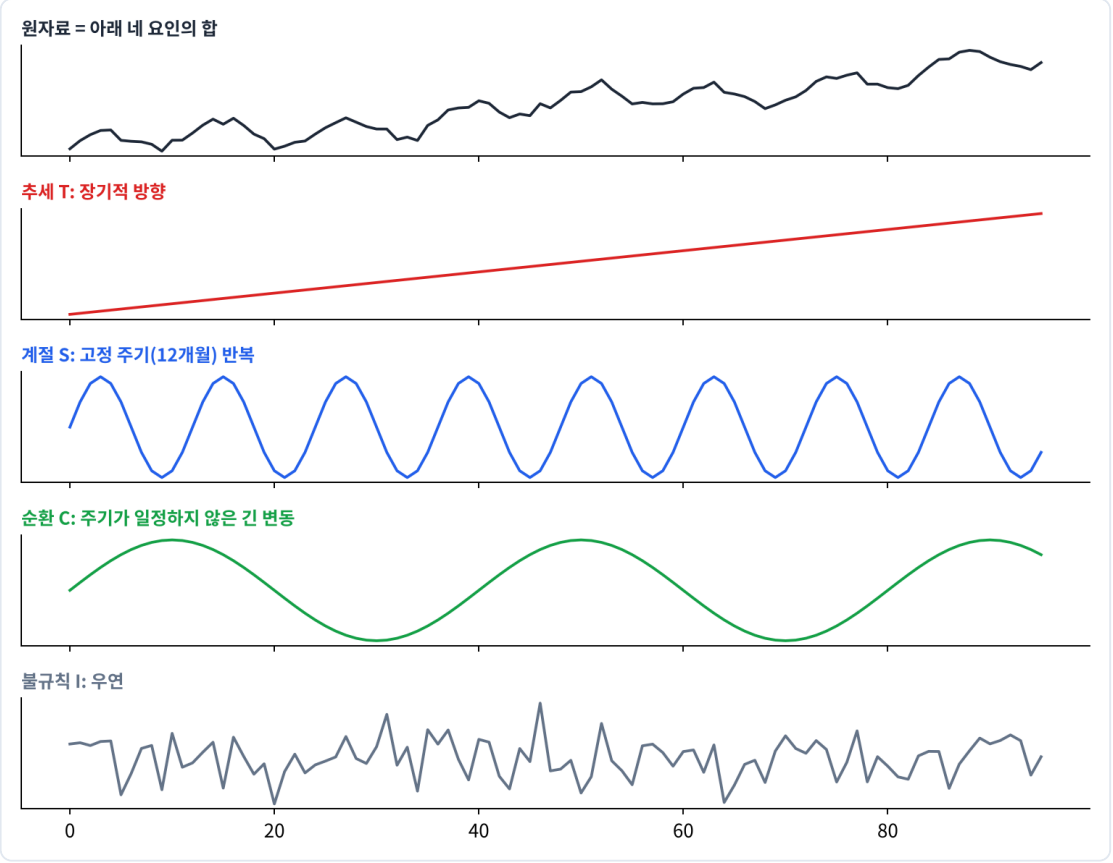
```
plot(Nile); Nile.diff <- diff(Nile, differences = 1)   # 차분
acf(Nile.diff); pacf(Nile.diff)                         # 절단 지점 확인
auto.arima(Nile)                                        # forecast 패키지
Series: Nile
ARIMA(1,1,1)
Coefficients:
         ar1      ma1
      0.2544  -0.8741
s.e.  0.1194   0.0605
AIC=1267.25   AICc=1267.51   BIC=1275.04
```

- `ARIMA(1,1,1)` 은 **1번 차분** 후 AR(1)과 MA(1)을 합친 모형입니다.
- **모형 점검:** 적합한 뒤 **잔차가 백색잡음**이면 좋은 모형입니다. 모형이 패턴을 다 뽑아내고 예측할 수 없는 잡음만 남았다는 뜻입니다. 잔차의 ACF가 시차 1부터 거의 0이면 됩니다. 원자료의 ACF가 처음부터 0이면 반대로 **예측할 패턴이 없는** 데이터입니다.
- 이후 `forecast(fit, h = 10)` 으로 앞으로 10개 시점을 예측합니다.

4. 분해 시계열

시계열을 **4가지 요인**으로 쪼개서 봅니다. R 함수는 `decompose()` 입니다.

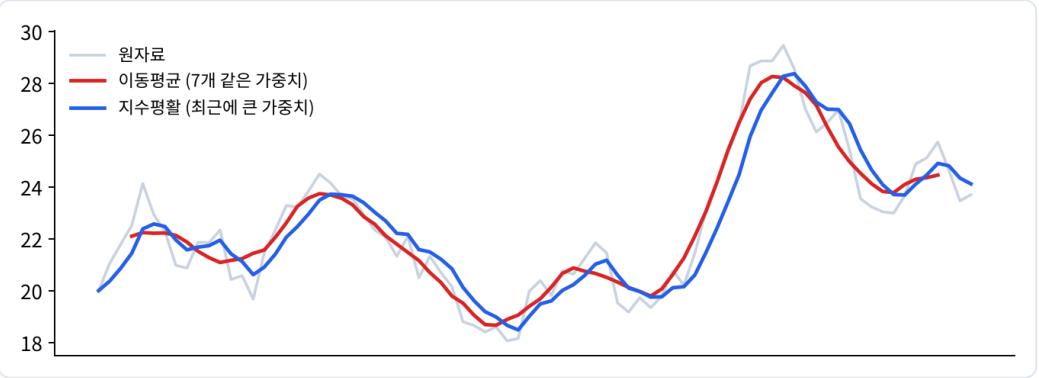
요인	뜻	예
추세	장기적으로 오르거나 내림	인구 증가
계절	**고정된** 주기 (요일, 월, 분기)	여름마다 아이스크림 매출 ↑
순환	**고정되지 않은** 긴 주기	경기 호황·불황
불규칙	위로 설명되지 않는 나머지	우연한 사건



▲ 원자료 = 추세 + 계절 + 순환 + 불규칙

5. 평활법

- **이동평균법:** 일정 기간의 평균으로 그래프를 매끄럽게 해서 추세를 봅니다. MA **모형**과 이름만 같고 다른 것입니다.
- **지수평활법:** 모든 과거 값을 쓰되 **최근 값일수록 큰 가중치**를 줍니다.



▲ 이동평균(같은 가중치)과 지수평활(최근에 큰 가중치)

시험에는 이렇게 나옵니다 · 출제 유형과 함정

- **정상성 조건:** "분산이 시점에 **의존**", "공분산이 **시점**에 의존" → 틀림 (공분산은 **시차**에만 의존)
- **정상화 방법:** 평균이 일정하지 않음 → **차분**, 분산이 일정하지 않음 → **변환**. 둘을 바꿔서 냅니다.
- "정상 시계열이면 관측값끼리 **독립**" → 틀림
- **AR·MA 판별:** AR ↔ **PACF** 절단, MA ↔ **ACF** 절단. 이 짝을 바꿔서 냅니다.
- **ARIMA 차수:** ARIMA(1, 2, 3)의 **d = 2 = 차분 횟수**입니다. **d = 0이면 ARMA**입니다.
- **분해 요인:** 계절 = **고정** 주기, 순환 = **비고정** 주기. 두 설명을 바꿔서 냅니다.
- **MA 모형은 항상 정상** → 맞음