3장 정형 데이터 마이닝 · 회차별 기출 (45~50회)

정답·해설 (보완판)

쉬운 설명 PDF 1~6단원 순서대로 정리

총 77문항 · 문항 끝에 출처(회차·번호) 표시

1단원 데이터 마이닝 개요·데이터 분할	· 데이터 마이닝 개요 · 추진 단계, 데이터 분할 · 검증	1~9번 (9문항)
2단원 분류 ① 로지스틱 회귀·의사결정나무	· 로지스틱 회귀, 의사결정나무	10~22번 (13문항)
3단원 분류 ② 앙상블·인공신경망·SVM	· 앙상블, 인공신경망 · 활성화 함수, SVM · 알고리즘 짝짓기	23~39번 (17문항)
4단원 분류 모형 성과 평가	· 지표 정의 · ROC, 오분류표 계산	40~47번 (8문항)
5단원 군집 분석	· 거리 척도, 계층적 군집 · 연결법, K-means · 혼합분포 · SOM · DBSCAN	48~64번 (17문항)
6단원 연관 분석	· 측도 정의 · 성질, 측도 계산, Apriori	65~77번 (13문항)

1단원 데이터 마이닝 개요·데이터 분할

데이터 마이닝 개요 · 추진 단계

1. 다음 중 분류 분석의 정의로 옳은 것은? 46회 36번

① 두 변수 간의 관계를 파악하고 예측하는 분석이다.

② 이미 분류된 데이터를 바탕으로 새로운 데이터가 속할 그룹을 예측하는 분석이다.

③ 데이터들 사이에 숨겨진 패턴 구조를 찾아내어 그룹화하는 분석이다.

④ 분석 데이터의 평균 또는 합을 예측하는 분석이다.

정답 ②

②는 이미 분류된 자료를 바탕으로 새로운 자료의 그룹을 예측한다는 정의이므로 맞다. 이메일과 스팸 여부가 함께 있는 사례를 학습하고 새 이메일의 범주를 예측하는 상황이 대표적이다.

핵심 개념: 분류는 범주를 알고 있는 학습 사례로 규칙을 학습하여 새로운 사례가 어느 범주에 속하는지 예측하는 지도학습이다. 이진 분류는 두 범주, 다중 분류는 세 개 이상 상호 배타적인 범주를 예측한다.

보기 검토: ①은 관계 파악과 예측이라는 설명으로 회귀를 포함한 여러 분석에 적용될 수 있어 분류의 구체적 정의가 아니다. ③은 정답 범주 없이 유사한 자료를 묶는 군집분석의 설명이다. ④는 평균·합 같은 수치형 결과를 예측하는 설명으로 분류와 다르다.

학습 포인트: 분류와 군집은 모두 그룹이라는 말을 사용할 수 있으나 정답 라벨의 존재가 다르다. 고객을 사전에 정한 이탈·유지 범주로 예측하면 분류이고, 고객의 구매 패턴을 보고 비슷한 집단을 새로 만들면 군집이다. 예측확률을 출력하더라도 최종 목표가 범주이면 분류 문제이다.

💡 **쉽게 이해하기** **분류** = 정답(그룹 이름)이 붙은 과거 데이터로 배워서, **새 데이터가 어느 그룹인지** 맞히기. 예: 과거 스팸 메일로 배워 새 메일이 스팸인지 판단. ③처럼 정답 없이 비슷한 것끼리 묶는 것은 **군집**입니다.

2. 다음 중 분류(Classification) 모형에 해당하지 않는 것은? 49회 33번

① 다중 회귀분석

② 인공신경망

③ 의사결정나무

④ 로지스틱 회귀분석

정답 ①

다중 회귀분석은 연속형 종속변수를 예측하는 회귀 모형이다. 인공신경망, 의사결정나무, 로지스틱 회귀분석은 범주형 종속변수의 분류에 사용할 수 있다.

💡 **쉽게 이해하기** 분류 모형은 Y가 **범주**(합격/불합격 등)입니다. **다중 회귀분석**은 Y가 **숫자**(집값, 연봉)인 예측 모형이라 분류가 아닙니다. 이름에 '회귀'가 들어가도 **로지스틱 회귀**는 확률로 범주를 고르므로 분류입니다.

3. 다음 중 데이터 분석 기법에 대한 설명으로 옳지 않은 것은? 49회 38번

① 회귀분석은 변수들 간의 관계를 분석하여 값을 예측하는 데 활용된다.

② 군집분석은 미래의 값을 예측하기 위한 대표적인 예측 기법이다.

③ 연관분석은 항목들이 함께 발생하는 규칙(관계)을 찾는 기법이다.

④ 분류분석은 데이터를 사전에 정의된 범주(class)로 나누는 기법이다.

정답 ②

군집분석은 유사한 개체끼리 집단으로 묶는 비지도 학습 기법으로, 미래 값을 예측하는 기법이 아니다. 예측에는 회귀분석이나 시계열분석 등을 사용한다.

💡 **쉽게 이해하기** 군집분석은 정답 없이 비슷한 것끼리 **묶기만** 합니다 (고객 세분화). 미래 값을 맞히는 것은 회귀·분류 같은 **예측** 기법입니다.

4. **데이터마이닝 수행 단계의 순서로 옳은 것은?** 46회 32번

① 목적 설정 → 데이터 가공 → 데이터 준비 → 기법 적용 → 검증
② 목적 설정 → 데이터 준비 → 데이터 가공 → 기법 적용 → 검증
③ 데이터 가공 → 데이터 준비 → 목적 설정 → 기법 적용 → 검증
④ 데이터 가공 → 데이터 준비 → 기법 적용 → 목적 설정 → 검증

정답 ②

②는 이 흐름을 따른다. 목적 설정에서 해결할 문제를 정하고, 데이터 준비에서 원천 자료를 확보·선별한다. 데이터 가공에서 정제·변환·변수 생성을 수행한다. 기법 적용에서 적절한 알고리즘으로 패턴이나 예측 모형을 만들며, 검증에서 결과의 성능·안정성·업무 적합성을 평가한다.

핵심 개념: 데이터마이닝의 기본 흐름은 목적 설정, 데이터 준비, 데이터 가공, 기법 적용, 검증이다. 목적이 먼저 정해져야 필요한 자료와 평가 기준을 선택할 수 있다.
보기 검토: ①은 데이터를 준비하기 전에 가공한다. ③은 목적이 정해지기 전에 가공·준비부터 수행한다. ④는 기법까지 적용한 뒤에 목적을 설정해 성공 기준이 뒤늦게 생긴다. 제시된 기본 순서로는 모두 부적절하다.
적용 예: 고객 이탈 예측이 목적이라면 이탈 정의와 예측 시점을 먼저 정한 뒤 이용 이력을 확보한다. 결측 처리와 최근 사용량 변수 생성 후 분류 모형을 학습하고, 시간적으로 나중 자료에서 성능을 확인한다. 실제 프로젝트에서는 검증 결과에 따라 앞 단계로 돌아가지만 기본적인 선행 관계는 유지한다.

💡 **쉽게 이해하기** 요리로 외우세요: 무엇을 만들지 정하고(**목적 설정**) → 장을 보고(**데이터 준비**) → 손질하고(**가공**) → 조리하고(**기법 적용**) → 맛보기(**검증**). 장보기 전에 손질할 수는 없으니 준비 → 가공 순서입니다.

5. **아래 보기에서 데이터 마이닝 추진 단계를 순서대로 나열한 것은?** 48회 40번

> 가. 데이터 준비
> 나. 목적 정의
> 다. 기법 적용
> 라. 데이터 가공
> 마. 검증

① 가→나→라→다→마
② 나→가→다→라→마
③ 나→가→라→다→마
④ 나→다→가→라→마

정답 ③

목적 정의→데이터 준비→데이터 가공→데이터 마이닝 기법 적용→검증 순서이다. 해결하려는 목적을 먼저 정하고 자료를 확보한 뒤 분석 가능한 형태로 정리하여 모형을 적용한다. 마지막에는 결과가 목적에 부합하는지 평가한다. 실제 프로젝트는 결과에 따라 앞 단계로 돌아갈 수 있지만 문항은 기본 추진 순서를 묻는다.

💡 **쉽게 이해하기** 가~마를 요리 순서(정하기 → 장보기 → 손질 → 조리 → 맛보기)에 맞춰 나열하면 나(목적 정의) → 가(준비) → 라(가공) → 다(기법 적용) → 마(검증)입니다. ②는 '기법 적용'과 '가공'의 순서를 바꾼 함정입니다.

데이터 분할 · 검증

6. **다음 중 데이터 분할 방식에 대한 설명으로 적절하지 않은 것은?** 48회 39번

① 훈련용 데이터는 모델이 데이터 패턴을 학습하고 가중치를 조정하는데 사용된다.
② 검증용 데이터는 모델의 과대 및 과소 적합 조정 시 사용된다.
③ 검증용 데이터는 해당 모델의 최종 성능을 평가 시 활용된다.
④ 평가용 데이터는 모델의 객관적인 성능 측정을 위해 학습에 활용되지 않은 데이터이다.

정답 ③

학습 데이터는 모수 학습, 검증 데이터는 모형과 하이퍼파라미터 선택, 테스트 데이터는 선택이 끝난 최종 모형의 성능 평가에 사용한다. 따라서 검증 데이터를 최종 성능 평가용이라고 한 ③이 틀렸다. 테스트 결과를 보며 반복적으로 모형을 선택하면 테스트 정보가 선택 과정에 유입되어 평가가 낙관적으로 편향될 수 있다.

💡 **쉽게 이해하기** 시험 공부 비유: 학습용 = **교재 문제**(실력 쌓기), 검증용 = **모의고사**(공부 방법 조정, 과적합 확인), 평가용(테스트) = **실제 시험**(최종 점수). 최종 성능은 한 번도 안 본 **테스트용**으로 잽니다.

7. **분석 모델을 구축할 때 학습용·검증용·테스트용 데이터의 분할에 관한 설명으로 옳은 것은?** 50회 47번

① 학습용 데이터에는 일반적으로 검증용이나 테스트용보다 더 많은 비율을 할당한다.
② 검증용 데이터는 모델의 최종 성능을 평가하기 위해서만 사용한다.
③ 테스트용 데이터를 이용하여 모델의 파라미터를 학습시킨다.
④ 세 종류의 데이터는 항상 동일한 비율로 나누어야 한다.

정답 ①

일반적으로 학습 데이터 비중을 크게 둔다. 학습 데이터는 파라미터 학습, 검증 데이터는 모델·하이퍼파라미터 선택, 테스트 데이터는 최종 성능 평가에 사용한다. 동일 비율은 필수가 아니다.

💡 **쉽게 이해하기** 공부(학습)에 가장 많은 문제가 필요하므로 학습용에 가장 큰 비율(예: 60%)을 줍니다. 최종 평가는 테스트용, 파라미터 학습은 학습용이고, 비율은 상황에 따라 다르게 정합니다(50:30:20, 60:20:20 등).

8. **분류 자료에서 특정 범주에 속한 사례 수가 다른 범주에 비해 지나치게 적어, 모델이 해당 범주를 제대로 학습하지 못하는 현상을 무엇이라 하는가?** 50회 34번

① 과소적합
② 과대적합
③ 기울기 소실
④ 범주 불균형

> **정답 ④**
> 클래스별 사례 수가 크게 차이 나는 문제는 범주 불균형이다. 소수 클래스의 성능을 별도로 점검하고 적절한 평가 지표와 샘플링·가중치를 고려한다.

💡 **쉽게 이해하기** 사기 거래 1개, 정상 거래 999개인 데이터를 떠올리세요. 모델이 '전부 정상'이라고만 해도 정확도 99.9%라서 사기를 배우지 못합니다. 이렇게 한 범주가 너무 적은 현상이 **범주 불균형**입니다. 해결은 오버샘플링·언더샘플링입니다.

9. **크기가 d인 자료에서 복원추출로 d개를 뽑아 부트스트랩(bootstrap) 표본을 만들 때, 특정 관측값 하나가 한 번도 뽑히지 않을 확률은?** 50회 38번

① $\frac{1}{d}$
② $1-(\frac{1}{d})^{d}$
③ $(1-\frac{1}{d})^{d}$
④ $1-(1-\frac{1}{d})^{d}$

> **정답 ③**
> 한 번 추출할 때 특정 관측값을 뽑지 않을 확률은 $1-\frac{1}{d}$이다. 독립적으로 d번 복원추출하므로 한 번도 뽑히지 않을 확률은 $(1-\frac{1}{d})^{d}$ 이며, d가 크면 약 $e^{-1}\approx 0.368$이다.

💡 **쉽게 이해하기** 한 번 뽑을 때 특정 데이터가 **안 뽑힐** 확률 = 1 − 1/d. 복원추출로 d번 뽑는 동안 **계속** 안 뽑혀야 하니 곱하기를 d번 → **(1 − 1/d)ᵈ**. d가 크면 약 0.368(36.8%)이고, 이렇게 빠진 데이터를 OOB라고 합니다. ④는 '한 번 이상 뽑힐' 확률입니다.

빠른 정답표

1	②	2	①	3	②	4	②	5	③	6	③	7	①	8	④	9	③

자주 나오는 함정

- 추진 단계: **목적 정의 → 데이터 준비 → 가공 → 기법 적용 → 검증** (준비와 가공 순서를 바꿔 냄)
- 분류 = 이미 분류된 데이터로 새 데이터의 그룹 예측 · **다중 회귀**는 분류 모형 아님 · 군집은 예측 기법 아님
- 최종 성능 평가는 **테스트용** (검증용 아님) · 학습용에 가장 많은 비율
- 부트스트랩에서 한 번도 안 뽑힐 확률 = **(1 − 1/d)ᵈ** ≈ 36.8% · 한 범주가 너무 적음 → **범주 불균형**

2단원 분류 ① 로지스틱 회귀·의사결정나무

로지스틱 회귀

10. 로지스틱 회귀분석의 적용 사례로 적절한 것은? 45회 40번

① 주택 가격 예측
② 제품 수명 예측
③ 마케팅 성공 여부 예측
④ 키와 몸무게의 상관관계 분석

정답 ③
마케팅 성공 여부는 범주형 반응변수이므로 ③이 적합하다. ① 주택 가격과 ② 제품 수명은 표현대로라면 연속형 수치 예측이며, ④는 변수 간 관계를 요약하는 상관분석 문제이다.
핵심 개념: 이항 로지스틱 회귀는 성공·실패, 구매·미구매 같은 두 범주의 사건 발생 확률을 모델링한다. 선형예측값 η를 $p = \frac{1}{1+e^{-\eta}}$로 변환하여 0과 1 사이 확률을 얻는다.
학습 포인트: 수명을 '특정 기간 안에 고장 여부'로 바꾸면 이항 분석이 가능하지만 이 보기에는 그런 조건이 없다. 로지스틱 회귀라는 이름의 회귀와 분류 활용을 혼동하지 않는다. 확률을 실제 범주로 바꾸려면 임계값을 정해야 하며 반드시 0.5여야 하는 것은 아니다. 계수는 로그오즈의 변화로 해석한다.

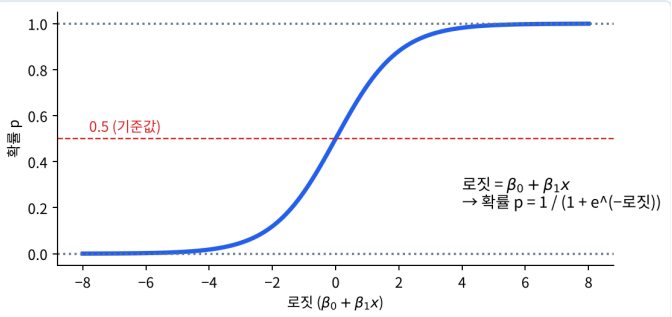
💡 **쉽게 이해하기** 로지스틱 회귀는 Y가 **예/아니오**처럼 범주일 때 그 확률을 계산합니다. 마케팅 '성공/실패'가 딱 맞습니다. 주택 가격·제품 수명은 숫자라 일반 회귀, 키와 몸무게의 관계는 상관분석입니다.

11. 로지스틱 시그모이드 함수의 출력 범위로 옳은 것은? 46회 39번

① $y \geq 1$
② 0 또는 1
③ $-1 \leq y \leq 1$
④ $0 < y < 1$

정답 ④
$z = 0$일 때 $y = 0.5$이고, z가 커지면 1에, 작아지면 0에 가까워진다. 유한한 z에서 0이나 1에 도달하지 않으므로 정확한 범위는 ④ $0 < y < 1$이다.
핵심 개념: 로지스틱 sigmoid는 $\sigma(z) = \frac{1}{1+e^{-z}}$이다. 유한한 실수 z에 대해 $e^{-z} > 0$이므로 분모는 항상 1보다 크고, 출력은 정확히 $0 < \sigma(z) < 1$이다.
보기 검토: ①의 $y \geq 1$은 출력이 항상 1보다 작으므로 틀리다. ②의 '0 또는 1'은 연속적인 확률 출력과 임계값으로 결정한 범주를 혼동한 설명이다. ③의 $-1 \leq y \leq 1$은 tanh의 범위($-1 < y < 1$)와 혼동하기 쉬운 표현이며 sigmoid의 범위가 아니다.

💡 **쉽게 이해하기** 시그모이드는 **S자 곡선**이라 아무리 큰 값을 넣어도 1에 닿지 않고, 아무리 작은 값을 넣어도 0에 닿지 않습니다. 그래서 출력은 **0 < y < 1**(확률). '0 또는 1'은 계단 함수, '−1~1'은 tanh입니다.



▲ 46회 39번 · 시그모이드 곡선: 어떤 값을 넣어도 0과 1 사이 확률이 나온다

12. 로지스틱 회귀분석에 대한 설명으로 적절하지 않은 것은? 48회 34번

① 로지스틱 회귀모형의 연결함수로는 시그모이드 함수를 사용한다.
② 합격/불합격과 같은 이진 분류 문제를 해결하는데 적합한 회귀분석이다.
③ 오즈(Odds)는 범주A에 속할 확률을 범주B에 속할 확률로 나눈값이다.
④ 종속변수인 로짓(Logit)과 독립변수는 서로 선형적 관계를 가진다.

정답 ①
일반적인 로지스틱 회귀의 연결함수는 logit(p)=log[p/(1−p)]이다. 시그모이드 p=1/(1+exp(−η))는 선형 예측값 η를 확률로 바꾸는 역연결함수이다. 따라서 연결함수를 시그모이드라고 한 ①이 틀렸다. 오즈는 p/(1−p)이고, 로그오즈를 설명변수의 선형 결합으로 모델링한다.

💡 **쉽게 이해하기** 로짓과 시그모이드는 **서로 되돌리는** 관계입니다. 로지스틱 회귀의 **연결 함수**(확률을 직선식으로 바꾸는 함수)는 **로짓** log(p/(1 − p))이고, 시그모이드는 그 반대로 직선식을 확률로 되돌리는 함수입니다. ①은 둘을 바꿔 쓴 단골 함정입니다.

13. 다음과 같은 로지스틱 회귀모형에서 설명변수 x가 1만큼 증가할 때 로짓(logit) 값의 변화로 옳은 것은? 50회 21번

$$p = \frac{1}{1+e^{(4.6-0.6x)}}$$

① 0.6 감소한다
② 0.6 증가한다
③ $e^{-0.6}$배 증가한다
④ $e^{0.6}$배 증가한다

정답 ②
$logit(p) = ln\frac{p}{1-p} = -4.6 + 0.6x$ 이다. x가 1 증가하면 로짓은 0.6 증가한다. 오즈(odds)는 $e^{0.6}$배가 되며, 이는 로짓의 변화량과 구분해야 한다.

💡 **쉽게 이해하기** 식 p = 1/(1 + e^(4.6 − 0.6x))를 로짓으로 바꾸면 log(p/(1 − p)) = −(4.6 − 0.6x) = **−4.6 + 0.6x**입니다. x가 1 늘면 로짓은 기울기만큼, 즉 **0.6 증가**합니다. 'e^0.6배'는 **오즈**의 변화라서 질문(로짓)과 다릅니다.

14. 로지스틱 회귀 결과의 해석으로 옳지 않은 것은? 46회 35번

> default의 Yes를 사건으로 하고 income과 balance를 설명변수로 사용한 이항 로지스틱 회귀이다.
> 계수 추정값: 절편 −11.54, income 0.00002081, balance 0.005647.
> income의 p값 0.0000299, balance의 p값 < 2×10^{-16}.

① 두 설명변수는 각각 유의수준 0.05에서 유의하다.
② income이 같으면 balance가 증가할수록 Yes의 예측 오즈가 커진다.
③ balance가 같으면 income이 증가할수록 Yes의 예측확률이 감소한다.
④ 회귀계수는 설명변수 한 단위 증가에 따른 로그 오즈의 변화량이다.

정답 ③

income의 계수가 양수이므로 balance를 고정하면 income 증가에 따라 로그 오즈·오즈·예측확률이 모두 증가한다. 감소한다고 말한 ③은 틀리다. sigmoid 변환은 입력이 커질수록 출력도 커지는 단조 증가 함수이다.

핵심 개념: 이항 로지스틱 회귀는 사건확률 p의 로그 오즈 $\log\frac{p}{1-p}$를 설명변수의 선형 결합으로 나타낸다. 여기서는 Yes가 사건이며 $\log\frac{p}{1-p} = -11.54 + 0.00002081 \times income + 0.005647 \times balance$이다.

보기 검토: ①은 income의 p값 0.0000299와 balance의 p값이 모두 0.05보다 작아 맞다. ②는 balance 계수가 양수이므로 맞다. ④는 회귀계수가 다른 변수를 고정했을 때 설명변수 한 단위 변화에 따른 로그 오즈 변화량이라는 정의이다.

계산 예: income 한 단위 증가의 오즈비는 $e^{0.00002081} \approx 1.00002081$이다. 1,000단위 증가라면 $e^{0.02081} \approx 1.02103$으로 오즈가 약 2.10% 증가한다. balance 한 단위 증가의 오즈비는 $e^{0.005647} \approx 1.005663$으로 약 0.566% 증가한다. 이것은 확률의 퍼센트포인트 증가와 다르다. 확률 변화량은 원래 p와 다른 변수의 값에 따라 달라진다.

📋 출력 읽는 법

절편 −11.54	모든 변수가 0일 때의 로그 오즈 (해석에 거의 안 씀)
income 0.00002081	**양수** → income이 늘면 연체 오즈 증가 (값이 작은 건 단위가 커서)
balance 0.005647	**양수** → balance가 늘면 연체 오즈 증가
p값 0.0000299, < 2×10^{-16}	둘 다 0.05보다 작음 → 둘 다 유의
계수의 의미	변수 1 증가 시 **로그 오즈**의 변화량 (오즈는 e^β배)

💡 **쉽게 이해하기** 로지스틱 회귀계수는 **부호**로 방향을 읽습니다. income 계수 0.0000208은 아주 작아도 **양수**이므로 balance가 같을 때 income이 늘면 Yes(연체) 확률이 **증가**합니다. ③은 방향을 거꾸로 말한 함정입니다. 두 p값 모두 0.05보다 작아 둘 다 유의합니다.

15. 아래 로지스틱 회귀분석 결과에 대한 해석 중 옳지 않은 것은? 50회 31번

어느 카드사 고객 자료를 이용하여 연체 여부(default)를 종속변수로, 학생 여부(student)와 카드 잔고(balance)를 설명변수로 하는 로지스틱 회귀분석을 수행한 R 출력 결과는 다음과 같다.

```
Call:
glm(formula = default ~ student + balance, family = binomial,
data = credit)

Deviance Residuals:
Min 1Q Median 3Q Max
-2.4578 -0.1422 -0.0559 -0.0203 3.7435

Coefficients:
Estimate Std. Error z value Pr(>|z|)
(Intercept) -10.600000 0.491800 -21.553 <2e-16 ***
studentYes -0.700000 0.283900 -2.466 0.0137 *
balance 0.005600 0.000230 24.348 <2e-16 ***
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 2920.6 on 9999 degrees of freedom
Residual deviance: 1571.7 on 9997 degrees of freedom
AIC: 1577.7

Number of Fisher Scoring iterations: 8
```

연체확률은 $p = \frac{1}{1+e^{-z}}$, $z = -10.6 - 0.7 \times studentYes + 0.0056 \times balance$ 로 계산하며, z 값에 따른 연체확률 p의 근삿값은 아래와 같다.

z값	연체확률 p
-5.0	0.0067
-5.1	0.0061
-5.2	0.0055
-5.3	0.0050
-5.4	0.0045
-5.5	0.0041
-5.6	0.0037
-5.7	0.0033
-5.8	0.0030
-5.9	0.0027
-6.0	0.0025

① 잔고가 1,000일 때 학생의 연체확률은 약 0.0033이다.
② 잔고가 1,000일 때 학생이 아닌 사람의 연체확률은 약 0.0067이다.
③ 잔고가 1,200일 때 학생의 연체확률은 0.0033보다 높다.
④ 잔고가 1,200일 때 학생이 아닌 사람의 연체확률은 0.0067보다 낮다.

정답 ④

학생·잔고 1,000: $z = -10.6 - 0.7 + 5.6 = -5.7$, $p \approx 0.0033$이다. 비학생·잔고 1,000: $z = -5.0$, $p \approx 0.0067$이다. 잔고가

1,200이면 z가 각각 -4.58, -3.88로 커져 연체확률이 모두 증가한다. 따라서 ④가 틀리다.

📋 출력 읽는 법

`glm(..., family = binomial)`	로지스틱 회귀 (binomial = 이항)
`studentYes −0.70, p 0.0137 *`	**더미변수**. 학생이면 로그 오즈 0.7 감소 → 같은 잔고면 학생이 덜 연체
`balance 0.0056, p < 2e-16 ***`	잔고 1 증가 → 로그 오즈 0.0056 증가 → 연체 확률 증가
`Null deviance 2920.6 (df 9999)`	절편만 넣은 모형의 이탈도. n = 10,000
`Residual deviance 1571.7 (df 9997)`	변수 2개를 넣은 모형의 이탈도. 크게 줄었으므로 설명력 있음
`AIC 1577.7`	모형 비교용. 작을수록 좋음

💡 **쉽게 이해하기** 표를 이용한 대입 문제입니다. z = −10.6 − 0.7 × (학생이면 1) + 0.0056 × 잔고. 잔고 1,000이면 학생 z = −5.7 → p ≈ 0.0033, 비학생 z = −5.0 → p ≈ 0.0067. 잔고가 1,200으로 늘면 z가 1.12 커지므로 **확률은 둘 다 올라갑니다**(balance 계수가 양수). 그래서 비학생의 확률은 0.0067보다 **높아지고**, '낮다'고 한 ④가 틀립니다.

의사결정나무

16. 의사결정나무에 대한 설명으로 틀린 것은? 45회 41번

① 가지치기를 통해 과적합을 방지할 수 있다.
② 자식마디의 순수도가 증가하도록 분류나무를 형성한다.
③ 지니 지수나 엔트로피를 기준으로 분할한다.
④ 가지치기를 통해 학습 데이터 세트에서의 정확도를 높일 수 있다.

정답 ④
학습 데이터 정확도를 높이는 것을 가지치기의 기본 효과로 제시한 ④는 부적절하다. 충분히 자란 트리를 단순화하면 훈련 오차는 증가하거나 그대로일 수 있고, 검증 성능은 좋아질 수 있다. 훈련 정확도 상승과 과적합 감소를 동일시하지 않는다.

핵심 개념: 가지치기는 불필요한 분기를 줄여 트리를 단순화하고 새 자료에 대한 일반화 성능을 개선하려는 절차이다. 학습 자료에 지나치게 맞춘 구조를 줄이는 것이 목적이다.
보기 검토: ①은 과적합 완화 취지이다. ②③은 분류나무에서 자식의 가중 평균 불순도가 낮아지는 분할을 찾는 설명이며, 각 자식 모두가 반드시 개별적으로 부모보다 순수해지는 보장은 없다. 회귀나무는 수치 반응에 맞는 분산·제곱오차 등의 기준을 사용한다. 가지치기가 항상 검증 성능 향상을 보장하는 것도 아니다.

💡 **쉽게 이해하기** 가지치기는 너무 자란 나무를 다듬어 **새 데이터에 대한 성능**(일반화)을 높이는 것입니다. 학습 데이터에 딱 맞춘 가지를 자르므로 **학습 데이터 정확도는 오히려 조금 떨어질 수 있습니다.** 교과서만 달달 외우던 습관을 버리고 원리를 익히는 것과 같습니다.

17. 다음 중 의사결정나무 모델에 대한 설명으로 적절하지 않은 것은? 48회 41번

① 데이터 분류 기준으로는 지니 지수 및 엔트로피, 카이제곱 통계량이 활용된다.
② 연속형 변수인 경우, 의사결정나무 모형은 학습 데이터에 대해 항상 예측 정확도 100%의 모델 구현이 가능하다.
③ 하위 노드로 내려갈수록 데이터 불순도는 점차 감소한다.
④ 불필요한 분기를 제거하는 가지치기를 통해 모델의 일반화 성능을 향상시킬 수 있다.

정답 ②
연속형 반응변수는 회귀나무로 예측하며 분류 정확도 100%라는 표현을 그대로 적용할 수 없다. 자료 중복, 서로 다른 반응값, 분할 제한 등이 있으므로 학습자료를 항상 완벽하게 맞춘다는 보장도 없다. 가지치기는 복잡한 분기를 줄여 과적합을 완화한다. 개별 자식 노드의 불순도가 언제나 더 작다는 절대적 주장보다는 분할의 가중 평균 불순도 감소로 이해한다.

💡 **쉽게 이해하기** 학습 데이터를 끝까지 쪼개면 정확도가 매우 높아질 수는 있지만, 같은 X 값인데 Y가 다른 데이터가 있으면 아무리 나눠도 구분할 수 없습니다. 그래서 '**항상** 100%'는 틀립니다. 시험에서 '항상', '반드시'가 붙은 보기는 의심하세요.

18. 분류나무의 평가 기준으로 사용되기 어려운 것은? 46회 45번

① 지니 지수
② 엔트로피 지수
③ 카이제곱 통계량
④ 잔차 제곱합

> **정답 ④**
> 잔차제곱합은 연속적인 결과값과 예측값의 차이를 제곱해 더한 것으로, 범주형 결과를 직접 다루는 분류나무의 대표적인 노드 평가 기준은 아니다. 이 조건에서 ④를 선택한다.
> 핵심 개념: 분류나무의 결과는 범주이고 회귀나무의 결과는 수치이다. 분류나무는 노드의 범주 혼합 정도를, 회귀나무는 수치 예측 오차를 평가한다. 분할 기준과 가지치기 기준도 엄밀하게는 구분해야 한다.
> 보기 검토: ① 지니 불순도는 $1-\sum p_k^2$로 범주의 혼합 정도를 나타낸다. ② 엔트로피는 $-\sum p_k \log p_k$로 역시 범주 혼합을 나타낸다. ③ 카이제곱 통계량은 범주별 분포의 차이를 이용하며 CHAID 등의 분할 판단에 사용된다. 모두 분류나무의 분할·노드 평가와 연결할 수 있다.

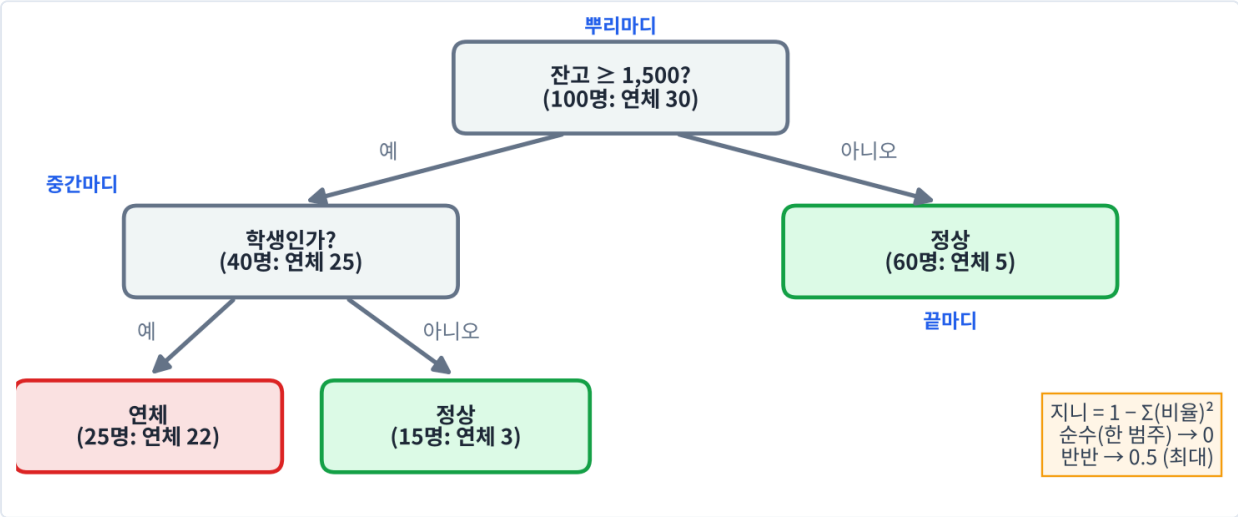
💡 **쉽게 이해하기** 분류나무의 Y는 **범주**라서 기준도 범주용입니다: 지니 지수, 엔트로피, 카이제곱. **잔차 제곱합**(예측값과 실제값의 차이 제곱)은 Y가 **숫자**일 때 쓰는 것이라 회귀나무·회귀분석의 기준입니다.

19. 의사결정나무에서 마디(노드)를 분리하는 기준에 대한 설명으로 적절하지 않은 것은? 49회 45번

① 카이제곱 통계량의 p-value가 작아지는 방향으로 분리한다.
② 지니 지수(Gini Index)가 최대가 되는 방향으로 분리한다.
③ 엔트로피 지수가 작아지는 방향으로 분리한다.
④ 분산 감소량이 커지는 방향으로 분리한다.

> **정답 ②**
> 지니 지수는 불순도 지표이므로 분리 후 지니 지수가 '작아지는' 방향으로 분리한다. 카이제곱 통계량의 p-value와 엔트로피는 작아지는 방향, 분산 감소량은 커지는 방향이 맞다.

💡 **쉽게 이해하기** 지니 지수는 **불순도**(여러 범주가 섞인 정도)입니다. 잘 나눌수록 각 마디가 한 범주로 깔끔해지므로 지니 지수가 **작아지는** 방향으로 나눕니다. '최대'는 반대로 가장 뒤섞이게 나누라는 뜻이라 틀립니다.



▲ 49회 45번 · 나눌수록 각 마디가 한 범주로 순수해진다 (지니 지수 ↓)

20. 어떤 노드에 속한 데이터 10개가 모두 하나의 클래스에만 속하고 다른 클래스의 개수는 0일 때(즉 완전히 한 범주로 몰려 있을 때), 이 노드의 지니 지수(Gini Index)와 엔트로피(Entropy)를 순서대로 바르게 나타낸 것은? 49회 46번

① 1, 1
② 1,0
③ 0, 1
④ 0, 0

> **정답 ④**
> 한 클래스의 비율이 p = 1이므로 지니 지수 = $1-1^2=0$, 엔트로피 = $-1\times\log_2 1=0$이다. 완전히 순수한 노드는 두 지표가 모두 0이다.

💡 **쉽게 이해하기** 10개가 모두 같은 범주 = **완전히 순수**. 지니 = $1-1^2$ = **0**, 엔트로피 = $-1\times\log_2 1$ = **0**. 섞인 게 없으니 두 지표 모두 0입니다. 반반 섞이면 지니 0.5, 엔트로피 1로 최대가 됩니다.

21. 의사결정나무에서 사용하는 지니지수(Gini index)에 대한 설명으로 틀린 것은? 50회 48번

① 지니지수는 노드의 불순도를 나타내는 지표이다.
② 노드에 한 가지 클래스만 존재하면 지니지수는 0이 된다.
③ 지니지수가 작을수록 해당 노드는 순수하다고 볼 수 있다.
④ 지니지수가 낮아질수록 노드의 불순도는 높아진다.

> **정답 ④**
> $Gini = 1-\sum_k pk2$ 이다. 한 클래스만 있으면 0이며 값이 작을수록 순수하다. 지니지수 감소를 불순도 증가로 해석한 ④는 틀리다.

💡 **쉽게 이해하기** 지니지수 = '얼마나 뒤섞였나' 점수. **낮을수록 깨끗**(순수)하고, 높을수록 지저분(불순)합니다. ④는 방향을 거꾸로 말했습니다.

22. 의사결정나무의 정지규칙(stopping rule)으로 적절하지 않은 것은? 50회 40번

① 분할로 얻는 정보이득이 미리 정한 최소 임계값을 초과하면 정지한다.

② 노드에 속한 자료의 수가 최소 기준 이하가 되면 정지한다.

③ 트리의 깊이가 설정한 최대치에 도달하면 정지한다.

④ 추가로 분할하여도 순도의 개선 효과가 충분하지 않으면 정지한다.

> **정답 ①**
> 정보이득이 충분히 크면 분할을 계속할 근거가 된다. 최소 개선량에 미달하거나 노드 자료 수가 작거나 최대 깊이에 도달했을 때 분할을 멈춘다.

💡 **쉽게 이해하기** 정지 규칙은 '더 나눠 봐야 **소용없을 때**' 멈추는 것입니다. 정보 이득(불순도 감소량)이 기준보다 **작으면** 정지합니다. 이득이 기준을 **넘으면** 오히려 나눌 가치가 있으니 계속 나눠야 합니다.

빠른 정답표

10	③	11	④	12	①	13	②	14	③	15	④	16	④	17	②	18	④	19	②
20	④	21	④	22	①														

자주 나오는 함정

- 로지스틱 연결 함수 = **로짓** (시그모이드 아님) · 시그모이드 출력 **0 < y < 1** · x 1 증가 → 로짓 **β만큼** 증가
- 출력 해석: 계수 **부호**로 증가/감소 판단 · 오즈는 e^β배
- 분리 기준: 지니·엔트로피가 **가장 작아지는** 방향, 카이제곱 p값 최소 · 분류나무 기준이 아닌 것 → **잔차 제곱합**
- 순수 노드의 지니·엔트로피 = **0, 0** · 정지 규칙: 정보 이득이 임계값보다 **작을 때** 정지 · 가지치기는 **새 데이터** 성능 향상

3단원 분류 ② 앙상블·인공신경망·SVM

앙상블

23. 다음 중 앙상블기법인 배깅(Bagging)과 부스팅(Boosting)에 대한 설명으로 적절한 것은? 45회 38번

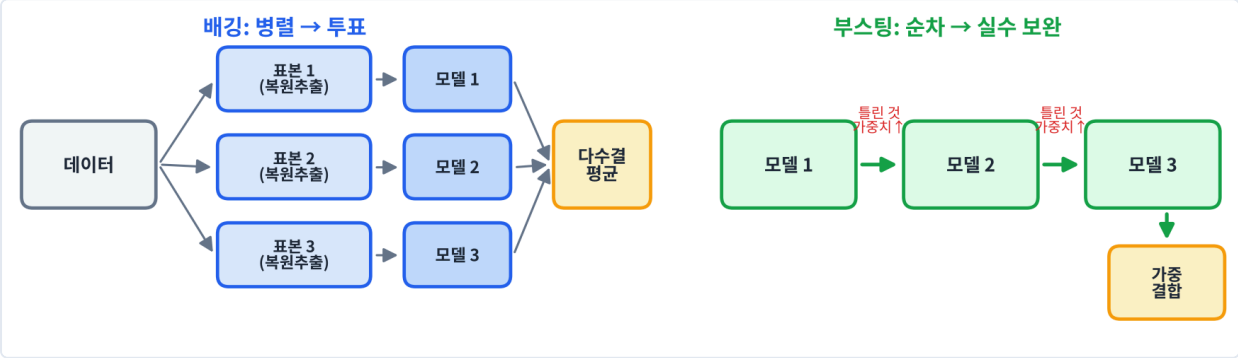
① 배깅은 모델 간 상호의존성을 강조한다.
② 배깅은 약한 학습기를 순차적으로 학습시킨다.
③ 부스팅은 오버샘플링을 통해 데이터 수를 증가시킨다.
④ 부스팅은 잘못 분류된 데이터에 더 큰 가중치를 부여한다.

정답 ④

AdaBoost는 잘못 분류된 관측값의 상대적 가중치를 높여 다음 학습기가 어려운 사례에 더 주목하도록 하므로 ④가 대표적으로 맞다.

핵심 개념: 배깅은 부트스트랩 표본으로 여러 기저모형을 학습하고 예측을 결합하는 방법이다. 부스팅은 앞선 모형의 오차를 보완하도록 순차적으로 모형을 추가하는 방법이다.
보기 검토: ①②는 순차적 의존성을 배깅의 핵심으로 잘못 설명한다. 배깅의 기저모형은 서로의 오차를 순차적으로 보완하는 구조가 아니다. ③은 부스팅을 단순한 자료 수 증가로 오해했다. 모든 부스팅이 같은 표본 가중치 갱신식을 사용하는 것은 아니며, 그래디언트 부스팅은 손실의 기울기 등을 이용한다. 알고리즘별 구현과 일반 개념을 구분한다.

💡 **쉽게 이해하기** **배깅** = 여러 학생이 각자 따로 공부해서(병렬, 독립) 다수결. **부스팅** = 한 학생이 시험 볼 때마다 **틀린 문제에 별표**(큰 가중치)를 쳐서 다음엔 그 문제를 더 집중해서 공부(순차). 오버샘플링은 범주 불균형 해결법이라 부스팅과 관계없습니다.



▲ 45회 38번 · 배깅은 따로 학습해 투표, 부스팅은 앞 모델의 실수를 보완하며 차례로 학습

24. 앙상블 모형에 대한 설명으로 옳은 것은? 46회 40번

① 부스팅은 각 모델을 병렬 학습한 후 최종 결과를 보팅 방식으로 집계하여 통합한다.
② 부스팅은 이전 모델의 오차를 보완하기 위해 순차적으로 모형을 학습한다.
③ 앙상블 모델은 항상 단일 모형보다 정확한 분석 성능을 보여준다.
④ 배깅은 이전 모델이 잘못 예측한 데이터에 가중치를 두어 순차적으로 학습한다.

정답 ②

부스팅은 이전 모형이 잘못 예측한 사례에 더 큰 가중치를 두거나(AdaBoost) 남은 오차를 다음 모형이 학습하도록(경사 부스팅) 모형을 순차적으로 추가한다. 따라서 ②가 맞다.

핵심 개념: 앙상블은 여러 모형을 결합하는 상위 개념이고, 배깅과 부스팅은 서로 다른 결합 방식이다. 배깅은 재표집한 자료로 여러 모형을 만들고 결합하는 방식이며, 부스팅은 이전 단계의 부족함을 보완하도록 순차적으로 학습한다.
보기 검토: ①은 병렬 학습 후 투표로 결합하는 배깅의 설명이다. ③은 앙상블이 항상 더 좋다고 단정해 틀리다. 자료·모형·설정에 따라 단일 모형보다 성능이 낮을 수도 있다. ④는 부스팅의 순차적 가중 학습을 배깅에 붙여 틀리다. 배깅은 부트스트랩 표본으로 여러 모형을 독립적으로 학습해 결합한다.

💡 **쉽게 이해하기** 부스팅의 핵심은 **순차**입니다. 앞 모델이 틀린 것을 다음 모델이 보완해야 하므로 동시에 할 수 없습니다. ①은 배깅 설명, ④는 부스팅 설명을 배깅이라고 바꿔 쓴 것입니다. 앙상블이 '**항상**' 더 좋은 것도 아닙니다.

25. 앙상블 학습에 대한 설명으로 적절하지 않은 것은? 47회 42번

① 배깅(Bagging)은 복원추출 기반의 부트스트랩 샘플을 생성하여 각 샘플마다 학습시킨 후 모든 모델의 예측 결과를 하나로 합치는 방식이다.

② 부스팅(Boosting)은 개별 모델에 동일한 가중치를 부여하여 순차적으로 학습한다.

③ 보팅(Voting)은 각 모델 예측 결과 중 가장 많이 나온 결과를 최종 결과로 채택한다.

④ 랜덤포레스트(Random Forest)는 배깅 방식을 기반으로 하여 복수의 독립적인 의사결정나무를 생성 후 예측을 수행한다.

정답 ②

부스팅은 이전 모형의 오차를 보완하며 순차적으로 학습한다. 모든 모델에 항상 동일 가중치를 준다는 일반화가 틀리다.

배깅은 여러 부트스트랩 표본으로 모형을 학습하고 분류는 투표, 회귀는 평균 등으로 결합한다. 부스팅은 이전 단계의 오차나 손실을 보완하는 학습을 순차적으로 수행한다. 결합 가중치나 보완 방법은 알고리즘에 따라 달라진다.

보기 판단: ②는 개별 모델에 항상 동일 가중치를 준다는 일반화가 틀렸다. ①은 배깅의 정의, ③은 하드 보팅의 정의이다. 소프트 보팅은 확률을 결합한다. ④의 랜덤포레스트는 배깅과 노드별 변수 무작위 선택을 함께 사용한다. 나무를 별도로 학습할 수 있지만 같은 원자료를 이용하므로 통계적으로 완전히 독립이라는 뜻으로 해석하지 않는다.

💡 **쉽게 이해하기** 부스팅은 모델들에게 **똑같은 무게를 주지 않습니다.** 틀린 데이터에 더 큰 가중치를 주고, 최종 결합에서도 성능 좋은 모델에 더 큰 발언권을 줍니다. '동일한 가중치'가 틀린 부분입니다.

26. 앙상블(Ensemble) 학습에 대한 설명으로 옳은 것은? 49회 40번

① 앙상블은 하나의 단일 모형만을 정교하게 학습시켜 성능을 높이는 방법이다.

② 배깅(Bagging)과 부스팅(Boosting)은 대표적인 앙상블 기법이다.

③ 랜덤 포레스트는 앙상블이 아닌 단일 의사결정나무 모형이다.

④ 앙상블 모형은 항상 개별 모형보다 결과 해석이 쉽다.

정답 ②

②가 옳다. 앙상블은 여러 모델을 결합하는 방법이며 배깅과 부스팅이 대표적이다. 랜덤 포레스트는 부트스트랩 표본과 특성 무작위 선택 등을 사용하는 트리 앙상블이다. 여러 모델을 결합하면 일반화 성능이 개선될 수 있지만 항상 개선되는 것은 아니다. 해석의 용이성도 모델 종류에 따라 다르므로 항상 개별 모델보다 쉽다는 ④는 틀리다.

💡 **쉽게 이해하기** 앙상블 = 여러 모델의 **합주**. 대표가 배깅과 부스팅이고, **랜덤 포레스트**도 나무 여러 그루를 모은 앙상블입니다. 모델이 여러 개라 오히려 **해석은 더 어렵습니다.**

27. 앙상블(Ensemble) 학습에 관한 설명으로 적절하지 않은 것은? 50회 45번

① 앙상블에 사용하는 개별 모델들 사이의 상관관계가 높을수록 예측 정확도가 향상된다.

② 여러 모델을 결합하므로 단일 모델보다 일반화 성능이 좋아질 수 있다.

③ 여러 모델의 예측 결과를 투표나 평균 등의 방법으로 결합한다.

④ 개별 모델들의 다양성(Diversity)을 확보하는 것이 중요하다.

정답 ①

모델들이 유사한 오류를 내면 결합의 이점이 작아진다. 적절한 개별 성능과 오류의 다양성을 확보하는 것이 중요하며 상관관계가 높을수록 항상 정확도가 향상되는 것은 아니다.

💡 **쉽게 이해하기** 똑같은 생각을 하는 사람 10명에게 물으면 1명에게 묻는 것과 같습니다. 앙상블은 서로 **다른**(상관이 낮은) 모델을 모아야 서로의 실수를 메워 줍니다. 그래서 '상관관계가 높을수록 향상'은 틀립니다.

인공신경망 · 활성화 함수

28. 인공신경망 모형에 대한 설명으로 틀린 것은? 45회 39번

① 예측 정확도가 높다.

② 설명력 있는 가중치를 산출할 수 있다.

③ 복잡한 패턴을 스스로 학습할 수 있다.

④ 다양한 비정형 데이터를 처리할 수 있다.

정답 ②

②를 '각 가중치를 명확한 변수 효과로 직접 설명할 수 있다'는 취지로 읽으면 부적절하다. 가중치가 존재하지 않는다는 뜻은 아니다. 여러 층의 상호작용과 비선형성 때문에 영향 해석이 복잡하다는 점이 핵심이다.

핵심 개념: 신경망은 가중치와 비선형 활성화함수를 조합하여 복잡한 함수를 학습한다. 가중치 자체는 실제로 계산되지만 깊은 네트워크의 개별 가중치를 선형회귀계수처럼 직접 해석하기는 어렵다.

보기 검토: ③④는 적절한 구조와 학습 조건에서 가능한 활용이다. ①의 높은 정확도는 가능한 장점이며 항상 다른 모형보다 높다는 보장은 없다. 설명가능성 기법을 활용할 수 있어도 모든 가중치가 자동으로 설명력 있는 계수가 되는 것은 아니다.

💡 **쉽게 이해하기** 인공신경망은 정확하지만 **블랙박스**입니다. 가중치가 수천 개라 '어떤 변수가 왜 중요한지' 설명하기 어렵습니다. 그래서 '설명력 있는 가중치를 산출'은 틀립니다. 해석이 쉬운 것은 의사결정나무입니다.

29. 다음 중 인공신경망(ANN)에 대한 설명으로 옳지 않은 것은?

46회 37번

① 이진 출력 노드에 sigmoid를 적용하는 은닉층 없는 신경망은 로지스틱 회귀의 함수 형태와 대응한다.

② 은닉층은 비선형 활성화 함수를 통해 복잡한 비선형 관계를 학습한다.

③ 렐루(ReLu) 함수는 입력값이 0보다 작으면 0으로, 0보다 크면 입력값을 그대로 출력한다.

④ 렐루(ReLu) 함수를 활성화 함수로 사용할 때, 은닉층이 없는 인공신경망은 로지스틱 회귀 모형과 동일한 특성을 가진다.

정답 ④

④의 ReLU는 $\max(0, z)$이며 출력 상한이 없다. 확률을 0과 1 사이로 변환하는 sigmoid와 다르므로 ReLU 출력만으로 로지스틱 회귀와 동일하다고 할 수 없다.

핵심 개념: 은닉층의 유무만으로 신경망과 로지스틱 회귀의 동일성을 판단할 수 없다. 입력의 가중합 $z = w^T x + b$에 이진 출력용 sigmoid를 적용하면 $p = \frac{1}{1+e^{-z}}$인 로지스틱 회귀의 함수 형태가 된다.

보기 검토: ①은 이진 출력 노드에 sigmoid를 사용한다는 조건이 있으므로 모형의 함수 형태는 로지스틱 회귀와 같다. 손실·정규화·최적화 설정까지 일치해야 학습 결과까지 같다고 말할 수 있다. ②는 비선형 활성화 함수가 복잡한 비선형 관계 학습을 가능하게 한다는 설명이다. ③은 ReLU의 정의로 맞으며 $z = 0$에서도 출력은 0이다.

학습 포인트: 모든 층에 선형 변환만 연속 적용하면 합성 결과도 하나의 선형 변환이다. 은닉층을 깊게 쌓는 것만으로 비선형성이 생기는 것은 아니다. 비선형 활성화 함수의 역할과 최종 출력의 의미를 함께 확인한다.

💡 **쉽게 이해하기** 은닉층 없이 입력이 출력으로 바로 가면 식은 '가중합 → 활성화 함수' 하나입니다. 활성화 함수가 **시그모이드**면 로지스틱 회귀와 똑같은 모양(0~1 확률)이 됩니다. **ReLU**는 출력이 0~∞라 확률이 아니므로 로지스틱과 같지 않습니다.

30. 다음 중 인공신경망의 구조에 대한 설명으로 옳지 않은 것은?

46회 41번

① 입력층의 노드 수는 입력 데이터 특성 수에 따라 결정된다.

② 적은 은닉층은 과소적합 발생 가능성 및 복잡한 모델에는 부적합할 수 있다.

③ 모든 은닉층은 항상 동일한 개수의 노드로 구성되어야 한다.

④ 은닉층의 수는 모형의 복잡도와 학습 능력에 영향을 미친다.

정답 ③

③은 모든 은닉층이 항상 같은 수의 노드로 구성되어야 한다고 단정한다. 20→50→30→3 같은 구조도 가능하므로 틀리다. 층별 너비는 표현 능력·계산 비용·규제 효과 등을 고려해 결정한다.

핵심 개념: 신경망의 구조는 입력 특성 수, 은닉층의 수와 너비, 출력 과제에 따라 정한다. 각 은닉층의 노드 수는 같게 만들 수도 있고 다르게 만들 수도 있다.

보기 검토: ①은 일반적인 MLP에서 입력 노드 수가 전처리 후 특성 수와 대응한다는 설명이다. ②는 표현 능력이 부족한 구조가 복잡한 관계를 학습하지 못해 과소적합할 가능성을 말한다. ④는 깊이가 함수 표현 능력과 학습 과정에 영향을 준다는 설명이다. 세 항목은 '가능성'과 '영향'을 설명하므로 적절하다.

학습 포인트: 은닉층이 많거나 넓다고 성능이 항상 높아지는 것은 아니다. 파라미터 증가로 과적합 위험과 학습 비용이 커질 수 있다. 충분히 넓은 한 은닉층도 많은 함수를 근사할 수 있지만 실제 학습의 효율성·일반화는 자료와 구조에 따라 다르다. 검증 성능을 기준으로 구조를 평가한다.

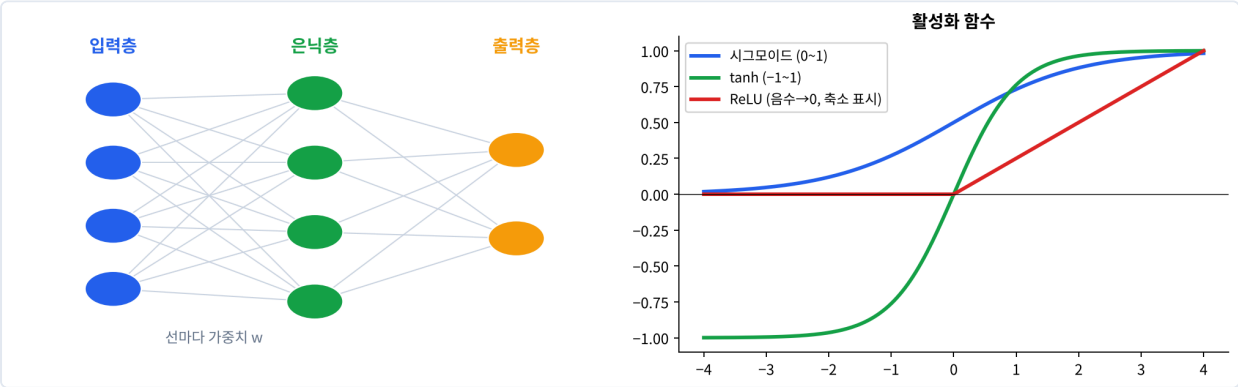
💡 **쉽게 이해하기** 은닉층마다 노드 수는 설계하는 사람이 정합니다. 예를 들어 64개 → 32개 → 16개처럼 **줄여 가는** 구조도 흔합니다. '항상 같아야 한다'는 틀립니다.

31. 단일 은닉층으로 구성된 다층 퍼셉트론에서 입력층 20개 노드, 은닉층 50개 노드, 출력층 3개로 구성될 때, 편향(Bias)을 제외한 가중치의 개수는? 46회 38번

① 73
② 150
③ 1150
④ 3000

> **정답 ③**
> 입력층 20개와 은닉층 50개의 연결은 $20 \times 50 = 1000$개이다. 은닉층 50개와 출력층 3개의 연결은 $50 \times 3 = 150$개이다. 전체 가중치는 $1000 + 150 = 1150$개이므로 ③이다.
>
> 핵심 개념: 완전연결층에서는 앞 층의 모든 노드가 다음 층의 모든 노드와 연결된다. 두 층 사이의 가중치 수는 앞 층 노드 수와 다음 층 노드 수의 곱이다. 이 문제는 완전연결 MLP를 전제로 하며 편향은 제외한다.
> 보기 검토: ①의 73은 노드 수 20+50+3의 합으로 연결 가중치 수가 아니다. ②의 150은 은닉층에서 출력층으로 가는 연결만 계산한 값이다. ④의 3,000은 이 구조의 두 연결 행렬 크기에서 나오지 않는 값이다.
> 추가 계산: 편향까지 포함하면 은닉층에 50개, 출력층에 3개가 추가되므로 총 학습 파라미터는 $1150 + 50 + 3 = 1203$개이다. 일반적으로 층 크기가 $a \to b \to c$라면 가중치 수는 $ab + bc$, 편향 포함 파라미터 수는 $ab + b + bc + c$이다.
> 학습 포인트: '층 수', '노드 수', '연결 수', '파라미터 수'를 구분한다. 입력 노드는 자료를 전달하므로 이 계산에서 입력층 자체에 별도의 편향 20개를 더하지 않는다.

💡 **쉽게 이해하기** 가중치는 **선(연결)마다 하나**씩 있습니다. 입력 20개가 은닉 50개와 모두 연결되면 20 × 50 = 1,000개, 은닉 50개가 출력 3개와 연결되면 50 × 3 = 150개. 합계 **1,150개**입니다. 노드 수를 더하거나(73) 한 층만 곱하면(150) 틀립니다.



▲ 46회 38번 · 층과 층 사이 선마다 가중치가 하나씩 있다 → 가중치 수 = 앞 층 노드 × 뒤 층 노드의 합

32. 인공신경망에서 각 층의 노드 수는 줄이고 은닉층의 수는 늘렸을 때 나타날 수 있는 현상으로 가장 적절한 것은? 49회 43번

① 모델 구조가 전체적으로 단순해진다.
② 모델의 학습 시간이 짧아진다.
③ 역전파 과정에서 기울기 소실(vanishing gradient) 문제가 발생할 수 있다.
④ 표현할 수 있는 함수의 복잡도가 감소한다.

> **정답 ③**
> ③이 가장 적절하다. 은닉층이 깊어지면 활성화함수와 가중치 상태 등에 따라 역전파 기울기가 반복적으로 작아져 앞쪽 층이 충분히 학습되지 않는 기울기 소실이 발생할 수 있다. 항상 발생하는 것은 아니며 활성화함수·초기화·잔차 연결 등으로 완화할 수 있다. 노드 수를 줄이고 층을 늘린다는 정보만으로 전체 파라미터 수, 학습 시간, 표현 능력의 증감을 확정할 수는 없다.

💡 **쉽게 이해하기** 역전파는 오차 신호를 출력층에서 입력층으로 **전달하며 곱해 가는** 과정입니다. 층이 깊어지면 1보다 작은 값을 여러 번 곱하게 되어 앞쪽 층에 도착할 때는 신호가 거의 0이 됩니다. 이것이 **기울기 소실**이고, 앞쪽 층이 학습되지 않습니다. 해결책으로 ReLU를 씁니다.

33. 다음 중 인공신경망 모형에서 입력층에서 전달된 신호의 합을 출력값으로 변환하여 다음 층으로 전달하는 함수는? 48회 42번

① 연결 함수
② 활성화 함수
③ 출력 함수
④ 가중치 함수

정답 ②
뉴런은 가중합과 편향을 계산한 뒤 활성화 함수를 적용하여 다음 층에 전달할 값을 만든다. sigmoid·tanh·ReLU 등이 대표적이다. 가중치는 신호의 영향 크기를 조절하는 값이고, 활성화 함수는 계산된 입력을 변환하는 함수이다. 비선형 활성화는 신경망이 복잡한 관계를 표현하는 데 중요한 역할을 한다.

💡 **쉽게 이해하기** 뉴런은 '입력 × 가중치'를 모두 더한 뒤, 그 합을 **활성화 함수**에 넣어 다음 층으로 보낼 값을 만듭니다. 사람 뇌에서 신호가 기준을 넘어야 다음 뉴런이 '활성화'되는 것을 흉내 낸 이름입니다.

34. 다층 퍼셉트론(MLP)에서 출력층의 결과가 다중 클래스(multiclass)일 때, 주로 사용하는 활성화 함수는? 46회 42번

① 렐루 (ReLu)
② 시그모이드 (Sigmoid)
③ 하이퍼볼릭 탄젠트 (Hyperbolic Tangent)
④ 소프트맥스 (Softmax)

정답 ④
softmax의 j번째 출력은 $p_j = \frac{e^{z_j}}{\sum_k e^{z_k}}$이다. 각 출력은 양수이며 모든 클래스의 출력 합이 1이므로 서로 배타적인 클래스 중 하나를 고르는 문제에 맞는다. 따라서 ④이다.
핵심 개념: 하나의 관측값이 여러 범주 중 정확히 하나에 속하는 다중 분류에서는 클래스별 점수를 확률처럼 해석할 수 있게 변환하는 softmax를 주로 사용한다. 출력 개수는 범주 개수와 대응한다.
보기 검토: ① ReLU는 출력 상한이 없어 클래스 확률을 합 1로 정규화하지 않는다. ② sigmoid는 이진 분류의 한 사건확률 또는 여러 라벨의 독립적인 여부를 표현하는 데 사용한다. ③ tanh는 출력이 음수일 수 있어 클래스별 확률을 직접 표현하는 대표 함수가 아니다.
계산 예: 세 클래스의 점수가 모두 같다면 각 출력은 $1/3$이다. 한 클래스의 점수가 상대적으로 커지면 그 클래스의 확률이 커지지만 다른 출력들과 함께 정규화된다.
학습 포인트: 다중 분류(multiclass)와 다중 라벨(multilabel)을 구분한다. 사진에 고양이 또는 개 중 하나를 붙이는 문제와, 한 사진에 사람·차량·동물이 동시에 있을 수 있는 문제는 다르다. 후자는 라벨별 sigmoid를 사용할 수 있다.

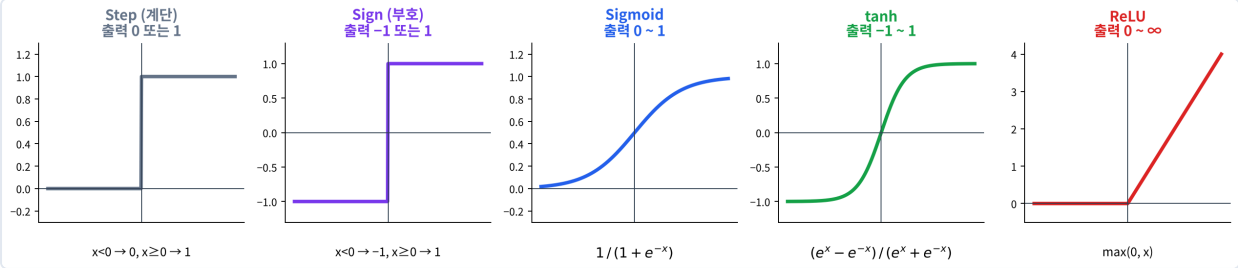
💡 **쉽게 이해하기** 출력 범주가 3개 이상이면 각 범주의 확률을 내야 하고, 그 확률들의 **합이 1**이어야 합니다. 이 일을 하는 함수가 **소프트맥스**입니다. 시그모이드는 범주가 2개(이진)일 때 씁니다.

35. 다음 중 소프트맥스 (Softmax) 활성화 함수로 옳은 것은? 47회 41번

① $f(a) = \frac{1}{1+e^{-a}}$
② $f(a_i) = \frac{e^{a_i}}{\sum_{j=1}^{k} e^{a_j}}$
③ $f(a) = \frac{e^{a} - e^{-a}}{e^{a} + e^{-a}}$
④ $f(a) = \max(0, a)$

정답 ②
각 지수값을 모든 범주의 지수값 합으로 나누므로 출력 확률의 합이 1이다.
소프트맥스의 k번째 출력은 $p_k = \frac{e^{z_k}}{\sum_j e^{z_j}}$이다. 각 출력은 양수이고 모두 합하면 분자들의 합과 분모가 같아져 1이 된다. 따라서 여러 상호 배타적 클래스의 예측 확률을 표현하는 출력층에 사용한다.
계산 예시: 입력 점수가 (0,0)이면 지수값은 (1,1), 합은 2이므로 출력은 (0.5,0.5)이다. 분모에 자기 지수값만 쓰거나 지수값 전체 합으로 나누지 않는 식은 이 정규화 조건을 만족하지 않는다. ②가 위 식에 해당한다. 클래스가 하나뿐인 소프트맥스는 출력이 항상 1이므로 43번의 이진 시그모이드와 구별해야 한다.

💡 **쉽게 이해하기** 식을 보고 이름 맞히기: ① $1/(1+e^{-a})$ = **시그모이드**, ② $e^{a_i} \div \Sigma e^{a_j}$ = **소프트맥스**(전체 중 내 몫 → 합이 1), ③ $(e^{a}-e^{-a})/(e^{a}+e^{-a})$ = **tanh**, ④ max(0, a) = **ReLU**. 분모에 Σ(시그마, 모두 더하기)가 있으면 소프트맥스입니다.



▲ 47회 41번 · 활성화 함수의 모양과 식: 출력 범위로 구분한다

36. 아래 설명에서 해당하는 활성화 함수는 무엇인가? 47회 43번

> 입력층이 직접 출력층으로 연결되고 출력층의 노드가 1개인 인공신경망에서 이 활성화 함수를 사용하면 로지스틱 회귀 모형과 작동 원리가 동일해진다.

① Sigmoid
② Tanh
③ ReLU
④ Softmax

정답 ①
출력 노드 하나에 시그모이드를 적용하면 이진 로지스틱 회귀와 같은 형태가 된다.
입력의 가중합을 $z = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$로 두면 시그모이드 출력은 $\sigma(z) = \frac{1}{1+e^{-z}}$이다. 이는 이진 로지스틱 회귀의 확률식과 같은 형태이다. 은닉층 없이 입력에서 출력 노드 하나로 직접 연결한다는 조건이 핵심이다.
보기 판단: ①이 정답이다. ② Tanh는 −1~1 범위여서 그 자체로 이 확률식이 아니다. ③ ReLU는 max(0,z)로 출력이 1을 넘을 수 있다. ④ 소프트맥스를 출력 하나에 적용하면 항상 1이다. 같은 확률식 형태라는 사실이 학습 손실·규제·최적화 설정까지 모두 자동으로 같다는 뜻은 아니다.

💡 **쉽게 이해하기** '입력층 → 출력층 바로 연결, 출력 노드 1개, 로지스틱 회귀와 같다' = 0~1 확률을 내는 **시그모이드**. 로지스틱 회귀가 바로 시그모이드로 확률을 계산하기 때문입니다.

37. 인공신경망에서 사용하는 활성화함수에 관한 설명으로 틀린 것은? 50회 42번

① 시그모이드 함수의 출력 범위는 0에서 1 사이이다.
② ReLU 함수는 입력이 음수인 구간에서 0을 출력한다.
③ 계단함수는 임계값을 기준으로 0 또는 1을 출력한다.
④ 쌍곡탄젠트(tanh) 함수의 출력 범위는 0에서 1 사이이다.

정답 ④
tanh의 출력 범위는 -1과 1 사이이다. 시그모이드는 0과 1 사이, ReLU는 $max(0, x)$, 계단함수는 임계값에 따라 0 또는 1을 출력한다.

💡 **쉽게 이해하기** 출력 범위로 외우세요: 시그모이드 **0~1**, tanh **−1~1**, ReLU **0~∞**, 계단 **0 또는 1**. tanh는 시그모이드를 아래로 늘려 가운데가 0이 되게 만든 모양입니다.

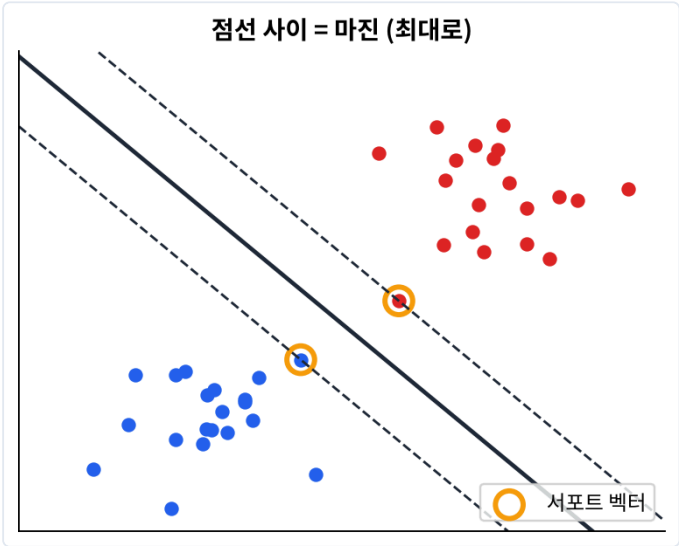
SVM · 알고리즘 짝짓기

38. 서포트 벡터 머신(SVM)에 대한 설명으로 옳지 않은 것은? 49회 41번

① 두 클래스 사이의 마진(margin)을 최대화하는 초평면(hyperplane)을 찾아 분류한다.
② 서포트 벡터는 결정 경계(초평면)에 가장 가까이 위치한 데이터 포인트이다.
③ 커널 함수는 고차원 데이터를 저차원으로 변환하여 계산을 단순화하는 역할을 한다.
④ 선형으로 분리되지 않는 데이터도 커널 기법을 이용하면 분류할 수 있다.

정답 ③
③이 틀리다. 커널은 특징 공간에서의 내적을 원래 입력을 이용해 계산하는 함수이며 비선형 결정 경계를 구성하는 데 활용된다. 고차원 데이터를 저차원으로 축소하는 기법으로 설명하면 안 된다. 고차원 특징을 명시적으로 모두 생성해야 하는 것도 아니다. 서포트 벡터는 결정 경계를 정하는 데 기여하는 표본이며, 하드 마진에서는 마진 경계에 위치하고 소프트 마진에서는 마진 내부나 오분류된 표본도 포함될 수 있다.

💡 **쉽게 이해하기** 직선으로 나눌 수 없는 데이터를 **차원을 늘려서**(예: 2차원 → 3차원) 나눌 수 있게 만드는 것이 커널입니다. 종이 위에 섞인 점들을 들어 올리면 사이에 판을 끼워 나눌 수 있는 것과 같습니다. 방향이 저차원 → **고차원**입니다.



▲ 49회 41번 · SVM: 두 그룹 사이 여백(마진)이 가장 넓은 경계선, 경계에 붙은 점이 서포트 벡터

39. 다음 (가)~(다)의 설명에 해당하는 분류 알고리즘을 순서대로 올바르게 연결한 것은? 50회 44번

> (가) 종속변수가 범주형일 때 로짓 변환과 시그모이드 함수를 이용하여 각 범주에 속할 확률을 추정한다.
> (나) 서로 다른 클래스 사이의 간격(마진)을 최대화하는 초평면을 찾아 분류한다.
> (다) 새로운 데이터와 가장 가까운 K개의 이웃을 찾아 다수결로 범주를 결정한다.

① 로지스틱 회귀 – SVM – KNN
② SVM – KNN – 로지스틱 회귀
③ KNN – 로지스틱 회귀 – SVM
④ SVM – 로지스틱 회귀 – KNN

정답 ①
로짓·시그모이드로 확률을 추정하는 것은 로지스틱 회귀, 최대 마진 초평면은 SVM, 가까운 K개 이웃의 다수결은 KNN이다.

💡 **쉽게 이해하기** 키워드 짝짓기: (가) **로짓·시그모이드·확률** → 로지스틱 회귀, (나) **마진 최대·초평면** → SVM, (다) **가까운 K개 이웃·다수결** → KNN.

빠른 정답표

23	④	24	②	25	②	26	②	27	①	28	②	29	④	30	③	31	③	32	③
33	②	34	④	35	②	36	①	37	④	38	③	39	①						

자주 나오는 함정

- 부스팅 = **순차** 학습, 오분류 데이터에 **큰 가중치** · 배깅 = 부트스트랩 **병렬** 학습 후 투표 · 모델 간 상관이 **낮을수록** 효과
- 활성화 함수: 다중 클래스 → **소프트맥스** · 은닉층 없이 **시그모이드** → 로지스틱과 같음 · tanh는 −1~1
- 가중치 수 = 입력×은닉 + 은닉×출력 (20×50 + 50×3 = 1,150) · 층을 깊게 → **기울기 소실** · 가중치 해석 **어려움**
- SVM: 마진 **최대** · 커널은 저차원 → **고차원**

4단원 분류 모형 성과 평가

지표 정의 · ROC

40. 모델이 참이라고 예측한 것 중에서 실제로도 참인 것은?

45회 35번

① 정밀도
② 정확도
③ 재현율
④ F1 점수

정답 ①

'모델이 참이라고 예측한 것 중 실제로도 참'이라는 질문은 ① 정밀도에 해당한다. 실제로 참인 것 중 얼마나 찾았는지를 묻는 재현율과 분모가 반대이다.

핵심 개념: 정밀도 Precision은 양성이라고 예측한 관측값 중 실제 양성의 비율이며 $\frac{TP}{TP+FP}$이다. 분모는 예측 양성 전체이다.

계산 예: 양성 예측 20건 중 실제 양성이 15건이면 정밀도 $= 15/20 = 0.75$이다. 이 수치는 개념을 설명하기 위한 예시이다. ② 정확도는 $\frac{TP+TN}{\text{전체}}$, ③ 재현율은 $\frac{TP}{TP+FN}$, ④ F1은 $\frac{2PR}{P+R}$이다. 불균형 자료에서는 정확도만으로 성능을 충분히 설명하기 어렵다. 어떤 사건을 양성으로 정했는지 먼저 확인한다.

💡 **쉽게 이해하기** **정밀도**는 '내가 참이라고 **찍은 것** 중 진짜 참의 비율'입니다. 비유: 스팸 필터가 스팸이라고 걸러 낸 메일 중 진짜 스팸의 비율. 기준이 **예측** 쪽입니다.

41. 실제 값이 참(True)인 경우 모델이 참으로 올바르게 예측한 비율을 의미하는 지표는?

46회 44번

① 정확도 (Accuracy)
② 정밀도 (Precision)
③ 재현율 (Recall)
④ F1-Score

정답 ③

질문은 '실제 값이 참인 경우'를 기준으로 비율을 구한다. 따라서 분모에는 실제 양성 전체인 TP+FN이 들어가고, 분자에는 그중 찾아낸 TP가 들어간다. ③이 맞다.

핵심 개념: 실제 양성 중 예측도 양성인 비율은 재현율 $Recall = \frac{TP}{TP+FN}$이다. 실제 양성을 기준으로 얼마나 놓치지 않고 찾아냈는지 나타내며 민감도와 같은 의미이다.

보기 검토: ① 정확도는 $\frac{TP+TN}{TP+TN+FP+FN}$으로 전체 관측값에서 맞춘 비율이다. ② 정밀도는 $\frac{TP}{TP+FP}$로 예측 양성 중 실제 양성의 비율이다. ④ F1은 정밀도와 재현율의 조화평균이며 직접적으로 실제 양성에서 찾아낸 비율만을 뜻하지 않는다.

계산 예: 실제 양성이 20명이고 그중 16명을 양성으로 예측했다면 $TP = 16$, $FN = 4$, 재현율은 $16/20 = 0.8$이다. 예측 양성이 총 25명이라면 정밀도는 $16/25 = 0.64$로 별도의 값이다.

학습 포인트: 재현율은 '실제 양성 중 얼마나 찾았나', 정밀도는 '양성으로 예측한 것 중 얼마나 맞았나'로 기억한다. 양성이 드문 자료에서는 모두 음성으로 분류해도 정확도가 높게 나올 수 있어 정확도만으로 판단하지 않는다.

💡 **쉽게 이해하기** **재현율(민감도)**은 '진짜 참인 것 중 내가 **찾아낸** 비율'입니다. 비유: 실제 환자 중 검사로 찾아낸 환자의 비율. 기준이 **실제** 쪽입니다. 정밀도(예측 기준)와 헷갈리지 마세요.

42. 다음 중 아래 설명이 나타내는 모델 성능 평가 지표는?

48회 44번

> 정밀도(Precision)와 재현율(Recall)의 조화평균으로 계산되며, 특히 데이터가 불균형한 상황에서 모델의 성능을 객관적으로 평가할 수 있다.

① 특이도 (Specificity)
② 정확도 (Accuracy)
③ F1-score
④ FP rate

정답 ③

F1=2PR/(P+R)=2TP/(2TP+FP+FN)으로 정밀도와 재현율의 조화평균이다. 정밀도는 양성 예측 중 실제 양성의 비율이고 재현율은 실제 양성 중 찾은 비율이다. 둘 중 하나가 낮으면 F1도 낮아진다. 불균형 자료에서 정확도보다 유용할 수 있지만 TN을 직접 반영하지 않으므로 항상 유일하게 적절한 지표는 아니다. ④ FP rate(위양성률)는 실제 음성 중 양성으로 잘못 예측한 비율 FP/(FP+TN)이다.

💡 **쉽게 이해하기** 정밀도와 재현율은 한쪽을 올리면 다른 쪽이 내려가기 쉽습니다. 둘을 공평하게 하나로 합친 점수가 **F1**(조화평균)입니다. 데이터가 불균형하면 정확도는 믿기 어려워서 F1을 씁니다.

43. X축은 1-특이도(False Positive Rate)를, Y축은 민감도를 나타낸 그래프는?

46회 43번

① ROC 커브
② PR 커브
③ 산점도
④ 이익 곡선

정답 ①

특이도는 $\frac{TN}{TN+FP}$, 1−특이도는 $\frac{FP}{TN+FP}$이다. 민감도는 $\frac{TP}{TP+FN}$이다. 따라서 X축 FPR, Y축 TPR이라는 축 조합을 갖는 그래프는 ① ROC 곡선이다.

핵심 개념: ROC는 분류 임계값을 바꾸면서 거짓양성률 FPR과 참양성률 TPR의 관계를 그린 곡선이다. TPR은 민감도 또는 재현율과 같다.

보기 검토: ② PR 곡선은 보통 X축 재현율, Y축 정밀도이다. ③ 산점도는 두 수치 변수의 관측쌍을 표시하는 일반적인 그래프이다. ④ 이익 곡선은 선택한 대상 비율과 확보한 양성·성과 등을 비교하는 그래프로 ROC의 축 정의와 다르다.

적용 예: 실제 음성 90개 중 9개를 양성으로 잘못 분류했다면 $FPR = 9/90 = 0.1$이다. 실제 양성 10개 중 8개를 찾아내면 $TPR = 8/10 = 0.8$이며 ROC 위의 점은 (0.1,0.8)이다. 이상적인 위치는 (0,1)이다.

학습 포인트: AUC는 임계값을 변화시킨 전반적인 순위 구별 능력을 요약한다. AUC가 높아도 특정 임계값의 정밀도·재현율이 충분하다는 보장은 없으므로 실제 사용 목적에 맞는 기준을 별도로 선택한다.

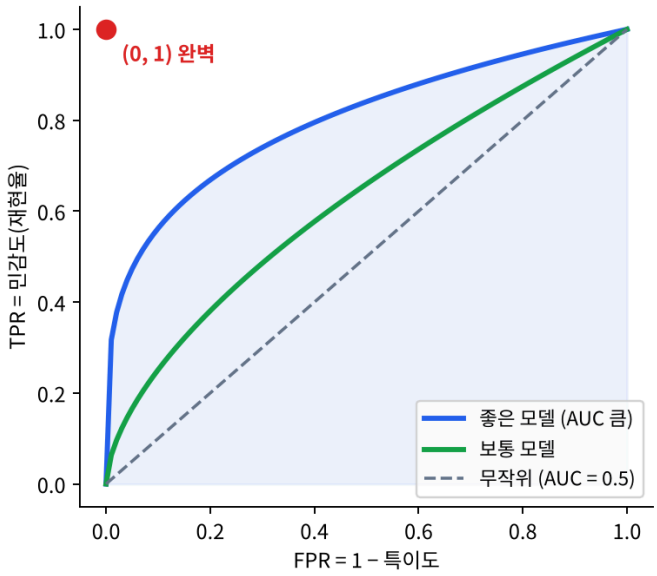
💡 **쉽게 이해하기** ROC 커브는 x축 **1 − 특이도**(잘못 울린 경보 비율), y축 **민감도**(제대로 찾은 비율)입니다. 왼쪽 위로 붙을수록 좋은 모델이고, 곡선 아래 넓이가 AUC입니다.

44. ROC 곡선으로 가장 효율적인 도형을 이끌어냈을 때의 X, Y 좌표 값은? 45회 37번

① (0, 0)
② (1, 0)
③ (0, 1)
④ (1, 1)

> **정답 ③**
> 거짓 양성이 없고 실제 양성을 모두 찾는 이상적인 지점은 $FPR = 0$, $TPR = 1$이므로 ③ (0,1)이다. 가로축을 특이도 자체로 바꾸어 읽지 않는다. 특이도는 1−FPR이다.
>
> 핵심 개념: 표준 ROC 곡선의 가로축은 거짓 양성률 $FPR = \frac{FP}{FP+TN}$, 세로축은 참 양성률 $TPR = \frac{TP}{TP+FN}$이다. 임계값을 바꾸면서 두 비율의 변화를 그린다.
> 보기 검토: (0,0)은 모두 음성으로 예측하는 극단, (1,1)은 모두 양성으로 예측하는 극단에 대응할 수 있다. (1,0)은 실제 방향과 반대로 분류하는 나쁜 지점이다. 실제 최적 임계값은 오분류 비용·유병률·운영 목표에 따라 달라지므로 모든 문제에서 왼쪽 위와의 단순 거리만으로 결정하지 않는다.

💡 **쉽게 이해하기** 가장 좋은 점은 x = 0(거짓 경보 **없음**), y = 1(진짜를 **모두** 찾음)인 **(0, 1)**, 즉 그래프의 왼쪽 위 모서리입니다.



▲ 45회 37번 · ROC 곡선: 왼쪽 위(0, 1)에 가까울수록 좋은 모델, 대각선은 무작위 수준

오분류표 계산

45. 아래 오분류표를 참고하여 민감도를 구하시오. 47회 44번

실제 \ 예측	True (P)	False (N)
True	200 (TP)	400 (FN)
False	100 (FP)	300 (TN)

① 0.33
② 0.5
③ 0.75
④ 0.8

> **정답 ①**
> 오분류표에서 $TP = 200$, $FN = 400$이므로 민감도 $= \frac{200}{200+400} = \frac{1}{3} \approx 0.33$이다.
> 민감도는 실제 양성 중 양성으로 찾아낸 비율이며 재현율 또는 TPR이라고도 한다. 먼저 오분류표에서 실제 양성에 속하는 TP와 FN을 찾아야 한다. 표에서 $TP = 200$, $FN = 400$이므로 실제 양성 전체는 600이다.
> 계산: 민감도 $= \frac{TP}{TP+FN} = \frac{200}{600} = 0.333\ldots$이므로 반올림한 ① 0.33이다. 분모를 예측 양성 TP+FP로 잡으면 정밀도를 계산하게 되어 다른 지표가 된다. 특이도는 $\frac{TN}{TN+FP}$, 정확도는 $\frac{TP+TN}{\text{전체}}$이다. 표의 행·열 배치보다 실제·예측의 표제를 먼저 확인해야 한다.

📋 **출력 읽는 법**

`행 = 실제, 열 = 예측`	먼저 어느 쪽이 실제인지 확인
`TP 200, FN 400`	실제 True 600개 중 200개만 찾음
`민감도`	TP ÷ (TP + FN) = 200 ÷ 600 ≈ 0.33

💡 **쉽게 이해하기** 민감도 = **실제 True** 행만 봅니다. 실제 True = TP 200 + FN 400 = 600. 그중 맞힌 것 TP 200 → 200 ÷ 600 = **0.33**. 실수로 예측 True 열(200 + 100)을 분모로 쓰면 정밀도(0.67)가 됩니다.

46. 다음 이진 분류 결과의 혼동행렬(Confusion Matrix)에서 F1 점수(F1-score)는? 49회 44번

	예측 = 긍정	예측 = 부정
실제 = 긍정	TP = 3	FN = 8
실제 = 부정	FP = 5	TN = 10

① 6/19
② 6/17
③ 3/8
④ 3/11

> **정답 ①**
> 정밀도 = TP/(TP + FP) = 3/8, 재현율 = TP/(TP + FN) = 3/11이다. F1 = 2 × 정밀도 × 재현율 ÷ (정밀도 + 재현율) = 2TP/(2TP + FP + FN) = 6/(6 + 5 + 8) = 6/19이다.

💡 **쉽게 이해하기** 정밀도 = TP ÷ 예측 긍정 = 3 ÷ (3 + 5) = 3/8, 재현율 = TP ÷ 실제 긍정 = 3 ÷ (3 + 8) = 3/11. F1 = 2 × 정밀도 × 재현율 ÷ (정밀도 + 재현율)인데, 더 간단한 공식 **F1 = 2TP ÷ (2TP + FP + FN)** = 6 ÷ (6 + 5 + 8) = **6/19**로 빨리 구할 수 있습니다.

47. 아래 혼동행렬로부터 계산한 오분류율(Error Rate)로 옳은 것은? 50회 49번

어떤 분류 모델의 예측 결과를 정리한 혼동행렬(Confusion Matrix)은 다음과 같다.

	예측 = True	예측 = False	합계
실제 = True	40	90	130
실제 = False	60	60	120
합계	100	150	250

① 0.20
② 0.40
③ 0.55
④ 0.60

> **정답 ④**
> 오분류는 FN = 90과 FP = 60으로 총 150건이다. 오분류율 $= (90 + 60)/250 = 0.60$이다. 정확도는 $(40 + 60)/250 = 0.40$이다.

💡 **쉽게 이해하기** 오분류율 = 틀린 것 ÷ 전체. 틀린 것은 **대각선이 아닌** 칸입니다: 실제 True인데 False로 예측 90 + 실제 False인데 True로 예측 60 = 150. 150 ÷ 250 = **0.6**. 맞힌 것(40 + 60 = 100)으로 정확도 0.4를 구해 1에서 빼도 같습니다.

빠른 정답표

40	①	**41**	③	**42**	③	**43**	①	**44**	③	**45**	①	**46**	①	**47**	④

자주 나오는 함정

- 정밀도 = **예측** 참 중 실제 참 · 재현율(민감도) = **실제** 참 중 참으로 예측 · F1 = 조화평균
- 계산 전에 표의 **행/열 중 어느 쪽이 실제**인지 먼저 확인
- ROC: x축 1 − 특이도, y축 민감도 · 이상적인 점 **(0, 1)**

5단원 군집 분석

거리 척도

48. 연속형 변수 간의 유사성 또는 거리를 측정하는 방법으로 적절하지 않은 것은? 45회 36번

① 맨하탄 거리
② 자카드 거리
③ 마할라노비스 거리
④ 유클리디안 거리

정답 ②

자카드는 집합의 교집합과 합집합 또는 이진 속성의 일치를 기반으로 하는 대표 유사도이므로 연속형 자료의 일반적인 거리 선택에서는 ②가 가장 부적절하다. 자카드 거리=1−자카드 유사도이다.

핵심 개념: 연속형 수치 벡터의 대표 거리는 유클리드, 맨해튼, 마할라노비스 등이다. 유클리드는 제곱 차이 합의 제곱근, 맨해튼은 절댓값 차이 합이며, 마할라노비스는 공분산 구조를 반영한다.
조건 주의: 수치 벡터에 대한 확장 자카드 등의 변형이 있으므로 연속형 자료에 어떤 형태로도 사용할 수 없다는 절대 명제는 아니다.
③은 공분산 행렬의 가역성 등을 확인해야 한다. 변수 단위가 다르면 거리에서 큰 척도의 변수가 지배할 수 있으므로 표준화와 거리 선택의 목적을 함께 검토한다.

💡 **쉽게 이해하기** 자카드는 '두 집합에 **공통으로** 들어 있는 것의 비율'이라 0/1, 있다/없다 같은 **범주형(이진)** 데이터용입니다. 맨해튼·유클리디안·마할라노비스는 숫자 좌표 사이의 거리라 연속형용입니다.

49. 다음 중 변수 간 상관관계를 고려하여 통계적 거리를 측정하는 방법은? 48회 43번

① 유클리드 거리
② 맨해튼 거리
③ 체비셰프 거리
④ 마할라노비스 거리

정답 ④

마할라노비스 거리는 공분산 행렬을 이용하여 변수의 분산과 상관구조를 반영한다. $d^2=(x-\mu)^T\Sigma^{-1}(x-\mu)$이며, 유클리드 거리는 제곱 차이 합의 제곱근, 맨해튼 거리는 절댓값 차이 합, 체비셰프 거리는 최대 절댓값 차이이다. 역행렬 사용에는 공분산 행렬의 가역성 등을 확인해야 한다.

💡 **쉽게 이해하기** 키와 몸무게처럼 함께 움직이는 변수를 그냥 더하면 같은 정보를 두 번 세게 됩니다. **마할라노비스** 거리는 공분산(상관)을 반영해 이 중복을 걸러 낸 '통계적' 거리입니다.

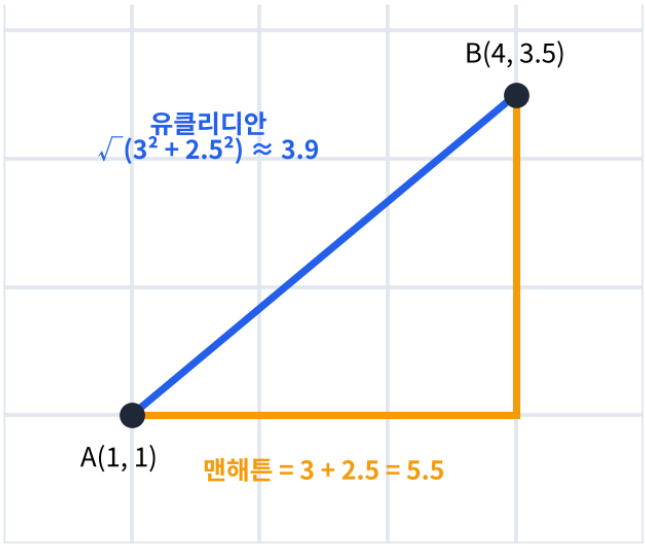
50. 맨해튼 거리(Manhattan distance)와 유클리디안 거리(Euclidean distance)에 대한 설명으로 옳지 않은 것은? 49회 48번

① 맨해튼 거리는 항상 유클리디안 거리보다 작거나 같다.
② 유클리디안 거리는 두 점을 잇는 직선(최단) 거리이다.
③ 맨해튼 거리는 각 차원(좌표) 차이의 절댓값을 모두 더한 값이다.
④ 맨해튼 거리는 격자(바둑판) 형태의 경로를 따라 이동한 거리와 같다.

정답 ①

맨해튼 거리는 항상 유클리디안 거리보다 크거나 같다. 예: (0, 0)과 (3, 4) 사이의 맨해튼 거리는 3 + 4 = 7, 유클리디안 거리는 5이다.

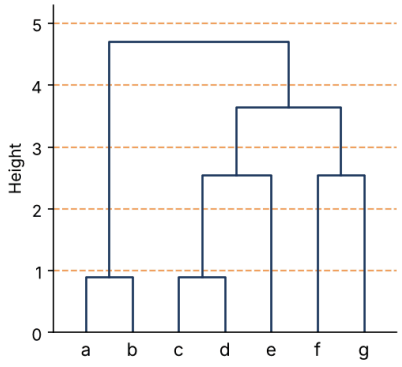
💡 **쉽게 이해하기** 직각삼각형으로 생각하세요. 유클리디안은 **빗변**(대각선 직선), 맨해튼은 **두 변을 따라** 걸은 길입니다. 두 변의 합은 빗변보다 항상 길거나 같으므로 맨해튼 ≥ 유클리디안입니다. ①은 부등호를 뒤집었습니다.



▲ 49회 48번 · 맨해튼(길 따라)은 유클리디안(직선)보다 항상 크거나 같다

계층적 군집 · 연결법

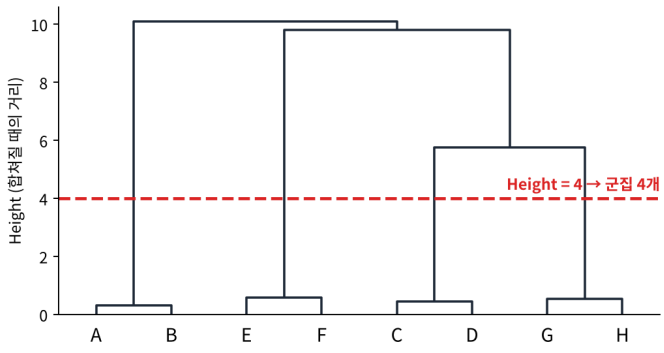
51. 아래 덴드로그램에서 Height=2일 때, 클러스터는 몇 개인가? 45회 44번



① 2개
② 3개
③ 4개
④ 5개

> **정답 ④**
> 높이 2보다 낮은 약 0.9에서 a와 b가 합쳐지고 c와 d도 합쳐진다. e, f, g는 높이 2에서 아직 각각 따로 있다. 따라서 군집은 {a,b}, {c,d}, {e}, {f}, {g}의 다섯 개이고 ④이다.
>
> 핵심 개념: 덴드로그램을 높이 h에서 수평으로 자르면 그 선 아래에서 이미 연결된 관측값들이 하나의 군집을 이룬다. 선과 교차하는 독립 가지 수 또는 아래쪽 연결 묶음을 세면 된다.
> 확인 방법: 최초 7개 단일 군집에서 절단선 아래 합병이 두 번 이루어졌으므로 $7-2=5$로 검산할 수 있다. 약 2.5의 합병은 절단 높이보다 위에 있으므로 포함하지 않는다. 가지의 좌우 배치나 관측값 사이 수평 거리는 군집 수 기준이 아니며, 높이는 사용한 연결법의 합병 기준을 나타낸다.

💡 **쉽게 이해하기** 덴드로그램에서 Height = 2인 곳에 **가로선**을 긋고, 그 선이 **세로선을 몇 개 자르는지** 셉니다. 높이 2보다 아래에서 이미 합쳐진 것(a-b, c-d)은 한 군집이고, 2보다 위에서 합쳐지는 것들은 아직 따로입니다. 그렇게 세면 **5개**입니다.



▲ 45회 44번 · 덴드로그램 읽기: 높이 h에 가로선을 그으면 만나는 세로선 수가 군집 수 (그림은 다른 예)

52. 최장연결법을 이용한 군집분석 수행 결과에 대한 설명으로 옳지 않은 것은? 46회 50번

① 군집 간 거리는 가장 멀리 떨어진 개체들의 거리를 기준으로 한다.
② 군집 간 거리가 최소인 군집들을 순차적으로 합치면서 계층 구조를 형성한다.
③ 동일한 데이터와 방법으로 다시 분석하면 결과가 달라질 수 있다.
④ 이상치에 민감하며, 군집 간 거리가 이상치에 크게 영향을 받을 수 있다.

> **정답 ③**
> 동일한 자료, 거리 계산, 전처리, 연결법과 동률 처리 규칙을 고정하면 응집형 계층 군집의 병합 절차는 결정적이다. 따라서 '다시 분석하면 결과가 달라질 수 있다'는 ③이 옳지 않다. 결과가 초기값에 따라 달라지는 것은 K-means의 특징이다.
>
> 핵심 개념: 최장연결법 complete linkage의 두 군집 A,B 사이 거리는 $d(A,B)=\max_{x\in A,\,y\in B} d(x,y)$이다. 각 단계에서는 이 군집 간 거리들이 가장 작은 두 군집을 합친다. '거리 정의에는 최대', '다음 병합 선택에는 최소'가 사용되는 점을 구분한다.
> 보기 검토: ①은 군집 사이 모든 관측쌍의 거리 중 최댓값을 사용하므로 맞다. ②는 그 방식으로 계산한 군집 간 거리 중 가장 작은 쌍을 병합하므로 맞다. ④는 멀리 떨어진 한 관측값이 최댓값을 크게 바꿀 수 있어 이상치의 영향을 받는다는 설명으로 맞다.
> 학습 포인트: K-means의 초기화 의존성과 계층 군집의 결정적인 병합 절차를 구분한다. 계층적 방법이라고 이상치의 영향이 없는 것은 아니며, 최단·최장·평균·Ward 연결법의 거리 정의를 따로 익힌다.

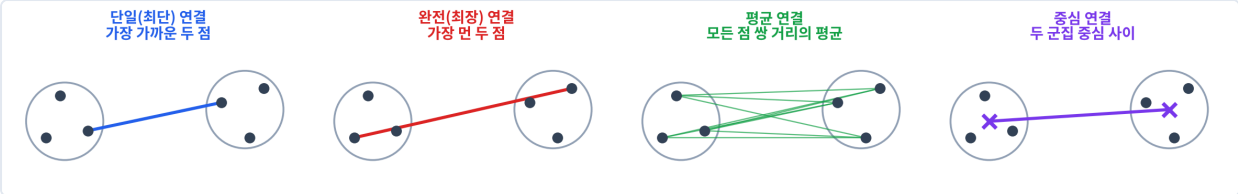
💡 **쉽게 이해하기** 계층적 군집은 계산 규칙이 정해져 있어서 **같은 데이터·같은 방법이면 결과가 항상 같습니다**(무작위 요소 없음). 결과가 매번 달라질 수 있는 것은 초기 중심을 무작위로 고르는 **K-means**입니다.

53. 다음 중 군집을 합병할 때 군집 내 오차 제곱합의 증가량이 가장 작은 쌍을 선택하는 연결법은? 47회 49번

① 중심 연결법
② 평균 연결법
③ 와드 연결법
④ 단일 연결법

> **정답 ③**
> Ward는 군집 합병으로 인한 군집 내 제곱합 증가가 가장 작은 쌍을 선택한다.
>
> Ward 연결법은 현재 군집 중 두 군집을 합쳤을 때 군집 내 오차제곱합이 얼마나 증가하는지 비교하고 그 증가량이 가장 작은 쌍을 선택한다. 유클리드 거리 기반에서는 증가량이 $\frac{n_A n_B}{n_A+n_B}\|\text{중심}_A-\text{중심}_B\|^2$로 표현된다.
> 보기 판단: ③이 정답이다. ① 중심 연결은 군집 중심 사이 거리, ② 평균 연결은 두 군집의 관측값 쌍 거리의 평균, ④ 단일 연결은 관측값 쌍 거리의 최솟값을 이용한다. Ward는 합병에 따른 분산 증가를 기준으로 한다는 차이가 있다. 단계마다 최선의 쌍을 고르는 방식이 전체 가능한 군집 분할의 전역 최적성을 보장하는 것은 아니다.

💡 **쉽게 이해하기** **와드** = 합쳤을 때 군집이 가장 **덜 퍼지는**(오차제곱합 증가가 최소인) 쌍을 고르는 방법입니다. 그래서 조밀하고 크기가 비슷한 군집이 생깁니다.



▲ 47회 49번 · 연결법별로 두 군집 사이 거리를 재는 기준이 다르다

54. 두 군집이 합쳐졌을 때 군집 내 오차 제곱합(SSE)이 가장 적게 증가하는 방향으로 병합되는 군집분석 연결법은? 48회 47번

① 중심 연결법
② 완전 연결법
③ 와드 연결법
④ 평균 연결법

정답 ③
와드 연결법은 두 군집을 합칠 때 군집 내 제곱합이 증가하는 정도를 계산하고 그 증가량이 최소인 쌍을 선택한다. 평균 연결법은 군집 간 관측값 거리의 평균, 완전 연결법은 가장 먼 거리, 중심 연결법은 중심 간 거리 등을 이용한다. 와드법은 보통 제곱 유클리드 거리와 연결되므로 단순히 최소 관측값 거리로 합친다는 설명과 구별한다.

💡 **쉽게 이해하기** '오차 제곱합(SSE)이 가장 적게 증가' = **와드 연결법**. 같은 내용이 47·48·49회에 연속으로 나왔습니다. 가장 먼 점 = 완전, 가장 가까운 점 = 단일, 중심 사이 = 중심 연결법입니다.

55. 계층적 군집분석의 와드 연결법(Ward's method)에 대한 설명으로 옳은 것은? 49회 47번

① 두 군집에 속한 개체 사이의 거리 중 가장 먼 거리를 기준으로 군집을 병합한다.
② 두 군집의 중심(centroid) 사이의 거리를 기준으로 군집을 병합한다.
③ 두 군집 사이의 가장 가까운 거리를 기준으로 군집을 병합한다.
④ 군집 내 오차제곱합(SSE)의 증가가 최소가 되도록 군집을 병합한다.

정답 ④
와드 연결법은 두 군집을 합칠 때 군집 내 오차제곱합(SSE)의 증가량이 최소가 되도록 병합한다. ①은 최장(완전) 연결법, ②는 중심 연결법, ③은 최단(단일) 연결법이다.

💡 **쉽게 이해하기** 보기를 연결법에 맞춰 보면 ① 가장 먼 거리 = **완전**(최장), ② 중심 사이 = **중심**, ③ 가장 가까운 거리 = **단일**(최단), ④ SSE 증가 최소 = **와드**입니다.

K-means · 혼합분포 · SOM · DBSCAN

56. K-means에 대한 설명으로 틀린 것은? 45회 42번

① 비지도 학습에 속하는 군집 알고리즘이다.
② 군집 개수 k를 알고리즘이 자동으로 선택해준다.
③ 클러스터의 중심점을 기준으로 군집을 형성한다.
④ 반복적으로 중심점을 재계산하며 수렴한다.

정답 ②
K를 자동으로 선택한다고 한 ②가 틀리다. 사용자가 여러 K 후보를 비교해 엘보·실루엣·업무 해석 등을 이용할 수 있지만 이것은 표준 K-means의 고정 K 학습 절차와 별도의 선택 과정이다.

핵심 개념: K-means는 군집 수 K를 정하고 관측값 배정과 중심 재계산을 반복하는 비지도학습이다. 표준 알고리즘은 군집 내 제곱거리 합을 줄이는 방향으로 진행한다.
보기 검토: ①③④는 대표적인 작동 방식이다. 유클리드 거리와 산술평균 중심을 이용하는 일반적 구현을 전제로 한다. 초기 중심에 따라 국소해가 달라질 수 있어 여러 초기화를 고려한다. 반복이 수렴했다고 전역 최적해를 찾았다는 뜻은 아니다. 거리 기반이므로 변수 척도와 이상치에도 영향을 받는다.

💡 **쉽게 이해하기** K-means의 K(군집 수)는 **사람이 미리 정해야** 합니다. 알고리즘은 정해진 K개로 나누기만 합니다. K를 고르는 데는 엘보우 방법이나 실루엣 계수를 참고합니다.

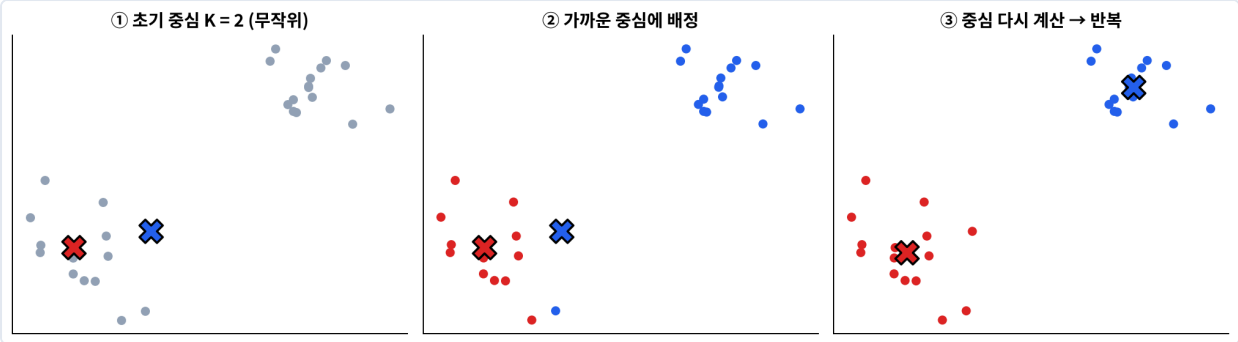
57. K-Means 군집 분석에서 초기 군집 중심 설정 방법으로 옳은 것은? 46회 46번

① 데이터셋 내 모든 데이터의 평균을 군집 중심으로 설정한다.
② 데이터셋 내 모든 데이터의 중앙값을 군집 중심으로 설정한다.
③ 데이터셋 내 무작위로 선택된 임의의 K개 관측점을 설정한다.
④ 군집의 개수만큼 평균값을 설정한다.

정답 ③
③의 자료에서 K개 관측점을 무작위로 선택하는 방법은 가능한 초기화 방식이다. 실무에서는 초기 중심이 너무 가까워지는 문제를 줄이기 위해 K-means++ 같은 방식도 사용하지만 무작위 초기화 자체는 맞는 설명이다.

핵심 개념: K-means는 K개의 중심을 초기화한 뒤, 각 관측값을 가까운 중심에 할당하고 각 군집의 평균으로 중심을 갱신하는 과정을 반복한다. 초기 중심 선택과 이후 중심 갱신은 서로 다른 단계이다.
보기 검토: ①의 전체 자료 평균은 하나의 중심만 제공하므로 일반적인 $K > 1$ 군집의 초기 중심을 구분해 주지 못한다. ②의 전체 자료 중앙값 역시 K개 군집 중심의 일반적 초기화 설명이 아니며, K-means의 중심 갱신은 군집별 평균이다. ④의 '군집 개수만큼 평균값'은 어떤 부분집합의 평균인지와 초기 할당이 제시되지 않아 초기화 절차를 설명하지 못한다.
학습 포인트: K-means는 초기값에 따라 서로 다른 지역 최적해로 수렴할 수 있다. 여러 초기값으로 반복하여 군집 내 제곱합이 작은 결과를 선택할 수 있다. 고정한 난수·자료·설정에서는 재현 가능한 결과를 얻을 수 있다.

💡 **쉽게 이해하기** K-means는 처음에 데이터 중 **K개를 무작위로 골라** 임시 중심(seed)으로 삼고 시작합니다. 전체 평균 하나로는 중심이 1개뿐이라 K개 군집을 시작할 수 없습니다.



▲ 46회 46번 · K-means: 무작위 중심 → 가까운 중심에 배정 → 중심 다시 계산 → 반복

58. 정형 데이터의 구조를 탐색할 때 반응변수 없이 적용할 수 있는 기법은? 48회 48번

① 로지스틱 회귀분석
② 의사결정나무 분류
③ K-평균 군집분석
④ 선형회귀분석

> **정답 ③**
> K-평균은 정답 라벨이나 반응변수 없이 유사한 관측값을 K개의 군집으로 묶는 비지도학습이다. 나머지 보기는 반응변수를 이용하는 지도학습 기법이다. 로지스틱 회귀와 의사결정나무 분류는 범주 예측, 선형회귀는 수치 예측에 사용한다. 군집 번호는 실제 정답 라벨을 자동으로 알아낸 결과가 아니라 분석 후 해석할 그룹이다.

💡 **쉽게 이해하기** '반응변수(Y) 없이' = 정답 없이 = **비지도 학습**. 보기 중 비지도는 **K-평균 군집**뿐입니다. 로지스틱·의사결정나무·선형회귀는 모두 Y가 필요한 지도 학습입니다.

59. 군집분석에 대한 설명으로 적절하지 않은 것은? 47회 48번

① 계층적 군집분석은 덴드로그램을 통해 시각화하여 직관적으로 표현할 수 있다.
② K-평균 군집분석에서 초기 중심값 설정은 군집분석 결과에 영향을 주지 않는다.
③ 이상치(Outlier)나 소음(Noise) 데이터는 군집분석의 성능에 영향을 줄 수 있으므로 전처리 과정에서 제거할 필요가 있다.
④ DBSCAN 방식은 군집 개수를 미리 정할 필요가 없다.

> **정답 ②**
> K-평균은 초기 중심에 따라 결과가 달라질 수 있다.
> K-평균은 초기 중심에서 시작해 관측값 배정과 중심 재계산을 반복하며 군집 내 제곱거리 합을 줄인다. 초기 중심이 다르면 다른 국소해에 도달할 수 있으므로 ②가 틀린 설명이다. 여러 초기화로 반복하거나 개선된 초기화 방법을 사용해 이 문제를 완화할 수 있다.
> 나머지 보기: ① 덴드로그램은 계층적 합병 구조를 시각화한다. ④ DBSCAN은 군집 개수를 직접 입력하지 않지만 밀도 매개변수는 설정해야 한다. ③의 이상치·잡음은 성능에 영향을 줄 수 있으므로 검토와 처리가 필요하다는 취지로 읽는다. 실제 희귀 집단이나 중요한 이상 사건일 수 있어 모든 이상치를 무조건 삭제하는 원칙은 적절하지 않다.

💡 **쉽게 이해하기** K-means는 처음 고른 중심이 어디냐에 따라 **결과가 달라집니다.** 그래서 여러 번 돌려 가장 좋은 결과를 고르기도 합니다. '영향을 주지 않는다'가 틀린 보기입니다.

60. 군집분석에 대한 설명 중 틀린 것은? 45회 47번

① 비지도학습의 한 형태이다.
② K-means는 대표적인 군집화 기법이다.
③ 입력변수가 범주형일 경우 군집 분석을 할 수 없다.
④ 유클리디안 거리 등을 이용해 유사도를 측정할 수 있다.

> **정답 ③**
> 범주형 입력이면 군집분석 자체를 할 수 없다는 ③은 틀리다. 범주형 자료에는 일치 여부 기반 비유사도와 K-modes 등을, 혼합 자료에는 적합한 거리나 K-prototypes 같은 방법을 고려할 수 있다.
> 핵심 개념: 군집분석은 정답 라벨 없이 관측값의 유사성을 이용해 집단을 찾는 비지도학습이다. 사용할 자료 유형에 맞는 거리와 군집 알고리즘을 선택해야 한다.
> 보기 검토: ①②는 기본 개념이고, ④의 유클리드 거리는 수치 자료에서 대표적으로 쓰인다. 범주형 코드를 임의 숫자로 바꿔 유클리드 거리를 적용하면 없는 순서·간격을 만들어낼 수 있어 주의한다. 군집 번호는 알고리즘이 만든 그룹 식별자이며 실제 정답 범주를 자동 발견한 것이라고 단정하지 않는다. 군집 결과의 업무 의미는 별도로 해석한다.

💡 **쉽게 이해하기** 범주형 변수도 자카드 거리, 단순 일치 계수 같은 **범주형용 거리**를 쓰면 군집 분석을 **할 수 있습니다.** '할 수 없다'는 틀립니다.

61. 혼합분포군집 모델에서 최대가능도추정을 보완하기 위해 사용되는 분석 기법은? 47회 45번

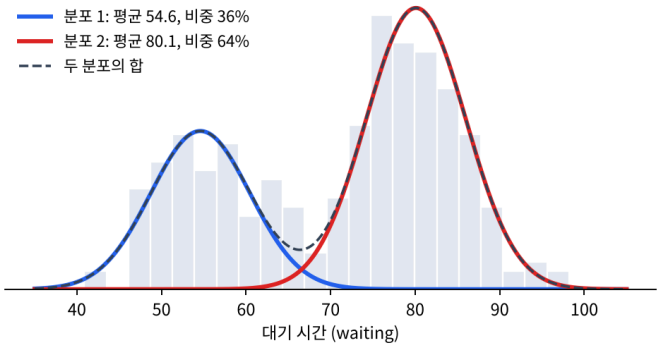
① K-NN 알고리즘
② K-평균 알고리즘
③ Apriori 알고리즘
④ EM 알고리즘

정답 ④

EM은 잠재변수의 기대값 계산과 가능도 최대화 단계를 반복한다.

혼합모형에서는 각 관측값이 어느 성분에서 발생했는지 직접 관측되지 않는 잠재변수가 있다. 이 때문에 관측자료의 가능도를 직접 최적화하기 어려운 경우 EM 알고리즘을 사용할 수 있다. E단계는 현재 모수로 잠재 소속의 조건부 확률 등을 계산하고, M단계는 그 결과를 사용한 기대 로그가능도를 최대화하여 모수를 갱신한다.
보기 판단: ④가 정답이다. ① K-NN은 이웃 기반 예측, ② K-평균은 중심까지 거리 기반 군집화, ③ Apriori는 빈발 항목집합 탐색과 관련된다. EM은 반복 개선 알고리즘이지만 초기값에 따라 다른 국소해에 도달할 수 있어 항상 전역 최적해를 보장한다고 말하지 않는다.

💡 **쉽게 이해하기** 혼합분포 군집은 '데이터가 여러 정규분포에서 섞여 나왔다'고 보고 각 분포의 평균·분산·비중을 추정합니다. 어느 분포 소속인지 모르는 상태에서 추정해야 해서 **E(소속 기댓값 계산) → M(모수 다시 추정)**을 반복하는 **EM 알고리즘**을 씁니다.



▲ 47회 45번 · 혼합분포 군집: 두 정규분포가 섞인 데이터에서 각 분포의 평균·비중을 EM으로 추정

62. SOM에 대한 설명 중 틀린 것은? 45회 43번

① SOM은 경쟁 학습 기반의 신경망이다.
② 차원을 축소해 시각화에 활용할 수 있다.
③ 입력 벡터와 가장 가까운 노드를 BMU라 한다.
④ 부분적으로(locally) 연결된다.

정답 ④

기본 SOM에서는 각 지도 노드가 입력의 모든 차원을 표현하는 가중치 벡터를 갖는다. 따라서 입력층과 지도 노드가 일부 차원끼리만 국소 연결된다는 뜻의 ④는 틀리다. 지도 노드 사이 이웃 관계와 입력 차원에 대한 연결은 다른 개념이다.

핵심 개념: SOM은 입력 벡터와 유사한 대표 벡터를 가진 지도 노드를 찾는 경쟁학습 기반의 비지도 신경망이다. 가장 가까운 노드가 BMU이며, BMU와 지도 위 이웃 노드의 대표 벡터를 입력 쪽으로 갱신한다.
보기 검토: ①은 경쟁학습, ②는 고차원 자료의 저차원 지도화, ③은 BMU의 정의와 맞다. 이웃 갱신이 BMU 주변 지도 노드에만 국소적으로 적용되는 것은 입력층과의 연결 구조와는 다른 개념이다. topology를 완벽하게 보존한다고 단정하지 않는다.

💡 **쉽게 이해하기** SOM은 입력층의 **모든** 노드가 경쟁층의 **모든** 노드와 연결된 **완전 연결** 구조입니다. 입력과 가장 가까운 노드(BMU, 승자 노드)가 학습되며, 고차원을 2차원 지도로 줄여 시각화합니다.

63. 다음 중 군집분석 기법에 대한 설명으로 적절하지 않은 것은? 47회 47번

① DBSCAN은 밀도 기반 군집화 방식으로 초기 중심값 설정이 불필요하다.
② 가우시안 혼합 모델(GMM)은 EM 알고리즘을 사용하여 모델 매개변수를 추정하며, 초기 중심값 설정에 따라 그 결과가 달라질 수 있다.
③ 자기 조직화 지도(SOM)는 비지도 학습으로 차원축소와 군집화를 동시에 수행한다.
④ 자기 조직화 지도(SOM)는 경쟁층의 모든 노드에 동일한 수의 데이터가 할당된다.

정답 ④

SOM의 경쟁층 각 노드에 배정되는 관측 수가 모두 같아야 할 필요는 없다.

DBSCAN은 eps와 min_samples 같은 밀도 조건으로 군집을 구성하며 초기 중심이나 군집 개수 K를 직접 정하지 않는다. GMM은 분포들의 혼합으로 관측값을 설명하고 EM 등의 방법으로 모수를 추정하므로 초기화가 결과에 영향을 줄 수 있다. SOM은 입력의 유사성 구조를 저차원 경쟁층 지도에 반영하는 비지도 방법이다.
보기 판단: ①②③은 위 특징을 설명한다. ④는 모든 경쟁층 노드에 같은 수의 관측값이 배정된다고 단정하므로 틀리다. SOM은 관측값에 가장 잘 대응하는 노드와 주변 노드를 갱신하지만 각 노드의 배정 빈도를 균등하게 만드는 조건은 없다. 일부 노드에는 많은 자료가, 다른 노드에는 거의 없는 자료가 대응할 수 있다.

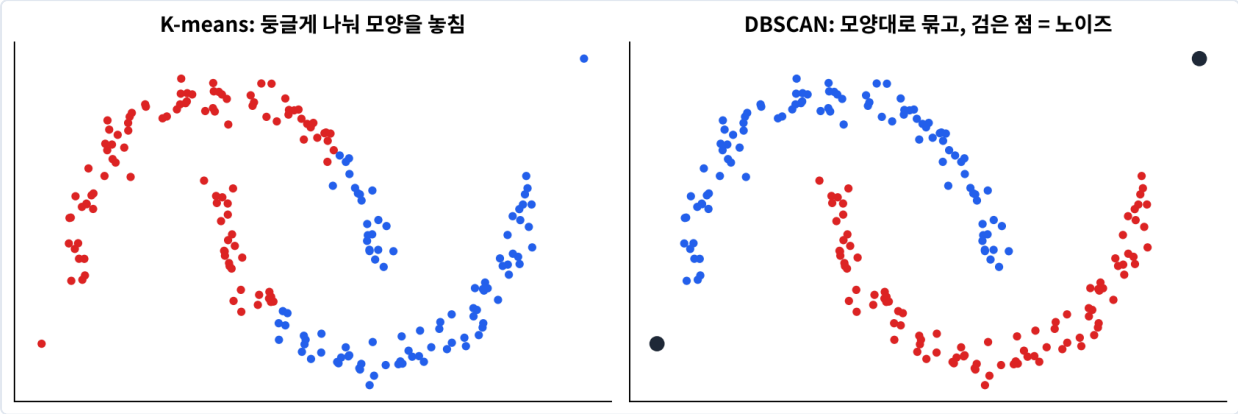
💡 **쉽게 이해하기** SOM은 비슷한 데이터를 같은 노드에 모으므로, 데이터가 몰리는 노드도 있고 거의 없는 노드도 있습니다. 노드마다 **같은 수**로 나눠 주는 규칙은 없습니다.

64. 밀도 기반 군집분석 기법인 DBSCAN에 관한 설명으로 틀린 것은? 50회 50번

① 군집의 개수 K를 사전에 지정할 필요가 없다.
② 밀도가 낮은 영역의 관측치를 노이즈(이상치)로 분류할 수 있다.
③ 반달 모양이나 오목한 형태 등 비구형 군집도 탐색할 수 있다.
④ DBSCAN은 군집 간 거리를 이용해 단계적으로 병합하는 계층적 군집분석 방법이다.

> **정답 ④**
> DBSCAN은 이웃 반경과 최소 이웃 수를 이용하는 밀도 기반 방법이다. 군집 수를 미리 지정하지 않고 비구형 군집과 노이즈를 탐색할 수 있다. 단계적 병합은 계층적 군집분석의 설명이다.

💡 **쉽게 이해하기** DBSCAN은 '빽빽하게 모인 곳'을 군집으로 봅니다(**밀도 기반**). 거리로 가까운 것부터 단계적으로 합치는 것은 **계층적 군집**의 설명이라 ④가 틀립니다. DBSCAN은 K가 필요 없고, 반달 모양도 잘 묶으며, 외톨이 점은 노이즈로 뺍니다.



▲ 50회 50번 · 반달 모양 데이터: K-means(왼쪽)는 잘못 묶고 DBSCAN(오른쪽)은 제대로 묶는다

빠른 정답표

48	②	49	④	50	①	51	④	52	③	53	③	54	③	55	④	56	②	57	③
58	③	59	②	60	③	61	④	62	④	63	④	64	④						

자주 나오는 함정

- 연속형 거리가 아닌 것 → **자카드** · 상관 고려 → **마할라노비스** · 맨해튼은 유클리디안보다 **크거나 같다**
- SSE 증가가 최소인 쌍 병합 → **와드** · 덴드로그램 Height에 가로선 → 만나는 세로선 수 = 군집 수
- K-means: k를 **직접** 정함, 초기 중심이 결과에 **영향** · 범주형도 군집 분석 가능
- 혼합분포 → **EM** · SOM은 **완전 연결** · DBSCAN은 밀도 기반, k 지정 불필요

6단원 연관 분석

측도 정의 · 성질

65. 연관분석에서 A → B일 경우, 지지도에 해당하는 것은? 45회 46번

① A가 나왔을 때 B도 나올 확률
② 전체 중에서 A와 B 동시에 구매할 확률
③ A가 발생한 경우 중 B도 발생한 비율
④ B가 발생한 경우 중 A도 발생한 비율

정답 ②
전체 중 동시 구매할 확률이라는 ②가 정의에 대응한다. ①③은 A가 있는 거래를 분모로 잡는 신뢰도 $P(B|A)$이고, ④는 역방향 신뢰도 $P(A|B)$이다.
핵심 개념: 연관규칙 A→B의 지지도는 전체 거래 중 A와 B를 함께 포함한 비율 $P(A \cap B)$이다. 규칙의 발생 빈도를 전체 거래 기준으로 나타내며 화살표 방향을 바꾸어도 같다.
계산 예: 전체 100건, A 포함 40건, 동시 포함 20건이라면 지지도는 $20/100 = 0.2$, A→B 신뢰도는 $20/40 = 0.5$이다. 같은 분자를 쓰더라도 분모가 달라지는 이유를 이해한다. 향상도는 신뢰도를 B의 전체 발생률로 나눈 값이다.

💡 **쉽게 이해하기** **지지도** = 전체 영수증 중 A와 B가 **함께** 찍힌 영수증의 비율. ①·③은 'A를 샀을 때'라는 조건이 붙은 **신뢰도**(A → B), ④는 B → A의 신뢰도입니다.

66. 연관규칙 분석에서 지지도(Support) 계산방식으로 옳은 것은? 48회 45번

① A를 포함하는 거래 중 A와 B가 동시에 거래되는 비율
② 전체 거래 중 A와 B가 동시에 포함된 거래 비율
③ A가 구매되지 않았을 때 B의 구매확률
④ A가 구매되지 않았을 때 B의 구매확률에 비해, A가 구매되었을 때 B의 구매확률이 증가한 비율

정답 ②
지지도는 전체 거래 중 A와 B가 동시에 발생한 비율 P(A∩B)이다. A 거래를 분모로 쓰는 P(B|A)는 신뢰도이다. 지지도와 신뢰도는 분자에 같은 동시 거래 건수가 들어갈 수 있어도 분모가 다르다. 지지도는 규칙의 전체 발생 빈도, 신뢰도는 선행항목 A가 있을 때 후행항목 B의 발생 비율을 나타낸다.

💡 **쉽게 이해하기** 지지도의 분모는 **전체 거래**입니다. 분모가 'A를 포함하는 거래'면 신뢰도, ④처럼 'A가 없을 때보다 있을 때 얼마나 늘었나'는 향상도 이야기입니다.

67. 다음 중 연관 분석에 대한 설명으로 옳지 않은 것은? 46회 48번

① 지지도는 전체 거래 중 특정 물건들이 동시에 나타나는 비율을 의미한다.
② 일반적으로 연관 분석 시 지지도보다 신뢰도가 더 중요하다.
③ 조건 반응(If - then) 기반으로 분석 결과에 대한 명확한 이해가 가능하다
④ 대표적인 예시로 장바구니 분석이 있다.

정답 ②
②는 신뢰도가 지지도보다 일반적으로 더 중요하다고 일괄적으로 순위를 정한다. 어떤 지표가 중요한지는 업무 목적과 규칙의 사용 방식에 따라 다르다. 드문 조합의 신뢰도가 높아도 전체 영향은 작을 수 있고, 흔한 결과 항목은 독립 관계에서도 신뢰도가 높게 나타날 수 있다.
핵심 개념: 연관규칙 A→B에서 지지도는 전체 거래에서 A와 B를 함께 포함하는 비율, 신뢰도는 A를 포함한 거래에서 B도 포함하는 비율이다. 향상도는 그 신뢰도를 B의 기본 발생률과 비교한 값이다.
보기 검토: ①은 공동 발생 비율이라는 지지도의 정의이다. ③은 'A가 있으면 B도 나타나는 경향'이라는 규칙 형태로 결과를 이해할 수 있다는 설명이다. ④의 장바구니 분석은 동시 구매 패턴을 찾는 대표 활용 사례이다. 다만 규칙의 방향이 상품 A의 구매가 B의 구매를 원인적으로 발생시킨다는 뜻은 아니다.
계산 예: 전체 거래의 90%가 우유를 포함하면, 커피 구매자 중 90%가 우유를 샀더라도 신뢰도 0.9만으로 특별한 연관이라고 말하기 어렵다. 향상도는 $0.9/0.9 = 1$이므로 독립적인 기준 발생률과 같은 수준이다.
학습 포인트: 지지도·신뢰도·향상도를 함께 보고 최소 거래건수와 활용 가치도 확인한다. 한 지표만 높다는 이유로 좋은 규칙이라고 결론 내리지 않는다.

💡 **쉽게 이해하기** 지지도(얼마나 자주), 신뢰도(얼마나 확실히), 향상도(우연보다 얼마나 나은지)는 **함께** 봐야 합니다. 신뢰도가 높아도 지지도가 아주 낮으면 몇 건 안 되는 우연일 수 있습니다. 어느 하나가 '더 중요'하다고 할 수 없습니다.

68. 다음 중 향상도(Lift)에 대한 설명으로 적절한 것은? 48회 50번

① 향상도는 'A와 B가 각각 독립적으로 일어날 확률의 곱'을 'A와 B가 동시에 일어날 확률'로 나누어 계산된다.
② 향상도가 1보다 크면 해당 규칙은 양의 상관성을 가진다.
③ 향상도가 0일 때, 두 거래품목 간에는 상관성이 없다.
④ 향상도가 0보다 작을 때, 음의 상관성을 가진다.

정답 ②
향상도=P(A∩B)/[P(A)P(B)]=P(B|A)/P(B)이다. 1보다 크면 독립일 때보다 함께 발생할 비율이 높고, 1이면 독립 기준과 같으며, 1보다 작으면 함께 발생할 비율이 낮다. 정의되는 경우 음수가 될 수 없다. ①은 비율을 거꾸로 적었고 ③은 독립 기준을 0으로 혼동했으며 ④도 불가능한 음수 값을 설명한다. 향상도가 높아도 충분한 거래 수와 실무적 의미를 추가로 검토해야 한다.

💡 **쉽게 이해하기** 향상도 = P(A∩B) ÷ (P(A) × P(B)). ①은 분자·분모를 **뒤집었습니다**. 독립이면 향상도 = **1**(0이 아님), 1보다 작으면 음의 관계입니다. 확률끼리 나눈 값이라 0보다 작아질 수는 없습니다.

69. 연관규칙 A → B의 방향을 B → A로 바꾸었을 때 지지도·신뢰도·향상도에 관한 설명 중 틀린 것은? 50회 33번

① 향상도는 바뀌지 않는다.
② 지지도는 바뀌지 않는다.
③ 신뢰도는 조건부확률에 기반한다.
④ 신뢰도는 바뀌지 않는다.

정답 ④

지지도 $P(A \cap B)$와 향상도 $\frac{P(A \cap B)}{P(A)P(B)}$는 방향에 무관하다.
신뢰도는 $P(B \mid A)$와 $P(A \mid B)$로 분모가 달라 일반적으로 바뀐다.
특수하게 같을 수는 있으나 항상 같다는 주장은 틀리다.

💡 **쉽게 이해하기** 방향을 바꿔도 '둘이 함께 산 비율'(지지도)과 '우연 대비 몇 배'(향상도)는 식이 대칭이라 그대로입니다. **신뢰도**만 분모가 P(A) → P(B)로 바뀌어서 달라집니다.

측도 계산

70. 다음은 거래 데이터에서 버터와 빵의 구매 비율이다. 빵을 구매했을 때 버터도 함께 구매할 신뢰도(빵 → 버터)는? 45회 45번

버터(A)	빵(B)	버터+빵
0.6	0.8	0.6

① 향상도: 0.25
② 향상도: 1.25
③ 신뢰도: 0.6
④ 신뢰도: 0.75

정답 ④

빵→버터 신뢰도 $= 0.6/0.8 = 0.75$이므로 ④이다. 거래 5건으로 보면 빵을 포함한 4건 중 버터도 포함한 거래가 3건이다.

핵심 개념: 지지도는 $P(A \cap B)$, 빵→버터 신뢰도는 $P(\text{버터}|\text{빵}) = \frac{P(\text{버터} \cap \text{빵})}{P(\text{빵})}$, 향상도는 신뢰도를 $P(\text{버터})$로 나눈 값이다.

보기 검토: ③ 0.6은 지지도 $P(\text{버터} \cap \text{빵})$이다. 향상도는 $\frac{0.6}{0.6 \times 0.8} = 1.25$로 ② 값이 계산상 맞지만 질문은 신뢰도를 묻는다. ①의 0.25는 계산 근거가 없다.

학습 포인트: 신뢰도는 방향에 따라 다르다. 버터→빵 신뢰도는 $0.6/0.6 = 1$이다. 향상도는 방향과 관계없이 같다.

💡 **쉽게 이해하기** 신뢰도(빵 → 버터) = 둘 다 산 비율 ÷ **조건(빵)**의 비율 = 0.6 ÷ 0.8 = **0.75**. 분모에 무엇을 넣는지는 **화살표 왼쪽**(조건)이 정합니다. 참고로 향상도 = 0.75 ÷ 0.6(버터) = 1.25입니다.

71. 아래 특정 기간 동안 판매된 음료 구매 건 수를 통해 "커피 → 우유"의 지지도는? 46회 49번

구매 품목	구매건수
커피	100
우유	100
녹차	100
커피 + 우유	250
우유 + 녹차	200
녹차 + 커피	200
커피 + 우유 + 녹차	50

① 0.2
② 0.25
③ 0.3
④ 0.35

정답 ③

커피와 우유를 함께 포함하는 거래는 두 품목만 구매한 250건과 세 품목을 모두 구매한 50건이다. 따라서 지지도 $= (250 + 50)/1000 = 300/1000 = 0.3$이며 ③이다.

핵심 개념: A→B의 지지도는 $P(A \cap B)$이다. 규칙에 화살표가 있어도 지지도는 '전체 거래 중 두 항목이 함께 발생한 비율'이며 방향에 따라 바뀌지 않는다. 조건부확률인 신뢰도와 구분한다.

자료 해석: 표의 구매 범주를 서로 중복되지 않는 조합별 거래건수로 읽는다. 커피만 100, 우유만 100, 녹차만 100, 커피·우유만 250, 우유·녹차만 200, 녹차·커피만 200, 세 품목 모두 50으로 총 1,000건이다. 각 단일 항목의 100을 전체 항목 구매 총수라고 해석하면 공동 구매 250보다 작아 모순이 생기므로 조합별 범주라는 해석이 필요하다.

보기 검토: ②의 0.25는 세 품목 공동 구매 50건을 빠뜨린 값이다. ①의 0.2와 ④의 0.35는 해당 공동 구매 건수와 맞지 않는다. 세 품목 구매에서도 커피와 우유는 함께 나타나므로 반드시 포함한다.

추가 계산: 커피 포함 거래는 $100 + 250 + 200 + 50 = 600$건이다. 커피→우유의 신뢰도는 $300/600 = 0.5$로 지지도 0.3과 다르다.

💡 **쉽게 이해하기** 지지도는 커피와 우유가 **함께 들어간 모든 거래**를 셉니다. '커피 + 우유' 250건뿐 아니라 '커피 + 우유 + 녹차' 50건도 포함 → 300건. 전체 = 100 + 100 + 100 + 250 + 200 + 200 + 50 = 1,000건. 300 ÷ 1,000 = **0.3**.

72. 아래 특정 기간 동안 판매된 음료 구매 건 수를 통해 "우유 → 커피"의 지지도는? 47회 50번

> 거래 구성: 커피만 20건, 우유만 50건, 커피와 우유 동시 구매 30건, 전체 100건.

① 0.2
② 0.3
③ 0.4
④ 0.5

정답 ②
지지도는 두 품목을 함께 포함한 거래 수를 전체 거래 수로 나눈 값이므로 $30/100 = 0.3$이다. 방향과 관계없다.
거래 범주가 서로 겹치지 않도록 정리된 표에서 전체 거래는 $20 + 50 + 30 = 100$건이다. 우유와 커피를 모두 포함하는 거래는 30건이므로 지지도 $= P(\text{우유} \cap \text{커피}) = 30/100 = 0.3$, 정답은 ②이다. 화살표 방향은 지지도 계산에 영향을 주지 않는다.
지표 비교: 우유 구매는 우유만 50건과 동시 구매 30건을 더한 80건이므로 우유→커피의 신뢰도는 $30/80 = 0.375$이다. 커피 구매는 $20 + 30 = 50$건이므로 커피→우유의 신뢰도는 $30/50 = 0.6$이다. 향상도는 $\frac{0.375}{50/100} = 0.75$이다.

💡 **쉽게 이해하기** 지지도는 방향과 상관없이 '둘을 **함께** 산 거래 ÷ 전체'입니다. 커피와 우유 동시 구매 30건 ÷ 전체 100건 = **0.3**. '우유만 50건'은 지지도 계산에 쓰지 않습니다.

73. 아래 품목별 거래 건수 테이블에서 연관규칙 A → B의 신뢰도는? 48회 49번

품목	구매건수
A	100
B	50
C	150
A, C	150
A, D	50
A, B, C	200
A, B, C, D	100
B, C, D	100

① 40 %
② 50 %
③ 60 %
④ 65 %

정답 ②
신뢰도(A→B)=A와 B 동시 거래 수/A 거래 수이다. A 거래는 A 100+A,C 150+A,D 50+A,B,C 200+A,B,C,D 100=600건이다. 그중 B도 포함한 거래는 200+100=300건이므로 300/600=0.5=50%이다. 표의 전체 거래는 900건이므로, 전체를 분모로 쓰면 지지도 300/900 ≈ 33.3%가 된다. 이를 신뢰도와 혼동하지 않는다. A를 포함하지 않은 거래는 신뢰도 분모에 넣지 않는다.

📋 **출력 읽는 법**

A가 포함된 행	A, AC, AD, ABC, ABCD → 100 + 150 + 50 + 200 + 100 = **600**
A와 B가 함께 포함된 행	ABC, ABCD → 200 + 100 = **300**
B, C, D (100)	A가 없으므로 분모·분자 모두 제외
신뢰도	300 ÷ 600 = 0.5

💡 **쉽게 이해하기** 신뢰도(A → B) = A와 B가 함께 든 거래 ÷ **A가 든 모든 거래**. A가 든 거래 = A 100 + (A, C) 150 + (A, D) 50 + (A, B, C) 200 + (A, B, C, D) 100 = 600. 그중 B도 있는 것 = 200 + 100 = 300. 300 ÷ 600 = **50%**.

74. 거래 100건 중 기저귀(A)를 포함한 거래는 51건, 맥주(B)를 포함한 거래는 50건, 두 품목을 모두 포함한 거래는 34건이다. 연관규칙 'A → B'에 대한 설명으로 옳지 않은 것은? 49회 49번

① 지지도(support)는 0.34이다.
② 신뢰도(confidence)는 약 0.67이다.
③ 신뢰도(confidence)는 0.34이다.
④ 향상도(lift)는 약 1.33으로 1보다 크다.

정답 ③
지지도 = 34/100 = 0.34, 신뢰도 = P(A ∩ B)/P(A) = 34/51 ≈ 0.67, 향상도 = 0.67 ÷ (50/100) ≈ 1.33이다. ③은 지지도 값을 신뢰도로 잘못 쓴 것이다.

💡 **쉽게 이해하기** 지지도 = 34 ÷ 100 = **0.34**, 신뢰도 = 34 ÷ 51(기저귀) ≈ **0.67**, 향상도 = 0.67 ÷ 0.50(맥주) ≈ **1.33**. ③은 지지도 값(0.34)을 신뢰도라고 바꿔 쓴 함정입니다.

75. 다음 거래 데이터에서 연관규칙 'B → C'의 지지도(support)는? 49회 50번

> 전체 거래 10건 중 품목 B를 포함한 거래는 7건, 품목 C를 포함한 거래는 6건이며, B와 C를 동시에 포함한 거래는 5건이다.

① 0.7
② 0.6
③ 0.5
④ 0.71

정답 ③
지지도 = B와 C를 동시에 포함한 거래 수 ÷ 전체 거래 수 = 5/10 = 0.5이다. 참고로 신뢰도는 5/7 ≈ 0.71이다.

💡 **쉽게 이해하기** 지지도 = 함께 들어 있는 거래 ÷ 전체 = 5 ÷ 10 = **0.5**. 5 ÷ 7(B 기준) ≈ 0.71은 **신뢰도**(B → C)라서 오답 보기로 나왔습니다.

76. 아래 자료에서 연관규칙 [우유 → 빵]의 향상도(Lift)를 계산한 값으로 옳은 것은? 50회 27번

어느 편의점의 거래 12건을 우유와 빵의 구매 조합에 따라 분류한 결과는 다음과 같다.

구매 조합	우유만 구매	빵만 구매	우유·빵 동시 구매	둘 다 미구매	합계
거래 건수	2건	2건	4건	4건	12건

① $\frac{2}{3}$
② $\frac{3}{4}$
③ 1
④ $\frac{4}{3}$

정답 ④
$P(\text{우유}) = 6/12$, $P(\text{빵}) = 6/12$, $P(\text{우유} \cap \text{빵}) = 4/12$이다.
향상도 $= \frac{4/12}{(6/12)(6/12)} = \frac{4}{3}$이다. 신뢰도 $4/6 = 2/3$와 혼동하지 않는다.

💡 **쉽게 이해하기** 먼저 각 확률을 구합니다. P(우유) = (우유만 2 + 둘 다 4) ÷ 12 = 6/12, P(빵) = (빵만 2 + 둘 다 4) ÷ 12 = 6/12, P(둘 다) = 4/12. 향상도 = (4/12) ÷ (6/12 × 6/12) = (1/3) ÷ (1/4) = **4/3**. 1보다 크므로 우유를 사면 빵을 살 확률이 높아집니다.

Apriori

77. 아래는 아이템별 거래 집합이다. Apriori 알고리즘을 적용하고 최소 지지도를 2로 설정했을 때, 길이가 가장 긴 빈발 항목집합은? 46회 47번

> 아이템 거래 : {a, b}, {a, b, d}, {b, c, e}, {d, e}, {a, b, c, e}
> 최소 지지도 2는 비율 2가 아닌 최소 지지건수 2를 뜻한다.

① {a, b}
② {a, b, d}
③ {b, c, e}
④ {a, b, c, e}

정답 ③
단일 항목의 건수는 $a=3, b=4, c=2, d=2, e=3$으로 모두 기준을 만족한다. 길이 2 중 a·b는 3건, b·c는 2건, b·e는 2건, c·e는 2건이다. 길이 3의 {b,c,e}는 T_3와 T_5에서 2건이다. 길이 4의 {a,b,c,e}는 T_5에서만 1건이므로 탈락한다.

핵심 개념: 빈발 항목집합은 지정한 최소 지지도를 만족하는 항목 조합이다. 이 문제의 '2'는 비율이 아니라 최소 지지건수 2이다. 다섯 거래 중 적어도 두 거래에 함께 나타나야 한다.
자료 확인: 그림의 거래는 $T_1 = \{a, b\}$, $T_2 = \{a, b, d\}$, $T_3 = \{b, c, e\}$, $T_4 = \{d, e\}$, $T_5 = \{a, b, c, e\}$이다.
보기 검토: ① {a,b}는 빈발이지만 길이 2이므로 최대 길이가 아니다. ② {a,b,d}는 T_2 한 건만 포함하여 기준을 충족하지 않는다. ③은 지지건수 2와 길이 3을 만족한다. ④는 길이는 길지만 한 건에만 나타나므로 빈발이 아니다.
학습 포인트: Apriori는 어떤 집합이 빈발이라면 모든 부분집합도 빈발이라는 성질을 이용한다. 빈발이 아닌 부분집합을 포함하는 후보는 제거할 수 있다. 최대 길이와 최대 지지건수는 다른 조건이다. {a,b}의 지지건수가 더 많아도 질문은 길이가 가장 긴 집합을 묻는다.

📋 **출력 읽는 법**

거래 5건	{a,b} / {a,b,d} / {b,c,e} / {d,e} / {a,b,c,e}
{a,b}	1·2·5번 거래 → 3회 ✔
{b,c,e}	3·5번 거래 → 2회 ✔ (3개짜리 중 유일하게 통과)
{a,b,d}	2번 거래만 → 1회 ✘
{a,b,c,e}	5번 거래만 → 1회 ✘

💡 **쉽게 이해하기** 최소 지지건수 2 = **2번 이상** 나온 묶음만 살아남습니다. 1개짜리: a 3, b 4, c 2, d 2, e 3 (모두 통과). 2개짜리: ab 3, bc 2, be 2, ce 2 등. 3개짜리: {b, c, e}가 {b, c, e}와 {a, b, c, e} 두 거래에 나와 통과. {a, b, d}는 1번, {a, b, c, e}는 1번뿐이라 탈락 → 가장 긴 것은 **{b, c, e}**.

빠른 정답표

65	②	66	②	67	②	68	②	69	④	70	④	71	③	72	②	73	②	74	③
75	③	76	④	77	③														

자주 나오는 함정

- 지지도 = P(A∩B) · 신뢰도 = P(A∩B) ÷ **P(A)** · 향상도 = 신뢰도 ÷ P(B)
- 방향을 바꾸면 **신뢰도만** 바뀜 (지지도·향상도 그대로) · 향상도 > 1 양의 관계, = 1 독립
- 품목 구매율은 그 품목이 **포함된 모든 거래**를 더해서 계산 · "신뢰도가 지지도보다 더 중요" → 틀림
- Apriori: 최소 지지도 미만을 지우며 1개 → 2개 → 3개 집합 순으로