ADsP 데이터분석 준전문가 · 3과목 3장 정형 데이터 마이닝

3과목 3장
정형 데이터 마이닝

초보자를 위한 설명 · 시험에 중요한 내용 중심 · 단원마다 출제 유형과 함정 정리

1단원	데이터 마이닝 개요·데이터 분할
2단원	분류 ① 로지스틱 회귀·의사결정나무
3단원	분류 ② 앙상블·인공신경망·나이브 베이즈·k-NN·SVM
4단원	분류 모형 성과 평가: 오분류표·ROC
5단원	군집 분석
6단원	연관 분석

보는 법

· 노란 상자 = 한 문장 요약·외우는 법 · 초록 상자 = 시험 출제 유형과 함정

1단원 데이터 마이닝 개요·데이터 분할

> **한 문장 요약:** 데이터 마이닝은 많은 데이터에서 **숨은 규칙·패턴**을 찾아 예측과 의사결정에 쓰는 것입니다. 정답(Y)이 있으면 **지도 학습**, 없으면 **비지도 학습**입니다. 모델은 **처음 보는 데이터**로 평가해야 하므로 데이터를 **나눠서** 검증합니다.

1. 데이터 마이닝의 종류

- **지도 학습: 정답(종속변수)이 있는** 데이터로 학습합니다. 예: "고양이", "강아지"라는 이름표가 붙은 사진으로 배워 새 사진을 판별합니다.
- **비지도 학습: 정답 없이** 학습합니다. 예: 이름표 없는 사진 100장을 **비슷한 것끼리 묶습니다**(군집화).

지도 학습		비지도 학습	
회귀 (Y 연속형)	선형회귀, 회귀나무, 신경망	**군집**	K-means, 계층적 군집, SOM, DBSCAN
분류 (Y 범주형)	로지스틱 회귀, 분류나무, 신경망, 앙상블, k-NN, SVM, 나이브 베이즈	**연관**	Apriori

목적	학습	하는 일	예
분류	지도	**이미 분류된 데이터**로 배워 새 데이터가 **어느 그룹에 속하는지** 판별	우량/불량, 신용등급
군집	비지도	비슷한 것끼리 **묶기만** 함 (미래 값 예측 아님)	고객 세분화
연관	비지도	**함께 일어나는** 규칙을 찾음	장바구니 분석

- **다중 회귀분석은 분류 모형이 아닙니다.** Y가 숫자인 예측 모형입니다. 로지스틱 회귀는 이름에 '회귀'가 있어도 분류입니다.

2. 데이터 마이닝 프로세스

목적 정의 → 데이터 준비 → 데이터 가공 → 기법 적용 → 검증

단계	하는 일
① **목적 정의**	무엇을 알고 싶은지 **분명한 목적**을 정함
② **데이터 준비**	필요한 데이터를 **수집**하고 정제해 품질과 양을 확보
③ **데이터 가공**	**목적변수를 정의**하고, 기법에 맞는 **형식으로 변환**
④ **기법 적용**	준비한 데이터에 분석 기법을 적용
⑤ **검증**	결과를 **평가**하고 실제 업무에 쓸 수 있는지 확인

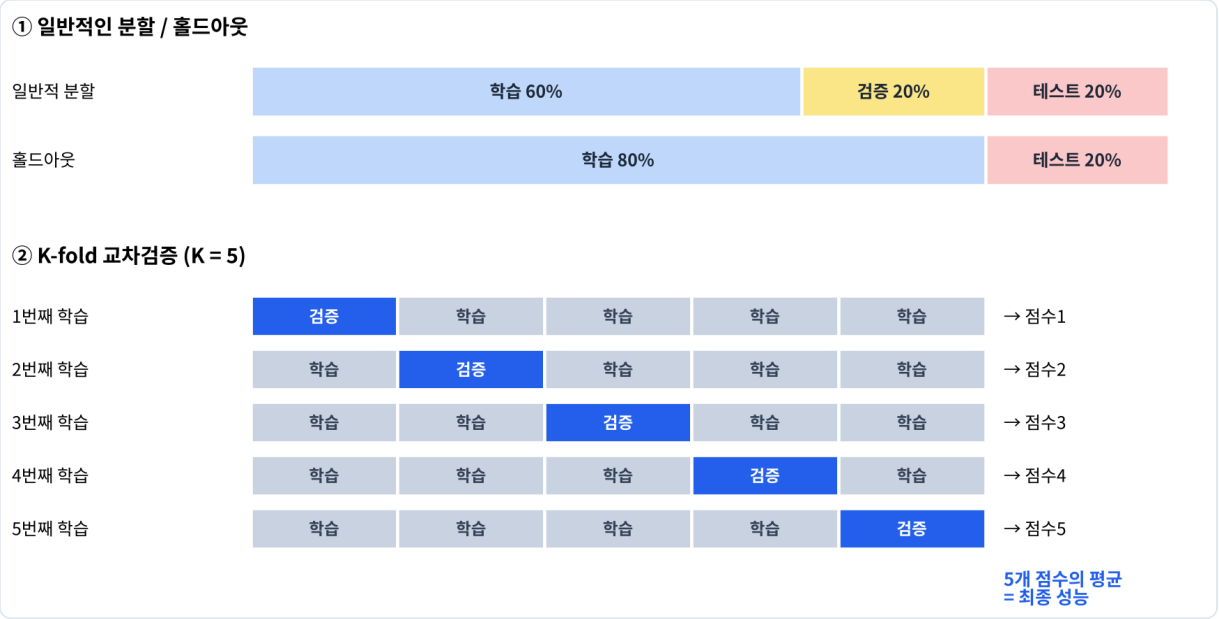
비유: 무엇을 만들지 정하고(목적) → 장을 보고(준비) → 손질하고(가공) → 조리하고(기법 적용) → 맛을 봅니다(검증). 장보기 전에 손질할 수 없으니 **준비 → 가공** 순서입니다.

3. 데이터 분할

비율은 보통 **학습 50% · 검증 30% · 테스트 20%**, 또는 **60% · 20% · 20%**입니다. **학습용이 가장 많습니다.**

데이터	하는 일
학습용 (train)	모델을 **만드는** 데이터 (가중치·파라미터 학습)
검증용 (validation)	모델이 적합한지 확인해 **과대·과소적합을 조정**
테스트용 (test)	**최종 성능** 평가. 학습에 **전혀 쓰지 않은** 데이터

비유: 학습용은 **교재 문제**, 검증용은 **모의고사**(공부 방법 조정), 테스트용은 **실제 시험**입니다.



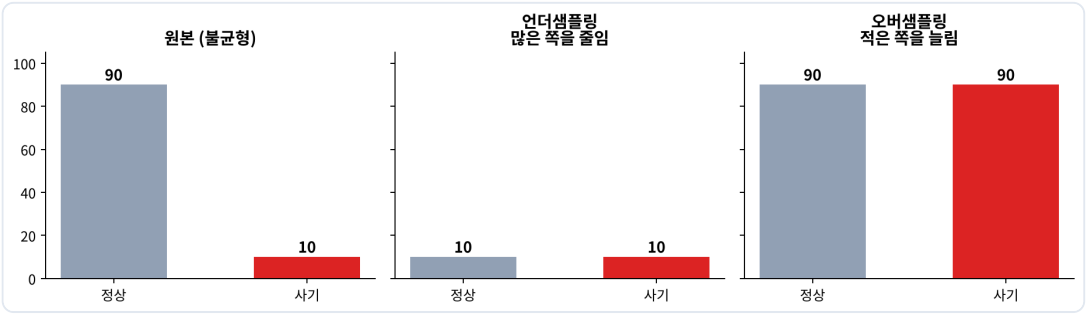
▲ 위: 일반적인 분할과 홀드아웃 / 아래: K-fold는 검증 조각을 돌아가며 바꾼다

- **홀드아웃:** 전체를 랜덤하게 **한 번** 나눕니다(예: 학습 80%, 테스트 20%).
- **K-fold 교차검증:** k개로 나눠 **k−1개로 학습, 1개로 검증**을 k번 반복하고 평균합니다.
- **부트스트랩:** 원본 크기만큼 **복원추출**(뽑은 것을 다시 넣고 뽑음)로 표본을 만듭니다. 같은 데이터가 여러 번 뽑힐 수 있습니다.

부트스트랩에서 한 번도 안 뽑힐 확률 = $(1 - 1/n)^n \approx 36.8\%$

- 한 번 뽑을 때 특정 데이터가 안 뽑힐 확률은 $1 - 1/n$입니다. n번 뽑는 동안 계속 안 뽑혀야 하므로 n번 곱합니다.

범주 불균형: 한 범주가 너무 적으면 모델이 그 범주를 제대로 학습하지 못합니다. 예: 사기 1건, 정상 999건이면 "전부 정상"이라고만 해도 정확도 99.9%입니다.



▲ 언더샘플링은 많은 쪽을 줄이고, 오버샘플링은 적은 쪽을 늘린다

- 해결: 많은 쪽을 줄이는 **언더샘플링**, 적은 쪽을 늘리는 **오버샘플링**

시험에는 이렇게 나옵니다 · 출제 유형과 함정

- **분류 정의:** "이미 분류된 데이터로 새 데이터가 속할 그룹을 예측" → 맞음
- **분류 모형이 아닌 것** → **다중 회귀분석** (Y가 숫자)
- "군집분석은 미래 값을 **예측**하는 기법" → 틀림
- **프로세스 순서:** 목적 정의 → 데이터 준비 → 가공 → 기법 적용 → 검증. **준비와 가공**, **가공과 기법 적용**의 순서를 바꾼 보기가 나옵니다.
- **데이터 분할:**
- "**검증용** 데이터로 최종 성능 평가" → 틀림 (테스트용)
- "학습용에 가장 많은 비율" → 맞음. "세 데이터는 항상 **같은 비율**" → 틀림
- "**테스트용**으로 파라미터 학습" → 틀림
- **부트스트랩:** 한 관측값이 한 번도 안 뽑힐 확률 → $(1 - 1/d)^d$
- **범주 불균형:** 특정 범주가 너무 적어 학습이 안 되는 현상 → **범주 불균형** (과소적합·과대적합·기울기 소실과 구분)

2단원 분류 ① 로지스틱 회귀·의사결정나무

한 문장 요약: 로지스틱 회귀는 회귀식으로 "Y = 1일 **확률**"을 계산해 분류하고, **의사결정나무**는 질문(분리 규칙)으로 데이터를 계속 나눠 분류합니다. 둘 다 **매회** 나옵니다.

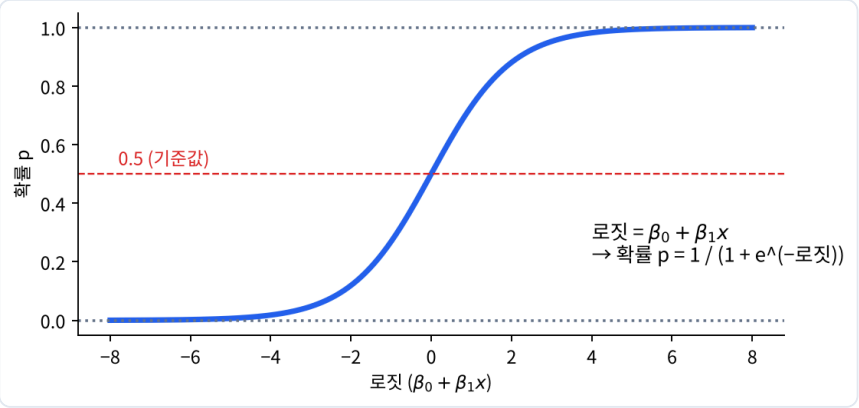
1. 로지스틱 회귀

- 종속변수 Y가 **범주형**(성공/실패, 합격/불합격)일 때 쓰는 회귀입니다. 결과는 **"Y = 1일 확률"**(0~1)이고, 보통 0.5를 기준으로 분류합니다.
- 예: **마케팅 성공 여부**, 대출 연체 여부. (주택 가격·제품 수명처럼 Y가 숫자면 일반 회귀)

오즈 → 로짓 → 시그모이드

용어	뜻	범위
오즈 (Odds)	p ÷ (1 − p): 성공 확률이 실패 확률의 **몇 배**인가	0 ~ ∞
로짓 (Logit)	log(오즈) = $\beta_0 + \beta_1 x$: 직선식으로 쓸 수 있게 만든 값	−∞ ~ ∞
시그모이드	로짓을 **다시 확률로** 되돌리는 함수	**0 ~ 1**

- **x가 1 늘면:** 로짓은 β_1**만큼** 늘고, 오즈는 **e^β_1배**가 됩니다.
- **연결 함수는 로짓**이고, 시그모이드는 그 **역함수**입니다. 둘을 바꿔 쓴 보기가 단골 함정입니다.



▲ 시그모이드 곡선: 어떤 값을 넣어도 0~1 사이 확률이 나온다

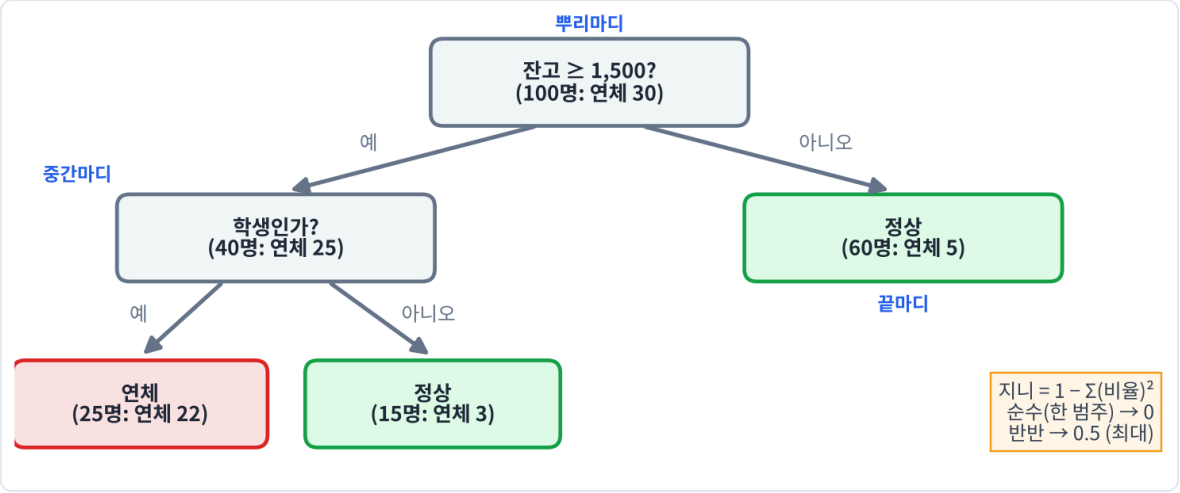
R 출력 읽기

```
glm(default ~ student + balance, family = binomial, data = credit)
             Estimate  Std. Error  z value  Pr(>|z|)
(Intercept) -10.6000     0.4918   -21.553   <2e-16 ***
studentYes   -0.7000     0.2839    -2.466   0.0137 *
balance       0.0056     0.0002    24.348   <2e-16 ***
```

- `family = binomial`이 로지스틱 회귀입니다.
- **계수 부호로 방향을 읽습니다.** balance가 **양수** → 잔고가 늘면 연체 확률 **증가**. studentYes가 **음수** → 같은 잔고면 학생이 연체 확률이 **낮음**.
- 계수 크기가 아무리 작아도(예: 0.00002) 양수면 증가 방향입니다.

2. 의사결정나무

- 데이터를 **질문(분리 규칙)으로 계속 나눠서** 분류하거나 예측합니다. Y가 범주형이면 **분류나무**, 숫자면 **회귀나무**입니다.
- 아래로 내려갈수록 각 마디가 한 범주로 **순수해지도록**(불순도 ↓) 나눕니다.



▲ 질문을 따라 내려가며 분류하는 나무 구조 (뿌리 → 중간 → 끝마디)

분리 기준: 나눈 뒤 불순도가 가장 크게 줄어드는 쪽

Y	분리 기준	방향
범주형 (분류나무)	**카이제곱 통계량**	p값이 **가장 작은** 쪽
	지니 지수	지니 지수가 **가장 작아지는** 쪽
	엔트로피 지수	엔트로피가 **가장 작아지는** 쪽
연속형 (회귀나무)	F 통계량, **분산 감소량**	p값 최소, 분산 감소 최대

지니 지수 = 1 − Σ(각 범주 비율)²는 섞인 정도(**불순도**)입니다.

- 한 범주만 있으면(**순수**) $1 - 1^2 = 0$입니다. 이때 엔트로피도 **0**입니다.
- 두 범주가 반반이면 $1 - (0.5^2 + 0.5^2) = 0.5$입니다.
- **낮을수록 순수**합니다.

정지 규칙: 더 나눠 봐야 소용없을 때 멈춥니다. 불순도 감소량(정보 이득)이 기준보다 **작을 때**, 마디의 자료 수가 기준 **이하**일 때, 나무 깊이가 **최대치**에 이르렀을 때입니다.

가지치기: 너무 자란 가지를 잘라 **과적합을 막습니다.** 학습 데이터 정확도는 조금 떨어질 수 있지만 **새 데이터 성능**(일반화)이 좋아집니다.

장점	단점
해석이 쉬움, 정규성·선형성 **가정이 필요 없음**, 이상값에 덜 민감	**과적합**되기 쉬움, 분류 경계 근처에서 오차가 큼

시험에는 이렇게 나옵니다 · 출제 유형과 함정

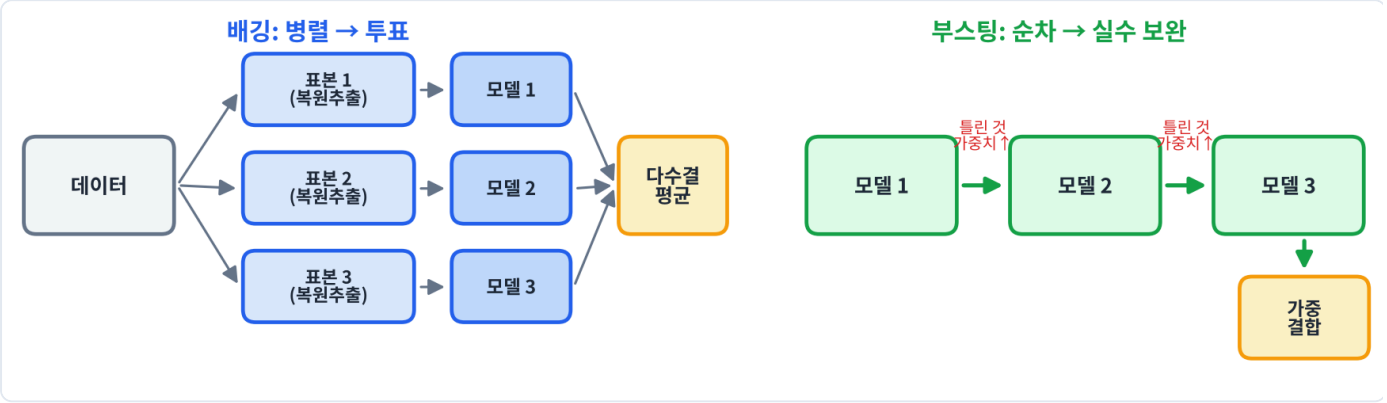
- **로지스틱:**
- 적용 사례 → **성공/실패 여부 예측**
- x 1 증가 시 로짓은 **β만큼** 증가 (예: 계수 0.6이면 로짓 0.6 증가). "e^0.6배"는 **오즈**의 변화
- 시그모이드 출력 범위 → **0 < y < 1**
- "연결 함수로 **시그모이드**를 사용" → 틀림 (연결 함수는 **로짓**)
- R 출력 해석: 계수가 **양수**인데 "증가할수록 확률 **감소**" → 틀림
- **의사결정나무:**
- "**지니 지수가 최대**가 되는 방향으로 분리" → 틀림
- 한 범주만 있는 마디의 지니·엔트로피 → **0, 0**
- "지니 지수가 낮을수록 불순도 **높음**" → 틀림
- 분류나무 기준이 **아닌** 것 → **잔차 제곱합**
- "가지치기로 **학습 데이터** 정확도를 높인다" → 틀림
- 정지 규칙: "정보 이득이 임계값을 **초과하면** 정지" → 틀림 (작을 때 정지)
- "연속형이면 학습 데이터 정확도 **항상 100%**" → 틀림

3단원 분류 ② 앙상블·인공신경망·나이브 베이즈·k-NN·SVM

한 문장 요약: 모델 하나보다 **여럿을 합치면** 더 정확합니다(**앙상블**). 사람 뇌를 흉내 낸 **인공신경망**은 활성화 함수가 핵심이고, **SVM**은 두 그룹 사이의 **여백(마진)을 최대로** 하는 선을 긋습니다.

1. 앙상블: 여러 모델의 힘을 합치기

- 음악의 합주처럼 **여러 모델을 만들어 결합**해 예측력을 높입니다. 결과가 **숫자면 평균, 범주면 다수결(보팅)**로 정합니다.
- 개별 모델들이 서로 **다를수록**(상관이 낮을수록) 효과가 큽니다. 비슷한 모델끼리 모으면 효과가 없습니다.
- 앙상블이 **항상** 단일 모델보다 좋은 것은 아니고, 모델이 여러 개라 **해석은 더 어렵습니다.**



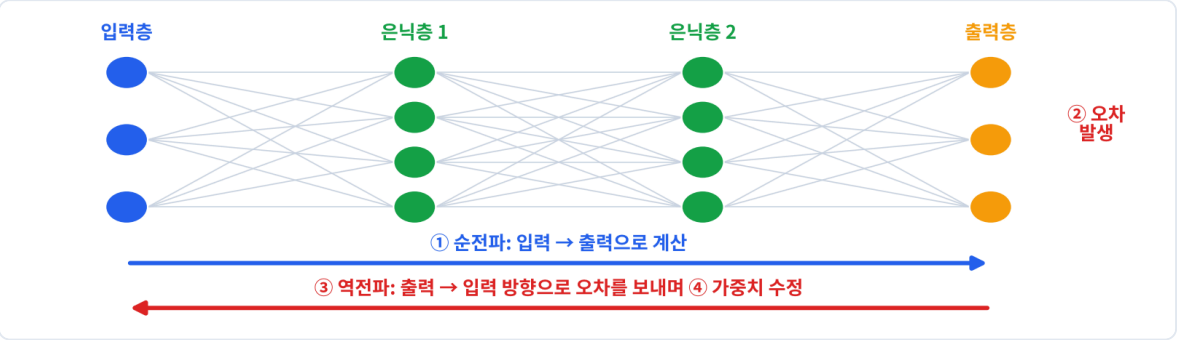
▲ 배깅은 동시에 따로 학습해 투표하고, 부스팅은 앞 모델의 실수를 보완하며 차례로 학습한다

	배깅 (Bagging)	부스팅 (Boosting)	랜덤 포레스트
방식	**부트스트랩**(복원추출) 표본 여러 개로 모델을 **독립적(병렬)**으로 학습 → 보팅	모델을 **순차적**으로 학습. 앞 모델이 **잘못 분류한 데이터에 더 큰 가중치**	배깅 + 마디마다 **변수도 무작위로** 뽑아 분할
비유	여러 학생이 **각자** 공부해 다수결	한 학생이 **틀린 문제에 별표** 치며 반복 공부	학생마다 **다른 과목**만 공부시켜 다수결
예		AdaBoost, GBM, XGBoost	의사결정나무 여러 그루

- **부트스트랩:** 크기 d인 데이터에서 복원추출로 d개를 뽑을 때, 어떤 관측값이 한 번도 안 뽑힐 확률은 $(1 - 1/d)^d$(약 36.8%)입니다.

2. 인공신경망 (ANN)

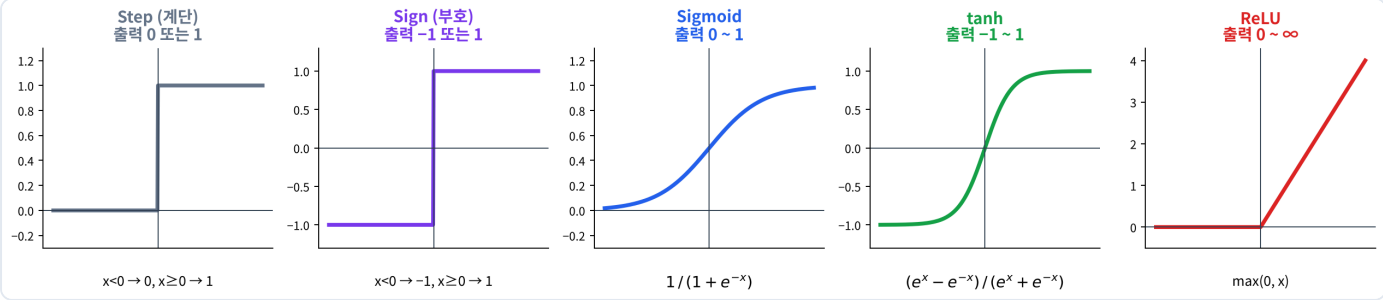
- 입력값에 **가중치(w)**를 곱해 더하고, **활성화 함수**를 거쳐 다음 층으로 보냅니다.
- 출력의 오차를 출력층 → 입력층 방향으로 거슬러 보내며 가중치를 고치는 것이 **역전파**입니다.



▲ 순전파로 계산해 오차를 구하고, 역전파로 오차를 거꾸로 보내며 가중치를 고친다

장점	단점
복잡한 **비선형** 패턴을 스스로 학습, 예측 정확도가 높음, 잡음에 강함	**결과 해석이 어려움**(블랙박스, 가중치로 설명 불가), 은닉층·노드 수를 정하기 어려움, 과적합

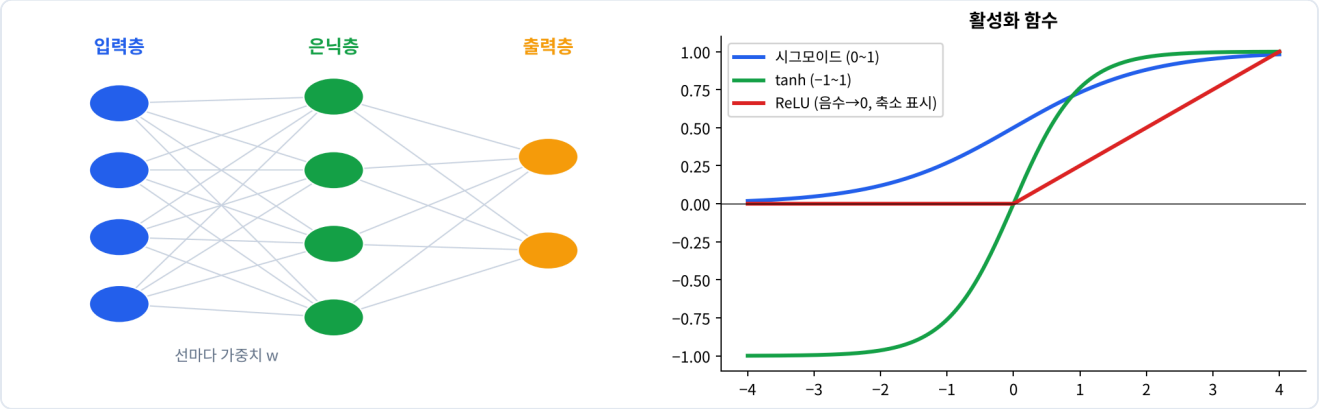
활성화 함수 (함수식이나 출력 범위로 **이름을 맞히는** 문제가 나옵니다)



▲ 활성화 함수의 모양과 식. 출력 범위로 구분한다

함수	출력	특징
Step (계단)	**0 또는 1**	임계값 기준으로 0 또는 1
Sigmoid	**0 ~ 1**	로지스틱 회귀와 같은 모양. 이진 분류 출력
tanh	**−1 ~ 1**	시그모이드를 늘린 모양, 중심값 0
ReLU	**0 ~ ∞**	max(0, x). 음수면 0. **기울기 소실**을 막아 딥러닝에서 가장 많이 씀
Softmax	0 ~ 1, **합 = 1**	**다중 클래스** 출력층. 식에 분모 **Σ**(모두 더하기)가 있음

구조와 계산

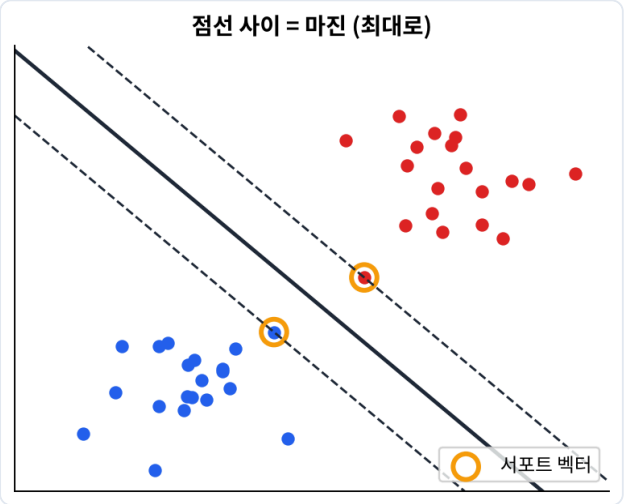


▲ 왼쪽: 입력층 → 은닉층 → 출력층 / 오른쪽: 주요 활성화 함수

- **입력층 노드 수 = 입력 변수 수, 출력층 노드 수 = 출력 범주 수**입니다. 은닉층마다 노드 수가 **같을 필요는 없습니다.**
- **가중치 개수:** 선(연결)마다 하나입니다. 입력 20, 은닉 50, 출력 3이면 20 × 50 + 50 × 3 = **1,150개**입니다(편향 제외).
- 은닉층·노드가 **너무 적으면** 과소적합, **너무 많으면** 과적합입니다.
- **기울기 소실:** 은닉층이 **너무 깊으면** 역전파 때 기울기가 0에 가까워져 앞쪽 층이 학습되지 않습니다.
- 은닉층 없이 출력 노드 1개에 **시그모이드**를 쓰면 **로지스틱 회귀**와 같아집니다(ReLU는 아님).

3. 나이브 베이즈, k-NN, SVM

기법	핵심
나이브 베이즈	**베이즈 정리**로 각 범주에 속할 확률을 구해 큰 쪽으로 분류. 변수들이 **서로 독립**이라고 단순하게(naive) 가정. 스팸 메일 필터링에 씀
k-NN (k-최근접 이웃)	새 데이터와 **가장 가까운 k개** 이웃의 다수결로 분류. **k에 따라 결과가 달라짐**. 미리 모델을 만들지 않는 **게으른 학습**
SVM (서포트 벡터 머신)	두 범주 사이 **마진(여백)이 최대**인 초평면으로 분류. 경계에 가장 가까운 점이 **서포트 벡터**. 직선으로 안 나뉘면 **커널 함수**로 **고차원**에 보내서 나눔



▲ SVM: 두 그룹 사이 여백(마진)이 가장 넓은 경계선을 찾는다

시험에는 이렇게 나옵니다 · 출제 유형과 함정

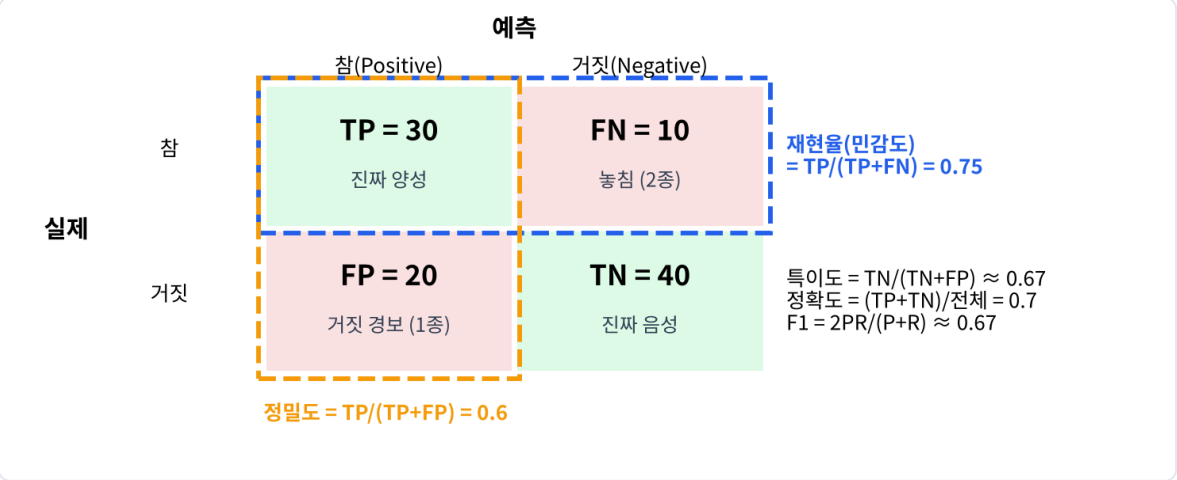
- **앙상블 (매회 나옴):**
- "부스팅은 잘못 분류된 데이터에 **더 큰 가중치**", "부스팅은 이전 모델의 오차를 보완하며 **순차** 학습" → 맞음

- "부스팅은 **병렬** 학습 후 보팅" → 틀림 (배깅). "배깅은 **순차** 학습" → 틀림
- "부스팅은 개별 모델에 **동일한 가중치**" → 틀림
- "개별 모델 간 **상관이 높을수록** 정확도 향상" → 틀림
- "앙상블은 **항상** 단일 모형보다 정확", "랜덤 포레스트는 앙상블이 **아니다**" → 틀림
- **부트스트랩:** 한 관측값이 한 번도 안 뽑힐 확률 → $(1 - 1/d)^d$
- **신경망:**
- 신호의 합을 출력값으로 변환하는 함수 → **활성화 함수**
- 다중 클래스 출력 → **소프트맥스**. 소프트맥스 식 고르기 (분모에 Σ)
- "**tanh** 출력은 0~1" → 틀림 (−1~1)
- 가중치 개수 계산 (입력×은닉 + 은닉×출력)
- "**설명력 있는 가중치**를 산출" → 틀림 (해석 어려움)
- "모든 은닉층은 노드 수가 **같아야**" → 틀림
- "**ReLU**로 은닉층 없는 신경망 = 로지스틱" → 틀림 (시그모이드일 때)
- 노드는 줄이고 은닉층을 늘리면 → **기울기 소실**
- **SVM:** "커널은 고차원을 **저차원**으로 변환" → 틀림 (저차원 → 고차원)
- **알고리즘 짝짓기:** 로짓·시그모이드로 확률 → 로지스틱, 마진 최대 → SVM, 가까운 K개 이웃의 다수결 → KNN

4단원 분류 모형 성과 평가: 오분류표·ROC

한 문장 요약: 분류 결과를 **오분류표**(혼동행렬)로 정리해 정확도·정밀도·재현율·F1을 계산하고, **ROC 커브**로 모델을 비교합니다. **계산 문제가 매회 나옵니다.**

1. 오분류표 (혼동행렬, Confusion Matrix)



▲ 오분류표와 지표: 정밀도는 "예측" 기준(세로), 재현율은 "실제" 기준(가로)

읽는 법: 뒤 글자(P/N)는 **예측**, 앞 글자(T/F)는 **맞았는지**입니다. FP = "Positive라고 했는데(P) 틀렸다(F)"

지표	식	뜻
정확도 (Accuracy)	(TP + TN) ÷ 전체	전체 중 **맞힌** 비율
오분류율 (Error Rate)	(FN + FP) ÷ 전체 = 1 − 정확도	전체 중 **틀린** 비율
재현율 = 민감도 (Recall)	TP ÷ (TP + FN)	**실제 참** 중 참으로 맞힌 비율
정밀도 (Precision)	TP ÷ (TP + FP)	**참이라고 예측한 것** 중 실제 참 비율
특이도 (Specificity)	TN ÷ (FP + TN)	**실제 거짓** 중 거짓으로 맞힌 비율
F1 Score	2 × 정밀도 × 재현율 ÷ (정밀도 + 재현율)	정밀도와 재현율의 **조화평균**. 데이터가 **불균형**할 때 유용

- **비유:** 정밀도 = 스팸이라고 걸러 낸 메일 중 진짜 스팸 비율, 재현율 = 진짜 스팸 중 걸러 낸 비율
- **F1 빠른 계산:** F1 = 2TP ÷ (2TP + FP + FN)

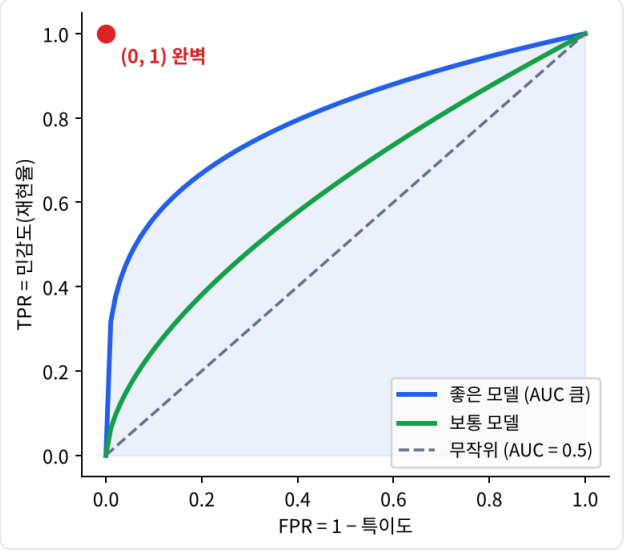
계산 연습 (교재 예제)

	예측 1 (True)	**예측 0 (False)**	**합계**
실제 1 (True)	950 (TP)	50 (FN)	1,000
실제 0 (False)	150 (FP)	850 (TN)	1,000
합계	1,100	900	2,000

- 정확도 = (950 + 850) ÷ 2,000 = **0.9**, 오분류율 = 200 ÷ 2,000 = **0.1**
- 민감도(재현율) = 950 ÷ 1,000 = **0.95**, 특이도 = 850 ÷ 1,000 = **0.85**
- 정밀도 = 950 ÷ 1,100 ≈ **0.864**
- F1 = 2 × 950 ÷ (2 × 950 + 150 + 50) = 1,900 ÷ 2,100 ≈ **0.905**

> **외우기: 정밀도는 "예측한 것 중"(세로), 재현율·민감도는 "실제 것 중"(가로)**입니다. 문제마다 행과 열의 배치가 다르므로 **어느 쪽이 실제인지 먼저 확인**하세요.

2. ROC 커브



▲ ROC 곡선: 왼쪽 위(0, 1)에 가까울수록 좋은 모델

- **x축 = 1 − 특이도 (FPR)**, **y축 = 민감도 (TPR)**입니다.
- **완벽한 모델은 (0, 1)**, 즉 왼쪽 위 모서리를 지납니다. 거짓 경보는 0이고 진짜를 모두 찾습니다.
- 곡선 아래 넓이 **AUC**가 **1에 가까울수록** 좋고, **0.5**면 무작위 수준(대각선)입니다.

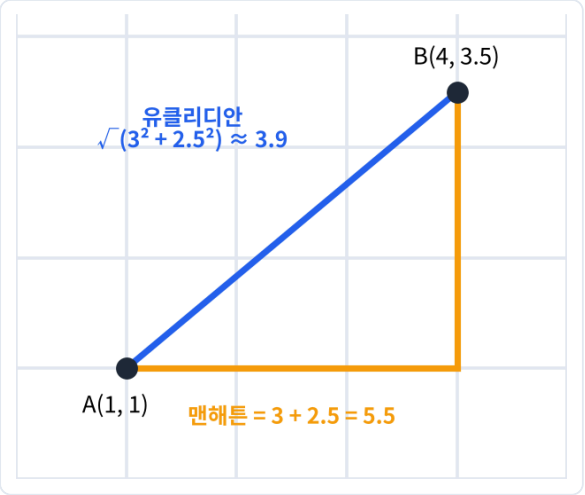
시험에는 이렇게 나옵니다 · 출제 유형과 함정

- **지표 정의:** 참이라고 예측한 것 중 실제 참 → **정밀도**. 실제 참 중 참으로 예측 → **재현율(민감도)**. 정밀도와 재현율의 조화평균 → **F1**
- **계산 (매회):** 오분류표를 주고 민감도·F1·오분류율을 구합니다. 표의 **행/열이 실제인지 예측인지** 먼저 확인합니다.
- 민감도: 분모를 예측 열로 잡으면 정밀도가 되는 함정
- 오분류율: **대각선이 아닌** 두 칸의 합 ÷ 전체
- **ROC:** x축 1 − 특이도, y축 민감도인 그래프 → **ROC 커브** (PR 커브·이익 곡선과 구분). 가장 좋은 점 → **(0, 1)**

5단원 군집 분석

한 문장 요약: 군집 분석은 정답 없이 **비슷한 것끼리 묶는** 비지도 학습입니다. "비슷하다"를 **거리**로 재고, 묶는 방법으로 **계층적 군집**(차례로 합침)과 **비계층적 군집**(K-means, 혼합분포, SOM, DBSCAN)이 있습니다.

1. 거리 척도



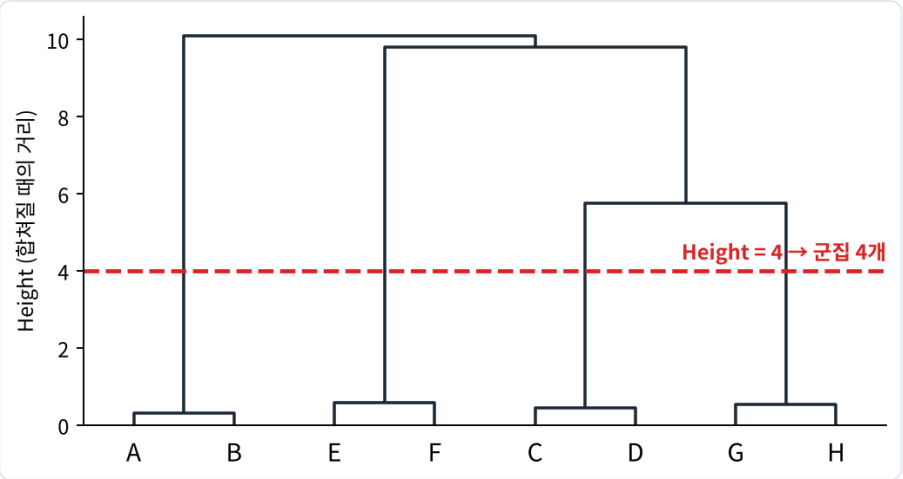
▲ 맨해튼 거리(길 따라)는 유클리디안 거리(직선)보다 항상 크거나 같다

자료	거리	설명
연속형	**유클리디안**	두 점 사이 **직선거리** (가장 짧은 거리)
	맨해튼	각 좌표 차이의 **절댓값을 더한** 거리. 바둑판 길을 따라 간 거리라 유클리디안보다 **크거나 같음**
	체비셰프	좌표 차이 중 **가장 큰 값**
	표준화 거리	변수별 표준편차로 나눠 **단위 차이**를 없앰
	마할라노비스	변수 간 **상관관계까지 고려**한 통계적 거리
범주형	**자카드**	두 집합에서 **겹치는 비율**(같으면 1, 완전히 다르면 0)

- **자카드는 범주형용**이므로 연속형 거리가 아닙니다. 범주형 변수도 이런 거리를 쓰면 군집 분석을 **할 수 있습니다.**

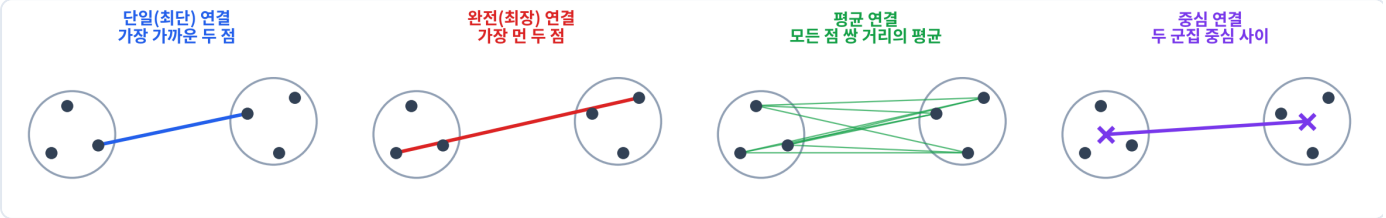
2. 계층적 군집

- 가까운 것끼리 **하나씩 합쳐 가며** 나무 모양(**덴드로그램**)을 만듭니다.
- 군집 수를 **미리 정하지 않아도** 됩니다. 덴드로그램을 보고 원하는 높이에서 자릅니다.
- 계산 규칙이 정해져 있어 같은 데이터·같은 방법이면 결과가 **항상 같습니다.** 한 번 합쳐진 군집은 **다시 나뉘지 않습니다.**



▲ 덴드로그램: 높이에서 가로선을 그으면 그 선과 만나는 세로선 수가 군집 수

군집 간 거리 (연결법) (교재 TIP: 각 연결법과 설명을 **짝지을 수** 있어야 합니다)

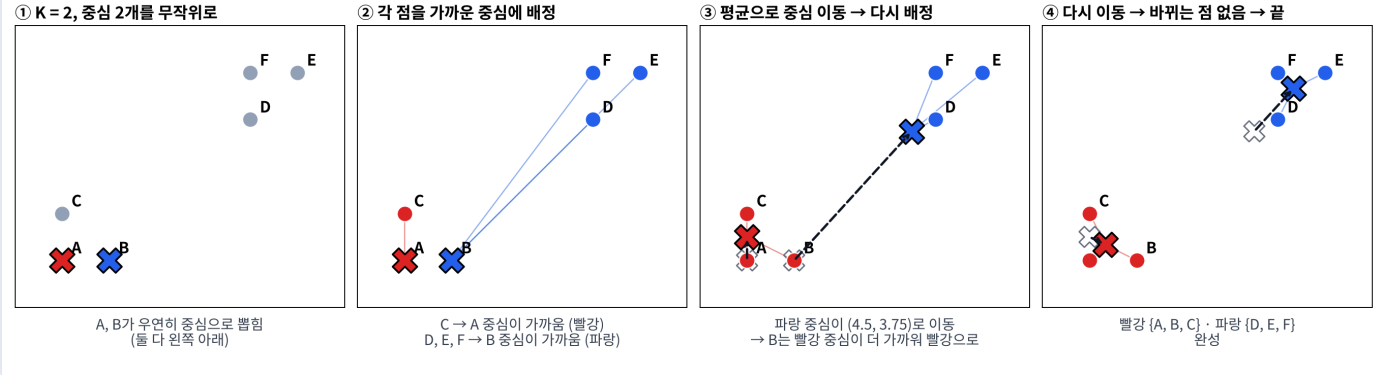


▲ 두 군집 사이의 거리를 무엇으로 볼까

연결법	두 군집 사이 거리
단일 (최단)	가장 **가까운** 두 점 사이 거리
완전 (최장)	가장 **먼** 두 점 사이 거리 (이상값에 민감)
평균	모든 점 쌍 거리의 **평균**
중심	두 군집 **중심** 사이 거리
와드	합쳤을 때 **군집 내 오차제곱합(SSE) 증가가 최소**인 쌍을 합침 (자주 나옴)

3. 비계층적 군집

① K-means (K-평균)



▲ K-means 예: 점 6개, K = 2. 중심을 무작위로 정하고 → 가까운 중심에 배정 → 군집 평균으로 중심 이동을 바뀌는 점이 없을 때까지 반복

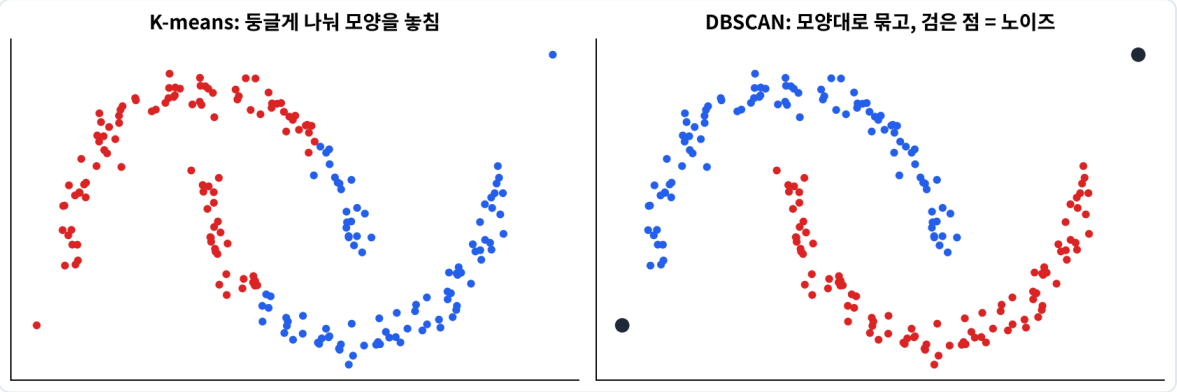
1. 군집 수 **K를 사람이 미리 정합니다.** 알고리즘이 자동으로 정해 주지 않습니다.
2. 데이터 중 **K개를 무작위로 골라** 초기 중심으로 삼습니다.
3. 각 데이터를 가장 가까운 중심에 배정합니다.

4. 군집별 평균으로 중심을 다시 계산하고, 변화가 없을 때까지 3~4를 반복합니다.

- **초기 중심에 따라 결과가 달라집니다.** 이상값에도 민감합니다.
- 정답(반응변수) 없이 구조를 찾는 **비지도 학습**의 대표 기법입니다.

② 혼합분포 군집, SOM, DBSCAN

기법	핵심
혼합분포 군집	데이터가 여러 **정규분포가 섞여** 나왔다고 보고 각 분포의 평균·분산·비중을 추정. 추정 방법은 **EM 알고리즘**(E: 소속 기댓값 계산 → M: 모수 다시 추정, 반복)
SOM (자기조직화지도)	코호넨이 만든 **비지도 신경망**. 고차원 데이터를 **2차원 격자(경쟁층)**로 줄여 시각화(차원 축소 + 군집화). 입력층과 경쟁층은 **완전 연결**. 입력과 가장 가까운 **승자 노드(BMU)**가 학습. **역전파 없이** 순전파만 써서 빠름. 노드마다 배정되는 데이터 수는 **같지 않음**
DBSCAN	**밀도** 기반. 빽빽하게 모인 곳을 군집으로 봄. **임의의 모양**(반달 등) 군집 가능, **K를 정할 필요 없음**, 외톨이 점은 **노이즈**로 구분. 계층적 방법이 **아님**



▲ 길쭉하거나 휘어진 모양은 K-means보다 DBSCAN이 잘 묶는다

시험에는 이렇게 나옵니다 · 출제 유형과 함정

- **거리:**
- 연속형 거리가 **아닌** 것 → **자카드**
- 상관관계를 고려한 통계적 거리 → **마할라노비스**
- "맨해튼은 항상 유클리디안보다 **작거나 같다**" → 틀림 (**크거나 같다**)
- "입력변수가 **범주형**이면 군집 분석 불가" → 틀림
- **계층적:**
- SSE 증가가 최소인 쌍을 합침 → **와드 연결법** (47·48·49회 연속)
- 연결법 짝짓기: 가장 먼 거리 → 완전, 중심 사이 → 중심, 가장 가까운 거리 → 단일
- 덴드로그램에서 Height = h에 가로선을 긋고 **만나는 세로선 수 = 군집 수**
- "최장연결법 결과는 다시 하면 **달라질 수 있다**" → 틀림
- **K-means:**
- "K를 **자동으로** 선택" → 틀림
- "초기 중심은 결과에 **영향 없음**" → 틀림
- 초기 중심 → **무작위로 고른 K개 관측점**
- 반응변수 없이 구조를 탐색하는 기법 → **K-평균 군집**
- **혼합분포:** 최대가능도추정을 보완하는 기법 → **EM 알고리즘**
- **SOM:** "**부분적으로(locally)** 연결" → 틀림 (완전 연결). "경쟁층 모든 노드에 **같은 수**의 데이터" → 틀림
- **DBSCAN:** "군집 간 거리로 단계적으로 병합하는 **계층적** 방법" → 틀림 (밀도 기반)

6단원 연관 분석

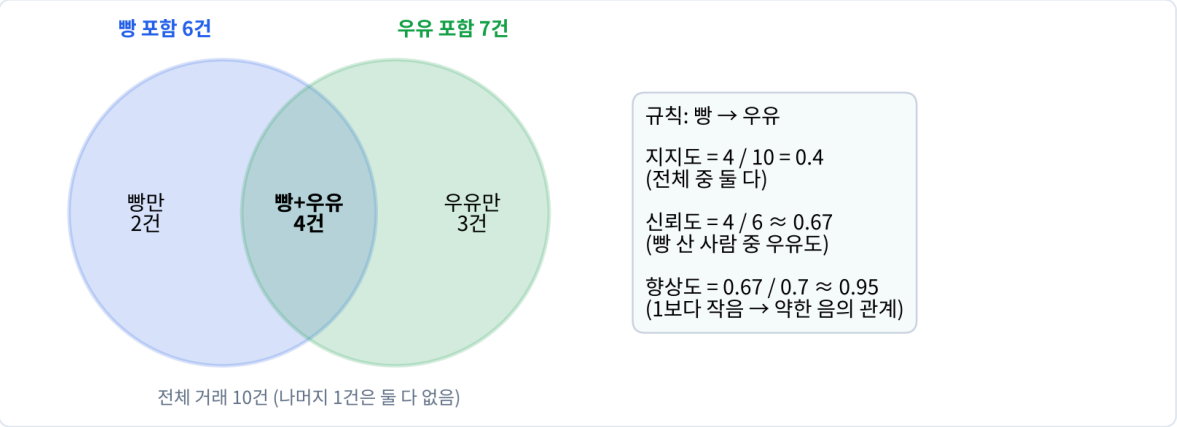
한 문장 요약: "빵을 사면 우유도 산다"처럼 **함께 일어나는 규칙**을 찾는 분석입니다(장바구니 분석). **지지도·신뢰도·향상도** 세 가지 계산이 **매회 1~3문항** 나옵니다.

1. 연관 분석 개요

- **장바구니 분석**이라고도 합니다. 고객의 구매 패턴에서 "빵을 산 고객은 우유도 살 확률이 높다" 같은 규칙을 찾습니다. 결과는 **IF ~ THEN ~** 형태로 해석합니다.
- **탐색적 기법**이라 결과를 이해하기 쉽고, 특별한 분석 목적(목적변수) 없이 쓰는 **비지도 학습**입니다. 사용이 편하고 계산이 간단합니다.
- 품목 수가 늘면 계산량이 **기하급수적으로** 늘어납니다. 그래서 비슷한 품목을 하나의 범주로 묶어 일반화하기도 합니다. 반대로 품목을 너무 세분화하면 의미 없는 규칙이 나옵니다.

2. 연관 분석의 측도

교재 TIP: 측도를 **직접 계산하는 문제가 자주** 나옵니다. 규칙은 무수히 많이 생기지만 모두 유용하지는 않으므로, 측도로 **의미 있는 규칙인지** 확인합니다.



▲ 거래 10건 예시로 보는 지지도 · 신뢰도 · 향상도

규칙 **A → B** ("A를 사면 B도 산다")에 대해:

측도	식	뜻
지지도 (Support)	P(A∩B) = **A와 B를 함께 포함한 거래 수 ÷ 전체 거래 수**	두 품목이 얼마나 **자주 같이** 팔리나
신뢰도 (Confidence)	P(B|A) = P(A∩B) ÷ P(A) = 함께 포함한 거래 수 ÷ **A를 포함한 거래 수**	A를 산 사람 중 B도 산 비율 (조건부 확률)
향상도 (Lift)	신뢰도(A→B) ÷ P(B) = P(A∩B) ÷ (P(A) × P(B))	A를 샀다는 정보가 B 구매 확률을 **몇 배** 높이나

- **방향을 바꾸면:** 신뢰도(A→B)와 신뢰도(B→A)는 **다릅니다**(분모가 바뀜). **지지도와 향상도는 같습니다**(식이 대칭).

향상도	뜻	관계
< 1	A를 사면 B를 살 확률이 **감소**	음의 상관관계
= 1	B를 살 확률에 **변화 없음**	관계없음 (독립)
> 1	A를 사면 B를 살 확률이 **증가**	양의 상관관계

그림으로 계산하기 (A = 빵, B = 우유) · 전체 10건, 빵 포함 6건, 우유 포함 7건, 둘 다 4건, 둘 다 없음 1건

측도	계산	값
지지도	둘 다 4 ÷ 전체 10	**0.4**
신뢰도 (빵 → 우유)	둘 다 4 ÷ **빵 포함** 6	**약 0.67**
향상도	신뢰도 0.67 ÷ P(우유) 0.7	**약 0.95**

- 빵을 산 사람의 67%가 우유도 샀지만, 원래 우유는 70%가 삽니다. 그래서 향상도가 1보다 조금 작습니다(약한 음의 관계). **신뢰도가 높아도 향상도는 1보다 작을 수 있으므로** 세 측도를 함께 봅니다.
- **분모는 전체 거래 수**입니다. 빵도 우유도 사지 않은 1건도 전체 10건에 포함합니다.
- **"빵 포함"은 빵이 들어 있는 모든 거래**입니다. 빵만 산 2건이 아니라 빵만 2건 + 빵·우유 4건 = 6건입니다.

3. 연관 분석의 알고리즘

- 가능한 모든 조합을 다 따지면 품목 수가 늘수록 계산 시간이 기하급수적으로 늘어납니다.
- Apriori는 **지지도**로 **빈발 항목 집합**(자주 나오는 품목 조합)을 가려내 계산을 줄입니다. 원리는 "어떤 집합이 빈발하지 않으면, 그 집합을 포함한 **더 큰 집합도 빈발할 수 없다**"입니다.

단계	하는 일
1	**최소 지지도**를 정함
2	최소 지지도보다 큰 **단일 품목**을 고름
3	고른 단일 품목으로 **2개짜리** 규칙을 만들고, 최소 지지도 이상인 것을 찾음
4	같은 과정을 반복해 **3개 이상** 품목의 규칙을 만들며 의미 있는 결과를 찾음

4. 연관 분석의 특징

장점	단점
결과가 **단순하고 분명**함 (IF ~ THEN ~)	**품목 세분화**가 어려움
분석을 위한 **계산이 간단**함	품목 수가 늘면 계산량이 **기하급수적으로** 증가
목적변수가 없어 데이터 탐색에 쓸 수 있음	**거래가 없는 품목**은 분석할 수 없음

- **품목 세분화 문제:** "빵을 사면 유제품을 산다"는 의미 있는 규칙이 있어도, 유제품을 우유·요구르트·치즈로 너무 잘게 나누면 이 규칙을 찾지 못할 수 있습니다.

시험에는 이렇게 나옵니다 · 출제 유형과 함정

- **정의:** A → B의 지지도 → **전체 중 A와 B를 동시에 포함한 비율**
- **계산 (매회):** 거래표나 품목별 거래 건수로 지지도·신뢰도·향상도를 구합니다. 신뢰도는 **분모가 A(조건)**입니다. 품목의 구매율은 그 품목이 **포함된 모든 거래**를 더해서 구합니다.
- **함정:**
- 지지도를 신뢰도로 착각하는 보기 → 신뢰도는 지지도 ÷ P(A)
- "방향을 바꿔도 **신뢰도는 그대로**" → 틀림 (지지도·향상도가 그대로)
- "향상도 > 1이면 양의 상관", "향상도 = 1이면 독립" → 맞음
- "일반적으로 지지도보다 **신뢰도가 더 중요**" → 틀림
- **Apriori:** 최소 지지도를 주고 가장 긴 빈발 항목집합을 찾는 문제가 나옵니다. 1개짜리 → 2개짜리 → 3개짜리 순서로, 최소 지지도에 못 미치는 것을 지워 가며 셉니다.